

Analyse en composantes principales

1

INTRODUCTION

Tableaux individus/variables : Premier exemple.

Tour de hanche et poids de 500 individus¹ :


Tour de hanches (cm)	Poids (kg)
93.5	65.6
94.8	71.8
⋮	⋮
95.0	80.7

1. G. Heinz, L.J. Peterson, R.W. Johnson et C.J. Kerk, «Exploring Relationships in Body Dimensions»' *Journal of Statistics Education* Volume 11, Number 2 (2003).
www.amstat.org/publications/jse/v11n2/datasets.heinz.html

Deux variables : représentation dans le plan

- liens entre variables
- groupes d'individus.

Tour de hanches et poids :



- Lien entre les deux variables (alignement approximatif des points)
- Deux groupes distincts femmes/hommes.

Individus/variables : Deuxième exemple.

Composition de 45 poteries trouvées en Grande Bretagne datant de l'époque romaine². 5 fours différents.

$$X \in \mathbb{R}^{45 \times 9} :$$

PAI ₂ O ₃	Fe ₂ O ₃	MgO	CaO	Na ₂ O	K ₂ O	TiO ₂	MnO	BaO	Four
18.8	9.52	2	0.79	0.4	3.2	1.01	0.077	0.015	1
16.9	7.33	1.65	0.84	0.4	3.05	0.99	0.067	0.018	1
18.2	7.64	1.82	0.77	0.4	3.07	0.98	0.087	0.014	1
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮
14.8	2.74	0.67	0.03	0.05	2.15	1.34	0.003	0.015	5
19.1	1.64	0.6	0.1	0.03	1.75	1.04	0.007	0.018	5

Ou $X \in \mathbb{R}^{45 \times 10}$ si l'on ajoute le four.

L'analyse de la composition de matériaux est un outil important pour l'étude des échanges dans les économies antiques. Des objets d'origines distinctes ont généralement des signatures chimiques différentes qui permettent d'identifier leur origine. Pour identifier ces signatures il faut être capable de regrouper entre eux des objets de composition similaire.

2. D'après J.Holland Jones et I.G.Robertson, www.stanford.edu/class/anthsci192

En général

Tableau de n individus et p variables, $n > p$ (mieux $n \gg p$).

$$X = \begin{pmatrix} x_1 \\ \vdots \\ x_n \end{pmatrix} = \begin{pmatrix} x_{11} & \dots & x_{1p} \\ \vdots & & \vdots \\ x_{n1} & \dots & x_{np} \end{pmatrix}.$$

Ligne $x_i = x_{i.}$: i -ième individu, point de $\mathbb{R}^p$

Colonne $x_{.k}$: k -ième variable

Attention : Les individus étant représentés par des vecteurs ligne, les calculs matriciels associés à des opérations linéaires seront quelque peu modifiés : par exemple, appliquer une rotation de matrice R à x_i résultera en un nouveau vecteur ligne $(Rx_i^T)^T = x_i R^T$.

Davantage de variables : comment représenter les individus ?

Observation : Si les individus sont concentrés dans un plan de $\mathbb{R}^p$,

—→ représenter dans ce plan.

Mathématiquement : changement de base (rotation) puis représentation des deux premières variables, les autres (de 3 à p) étant nulles.

Idée générale : Si les individus sont tous proches d'un plan,

—→ trouver le plan le meilleur (au sens où la somme des distances des points au plan est la plus petite possible)

—→ représenter les données par la projection sur ce plan.

Qualité recherchée : Les distances entre individus projetés doivent refléter au mieux leurs distances dans $\mathbb{R}^p$. Respecter la géométrie des données.

Remarques diverses

- ▶ Projeter en dimension deux peut être trop grossier. On peut chercher le sous-espace de dimension trois le meilleur
 - représentation des données plus difficile :
en pratique on représentera 2 ou 3 projections en dimension 2.
 - interprétation délicate.
- ▶ Difficulté liée à la normalisation des variables. Si p. ex. $p = 3$, multiplier la 3^e variable par un petit facteur concentrera les individus sur le plan contenant les deux premiers. Dire que les individus sont presque dans un plan *dépend des échelles*.
- ▶ Le bilan sera la création de nouvelles variables appelées **composantes principales**

2

ASPECTS MATHÉMATIQUES DE L'ACP

Problème mathématique

Trouver le plan Π qui minimise

$$\sum_i d(x_i, \Pi)^2 = \sum_i \|x_i - P(x_i)\|^2$$

P : projection orthogonale sur le plan Π .

Recentrage : Soit $\bar{x}$ l'individu moyen, si l'on recentre les variables d'abord

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i \in \mathbb{R}^p,$$

$$X \longleftarrow \begin{pmatrix} x_1 - \bar{x} \\ \vdots \\ x_n - \bar{x} \end{pmatrix}.$$

le problème reste le même sauf que tout est décalé du vecteur $\bar{x}$, et Π devient un plan vectoriel (i.e. $0 \in \Pi$. On admet.), ce qui simplifie énormément les écritures. On supposera ce recentrage préalable fait.

Rappels de calcul matriciel. Notations

- Produit scalaire : $\langle x, y \rangle = x^T y = \sum x_i y_i$
- Transposée : $(AB)^T = B^T A^T$
- P projection orthogonale ssi $P = P^2 = P^T$ (idempotente et symétrique).
Rq : On vérifie facilement qu'alors $(x - Px) \perp Px$
- Matrice orthogonale : $QQ^T = Q^T Q = Id$
- Toute matrice symétrique est diagonalisable dans une base orthogonale :
 $S = QDQ^{-1} = QDQ^T$
- Rang d'une matrice : dimension de l'espace image. $Rg(M) = Rg(M^T)$
- Si $x \in \mathbb{R}^n$ et $y \in \mathbb{R}^p$, $M = xy^T$ est de rang 1. $M_{ij} = x_i y_j$.
- $\|\cdot\|_F$ désigne la norme de Frobenius :

$$\|M\|_F^2 = \sum_{ij} M_{ij}^2 = Tr(M^T M).$$

- Soient a_i des vecteurs ligne et b_j des vecteurs colonne.

$$\text{Si } A = \begin{bmatrix} a_1 \\ \vdots \\ a_n \end{bmatrix}, B = [b_1 \dots b_p], \text{ alors } AB = [Ab_1 \dots Ab_p] = \begin{bmatrix} a_1 B \\ \vdots \\ a_n B \end{bmatrix} = \langle a_i, b_j \rangle_{ij}$$

Point de vue matriciel

Le résultat donnera une approximation de X par une matrice de rang 2 (formée des individus projetés) :

$$\begin{array}{|c|} \hline X \\ \hline \end{array} \simeq c_1 v_1^T + c_2 v_2^T = \begin{array}{|c|} \hline \\ \hline \end{array} \begin{array}{|c|} \hline \\ \hline \end{array} + \begin{array}{|c|} \hline \\ \hline \end{array} \begin{array}{|c|} \hline \\ \hline \end{array}$$

$$\text{Ligne } i : \quad x_i \quad \simeq \quad c_1(i) v_1^T + c_2(i) v_2^T$$

Chaque individu est approché dans le plan engendré par les **axes principaux** v_1 et v_2 , qui seront normés à 1.

Les variables. L'ACP permet aussi de comprendre les liens entre variables. En effet, l'identité $X \simeq c_1 v_1^T + c_2 v_2^T$ exprime que chaque variable, colonne de X , est approximativement combinaison linéaire de c_1 et c_2 .

Réécriture du problème mathématique

Si P est une matrice de projection orthogonale, la projection d'un vecteur ligne x_i est (en colonne) $Px_i^T = (x_i P^T)^T = (x_i P)^T$. En somme, matriciellement en ligne on a $P(x_i) = x_i P$. Le critère vaut

$$\sum_i \|x_i - P(x_i)\|^2 = \sum_i \|x_i - x_i P\|^2$$

et comme, ligne à ligne

$$x_i - x_i P = e_i^T (X - XP) = (X - XP)_i.$$

ceci devient

$$\sum_i \|x_i - P(x_i)\|^2 = \sum_i \|(X - XP)_i\|^2 = \|X - XP\|_F^2$$

Le problème en dimension générale

Il s'agit donc de trouver la matrice P de projection orthogonale sur un espace E de dimension k (p.ex. $k = 2$) qui réalise

$$P = \arg \min_{\text{Rang}(P) \leq k} \|X - XP\|_F^2, \quad (1)$$

La décomposition en valeurs singulières sera l'instrument central pour résoudre ce problème.

La SVD (Singular value decomposition)

La décomposition en valeurs singulières permet d'écrire une matrice X sous la forme

$$\boxed{X} = \boxed{U} \boxed{\Lambda} \boxed{V^T}$$

où

- U est à colonnes orthonormées : $U^T U = I$
- Λ est diagonale
- V est orthogonale.

La transposition de l'identité informelle ci-dessus donne la forme dans le cas où X est horizontalement allongée.

- Algorithmes numériquement très efficaces pour réaliser cette décomposition.
- Transformation de base extensivement utilisée en pratique.

Remarque

$$U \Lambda V^T = \begin{array}{|c|c|c|c|} \hline & & & \\ \hline u_1 & u_2 & \dots & u_p \\ \hline \end{array} \begin{array}{|c|} \hline \lambda_1 \\ \hline \ddots \\ \hline \lambda_p \\ \hline \end{array} \begin{array}{|c|} \hline v_1^T \\ \hline v_2^T \\ \hline \vdots \\ \hline v_p^T \\ \hline \end{array} = \sum_i \lambda_i \begin{array}{|c|} \hline u_i \\ \hline \end{array} \begin{array}{|c|} \hline v_i^T \\ \hline \end{array}$$

Somme de p matrices de rang 1.

Plus formellement :

Théorème

Soit $X \in \mathbb{R}^{n \times p}$ une matrice, avec $n \geq p$. Il existe deux matrices à colonnes orthonormées U et V (i.e. $U^T U = V^T V = Id$) et une matrice diagonale $\Lambda \in \mathbb{R}^{p \times p}$ à entrées positives telles que

$$X = U \Lambda V^T$$

Par conséquent, en appelant u_k et v_k les vecteurs colonne de U et V (vecteurs singuliers à droite et à gauche), on a la décomposition en somme de matrices de rang 1 :

$$X = \sum_{k=1}^p \lambda_k u_k v_k^T, \quad \lambda_k = \Lambda_{kk}.$$

La matrice Λ contient nécessairement les racines carrées des valeurs propres de $X^T X$, appelées valeurs singulières, et si ces dernières sont distinctes et rangées par ordre décroissant, cette décomposition est unique.

Démonstration basée sur la diagonalisation de $X^T X$ (noter que $X^T X = V \Lambda^2 V^T$).

Solution du problème

Théorème

On suppose les valeurs singulières distinctes et ordonnées : $\lambda_1 > \lambda_2 > \dots \lambda_n$. Soit P_k

$$P_k = \sum_{j \leq k} v_j v_j^T$$

la projection orthogonale sur l'espace engendré par les k premiers vecteurs singuliers à droite. Pour toute matrice de projection P orthogonale sur un espace de dimension $\leq k$, on a

$$\|X - XP_k\|_F \leq \|X - XP\|_F.$$

Remarque. Le lemme reste vrai même si des valeurs singulières sont égales, mais P_k risque de ne plus être unique.

La matrice approchée vaut donc

$$XP = \sum_{j=1}^k \lambda_j u_j v_j^T.$$

On a simplement mis à zéro les $p - k$ plus petites valeurs singulières.

Démonstration

En raison du théorème de Pythagore $\|X\|_F^2 = \|XP\|_F^2 + \|X(I - P)\|_F^2$; il suffit donc de montrer que $\|XP_k\|_F \geq \|XP\|_F$. En reprenant la relation $X^T X = VDV^T$:

$$\|XP\|_F = \text{Tr}(PVDV^T P) = \text{Tr}(DQ)$$

où $Q = V^T P V$ est un projecteur orthogonal de rang $\leq k$. Comme $\text{Tr}(Q^2) = \text{Tr}(Q) \leq k$, la somme de ses coefficients diagonaux est $\leq k$. Par ailleurs, comme $Q^T Q = Q$, le carré de la norme de la colonne $Q_{.i}$ vaut Q_{ii} , en particulier $|Q_{ii}| \leq 1$. Donc

$$\|XP\|_F = \sum_i D_i Q_{ii} \leq \max \left\{ \sum_i D_i x_i : |x_i| \leq 1, \sum_i x_i \leq k \right\} = \sum_{i=1}^k D_i.$$

C'est la valeur atteinte pour $P = P_k$.

On a même plus généralement :

Théorème

Sous les hypothèses du théorème précédent, pour toute matrice A de rang k on a

$$\|X - XP_k\|_F \leq \|X - A\|_F.$$

Principe de la démonstration : Vérifier que

$$\begin{aligned}\|X - A\|_F^2 &= \|X(Id - P) + (X - A)P\|_F^2 \\ &= \|X(Id - P)\|_F^2 + \|(X - A)P\|_F^2 \\ &\geq \|X - XP_k\|_F^2.\end{aligned}$$

Inertie des espaces

On définit l'inertie des individus par la quantité

$$I = \frac{1}{n} \sum_i \|x_i\|^2.$$

Comme les individus sont centrés, cette quantité réelle mesure la **dispersion** des individus dans l'espace à p dimensions. C'est la somme des variances des p variables.

Soit P_E le projecteur orthogonal sur un e.v. $E \subset \mathbb{R}^p$; on définit l'inertie de E :

$$I_E = \frac{1}{n} \sum_i \|P_E x_i\|^2 = \frac{1}{n} \sum_i \|x_i\|^2 - \frac{1}{n} \sum_i \|x_i - P_E x_i\|^2$$

en vertu du théorème de Pythagore. Le problème (1) est donc équivalent à trouver l'espace E_k de dimension k d'inertie maximale.

Minimiser les erreurs $x_i - P x_i$ revient à maximiser la variabilité des $P x_i$

3

ASPECTS PRATIQUES L'ACP

Calcul pratique de l'ACP.

(La matrice X est supposée déjà recentrée)

- Faire une SVD de X : $X = U\Lambda V^T$. $U = [u_1, \dots, u_p]$, $V = [v_1, \dots, v_p]$
- $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p$
- Composantes principales : $c_k = \lambda_k u_k$. $C = [c_1 \dots c_p] = U\Lambda$
- Axes principaux : $v_1, \dots, v_p$


On a

$$X = CV^T = \sum_k c_k v_k^T$$

Comme $C = XV$, la k -ème composante principale est la combinaison linéaire des variables avec les poids contenus dans la k -ième colonne de V .

La représentation des individus dans un plan se borne alors à ne considérer que c_1 et c_2 .

L'exemple des poteries



La variable «four» n'a pas servi à l'ACP : Apprentissage non-supervisé.

Définition


Les v_k sont les **facteurs principaux**, ou **axes principaux**.

Le vecteur $c_k = Xv_k$ est la k -ième **composante principale**. $\|c_k\| = \lambda_k$.

$\frac{\lambda_1^2 + \dots + \lambda_k^2}{\lambda_1^2 + \dots + \lambda_p^2} = \frac{I_{E_k}}{I}$ est la **fraction d'inertie expliquée** par $E_k = \text{Span}(v_1, \dots, v_k)$.

Rappel : $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p$.

Plus la fraction d'inertie expliquée par E_k est proche de 1,
plus la projection de chaque variable x_j sur E_k est proche de x_j ,
plus les $c_1, \dots, c_k$ représentent bien les individus.




Il faut cependant se méfier : p. ex., sur des données non normalisées, on aura typiquement une distribution plus concentrée de l'inertie.

Un exemple.

On a mesuré la largeur et la longueur de la tête chez 25×2 frères³.

Ce qui donne 25 individus, et 4 variables : longueur et largeur pour l'un, longueur et largeur pour l'autre.



On obtient sur ces exemples

$$V = \begin{pmatrix} 0,57 & -0,69 & -0,44 & -0,01 \\ 0,41 & -0,22 & 0,87 & -0,17 \\ 0,60 & 0,63 & -0,21 & -0,44 \\ 0,39 & 0,27 & 0,06 & 0,88 \end{pmatrix}, \quad D = \Lambda^2 = \begin{pmatrix} 228 & 0 & 0 & 0 \\ 0 & 29,4 & 0 & 0 \\ 0 & 0 & 17 & 0 \\ 0 & 0 & 0 & 9 \end{pmatrix}$$

Les composantes principales sont en gros

- somme des périmètres des têtes
- différence entre les deux frères
- allongement de la tête du premier
- allongement de celle du second.

Le fait que la première valeur propre sorte du lot (80% d'inertie expliquée) indique que les individus se distinguent surtout par la somme des périmètres des crânes des deux frères.

Normalisation

L'ACP doit être faite sur des variables centrées, sinon, si les individus sont dans un nuage écarté de l'origine, la première composante sera essentiellement la distance à l'origine et pourra porter quasiment toute l'inertie si le centre du nuage est loin.

L'ACP n'est pas invariante par changement d'échelle sur les variables.

Si les variables sont non comparables (i.e. m et kg), on normalise :

$$x_{ik} \longleftarrow x_{ik} / \|x_{.k}\|$$

afin d'avoir un résultat **indépendant des unités utilisées**.

Si les variables sont comparables on peut préférer de ne pas faire de normalisation. Par exemple si les individus sont les pays et les variables la proportion de personnes ayant telle ou telle profession, on peut vouloir ne pas donner trop de poids dans l'analyse aux professions d'effectif très faible, ce qui sera compromis si l'on normalise. La normalisation serait une forme d'amplification du bruit en donnant trop de poids à une variable subalterne.

Solution par défaut : normalisation.

Normalisation : l'exemple des têtes

On obtient un résultat un peu différent :

$$V = \begin{pmatrix} 0,49 & -0,48 & -0,72 & 0,07 \\ 0,49 & -0,54 & 0,68 & -0,08 \\ 0,51 & 0,50 & -0,05 & -0,70 \\ 0,51 & 0,48 & 0,09 & 0,71 \end{pmatrix}, \quad D = \Lambda^2 = \begin{pmatrix} 3,2 & 0 & 0 & 0 \\ 0 & 0,38 & 0 & 0 \\ 0 & 0 & 0,27 & 0 \\ 0 & 0 & 0 & 0,16 \end{pmatrix}.$$

V est cette fois très proche de la matrice

$$V = \frac{1}{2} \begin{pmatrix} 1 & -1 & -\sqrt{2} & 0 \\ 1 & -1 & \sqrt{2} & 0 \\ 1 & 1 & 0 & -\sqrt{2} \\ 1 & 1 & 0 & \sqrt{2} \end{pmatrix}.$$

Interprétation de Λ^2 . Chaque terme correspond à l'inertie du sous-espace de dimension 1 correspondant, et leur somme fait l'inertie totale (théorème de Pythagore). Sa valeur mesure la contribution de l'axe aux données. Ici, le premier axe contribue à 80% de l'inertie car $3,2 / (3,2 + 0,38 + 0,27 + 0,16) = 80\%$. Λ^2 contient les valeurs propres de la matrice de corrélation des données.

Le cercle des corrélations

Rappel : $Cor(x, y) = \frac{\langle x, y \rangle}{\|x\| \|y\|}$ pour x et y recentrés.

But : liens entre variables d'origine et les composantes principales.

Tracé : Les vecteurs $(Cor(c_1, x_{.k}), Cor(c_2, x_{.k}))$. Noter que comme les $u_k = U_{.k}$ forment une base orthogonale de l'espace colonne de X , on a


$$X_{.k} = \sum_i \langle u_i, X_{.k} \rangle u_i = \|X_{.k}\| \sum_i Cor(c_i, X_{.k}) u_i$$

On voit que $\sum_i Cor(c_i, X_{.k})^2 = 1$. Ce tracé illustre donc la contribution des deux premières composantes à chaque variable. Il permet

- de voir les variables qui sont bien représentées par les deux premières composantes principales : le vecteur est de norme proche de 1
- d'interpréter chaque composante en observant quelles variables sont positivement ou négativement corrélées avec elle.
- de faire apparaître graphiquement les corrélations entre variables au travers de la proximité des points

Le cercle des corrélations : l'exemple des têtes

On obtient ici



Bonne représentation des variables. Confirmée par une inertie totale de 89,3%.

La première composante mesure l'amplitude cumulée de toutes les variables.
La seconde oppose les paires (L1,I1) et (L2,I2), c'est-à-dire les deux frères.



Les deux proximités de vecteurs montrent une forte corrélation entre largeur et longueur (Cette conclusion ne tient que du fait que les vecteurs étant de norme proche de 1, les projections sont proches des variables, qui sont donc également fortement corrélées).

4

AUTRES EXEMPLES


Poteries : individus dans les plans principaux

On voit nettement des regroupements qui permettent de classer différents types de poterie :




Les composantes C1 et C2 ne séparent pas les fours 4 et 5, et l'utilisation du troisième facteur n'améliore pas ce point.

Le four 3 n'a que deux représentants, ce qui est statistiquement peu.



Les deux premiers axes se dégagent assez bien avec 75% d'inertie expliquée.


Poteries : cercle des corrélations



La première composante oppose PaL_2O_3 et TiO_2 à MnO , K_2O , MgO , et Fe_2O_3 .

Un exemple avec interprétation

Le premier axe fait souvent apparaître un effet « taille », cf. la somme des périmètres des têtes, ou comme ici (notes de 104 étudiants dans 9 matières ; données deug de R) le score global de l'étudiant



Le deuxième axe oppose les scientifiques aux littéraires (ou aux communicants...).

5

TAKE HOME MESSAGE

Nouvelles variables explicatives $c_j = Xv_j$ (composantes principales) obtenues par combinaison des anciennes. C'est un prétraitement, pas une méthode de prédiction.

Choisies en sorte que la structure géométrique des individus restreints aux premières composantes soit la plus fidèle possible à la géométrie des individus complets.

Ce qui signifie que les premières variables concentrent l'information. Fidélité mesurée par le poids relatif des valeurs propres (inerties).

Ces nouvelles variables sont décorrélées : $c_i \perp c_j$, $i \neq j$.

Il est généralement préférable de travailler sur données standardisées, au minimum centrées.

Le premier axe fait souvent apparaître un effet « taille ».

Dans la SVD de X : $X = U\Lambda V^T$, la matrice V contient les v_i en colonne, et $C = U\Lambda = XV$ contient les c_i en colonne.


$(c_{i1}, \dots, c_{ik})$ exprime, dans la base orthonormée $(v_1, \dots, v_p)$, l'individu $(x_{i1}, \dots, x_{ip})$ projeté sur $\text{Vect}(v_1 \dots v_k)$.

6

EXTRAS

Variables supplémentaires

On peut aussi représenter une variable $x \in \mathbb{R}^n$ n'ayant pas servi à l'analyse, dite « variable supplémentaire », toujours avec le calcul des corrélations $Cor(x, c_1)$ et $Cor(x, c_2)$. Ici nous avons placé les cinq variables indicatrices de four :



Les confusions 4/5 et 2/3 font que les variables de four apparaissent mal expliquées, à l'exception du four 1.

Les variables supplémentaires sont généralement plutôt des variables à prédire, pas toujours disponibles.