

•

ANALYSE FACTORIELLE

DISCRIMINANTE

1

INTRODUCTION

Problématique

Données : paires $(X_i, Y_i) \in \mathbb{R}^p \times C$

C est l'ensemble des classes (ou groupes) ; on supposera $C = \{1, 2, \dots, k\}$.

Par exemple


- $X_i = (X_{i1}, \dots, X_{ip})$ est une liste de symptômes (fièvre, ...) et d'informations (âge, ...) sur l'individu i ,
- $Y_i \in \{0, 1\}$ indique si le sujet est atteint d'une certaine maladie.
- ou bien $Y_i \in \{M_1, \dots, M_k\}$ une maladie.

Il s'agit de voir comment X_i permet de prédire Y_i .

→ Apprentissage supervisé.

Exemple

- $X_i = (\text{Tour de hanches}, \text{Poids})$
- $Y_i \in \{F, H, \}$



2

MODÈLE PROBABILISTE

Idée générale

- Considérer les paires (X_i, Y_i) comme des réalisations iid d'une certaine distribution $P_{X,Y}$.
- Estimer cette distribution
- Pour un nouvel individu $(x, y = ?)$ estimer y par la valeur la plus vraisemblable sachant x

$$\hat{y} = \arg \max_y P_{Y|X}(y|X=x)$$

Rq :

$$\hat{y} = \arg \max_y \frac{P_{Y,X}(y,x)}{P_X(x)} = \arg \max_y P_{Y,X}(y,x)$$

Tour de hanches (cm) et poids (kg) de 488 personnes arrondis au plus proche multiple de 10.

Effectifs :

		Poids/Sexe									
		50		60		70		80		90	
		F	H	F	H	F	H	F	H	F	H
Tour	80	8	0	0	2	0	0	0	0	0	0
	90	59	1	55	21	4	53	0	8	0	1
	100	4	0	62	1	37	25	3	67	0	37
	110	0	0	0	0	8	0	12	5	2	12

$X = (\text{Tour de hanches}, \text{Poids})$

$Y = \text{Sexe}$

Tour de hanches (cm) et poids (kg) de 488 personnes arrondis au plus proche multiple de 10.

Proportions :

		Poids/Sexe									
		50		60		70		80		90	
		F	H	F	H	F	H	F	H	F	H
Tour	80	6	0	0	4	0	0	0	0	0	0
	90	121	2	113	43	8	109	0	16	0	2
	100	8	0	127	2	76	51	6	138	0	76
	110	0	0	0	0	16	0	25	10	4	25

Probabilités multipliées par 1000

Décision : $X=(T,P)=(90,60) \longrightarrow F$

$$P(Y = F|X = (90, 60)) = \frac{113}{133+43}$$

X est continue et Y discrète : Combinaison discret/continu

Densité jointe $p_{X,Y}(x, y)$. Intégrer en x et sommer sur y :

$$E[f(X, Y)] = \sum_y \int f(x, y) p_{X,Y}(x, y) dx.$$

Avec $f(x, y) = 1_{a \leq x \leq b} 1_{y=c}$:

$$P(a < X < b, Y = c) = \int_a^b p_{X,Y}(x, c) dx$$

Loi de X : on applique la formule avec f indépendante de y :

$$E[f(X)] = \sum_y \int f(x) p_{X,Y}(x, y) dx = \int f(x) p_X(x) dx$$

$$p_X(x) = \sum_y p_{X,Y}(x, y).$$

Modèle probabiliste

[Dans toute la suite, le vecteur de variables explicatives X_i sera considéré comme un vecteur colonne]

- Y_i est tiré selon une certaine loi discrète : $P(Y_i = c) = p_c, c \in C$.
- Conditionnellement à $Y_i = c, X_i \sim \mathcal{N}(\mu_c, W)$.

Paramètres : $(p_1, \dots, p_p), (\mu_1, \dots, \mu_p), W$.

Loi conjointe :

$$p_{X,Y}(x, c) = p_{X|Y}(x|c)p_c = g_{\mu_c, W}(x)p_c$$

$$\text{où } g_{\mu, W}(x) = \frac{1}{(2\pi)^{\frac{p}{2}} \sqrt{\det(W)}} e^{-\frac{1}{2}(x-\mu)^T W^{-1}(x-\mu)}$$

$g_{\mu, W}$: est la densité de la loi gaussienne $\mathcal{N}(\mu, W)$,

p_c : est la probabilité d'occurrence de la classe c .

Rq : Ici W ne dépend pas de c .

Loi de X

$$\begin{aligned}
 E[f(X)] &= \sum_c p_c \int f(x) e^{-\frac{1}{2}(x-\mu_c)^T W^{-1}(x-\mu_c)} \frac{dx}{(2\pi)^{\frac{p}{2}} \sqrt{\det(W)}} \\
 &= \int f(x) p_X(x)
 \end{aligned}$$

avec

$$p_X(x) = \sum_c g_{\mu_c, W}(x) p_c$$

La distribution de X est un mélange de gaussiennes.

Avec un abus de notation concernant les densité continues, on a en résumé

$$\begin{aligned}
 p(X = x | Y = c) &= g_{\mu_c, W}(x) \\
 p(X = x, Y = c) &= g_{\mu_c, W}(x) p_c \\
 p(X = x) &= \sum_c g_{\mu_c, W}(x) p_c
 \end{aligned}$$

3

ANALYSE DISCRIMINANTE LINÉAIRE

Estimation.

L'estimation ne pose aucun problème

$$n_c = |\{i : Y_i = c\}|, \quad \text{nb d'observations de la classe } c$$

$$\hat{p}_c = \frac{n_c}{n}, \quad \text{probabilité estimée } c$$

$$\hat{\mu}_c = \frac{1}{n_c} \sum_{i: Y_i=c} X_i, \quad \text{moyenne des } X_i \text{ observés pour lesquels } Y_i = c$$

$$\hat{R}_c = \frac{1}{n_c} \sum_{i: Y_i=c} (X_i - \hat{\mu}_c)(X_i - \hat{\mu}_c)^T, \quad \text{variance observée dans la classe } y$$

$$\widehat{W} = \frac{1}{n} \sum_c n_c \hat{R}_c, \quad \text{variance intraclasse}$$

(W=within, p.opp. between) qui sont également les estimateurs au maximum de vraisemblance. Rappelons que le clustering par centroïdes de la leçon précédente diffère en ce que les classes étaient inconnues, il s'agissait d'un problème différent : la classification non-supervisée.

Prise de décision.

Soit une nouvelle observation X dont la classe est inconnue, on a pour tout y

$$p(Y = y|X) = \frac{p(X, Y = y)}{p(X)} = \frac{g_{\mu_y, W}(x)p_y}{P(X)}$$

D'où

$$\begin{aligned}\hat{y} &= \arg \max_y g_{\mu_y, \widehat{W}}(X)p_y \\ &= \arg \max_y \left(X^T \widehat{W}^{-1} \hat{\mu}_y - \frac{1}{2} \hat{\mu}_y^T \widehat{W}^{-1} \hat{\mu}_y + \ln p_y \right) \quad (\text{en passant au log}).\end{aligned}$$

Posons

$$a_y = \widehat{W}^{-1} \hat{\mu}_y, \quad q_y = -\frac{1}{2} \hat{\mu}_y^T \widehat{W}^{-1} \mu_y + \ln p_y$$

la classe c sera choisie ssi

$$\langle X, a_c - a_y \rangle + q_c - q_y \geq 0 \quad \text{pour tout } y \in C.$$

Prise de décision.

La classe c sera choisie ssi

$$\langle X, a_c - a_y \rangle + q_c - q_y \geq 0 \quad \text{pour tout } y \in C.$$

Ce qui signifie que X appartient à une certaine intersection d'hyperplans. Tout se passe donc comme pour le clustering par centroïdes sauf que les q_y décalent les frontières, à cause du terme $\ln p_y$: l'espace des X est séparé en k régions délimitées par des morceaux d'hyperplans, à chaque région correspond exactement une classe.

(segment de droites pour le plan)

L'analyse discriminante fournit donc directement une méthode de prédiction.

La prise de décision est basée seulement sur les $k - 1$ variables

$\langle X, a_i - a_j \rangle ?$
 $i \neq j$
 C.L. des $!!$

$???$
 $\left\{ \begin{array}{l} \langle X, a_1 - a_k \rangle \\ \vdots \\ \langle X, a_{k-1} - a_k \rangle \end{array} \right.$

c est qui R ?
 Δ numéro de la classe
 $a_j ?$
 $\uparrow$
 a_c


Invariance

Il est immédiat de vérifier qu'une transformation $X_i \mapsto AX_i + b$ ne changera rien aux résultats.

Une standardisation n'est donc théoriquement pas nécessaire.

Exemple à deux classes

La droite séparatrice




Attention, en général de tels graphiques sont impossibles à réaliser car on a bien plus de deux variables.

3. ANALYSE DISCRIMINANTE LINÉAIRE

Avec trois classes

Iris de Fisher







Matrice de confusion :

$y \setminus \hat{y}$	Set.	Vers.	Virg.
Setosa	49	1	0
Versicolor	0	36	14
Virginica	0	15	35

Taux d'erreur : 0.2

Effet du déséquilibre

A droite, le groupe de femmes est répété 4 fois



4

ANALYSE DISCRIMINANTE QUADRATIQUE

Analyse discriminante quadratique

Même principe sauf que les R_y ne sont plus supposées égales. On a maintenant

$$p(X = x, Y = c) = p(X = x|Y = y)p(Y = y) = g_{\mu_y, R_y}(x)p_y$$





et

$$\hat{y} = \arg \max_y -\frac{1}{2}(X - \mu_y)^T R_y^{-1}(X - \mu_y) + \log p_y - \frac{1}{2} \log \det(R_y).$$



Le terme quadratique en X , $X^T R_y^{-1} X$, doit être pris en compte car il diffère d'un y à l'autre. Les régions sont donc maintenant séparées par des morceaux de quadriques.

Rq : Dans l'analyse discriminante quadratique, si l'on contraint les matrices de covariances à être diagonales, on retrouve l'algorithme connu sous le nom de "Naive Bayes".

Linéaire vs quadratique



Avec trois classes



5

LES FACTEURS PRINCIPAUX

Les facteurs principaux

on parle de a ? oui

Autre point de vue : chercher les variables $\langle a, X \rangle$ les plus discriminantes, c.-à-d. de faire une sorte d'ACP supervisée.

Il faut

 $x = \text{observation}$

soit vent d'être quoi?

gou

- Faible variance de $\langle a, X \rangle$ à l'intérieur de chaque classe (proche de $\langle a, \hat{\mu}_y \rangle$ dans la classe y) $\rightarrow$ con même classe
- Les $\langle a, \hat{\mu}_y \rangle$ très différents (les centres se distinguent).

pas une variance
oui mais dans le
sens de $\langle X, a \rangle - \langle a, \hat{\mu}_y \rangle$ non

Ceci conduit à maximiser le rapport de la variance des k nombres $\langle a, \hat{\mu}_c \rangle$ par la somme des variances de $\langle a, X \rangle$ dans chaque classe.

pourquoi?

$\xrightarrow{\text{variance de } \langle a, \hat{\mu}_c \rangle}$ $\xrightarrow{\text{somme des var. intra classe}}$ $\xrightarrow{\text{ce qui veut}}$ $\xrightarrow{\text{numérateur}}$ $\xrightarrow{\text{dénominateur}}$

Définissons la matrice de covariance interclasse par la covariance des centres de gravité, avec les pondérations correspondantes

$\uparrow$ $\text{moyenne de } p_y \text{ pondérée-moy des } X_i$

$$B = \sum_y p_y (\hat{\mu}_y - \hat{\mu})(\hat{\mu}_y - \hat{\mu})^T, \quad \hat{\mu} = \sum_y p_y \hat{\mu}_y = \frac{1}{n} \sum X_i$$

$\uparrow$ $\text{importance de la classe}$



(Rq : B=between. Il est classique que la variance totale $\frac{1}{n} \sum_i (X_i - \hat{\mu})(X_i - \hat{\mu})^T$ est la somme de la variance interclasse et de la variance intraclasse).

Les facteurs principaux

On cherche à maximiser

$$\frac{\text{Variabilité interclasse}}{\text{Variabilité intraclasse}} = \frac{a^T B a}{a^T W a}$$

multiplie par le facteur de Lagrange

$$= \frac{\langle a, B a \rangle}{\langle a, W a \rangle} = \lambda$$

Solution : le vecteur propre associé à la plus grande valeur propre de $W^{-1}B$.

$$B a = \lambda W a$$

Les vecteurs propres suivants : axes discriminants, au nombre de $k - 1$ (le rang de $W^{-1}B$). L'esprit de la procédure est proche de l'ACP.

L'approche par facteurs principaux ne conduit pas directement à une méthode de prise de décision, mais permet des représentations graphiques.

Comparaison avec l'analyse discriminante linéaire.

AFD : Décision de classement de l'individu $X \in \mathbb{R}^p$ basée seulement les k nombres $C_y = X^T W^{-1} \hat{\mu}_y$ (en fait seulement les $C_y - C_k$, ce qui fait $k - 1$ variables).

Les facteurs principaux sont les $a_j^T X$, mais ,

$$\begin{aligned}
 a_j &= \lambda_j W^{-1} B a_j \quad (\text{vect. pr.}) \\
 &= \lambda_j W^{-1} \left(\sum_y p_y (\hat{\mu}_y - \hat{\mu})(\hat{\mu}_y - \hat{\mu})^T \right) a_j \\
 &= \lambda_j \sum_y p_y \langle \hat{\mu}_y - \hat{\mu}, a_j \rangle W^{-1} (\hat{\mu}_y - \hat{\mu}) \\
 &= \lambda_j \sum_y p_y \langle \hat{\mu}_y - \hat{\mu}, a_j \rangle W^{-1} \hat{\mu}_y.
 \end{aligned}$$

Ces variables sont donc combinaisons linéaires des C_c , et l'on montre sans grande difficulté que réciproquement les C_c sont combinaisons de ces variables. Les variables sélectionnées sont donc essentiellement les mêmes mais exprimées différemment.