

COMPARAISON DE MODÈLES PAR VALIDATION CROISÉE

1

INTRODUCTION

Apprentissage

Problème : Expliquer Y en fonction de X

Exemples :

- Y maladie, X = symptômes
- Y = revenu, X = (âge, nb d'années d'études, ...)

Principe : Échantillon supposé iid : $(Y_1, X_1), (Y_2, X_2), \dots (Y_n, X_n)$

→ modèle estimé $Y \simeq \hat{f}(X)$.

Exemples : Y = revenu, X = âge, et

- Modèle linéaire : $f(x) = ax + b$. Deux paramètres à estimer (régression linéaire)
- Modèle non-linéaire : $f(x) = ax + b \sin(cx) + d$. Quatre paramètres à estimer
- ...

Méthode d'estimation typique : on cherche f dans la famille donnée qui minimise l'erreur de prédiction sur les données

$$\frac{1}{n} \sum_{k=1}^n \|Y_k - f(X_k)\|^2$$

Choix de modèle

On suppose ici que les estimateurs sont donnés (algorithmes) :

$$(Y_1, X_1), (Y_2, X_2), \dots (Y_n, X_n) \longrightarrow \hat{f}_1$$

...

$$(Y_1, X_1), (Y_2, X_2), \dots (Y_n, X_n) \longrightarrow \hat{f}_p$$

Problème : Comment déterminer le meilleur sans utiliser un autre jeu de données ?


2

SURAJUSTEMENT

Exemple

On estime deux modèles, polynôme d'ordre 3 et 6, sur les données (simulées) :


$$y_i = (5x_i - 1)^2(x_i - 1) + u_i, \quad u_i \sim \mathcal{N}(0, 0.25)$$



Comment voir que P_6 est moins bon que P_3 ?

Exemple

Pire encore



Situation générale

Plusieurs modèles différents, avec chacun son estimateur :

$$\begin{aligned}\widehat{f}_p : \mathbb{R}^d &\longrightarrow \mathbb{R} \\ x &\longrightarrow \widehat{f}_p(x) = \widehat{y}\end{aligned}$$

(on devrait noter $\widehat{y}_p$). Estimée de l'erreur de prédiction (Mean Square Error) pour chacun

$$\widehat{MSE}(p) = \widehat{MSE}(\widehat{f}_p) = \frac{1}{n} \sum_{k=1}^n \|Y_k - \widehat{f}_p(X_k)\|^2$$

C'est une estimée du vrai risque, valeur moyenne mesurée sur un échantillon étranger à l'expérience :

$$MSE(p) = E[\|Y_0 - \widehat{f}_p(X_0)\|^2].$$

Véritable erreur de prédiction.

La valeur $\widehat{MSE}(p)$ est biaisée : les échantillons $(Y_1, X_1), \dots, (Y_n, X_n)$ sont juges et parties, en particulier, si $p = n$, on trouve typiquement $\widehat{MSE}(p) = 0$ alors que $MSE(p)$ sera non nul ;

Surajustement (overfitting) : Le modèle créé s'est hyper-adapté à l'échantillon, au détriment d'un nouvel arrivant.

$\widehat{MSE}(p)$ ne permet pas directement de juger à elle seule du meilleur p .

$\widehat{MSE}$ sera le plus petit pour le modèle le plus compliqué car il pourra bien approcher les données, mais ce modèle risque d'avoir un MSE très mauvais.

3

SOLUTIONS

Solution 1 : Data splitting.

On pose $Z_i = (X_i, Y_i)$

Séparer l'échantillon en deux :

- ① Estimer chaque modèle sur la moitié $(Z_1, \dots, Z_{n/2})$ des échantillons
- ② Calculer les MSE sur l'autre moitié $(Z_{n/2+1}, \dots, Z_n)$ des échantillons

$$\widehat{MSE}(p) = \frac{2}{n} \sum_{k=n/2+1}^n \|Y_k - \hat{Y}_k\|^2 = \frac{2}{n} \sum_{k=n/2+1}^n \|Y_k - f_p(X_k)\|^2$$

- ③ Choisir le p qui minimise le $\widehat{MSE}$.
- ④ Réestimer le modèle avec ce p sur toutes les données.

Simple mais deux défauts visibles :

- ① Le choix de prendre les premiers pour l'apprentissage et les derniers pour le test est arbitraire.
- ② On estime plutôt un $MSE(p)$ correspondant à une estimation sur $n/2$ échantillons, qu'à n échantillon (cf la dernière étape).

Solution 2 : Leave-one-out.

On définit l'ensemble privé de l'échantillon k :

$$Z^k = \{Z_1, \dots, Z_{k-1}, Z_{k+1}, \dots, Z_n\}$$

Calculer, pour chaque échantillon Z_k , l'erreur du modèle estimé sur Z^k

① Pour chaque modèle p

① Pour chaque $1 \leq k \leq n$

① Estimer le modèle sur l'échantillon Z^k

② Calculer l'erreur individuelle de prédiction sur (Y_k, X_k)

$$E(k, p) = \|Y_k - \hat{Y}_k\|^2 = \|Y_k - \hat{f}_p^k(X_k)\|^2$$

② Calculer le MSE

$$\widehat{MSE}(p) = \frac{1}{n} \sum_k E(k, p)$$

② Choisir le p qui minimise le $\widehat{MSE}$. Réestimer le modèle avec ce p sur toutes les données.

Une bonne méthode mais possiblement **très coûteuse**.

Solution 3 : K -fold validation croisée.

Une méthode intermédiaire en «data-splitting» et leave-one-out :

- ① Séparer aléatoirement l'échantillon en deux ensembles, un de taille n/K (test) et un de taille $n - n/K$ (apprentissage). P.ex. $K = 5$.
- ② Calculer pour chaque modèle p l'erreur de prédiction obtenue
- ③ Répéter plusieurs fois et moyenner pour obtenir les $\widehat{MSE}(p)$

Version à l'ancienne :

- ① On sépare l'échantillon K ensembles de taille n/K .
- ② Pour chaque modèle p
 - ① Calculer les K MSE correspondant au K -ième ensemble choisi comme test et le reste en apprentissage
 - ② Faire la moyenne des K erreurs de prédictions obtenues, ce qui donne $\widehat{MSE}(p)$

Solution 3 : K -fold validation croisée.

Résultat :

- ① Pour chaque $1 \leq s \leq S$ (indice de répétition)
 - ① Séparer aléatoirement l'échantillon $(Z_1, \dots, Z_n)$ en deux ensembles : T de taille n/K (test), et $A = \bar{T}$ (apprentissage)
 - ② Pour chaque modèle p , faire l'estimation sur A
 - ③ Calculer l'erreur de prédiction sur T pour chaque p

$$E(s, p) = \frac{K}{n} \sum_{X \in T} \|Y - \hat{f}_p^A(X)\|^2$$

- ② Calculer les $\widehat{MSE}$

$$\widehat{MSE}(p) = \frac{1}{S} \sum_s E(s, p)$$

- ③ Choisir le p qui minimise le MSE et réestimer le modèle avec ce p sur toutes les données.

Points pratiques.

Usuellement $5 \leq K \leq 10$

Souvent des résultats aussi satisfaisants que le leave-one-out, voire meilleurs (!!!)

Le choix de S n'est pas critique, il peut être grand si le temps de calcul le permet. Faire $S \simeq n/K$ garantit qu'une large part de l'ensemble sera utilisée en test.

Boucle sur p *intérieure* à la boucle sur s : tous les modèles sont comparés sur les mêmes jeux de données Ce n'est pas l'option naturelle quand on programme. Sinon on observe plus de fluctuations

Si n est petit (<100) le leave-one-out est une bonne option (le 10-fold prendra quelques échantillons, ce qui ressemble beaucoup). Si n est grand, il est souvent trop long à faire tourner.

Attention. Si l'on emboîte plusieurs algorithmes (p.ex. modification des variables X par ACP puis calcul du modèle), il est important, de faire la séparation A/T dès le début ce qui alourdit l'algorithme

Exemple : LOO vs 10%-Fold.

Tableau X à 251 individus (des hydrocarbures) et 401 variables (un spectre)¹ :

$$n = 251, \quad X_i \in \mathbb{R}^{401}$$

Y_i est la température de gel. On a recentré les variables. Noter que l'on voit bien la corrélation des régresseurs en raison de la régularité en fréquence.







Figure – Spectres NIR de 4 échantillons d'hydrocarbure avant et après recentrage.

1. Mis à disposition par Eigenvector Research, Inc., www.eigenvector.com/data/index.htm .

Exemple : LOO vs 10%-Fold.

On va comparer deux méthodes de régression linéaire : le PLS et l'ACP sur les variables. Voici le score obtenu en fonction du nombre de variables utilisées (i.e. deux fois 18 modèles comparés) :



La 10%-fold CV conduit à moins de fluctuations.

Explication possible : Dans le leave one out, à modèle fixe, $\hat{f}_p$ change peu (on ne change que deux échantillons), mais il peut y avoir des changements importants au passage d'un ordre à l'autre (instabilité du modèle). Dans le V-fold, le modèle estimé variera davantage, ce qui entraîne une meilleure moyennisation et moins de variabilité d'un ordre à l'autre.

4

LE SURAJUSTEMENT N'EST PAS TOUJOURS NUISIBLE

Considérons la régression linéaire.

$$Y \simeq X\beta_*$$

$$\beta_{OLS} = (X^T X)^{-1} X^T Y$$

et l'estimateur ridge

$$\hat{\beta}_R = \arg \min_{\beta} \frac{1}{2} \|Y - X\beta\|^2 + \lambda \|\beta\|^2.$$

- ❶ Si $p < n$ et $p \simeq n$

Hyper-adaptation (interpolation) $\longrightarrow \|\beta_{OLS}\| \gg 1$

On trouve $\widehat{MSE}_{CV}$ très élevé.

L'estimation ridge sera pourra corriger cela.

- ❷ Si $p \gg n$ l'estimateur ridge avec $\lambda = 0$ choisira parmi toutes les solutions de $X\beta = y$ celle qui minimise $\|\beta\|$, ce qui peut rattraper le défaut précédent. On peut observer un $\widehat{MSE}$ par validation croisée raisonnablement petit.

Si le nombre de paramètres est très grand, il se peut qu'un interpolateur donne de bons résultats, car il est choisi parmi un très grand nombre avec un critère raisonnable !

Ceci n'arrive que si le nombre de paramètre est grand devant le nombre d'individus.

Sur le ridge avec $\lambda = 0$

C'est la solution de

$$\hat{\beta}_R = \arg \min_{X\beta=Y} \|\beta\|.$$

La solution est

$$\beta_{OLS} = (X^T X)^+ X^T Y$$

où le M^+ désigne la pseudo inverse de la matrice M . C'est généralement la solution donnée par défaut par les programmes de régression OLS si $X^T X$ n'est pas inversible.

OLS et surajustement

Données : Chaque jour est mesurée la force du vent en $p_0 = 2000$ points de l'Atlantique nord (variable explicative), ainsi que la hauteur des vagues (réponse) en un point fixe du golfe de Gascogne. Il y a $n_0 = 8000$ jours de mesure.

On extrait $n = 500$ individus pour l'estimation, les 7500 individus restants servant au calcul du MSE. Différentes régression OLS sont faites en utilisant les p premiers régresseurs. La figure montre l'évolution du **logarithme** du MSE :

