


MOTIVATION DES ESTIMATEURS

RIDGE ET LASSO

Régression polynomiale


On estime deux modèles, polynôme d'ordre 3 et 6, sur les données (simulées) :

$$y_i = (5x_i - 1)^2(x_i - 1) + u_i, \quad u_i \sim \mathcal{N}(0, 0.25)$$



$$y_i = (5x_i - 1)^2(x_i - 1) + u_i, \quad u_i \sim \mathcal{N}(0, 0.25)$$

$$y = X\beta^* + u, \quad X = \begin{pmatrix} 1 & x_1 & \dots & x_1^{p^*} \\ \vdots & \vdots & & \vdots \\ 1 & x_n & \dots & x_n^{p^*} \end{pmatrix} \begin{pmatrix} \beta_1^* \\ \vdots \\ \beta_{p^*}^* \end{pmatrix} + \begin{pmatrix} u_1 \\ \vdots \\ u_n \end{pmatrix}.$$



Quand le degré p augmente, l'adéquation (RSS) change peu mais $\|\beta\|$ augmente vite.

Liens avec la décomposition biais-variance

à quoi ça sert ?

$$\hat{\beta}_p = (X_p^T X_p)^{-1} X_p^T y = (X_p^T X_p)^{-1} X_p^T X_{p_*} \beta^* + (X_p^T X_p)^{-1} X_p^T u$$

Le premier terme correspond à l'adéquation d'un polynôme d'ordre p à des données non-bruitées. Il est exact si $p \geq p_*$ (β_* avec des zéros ajoutés). Le deuxième terme correspond à l'adéquation d'un polynôme d'ordre p au bruit, sa norme augmente avec p .

Il est plus simple de raisonner sur les prédictions. On a la décomposition de l'erreur


$$\begin{aligned} \hat{y} - P(x) &= X_p \hat{\beta}_p - X_{p_*} \beta^* \\ &= \underbrace{(Q_p - Id) X_{p_*} \beta^*}_{\text{Biais} = E[\hat{y} - P(x)]} + \underbrace{Q_p u}_{\text{Bruit}}, \quad Q_p = X_p (X_p^T X_p)^{-1} X_p^T \end{aligned}$$

où Q_p est le projecteur orthogonal sur l'espace des colonnes de X_p . Si $p \geq p_*$, $Q_p X_{p_*} = X_{p_*}$ le premier terme est nul. Le second est de variance totale $p \sigma_u^2$.

$$\underbrace{\|\hat{y} - P(x)\|^2}_{\text{Erreur}} = \underbrace{\|(Q_p - Id)X_{p_*}\beta^*\|^2}_{\text{Terme de biais}} + \underbrace{\|Q_p u\|^2}_{\text{Terme de variance}}$$

On obtient sur une réalisation de l'expérience précédente :


Décomposition de l'erreur
en fonction de l'ordre du polynôme



Asym.
Asym.

on peut pas
toujours tracer
ce graphique.
Pg?
cà cause
de l'erreur...

Même expérience sauf que $y_i = \tanh(4x_i) + u_i$



Bilan

La décomposition biais/variance peu se faire aussi sur $\hat{\beta}$

$$\underbrace{\hat{\beta} - \beta_*}_{\text{Erreur}} = \underbrace{\hat{\beta} - E[\hat{\beta}]}_{\text{Terme de variance}} + \underbrace{E[\hat{\beta}] - \beta_*}_{\text{Terme de biais}}$$

$$\underbrace{E[\|\hat{\beta} - \beta_*\|^2]}_{\text{MSE}} = \underbrace{\text{Var}(\hat{\beta})}_{\text{Variance}} + \underbrace{\|E[\hat{\beta}] - \beta_*\|^2}_{\text{Carré de biais}}$$

Quand p augmente :

- L'adéquation s'améliore, mais le surajustement s'accompagne d'une forte augmentation de $\|\hat{\beta}\|$
- Le biais diminue mais la variance augmente