

## Chapitre 2 : Sélection de variables et pénalisations

Agathe Guilloux

Professeure au LaMME - Université d'Évry - Paris Saclay

## Avant de commencer

- ▶ Les documents du cours sont disponibles ici : <http://www.math-evry.cnrs.fr/members/aguilloux/enseignements/m2upmc>
- ▶ Bibliographie (pour ce chapitre) :
- ▶ Contrôle des connaissances : 2 TP rendus, 1 projet (type concours de DataScience), 1 examen court.
- ▶ Pré-requis : cours de Statistique de base [http://www.proba.jussieu.fr/pageperso/rebafka/StatBase\\_poly\\_partie2.pdf](http://www.proba.jussieu.fr/pageperso/rebafka/StatBase_poly_partie2.pdf).

## Chapitre 2 : Sélection de variables et pénalisations

Agathe Guilloux

Professeure au LaMME - Université d'Évry - Paris Saclay

## Avant de commencer

- ▶ Se connecter à ma page  
<http://www.lsta.upmc.fr/guilloux.php?main=enseignement> et récupérer les transparents ici.
- ▶ Bibliographie :  
Jean-Marc Azaïs et Jean-Marc Bardet

## Les données swiss du package faraway

Standardized fertility measure and socio-economic indicators for each of 47 French-speaking provinces of Switzerland at about 1888.

A data frame with 47 observations on 6 variables, each of which is in percent, i.e., in  $[0, 100]$ .

- ▶ `Fertility` common standardized fertility measure
- ▶ `Agriculture` % of males involved in agriculture as occupation
- ▶ `Examination` % draftees receiving highest mark on army examination
- ▶ `Education` % education beyond primary school for draftees.
- ▶ `Catholic` % 'catholic' (as opposed to 'protestant').
- ▶ `Infant.Mortality` live births who live less than 1 year.

All variables but `Fertility` give proportions of the population.

Switzerland, in 1888, was entering a period known as the demographic transition; i.e., its fertility was beginning to fall from the high level typical of underdeveloped countries.

The data collected are for 47 French-speaking "provinces" at about 1888.

Here, all variables are scaled to  $[0, 100]$ , where in the original, all but "Catholic" were scaled to  $[0, 1]$ .

Sélection de variables  $\ell_0$

## Tests de Student et de Fisher

On se place dans le modèle

$$Y = X\beta + \epsilon$$

avec  $\epsilon \sim \mathcal{N}((0, \dots, 0)^\top, \sigma^2 I_n)$  et  $X\beta \in V = \text{vect}(\mathbf{1}, X^1, \dots, X^p)$ .

On veut **sélectionner** les variables qui ont une influence sur  $Y$ , i.e.  
déterminer les indices  $k \in \{1, \dots, p\}$  pour lesquels  $\beta_k \neq 0$ .

- Si on veut tester  $H_0 : \beta_k = 0$ , on peut utiliser le test de Student de niveau

$$\mathbb{P}_{H_0} \left( \left| \frac{\hat{\beta}_j - \beta_j}{\sqrt{\hat{\sigma}^2 (X^\top X)^{-1}_{jj}}} \right| > F_{\mathcal{T}(n-p-1)}^{-1}(1 - \alpha/2) \right) = \alpha$$

- Si on veut tester  $H_0 : \beta_{k_1} = \dots = \beta_{k_l} = 0$ , on pourrait utiliser les statistiques de Student mais le niveau pour un seuil  $s$  est alors donné par :

$$\begin{aligned}\mathbb{P}_{H_0}(\bar{H}_0) &= \mathbb{P}\left(\left|\frac{\hat{\beta}_{k_1}}{\sqrt{\hat{\sigma}^2(X^\top X)_{k_1 k_1}^{-1}}}\right| > s \cup \dots \cup \left|\frac{\hat{\beta}_{k_l}}{\sqrt{\hat{\sigma}^2(X^\top X)_{k_l k_l}^{-1}}}\right| > s\right) \\ &\leq \mathbb{P}\left(\left|\frac{\hat{\beta}_{k_1}}{\sqrt{\hat{\sigma}^2(X^\top X)_{k_1 k_1}^{-1}}}\right| > s\right) + \dots + \mathbb{P}\left(\left|\frac{\hat{\beta}_{k_l}}{\sqrt{\hat{\sigma}^2(X^\top X)_{k_l k_l}^{-1}}}\right| > s\right).\end{aligned}$$

Pour garantir un niveau  $\alpha$ , il faut prendre  $s = F_{\mathcal{T}(n-p-1)}^{-1}(1 - \alpha/(2l))$  pour avoir :

$$\mathbb{P}_{H_0}(\bar{H}_0) \leq \frac{\alpha}{l} + \dots + \frac{\alpha}{l} = \alpha.$$

Mais la puissance de chaque test est alors assez mauvaise car

$$F_{\mathcal{T}(n-p-1)}^{-1}(1 - \alpha/(2l)) \gg F_{\mathcal{T}(n-p-1)}^{-1}(1 - \alpha/(2)) \text{ si } l \gg 1.$$



## Test pour modèles emboîtés

Pour tester  $H_0 : \beta_{k_1} = \dots = \beta_{k_l} = 0$ , on utilise le test de Fisher.

- ▶ On note  $W = \text{vect}\{(\mathbf{1}, X_1, \dots, X_p)/(X_{k_1}, \dots, X_{k_l})\}$  de dimension  $p + 1 - l$ .
- ▶ On note  $X\tilde{\beta} = \text{Proj}_W^\top(Y)$  et on a toujours  $X\hat{\beta} = \text{Proj}_V^\top(Y)$ .

### Loi sous $H_0$

Sous  $H_0$ , on a donc

$$Y - X\hat{\beta} = \epsilon - \text{Proj}_V^\perp(\epsilon) = \text{Proj}_{V^\perp}(\epsilon) \text{ et}$$

$$Y - X\tilde{\beta} = \epsilon - \text{Proj}_W^\perp(\epsilon) = \text{Proj}_{W^\perp}(\epsilon).$$

On remarque que  $W \subset V$  et donc

$$W^\perp = V^\perp \bigoplus W^{\perp_V}.$$

## Statistique de Fisher

On a

$$\|Y - X\tilde{\beta}\|^2 - \|Y - X\hat{\beta}\|^2 = \|\text{Proj}_{W^\perp_V}^\perp(\epsilon)\|^2.$$

donc

$$\frac{(n - p - 1)(\|Y - X\tilde{\beta}\|^2 - \|Y - X\hat{\beta}\|^2)}{l\|Y - X\hat{\beta}\|^2} \underset{H_0}{\sim} \mathcal{F}(l, n - p - 1).$$

Si le modèle de départ a  $p$  variables, il y a  $\#\mathcal{P}\{1, \dots, p\} = 2^p$  sous-modèles à explorer. Il faut des algorithmes efficaces :

- ▶ **forward** : on part du modèle avec seulement l'intercept et on ajoute les variables une à une. A chaque pas, on ajoute celle qui a la plus grande statistique de Fisher. On s'arrête quand la p-value associée devient  $> 0.1$  (seuil arbitraire)
- ▶ **backward** : on part du modèle avec toutes les variables et on retire les variables une à une. A chaque pas, on retire celle qui a la plus petite statistique de Fisher. On s'arrête quand la p-value associée devient  $< 0.1$  (seuil arbitraire)
- ▶ **stepwise** mixte des deux premières (on ajoute, puis on permet une élimination, etc)

## Modèles, vrai modèle

On se donne une famille de modèles  $\mathcal{M}$ , par exemple  $\mathcal{M} = \mathcal{P}\{1, \dots, p\}$ . On suppose qu'il existe un vrai modèle  $m^* \in \mathcal{M}$  tel que :

$$Y = X^{(m^*)} \beta^{(m^*)} + \epsilon^* \text{ avec } \epsilon^* \sim \mathcal{N}((0, \dots, 0)^\top, (\sigma^{m^*})^2 I_n).$$

On veut retrouver  $m^*$ .

- ▶ **Attention** : le  $R^2$  n'est pas un bon critère pour ce problème car il choisira toujours le modèle complet (avec toutes les covariables)
- ▶ On note  $m_{tot}$  le modèle complet.

## Estimation dans le modèle $m$

Dans le modèle  $m$ , on note  $|m|$  le nombre de covariables qu'il contient et

$$\hat{\beta}^{(m)} = ((X^{(m)})^\top X^{(m)})^{-1} (X^{(m)})^\top Y$$

$$\hat{Y}^{(m)} = X^{(m)} \hat{\beta}^{(m)}$$

$$\widehat{(\sigma^m)^2} = \frac{\|Y - \hat{Y}^{(m)}\|_2^2}{n - |m|}$$

## Risque quadratique

Le risque quadratique de  $\hat{Y}^{(m)}$  pour l'estimation de  $X^* \beta^*$  est donné par

$$\begin{aligned}\mathbb{E}_{m^*}(\|\hat{Y}^{(m)} - X^* \beta^*\|^2) &= \underbrace{\mathbb{E}_{m^*}(\|\hat{Y}^{(m)} - X^{(m)} \beta^{(m)}\|^2)}_{\text{variance}} + \underbrace{\|X^{(m)} \beta^{(m)} - X^* \beta^*\|^2}_{\text{biais}^2} \\ &= \sigma^2 |m| + \|X^{(m)} \beta^{(m)} - X^* \beta^*\|^2\end{aligned}$$

où  $X^{(m)} \beta^{(m)}$  est la projection de  $X^* \beta^*$  sur  $\text{vect}(X^{(m)})$ .

Les termes de biais et de variance sont inconnus, il faut donc les estimer.

## Estimations des termes de biais et de variance

On montre que

$$\mathbb{E}_{m^*}(\|\hat{Y}^{(m)} - Y\|^2) = (n - |m|)\sigma^2 + \|X^{(m)}\beta^{(m)} - X^*\beta^*\|^2.$$

Finalement

$$\begin{aligned}\mathbb{E}_{m^*}(\|\hat{Y}^{(m)} - X^*\beta^*\|^2) &= \sigma^2|m| - (n - |m|)\sigma^2 + \mathbb{E}(\|\hat{Y}^{(m)} - Y\|^2) \\ &= 2\sigma^2|m| + \mathbb{E}_{m^*}(\|\hat{Y}^{(m)} - Y\|^2) - n\sigma^2.\end{aligned}$$

On approxime  $\mathbb{E}_{m^*}(\|\hat{Y}^{(m)} - Y\|^2)$  par

$$\|\hat{Y}^{(m)} - Y\|^2 = (n - |m|)\hat{\sigma}_{(m)}^2.$$

## Cp de Mallows

On choisit  $\hat{m}_{Cp} \in \mathcal{M}$  tel que :

$$\hat{m}_{Cp} = \underset{m \in \mathcal{M}}{\operatorname{argmin}} Cp(m),$$

avec

$$Cp(m) = \frac{\hat{\sigma}_{(m)}^2}{\hat{\sigma}_{(m)\text{tot}}^2} + 2 \frac{|m|}{n}$$



## Divergence de Kullback (1)

La divergence de Kullback entre deux densités  $f$  et  $f^*$  s'écrit (sous les bonnes conditions)

$$\mathcal{K}(f, f^*) = \int f^* \log \left( \frac{f^*}{f} \right).$$

Si les deux densités sont deux gaussiennes sur  $\mathbb{R}^n$  :  $\mathcal{N}(\mu, \sigma^2)$  et  $\mathcal{N}(\mu_*, \sigma_*^2)$ , on obtient

$$\mathcal{K}(f, f^*) = \frac{n}{2} \log \frac{\sigma^2}{\sigma_*^2} - \frac{n}{2} + \frac{n}{2} \frac{\sigma_*^2}{\sigma^2} + \frac{1}{2\sigma^2} \|\mu_* - \mu\|^2.$$

## Divergence de Kullback (2)

En régression, on veut minimiser

$$\begin{aligned} & \mathbb{E}_{m^*} \left( \log \frac{\hat{\sigma}_{(m)}^2}{\sigma_*^2} - 1 + \frac{\sigma_*^2}{\hat{\sigma}_{(m)}^2} + \frac{1}{n\hat{\sigma}_{(m)}^2} \|\mu_* - X^{(m)}\hat{\beta}^{(m)}\|^2 \right) \\ &= \mathbb{E}_{m^*} \left( \log \frac{\hat{\sigma}_{(m)}^2}{\sigma_*^2} \right) - 1 + \frac{n - |m|}{n - |m| - 2} + \frac{n}{n} \frac{n - |m|}{n - |m| - 2}. \end{aligned}$$

Après quelques approximations, on obtient le critère AIC.

## AIC/BIC - divergence de Kullback

On choisit  $\hat{m}_{AIC} \in \mathcal{M}$  et  $\hat{m}_{BIC} \in \mathcal{M}$  tel que :

$$\hat{m}_{AIC} = \operatorname{argmin}_{m \in \mathcal{M}} AIC(m),$$

$$\hat{m}_{BIC} = \operatorname{argmin}_{m \in \mathcal{M}} BIC(m),$$


avec

$$AIC(m) = \log(\hat{\sigma}_{(m)}^2) + 2 \frac{|m| + 1}{n}$$


$$BIC(m) = \log(\hat{\sigma}_{(m)}^2) + \frac{\log(n)|m|}{n}$$

# Illustration d'après Azaïs et Bardet

Comparaison des prédictions : modèle total, backward par Fisher, AIC, BIC



# Illustration d'après Azaïs et Bardet



## Exercice

1. Reprendre l'exemple d'école et coder les différentes procédures de sélection de modèles.
2. Finir l'analyse du jeu de données  
<https://archive.ics.uci.edu/ml/datasets/Student+Performance>, sélection de variables incluse. Comparer les modèles choisis par les différentes procédures de sélection.

Régressions pénalisées et sur variables synthétiques

On observe  $Y$  et  $X$  de dimension  $n \times p$ . On fait l'hypothèse qu'il existe un vrai modèle  $m^*$  tel que

$$Y = X^{m^*} \beta^{m^*} + \epsilon^{m^*} = X^* \beta^* + \epsilon^*,$$

et que  $|m^*|$  est petit devant  $p$  et  $n$ .

Quand  $p$  devient grand par rapport à  $n$ , il y a trois problèmes potentiels:

- ▶  $\hat{\beta} = (X^\top X)^{-1} X^\top Y$  peut ne pas être défini car  $X^\top X$  n'est alors plus inversible (c'est aussi le cas si des colonnes de  $X$  sont colinéaires)
- ▶ La variance d'estimation à partir de  $X$  devient trop grande. En effet, on a déjà montré que

$$\mathbb{E}(\|X\hat{\beta} - X^* \beta^*\|^2) = p\sigma^2 + \|X^{(m)} \beta^{(m)} - X^* \beta^*\|^2 = p\sigma^2.$$

- ▶ Les algorithmes de sélection de variables  $\ell_0$  ne peuvent plus être appliqués à cause des  $2^p$  modèles à comparer.



# Introduction

La régression ridge et PCR (principal components regression) s'attaquent aux deux premiers problèmes :

- ▶ la première en régularisant le problème des moindres carrés
- ▶ la seconde en travaillant sur des variables synthétiques issues d'une PCA (APC).

Les deux ont de bonnes performances en prédiction mais ont l'inconvénient de produire des modèles difficilement interprétables.

## Régression Ridge

Objectif: Trouver  $\beta$  quand  $X^T X$  est non-inversible.

Hoerl et Kennard (1970) ont l'idée d'ajouter à  $X^T X$  une matrice diagonale  $\lambda \text{Id}_n$  pour retrouver l'inversibilité pour

$$X^T X + \lambda \text{Id}_p = P D P^{-1} + \lambda \text{Id}_p = P (D + \lambda \text{Id}_p) P^{-1}.$$

## Pénalité ridge

$$\hat{\beta}_{\lambda}^{\text{ridge}} = \underset{\beta \in \mathbb{R}^p}{\text{argmin}} \|Y - X\beta\|^2 + \lambda \sum_{j=1}^p \beta_j^2.$$

Montrons que les deux définitions sont équivalentes.

# Loi de l'estimateur ridge

## Loi gaussienne

est biaisé ! plus pour  $p$ -value...

Sous l'hypothèse gaussienne  $\hat{\beta}_\lambda^{\text{ridge}}$  reste gaussien mais a pour moments

$$\mathbb{E}\hat{\beta}_\lambda^{\text{ridge}} = (X^\top X + \lambda \text{Id}_p)^{-1} X^\top Y = (X^\top X + \lambda \text{Id}_p)^{-1} X^\top X \beta^*$$

$$\begin{aligned}\mathbb{V}\hat{\beta}_\lambda^{\text{ridge}} &= (X^\top X + \lambda \text{Id}_p)^{-1} X^\top \mathbb{V}(\epsilon^*) X (X^\top X + \lambda \text{Id}_p)^{-1} \\ &= \sigma^2 (X^\top X + \lambda \text{Id}_p)^{-1} X^\top X (X^\top X + \lambda \text{Id}_p)^{-1}.\end{aligned}$$

Il est donc biaisé pour l'estimation de  $\beta^*$ , de même  $X\hat{\beta}_\lambda^{\text{ridge}}$  est biaisé pour l'estimation de  $X^*\beta^*$ . On va montrer que, même si la régression ridge augmente le biais, elle peut diminuer le risque quadratique.

c'est quoi ?  
(voir ci-dessous)

## Propriété sur le risque quadratique

*donné par l'hypothèse faite en p. 24*

On connaît le risque quadratique de l'estimateur des moindres carrés

$$\mathbb{E}(\|X\hat{\beta} - X\beta^*\|^2) = p\sigma^2 + \|X^{(m)}\beta^{(m)} - X\beta^*\|^2 = p\sigma^2.$$

Calculons celui de pour la régression ridge

$$\begin{aligned}\mathbb{E}(\|X\hat{\beta}_{\lambda}^{\text{ridge}} - X\beta^*\|^2) \\ = \mathbb{E}(\|X(X^{\top}X + \lambda\text{Id}_p)^{-1}X^{\top}X\beta^* - X\beta^*\|^2) + \mathbb{E}(\|X(X^{\top}X + \lambda\text{Id}_p)^{-1}X^{\top}\epsilon\|^2)\end{aligned}$$

## Design orthogonal

Dans le cas d'un design orthogonal, le risque quadratique s'écrit

$$\mathbb{E}(\|X\hat{\beta}_{\lambda}^{\text{ridge}} - X\beta^*\|^2) = \sigma^2 p \frac{1}{(\lambda + 1)^2} + \|\beta^*\|^2 \frac{\lambda^2}{(1 + \lambda)^2}.$$

Il existe donc un  $\lambda^* > 0$  tel que  $\mathbb{E}(\|X\hat{\beta}_{\lambda^*}^{\text{ridge}} - X\beta^*\|^2)$  est minimale et inférieure  $p\sigma^2$ .

*on le trouve avec descente du gradient...*

## Valeur des coefficients

### Effet de $\lambda$ sur les estimateurs

Toujours en design orthogonal, on écrit simplement

$$\hat{\beta}_{\lambda}^{\text{ridge}} = \frac{1}{1 + \lambda} \hat{\beta}.$$

## En pratique

Pour éviter les problèmes d'échelle, on ajoute cette matrice diagonale  $\lambda \text{Id}_n$  à la matrice  $X$  dont les colonnes ont été au préalable renormalisées et pour un signal  $Y$  recentré.

### Exercice

On note

- ▶  $Y^c = Y - \bar{Y}$
- ▶ pour tout  $j = 2, \dots, p$   $X^{j,S} = \frac{X^j - \bar{X}^j}{\text{sd}(X^j)}$  et  $X^S = (X^{2,S}, \dots, X^{p,S})$ .

Ecrire la correspondance les moindres carrés classiques  $\underset{\beta \in \mathbb{R}^p}{\operatorname{argmin}} \|Y - X\beta\|^2$  et les moindres carrés obtenus sur les variables renormalisées.

$$\underset{\gamma \in \mathbb{R}^{p-1}}{\operatorname{argmin}} \|Y^c - X^S \gamma\|^2$$

Dans l'estimateur des moindres carrés obtenus sur les variables renormalisées, on remplace  $(X^S)^\top X^S$  par  $((X^S)^\top X^S + \lambda \text{Id}_n)$ . C'est équivalent à considérer

### Pénalité ridge

$$\hat{\gamma}_\lambda^{\text{ridge}} = \underset{\gamma \in \mathbb{R}^p}{\operatorname{argmin}} \|Y^c - X^S \gamma\|^2 + \lambda \sum_{j=2}^p \gamma_j^2.$$

### Exercice

Que valent alors les estimateurs des coefficients de  $\beta^*$  ?

## Cross-validation pour $\lambda$

On a montré (dans le cas d'un design orthogonal) qu'il existe une valeur  $\lambda^*$  du paramètre de régularisation qui minimise le risque quadratique de l'estimateur ridge. Cette valeur idéale dépend de quantités inconnues, il faut donc l'estimer.

Si on avait à disposition d'autres données, on aurait

- ▶ des données d'apprentissage (training, learning set)

$$\mathcal{S}_L = \{(Y_1, X_1), \dots, (Y_n, X_n)\}$$

- ▶ des données de validation, de test (testing, validation set)

$$\mathcal{S}_T = \{(Y_{+,1}, X_{+,1}), \dots, (Y_{+,n'}, X_{+,n'})\} \text{ avec } Y_+ = X_+ \beta^* + \epsilon_+ \text{ ET } \epsilon \text{ et } \epsilon_+ \text{ indépendants.}$$



$$Y = X\beta + \epsilon$$

Hypo:  $\beta$  à estimer  
 $\epsilon \sim N(0, \sigma^2)$   
 on se donne une loi  $\rightarrow$  on veut prédire  
 $\rightarrow$  donner des inconnues en plus... (ces points)

t alors le modèle qui minimise l'erreur de généralisation.

On choisirait alors le modèle qui minimise l'erreur de généralisation. *(ces points)*

$$\mathbb{E}(\|Y_+ - \hat{Y}_+^{(\lambda)}\|^2) = \mathbb{E}(\|Y_+ - X_+ \hat{\beta}^{(\lambda)}\|^2) = \underbrace{n'(\Sigma_+^{-1})}_{n'} \mathbb{E}(\|X_+ \hat{\beta}^{(\lambda)} - X_+ \beta^*\|^2).$$
$$\mathbb{E}(\|\hat{Y}^{(\lambda)} - X\beta^*\|^2) = \mathbb{E}(\|X\hat{\beta}^{(\lambda)} - X\beta^*\|^2). \leftarrow \text{il y a pas}$$

## Estimation de l'erreur de généralisation

pour pouvoir choisir  $\lambda$  (on peut avoir plusieurs  $\lambda$ )  
selon la distance au grad.  
→ formule de test

On estime l'erreur de généralisation  $\mathbb{E}(\|Y_+ - \hat{Y}_+^{(\lambda)}\|^2) = \mathbb{E}(\|Y_+ - X_+ \hat{\beta}^{(\lambda)}\|^2)$  à partir de l'échantillon  $\mathcal{S}_T = \{(Y_{+,1}, X_{+,1}), \dots, (Y_{+,n'}, X_{+,n'})\}$  par

$$\frac{1}{n'} \sum_{i=1}^{n'} (Y_{+,i} - X_{+,i} \hat{\beta}^{(\lambda)})^2,$$

où  $\hat{\beta}^{(\lambda)}$  a été calculé sur l'échantillon d'apprentissage  $\mathcal{S}_L$  et pour la valeur  $\lambda$  du paramètre de régularisation.

## En pratique

70%

30%

port apprentissage >> port test

→ on n'est pas sûr (erreurs humaine)

Même en l'absence de données de validation (situation fréquente en pratique), on peut vouloir créer des données qui "ressemblent" à des données de test pour appliquer ce qui précède. Il y a deux grandes classes de méthodes : la cross-validation et le bootstrap.

?

?

## Leave-one-out (jackknife)

Long ...

Chaque observation joue à tour de rôle le rôle d'échantillon de validation.

Estimation de l'erreur de généralisation par leave-one-out

$$\mathbb{E}(\|\widehat{Y_+} - \widehat{Y_+^{(\lambda)}}\|^2)_{loo} = \frac{1}{n} \sum_{i=1}^n (Y_i - X_i \hat{\beta}_{(-i)}^{(\lambda)})^2,$$

où  $\hat{\beta}_{(-i)}^{(\lambda)}$  a été calculé sur l'échantillon  $\mathcal{S}_L \setminus (Y_i, X_i)$  et pour la valeur  $\lambda$  du paramètre.

## K-fold cross-validation

PB: quelle valeur pour le  $K$ ?

On découpe l'échantillon initial en  $K$  sous-ensembles pour obtenir la partition  $\mathcal{S}_L = \mathcal{S}_{L,1} \cup \dots \cup \mathcal{S}_{L,K}$ . Dans le cas, où  $n = Kn_K$ , on tire aléatoirement et sans remise dans  $\mathcal{S}_L$  pour former les  $\mathcal{S}_{L,k}$ .

### Estimation de l'erreur de généralisation par K-fold cross-validation

$$\widehat{eg(\lambda)}_{Kfold-cv} = \mathbb{E}(\|\widehat{Y_+} - \widehat{Y_+^{(\lambda)}}\|^2)_{Kfold-cv} = \frac{1}{n_K K} \sum_{k=1}^K \sum_{i=1}^{n_K} (Y_{k,i} - X_{k,i} \hat{\beta}_{(-k)}^{(\lambda)})^2,$$

où  $\hat{\beta}_{(-k)}^{(\lambda)}$  a été calculé sur l'échantillon  $\mathcal{S}_L \setminus \mathcal{S}_{L,k}$  et pour la valeur  $\lambda$  du paramètre.

On choisit alors

$$\hat{\lambda} = \arg \min_{\lambda \in \Lambda} \widehat{eg(\lambda)}_{Kfold-cv}$$

Pourquoi ?

## Propriété sur les variables corrélées

### Théorème - Zou et Hastie (2005)

On suppose que toutes les variables ont été renormalisées. Pour deux variables  $X^j$  et  $X^{j'}$ , on a

$$\frac{1}{\|Y\|} |\hat{\beta}_{\lambda}^{j, \text{ridge}} - \hat{\beta}_{\lambda}^{j', \text{ridge}}| \leq \frac{1}{\lambda} \sqrt{2(1 - \text{cor}(X^j, X^{j'}))}.$$

Permet de savoir qui il faut supprimer.

Les variables redondantes: - utile pour valider  
- moins pas pour prédire

## Régression sur PC

En considérant  $X^S$ , on peut décrire l'ACP via la formule

$$(X^S)^\top X^S = VD^2V^\top$$

les colonnes de  $V$  sont les vecteurs propres de  $X^S$  et également les composantes principales. La PCR consiste à régresser  $Y$  sur les  $m < p$  premières composantes principales.



Lasso et elastic-net

# Introduction


La régression ridge consiste à résoudre

$$\hat{\beta}_{\lambda}^{\text{ridge}} = \underset{\beta \in \mathbb{R}^p}{\operatorname{argmin}} \|Y - X\beta\|^2 + \lambda \sum_{j=1}^p \beta_j^2.$$

ce qui est équivalent à

$$\hat{\beta}_{\lambda}^{\text{ridge}} = \underset{\beta \in \mathbb{R}^p}{\operatorname{argmin}} \|Y - X\beta\|^2 \text{ s.c. } \sum_{j=1}^p \beta_j^2 < t.$$

# Introduction



# Introduction

En reprenant les idées de la construction du Cp de Mallows, on montre que

$$\hat{m}_{\text{Mallows}} = \underset{m}{\operatorname{argmin}} Cp(m) \simeq \hat{\beta}_{\lambda}^{\text{Mallows}} = \underset{\beta \in \mathbb{R}^p}{\operatorname{argmin}} \|Y - X\beta\|^2 + \lambda \|\beta\|_0.$$

C'est équivalent à

$$\hat{\beta}_{\lambda}^{\text{Mallows}} = \underset{\beta \in \mathbb{R}^p}{\operatorname{argmin}} \|Y - X\beta\|^2 \text{ s.c. } \|\beta\|_0 < t.$$

c'est pour  
cette raison ?

## Le lasso

Introduit en 1996 par Tibshirani, la lasso peut être vu comme un intermédiaire entre la régression ridge et la sélection  $\ell_0$ .

### Pénalité lasso

$$\begin{aligned}\hat{\beta}_{\lambda}^{\text{lasso}} &= \underset{\beta \in \mathbb{R}^p}{\operatorname{argmin}} \|Y - X\beta\|^2 + \lambda \sum_{j=1}^p |\beta_j| \\ &= \underset{\beta \in \mathbb{R}^p}{\operatorname{argmin}} \|Y - X\beta\|^2 + \lambda \|\beta\|_1.\end{aligned}$$

## Le lasso

### Solution lasso sur design orthogonal

Quand  $X^\top X = Id_p$ ,

$$\hat{\beta}_{\text{lasso}}^{(\lambda)} = \mathcal{S}_{\lambda/2}(Y^\top X),$$

avec  $\mathcal{S}_\tau(x) = \text{sign}(x)(|x| - \tau)_+$ .

# L'elastic net

## Elastic net

$$\hat{\beta}_{\lambda}^{\text{en}} = \underset{\beta \in \mathbb{R}^p}{\operatorname{argmin}} \|Y - X\beta\|^2 + \lambda_1 \|\beta\|_1 + \lambda_2 \|\beta\|_2^2$$

Attention dans `glmnet`, l'elastic-net est défini par

$$\hat{\beta}_{\lambda}^{\text{en}} = \underset{\beta \in \mathbb{R}^p}{\operatorname{argmin}} \|Y - X\beta\|^2 + \lambda \left( \alpha \|\beta\|_1 + \frac{1 - \alpha}{2} \lambda_2 \|\beta\|_2^2 \right)$$

## Comparaison sur simulation

On utilise la librairie `glmnet` On veut comparer sur le modèle

```
n=50
p=30
puis=c(0:9)
puis_petit=c(10:28)
beta=c(0.95^(puis),gamma^puis_petit)
X=cbind(matrix(rnorm(n*(p-1)),ncol=(p-1)))
epsilon=rnorm(n)
beta0=2
Y=beta0+X%%beta+epsilon
```

les différentes procédures d'estimation (Cp de Mallows, ridge, lasso, elastic net) , en terme

- ▶ de pouvoir de sélection (taille du modèle sélectionné, sensibilité (TP/(TP+FN)), spécificité (TN/(FP+TN)))
- ▶ d'erreur d'estimation  $\|\hat{\beta} - \beta^*\|$
- ▶ d'erreur de prévision  $\|X\hat{\beta} - X\beta^*\|$

On peut faire varier la corrélation entre les covariables via la fonction "covariates.matrix".