

MACHINE LEARNING M1

APPROCHES NON PARAMÉTRIQUES

V. Monbet

¹ Université de Rennes 1/UFR Mathématiques

Outline

Introduction

Méthodes des k plus proches voisins

Estimateur à noyau

Classification

Conclusion/discussion

Contexte

Données :

- ▶ Les "réponses" :
Cas de la régression : $y_i \in \mathbb{R}$ pour $i = 1, \dots, n$
Cas de la classification : $y_i \in C$ pour $i = 1, \dots, n$ et $C = \{1, \dots, k\}$
- ▶ Les "variables explicatives" ou "régresseurs", $x_i \in \mathbb{R}^p$ pour $i = 1, \dots, n$.
- ▶ Chaque paire (y_i, x_i) représente une expérience (individu).

Problème :

- ▶ Expliquer Y en fonction de X

Principe :

- ▶ Échantillon supposé iid : $(Y_1, X_1), (Y_2, X_2), \dots, (Y_n, X_n)$
→ modèle estimé $Y \simeq \hat{f}(X)$.

Exemples :

- ▶ Y : spam/non spam, X : type d'adresse d'expéditeur, nombre d'adresses, fréquence des mots du titre, fréquence des mots du message, nombre de mots dans le message, etc.
- ▶ Y : connection normale/connection attaque, X : temps de connection, heure de la connection, historique de cliques, etc.

Compromis biais/variance

Données :

- ▶ Les "réponses" : y_i pour $i = 1, \dots, n$
- ▶ Les "variables explicatives" ou "régresseurs", $x_i \in \mathbb{R}^p$ pour $i = 1, \dots, n$.

Problème :

- ▶ Estimer

$$f^* \in \arg \min_{f \in \mathcal{F}} \mathcal{R}(f) = E(\ell(Y, f(X)))$$


par $\hat{f}_n$ où l'indice n indique que $\hat{f}_n$ est construit à partir des n données disponibles.

- ▶ Exemple de la régression linéaire :
 - $\mathcal{F}$: ensemble des applications linéaires de $\mathbb{R}^p \rightarrow \mathbb{R}$
 - Fonction de perte : $\ell(Y, f(X)) = (Y - f(x))^2$

Modéliser signifie fixer une classe de fonctions $\mathcal{F}$ et supposer que $f^* \in \mathcal{F}$

Erreurs :

$$\mathcal{R}(\hat{f}) - \mathcal{R}^* = \underbrace{\mathcal{R}(\hat{f}) - \inf_{f \in \mathcal{F}}}_{\text{estimation}} + \underbrace{\inf_{f \in \mathcal{F}} - \mathcal{R}^*}_{\text{approximation}}$$



Ces deux erreurs varient dans des directions opposées et l'enjeu du machine learning est de trouver le bon compromis entre les deux termes.

Approches paramétriques vs non paramétriques

Dans les approches **paramétriques**

- ▶ régression linéaire multiple
- ▶ analyse discriminante, régression logistique

on fait des hypothèses fortes sur la forme du modèle f (ie sur l'ensemble $\mathcal{F}$). Le modèle dépend d'un vecteur de paramètres β on optimise un critère global pour estimer f

$$\hat{\beta} = \arg \min_{\beta} \frac{1}{n} \sum_{i=1}^n \|y_i - f(X_i; \beta)\|^2$$

→ erreur d'estimation faible et erreur d'approximation forte.

Les approches **non paramétriques**¹ sont moins restrictives ; l'ensemble $\mathcal{F}$ est plus large. Elles consistent à considérer les observations x_i qui sont au voisinage du point d'intérêt x_0 pour estimer

$$\hat{y}_0 = \hat{f}(x_0)$$

autrement dit, on considère un critère local.

→ erreur d'estimation forte et erreur d'estimation forte.

Exemple de méthodes non paramétriques

- ▶ Algorithme des k plus proches voisins
- ▶ Arbres de décision

Outline

Introduction

Méthodes des k plus proches voisins

Estimateur à noyau

Classification

Conclusion/discussion


Principe de l'algorithme des k-ppv

La prédiction associée à un nouvel individu $\mathbf{x}_0 \in \mathcal{X}$ est obtenue en cherchant dans l'ensemble d'apprentissage les k instances les plus proches de $\mathbf{x}_0$ et en calculant la moyenne des réponses correspondantes.

$$\hat{Y}(\mathbf{x}_0) = \frac{1}{k} \sum_{i|\mathbf{x}_i \in V(\mathbf{x}_0)} y_i$$

où $V(\mathbf{x}_0)$ est le voisinage de $\mathbf{x}_0$ ie

$$V(\mathbf{x}_0) = \{x \in \mathcal{X} | \text{dist}(x, \mathbf{x}_0) < \text{dist}(x_{(k)}, \mathbf{x}_0)\}$$



Quelles distances pour trouver les voisins

Pour trouver les k plus proches voisins de x_0 , on doit choisir une distance.

- ▶ Si les variables explicatives sont toutes quantitatives, la distance usuelle est la distance euclidienne

$$dist(\mathbf{x}_{i'}, \mathbf{x}_j) = \sqrt{\sum_{j=1}^p (x_{i'j} - x_{jj})^2}$$


Il est important de normaliser les données pour que toutes les variables aient la même échelle.

- ▶ Si une partie des variables explicatives sont des données qualitatives, on les transforme en "dummies" et on peut de nouveau utiliser la distance euclidienne.
- ▶ Si toutes les données sont qualitatives, il existe des distances spécifiques : distance du chi2, distance de Jaccard, etc.

Sélection du nombre de voisins - exemple

On estime deux modèles l'un avec 1 voisin et l'autre 8 voisins sur les données (simulées) :

$$y_i = (5x_i - 1)^2(x_i - 1) + u_i, \quad u_i \sim \mathcal{N}(0, 0.25)$$



- Plus le nombre de voisins est petit et plus le risque de sur apprentissage est fort. L'erreur d'estimation (variance) domine l'erreur d'approximation (biais).
- Plus le nombre de voisins est grand et plus on lisse la courbe. L'erreur d'approximation domine l'erreur d'estimation.

Validation croisée

En pratique, on estime le nombre optimal de voisins par **validation croisée**.
L'algorithme ci-dessous décrit la validation croisée Monte Carlo (S quelconque, de préférence grand).

Répéter S fois,

1. Séparer aléatoirement l'échantillon $(Z_1, \dots, Z_n)$ en deux ensembles : T (test) de taille n/v , et A (apprentissage) le complémentaire de T
2. Estimer le modèle sur A pour chaque nombre de voisins k
3. Calculer l'erreur de prédiction sur T pour chaque k


$$E(s, k) = \frac{v}{n} \sum_{i \in T} (\hat{y}_i(k) - y_i)^2$$

Estimer l'erreur moyenne pour chaque valeur de k


$$\widehat{MSE} = \frac{1}{S} \sum_{s=1}^S E(s, k)$$

Exemple

$$y_i = (5x_i - 1)^2(x_i - 1) + u_i, \quad u_i \sim \mathcal{N}(0, 0.25)$$



On répète $S = 50$ fois l'estimation par la méthode des k-ppv pour k variant de 1 à 10. Les boxplots de la figure du haut représentent la distribution des $\widehat{MSE}$.



Le graphique suggère de retenir 3 ou 4 voisins. Et on obtient l'estimation de la figure du bas.

Un des inconvénients de l'estimateur des plus proches voisins est qu'on soit rechercher les voisins. Même s'il existe des algorithmes permettant de faire des recherches rapides, le coût de calcul peu rester important.

Il existe bien sûr d'autres approches non paramétriques : estimateur à noyau, arbres de décision, etc.

Outline

Introduction

Méthodes des k plus proches voisins

Estimateur à noyau

Classification

Conclusion/discussion

Principe de l'estimation à noyau

La prédiction associée à un nouvel individu $\mathbf{x}_0 \in \mathcal{X}$ est obtenue en calculant une moyenne pondérée de l'ensemble des réponses contenues dans l'ensemble d'apprentissage

$$\hat{Y}(\mathbf{x}_0) = \frac{1}{n} \sum_{i=1}^n w(\mathbf{x}_0, \mathbf{x}_i) y_i$$

où le noyau w donne un poids plus fort aux points qui sont proches de $\mathbf{x}_0$.

Exemples de noyaux


- ▶ noyau Uniforme : $K(\mathbf{x}_0, \mathbf{x}) = \frac{1}{h} \mathbb{I}_{[\mathbf{x}_0 - h/2, \mathbf{x}_0 + h/2]}(\mathbf{x})$
C'est le noyau de l'histogramme.
- ▶ noyau Gaussien (radial basis) : $K(\mathbf{x}_0, \mathbf{x}) = \frac{1}{\sqrt{2\pi h^2}} \exp\left(-\frac{(\mathbf{x}_0 - \mathbf{x})^2}{h^2}\right)$
- ▶ noyau Tri cube : $(1 - |\mathbf{x}_0 - \mathbf{x}|^3)^3 \mathbb{I}_{|\mathbf{x}_0 - \mathbf{x}| < h}$

Le paramètre h , appelé largeur de fenêtre (bandwidth), contrôle la régularité de l'estimation. Plus h est grand et plus l'estimation est lisse.

Exemple

On estime deux modèles l'un avec $h^2 = 0.2$ et l'autre avec $h^2 = 0.05$ sur les données (simulées) :

$$y_i = (5x_i - 1)^2(x_i - 1) + u_i, \quad u_i \sim \mathcal{N}(0, 0.25)$$



Le choix de la largeur de fenêtre h est crucial,


- ▶ h petit réduit le biais, mais peut conduire à une forte variance,
- ▶ h grand permet de contrôler la variance mais augmente le biais.

L'estimation est plus lisse que celle de la méthode des plus proches voisins. Mais le temps de calcul peut devenir important si n est grand.

k-ppv et noyau

En machine learning, il est classique d'associer les deux méthodes pour combiner leurs avantages respectifs,

- ▶ on sélectionne les k plus proches voisins,
- ▶ on calcule une moyenne pondérée pour donner plus de poids aux voisins les plus proches de x_0 .



Outline

Introduction

Méthodes des k plus proches voisins

Estimateur à noyau

Classification

Conclusion/discussion


Méthode des plus proches voisins pour la classification

$$y_i \in C \text{ pour } i = 1, \dots, n \text{ et } C = \{1, \dots, L\}$$

Dans un cadre de classification, la méthode des plus proches voisins est similaire au cas de la régression.

- ▶ on sélectionne les k plus proches voisins comme précédemment
- ▶ on estime la réponse par un vote à la majorité

$$\hat{y}_0 = \arg \max_{\ell \in \{1, \dots, L\}} \sum_{i \in V(x_0)} \mathbb{I}_{y_i = \ell}.$$



Le classifieur de Bayes

Supposons que nous connaissions $P(Y = y|X = x)$ avec Y la variable de classe (à prédire) et X les variables explicatives. Dans ce cas, on prédit la classe la plus probable.

Le classifieur de Bayes prédit $y^* = \arg \max_y P(Y = y|X = x)$ et il est optimal au sens de l'erreur de classement.

Bien que le classificateur optimal de Bayes soit aussi bon que possible, il peut toujours commettre des erreurs. Il se trompe toujours si un échantillon n'a pas l'étiquette la plus probable. Nous pouvons calculer précisément la probabilité que cela se produise (ce qui correspond exactement au taux d'erreur) :

$$E_{BayesOpt} = 1P(Y = y^*|X = x)$$

Supposons par exemple qu'un courriel x puisse être classé comme spam (+1) ou non spam (-1). Pour le même courriel x , les probabilités conditionnelles sont les suivantes :

$$P(Y = +1|X = x) = 0.8, P(Y = -1|X = x) = 0.2$$

Dans ce cas, le classificateur optimal de Bayes prédit l'étiquette $y^* = +1$ comme étant la plus probable, et son taux d'erreur est le suivant

$$E_{BayesOpt} = 0.2$$

Convergence du l'estimateur du 1 ppv

Quand $n \rightarrow \infty$, l'erreur du 1 ppv n'est pas plus grande que 2 fois l'erreur du classifieur bayésien optimal (Cover and Hart, 1967). (Similar guarantees hold for $k > 1$)

On note Y la variable de classe et X les variables explicatives.

Soit x_{NN} le plus proche voisin du point x^* .

Quand $n \rightarrow \infty$, $dist(x_{NN}, x^*) \rightarrow 0$ On retourne la classe de x_{NN} . Quelle est la probabilité qu'elle soit différente de la classe de x^* ?

$$E_{NN} = P(Y = y|X = x^*)(1 - P(Y = y|X = x_{NN})) + P(Y = y|X = x_{NN})(1 - P(Y = y|X = x^*))$$

$$\begin{aligned} E_{NN} &\leq (1 - P(Y = y|X = x_{NN})) + (1 - P(Y = y|X = x^*)) \\ &= 2(1 - P(Y = y|X = x^*)) \\ &= 2E_{BayesOpt} \end{aligned}$$

L'inégalité vient du fait que $P(Y = y|X = x^*) \leq 1$ et $P(Y = y|X = x_{NN}) \leq 1$.

On utilise aussi $P(Y = y|X = x^*) = P(Y = y|X = x_{NN})$ à la limite.

Outline

Introduction

Méthodes des k plus proches voisins

Estimateur à noyau

Classification


Conclusion/discussion

Conclusion/discussion

- ▶ Les méthodes non paramétriques sont faciles à mettre en oeuvre, elles reposent essentiellement sur la distance entre les observations.
- ▶ Le choix des hyperparamètres (nombre de voisins, largeur de fenêtre) est crucial car il permet de trouver le bon équilibre entre le biais et la variance.
- ▶ Les méthodes des plus proches voisins et de l'estimation à noyau conduisent à des modèles qui ne sont pas interprétables : elles n'aident pas à comprendre les phénomènes en jeu.

Le fléau de la dimension


- ▶ Les méthodes non paramétriques souffrent (toujours) du fléau de la dimension : plus la dimension augmente, moins nous avons d'observations dans le voisinage de x_0 et plus la vitesse de convergence est lente (ie il faut plus d'observations pour obtenir une certaine qualité d'estimation).



<https://www.visiondummy.com/2014/04/curse-dimensionality-affect-classification/>

Exemple de la sphère en grande dimension

Volume de la sphere dans $\mathbb{R}^d$: $V = cr^d$.



Grand cercle $r_o = 1$,


Petit cercle $r_i = .95$

$$V = cr_o^d = c,$$

$$V_{\text{shell}} = c - cr_i^d,$$

Volume du bord de la sphere :

$$\frac{V_{\text{shell}}}{V} = 1 - r_i^d$$



Quand la dimension augmente, la plupart des points appartiennent à la fraction du "bord" de la sphère. Le volume à l'intérieur de la petite sphère est presque vide...

Il est difficile de trouver de bons voisins dans ce cas !