

MACHINE LEARNING M1

APPROCHES NON PARAMÉTRIQUES

ARBRES DE DÉCISION

V. Monbet

¹ Université de Rennes 1/UFR Mathématiques

Plan

Introduction

Exemple en régression

Algorithme de construction d'un arbre de régression

Arbres de classification

Conclusion

Contexte

Données :

- ▶ Les "réponses" :

Cas de la régression : $y_i \in \mathbb{R}$ pour $i = 1, \dots, n$

Cas de la classification : $y_i \in C$ pour $i = 1, \dots, n$ et $C = \{1, \dots, k\}$

- ▶ Les "variables explicatives" ou "régresseurs", $x_i \in \mathbb{R}^p$ pour $i = 1, \dots, n$.
- ▶ Chaque paire (y_i, x_i) représente une expérience (individu).

Problème :

- ▶ Expliquer Y en fonction de X

Principe :

- ▶ Échantillon supposé iid : $(Y_1, X_1), (Y_2, X_2), \dots, (Y_n, X_n)$
→ modèle estimé $Y \simeq \hat{f}(X)$.




Exemples :

- ▶ Y : spam/non spam, X : type d'adresse d'expéditeur, nombre d'adresses, fréquence des mots du titre, fréquence des mots du message, nombre de mots dans le message, etc.
- ▶ Y : connection normale/connection attaque, X : temps de connection, heure de la connection, historique de cliques, etc.

Principe des arbres de décision

- ▶ Le principe des algorithmes d'arbre de décision est de partitionner l'espace en rectangles et d'ajuster un modèle (très) simple dans chaque région.
- ▶ Le concept est simple mais souvent efficace.
- ▶ Par exemple, considérons un problème de régression pour prédire une réponse continue $Y \in \mathcal{Y}$ à partir de 2 entrées X_1 et X_2 prenant chacune ses valeurs dans l'intervalle unité. Dans chaque cellule R_m , Y est prédit par la valeur moyenne c_m des valeurs observées dans la cellule.

$$\hat{f}(x) = \sum_{m=1}^M c_m \mathbb{I}_{R_m}(X_1, X_2)$$



Plan

Introduction

Exemple en régression


Algorithme de construction d'un arbre de régression

Arbres de classification

Conclusion


Exemple, Ozone (2 variables explicatives)

- Maximum d'O3 journalier en fonction de la température et de l'intensité du vent à 12h.




Exemple, Ozone

- Maximum d'O3 journalier en fonction de la température et de l'intensité du vent à 12h.




Exemple, Ozone

- Maximum d'O3 journalier en fonction de la température et de l'intensité du vent à 12h.




Exemple, Ozone

- Maximum d'O3 journalier en fonction de la température et de l'intensité du vent à 12h.




Exemple, Ozone

- Maximum d'O3 journalier en fonction de la température et de l'intensité du vent à 12h.




Exemple, Ozone

- Maximum d'O3 journalier en fonction de la température et de l'intensité du vent à 12h.




Exemple, Ozone

- Maximum d'O3 journalier en fonction de la température et de l'intensité du vent à 12h.




Exemple, Ozone

- Maximum d'O₃ journalier en fonction de la température et de l'intensité du vent à 12h.




Exemple, Ozone

- Maximum d'O3 journalier en fonction de la température et de l'intensité du vent à 12h.




Exemple, Ozone

- Maximum d'O3 journalier en fonction de la température et de l'intensité du vent à 12h.




Exemple, Ozone

- Maximum d'O3 journalier en fonction de la température et de l'intensité du vent à 12h.




Exemple, Ozone

- Maximum d'O3 journalier en fonction de la température et de l'intensité du vent à 12h.




Exemple, Ozone

- Maximum d'O3 journalier en fonction de la température et de l'intensité du vent à 12h.




Exemple, Ozone

- Maximum d'O3 journalier en fonction de la température et de l'intensité du vent à 12h.




Exemple, Ozone

- Maximum d'O3 journalier en fonction de la température et de l'intensité du vent à 12h.



Représentation graphique



- Dans chaque noeud, on a le nom de la variable qui divise ainsi que son seuil de division, l'erreur aux moindres carrés et le nombre d'observation de la sous-région ainsi que la prédiction associée.
- Les noeuds terminaux sont appelés "feuilles".

Plan

Introduction

Exemple en régression


Algorithme de construction d'un arbre de régression

Arbres de classification

Conclusion

Construction d'un arbre de décision : algorithme glouton

- Trouver la partition qui minimise l'erreur aux moindres carrés $\sum_{i=1}^n (y_i - f(\mathbf{x}_i))^2$, avec f un arbre de décision, est numériquement impossible (trop coûteux).
- Les arbres sont estimés par un algorithme itératif qui construit une suite de partitions imbriquées.
- A chaque itération, l'algorithme choisit la variable et le seuil qui permettent d'obtenir une nouvelle division pour une sous région de la partition.
Critère de division : on cherche une division telle que la somme pondérée des variances des régions enfants soit inférieure à la variance de la région parent.
- Exemple : prédiction du maximum d'ozone journalier



Variance avant la division : 794

Moyenne des variances après division : 299

- Quand la partition finale est obtenue, la fonction de régression est

$$f(\mathbf{x}) = \sum_{m=1}^M c_m \mathbb{I}_{R_m}(\mathbf{x}) \text{ avec } c_m = \frac{1}{|\{i | \mathbf{x}_i \in R_m\}|} \sum_{\{i | \mathbf{x}_i \in R_m\}} y_i$$

Une itération de l'algorithme

- Considérons toutes les données de la région R_m , une variable de division x_j et un seuil s , on définit les sous régions

$$R_{m1}(j, s) = \{\mathbf{x} \in R_m | x_j \leq s\} \text{ and } R_{m2}(j, s) = \{\mathbf{x} \in R_m | x_j > s\}$$

- On cherche alors la variable x_{j^*} et le seuil s^* tels que

$$(j^*, s^*) = \arg \min_{j, s} \left(\sum_{\{i | \mathbf{x}_i \in R_{m1}(j, s)\}} (y_i - c_1)^2 + \sum_{\{i | \mathbf{x}_i \in R_{m2}(j, s)\}} (y_i - c_2)^2 \right).$$

avec

$$c_1 = \sum_{\{i | \mathbf{x}_i \in R_1\}} y_i \text{ et } c_2 = \sum_{\{i | \mathbf{x}_i \in R_2\}} y_i$$

- Pour chaque variable, le choix du seuil s est (numériquement) très rapide et la sélection de la meilleure paire (j, s) est faisable.

Critères d'arrêt

Les divisions sont répétées jusqu'à atteindre au moins un critère d'arrêt.


Les critères d'arrêt classiques sont

- ▶ le nombre minimum d'observations pour faire une division : si le nombre d'observations est faible l'estimation des variances risque d'être biaisée et bruitée ;
- ▶ le nombre minimum d'observations par feuille : si le nombre d'observations est faible la prédiction de la variable cible sera peu précise (forte variance d'estimation) ;
- ▶ la profondeur maximum : un arbre trop profond conduit à une situation de sur-apprentissage.

Une alternative consiste à considérer un ensemble de validation pour faire de la validation croisée. On arrête alors l'algorithme lorsque l'erreur de prédiction de l'ensemble de validation ne décroît plus assez.

Une autre façon de poser la question : Quelle est la bonne taille pour un arbre de décision ?


- **Compromis biais-variance** : un arbre profond risque de faire du sur-apprentissage tandis qu'un arbre trop petit ne va pas permettre de capturer les structures importantes.



- La profondeur de l'arbre contrôle le compromis entre le biais et la variance
 - **Profondeur faible** (= peu de divisions) conduit à des arbres avec une **faible variance** mais un **fort biais**
 - **Profondeur importante** (= beaucoup de divisions) conduit à des arbres avec une **forte variance** et un **biais faible**.


Exemple

$$y_i = (5x_i - 1)^2(x_i - 1) + u_i, \quad u_i \sim \mathcal{N}(0, 0.25)$$



On répète $S = 50$ fois l'estimation d'un arbre avec un nombre minimum d'observations par feuille variant de 1 à 10.

Les boxplots de la figure du haut représentent la distribution des $\widehat{MSE}$.



Le graphique suggère de retenir 1 ou 2 observations par feuille. Et on obtient l'estimation de la figure du bas.

Optimiser la profondeur d'un arbre de décision

- ▶ La stratégie classique est de construire un arbre trop profond $\mathbb{T}_0$, en stoppant par exemple l'algorithme lorsque le nombre minimum d'observations par nœud est atteint. Puis l'arbre est élagué pour optimiser un critère coût-complexité.
- ▶ Le critère **coût-complexité** est défini par



$$C_\alpha(\mathbb{T}) = \underbrace{\sum_{m=1}^{|\mathbb{T}|} N_m Q_m(\mathbb{T})}_{\text{cost}} + \underbrace{\alpha |\mathbb{T}|}_{\text{complexity}}$$

where $N_m = \text{Card}(\{\mathbf{x}_i \in R_m\})$ et $Q_m(T) = \frac{1}{N_m} \sum_{\{i|\mathbf{x}_i \in R_m\}} (y_i - \hat{c}_m)^2$. $|\mathbb{T}|$ définit la profondeur de l'arbre.

- ▶ L'idée est de trouver pour chaque α , le sous arbre $\mathbb{T}_\alpha$ de $\mathbb{T}$ qui minimise $C_\alpha(\mathbb{T})$.
- ▶ α est appelé **complexity parameter**.
Il joue un rôle similaire à la constante de régularisation introduite dans la régression pénalisée.
- ▶ En pratique sélectionne α par validation croisée 5- ou 10-fold.

Exemple d'élitage

Arbre trop profond à gauche et arbre élagué à droite.



Courbe à approcher (bleu), observations bruitées (noir) et estimation (rouge).

Plan

Introduction

Exemple en régression

Algorithme de construction d'un arbre de régression

Arbres de classification

Conclusion

Arbres de classification

- ▶ Quand $\mathcal{Y} = \{1, \dots, K\}$ i.e. Y est une variable qualitative, les algorithmes d'arbre sont similaires au cas de la régression pour une variable quantitative.
- ▶ La principale différence est le choix du critère à optimiser pour choisir la variable et le seuil de division.¹
On choisit un critère I de mesure d'homogénéité parmi ceux proposés ci-dessous et on cherche le couple (j^*, s^*) qui permet le meilleur gain d'homogénéité.
- ▶ La prédiction dans une feuille R_m est donnée par un vote à la majorité

$$\hat{y} = \arg \max_{k \in \mathcal{Y}} \hat{p}_{mk}$$

où

$$\hat{p}_{mk} = \frac{1}{N_m} \sum_{i | \mathbf{x}_i \in R_m} \mathbb{I}(y_i = k)$$

- ▶ Critères : indice de Gini ou entropie [algorithme CART], test du chi2 [algorithme CHAID].

1. Dans le cas de la régression, on utilise la variance.

Mesures d'impureté

- L'**indice de Gini** est une mesure d'inégalité. Il a été introduit pour mesurer des inégalité de revenu.
Il est égal à 0 en cas de totale égalité (homogénéité parfaite) et 1 en cas de totale inégalité.

$$I_m = 1 - \sum_{k=1}^K p_{mk}^2$$

avec $p_{mk} = \frac{1}{N_m} \sum_{i|x_i \in R_m} \mathbb{I}_{\{y_i=k\}}$, m le numéro de sous région et k le numéro de classe.

Dans le cas d'une variable dichotomique, l'indice de Gini calcule une variance. Il est donc très proche du critère utilisé en régression.

- L'**entropie** peut être interprétée comme une mesure de désordre.
Une entropie nulle correspond à un milieu parfaitement ordonné (ie une sous région parfaitement homogène).

$$E_m = \sum_{k=1}^K p_{mk} \log p_{mk}$$

- En général, on n'utilise pas l'erreur de classification car elle est moins sensible et a tendance à sélectionner des divisions qui conduisent à des nœuds qui ne sont pas purs.

Test du χ^2

Certains algorithmes se basent sur un test du χ^2 pour sélectionner la variable et le seuil de division.

Plan

Introduction

Exemple en régression

Algorithme de construction d'un arbre de régression

Arbres de classification

Conclusion

Remarques de conclusion

Les arbres de décision ont un certain nombre d'avantages :

- ▶ Ce sont des modèles non paramétriques (très proches du modèle des ppv) qui permettent de prendre en compte des relations non linéaires entre les variables.
- ▶ Les arbres nécessitent peu ou pas de pré-traitement.
Par exemple, il est inutile de faire des transformations marginales. En particulier, les outliers des variables prédictives ont relativement peu d'impact sur le choix des divisions.
- ▶ Les arbres prennent en compte les variables explicatives catégorielles à plus de 2 modalités. Voir J. Friedman, Hastie, and Tibshirani (2001).
- ▶ Les valeurs manquantes ne posent pas non plus de problème Une solution classique consiste à créer pour chaque variable une catégorie "missing".

Mais, les performances prédictives des arbres de décision sont souvent un peu en dessous de celles d'autres algorithmes. Ceci est dû au fait que les arbres sont composés par des règles très simples qui conduisent à des décisions qui ne sont pas lisses. De plus les arbres profonds ont une forte variance et les arbres peu profonds un fort biais.

Références

Breiman, Leo. 1984. Classification and Regression Trees. Routledge.

Breiman, Leo, and Ross Ihaka. 1984. Nonlinear Discriminant Analysis via Scaling and Ace. Department of Statistics, University of California.

Friedman, Jerome, Trevor Hastie, and Robert Tibshirani. 2001. The Elements of Statistical Learning. Vol. 1. Springer Series in Statistics New York, NY, USA :