
Rapport Étude 1 - APST

Classification de cancer à partir de données ARN

Enseignant :
Mme MAUMY

Étudiant :
Nathan HASCOET

9 mars 2026

1 Le jeu de données

Le jeu de données contient 801 patients et 20 532 gènes (les variables). Dans tous les scripts fournis l'ensemble du jeu de données a été exploité.

2 Organisation des différents scripts python

Voici une courte description des différents scripts :

ACP.py : Ce script applique bêtement une ACP sur l'ensemble du jeu de données

K-means.py : Ce script applique un algorithme des K-means sur l'ensemble des données

CAH.py : Ce script effectue une classification ascendante hiérarchique sur l'ensemble des données


Analyse_Discriminante.py : Analyse discriminante linéaire et quadratique sur l'ensemble des données puis sur une partie des variables synthétiques créées

Objectifs


1. Être capable de prédire qu'il y a bien 5 types de cancers dans ce jeu de données
2. Réussir à prédire correctement le cancer de chacun des patients.

3 ACP.py

Nous avons effectué une Analyse en composantes principales sur l'ensemble des données, ayant bien sûr moins de 20 532 patients, le nombre de composantes principales non nuls est inférieur ou égale à 801. Pour connaître le nombre de variables à prendre en compte pour ne pas ou perdre le moins possible d'informations, nous traçons le graphique des inerties cumulées :




Pour obtenir 95% de l'inertie totale, 530 variables (synthétiques obtenue après l'ACP) sont suffisantes. On remarque aussi que les 2 première variables ne contiennent que peux d'informations de l'inertie totales :




Bien que l'on soit capable de réduire considérablement le nombre de variables, mais le fait le nombre de patients est bien moindre que le nombre de variables il semble pertinent de garder l'ensemble des variables dans un premier temps, au vu du temps de calcul nécessaire.

4 K-means

Aucune ACP n'a été effectuée au préalable, nous avons choisi autant de classes que de cancer listés dans le jeux de donnés (5). Le nombre de fois que l'algorithme de Kmeans a été exécuté a été choisi à 50, et parmi ces 50 familles de centroides, la famille avec la meilleur inertie est choisie. Le taux de mal classé est assez faible malgré cela : 0.749 %.




Si l'on augmente le nombre de classe de 1 puis 2 (6 et 7 classes), et le taux de mal classé est le même pour ces 3 cas (à l'approximation choisie : 3 décimales) : 0.749 %.




On remarque que dans les deux cas, la classe des cancer BRCA se scinde en 2 puis en 3, c'est un phénomène que nous allons constater aussi, d'une certaine manière, à l'aide d'une classification hiérarchique des données qui permettra de justifier ce scindage en 2 de cette catégorie.

A partir de 3 classes en plus (donc 8 au total), le taux de mal classé diminue de 0.3 % : 0.499 %
Et cette fois on constate que c'est la classe de cancer nommé KIRC qui se scinde en 2.




5 Classification Hiérarchique Ascendante


Regardons le graphique de la différence de variance interclasse lors de la fusion de 2 classes (sur l'axes des ordonnées, il a été volontairement indiqué chacune des valeurs pour visualiser les sauts) :



On remarque qu'à partir de 789, les saut des distances sont significatifs, Changement que l'on observe sur le graphique des variance interclasse (qui correspond à la variance interclasse : 1781) :




On remarque tout de suite que ce seuil (789) correspond à 6 classes et non pas 5. En choisissant ce seuil de 789 on obtient le dendrogramme suivant :



Et le taux de mal classé est de 0.499 % (taux très semblable à celui obtenu à la méthode des K-means)

Et nous pouvons constater de nouveau que c’est la catégorie de Cancer BRCA qui se scinde en 2.

Si nous changeons le seuil et le choisissons à 1500 nous aurons les 5 classes de cancers :



Le taux de mal classé est de : 0.499 %

6 Analyse discriminante

Il a été choisi d’effectuer une analyse discriminante linéaire et quadratique sur l’ensemble des données.

Pour l’analyse discriminante **linéaire** et **quadratique**, l’erreur est très faible : pour la **quadratique** il n’y a pas d’erreur (mais un message d’erreur comme quoi, évidemment, les données sont corrélés), et pour la linéaire il y a **1** unique erreur.


Il a été effectué, après coup, une validation croisée (entraînement sur les 2/3 des données et test sur 1/3 des données, le choix est fait aléatoirement, et ce choix est refait 10 fois puis moyenné). Et à ce test les 2 algorithmes sont bien moins performant (phénomène de sur-apprentissage à priori) :

linéaire : 26.18 %


quadratique : 69.963 %

C’est pour cette raison que le choix a été fait de faire une ACP puis d’effectuer une analyse discriminante sur les 40 première composantes principales. Les résultats sont bien plus probant (à partir de 9 composantes principales, l’erreur d’apprentissage retombe à 0 pour l’analyse discriminante quadratique).


ACP puis Linéaire



ACP puis Quadratique



On constate qu'il ne suffit que d'une dizaine de composantes principales pour obtenir des prédictions qui semblent être de bonne qualité.



scikit-learn permet de facilement tracer les plans factoriels qui permettent de discriminer **visuellement** les 5 groupes bien plus rapidement qu'avec une simple ACP.

7 Conclusion

1. **BRCA** : le phénomène constaté semble pertinent à être considéré, en effet en faisant une rapide recherche nous constatons que le cancer BRCA se scinde en 2 types de cancer. Cette éventuelle interprétation, n'est appuyé que par une simple et courte recherche sur internet, l'appui d'un ou d'une experte aurait été plus que pertinente.
2. Une chose curieuse que je n'ai pu expliquer est que la matrice de variance intraclasse est à priori non inversible, mais cela ne provoque pas d'erreur sur l'analyse discriminante linéaire (contrairement à l'analyse discriminante quadratique) pour l'algorithme fourni par la bibliothèque scikit-learn.
3. L'interprétation des résultats s'avère compliqué sachant que je n'ai presque aucunes connaissances médicales, l'ajustement des paramètres est donc très probablement grandement discutable.
4. Il aurait pu être intéressant de croiser la CAH ou les K-means pour créer cette 6^{ième} catégorie de cancer puis d'appliquer une analyse discriminantes pour voir s'il était possible d'expliquer ces résultats à l'aide des variables.