

RÉGRESSION LINÉAIRE

1

INTRODUCTION

Présentation déterministe


Données :

- Les « réponses » $y_i \in \mathbb{R}$, $i = 1, \dots, n$
- Les « variables explicatives », ou « régresseurs », $x_i \in \mathbb{R}$, $i = 1, \dots, n$.

Chaque paire (y_i, x_i) représente une expérience, un « individu ».

Approcher au mieux y_i par une fonction affine de x_i :

$$y_i \simeq ax_i + b.$$



Rappels (?)

$x = (x_1, \dots, x_n)^T$ et $y = (y_1, \dots, y_n)^T$ deux vecteurs de $\mathbb{R}^n$, p. ex. des paires (âge, revenu) pour des individus.

Moyenne empirique : $\bar{x} = \frac{1}{n} \sum x_j$

Individu recentré : $x_j - \bar{x}$

Variance empirique : $\sigma_x^2 = s_x^2 = \text{Var}(x) = \overline{(x - \bar{x})^2} = \overline{x^2} - \bar{x}^2$

Ecart-type : $\sigma_x = s_x = \sqrt{\text{Var}(x)}$

Covariance empirique : $c_{xy} = \text{Cov}(x, y) = \overline{(x - \bar{x})(y - \bar{y})} = \overline{xy} - \bar{x}\bar{y}$

Coefficient de corrélation : $r_{xy} = \text{Cor}(x, y) = \frac{c_{xy}}{s_x s_y}$

Moindres carrés

On minimise la somme des carrés d'écarts résiduels (erreurs de prédiction)

$$\min_{a,b} SS(a, b), \quad SS(a, b) = \sum_i (y_i - ax_i - b)^2$$

Annulation des dérivées en a et en b


$$\sum_i x_i (ax_i + b - y_i) = 0$$

$$\sum_i ax_i + b - y_i = 0.$$

On trouve

$$\begin{aligned} \hat{a} &= \frac{c_{xy}}{s_x^2} = r_{xy} \frac{s_y}{s_x} \\ \hat{b} &= \bar{y} - \hat{a}\bar{x} \end{aligned}$$

1. INTRODUCTION



$$\hat{b} = 57$$

$$\hat{a} = 0,52$$

Décomposition de la variance

Prédictions et résidus (ou erreurs de prédiction ou écarts résiduels) :

$$\hat{y}_i = \hat{a}x_i + \hat{b}$$

$$\hat{u}_i = y_i - \hat{y}_i = y_i - \hat{a}x_i - \hat{b}$$

Définition (Coefficient de détermination)

$$R^2 = 1 - \frac{s_{\hat{u}}^2}{s_y^2}$$

Il est d'autant plus proche de 1 que la régression s'attache aux données.

Proposition (Décomposition de la variance)

$$s_y^2 = s_{\hat{y}}^2 + s_{\hat{u}}^2$$

$$R^2 = \frac{s_{\hat{y}}^2}{s_y^2} = \text{Cor}(x, y)^2.$$

Démonstration : On remarque que

$$s_{\hat{y}}^2 + s_{\hat{u}}^2 + 2\text{Cov}(\hat{y}, \hat{u}) = s_{\hat{y}+\hat{u}}^2 = s_y^2.$$

Il s'agit donc de montrer que $\text{Cov}(\hat{y}, \hat{u}) = 0$. Mais

$$\text{Cov}(\hat{y}, \hat{u}) = \text{Cov}(\hat{y}, y) - \text{Cov}(\hat{y}, \hat{y}) = \text{Cov}(\hat{y}, y) - s_{\hat{y}}^2$$

et

$$\text{Cov}(\hat{y}, y) = \hat{a}\text{Cov}(x, y) + \text{Cov}(\hat{b}, y) = \hat{a}^2 s_x^2 = s_{\hat{y}}^2. \quad (*)$$



On a bien $\text{Cov}(\hat{y}, \hat{u}) = 0$.

Pour la dernière relation, on divise (*) par $s_y s_{\hat{y}}$:

$$\frac{s_{\hat{y}}}{s_y} = \frac{\text{Cov}(\hat{y}, y)}{s_y s_{\hat{y}}} = \text{Cor}(\hat{y}, y) = \text{sign}(\hat{a}) \text{Cor}(x, y).$$

Comparaison de R^2

Le deuxième ensemble consiste en des mesures de pression atmosphérique en fonction de la température d'ébullition de l'eau en divers endroits de l'Himalaya.



Bilan sur le R^2 : Il mesure l'adéquation du modèle au données, ce qui revient à la corrélation entre régresseurs et réponses.

2

Régression linéaire multiple

Les données

- ▶ Variables observées (ou réponses) y_i
- ▶ Variables explicatives (ou régresseurs) x_i , $i = 1, \dots, n$,
- ▶ Chaque paire (y_i, x_i) représente une expérience (individu).

Arrangement en tableau :

$$y = \begin{pmatrix} y_1 \\ \vdots \\ y_n \end{pmatrix}, \quad X = \begin{pmatrix} x_1 \\ \vdots \\ x_n \end{pmatrix} = \begin{pmatrix} 1 & x_{12} & \dots & x_{1p} \\ \vdots & \vdots & & \vdots \\ 1 & x_{n2} & \dots & x_{np} \end{pmatrix}.$$

x_i est donc un vecteur ligne. On convient généralement que le premier régresseur est la constante.

On cherche à prédire les y_i au mieux à l'aide des x_{ij} :

$$y_i \simeq x_i \beta = \beta_1 + \sum_{j=2}^p x_{ij} \beta_j, \quad i = 1, \dots, n,$$

pour un certain β à trouver. Ceci se réécrit de manière plus compacte

$$y = X\beta + u$$

$x_i \beta$ est la prédiction linéaire de y_i par x_i et u_i l'erreur de prédiction (à réduire).

Moindres carrés

Définition

Pour tout β , on définit l'erreur quadratique d'ajustement (ou erreur résiduelle) $SS(\beta)$ comme

$$SS(\beta) = \|y - X\beta\|^2 = \sum_i (y_i - x_i\beta)^2.$$

Le vecteur des coefficients de régression calculés aux moindres carrés ordinaires est

$$\hat{\beta} = \arg \min_{\beta} SS(\beta)$$

SS=Sum of Squares

Résolution

Théorème

On suppose la matrice $X^T X$ inversible. Alors $\hat{\beta}$ est donné par

$$\hat{\beta} = (X^T X)^{-1} X^T y.$$

En effet :

$$\frac{\partial SS(\beta)}{\partial \beta_j} = \sum_i \frac{\partial}{\partial \beta_j} (x_i \beta - y_i)^2 = \sum_i 2x_{ij}(x_i \beta - y_i) = 2(X^T(X\beta - y))_j$$

d'où l'équation $X^T(X\beta - y) = 0$.

Rq : On peut vérifier que pour tout β

$$SS(\beta) = SS(\hat{\beta}) + \|X(\beta - \hat{\beta})\|^2$$

ce qui est une autre façon de démontrer l'optimalité de $\hat{\beta}$.

Exemple : le modèle de Cobb-Douglas.

On considère les variables, chacune concernant la totalité des États-Unis et i étant l'indice d'une année :

- P_i : production
- K_i : capital (valeur des usines)
- T_i : travail fourni (basé sur un calcul du nombre total de travailleurs)

Expliquer P_i à l'aide de (K_i, T_i) . Modèle de Cobb et Douglas¹ :

$$P = \alpha K^{\beta_2} T^{\beta_3}.$$

α , β_2 et β_3 sont les paramètres du modèle. On va prendre le logarithme dans cette équation, ce qui nous ramène au cas linéaire.

$$y = \sum_{j=1}^3 \beta_j x_j$$

$$\beta_1 = \log(\alpha)$$

$$y = \log(P)$$

$$x = (1, \log(K), \log(T)).$$

1. "A theory of production", *American Economic Review*, 18, 139-165, 1928.

Données utilisées par Cobb et Douglas (1928) :

Année	P	K	T	Année	P	K	T	Année	P	K	T
1899	100	100	100	1907	151	176	138	1915	189	266	154
1900	101	107	105	1908	126	185	121	1916	225	298	182
1901	112	114	110	1909	155	198	140	1917	227	335	196
1902	122	122	118	1910	159	208	144	1918	223	366	200
1903	124	131	123	1911	153	216	145	1919	218	387	193
1904	122	138	116	1912	177	226	152	1920	231	407	193
1905	143	149	125	1913	184	236	154	1921	179	417	147
1906	152	163	133	1914	169	244	149	1922	240	431	161

On trouve $\beta_1 = 0.23$ et $\beta_2 = 0.81$.

On peut vérifier par une méthode d'intervalle de confiance que l'écart mesuré entre $\beta_1 + \beta_2$ et 1 n'est pas significatif.

Définition

- Vecteur des valeurs ajustées (prédictions) : $\hat{y} = X\hat{\beta}$, soit $\hat{y}_i = x_i\hat{\beta}$.
- Vecteur des résidus (erreurs de prédiction) : $\hat{u} = y - \hat{y}$.

Définition (Coefficient de détermination)

$$R^2 = 1 - \frac{s_u^2}{s_y^2}$$

Il est d'autant plus proche de 1 que la régression s'attache aux données.

Décomposition de la variance

Proposition (Décomposition de la variance)

On a

$$s_y^2 = s_{\hat{y}}^2 + s_{\hat{u}}^2$$

$$TSS = ESS + RSS$$

Var. Totale = Var. Expliquée + Var. Résiduelle.

En particulier

$$R^2 = \frac{s_{\hat{y}}^2}{s_y^2} = \text{Cor}(\hat{y}, y)^2.$$

Attention TSS , RSS et ESS sont non-normalisés : $RSS = \sum (y_i - \hat{y}_i)^2 = ns_{\hat{u}}^2$.

Exemple : Cobb-Douglas.

Dans le cas du modèle de Cobb-Douglas, on trouve

$$s_y^2 = 2,3 \quad s_{\hat{y}}^2 = 1,6 \quad s_u^2 = 0,7$$
$$R^2 = 0,7$$

On dit que *le travail et le capital investi expliquent 70% de la variabilité de la production* (en fait son logarithme).

Exemple : Consommation des voitures.

Pour 82 voitures, on dispose des variables suivantes ²

C : Consommation (litres au cent)

Vol : Volume de l'habitacle

Pui : Puissance

Vit : Vitesse maximale

Pd : Poids.

On se propose de prédire la consommation à l'aide des quatre autres variables.

2. R.M. Heavenrich, J.D. Murrell, and K.H. Hellman, "Light Duty Automotive Technology and Fuel Economy Trends Through 1991, U.S.", Environmental Protection Agency, 1991. Emprunté à la page internet de Larry Wasserman.

Exemple (suite)

Premier modèle :

$$C \simeq \beta_1 + \beta_2.Vol + \beta_3.Pui + \beta_4.Vit + \beta_5.Pd$$

On trouve $R^2 = 0.92$.

Des tentatives montrent que l'on a intérêt à inclure le carré du poids :

$$C \simeq \beta_1 + \beta_2.Vol + \beta_3.Pui + \beta_4.Vit + \beta_5.Pd + \beta_6.Pd^2$$

On trouve $R^2 = 0.93939$.

De nouvelles tentatives montrent que le volume est en fait inutile :

$$C \simeq \beta_1 + \beta_2.Pui + \beta_3.Vit + \beta_4.Pd + \beta_5.Pd^2$$

On trouve $R^2 = 0.939386$.

Le modèle explique 94% de la variabilité de la consommation de la voiture.

Sélection des variables par méthode ascendante :

Ajouter les régresseurs un par un en choisissant à chaque fois celui qui minimise le plus le RSS :

Méthode Ascendante (forward stepwise) :

- 1 Partir du modèle avec la constante : $M = \{1\}$
- 2 Pour tout $j \notin M$: Considérer le modèle $M \cup \{j\} \rightarrow RSS(M \cup \{j\})$
- 3 Inclure à M la variable de moindre $RSS(M \cup \{j\})$
- 4 Repartir à 2

Rq : À l'étape j , on n'a pas forcément obtenu le meilleur modèle à j variables.

Il existe aussi la méthode descendante : elle part du modèle complet et élimine à chaque étape le régresseur le moins bon en terme de saut de RSS.

3

VARIABLES EXPLICATIVES CATÉGORIELLES

3. VARIABLES EXPLICATIVES CATÉGORIELLES

Le salaire en fonction de l'âge et du statut marital. Création de dummy variables :

$$y = \begin{pmatrix} 1200 \\ 3000 \\ 2700 \\ 500 \\ 1500 \\ 750 \\ 2100 \\ 2200 \end{pmatrix}, \quad \begin{pmatrix} 25 & \text{Marié} \\ 30 & \text{Marié} \\ 57 & \text{Divorcé} \\ 40 & \text{Séparé} \\ 45 & \text{Divorcé} \\ 47 & \text{Marié} \\ 31 & \text{Séparé} \\ 60 & \text{Veuf} \end{pmatrix} \longrightarrow X = \begin{pmatrix} 1 & 25 & 1 & 0 & 0 \\ 1 & 30 & 1 & 0 & 0 \\ 1 & 57 & 0 & 1 & 0 \\ 1 & 40 & 0 & 0 & 1 \\ 1 & 45 & 0 & 1 & 0 \\ 1 & 47 & 1 & 0 & 0 \\ 1 & 31 & 0 & 0 & 1 \\ 1 & 60 & 0 & 0 & 0 \end{pmatrix}.$$

Après estimation, on aura

$$\hat{y} = \beta_1 + \beta_2 \text{âge} + \beta_3 \mathbf{1}_{\text{marié}} + \beta_4 \mathbf{1}_{\text{divorcé}} + \beta_5 \mathbf{1}_{\text{séparé}}$$

«Veuf» est la modalité de référence. Pour un veuf, la prédiction est $\hat{y} = \beta_1 + \beta_2 \text{âge}$. β_3 représente la *différence* de salaire prédit entre un marié et un veuf du même âge.

La modalité de référence

$$\hat{y} = \beta_1 + \beta_2 \text{âge} + \beta_3 1_{\text{marié}} + \beta_4 1_{\text{divorcé}} + \beta_5 1_{\text{séparé}}$$

Si l'on remplace $1_{\text{marié}}$ par $1 - 1_{\text{divorcé}} - 1_{\text{séparé}} - 1_{\text{veuf}}$ on fait apparaître les coefficients que l'on obtient en mettant «marié» en modalité de référence

$$\hat{y} = (\beta_1 + \beta_3) + \beta_2 \text{âge} + (\beta_4 - \beta_3) 1_{\text{divorcé}} + (\beta_5 - \beta_3) 1_{\text{séparé}} - \beta_3 1_{\text{veuf}}$$

C'est le même modèle écrit différemment.

4

LE MODÈLE GAUSSIEN ET LES TESTS

Modèle. Expression de $\hat{\beta}$

$$y = x\beta^* + u, \quad u_i \sim \mathcal{N}(0, \sigma^2), \quad u_i \text{ iid.}$$

De façon plus savante $u \sim \mathcal{N}(0, \sigma^2 Id)$. Et même $y \sim \mathcal{N}(x\beta^*, \sigma^2 Id)$. La formule

$$\hat{\beta} = (X^T X)^{-1} X^T y = (X^T X)^{-1} X^T (X\beta^* + u) = \beta^* + (X^T X)^{-1} X^T u$$

permet de déduire la loi de $\hat{\beta}$ et d'avancer dans la théorie. En particulier on vérifie que $E[\hat{\beta}] = \beta^*$ et

$$\text{Cov}(\hat{\beta}_i, \hat{\beta}_j) = \sigma^2 \left((X^T X)^{-1} \right)_{ij}.$$

En général, σ est assez bien estimé sur les données, ce qui fait que la variance de $\hat{\beta}$ est connue, ce qui est remarquable, et permet d'évaluer précisément l'erreur commise par l'estimateur.

Le cas $p = 1$

Un seul paramètre, l'espérance β_1^* :

$$\begin{aligned}y_i &= \beta_1^* + u_i, \quad u_i \sim \mathcal{N}(0, \sigma^2) \\ \hat{\beta}_1 &= \frac{1}{n} \sum_i y_i = \beta_1^* + \frac{1}{n} \sum_i u_i \\ \hat{\sigma}^2 &= \frac{1}{n} \sum_i (y_i - \hat{\beta}_1)^2.\end{aligned}$$

On a donc en gros :

$$\hat{\beta}_1 = \beta_1^* + \frac{\hat{\sigma}}{\sqrt{n}} \mathcal{N}(0, 1)$$

Comme avec probabilité écrasante, $|\mathcal{N}(0, 1)| < 3$, on peut tester la nullité de β_1^* avec $|\hat{\beta}_1| \geq \frac{q\hat{\sigma}}{\sqrt{n}}$, ici $q = 3$. En pratique on donne la p-value : $\alpha = P(|\mathcal{N}(0, 1)| > q)$ avec $q = \sqrt{n}|\hat{\beta}_1|\hat{\sigma}$. Une petite p-value α indique que $\beta_1^* \neq 0$, α étant la probabilité de se tromper sur une telle affirmation.

Retour au cas p quelconque

La même procédure s'applique au cas général : on peut tester chaque coefficient.
Pour la consommation des voitures on obtient :

Coefficient	Estimate $\hat{\beta}_j$	$\alpha_j = \Pr(> t)$
(Intercept)	4.611e-02	0.02570 *
Vol	1.727e-06	0.93022
Puiss	2.213e-04	0.00228 **
Vitesse	-4.997e-04	0.02028 *
Poids	5.311e-04	0.00501 **

Le calcul montre que α_j est fonction croissante de $RSS(M \setminus \{j\})$

Liens avec le maximum de vraisemblance

$$\begin{aligned} p(y_1, \dots, y_n) &= p(y_1) \dots p(y_n) \quad (\text{indépendance}) \\ &= \prod_{i=1}^n \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}(y_i - x_i\beta)^2} \\ &= \frac{1}{(\sigma\sqrt{2\pi})^n} \exp \left\{ -\frac{1}{2} \sum_{i=1}^n (y_i - x_i\beta)^2 \right\} \end{aligned}$$

Minimiser $SS(\beta)$ c'est bien maximiser la vraisemblance.