

Analyse en composantes principales


1 Introduction

Soit un tableau de n individus et p variables, $n > p$

$$X = \begin{pmatrix} x_1 \\ \vdots \\ x_n \end{pmatrix} = \begin{pmatrix} x_1^1 & \dots & x_1^p \\ \vdots & & \vdots \\ x_n^1 & \dots & x_n^p \end{pmatrix}.$$

n est typiquement grand devant p . Chaque ligne x_i est un individu et chaque colonne x^k représente une variable. Chaque individu est un point de l'espace $\mathbb{R}^p$.

PREMIER EXEMPLE. x_k^1 est le tour de hanches du sujet k et x_k^2 son poids¹



Dans tous les cas où il n'y a que deux variables seulement, la représentation des individus ne pose pas de problème : on les pose dans le plan, chaque axe représentant une variable ; on peut voir apparaître ainsi des liens entre les variables, ou bien des groupes d'individus. Dans cet exemple on a distingué les hommes et les femmes dans le tracé (il y a donc une troisième variable : le sexe) et l'on voit d'une part un lien entre ces deux variables (alignement approximatif des points) et également deux groupes distincts où se trouvent les femmes et les hommes respectivement.

AUTRE EXEMPLE. Considérons comme exemple des données consistant en la composition de 45 poteries trouvées en Grande Bretagne datant de l'époque romaine². La composition est la teneur en 9 composants (fer, manganèse....). Elles proviennent de 5 fours différents. La matrice X est la matrice 45×9 des compositions.

PAI ₂ O ₃	Fe ₂ O ₃	MgO	CaO	Na ₂ O	K ₂ O	TiO ₂	MnO	BaO	Four
18.8	9.52	2	0.79	0.4	3.2	1.01	0.077	0.015	1
16.9	7.33	1.65	0.84	0.4	3.05	0.99	0.067	0.018	1
18.2	7.64	1.82	0.77	0.4	3.07	0.98	0.087	0.014	1
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
14.8	2.74	0.67	0.03	0.05	2.15	1.34	0.003	0.015	5
19.1	1.64	0.6	0.1	0.03	1.75	1.04	0.007	0.018	5

1. G. Heinz, L.J. Peterson, R.W. Johnson et C.J. Kerk, «Exploring Relationships in Body Dimensions»' *Journal of Statistics Education* Volume 11, Number 2 (2003). www.amstat.org/publications/jse/v11n2/datasets.heinz.html

2. D'après J.Holland Jones et I.G.Robertson, www.stanford.edu/class/anthsci192

Notons qu'en archéologie, l'analyse de la composition de matériaux est un outil important pour l'étude des échanges dans les économies antiques. Des objets d'origines distinctes ont généralement des signatures chimiques différentes qui permettent d'identifier leur origine. Pour identifier ces signatures il faut être capable de regrouper entre eux des objets de composition similaire.

Il y a maintenant bien trop de variables pour pouvoir représenter les individus aisément. On peut à la rigueur comparer deux individus, voir s'ils sont proches ou éloignés d'un individu donné en inspectant les valeurs numériques, mais il est impossible de faire apparaître directement des groupements d'individus ou quelque structure particulière que ce soit.

L'objectif de l'ACP est de réaliser la démarche du premier exemple dans le cas de plus de deux variables, $p > 2$. L'idée est la suivante : Supposons dans un premier temps que les individus soient en fait concentrés dans un plan de $\mathbb{R}^p$, le bon sens veut alors que l'on représente directement les individus dans ce plan. Mathématiquement cela signifie que l'on fait un changement de base où les deux premiers axes sont dans le plan et les autres leurs sont orthogonaux ; les coordonnées (nouvelles variables) 3 à p seront donc nulles pour tous les individus.

Supposons maintenant que les individus soient tous proches d'un plan, l'idée est alors de trouver le plan le meilleur (au sens où la somme des distances des points au plan est la plus petite possible) et de représenter les données par la projection sur ce plan. Notons que la qualité recherchée pour cette représentation dans le plan est que les distances entre individus apparaissant avec cette représentation reflètent au mieux les distances entre individus dans $\mathbb{R}^p$. Le principe sera d'approcher X par une matrice de rang 2

$$\boxed{X} \simeq c_1 v_1^T + c_2 v_2^T = \begin{array}{|c|} \hline \boxed{} \\ \hline \end{array} \begin{array}{|c|} \hline \boxed{} \\ \hline \end{array} + \begin{array}{|c|} \hline \boxed{} \\ \hline \end{array} \begin{array}{|c|} \hline \boxed{} \\ \hline \end{array}$$

où l'on voit que chaque individu se retrouve désormais dans le plan engendré par les *axes principaux* v_1 et v_2 , qui seront normés à 1.

Si ce « meilleur plan » n'est en réalité pas très bon, on peut alors chercher le sous-espace de dimension trois le meilleur, mais la représentation des données sera plus difficile : en pratique on représentera plusieurs projections en dimension deux, mais l'interprétation commence à être délicate.

Soulignons dès à présent qu'une des difficultés majeures est l'incertitude liée à la normalisation des variables. En effet si par exemple $p = 3$ et que le nuage de point est en gros une sphère, on ne pourra pas considérer que les individus sont presque sur un plan ; en revanche une homothétie sur le troisième axe pourra les faire se concentrer sur cet axe ou au contraire sur le plan contenant les deux premiers.

L'ACP a un autre objectif que la représentation de données dans le plan, c'est la compression afin de pouvoir travailler sur des données de taille réduite (les comparer...), par exemple passer de $p = 10000$ (une image) à $p = 20$.

Les variables. L'ACP permet aussi de comprendre les liens entre variables. En effet, l'identité $X \simeq c_1 v_1^T + c_2 v_2^T$ exprime que chaque variable, colonne de X , est approximativement combinaison linéaire de c_1 et c_2 .

2 Approximation du nuage et décomposition en valeurs singulières

2.1 Rappels d'algèbre matricielle

Dans ce qui suit, on identifie toute application linéaire de $\mathbb{R}^n$ dans $\mathbb{R}^p$ à sa représentation matricielle $M \in \mathbb{R}^{n \times p}$. De même un vecteur $x \in \mathbb{R}^p$ sera identifié à une matrice $p \times 1$, et éventuellement $1 \times p$ (ligne d'une matrice). On pourra écrire par exemple $\langle Mx, Ny \rangle = x^T M^T Ny = \text{Tr}(Ny x^T M^T)$.

Une application P est une projection orthogonale si pour tout $x \in \mathbb{R}^n$, $\langle Px, (I - P)x \rangle = 0$. On vérifie facilement que ceci signifie que $P^T = P = P^2$ (application idempotente et symétrique).

Toute matrice symétrique est diagonalisable dans une base orthogonale.

Le rang d'une application est la dimension de son espace image (espace engendré par les colonnes de la matrice). Si $M \in \mathbb{R}^{p \times n}$, son rang est inférieur à $n \wedge p$, et si son rang vaut cette valeur elle est dite de rang plein. Si P est une matrice de projection orthogonale, ses valeurs propres sont égales à 0 ou 1 et son rang vaut sa trace (une diagonalisation ne change ni le rang ni la trace).

Si $M \in \mathbb{R}^{n \times p}$, $n \geq p$, est de rang p , la matrice de projection orthogonale sur l'espace colonnes de M est $M(M^T M)^{-1} M^T \in \mathbb{R}^{n \times n}$.

Si l'on note c_j la j -ième colonne de M et l_i sa i -ième ligne, alors

$$MM^T = \sum_j c_j c_j^T, \quad M^T M = \sum_i l_i^T l_i.$$

3 La décomposition en valeurs singulières

Le problème est donc de trouver l'espace affine de dimension k qui approche au mieux les individus, au sens où la projection orthogonale sur cet espace les déplace le moins possible. Pour avoir une analyse indépendante des effets de translation sur les variables, on travaillera sur les individus recentrés :

$$\tilde{x}_i = x_i - \bar{x}, \quad \tilde{X} = \begin{pmatrix} x_1 - \bar{x} \\ \vdots \\ x_n - \bar{x} \end{pmatrix}, \quad \bar{x} = \frac{1}{n} \sum_{i=1}^n x_i \in \mathbb{R}^p.$$

La moyenne empirique $\bar{x}$ est aussi appelée centre de gravité. On les standardise également souvent pour être invariant aux changements d'échelle, mais nous reviendrons sur cette question plus bas. On suppose désormais le recentrage fait et l'on note X pour $\tilde{X}$. Ceci fait, on peut se restreindre désormais à une projection vectorielle.

Il s'agit donc de trouver la matrice P_k de projection orthogonale sur un espace E_k de dimension k qui minimise $\sum_i \|x_i - x_i P_k\|^2$ (comme x_i est une ligne, $P_k(x)$ est représenté par $x_i P_k$), soit

$$P_k = \arg \min_{\text{Rang}(P) \leq k} \|X - XP\|_F^2, \quad E_k = \text{Im}(P_k). \quad (1)$$

où $\|\cdot\|_F$ désigne la norme de Frobenius :

$$\|M\|_F^2 = \sum_{ij} M_{ij}^2 = \text{Tr}(M^T M).$$

La décomposition en valeurs singulières sera l'instrument central pour résoudre ce problème. Elle décompose une matrice X sous la forme

$$\boxed{X} = \boxed{U} \boxed{\Lambda} \boxed{V^T}$$

où U est à colonnes orthonormées ($U^T U = I$), Λ est diagonale, et V est orthogonale. La transposition de l'identité informelle ci-dessus donne la forme dans le cas où X est horizontalement allongée. Il existe des algorithmes numériquement très efficaces pour réaliser cette décomposition, c'est pourquoi son usage est recommandé en pratique.

Théorème 1. Soit $X \in \mathbb{R}^{n \times p}$ une matrice, avec $n \geq p$. Il existe deux matrices à colonnes orthonormées U et V (i.e. $U^T U = V^T V = Id$) et une matrice diagonale $\Lambda \in \mathbb{R}^{p \times p}$ à entrées positives telles que

$$X = U \Lambda V^T$$

Par conséquent, en appelant u_i et v_i les vecteurs colonne de U et V (vecteurs singuliers à droite et à gauche), on a la décomposition en somme de matrices de rang 1 :

$$X = \sum_{i=1}^p \lambda_i u_i v_i^T, \quad \lambda_i = \Lambda_{ii}.$$

La matrice Λ contient nécessairement les racines carrées des valeurs propres de $X^T X$, appelées valeurs singulières, et si ces dernières sont distinctes et rangées par ordre décroissant, cette décomposition est unique.

Démonstration. On ne traite que le cas où $X^T X$ a toutes ses valeurs propres non nulles. On peut diagonaliser $X^T X$:

$$X^T X = V D V^T.$$

On vérifie alors que $\Lambda = \sqrt{D}$ et $U = X V \Lambda^{-1}$ convient.

Pour l'unicité, noter que u_i (resp. de v_i) est le vecteur propre de $X X^T$ (resp. $X^T X$) associé à λ_i^2 , vecteur unique au signe près. ■

On peut maintenant donner la solution :

Théorème 2. On suppose les valeurs singulières distinctes et ordonnées : $\lambda_1 > \lambda_2 > \dots \lambda_n$. Soit P_k

$$P_k = \sum_{i \leq k} v_i v_i^T$$

la projection orthogonale sur l'espace engendré par les k premiers vecteurs singuliers à droite. Pour toute matrice de projection P orthogonale sur un espace de dimension $\leq k$, on a

$$\|X - X P_k\|_F \leq \|X - X P\|_F.$$

Remarque. Supposer les valeurs singulières distinctes permet d'identifier les vecteurs singuliers de manière unique (au signe près), ce qui clarifie l'exposé, mais le lemme reste vrai même si des valeurs singulières sont égales, le seul changement étant que si $\lambda_k = \lambda_{k+1}$, alors P_k n'est plus unique. Nous ne détaillons pas ce point.

Démonstration. En raison du théorème de Pythagore $\|X\|_F^2 = \|XP\|_F^2 + \|X(I-P)\|_F^2$; il suffit donc de montrer que $\|XP_k\|_F \geq \|XP\|_F$. En reprenant la relation $X^T X = V D V^T$ et

$$\|XP\|_F = \text{Tr}(P V D V^T P) = \text{Tr}(D Q)$$

où $Q = V^T P V$ est un projecteur orthogonal de rang $\leq k$. Comme $\text{Tr}(Q^2) = \text{Tr}(Q) \leq k$, la somme de ses coefficients diagonaux est $\leq k$. Par ailleurs, comme $Q^T Q = Q$, le carré de la norme de la colonne $Q_{.i}$ vaut Q_{ii} , en particulier $|Q_{ii}| \leq 1$. Donc

$$\|XP\|_F = \sum_i D_i Q_{ii} \leq \max \left\{ \sum_i D_i x_i : |x_i| \leq 1, \sum x_i \leq k \right\} = \sum_{i=1}^k D_i.$$

C'est la valeur atteinte pour $P = P_k$. ■

On a même plus généralement :

Théorème 3. *Sous les hypothèses du théorème précédent, pour toute matrice A de rang k on a*

$$\|X - XP_k\|_F \leq \|X - A\|_F.$$

Démonstration. En effet la matrice A s'écrit AP où P est le projecteur orthogonal sur l'orthogonal du noyau et donc, en utilisant le théorème de Pythagore (noter que $\|X\|_F^2 = \text{Tr}(X^T X) = \text{Tr}(X X^T)$) :

$$\|X - A\|_F^2 = \|X(Id - P) + (X - A)P\|_F^2 = \|X(Id - P)\|_F^2 + \|(X - A)P\|_F^2 \geq \|X - XP_k\|_F^2. \quad \blacksquare$$

Corollaire 4. *L'espace E_k de dimension k solution de (1) est engendré par les k premiers vecteurs singuliers à droite ($v_1, \dots, v_k$); si des valeurs propres sont égales il n'y a pas nécessairement unicité.*

Exercice. Vérifier que $Xv_i = \lambda_i u_i$ et $X^T u_i = \lambda_i v_i$. On suppose maintenant que les valeurs singulières sont distinctes. Vérifier que toute paire (u, v) telle que $Xv = \lambda u$ et $X^T u = \lambda v$ pour un certain $\lambda > 0$ apparaît dans la décomposition (à un facteur près).

4 Inertie des espaces

Présentons un autre point de vue qui plutôt que de minimiser l'erreur $x_i - Px_i$ cherche à maximiser la dispersion des individus Px_i . On va voir que ceci revient au même.

On définit l'inertie des individus par la quantité

$$I = \frac{1}{n} \sum_i \|x_i\|^2.$$

L'inertie est donc également la somme des variances empiriques des p variables; c'est encore n^{-1} fois le carré de la norme de Frobenius de X (somme des carrés des coefficients). Cette quantité réelle mesure la **dispersion** des individus dans l'espace à p dimensions. Soit la matrice de covariance empirique des individus

$$R = \frac{1}{n} \sum_i x_i^T x_i = \frac{1}{n} X^T X, \quad R_{jk} = \frac{1}{n} \sum_i x_i^j x_i^k.$$

L'inertie est simplement la trace de R .

Soit E un sous-espace de $\mathbb{R}^p$ et P_E le projecteur orthogonal sur E ; on note I_E l'inertie des individus projetés, appelée l'inertie de E :

$$I_E = \frac{1}{n} \sum_i \|P_E x_i\|^2 = \frac{1}{n} \sum_i \|x_i\|^2 - \frac{1}{n} \sum_i \|x_i - P_E x_i\|^2.$$

L'inertie de E est donc également une mesure de la proximité entre les individus et E .

Le problème (1) est donc équivalent à trouver l'espace E_k de dimension k d'inertie maximale. Comme on vient de le voir, cet espace est engendré par les k vecteurs propres associés aux k plus grandes valeurs propres de R . Ces espaces sont emboîtés, ce qui n'était pas évident au départ.

5 Propriétés fondamentales de l'ACP

Calcul pratique de l'ACP. (La matrice X est supposée déjà recentrée) Faire une SVD de X : $X = U\Lambda V^T$. V contient dans ses colonnes les axes principaux et $C = U\Lambda$ les composantes principales, soit pour la k -ième colonne $c_k = \lambda_k u_k$.

On a

$$X = CV^T = \sum_i c_i v_i^T$$

Comme $C = XV$, la i -ème composante principale est la combinaison linéaire des variables avec les poids contenus dans la i -ième colonne de V .

Définition 5. Les v_k sont les facteurs principaux, ou axes principaux.

Le vecteur $c_k = Xv_k$ est la k -ième composante principale. $\|c_k\| = \lambda_k$.

$\frac{\lambda_1^2 + \dots + \lambda_k^2}{\lambda_1^2 + \dots + \lambda_p^2} = \frac{I_{E_k}}{I}$ est la fraction d'inertie expliquée par E_k .

Il résulte de ce qui précède que la matrice de covariance des c_i est la diagonale des λ_k .

Plus la fraction d'inertie expliquée par E_k est proche de 1, plus la projection des variables x_j sur E_k est proche de x_j , c'est-à-dire que les $c_1, \dots, c_k$ permettent de bien représenter les individus.

Un exemple. On a mesuré la largeur et la longueur de la tête chez des frères. Les variables sont donc au nombre de quatre dans l'ordre suivant : longueur et largeur pour l'un, longueur et largeur pour l'autre. Ce tableau de 25 individus est représenté sur la figure 1. On obtient sur cet exemple

$$V = \begin{pmatrix} 0,57 & -0,69 & -0,44 & -0,01 \\ 0,41 & -0,22 & 0,87 & -0,17 \\ 0,60 & 0,63 & -0,21 & -0,44 \\ 0,39 & 0,27 & 0,06 & 0,88 \end{pmatrix}, \quad D = \Lambda^2 = \begin{pmatrix} 228 & 0 & 0 & 0 \\ 0 & 29,4 & 0 & 0 \\ 0 & 0 & 17 & 0 \\ 0 & 0 & 0 & 9 \end{pmatrix}$$

En première approximation, on peut dire que les composantes principales correspondent dans l'ordre à

- somme des périmètres des têtes
- différence entre les deux frères
- allongement de la tête du premier




FIGURE 1 – Longueur et largeur de la tête sur 25 couples de frères (données `frets{boot}` de R). Les données correspondant au plus vieux sont en traits plein.

- allongement de celle du second.

Le fait que la première valeur propre sorte du lot (80% d'inertie expliquée) indique que les individus se distinguent surtout par la somme des périmètres des crânes.

*** Une caractérisation.** La proposition suivante permet de caractériser c_k à une constante près comme vecteur qui maximise la covariance cumulée avec les variables :

Proposition 6. *La k -ième composante principale normalisée $u_k = c_k/\lambda_k$ est solution du problème de maximisation*

$$\max_u \sum_{j=1}^p \langle u, x^j \rangle^2, \quad \text{sous } u \perp c_1, \dots, c_{k-1}, \quad \text{et } \|u\| = 1.$$

La valeur du maximum est λ_k^2 .

REMARQUE. Les données étant centrées, ces produits scalaires sont donc, à facteurs constant près, des covariances empiriques. Si les x^j sont normés, ce qui est généralement le cas, ce sont même des corrélations.

Démonstration. Soit u la solution de ce problème, alors u est combinaison linéaire des x^j (en effet, si P est la projection orthogonale sur l'espace des x^j et $\|u\| = 1$, un remplacement de u par $Pu/\|Pu\|$ augmente les produits scalaires). u a donc la forme $u = Uz$ et la première contrainte signifie que z a ses $k-1$ premières composantes nulles. Le critère s'écrit (rappelons que $XX^T = UDU^T$ et $U^TU = I$)

$$\sum_{j=1}^p \langle u, x^j \rangle^2 = \sum_j u^T x^j x^{jT} u = u^T XX^T u = z^T Dz.$$

La deuxième contrainte sur u est que $\|u\|^2 = 1$; les $k-1$ premières composantes de z étant nulles, on a nécessairement $z^T Dz \leq \lambda_k^2 \|z\|^2 = \lambda_k^2$, et par ailleurs cette valeur est atteinte pour z égal au k -ième vecteur de la base canonique. Ce qui correspond bien à $u = u_k$. ■

6 ACP sur données réduites

L'ACP n'est pas invariante par changement d'échelle sur les variables. Il est donc important, si les colonnes de X contiennent des données non comparables (i.e. des mètres et des kilogrammes) de les normaliser, afin d'avoir un résultat **indépendant des unités utilisées**. Si en revanche les colonnes sont comparables (comme celles de l'exemple des têtes du paragraphe précédent) on peut préférer de ne pas faire de normalisation : on considère ainsi que l'information de niveau relatif entre les différentes variables est importante, et les variables de faible amplitude seront

pénalisées au sens où elles interviendront moins dans les premières composantes principales (comparer l'exemple numérique de ce paragraphe et celui du paragraphe précédent).

Sur les données du paragraphe précédent, on obtient un résultat analogue :

$$V = \begin{pmatrix} 0,49 & -0,48 & -0,72 & 0,07 \\ 0,49 & -0,54 & 0,68 & -0,08 \\ 0,51 & 0,50 & -0,05 & -0,70 \\ 0,51 & 0,48 & 0,09 & 0,71 \end{pmatrix}, \quad D = \Lambda^2 = \begin{pmatrix} 3,2 & 0 & 0 & 0 \\ 0 & 0,38 & 0 & 0 \\ 0 & 0 & 0,27 & 0 \\ 0 & 0 & 0 & 0,16 \end{pmatrix}.$$

V est cette fois très proche de la matrice


$$V = \frac{1}{2} \begin{pmatrix} 1 & -1 & -\sqrt{2} & 0 \\ 1 & -1 & \sqrt{2} & 0 \\ 1 & 1 & 0 & -\sqrt{2} \\ 1 & 1 & 0 & \sqrt{2} \end{pmatrix}.$$

Interprétation de Λ^2 . Chaque terme correspond à l'inertie du sous-espace de dimension 1 correspondant, et leur somme fait l'inertie totale (théorème de Pythagore). Sa valeur mesure la contribution de l'axe aux données. Ici, le premier axe contribue à 80% de l'inertie car $3,2/(3,2 + 0,38 + 0,27 + 0,16) = 80\%$. Λ^2 contient les valeurs propres de la matrice de corrélation des données.

Le cercle des corrélations. Plutôt que de regarder les deux premières colonnes de la matrice V , il existe une représentation permettant d'étudier les liens entre variables d'origine et les nouvelles variables que sont les composantes principales : c'est la projection des variables normalisées $x_j \in \mathbb{R}^n$ sur le plan engendré par (c_1, c_2) . Il se trouve que chacun de ces p points a pour coordonnées les corrélations avec les deux composantes. Ces paires se trouvent dans les deux premières colonnes de ΛV .

En effet, ce plan a pour base orthonormée (u_1, u_2) , si bien que la projection de x_j sur ce plan y a pour coordonnées $\langle x_j, u_1 \rangle$ et $\langle x_j, u_2 \rangle$. Comme $u_k = \frac{c_k}{\|c_k\|}$, ce sont également les corrélations de x_j avec c_1 et c_2 . Ces produits scalaires se trouvent dans les deux premières colonnes de $U^T X = \Lambda V$.

On obtient ici



Si l'ACP n'est pas normalisée, on trace quand même les corrélations. Ce tracé permet

- de voir les variables qui sont bien représentées par les deux premières composantes principales : le vecteur est de norme proche de 1
- d'interpréter chaque composante en observant quelles variables sont positivement ou négativement corrélées avec elle.
- de faire apparaître graphiquement les corrélations entre variables au travers de la proximité des points


On voit ici une bonne représentation des variables, ce qui se confirme par une inertie totale de 89,3%. On voit également que la première composante mesure l'amplitude cumulée de toutes les variables et que la seconde oppose les paires (L1,l1) et (L2,l2), c'est-à-dire les deux frères.

De plus, les deux proximités de vecteurs montrent que les frères sont très corrélés (Cette conclusion ne tient que du fait que les vecteurs sont de norme proche de 1 car sinon une corrélation des projection n'entraîne pas une corrélation des vecteurs).

7 Représentations dans les plans principaux

Le programme présenté dans l'introduction est réalisé et l'on peut représenter les individus, points de $\mathbb{R}^p$, dans le plan (v_1, v_2) , points dont les coordonnées sont fournies par les deux premières colonnes de C . Ce tracé peut faire apparaître des individus marginaux ou des classes bien séparées. Cette représentation est d'autant meilleure que la fraction d'inertie expliquée par E_2 est grande. Si cette inertie est trop faible, on peut compléter par des représentations dans le plan (v_1, v_3) ou (v_2, v_3) .



Reprenons les données de poterie présentées dans l'introduction. On a tracé les individus dans le plan (v_1, v_2) en marquant le numéro du four. On voit nettement des regroupements qui permettent de classer différents types de poterie (l'ACP est ici normalisée mais une ACP non normalisée donne des résultats similaires) :



Les composantes ne séparent pas les fours 4 et 5, et un graphique non présenté ici montre que l'utilisation du troisième facteur n'améliore pas ce point. Noter que le four 3 n'a que deux représentants.

On voit sur le second graphique, projection des variables explicatives sur le plan des deux premières composantes principales, que la première composante oppose PaL_2O_3 et TiO_2 à MnO , K_2O , MgO , et Fe_2O_3 . L'interprétation de la nature des facteurs principaux est ici affaire de chimistes. Les valeurs propres Λ_i^2 sont tracées dans la figure se trouvant plus bas; les deux premiers axes se dégagent assez bien avec 75% d'inertie expliquée.


On peut aussi représenter une variable $x \in \mathbb{R}^n$ n'ayant pas servi à l'analyse, dite « variable supplémentaire », toujours avec le calcul des corrélations $\text{Cor}(x, c_1)$ et $\text{Cor}(x, c_2)$. Ici nous avons placé les cinq variables indicatrices de four :



8 Bilan

L'analyse en composantes principales propose donc de nouvelles variables explicatives $c_i = Xu_i$ (composantes principales). Ces variables sont choisies en sorte que la structure géométrique (distances entre les individus) des individus restreints aux premières composantes soit la plus fidèle possible à la géométrie des individus complets, ou en d'autres termes en sorte que les premières variables concentrent l'information. Cette fidélité se mesure aux poids relatif des valeurs propres associées aux composantes conservées, les inerties. Ceci justifie la représentation des individus dans les premiers plans factoriels. Il est généralement préférable de travailler sur données réduites pour ne pas défavoriser a priori certaines variables.

Le premier axe fait souvent apparaître un effet « taille », cf. la somme des périmètres des têtes au § 6, ou comme ici (notes de 104 étudiants dans 9 matières ; données `deug` de R) le score global de l'étudiant



On notera que le deuxième axe oppose les scientifiques aux littéraires (ou aux communicants...).

Ces nouvelles variables sont décorrélées

La k -ième composante principale c_k minimise la quantité $\sum_j \|x_j - c_k\|^2$ sous la contrainte d'être orthogonale aux précédentes. Les composantes principales c_i sont vecteurs propres de XX^T , les facteurs v_i sont vecteurs propres normés de X^TX . Dans la SVD de X : $X = U\Lambda V^T$, la matrice V contient les v_i en colonne, et $C = U\Lambda$ contient les c_i en colonne.