

CLASSIFICATION NON SUPERVISÉE


1

INTRODUCTION



Objectifs

Regrouper des individus (points de $\mathbb{R}^p$), en groupes (classes) d'individus proches en un certain sens.

Par exemple :



Il peut *éventuellement* exister une réalité sous-jacente



Mais on n'y a pas accès : **classification non supervisée**

Objectifs

- Analyser
- Concentrer l'information
- Transmissions, codage : remplacer un nouvel individu par son numéro de groupe.

Exemple :

- Wine dataset (scikitlearn) : 178 individus et 13 variables (mesures chimiques)

2

RAPPELS SUR LA VARIANCE

La variance d'un ensemble de points $A \subset \mathbb{R}^d$ vaut

$$V(A) = \frac{1}{|A|} \|x - g_A\|^2, \quad g_A = \frac{1}{|A|} \sum_{x \in A} x.$$


Soit $E \subset \mathbb{R}^d$, et une partition $E = A_1 \cup A_2 \cup \dots \cup A_q$. On a

$$V(E) = \sum_i p_i \|g_{A_i} - g_E\|^2 + \sum_i p_i V(A_i), \quad p_i = \frac{|A_i|}{|E|}$$

Variance totale = Variance interclasse + Variance intraclasse

En notant pour tout $x \in A_i$, $\hat{x} = g_{A_i}$, la formule se réécrit :

$$\sum_x \|x - g_E\|^2 = \sum_x \|\hat{x} - g_E\|^2 + \sum_x \|x - \hat{x}\|^2$$



3

CLASSIFICATION HIÉRARCHIQUE

Méthode ascendante

- Commencer par se donner une mesure de *dissimilarité* entre individus.
 Cas quantitatif : $d(x, y) = \|x - y\|$.
 Rq. Les variables ne sont pas forcément numériques.
 Rq. On parle parfois plus simplement de *distance*, même si c'est un abus.
- En déduire une distance entre classes, typiquement

Single link :
$$\Delta(A, B) = \min_{x \in A, y \in B} d(x, y)$$

Complete link :
$$\Delta(A, B) = \max_{x \in A, y \in B} d(x, y)$$


Distance moyenne :
$$\Delta(A, B) = \frac{1}{|A| \cdot |B|} \sum_{x \in A, y \in B} d(x, y)$$

Ward :
$$\Delta(A, B) = \frac{|A| \cdot |B|}{|A| + |B|} \|g_A - g_B\|^2 \quad (\text{centres de gravité}).$$


(Choix classiques proposés par les logiciels)

3. CLASSIFICATION HIÉRARCHIQUE


Single




Complete



Moyenne



Ward



Méthode ascendante

- (1) Initialiser avec une classe par individu
- (2) Fusionner les deux classes les plus proches
- (3) Revenir à (2) jusqu'à fusion complète.
- (4) Chaque étape donne une classification.

L'ensemble donne un arbre de classification.

Exemple

Individus : Europe des 28 en 2019¹


17 variables :

- Taux de chômage : femmes, hommes, <25ans, 25-74, global
- Taux de d'activité : femmes, hommes, <25ans, 25-54, 55-74, global
- Poids de la dette publique
- Dépenses des administrations publiques
- Ménages ayant internet
- Particuliers utilisant quotidiennement Internet : tous, 16-24
- Taille des ménages² (2018)

1. Source : INSEE

2. Ensemble des occupants d'un même logement, possiblement une seule personne.


Dendrogramme



En abscisse se trouve la dissimilarité entre les deux classes réunies, $d(A, B)$.

3. CLASSIFICATION HIÉRARCHIQUE

Avec standardisation des variables



Sur la méthode de Ward. Le critère global

Un calcul classique montre que pour la distance de Ward

$$\Delta(A, B)^2 = \sum_{x \in A \cup B} \|x - g_{A \cup B}\|^2 - \sum_{x \in A} \|x - g_A\|^2 - \sum_{x \in B} \|x - g_B\|^2$$

Réunir les deux classes de $\Delta(A, B)$ minimum revient à faire la fusion qui augmente le moins la variance intraclasse (erreur d'approximation)

$$W = \sum_i \sum_{x \in A_i} \|x - g_{A_i}\|^2 = \sum_x \|x - \hat{x}\|^2 \quad (1)$$

où $\hat{x} = g_A$ si A est la classe de x . Car $\Delta(A, B)$ est la différence avant et après fusion.

Dans le cas de Ward, l'algorithme tente donc de diminuer le nombre de classes en augmentant le moins possible le critère W (within), mais il ne trouve pas forcément la meilleure solution à k classes à chaque fois.

L'algorithme de Lance-Williams

On a les formules (Lance-Williams dissimilarity update formula) :



$$\text{Single link :} \quad \Delta(A \cup B, C) = \frac{1}{2} \Delta(A, C) + \frac{1}{2} \Delta(B, C) - \frac{1}{2} |\Delta(A, C) - \Delta(B, C)|$$

$$\text{Complete link :} \quad \Delta(A \cup B, C) = \frac{1}{2} \Delta(A, C) + \frac{1}{2} \Delta(B, C) + \frac{1}{2} |\Delta(A, C) - \Delta(B, C)|$$

$$\text{Distance moyenne :} \quad \Delta(A \cup B, C) = \frac{|A|}{|A|+|B|} \Delta(A, C) + \frac{|B|}{|A|+|B|} \Delta(B, C).$$

L'algorithme de Lance-Williams consiste à utiliser ces formules, ce qui économise des calculs puisque les $d(x, y)$ n'apparaissent plus (sauf à la première étape).

Evolution du critère de Ward sur les pays







Sans et avec standardisation des variables.

De telles courbes sont propres à la méthode de Ward.

3. CLASSIFICATION HIÉRARCHIQUE

Exemple des poteries

Sans et avec standardisation des variables



Bilan

La CAH ne fournit pas directement de méthode de prédiction. C'est d'abord un outil d'analyse. Les arbres de décision seront une méthode de prédiction dans cet esprit.

Avantage : Une structure hiérarchique est fournie.

Inconvénient : On ne sait pas trop ce qui est minimisé (sauf dans le cas Ward, et encore la minimisation n'est pas optimale)

La méthode part du tableau de distances entre individus. Les logiciels acceptent un tableau de distances en entrée.

La distance de Ward est recommandée par défaut.

Le résultat dépend de la normalisation des données, mais pas du centrage car n'interviennent que des distances $\|x - y\|$.





Coût calcul $> n^2$ (distances entre paires d'individus). Ce peut être dissuasif.

Choix du nombre de classes : difficile, dépend de la situation.

3. CLASSIFICATION HIÉRARCHIQUE

Des situations où single gagne

Ward à gauche et single à droite. On a demandé le bon nombre de classes :



4

K-MEANS

Principe

- On donne : les points et un nombre n_c de groupes attendus
- L'algorithme doit rendre : n_c centres

A chaque point on associe le centre le plus proche, ce qui détermine les groupes, et des régions.





Diagramme de Voronoï associé à une famille de centres



Chaque région est l'ensemble des points pour lesquels le centre (centroïde) est le plus proche.

Objectif à optimiser

On cherche les centres $c_1, \dots, c_{n_c}$ qui minimisent la somme des distances au centre le plus proche

$$\sum_x \min_j \|x - c_j\|^2 = \sum_x \|x - \hat{x}\|^2$$

On peut voir le centre le plus proche $\hat{x}$ comme un codage, une approximation, un arrondi, de x .

Algorithme des k-means

- (1) Partir de n_c centres tirés aléatoirement
- (2) Associer à chaque donnée son centre le plus proche
- (3) Recalculer chaque centre comme moyenne des données qui lui ont été associées
- (4) Revenir à (2), jusqu'à convergence

La limite peut dépendre de l'initialisation.

Il y a des variantes.

Une initialisation plus élaborée de l'algorithme des k-means

L'algorithme kmeans++ d'Arthur et Vassilvitskii (2006) :


- Choisir le premier centre c_1 aléatoirement dans les données.
- Pour $j = 1, \dots, N - 1$:
 - Calculer pour chaque point x_i la distance au centre le plus proche

$$d_i^2 = \min_{k \leq j} \|x_i - c_k\|^2$$


- Tirer aléatoirement c_{j+1} parmi les x_i selon les probabilités $d_i^2 / \sum_k d_k^2$.

Algorithme des k-means


Exemple³




0a. Données d'entrée




0b. initialisation




1a. assignation




1b. calcul des points moyens




2a. assignation




2b. calcul des points moyens



3a. assignation





3b. calcul des points moyens

4a. assignation
clusters stables (fin)


Dépendance au nombre de groupes demandés

On a simulé un mélange de 5 gaussiennes puis fait les k-means :



Résultat sur les données Europe après standardisation

On représente les individus et leur classe dans le plan (C_1, C_2) d'une ACP



Bilan

Le résultat dépend de la **normalisation** des données.

Coût calcul : Potentiellement plus faible que la CAH.

Choix du nombre de classes : difficile, dépend de l'application.

Distance euclidienne seulement.

Fournit une méthode de prédiction par attribution à un nouvel individu de l'étiquette majoritaire dans la classe à laquelle il appartient (celle du centroïde le plus proche).

5

TRAITEMENT DES VARIABLES QUALITATIVES

Exemple

Census Income Data Set (UCI repository) :

- income : $>50K$, $\leq 50K$.
- age : continuous.
- workclass : Private, Not ncorporated self employment, Incorporated self employment, Federal-gov, Local-gov, State-gov, Without-pay, Never-worked.
- education : Bachelors, Some-college, 11th, HS-grad, Prof-school, Assoc-acdm, Assoc-voc, 9th, 7th-8th, 12th, Masters, 1st-4th, 10th, Doctorate, 5th-6th, Preschool.
- education-num : continuous.
- marital-status : Married-civ-spouse, Divorced, Never-married, Separated, Widowed, Married-spouse-absent, Married-AF-spouse.
- ...

Pour chaque variable catégorielle à k modalités, on crée $k - 1$ variables, chacune étant l'indicatrice des $k - 1$ premières modalités. Ces $k - 1$ variables vont remplacer la variable catégorielle dans le tableau individus/variable. La k -ième n'est généralement pas rentrée car elle est fonction linéaire des autres (la somme des indicatrices fait 1).

Exemple

$$\begin{pmatrix} \text{Marié} \\ \text{Marié} \\ \text{Divorcé} \\ \text{Séparé} \\ \text{Divorcé} \\ \text{Marié} \\ \text{Séparé} \\ \text{Veuf} \end{pmatrix} \longrightarrow \begin{pmatrix} 1 & 0 & 0 \\ 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \\ 0 & 1 & 0 \\ 1 & 0 & 0 \\ 0 & 0 & 1 \\ 0 & 0 & 0 \end{pmatrix}.$$

Chaque modalité devient un vecteur de la base canonique de $\mathbb{R}^{k-1}$ ou le vecteur nul.

Les $k - 1$ variables sont appelées «dummy variables».

La modalité nulle (veuf) sera appelée en régression «modalité de référence».

Les logiciels font habituellement eux-mêmes ces transformations, de manière transparente pour l'utilisateur.