
RÉSOLUTION NUMÉRIQUE DE PROBLÈMES AUX DÉRIVÉES PARTIELLES DE LA PHYSIQUE

STÉPHANE BALAC

UFR de Mathématiques
Campus de Beaulieu
263 avenue du Général Leclerc, CS 74205
35042 RENNES Cédex




Table des matières

Table des matières	iii
1 Étude d'un problème aux limites unidimensionnel	1
1.1 Modélisation de phénomènes physiques	1
1.1.1 Équation des cordes vibrantes	1
1.1.2 Équation de la chaleur	3
1.2 Problème aux limites vs. problème de Cauchy	5
1.3 Problème bien posé mathématiquement	6
1.3.1 Existence de la solution au problème aux limites	6
1.3.2 Régularité de la solution	9
1.3.3 Principe du maximum	10
1.3.4 Dépendance continue de la solution du problème aux limites vis à vis des données	13
1.3.5 Unicité de la solution au problème aux limites	14
1.4 Approximation par différences finies	16
1.4.1 Approximation d'une dérivée	16
Approximation d'une dérivée première	16
Approximation d'une dérivée seconde	17
1.4.2 Construction de l'approximation par différences finies	17
1.4.3 Existence et unicité d'une solution au problème discret	19
Cas particulière d'une équation différentielle à coefficients constants	25
1.4.4 Dépendance continue de la solution du problème discret vis à vis des données . . .	26
1.4.5 Majoration d'erreur	31
Notion de consistance d'un schéma aux différences finies	32
Notion de convergence pour un schéma aux différences finies	33
Principe de Lax	34
1.5 Classification des équations aux dérivées partielles linéaires d'ordre 2	36
1.5.1 Formulation d'une équation aux dérivées partielles linéaire d'ordre inférieur ou égal à 2	36
1.5.2 Rappels sur la classifications des coniques	37
1.5.3 Équations aux dérivées partielles elliptiques	37
1.5.4 Équations aux dérivées partielles paraboliques	38
1.5.5 Équations aux dérivées partielles hyperboliques	38

2	Problèmes aux limites elliptiques	39
2.1	Modélisation de phénomènes physiques conduisant à des problèmes aux limites elliptiques	39
2.1.1	Un problème de magnétostatique en imagerie par résonance magnétique	39
	Description du problème	39
	Le modèle mathématique	40
	Réduction à un problème en domaine borné	42
2.1.2	Champ électrique à l'intérieur d'un réservoir partiellement rempli par un hydrocarbure	44
	Modélisation du problème physique	44
	Formulation du problème sous l'hypothèse d'axisymétrie	46
2.1.3	Un problème de thermique stationnaire	47
2.2	Etude d'un problème modèle	48
2.2.1	Formulation du problème	48
2.2.2	Principe du Maximum	50
2.2.3	Étude du problème de Dirichlet	52
2.2.4	Recherche d'une solution à variables séparées au problème de Dirichlet	53
	Extension au problème de Dirichlet complet	55
2.3	Approximation du problème modèle par la méthode des différences finies	56
2.3.1	Approximation des dérivées partielles	56
	Approximation d'une dérivée partielle première	56
	Approximation d'une dérivée partielle seconde	57
2.3.2	Approximation par différences finies du problème de Dirichlet	58
	Consistance de l'approximation	59
	Écriture de l'équation discrétisée sous forme d'un système linéaire	61
	Stabilité de la méthode de discrétisation	64
	Etude de l'erreur d'approximation	66
3	Problèmes aux limites paraboliques	67
3.1	Modélisation de phénomènes physiques conduisant à des problèmes paraboliques	67
3.1.1	Phénomènes thermiques dans les lasers solides	67
	Modélisation mathématique dans le cas de pompage à émission continue	69
	Modélisation mathématique dans le cas du pompage laser à impulsions	70
3.1.2	Propagation d'une onde dans une fibre optique	71
	L'équation non-linéaire de Schrödinger	71
	Solutions particulières de l'équation NLS : les solitons	72
	Résolution de l'équation linéaire de Schrödinger	72
3.2	Étude d'un problème modèle	74
3.2.1	Étude de l'existence d'une solution : méthode de la séparation des variables	75
3.2.2	Énergie du système du physique modélisé en l'absence de terme source	77
3.2.3	Unicité de la solution au problème modèle	77
3.2.4	Problème bien posé au sens de Hadamard	78
3.3	Approximation par un schéma différences finies explicite du problème modèle	78
3.3.1	Construction du schéma différences finies	78

3.3.2	Notion de stabilité pour un schéma de différences finies	81
3.3.3	Notion de consistance d'un schéma de différences finies	86
3.3.4	Notion de convergence pour un schéma différences finies	88
3.4	Approximation par un schéma différences finies implicite du problème modèle	90
3.4.1	Construction du schéma différences finies implicite	90
3.4.2	Étude de la stabilité du schéma implicite	91
3.4.3	Étude de la consistance du schéma implicite	92
3.5	Le schéma différences finies de Crank et Nicolson	93
3.5.1	Construction du schéma	93
3.5.2	Étude de la stabilité du schéma de Crank-Nicolson	95
3.5.3	Étude de la consistance du schéma de Crank-Nicolson	96
3.5.4	Convergence du schéma de Crank-Nicolson	98
4	Problèmes aux limites hyperboliques du premier ordre	99
4.1	Modélisation mathématique de phénomènes physiques par une équation de transport	99
4.1.1	Un modèle de trafic routier	100
4.1.2	Transport d'un polluant	101
4.1.3	Vieillessement des populations : équation de McKendric et von Foerster	102
4.1.4	Différentes formes pour l'équation du transport	103
4.2	Étude de l'équation d'advection à vitesse constante	104
4.2.1	Cas de l'équation homogène	104
4.2.2	Cas d'une équation non homogène	107
4.3	Étude de l'équation d'advection à vitesse variable	108
4.3.1	Cas de l'équation homogène	108
4.3.2	Cas de l'équation non homogène	113
4.4	Approximation par différences finies de l'équation d'advection	114
4.4.1	Un premier schéma : le schéma Upwind	114
4.4.2	Convergence d'un schéma aux différences finies	116
4.4.3	Consistance d'un schéma aux différences finies	120
	Une propriété du schéma Upwind pour l'équation homogène d'advection à vitesse constante	122
4.4.4	Stabilité d'un schéma aux différences finies	123
4.4.5	Étude de la convergence du schéma Upwind	125
4.4.6	Mise en œuvre du schéma Upwind et illustration de ses propriétés	128
4.5	Autres schémas d'approximation de l'équation d'advection	132
4.5.1	Un schéma d'ordre 2 en espace	132
	Étude de la consistance du schéma	132
	Étude de la stabilité du schéma	133
4.5.2	Le schéma de Lax-Wendroff	134
4.5.3	Le schéma saute-mouton (ou leapfrog)	135
4.5.4	Les schémas implicites	138

5 Problèmes aux limites hyperboliques du second ordre	141
5.1 Étude des propriétés de l'équation des ondes	141
5.2 Schéma aux différences finies pour l'équation des ondes	148
5.2.1 Construction du schéma	148
5.2.2 Mise en œuvre du schéma	149
5.3 Consistance du schéma aux différences finies	150
5.4 Stabilité du schéma aux différences finies	152
5.5 Erreur sur l'initialisation du schéma	157
5.6 Illustrations numériques	158
5.6.1 Étude de l'erreur commise	158
5.6.2 Étude des variations de l'énergie	160
Bibliographie	163

Étude d'un problème aux limites unidimensionnel

On considère le problème ($\mathcal{P}$) suivant posé dans l'ouvert $]a, b[$ de $\mathbb{R}$: trouver une fonction $u \in \mathcal{C}^2([a, b])$ telle que

$$-(\alpha(x) u'(x))' + \beta(x) u'(x) + \gamma(x) u(x) = f(x) \quad \forall x \in]a, b[\quad (1.1)$$

$$u(a) = u_a, \quad u(b) = u_b \quad (1.2)$$

où β , γ et f désignent trois applications continues sur $[a, b]$, α désigne une application de classe $\mathcal{C}^1$ sur $[a, b]$, et u_a , u_b désignent deux réels.

1.1 Modélisation de phénomènes physiques

1.1.1 Équation des cordes vibrantes

Une corde sans raideur, inextensible, de masse linéique μ constante, est tendue avec une force de tension $\mathbf{T}$. Dans un repère orthonormé direct $(0, \mathbf{x}, \mathbf{y})$, la corde se confond au repos avec l'axe $(0, \mathbf{x})$. On s'intéresse aux petits mouvements transversaux de cette corde dans le plan $(0, \mathbf{x}, \mathbf{y})$. On suppose qu'un point de la corde repéré par l'abscisse x au repos reste pendant tout le mouvement de la corde à la même abscisse. On note $u(x, t)$ le déplacement vertical d'un point d'abscisse x à l'instant t . Sous l'hypothèse de petites vibrations, la tangente à la corde au point de coordonnées $(x, u(x, t))$ fait avec l'horizontale un angle $\theta(x, t)$ qui reste petit. L'évolution au cours du temps de la corde est régie par la deuxième loi de Newton




FIG. 1 Corde vibrante.

ou principe fondamental de la dynamique.⁽¹⁾

Considérons un élément de corde infinitésimal compris entre les abscisses x et $x + \delta x$ (δx est un réel positif, très petit). Nous désignons par $u(x, t)$ le déplacement vertical au point d'abscisse x et par $u(x, t) + \delta u$ le déplacement vertical au point d'abscisse $x + \delta x$. Sous l'hypothèse de petites vibrations, le réel δu est petit en valeur absolue. Les forces s'exerçant sur cet élément de corde au cours du temps sont, voir la Fig. 2 :

⁽¹⁾. Ces lois du mouvement ont été énoncées par Newton dans son ouvrage *Philosophiae naturalis principia mathematica* en 1687. Dans le cas d'un corps de masse m constante, la deuxième loi de Newton s'énonce ainsi : l'accélération subie par ce corps dans un référentiel galiléen est proportionnelle à la résultante des forces qu'il subit, et inversement proportionnelle à sa masse m . En d'autres termes, $\sum_i \mathbf{F}_i = m \boldsymbol{\gamma}$ où $\mathbf{F}_i$ désignent les forces extérieures exercées sur l'objet et $\boldsymbol{\gamma}$ l'accélération de son centre d'inertie.




FIG. 2 Forces s'exerçant sur un élément de corde infinitésimal.

- une tension $\mathbf{T}(x, t)$ s'exerçant en $(x, u(x, t))$ vers la gauche et faisant un angle $\theta(x, t)$ avec l'horizontale ;
- une tension $\mathbf{T}(x + \delta x, t)$ s'exerçant en $(x + \delta x, u(x + \delta x, t))$ vers la droite et faisant un angle $\theta(x + \delta x, t)$ avec l'horizontale ;
- diverses forces externes comme la pesanteur ou comme des forces d'amortissement que nous supposons orientées verticalement et représentées par une densité linéique de force notée $f(x, t)$.

L'élément de corde infinitésimal compris entre les abscisses x et $x + \delta x$ a une longueur valant $\sqrt{\delta x^2 + \delta u^2}$. Sous l'hypothèse de petites vibrations, δu est petit et la longueur peut être approchée par δx puisque

$$\sqrt{\delta x^2 + \delta u^2} = \delta x \sqrt{1 + \frac{\delta u^2}{\delta x^2}} = \delta x \left(1 + \left(\frac{\delta u}{2\delta x} \right)^2 + \mathcal{O}_0 \left(\left(\frac{\delta u}{2\delta x} \right)^4 \right) \right).$$

Sa masse vaut donc approximativement $\mu(x)\delta x$. La deuxième loi de Newton ⁽¹⁾ en projection sur les axes $(0, \mathbf{x})$ et $(0, \mathbf{y})$ s'écrit

$$0 = T(x + \delta x, t) \cos(\theta(x + \delta x, t)) - T(x, t) \cos(\theta(x, t)) \quad (1.3)$$

$$\mu(x) \delta x \frac{\partial^2 u}{\partial t^2} = T(x + \delta x, t) \sin(\theta(x + \delta x, t)) - T(x, t) \sin(\theta(x, t)) + f(x, t) \delta x \quad (1.4)$$

où T désigne l'intensité de la force de tension $\mathbf{T}$. Sous l'hypothèse de petites vibrations, l'angle $\theta(x, t)$ reste petit et en première approximation $\cos(\theta(x + \delta x, t)) \approx 1$ et $\cos(\theta(x, t)) \approx 1$. On a donc sous cette approximation $T(x + \delta x, t) = T(x, t)$. En divisant par δx et en passant à la limite quand δx tend vers 0, il vient

$$\frac{\partial T}{\partial x}(x, t) = \lim_{\delta x \rightarrow 0} \frac{T(x + \delta x, t) - T(x, t)}{\delta x} = 0,$$

autrement dit, la force de tension $\mathbf{T}$ est d'intensité constante le long de la corde ; elle ne dépend pas de la position x le long de la corde et on a $T(x, t) = T(t)$ pour tout $x \in [a, b]$ et pour tout $t \geq 0$. En combinant cette relation avec l'approximation $\sin(\theta(x + \delta x, t)) \approx \theta(x + \delta x, t)$ et $\sin(\theta(x, t)) \approx \theta(x, t)$, l'équation (1.4) s'écrit

$$\mu(x) \delta x \frac{\partial^2 u}{\partial t^2} = T(t) (\theta(x + \delta x, t) - \theta(x, t)) + f(x, t) \delta x. \quad (1.5)$$

En divisant par δx chaque membre de l'équation et en passant à la limite quand δx tend vers 0, il vient

$$\mu(x) \frac{\partial^2 u}{\partial t^2}(x, t) = T(t) \frac{\partial \theta}{\partial x}(x, t) + f(x, t). \quad (1.6)$$

À partir de la figure 2, on établit la relation suivante entre u et θ :

$$\tan(\theta(x, t)) = \lim_{\delta x \rightarrow 0} \tan(\theta(x + \delta x, t)) = \lim_{\delta x \rightarrow 0} \frac{\delta u}{\delta x} = \lim_{\delta x \rightarrow 0} \frac{u(x + \delta x, t) - u(x, t)}{\delta x} = \frac{\partial u}{\partial x}(x, t).$$

Pour $\theta(x, t)$ petit, on a $\tan(\theta(x, t)) \approx \theta(x, t)$ et par suite $\frac{\partial \theta}{\partial x}(x, t) \approx \frac{\partial^2 u}{\partial x^2}(x, t)$. On obtient finalement l'équation aux dérivées partielles suivante sur $]a, b[$:

$$\mu(x) \frac{\partial^2 u}{\partial t^2}(x, t) - T(t) \frac{\partial^2 u}{\partial x^2}(x, t) = f(x, t). \quad (1.7)$$

Dans cette équation μ est la densité linéique de masse, homogène à une masse par unité de longueur ($M L^{-1}$), u est un déplacement homogène à une longueur (L), T est une force⁽²⁾ et par conséquent est homogène à $M L T^{-2}$, f correspond à une densité linéique de force et par conséquent est homogène à $M T^{-2}$. On vérifiera que l'équation (1.7) est bien homogène en terme de dimension. Cette équation est appelée *équation des ondes* ou *équation des cordes vibrantes*. Dans le cas où on peut faire l'hypothèse que le phénomène observé ne dépend pas du temps, on obtient l'équation

$$-Tu''(x) = f(x) \quad \forall x \in]a, b[\quad (1.8)$$

qui est de la forme (1.1). Dans le cas où la tension T ne dépend pas du temps et que les forces exercées sont périodiques en temps de pulsation ω , de la forme $f(x, t) = f(x) \sin(\omega t)$, la solution est elle aussi périodique de pulsation ω de la forme $u(x, t) = u(x) \sin(\omega t)$. L'équation (1.7) s'écrit alors

$$-Tu''(x) - \omega^2 \mu(x) u(x) = f(x) \quad \forall x \in]a, b[\quad (1.9)$$

qui est aussi de la forme (1.1).

1.1.2 Équation de la chaleur

On considère une tige métallique de longueur L et de section constante d'aire S supposée très petite devant sa longueur, de sorte que nous pouvons supposer que les seuls phénomènes physiques agissant sur la tige ont lieu dans la direction définie par l'axe de la tige. En particulier, s'agissant ici de la modélisation de phénomènes thermiques, nous supposons la barre isolée thermiquement sur sa longueur, les échanges thermiques avec le milieu ambiant ne pouvant se faire que par ses deux extrémités.

La puissance thermique (ou flux thermique) désigne la quantité de chaleur traversant une surface isotherme par unité de temps. Il s'agit donc d'un flux de chaleur qui s'exprime en Watt, la quantité de chaleur étant exprimée en Joule et le temps en seconde. Effectuons un bilan énergétique entre les instants t et $t + \delta t$ sur un élément de tige infinitésimal : la puissance entrante P_1 moins la puissance sortante P_2 est égale la puissance produite P_3 (ou à la puissance dissipée) au sein du matériau plus la puissance stockée P_4 .

Supposons que la barre soit assimilable à un segment $[a, b]$ de longueur $L = b - a$. Notons $q(x, t)$ la densité de flux thermique (flux thermique par unité de surface exprimé en Watt par mètre carré (W/m^2)) « entrant » en $x \in]a, b[$ et $q(x + \delta x, t)$ la densité de flux d'énergie « sortant » en $x + \delta x$. Le bilan du transfert par conduction thermique, qui correspond à un transfert thermique spontané d'une région de température élevée vers une région de température plus basse, s'exprime donc sous la forme $P_1 - P_2 = (q(x) - q(x + dx)) S$.

En cas de variation de température de δT , l'élément de tige compris entre x et $x + dx$, de capacité thermique c (exprimée en $J/kg K$) et de masse volumique ρ (exprimée en kg/m^3), voit son énergie interne varier de $\delta U = \rho c S \delta x \delta T$. La puissance moyenne stockée dans l'élément de tige entre les instants t et $t + \delta t$ s'exprime donc sous la forme

$$P_4 = \frac{\delta U}{\delta t} = \rho c S \delta x \frac{\delta T}{\delta t}.$$

La tige métallique peut également être le siège de phénomènes producteurs d'énergie thermique ou, à l'inverse, dissipateurs de cette énergie (par exemple dans le cas d'une tige métallique parcourue par un courant, il y a dissipation d'énergie par effet Joule). Désignons par $f(x, t)$ la densité volumique de puissance produite ou dissipée au temps t et à la position x dans la tige considérée comme une quantité algébrique, positive en cas de production thermique et négative en cas de dissipation thermique. La

(2). L'unité pour une force dans le système international (SI) est le newton ; 1 newton correspond à $1 kg m s^{-2}$.

puissance produite ou dissipée au sein du matériau dans l'élément de tige compris entre x et $x + \delta x$ s'exprime donc sous la forme $P_3(x, t) = f(x, t) S \delta x$.

D'où l'équation de bilan :

$$P_1 - P_2 - P_3 - P_4 = \left(q(x, t) - q(x + dx, t) + f(x, t) dx + \rho c \delta x \frac{\delta T}{\delta t} \right) S = 0.$$

En divisant par δx et en passant à la limite quand δx tend vers 0, puis en divisant par δt et en passant à la limite quand δt tend vers 0, nous obtenons

$$-\frac{\partial q}{\partial x}(x, t) + f(x, t) + \rho c \frac{\partial T}{\partial t}(x, t) = 0. \quad (1.10)$$

Notons que dans cette équation aux dérivées partielles interviennent deux inconnues : la température T et la densité de flux thermique q . D'après la *loi de Fourier*, la densité de flux de chaleur (ou densité de flux thermique, c'est-à-dire le flux thermique par unité de surface) est proportionnelle au gradient de température, ce qui dans notre cas s'exprime sous la forme

$$q(x, t) = -\lambda(x) \frac{\partial T}{\partial x}(x, t) \quad (1.11)$$

où la constante de proportionnalité λ est nommée *conductivité thermique* du matériau et s'exprime en Watt par mètre-Kelvin (W/m·K).

En combinant (1.10) et (1.11), nous obtenons l'équation de la chaleur :

$$\rho c \frac{\partial T}{\partial t}(x, t) - \frac{\partial}{\partial x} \left(\lambda(x) \frac{\partial T}{\partial x}(x, t) \right) = f(x, t) \quad \forall x \in]a, b[. \quad (1.12)$$

Dans le cas du régime stationnaire, la dépendance en temps disparaît et l'équation (1.12) prend la forme suivante

$$-(\lambda(x)T'(x))' = f(x) \quad \forall x \in]a, b[$$

qui est de la forme (1.1).

Intéressons-nous à présent aux conditions aux limites aux deux extrémités a et b de la barre. Différentes situations physiques peuvent être modélisées.

- La température aux extrémités de la barre peut être imposée. On traduit cette situation en imposant des conditions de Dirichlet aux extrémités :

$$T(a) = T_a, \quad T(b) = T_b,$$

où T_a et T_b désignent deux réels.

- Il est souvent plus réaliste d'imposer la densité de flux thermique q aux extrémités (pour tenir compte de pertes par rayonnement par exemple). On a dans ce cas une condition aux limites de type Neumann de la forme :

$$T'(a) = q_a, \quad T'(b) = q_b,$$

où q_a et q_b désignent deux réels. Le cas où la barre est isolée à ses extrémités est modélisé en utilisant une condition aux limites de Neumann homogène : $T'(a) = T'(b) = 0$.

- On peut aussi dans certains cas imposer une condition aux limites correspondant à un échange thermique avec le milieu extérieur par convection. Le flux de chaleur échangé par convection entre l'extrémité de la barre à la température T et l'air ambiant à la température T_e est donné par : $q(a) = h_c (T(a) - T_e)$ où h_c désigne le coefficient d'échange superficiel par convection. On a donc d'après (1.11) la condition aux limites suivante pour la température :

$$\lambda T'(a) = h_c (T_e - T(a)), \quad \lambda T'(b) = h_c (T_e - T(b)). \quad (1.13)$$

- Une condition aux limites plus générale encore est :

$$\lambda T'(a) = h_c (T_e - T(a)) + \varepsilon \sigma (T_e - T(a))^4 \quad (1.14)$$

où σ est la *constante de Stefan-Boltzmann* et l'émissivité ε est un coefficient sans unité, compris entre 0 et 1.

1.2 Problème aux limites vs. problème de Cauchy

Avant d'aller plus loin, il est souhaitable de bien faire la différence entre le problème aux limites ($\mathcal{P}$) : trouver $u \in \mathcal{C}^2([a, b])$ tel que

$$(\mathcal{P}) \quad \begin{cases} -(\alpha(x) u'(x))' + \beta(x) u'(x) + \gamma(x) u(x) = f(x) & \forall x \in]a, b[\\ u(a) = u_a, \quad u(b) = u_b \end{cases}$$

et le problème de Cauchy ($\mathcal{Q}$) correspondant à la même équation différentielle avec des conditions initiales : trouver $u \in \mathcal{C}^2([a, b])$ tel que

$$(\mathcal{Q}) \quad \begin{cases} -(\alpha(x) u'(x))' + \beta(x) u'(x) + \gamma(x) u(x) = f(x) & \forall x \in]a, b[\\ u(a) = u_a, \quad u'(a) = v_a \end{cases}$$

où β , γ et f désignent trois applications continues sur $[a, b]$, α désigne une application de classe $\mathcal{C}^1$ sur $[a, b]$, et u_a , v_a et u_b désignent deux réels. En posant $v = u'$, l'équation différentielle se réécrit :

$$\alpha(x) \underbrace{u''(x)}_{v'(x)} = (-\alpha'(x) + \beta(x)) \underbrace{u'(x)}_{v(x)} + \gamma(x) u(x) - f(x).$$

On peut donc réécrire le problème de Cauchy ($\mathcal{Q}$) sous la forme d'un système différentiel linéaire d'ordre 1 en introduisant le vecteur $Y(x) = \begin{pmatrix} u(x) \\ v(x) \end{pmatrix}$ de $\mathbb{R}^2$. On a

$$Y'(x) = \begin{pmatrix} u'(x) \\ v'(x) \end{pmatrix} = \begin{pmatrix} v(x) \\ \frac{1}{\alpha(x)} (-\alpha'(x) + \beta(x)) v(x) + \gamma(x) u(x) - f(x) \end{pmatrix} = A(x) Y(x) + B(x)$$

où $A(x)$ désigne la matrice de $\mathcal{M}_2(\mathbb{R})$, dont les coefficients dépendent du paramètre x , définie par

$$A(x) = \begin{pmatrix} 0 & 1 \\ \frac{\gamma(x)}{\alpha(x)} & \frac{-\alpha'(x) + \beta(x)}{\alpha(x)} \end{pmatrix}$$

et $B(x)$ est le vecteur de $\mathbb{R}^2$ défini par

$$B(x) = \begin{pmatrix} 0 \\ -\frac{f(x)}{\alpha(x)} \end{pmatrix}.$$

Ainsi, résoudre le problème de Cauchy ($\mathcal{Q}$) revient à résoudre le système différentiel

$$(\mathcal{Q}_S) \quad \begin{cases} Y'(x) = A(x) Y(x) + B(x) & \forall x \in]a, b[\\ Y(a) = \begin{pmatrix} u_a \\ v_a \end{pmatrix} \end{cases}$$

Rappelons le résultat d'existence-unicité pour le problème ($\mathcal{Q}_S$) qui est un corollaire du théorème de Cauchy-Lipschitz, voir par ex. [5, 7].

THÉORÈME 1.1 (Théorème de Cauchy-Lipschitz linéaire)

Si les applications $A : x \in [a, b] \mapsto A(x) \in \mathcal{M}_2(\mathbb{R})$ et $B : x \in [a, b] \mapsto B(x) \in \mathbb{R}^2$ sont continues sur $[a, b]$ alors pour tout $Y_0 \in \mathbb{R}^2$, le problème : trouver $Y \in \mathcal{C}^1([a, b], \mathbb{R}^2)$ tel que

$$\begin{cases} Y'(x) = A(x) Y(x) + B(x) & \forall x \in]a, b[\\ Y(a) = Y_0 \end{cases}$$

admet une unique solution.

En particulier, on déduit du théorème 1.1, sous les hypothèses :

- $\alpha \in C^1([a, b])$ et il existe $\alpha_0 \in \mathbb{R}_+^*$ tel que $\alpha(x) \geq \alpha_0$ pour tout $x \in [a, b]$,
- β, γ et f sont des applications continues sur $[a, b]$,

que le problème de Cauchy (Q) admet une unique solution. Malheureusement, le fait que le problème de Cauchy (Q) admette une unique solution ne donne aucune information sur l'existence et l'unicité d'une solution pour le problème aux limites (P).

Exemple 1.1 Considérons l'équation différentielle $-u''(x) - cu(x) = d$ sur $[-1, 1]$ où c et d sont deux réels strictement positifs. La solution générale de cette équation différentielle linéaire du second ordre est $u : x \in [-1, 1] \mapsto C_1 \cos(\sqrt{c}x) + C_2 \sin(\sqrt{c}x) - \frac{d}{c}$.

- Considérons le problème de Cauchy constitué de cette équation différentielle et des conditions initiales $u(-1) = 0$ et $u'(-1) = 0$. Ces deux conditions imposent que $C_1 = \frac{d}{c} \cos(\sqrt{c})$ et que $C_2 = -\frac{d}{c} \sin(\sqrt{c})$. On a donc existence et unicité d'une solution à ce problème de Cauchy pour toute valeur $c > 0$.
- Considérons à présent le problème aux limites constitué de cette équation différentielle et des conditions aux limites $u(-1) = 0$ et $u(1) = 0$. Ces deux conditions imposent que C_1 et C_2 vérifient

$$\begin{cases} C_1 \cos(\sqrt{c}) = \frac{d}{c} \\ C_2 \sin(\sqrt{c}) = 0 \end{cases} \quad (1.15)$$

On en déduit donc que

- Si $\sqrt{c} = \frac{\pi}{2} + k\pi$ avec $k \in \mathbb{N}$ alors $\cos(\sqrt{c}) = 0$ et la première équation conduit à une contradiction car $\frac{d}{c} > 0$. Donc le problème aux limites n'a pas de solution.
- Si $\sqrt{c} = k\pi$ avec $k \in \mathbb{N}^*$ alors la seconde équation du système (1.15) est identiquement satisfaite quelle que soit la valeur de C_2 et la première équation impose que $C_1 = (-1)^k \frac{d}{c}$. On a donc dans ce cas une infinité de solutions au problème aux limites qui sont toutes les fonctions de la forme $u : x \in [-1, 1] \mapsto (-1)^k \frac{d}{k^2\pi^2} \cos(k\pi x) + C_2 \sin(k\pi x) - \frac{d}{k^2\pi^2}$ avec C_2 un réel quelconque.
- Enfin, en considérant par exemple la valeur $c = \frac{\pi}{16}$, le système (1.15) admet pour unique solution $C_1 = \frac{16\sqrt{2}}{\pi^2}d$ et $C_2 = 0$. Donc le problème aux limites admet pour unique solution $u : x \in [-1, 1] \mapsto \frac{16\sqrt{2}}{\pi^2}d \cos(\frac{\pi}{4}x) - \frac{16d}{\pi^2}$.

Remarque 1.1 Nous verrons en travaux pratiques comment exploiter les méthodes de résolution numérique d'un problème de Cauchy pour construire une approche, appelée *méthode de tir*, permettant de calculer une approximation de la solution du problème aux limites (P).

1.3 Problème bien posé mathématiquement

On dit qu'un problème est *bien posé au sens de Hadamard* s'il admet une unique solution qui « dépend continûment des données ». L'existence de la solution est primordiale. La condition d'unicité l'est tout autant si l'on souhaite s'accorder sur la solution à calculer. La condition que la solution doit « dépendre continûment des données » traduit le fait que de petites variations sur les données doivent se traduire par de petits écarts sur la solution du problème considéré. Il s'agit d'une condition essentielle pour le calcul numérique d'une solution à un problème donné compte tenu de la représentation des nombres sur un ordinateur qui introduisent naturellement des variations sur les données (par exemple, π ou $1/3$ ne sont représentés que de manière approchée en arithmétique flottante⁽³⁾).

1.3.1 Existence de la solution au problème aux limites

Commençons par établir que notre problème aux limites modèle (P) admet une solution.

(3). Arithmétique des nombres réels sur ordinateur, dite en virgule flottante, voir par exemple [13, 11].

HADAMARD, Jacques Salomon (1865, Versailles - 1963, Paris).



Mathématicien français ayant eu une grande influence sur l'école française de mathématiques au début du XX^e siècle. Il est considéré comme un précurseur dans la théorie des équations aux dérivées partielles, dont il est un des fondateurs sous sa forme moderne. Il est également connu pour ses travaux en théorie des nombres, en analyse complexe, en analyse fonctionnelle et en géométrie différentielle.

THÉORÈME 1.2 (Existence de la solution)

On suppose que :

- $\alpha \in \mathcal{C}^1([a, b])$ et il existe $\alpha_0 \in \mathbb{R}_+^*$ tel que $\alpha(x) \geq \alpha_0$ pour tout $x \in [a, b]$;
- $\gamma \in \mathcal{C}^0([a, b])$ et $\gamma(x) \geq 0$ pour tout $x \in [a, b]$;
- $\beta \in \mathcal{C}^1([a, b])$ et $\beta'(x) \leq 2\gamma(x)$ pour tout $x \in [a, b]$;
- f est une application continue sur $[a, b]$.

Sous ces hypothèses, le problème : trouver une fonction $u \in \mathcal{C}^2([a, b])$ telle que

$$(\mathcal{P}) \quad \begin{cases} -(\alpha(x) u'(x))' + \beta(x) u'(x) + \gamma(x) u(x) = f(x) & \forall x \in]a, b[\\ u(a) = u_a, \quad u(b) = u_b \end{cases}$$

admet une solution.

Démonstration Considérons les deux problèmes de Cauchy suivants :

trouver $u_1 \in \mathcal{C}^2([a, b])$ tel que

$$(\mathcal{P}_1) \quad \begin{cases} -(\alpha(x) u_1'(x))' + \beta(x) u_1'(x) + \gamma(x) u_1(x) = f(x) & \forall x \in]a, b[\\ u_1(a) = u_a, \quad u_1'(a) = 0 \end{cases}$$

et trouver $u_2 \in \mathcal{C}^2([a, b])$ tel que

$$(\mathcal{P}_2) \quad \begin{cases} -(\alpha(x) u_2'(x))' + \beta(x) u_2'(x) + \gamma(x) u_2(x) = 0 & \forall x \in]a, b[\\ u_2(a) = 0, \quad u_2'(a) = 1 \end{cases}$$

Sous les hypothèses du théorème 1.2, ces deux problèmes de Cauchy admettent une unique solution, voir la section 1.2. Considérons la fonction $u = u_1 + \kappa u_2$ où u_1 et u_2 désignent respectivement les solutions des problèmes $(\mathcal{P}_1)$ et $(\mathcal{P}_2)$ et κ est un réel dont on fixera la valeur ultérieurement. Comme les équations différentielles des problèmes $(\mathcal{P}_1)$ et $(\mathcal{P}_2)$ sont linéaires, on vérifie sans peine que u satisfait l'équation différentielle

$$-(\alpha(x) u'(x))' + \beta(x) u'(x) + \gamma(x) u(x) = f(x) \quad \forall x \in]a, b[.$$

Par ailleurs, compte-tenu des conditions initiales des problèmes $(\mathcal{P}_1)$ et $(\mathcal{P}_2)$

$$\begin{aligned} u(a) &= u_1(a) + \kappa u_2(a) = u_a, \\ u(b) &= u_1(b) + \kappa u_2(b). \end{aligned}$$

Si $u_2(b) \neq 0$ alors en choisissant pour κ la valeur $\kappa = (u_b - u_1(b))/u_2(b)$, on trouve $u(b) = u_b$ et la fonction $u = u_1 + \kappa u_2$ est par conséquent solution du problème $(\mathcal{P})$. Le problème $(\mathcal{P})$ admet donc au moins une solution.

Reste à établir que l'on a effectivement $u_2(b) \neq 0$ sous les hypothèses du théorème. Comme pour tout $x \in]a, b[$, on a $-(\alpha(x) u_2'(x))' + \beta(x) u_2'(x) + \gamma(x) u_2(x) = 0$, en multipliant chaque membre de cette égalité

par $u_2(x)$ et en intégrant sur $[a, b]$, on obtient

$$-\int_a^b (\alpha(x) u_2'(x))' u_2(x) dx + \int_a^b \beta(x) \underbrace{u_2(x) u_2'(x)}_{=\frac{1}{2}(u_2^2)'(x)} dx + \int_a^b \gamma(x) u_2^2(x) dx = 0.$$

Appliquons la formule d'intégration par parties aux deux premières intégrales. En tenant compte du fait que $u_2(a) = 0$, on obtient

$$-\alpha(b) u_2(b) u_2'(b) + \int_a^b \alpha(x) (u_2'(x))^2 dx + \frac{1}{2} \beta(b) u_2^2(b) - \frac{1}{2} \int_a^b \beta'(x) u_2^2(x) dx + \int_a^b \gamma(x) u_2^2(x) dx = 0,$$

ce que l'on peut encore écrire

$$u_2(b) (\alpha(b) u_2'(b) - \frac{1}{2} \beta(b) u_2(b)) = \int_a^b \alpha(x) (u_2'(x))^2 dx + \frac{1}{2} \int_a^b (2\gamma(x) - \beta'(x)) u_2^2(x) dx. \quad (1.16)$$

Compte tenu des hypothèses du théorème, on a $\int_a^b (2\gamma(x) - \beta'(x)) u_2^2(x) dx \geq 0$ et comme u_2' est continue sur $[a, b]$ avec $u_2'(a) \neq 0$, u_2' ne s'annule pas au voisinage de a . Il existe donc un intervalle de la forme $[a, a + \eta]$ où u_2' est non nulle. Par conséquent,

$$\int_a^b \alpha(x) (u_2'(x))^2 dx \geq \alpha_0 \int_a^{a+\eta} (u_2'(x))^2 dx > 0.$$

Le membre de droite dans l'égalité (1.16) est donc strictement positif. Par conséquent, le membre de gauche est non nul, ce qui implique que le membre de gauche est lui aussi non nul et finalement que $u_2(b) \neq 0$.

Signalons que l'on peut aussi déduire de (1.16) que $u_2(b) \neq 0$ en raisonnant par l'absurde. Supposons que $u_2(b) = 0$. D'après (1.16), compte tenu du fait que $\int_a^b (2\gamma(x) - \beta'(x)) u_2^2(x) dx \geq 0$, on a nécessairement $\int_a^b \alpha(x) (u_2'(x))^2 dx = 0$. Comme la fonction α est supposée strictement positive et que u_2 est de classe $\mathcal{C}^2$ sur $[a, b]$, on en déduit que u_2' est nulle sur $[a, b]$. En particulier $u_2'(a) = 0$, ce qui contredit la condition initiale du problème ($\mathcal{P}_2$) définissant la fonction u_2 .

On pourra noter que la valeur $u_2'(a)$ n'a pas été explicitement exploitée : nous avons juste utilisé le fait que cette valeur était non nulle. Une autre valeur que la valeur 1 choisie comme condition initiale du problème ($\mathcal{P}_2$) aurait donc pu être considérée. $\square$

Remarque 1.2 L'idée exploitée dans la preuve du théorème 1.6 donne lieu à une méthode de résolution du problème aux limites ($\mathcal{P}$) appelée *méthode de tir* (*shooting method* en anglais). Cette méthode consiste à utiliser les méthodes de résolution d'équations différentielles avec données initiales telles la méthode d'Euler ou les méthodes de Runge-Kutta, pour calculer une approximation de la solution des problèmes de Cauchy ($\mathcal{P}_1$) et ($\mathcal{P}_2$). On calcule ensuite $\kappa = (u_b - u_1(b))/u_2(b)$ et, comme établi dans la preuve du théorème 1.6, la fonction $u = u_1 + \kappa u_2$ est la solution du problème aux limites ($\mathcal{P}$). Toutefois, la méthode de tir est sujette à des instabilités numériques et on lui préfère en pratique des méthodes d'approximation telles la méthode des différences finies ou la méthode des éléments finis que nous allons présenter dans la suite de ce chapitre.

Remarque 1.3 Les hypothèses du théorème 1.2 correspondent à des conditions suffisantes d'existence d'une solution au problème modèle ($\mathcal{P}$). Il ne s'agit nullement de conditions nécessaires. On peut d'ailleurs démontrer l'existence d'une solution au problème ($\mathcal{P}$) sous des hypothèses plus faibles que celles considérées ici mais cela nécessite des développements mathématiques plus élaborés que ceux utilisés dans la preuve du théorème 1.2. Ajoutons qu'il serait illusoire de vouloir démontrer l'existence d'une solution au problème ($\mathcal{P}$) sans aucune hypothèse sur les fonctions coefficients α, β, γ . Par exemple, pour $\alpha : x \in [0, 1] \mapsto -x^3$, $\beta : x \in [0, 1] \mapsto x^2$, γ et f égales à la fonction nulle, le problème modèle ($\mathcal{P}$) n'admet pas de solution et ceci, quelles que soient les valeurs de u_0 et u_1 distinctes correspondant aux données aux

limites. En effet, on montre sans difficulté que pour ces données les solutions de l'équation différentielle homogène linéaire d'ordre 2

$$-(\alpha(x) u'(x))' + \beta(x) u'(x) + \gamma(x) u(x) = f(x) \quad \forall x \in]0, 1[$$

sont les fonctions de la forme $u : x \in]0, 1[\mapsto C_1 + \frac{C_2}{x}$. Aucune de ces fonctions, autres que les fonctions constantes correspondant au cas où $C_2 = 0$, n'est bornée en 0. Dans le cas où $u_0 \neq u_1$, une fonction constante ne peut pas être solution. Il n'existe donc pas de solution au problème $(\mathcal{P})$.

1.3.2 Régularité de la solution

Nous avons établi au théorème 1.2 que sous les hypothèses

- $\alpha \in \mathcal{C}^1([a, b])$ et il existe $\alpha_0 \in \mathbb{R}_+^*$ tel que $\alpha(x) \geq \alpha_0$ pour tout $x \in [a, b]$;
- $\gamma \in \mathcal{C}^0([a, b])$ et $\gamma(x) \geq 0$ pour tout $x \in [a, b]$;
- $\beta \in \mathcal{C}^1([a, b])$ et $\beta'(x) \leq 2\gamma(x)$ pour tout $x \in [a, b]$;
- f est une application continue sur $[a, b]$;

le problème aux limites modèle $(\mathcal{P})$ admettait une unique solution. Si les données sont un peu plus régulières que ce qui est exigé par les hypothèses du théorème 1.2, on peut s'attendre à ce que la solution du problème aux limites modèle $(\mathcal{P})$ soit elle aussi un peu plus régulière que la régularité $\mathcal{C}^2$ obtenue par le théorème 1.2. C'est effectivement le cas.

PROPOSITION 1.1 *On se place sous les hypothèses du théorème 1.2. Si pour un entier $n \geq 1$, les applications β , γ et f sont de classe $\mathcal{C}^n$ sur $[a, b]$ et si α est de classe $\mathcal{C}^{n+1}$ sur $[a, b]$, alors la solution u du problème aux limites $(\mathcal{P})$ sera de classe $\mathcal{C}^{n+2}$ sur $[a, b]$.*

Démonstration On procède par récurrence sur l'entier n .

$\supseteq$ Pour $n = 1$, les fonctions β , γ et f sont de classe $\mathcal{C}^1$ sur $[a, b]$ et α est de classe $\mathcal{C}^2$ sur $[a, b]$. D'après le théorème 1.2, le problème $(\mathcal{P})$ admet une solution de classe $\mathcal{C}^2$ sur $[a, b]$. De plus, l'application

$$x \in [a, b] \mapsto \beta(x) u'(x) + \gamma(x) u(x) - f(x)$$

est de classe $\mathcal{C}^1$ sur $[a, b]$. Par conséquent, comme u est solution du problème $(\mathcal{P})$, on a

$$\forall x \in [a, b] \quad (\alpha(x) u'(x))' = \beta(x) u'(x) + \gamma(x) u(x) - f(x)$$

et par suite $(\alpha \times u')' \in \mathcal{C}^1([a, b])$. On a donc $\alpha \times u'$ qui est de classe $\mathcal{C}^2$ sur $[a, b]$. Comme $\alpha \in \mathcal{C}^2([a, b])$ est strictement positive sur $[a, b]$, on en conclut que u' est de classe $\mathcal{C}^2$ sur $[a, b]$ et donc que u est de classe $\mathcal{C}^3$ sur $[a, b]$.

$\supseteq$ Supposons que pour un entier naturel k , la solution u du problème aux limites $(\mathcal{P})$ soit de classe $\mathcal{C}^{k+2}$ sur $[a, b]$ et montrons que si les applications β , γ et f sont de classe $\mathcal{C}^{k+1}$ sur $[a, b]$ et si α est de classe $\mathcal{C}^{k+2}$ sur $[a, b]$, alors la solution u du problème aux limites $(\mathcal{P})$ est de classe $\mathcal{C}^{k+3}$ sur $[a, b]$.

Comme u est supposé de classe $\mathcal{C}^{k+2}$ sur $[a, b]$, u' est de classe $\mathcal{C}^{k+1}$ sur $[a, b]$. Comme les applications β , γ et f sont supposées de classe $\mathcal{C}^{k+1}$ sur $[a, b]$, l'application

$$x \in [a, b] \mapsto \beta(x) u'(x) + \gamma(x) u(x) - f(x)$$

est de classe $\mathcal{C}^{k+1}$. Comme u est solution du problème aux limites modèle $(\mathcal{P})$,

$$\forall x \in [a, b] \quad (\alpha(x) u'(x))' = \beta(x) u'(x) + \gamma(x) u(x) - f(x).$$

On a donc $\alpha \times u'$ qui est de classe $\mathcal{C}^{k+2}$ sur $[a, b]$. Comme $\alpha \in \mathcal{C}^{k+2}([a, b])$ est strictement positive sur $[a, b]$, on en conclut que u' est de classe $\mathcal{C}^{k+2}$ sur $[a, b]$ et donc que u est de classe $\mathcal{C}^{k+3}$ sur $[a, b]$. $\square$

1.3.3 Principe du maximum

Le principe du maximum regroupe un ensemble de résultats concernant d'une part les points de maximum (ou de minimum) de solutions de certains problèmes aux limites et d'autre part les propriétés de dépendance de ces solutions par rapport aux données.

Nous désignons par $\mathcal{L}$ l'opérateur différentiel du second ordre défini par

$$\mathcal{L} : u \in \mathcal{C}^2([a, b]) \mapsto -(\alpha u')' + \beta u' + \gamma u \in \mathcal{C}^0([a, b])$$

où les applications β et γ sont continues sur $[a, b]$ et α est de classe $\mathcal{C}^1$ sur $[a, b]$.

THÉORÈME 1.3 (Principe du maximum)

On suppose qu'il existe $\alpha_0 \in \mathbb{R}_+^*$ tel que pour tout $x \in]a, b[$, $\alpha(x) \geq \alpha_0$.

Soit $u \in \mathcal{C}^2([a, b])$ tel que pour tout $x \in]a, b[$ on ait $\mathcal{L}u(x) \leq 0$. Sous ces hypothèses,

- si $\gamma = 0$ alors $\max_{x \in [a, b]} u(x) = \max\{u(a), u(b)\}$;
- si $\gamma \geq 0$ alors $\max_{x \in [a, b]} u(x) \leq \max\{u(a), u(b), 0\}$ (avec égalité si $\max_{x \in [a, b]} u(x) \geq 0$).

Démonstration Commençons par rappeler qu'une fonction u continue sur l'intervalle fermé borné $[a, b]$ est bornée et atteint ses bornes.⁽⁴⁾ Elle admet donc bien un maximum sur $[a, b]$.

① Intéressons-nous pour commencer au cas où $\gamma = 0$.

⊇ Supposons dans un premier temps que $\mathcal{L}u < 0$. Raisonnons par l'absurde et supposons que le maximum de u soit atteint en $x_0 \in]a, b[$. On a dans ce cas $u'(x_0) = 0$ et $u''(x_0) \leq 0$. Par conséquent,

$$\mathcal{L}u(x_0) = -\alpha(x_0)u''(x_0) - \alpha'(x_0)u'(x_0) + \beta(x_0)u'(x_0) = -\alpha(x_0)u''(x_0) \geq 0$$

car par hypothèse $\alpha(x_0) > 0$. Cela contredit l'hypothèse $\mathcal{L}u < 0$. Donc, pour le cas considéré, le maximum de u n'est pas atteint dans $]a, b[$. Il est par conséquent atteint en a ou en b et on a bien $\max_{x \in [a, b]} u(x) = \max\{u(a), u(b)\}$.

⊇ Supposons à présent que nous avons seulement $\mathcal{L}u \leq 0$ et tachons d'exploiter le résultat précédent. Considérons une fonction $\varphi \in \mathcal{C}^2([a, b])$ telle que $\varphi \geq 0$ sur $[a, b]$ et $\mathcal{L}\varphi < 0$ sur $]a, b[$. Une telle fonction existe bien ; par exemple la fonction $\varphi : x \in [a, b] \mapsto e^{\lambda x}$ où λ est choisi assez grand pour que $\max_{x \in [a, b]} \{\lambda^2 \alpha(x) - \lambda(\beta(x) - \alpha'(x))\} > 0$ convient⁽⁵⁾ puisque

$$\mathcal{L}\varphi(x) = \underbrace{-e^{\lambda x}}_{>0} \underbrace{(\lambda^2 \alpha - \lambda(\beta - \alpha'))}_{>0} < 0.$$

Pour tout $n \in \mathbb{N}^*$, considérons la fonction v_n de $\mathcal{C}^2([a, b])$ définie par $v_n = u + \frac{1}{n}\varphi$. On a

$$\mathcal{L}v_n = \underbrace{\mathcal{L}u}_{\leq 0} + \frac{1}{n} \underbrace{\mathcal{L}\varphi}_{< 0} < 0.$$

Par conséquent, en appliquant la première partie de la preuve à la fonction v_n , on en déduit que $\max_{x \in [a, b]} v_n(x) = \max\{v_n(a), v_n(b)\}$, i.e.

$$\max_{x \in [a, b]} \left(u(x) + \frac{1}{n}\varphi(x) \right) = \max \left\{ u(a) + \frac{1}{n}\varphi(a); u(b) + \frac{1}{n}\varphi(b) \right\}.$$

⁽⁴⁾. Voir par exemple [4, Théorème 13.4].

⁽⁵⁾. Cette condition est bien vérifiée puisque d'après les hypothèses du théorème, il existe $\alpha_0 \in \mathbb{R}_+^*$ tel que pour tout $x \in]a, b[$, $\alpha(x) \geq \alpha_0 > 0$.

Supposons par convenance que le maximum est atteint en a (un raisonnement similaire s'applique si le maximum est atteint en b). On a dans ce cas, pour tout $n \in \mathbb{N}^*$ et pour tout $x \in [a, b]$,

$$u(x) \leq u(x) + \frac{1}{n}\varphi(x) \leq u(a) + \frac{1}{n}\varphi(a).$$

En passant à la limite quand n tend vers $+\infty$ dans l'expression précédente, on obtient $u(x) \leq u(a)$. Comme $u(a) \leq \max\{u(a); u(b)\}$, on en déduit que, pour tout $x \in [a, b]$, on a $u(x) \leq \max\{u(a); u(b)\}$ et par conséquent que

$$\max_{x \in [a, b]} u(x) \leq \max\{u(a), u(b)\}.$$

Cela équivaut à dire que $\max_{x \in [a, b]} u(x) = \max\{u(a), u(b)\}$.

② Plaçons nous à présent dans le cas où $\gamma \geq 0$ (et $\gamma \neq 0$). Notons que si $u \leq 0$ alors il est immédiat que $\max_{x \in [a, b]} u(x) \leq 0$ et par conséquent que $\max_{x \in [a, b]} u(x) \leq \max\{u(a), u(b), 0\}$. Seul le cas où $u \geq 0$ avec $u \neq 0$ présente un intérêt. Il existe dans ce cas $x_0 \in]a, b[$ tel que $u(x_0) > 0$ et comme u est continue, u ne s'annule pas sur un voisinage de x_0 . Désignons par $[a_1, b_1]$ un sous-intervalle maximal où $u > 0$. Introduisons l'opérateur différentiel du second ordre $\mathcal{M}$ défini par

$$\mathcal{M} : u \in \mathcal{C}^2([a, b]) \longmapsto -(\alpha u')' + \beta u' \in \mathcal{C}^0([a, b]).$$

On a $\mathcal{M}u = \mathcal{L}u - \gamma u$. Comme $\gamma \geq 0$ et que sur $[a_1, b_1]$ on a $u > 0$, on en déduit que $\mathcal{M}u \leq 0$ sur $[a_1, b_1]$. Par conséquent, d'après la première partie de la preuve $\max_{x \in [a_1, b_1]} u(x) = \max\{u(a_1), u(b_1)\}$. Si a_1 et b_1 appartiennent tous les deux à $]a, b[$ alors $\max_{x \in [a_1, b_1]} u(x) = 0$. C'est en contradiction avec le fait que u est strictement positive sur $[a_1, b_1]$. On a donc nécessairement a_1 ou b_1 qui coïncident respectivement avec a ou b . Par conséquent, $\max_{x \in [a, b]} u(x) \leq \max\{u(a), u(b), 0\}$. $\square$

Remarque 1.4 On peut reformuler le résultat de la manière suivante : si f est une fonction négative et u_a et u_b sont des réels négatifs alors la solution u du problème (1.1)–(1.2) est telle que $u \leq 0$. Ainsi, si f représente une force s'exerçant sur une tige métallique fixée à ses deux extrémités ($u_a = u_b = 0$) alors la solution u va dans le sens où tire la force.

En remplaçant u par $-u$ dans le théorème 1.3, on obtient le résultat suivant.

COROLLAIRE 1.1 On suppose qu'il existe $\alpha_0 \in \mathbb{R}_+^*$ tel que $\alpha(x) \geq \alpha_0$ pour tout $x \in]a, b[$. Soit $u \in \mathcal{C}^2([a, b])$ tel que pour tout $x \in]a, b[$ on ait $\mathcal{L}u(x) \geq 0$. Sous ces hypothèses,

- si $\gamma = 0$ alors $\min_{x \in [a, b]} u(x) = \min\{u(a), u(b)\}$;
- si $\gamma \geq 0$ alors $\min_{x \in [a, b]} u(x) \leq \min\{u(a), u(b), 0\}$ (avec égalité si $\min_{x \in [a, b]} u(x) \leq 0$).

Cette propriété mathématique correspond à l'intuition physique qu'on peut avoir du phénomène de chauffage d'une barre évoqué dans la section précédente : si on chauffe le barreau tout en maintenant ses deux extrémités à une température fixe, la température aux points intérieurs du barreau sera supérieure à celle des extrémités.

Exemple 1.2 Considérons le problème : trouver $u \in \mathcal{C}^2([0, 1])$ tel que

$$(\mathcal{P}) \quad \begin{cases} -u''(x) + cu(x) = d & \forall x \in]-1, 1[\\ u(-1) = u(1) = 0 \end{cases}$$

où c et d sont deux constantes réelles. Seuls les cas où $c \geq 0$ et $d \leq 0$ correspondent aux hypothèses du principe du maximum donné au théorème 1.3.

— Si $c > 0$ alors le problème admet une unique solution qui a pour expression

$$u(x) = \frac{d}{c} \left(1 - \frac{\text{ch}(\sqrt{c}x)}{\text{ch}(\sqrt{c})} \right).$$

En étudiant sur $[-1, 1]$ cette fonction, on montre que

- Si $d < 0$ alors $\max_{x \in [-1, 1]} u(x) = u(1) = u(-1) = 0$. Le principe du maximum est bien satisfait comme attendu : $\max_{x \in [-1, 1]} u(x) = \max(u(1), u(-1), 0)$.
- Si $d = 0$ alors l'unique solution du problème $(\mathcal{P})$ est la solution nulle et le principe du maximum est bien satisfait comme attendu : $\max_{x \in [-1, 1]} u(x) = 0 = \max(u(1), u(-1), 0)$.
- Si $c = 0$ alors le problème $(\mathcal{P})$ admet une unique solution qui a pour expression $u(x) = \frac{d}{2}(1 - x^2)$. Dans le cas où $d < 0$, la fonction u est négative sur $[-1, 1]$ et atteint son maximum, qui vaut 0, en ± 1 . Le principe du maximum est bien satisfait comme attendu : $\max_{x \in [-1, 1]} u(x) = 0 = \max(u(1), u(-1))$. Dans le cas où $d = 0$, la fonction u est la fonction nulle et le principe du maximum est satisfait.
- Si $c < 0$ alors nous ne sommes plus dans un cas où les hypothèses du théorème 1.3 sont satisfaites. Dans le cas où $\sqrt{|c|} \notin \{\frac{\pi}{2}k ; k \in \mathbb{N}^*\}$, le problème $(\mathcal{P})$ admet une unique solution qui a pour expression

$$u(x) = \frac{d}{c} \left(1 - \frac{\cos(\sqrt{|c|}x)}{\cos(\sqrt{|c|})} \right).$$

(Dans le cas contraire, le problème $(\mathcal{P})$ admet soit aucune solution, soit une infinité de solutions.)
 Considérons le cas particulier où $c = -\frac{\pi^2}{16}$ et $d = -1$. La fonction u est strictement décroissante sur $[-1, 0]$ et strictement croissante sur $[0, 1]$ avec $u(-1) = u(1) = 0$ et $u(0) = -\frac{16}{\pi^2}(\sqrt{2} - 1) < 0$. On a donc $\max_{x \in [-1, 1]} u(x) = 0$ et $\max(u(-1), u(1), 0) = 0$. Ainsi, $\max_{x \in [-1, 1]} u(x) = \max(u(-1), u(1), 0) = 0$, autrement dit, dans ce cas particulier le principe du maximum est satisfait bien que les hypothèses du théorème 1.3 ne soient pas satisfaites. Ces hypothèses correspondent à des conditions suffisantes pour que le principe du maximum ait lieu mais pas à des conditions nécessaires.

L'énoncé du théorème 1.3 se généralise au cas d'un opérateur linéaire elliptique $\mathcal{L}$ du second ordre en dimension d défini sur un ouvert connexe $\Omega \subset \mathbb{R}^d$ non vide par

$$\forall u \in \mathcal{C}^2(\Omega) \quad \forall x \in \Omega \quad \mathcal{L}u(x) = - \sum_{i,j=1}^d \alpha_{i,j}(x) \frac{\partial^2 u}{\partial x_i \partial x_j}(x) + \sum_{i=1}^d \beta_i(x) \frac{\partial u}{\partial x_i}(x) + \gamma(x)u(x) \quad (1.17)$$

où $\alpha_{i,j}$, β_j , $i, j = 1, \dots, d$ et γ sont des fonctions bornées sur Ω et $A = (\alpha_{ij})_{i,j=1,\dots,d}$ est symétrique et uniformément définie positive, i.e.

$$\exists \lambda > 0 \quad \forall x \in \overline{\Omega} \quad \forall \zeta \in \mathbb{R}^d \quad \zeta^\top A \zeta \geq \lambda |\zeta|_{\mathbb{R}^d}.$$

Le principe du maximum prend la forme suivante.

THÉORÈME 1.4 (Principe du maximum en dimension supérieure)

Soit Ω est un ouvert connexe et borné de $\mathbb{R}^d$ et $u \in \mathcal{C}^2(\Omega) \cap \mathcal{C}^0(\overline{\Omega})$ telle que $\mathcal{L}u \leq 0$ dans Ω où $\mathcal{L}$ est défini en (1.17).

— Si $\gamma > 0$ alors u atteint son maximum dans $\overline{\Omega}$ sur la frontière $\partial\Omega$ de Ω :

$$\sup_{x \in \overline{\Omega}} u(x) = \sup_{x \in \partial\Omega} u(x).$$

— Si $\gamma \geq 0$ et si le maximum de u sur $\overline{\Omega}$ est positif, alors u atteint son maximum sur la frontière $\partial\Omega$ de Ω .

1.3.4 Dépendance continue de la solution du problème aux limites vis à vis des données

Nous allons à présent établir, en utilisant le principe du maximum, que la solution du problème aux limites (1.1)–(1.2) dépend continûment des données du problème.

Rappelons que pour une fonction u bornée sur $[a, b]$, on note $\|u\|_\infty = \sup_{x \in [a, b]} |u(x)|$ et cette quantité définit une norme⁽⁶⁾ sur l'espace vectoriel des applications bornées sur $[a, b]$. De plus, si u est continue sur $[a, b]$ alors u atteint ses bornes sur $[a, b]$, i.e. $\|u\|_\infty = \max_{x \in [a, b]} |u(x)|$.

THÉORÈME 1.5 *On suppose que :*

- $\alpha \in \mathcal{C}^1([a, b])$ et il existe $\alpha_0 \in \mathbb{R}_+^*$ tel que $\alpha(x) \geq \alpha_0$ pour tout $x \in [a, b]$;
- β et f sont des applications continues sur $[a, b]$;
- $\gamma \in \mathcal{C}^0([a, b])$ et $\gamma(x) \geq 0$ pour tout $x \in [a, b]$.

Pour toute solution $u \in \mathcal{C}^2([a, b])$ du problème aux limites

$$\begin{cases} -(\alpha(x) u'(x))' + \beta(x) u'(x) + \gamma(x) u(x) = f(x) & \forall x \in]a, b[\\ u(a) = u_a, \quad u(b) = u_b \end{cases}$$

il existe $C \in \mathbb{R}_+^$ tel que*

$$\|u\|_\infty \leq \max\{|u(a)|, |u(b)|\} + C \|f\|_\infty.$$

Démonstration On désigne comme précédemment par $\mathcal{L}$ l'opérateur différentiel du second ordre défini par

$$\mathcal{L} : u \in \mathcal{C}^2([a, b]) \mapsto -(\alpha u')' + \beta u' + \gamma u \in \mathcal{C}^0([a, b]).$$

Pour $\lambda > 0$, considérons la fonction $\varphi : x \in [a, b] \mapsto e^{\lambda(b-a)} - e^{\lambda(x-a)}$ de classe $\mathcal{C}^2$ sur $[a, b]$. Pour tout $x \in [a, b]$, on a $\varphi(x) \geq 0$ et

$$\mathcal{L}\varphi(x) = -(\alpha(x) \varphi'(x))' + \beta(x) \varphi'(x) + \gamma(x) \varphi(x) = \underbrace{\gamma(x) e^{\lambda(b-a)}}_{\geq 0} + p(x) \underbrace{e^{\lambda(x-a)}}_{\geq 1}$$

où p est la fonction

$$p(x) = \underbrace{\alpha(x)}_{\geq \alpha_0 > 0} \lambda^2 + (\alpha'(x) - \beta(x))\lambda - \gamma(x).$$

Comme $\alpha(x) \geq \alpha_0 > 0$, on en déduit qu'en choisissant λ suffisamment grand, on a $p(x) \geq 1$ pour tout $x \in [0, 1]$ et par conséquent $\mathcal{L}\varphi \geq 1$.

$\geq$ Considérons la fonction $v \in \mathcal{C}^2([a, b])$ définie par

$$\forall x \in [a, b] \quad v(x) = u(x) - \|\mathcal{L}u\|_\infty \varphi(x). \quad (1.18)$$

Cette fonction est telle que

$$\mathcal{L}v = \mathcal{L}u - \|\mathcal{L}u\|_\infty \underbrace{\mathcal{L}\varphi}_{\geq 1} \leq \mathcal{L}u - \|\mathcal{L}u\|_\infty \leq 0.$$

Donc, d'après le principe du maximum (voir le théorème 1.3), on a $\max_{x \in [a, b]} v(x) \leq \max\{v(a), v(b), 0\}$. Or, d'après (1.18), on a $v(x) \leq u(x)$ pour tout $x \in [a, b]$ donc

$$\max_{x \in [a, b]} v(x) \leq \max\{u(a), u(b), 0\} \leq \max\{|u(a)|, |u(b)|\}.$$

Par ailleurs, d'après (1.18),

$$\begin{aligned} \max_{x \in [a, b]} u(x) &= \max_{x \in [a, b]} (v(x) + \|\mathcal{L}u\|_\infty \varphi(x)) \leq \underbrace{\max_{x \in [a, b]} v(x)}_{\leq \max\{|u(a)|, |u(b)|\}} + \|\mathcal{L}u\|_\infty \underbrace{\max_{x \in [a, b]} \varphi(x)}_{\leq e^{\lambda(b-a)} - 1} \\ &\leq \max\{|u(a)|, |u(b)|\} + C \|\mathcal{L}u\|_\infty \end{aligned}$$

(6). Voir par exemple [3, Proposition 7.6].

où on a posé $C = e^{\lambda(b-a)} - 1 > 0$.

⊇ Considérons à présent la fonction $w \in \mathcal{C}^2([a, b])$ définie par

$$\forall x \in [a, b] \quad w(x) = -u(x) - \|\mathcal{L}u\|_\infty \varphi(x). \quad (1.19)$$

Cette fonction est telle que

$$\mathcal{L}w = -\mathcal{L}u - \|\mathcal{L}u\|_\infty \underbrace{\mathcal{L}\varphi}_{\geq 1} \leq -\mathcal{L}u - \|\mathcal{L}u\|_\infty \leq 0.$$

Donc, d'après le principe du maximum (voir le théorème 1.3), on a $\max_{x \in [a, b]} w(x) \leq \max\{w(a), w(b), 0\}$. Or, d'après (1.19), on a $w(x) \leq -u(x)$ pour tout $x \in [a, b]$, donc

$$\max_{x \in [a, b]} w(x) \leq \max\{-u(a), -u(b), 0\} \leq \max\{|u(a)|, |u(b)|\}.$$

Par ailleurs, d'après (1.19),

$$\begin{aligned} \max_{x \in [a, b]} -u(x) &= \max_{x \in [a, b]} (w(x) + \|\mathcal{L}u\|_\infty \varphi(x)) \leq \underbrace{\max_{x \in [a, b]} w(x)}_{\leq \max\{|u(a)|, |u(b)|\}} + \|\mathcal{L}u\|_\infty \underbrace{\max_{x \in [a, b]} \varphi(x)}_{\leq C = e^{\lambda(b-a)} - 1} \\ &\leq \max\{|u(a)|, |u(b)|\} + C \|\mathcal{L}u\|_\infty. \end{aligned}$$

⊇ Finalement, on en conclut que

$$\begin{aligned} \|u\|_\infty &= \sup_{x \in [a, b]} |u(x)| = \max_{x \in [a, b]} |u(x)| = \max\left\{ \max_{x \in [a, b]} u(x), \max_{x \in [a, b]} -u(x) \right\} \\ &\leq \max\{|u(a)|, |u(b)|\} + C \|f\|_\infty. \end{aligned}$$

Le théorème est démontré. $\square$

On peut interpréter le résultat du théorème 1.5 ainsi : si les valeurs des données aux limites u_a et u_b sont perturbées d'une quantité ε_1 et si la fonction f est perturbée d'une quantité ε_2 alors la solution du problème aux limites (1.1)–(1.2) subira une perturbation inférieure à $\varepsilon_1 + C\varepsilon_2$, autrement dit, la solution subira une perturbation du même ordre de grandeur que la perturbation des données.

1.3.5 Unicité de la solution au problème aux limites

Nous pouvons à présent compléter le théorème 1.2 en montrant que la solution de notre problème aux limites modèle ($\mathcal{P}$) est unique.

THÉORÈME 1.6 (Unicité de la solution)

On suppose que :

- $\alpha \in \mathcal{C}^1([a, b])$ et il existe $\alpha_0 \in \mathbb{R}_+^*$ tel que $\alpha(x) \geq \alpha_0$ pour tout $x \in [a, b]$;
- $\gamma \in \mathcal{C}^0([a, b])$ et $\gamma(x) \geq 0$ pour tout $x \in [a, b]$;
- β et f sont des applications continues sur $[a, b]$.

Sous ces hypothèses, la solution du problème : trouver une fonction $u \in \mathcal{C}^2([a, b])$ telle que

$$(\mathcal{P}) \quad \begin{cases} -(\alpha(x) u'(x))' + \beta(x) u'(x) + \gamma(x) u(x) = f(x) & \forall x \in]a, b[\\ u(a) = u_a, \quad u(b) = u_b \end{cases}$$

si elle existe, est unique.

Démonstration Supposons que le problème aux limites admette deux solutions u et v . Considérons la fonction $w = u - v \in \mathcal{C}^2([a, b])$. Elle est solution du problème aux limites

$$\begin{cases} -(\alpha(x) w'(x))' + \beta(x) w'(x) + \gamma(x) w(x) = 0 & \forall x \in]a, b[\\ w(a) = 0, & w(b) = 0. \end{cases}$$

D'après le théorème 1.5, la fonction w vérifie

$$\|w\|_\infty \leq \max\{|w(a)|, |w(b)|\} = 0.$$

Donc $\|w\|_\infty = 0$ et par conséquent w est la fonction nulle. Les deux fonctions u et v sont donc égales. La solution du problème aux limites, si elle existe, est donc unique. $\square$

Ainsi, sous les hypothèses du théorème 1.2 la solution du problème aux limites modèle $(\mathcal{P})$ existe et est unique.

Remarque 1.5 On peut montrer l'unicité de la solution du problème $(\mathcal{P})$ sans avoir recours au théorème 1.5 mais sous l'hypothèse supplémentaire : $\beta \in \mathcal{C}^1([a, b])$ est telle que $\beta'(x) \leq 2\gamma(x)$ pour tout $x \in [a, b]$. On reprend l'idée exploitée dans la preuve du théorème 1.2. Supposons que le problème $(\mathcal{P})$ admette deux solutions u et v et considérons la fonction $w = u - v$. On vérifie sans peine que $w \in \mathcal{C}^2([a, b])$ est solution du problème

$$(\mathcal{P}_0) \quad \begin{cases} -(\alpha(x) w'(x))' + \beta(x) w'(x) + \gamma(x) w(x) = 0 & \forall x \in]a, b[\\ w(a) = 0, & w(b) = 0 \end{cases}.$$

En multipliant chaque membre de l'équation différentielle par $w(x)$ et en intégrant sur $[a, b]$, on obtient

$$-\int_a^b (\alpha(x) w'(x))' w(x) \, dx + \int_a^b \beta(x) \underbrace{w(x) w'(x)}_{=\frac{1}{2}(w^2)'(x)} \, dx + \int_a^b \gamma(x) w^2(x) \, dx = 0.$$

Appliquons la formule d'intégration par parties aux deux premières intégrales. En tenant compte du fait que $w(a) = w(b) = 0$, on obtient

$$\int_a^b \alpha(x) (w'(x))^2 \, dx + \int_a^b (\gamma(x) - \frac{1}{2}\beta'(x)) w^2(x) \, dx = 0. \quad (1.20)$$

Compte tenu des hypothèses du théorème 1.6 et de l'hypothèse supplémentaire introduite en préambule, chacune des deux intégrales dans (1.20) est positive. Donc la relation (1.20) ne peut être satisfaite que si chacune des deux intégrales est nulle. En particulier, $\int_a^b \alpha(x) (w'(x))^2 \, dx = 0$ et comme $\alpha > 0$ sur $[a, b]$ cela implique que $w' = 0$ sur $[a, b]$. Donc w est une fonction continue, constante sur $[a, b]$. Cette fonction constante prend la valeur 0 en a et b . Il s'agit donc de la fonction nulle. On a donc $v = u$, ce qui signifie que la solution du problème $(\mathcal{P})$ est unique.

Remarque 1.6 Soit ρ la fonction de classe $\mathcal{C}^\infty$ sur $[a, b]$, strictement positive, définie par

$$\rho : x \in [a, b] \mapsto \exp\left(\frac{1}{2} \int_a^x \frac{\beta(t) - \alpha'(t)}{\alpha(t)} \, dt\right)$$

sous l'hypothèse des théorèmes précédents : $\alpha \in \mathcal{C}^1([a, b])$ et il existe $\alpha_0 \in \mathbb{R}_+^*$ tel que $\alpha(x) \geq \alpha_0$ pour tout $x \in [a, b]$. Désignons par u la solution du problème aux limites $(\mathcal{P})$ et considérons le changement d'inconnue $u = \rho v$. On a $u' = \rho' v + \rho v'$, $u'' = \rho'' v + 2\rho' v' + \rho v''$ et compte tenu de l'expression de la fonction ρ , on a $-2\alpha\rho' - \alpha\rho + \beta\rho = 0$. On établit ainsi que la nouvelle inconnue v est solution de l'équation différentielle

$$-\alpha(x) v''(x) + \tilde{\gamma}(x) v(x) = \tilde{f}(x) \quad \forall x \in]a, b[$$

où $\tilde{f} = \frac{f}{\rho}$ et $\tilde{\gamma} = \gamma + \frac{1}{4\alpha}(\beta - \alpha')(\beta + \alpha') - \frac{1}{2}(\beta - \alpha')'$.

L'inconnue v est donc solution d'un problème aux limites de la même forme que l'inconnue u mais sans dérivée d'ordre 1 dans l'équation différentielle.

1.4 Approximation par différences finies

1.4.1 Approximation d'une dérivée

Approximation d'une dérivée première

Considérons une fonction f de $\mathbb{R}$ dans $\mathbb{R}$ de classe $\mathcal{C}^1$ sur un intervalle ouvert $]a, b[$ de $\mathbb{R}$. En tout point x de $]a, b[$, la fonction f admet une dérivée $f'(x)$ telle que

$$f'(x) = \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h}. \quad (1.21)$$

On peut donc obtenir une valeur approchée de la dérivée de f en x en considérant, pour une valeur $h > 0$ « assez petite », la quantité

$$\delta^{[1p]}f(x) = \frac{f(x+h) - f(x)}{h}. \quad (1.22)$$

Remarquons que comme x appartient à $]a, b[$, qui est un intervalle ouvert, on est assuré que pour des valeurs de h suffisamment petites le point $x+h$ appartient lui aussi à $]a, b[$ et par conséquent que la quantité $f(x+h)$ est bien définie.

D'après la formule de Taylor-Young à l'ordre 1,

$$f(x+h) = f(x) + hf'(x) + \mathcal{O}(h^2). \quad (1.23)$$

On en déduit que

$$\delta^{[1p]}f(x) = f'(x) + \mathcal{O}(h). \quad (1.24)$$

L'erreur commise en approchant la dérivée de f en x par la quantité $\delta^{[1p]}f(x)$ définie par la relation (1.22) est donc comparable à h . On dit que la formule d'approximation (1.22) est précise à l'ordre 1. Cette formule d'approximation est qualifiée de *formule de différence finie progressive d'ordre 1*.

Bien entendu, d'après la formule (1.21), on a aussi⁽⁷⁾

$$f'(x) = \lim_{h \rightarrow 0} \frac{f(x) - f(x-h)}{h}. \quad (1.25)$$

Reprenant le raisonnement précédent, nous obtenons que la dérivée de f en x peut être approchée, avec une erreur elle aussi comparable à h , par la quantité

$$\delta^{[1r]}f(x) = \frac{f(x) - f(x-h)}{h} \quad (1.26)$$

pour $h > 0$ « assez petit ». Cette formule d'approximation est qualifiée de *formule de différence finie rétrograde d'ordre 1*.

Exercice 1.1 On suppose que l'application f est de classe $\mathcal{C}^2$ sur $[a, b]$. Montrer que la dérivée de f en x peut être approchée avec une erreur proportionnelle à h^2 par la quantité

$$\delta^{[1c]}f(x) = \frac{f(x+h) - f(x-h)}{2h}. \quad (1.27)$$

Cette formule d'approximation est qualifiée de *formule de différence finie centrée d'ordre 1* (de dérivation).

⁽⁷⁾. Par simple changement de variable dans la limite de h en $-h$.

Approximation d'une dérivée seconde

Considérons à présent une fonction f de $\mathbb{R}$ dans $\mathbb{R}$ de classe $\mathcal{C}^2$ sur un intervalle ouvert $]a, b[$ de $\mathbb{R}$. En utilisant la formule de différence finie rétrograde (1.26), nous pouvons approcher la dérivée seconde de f en $x \in]a, b[$ par

$$f''(x) \approx \frac{f'(x) - f'(x-h)}{h} \quad (1.28)$$

pour $h > 0$ assez petit. En approchant les dérivées premières $f'(x)$ et $f'(x-h)$ par une formule de différence finie progressive de la forme (1.22), nous obtenons l'approximation

$$f''(x) \approx \frac{1}{h} \left(\frac{f(x+h) - f(x)}{h} - \frac{f(x) - f(x-h)}{h} \right) = \frac{f(x+h) - 2f(x) + f(x-h)}{h^2}. \quad (1.29)$$

Reprenant les idées introduites pour l'approximation de la dérivée première de f , considérons cette fois-ci la formule de Taylor-Young à l'ordre 3 appliquée à f , que l'on suppose ici de classe $\mathcal{C}^3$, entre x et $x+h$. On a

$$f(x+h) = f(x) + h f'(x) + \frac{h^2}{2} f''(x) + \frac{h^3}{6} f'''(x) + \mathcal{O}_0(h^4). \quad (1.30)$$

De la même manière, la formule de Taylor-Young à l'ordre 3 appliquée à f entre $x-h$ et x indique que

$$f(x-h) = f(x) - h f'(x) + \frac{h^2}{2} f''(x) - \frac{h^3}{6} f'''(x) + \mathcal{O}_0(h^4). \quad (1.31)$$

En sommant les relations (1.30) et (1.31), on obtient

$$f(x+h) + f(x-h) = 2f(x) + h^2 f''(x) + \mathcal{O}_0(h^4). \quad (1.32)$$

On en déduit que la dérivée seconde de f en x peut être approchée avec une erreur comparable à h^2 par la quantité

$$\delta^{[2c]} f(x) = \frac{f(x+h) - 2f(x) + f(x-h)}{h^2}. \quad (1.33)$$

Cette formule d'approximation est qualifiée de formule de différence finie centrée d'ordre 2 (de dérivation et de précision).

Remarque 1.7 Pour établir la formule d'approximation (1.29) de la dérivée seconde, nous avons utilisé successivement une formule de différence finie rétrograde d'ordre 1 de dérivation pour obtenir (1.29) puis deux fois une formule de différence finie progressive d'ordre 1 de dérivation appliquée à $f'(x)$ et à $f'(x-h)$ pour obtenir (1.29). On pourra vérifier qu'en « inversant » l'ordre d'utilisation des formules rétrograde et progressive, on obtient également la formule (1.33) de différence finie centrée d'ordre 2.

Exercice 1.2 On suppose que l'application f est de classe $\mathcal{C}^4$ sur $]a, b[$. Montrer que la dérivée seconde de f en x peut être approchée avec une erreur comparable à h^4 par la quantité

$$\delta^{[2,4]} f(a) = \frac{-f(x+2h) + 16f(x+h) - 30f(x) + 16f(x-h) - f(x-2h)}{12h^2}. \quad (1.34)$$

1.4.2 Construction de l'approximation par différences finies

Considérons une subdivision uniforme $(x_j)_{j=0,\dots,J}$ de l'intervalle $[a, b]$ de pas $h = (b-a)/J$ constant. Nous allons chercher à déterminer une valeur approchée de la solution de l'équation (1.1) en chaque nœud x_j de la subdivision. On pourra remarquer que, compte tenu des conditions aux limites de Dirichlet (1.2), il n'est pas nécessaire d'effectuer un calcul pour les nœuds x_0 et x_J : les valeurs prises par la solution en ces nœuds sont connues.

Commençons par reformuler l'équation (1.1) sous la forme

$$-\alpha(x) u''(x) + \underbrace{(\beta(x) - \alpha'(x))}_{=\tilde{\beta}(x)} u'(x) + \gamma(x) u(x) = f(x) \quad \forall x \in]a, b[\quad (1.35)$$

où on pose $\tilde{\beta}(x) = \beta(x) - \alpha'(x)$ pour tout $x \in [a, b]$. Au nœud x_j , $j = 1, \dots, J-1$, nous considérons les approximations

$$\begin{aligned} u''(x_j) &\approx \delta^{[2c]} u(x_j) = \frac{u(x_j + h) - 2u(x_j) + u(x_j - h)}{h^2}, \\ u'(x_j) &\approx \delta^{[1c]} u(x_j) = \frac{u(x_j + h) - u(x_j - h)}{2h}. \end{aligned}$$

En désignant par u_j la valeur approchée de la solution u de l'équation (1.35) au nœud x_j , nous déduisons de (1.35) l'équation suivante, qualifiée d'*équation discrète* ou de *discrétisation* de l'équation (1.35) :

$$-\alpha(x_j) \frac{u_{j+1} - 2u_j + u_{j-1}}{h^2} + \tilde{\beta}(x_j) \frac{u_{j+1} - u_{j-1}}{2h} + \gamma(x_j) u_j = f(x_j) \quad \forall j = 1, \dots, J-1. \quad (1.36)$$

Nous déduisons par ailleurs des conditions aux limites (1.2), les conditions suivantes aux nœuds du bord :

$$u_0 = u_a \quad \text{et} \quad u_J = u_b. \quad (1.37)$$

En tenant compte de ces conditions aux limites, nous obtenons les équations discrètes suivantes :

— Pour $j = 1$

$$\left(2 \frac{\alpha(x_1)}{h^2} + \gamma(x_1)\right) u_1 + \left(-\frac{\alpha(x_1)}{h^2} + \frac{\tilde{\beta}(x_1)}{2h}\right) u_2 = f(x_1) + \left(\frac{\alpha(x_1)}{h^2} + \frac{\tilde{\beta}(x_1)}{2h}\right) u_a$$

où nous avons placé dans le second membre les termes correspondant à des données.

— Pour $j = 2, \dots, J-2$

$$\left(-\frac{\alpha(x_j)}{h^2} - \frac{\tilde{\beta}(x_j)}{2h}\right) u_{j-1} + \left(2 \frac{\alpha(x_j)}{h^2} + \gamma(x_j)\right) u_j + \left(-\frac{\alpha(x_j)}{h^2} + \frac{\tilde{\beta}(x_j)}{2h}\right) u_{j+1} = f(x_j)$$

— Pour $j = J-1$

$$\begin{aligned} \left(-\frac{\alpha(x_{J-1})}{h^2} - \frac{\tilde{\beta}(x_{J-1})}{2h}\right) u_{J-2} + \left(2 \frac{\alpha(x_{J-1})}{h^2} + \gamma(x_{J-1})\right) u_{J-1} &= f(x_{J-1}) \\ &+ \left(-\frac{\alpha(x_{J-1})}{h^2} + \frac{\tilde{\beta}(x_{J-1})}{2h}\right) u_b \end{aligned}$$

où nous avons placé dans le second membre les termes correspondant à des données.

Nous avons donc un système linéaire de $J-1$ équations avec $J-1$ inconnues qui sont $u_1, \dots, u_{J-1}$. Nous allons ré-écrire ce système linéaire sous forme matricielle.

Désignons par $\mathbf{U}$ le vecteur de $\mathbb{R}^{J-1}$ dont les composantes sont $u_1, \dots, u_{J-1}$. Compte tenu de (1.37), le système d'équations (1.36) se ré-écrit sous la forme du système linéaire

$$\mathbf{A} \mathbf{U} = \mathbf{F} \quad (1.38)$$

où $\mathbf{A}$ est la matrice tri-diagonale de $\mathcal{M}_{J-1}(\mathbb{R})$

$$\mathbf{A} = \begin{pmatrix} a_{1,1} & a_{1,2} & & & \\ a_{2,1} & a_{2,2} & a_{2,3} & & \\ & a_{3,2} & \ddots & \ddots & \\ & & \ddots & \ddots & a_{J-2,J-1} \\ & & & a_{J-1,J-2} & a_{J-1,J-1} \end{pmatrix} \quad (1.39)$$

où

$$\begin{aligned} a_{j,j} &= 2 \frac{\alpha(x_j)}{h^2} + \gamma(x_j) & \forall j \in \{1, \dots, J-1\}, \\ a_{j,j-1} &= -\frac{\alpha(x_j)}{h^2} - \frac{1}{2h} \tilde{\beta}(x_j) & \forall j \in \{2, \dots, J-1\}, \\ a_{j,j+1} &= -\frac{\alpha(x_j)}{h^2} + \frac{1}{2h} \tilde{\beta}(x_j) & \forall j \in \{1, \dots, J-2\}, \end{aligned}$$

les autres coefficients de la matrice étant nuls, et F est le vecteur de $\mathbb{R}^{J-1}$ dont les composantes sont

$$F = \begin{pmatrix} f(x_1) + \frac{\alpha(x_1)}{h^2} u_a + \frac{1}{2h} \tilde{\beta}(x_1) u_a \\ f(x_2) \\ \vdots \\ f(x_{J-2}) \\ f(x_{J-1}) + \frac{\alpha(x_{J-1})}{h^2} u_b - \frac{1}{2h} \tilde{\beta}(x_{J-1}) u_b \end{pmatrix}. \quad (1.40)$$

Un inconvénient du schéma qui vient d'être proposé est qu'il nécessite de connaître l'expression de $\tilde{\beta}$ en chaque nœud de la subdivision, ce qui implique de connaître l'expression de α' . On peut construire un schéma alternatif qui ne nécessite pas de connaître l'expression de α' .

1.4.3 Existence et unicité d'une solution au problème discret

Se pose bien entendu la question de savoir si le système linéaire (1.38) admet une unique solution. Dans le cas contraire, l'approche utilisée pour construire le schéma numérique (1.36) – (1.37) permettant de calculer une solution approchée du problème aux limites (1.1)–(1.2) est sans utilité. Comme on peut s'y attendre, l'existence d'une unique solution au système linéaire (1.38) dépend des propriétés des fonctions α , β et γ qui interviennent dans la définition de la matrice A . Afin d'énoncer un résultat donnant une condition suffisante d'existence d'une unique solution au système linéaire (1.38), introduisons quelques résultats d'algèbre linéaire.

DÉFINITION 1.1 (Matrice à diagonale dominante)

Une matrice carrée $A = (a_{i,j})_{i,j \in \{1, \dots, n\}}$ de $\mathcal{M}_n(\mathbb{K})$ est dite à diagonale dominante lorsque le module de chaque terme diagonal est supérieur ou égal à la somme des modules des autres termes de sa ligne, i.e. si

$$\forall i \in \{1, \dots, n\} \quad |a_{i,i}| \geq \sum_{\substack{j=1 \\ j \neq i}}^n |a_{i,j}|.$$

De la même manière, A est dite à diagonale strictement dominante lorsque

$$\forall i \in \{1, \dots, n\} \quad |a_{i,i}| > \sum_{\substack{j=1 \\ j \neq i}}^n |a_{i,j}|.$$

Enfin, si A est à diagonale dominante et si

$$\exists i_0 \in \{1, \dots, n\} \quad |a_{i_0, i_0}| > \sum_{\substack{j=1 \\ j \neq i_0}}^n |a_{i_0, j}|$$

alors A est dite à diagonale fortement dominante.

Bien entendu, toute matrice à diagonale strictement dominante est une matrice à diagonale fortement dominante.

PROPOSITION 1.2 On suppose que pour tout $j \in \{1, \dots, J-1\}$ on a $\alpha(x_j) > 0$ et $\alpha(x_j) \pm \frac{h}{2} \tilde{\beta}(x_j) > 0$.

✕ Si pour tout $j \in \{1, \dots, J-1\}$ on a $\gamma(x_j) \geq 0$, alors la matrice A définie en (1.39) est à diagonale fortement dominante.

✕ Si pour tout $j \in \{1, \dots, J-1\}$ on a $\gamma(x_j) > 0$, alors la matrice A définie en (1.39) est à diagonale strictement dominante.

Démonstration Pour $i \in \{2, \dots, J-2\}$, on a

$$\sum_{\substack{j=1 \\ j \neq i}}^{J-1} |a_{i,j}| = |a_{i,i-1}| + |a_{i,i+1}| = \frac{1}{h^2} \left| -\alpha(x_i) - \frac{1}{2}h\tilde{\beta}(x_i) \right| + \frac{1}{h^2} \left| -\alpha(x_i) + \frac{1}{2}h\tilde{\beta}(x_i) \right|.$$

D'après les hypothèses sur le signe de ces quantités, on a

$$\sum_{\substack{j=1 \\ j \neq i}}^{J-1} |a_{i,j}| = \frac{1}{h^2} \left(\alpha(x_i) + \frac{1}{2}h\tilde{\beta}(x_i) \right) + \frac{1}{h^2} \left(\alpha(x_i) - \frac{1}{2}h\tilde{\beta}(x_i) \right) = \frac{2}{h^2} \alpha(x_i).$$

Par ailleurs, comme $\alpha(x_j) \geq 0$ et $\gamma(x_j) \geq 0$ pour tout $j \in \{1, \dots, J-1\}$, on a

$$|a_{i,i}| = \left| \frac{2}{h^2} \alpha(x_i) + \gamma(x_i) \right| = \frac{2}{h^2} \alpha(x_i) + \gamma(x_i) \geq \frac{2}{h^2} \alpha(x_i).$$

Notons que sous l'hypothèse $\gamma(x_j) > 0$ pour tout $j \in \{1, \dots, J-1\}$, l'inégalité devient stricte : $|a_{i,i}| > \frac{2}{h^2} \alpha(x_i)$. On en déduit que pour tout $i \in \{2, \dots, J-2\}$, on a

$$\begin{aligned} & \text{— sous l'hypothèse } \gamma(x_j) \geq 0 \text{ pour tout } j \in \{1, \dots, J-1\} : |a_{i,i}| \geq \sum_{\substack{j=1 \\ j \neq i}}^{J-1} |a_{i,j}|; \\ & \text{— sous l'hypothèse } \gamma(x_j) > 0 \text{ pour tout } j \in \{1, \dots, J-1\} : |a_{i,i}| > \sum_{\substack{j=1 \\ j \neq i}}^{J-1} |a_{i,j}|. \end{aligned}$$

Reste à considérer le cas $i = 1$ et le cas $i = J-1$.

Comme $\alpha(x_1) \pm \frac{h}{2}\tilde{\beta}(x_1) > 0$ et $\alpha(x_{J-1}) \pm \frac{h}{2}\tilde{\beta}(x_{J-1}) > 0$, on a

$$\begin{aligned} \sum_{j=2}^{J-1} |a_{1,j}| &= \frac{1}{h^2} \left| -\alpha(x_1) + \frac{1}{2}h\tilde{\beta}(x_1) \right| = \frac{1}{h^2} \left(\alpha(x_1) - \frac{1}{2}h\tilde{\beta}(x_1) \right) < \frac{2}{h^2} \alpha(x_1) \leq |a_{1,1}|, \\ \sum_{j=1}^{J-2} |a_{J-1,j}| &= \frac{1}{h^2} \left| -\alpha(x_{J-1}) - \frac{1}{2}h\tilde{\beta}(x_{J-1}) \right| = \frac{1}{h^2} \left(\alpha(x_{J-1}) + \frac{1}{2}h\tilde{\beta}(x_{J-1}) \right) \\ &< \frac{2}{h^2} \alpha(x_{J-1}) \leq |a_{J-1,J-1}|. \end{aligned}$$

Les deux résultats énoncés dans la proposition sont démontrés. $\square$

Remarque 1.8 La condition $\alpha(x_j) \pm \frac{h}{2}\tilde{\beta}(x_j) > 0$ pour tout $j \in \{1, \dots, J-1\}$ est assez peu contraignante d'un point de vue pratique car sous l'hypothèse où α est une fonction strictement positive sur $[a, b]$, cette condition est réalisée dès que le pas h de la subdivision de $[a, b]$ est pris assez petit.

THÉORÈME 1.7 (Lemme de Hadamard)

Une matrice à diagonale strictement dominante est inversible.

Démonstration Soit $A = (a_{i,j})_{i,j \in \{1, \dots, n\}}$ une matrice carrée de $\mathcal{M}_n(\mathbb{K})$ à diagonale strictement dominante. Elle sera inversible si, et seulement si, son noyau est réduit au vecteur nul.⁽⁸⁾ Considérons un vecteur X appartenant au noyau de A , i.e. tel que $AX = 0$ et montrons que X est égal au vecteur nul. Pour cela raisonnons par l'absurde. Désignons par $x_1, \dots, x_n$ les composantes du vecteur X ; on a

$$\forall i \in \{1, \dots, n\} \quad \sum_{j=1}^n a_{i,j} x_j = 0.$$

(8). Voir [4], chap. 10.

Soit $i_0 \in \{1, \dots, n\}$ tel que $|x_{i_0}| = \max \{|x_i|, i \in \{1, \dots, n\}\}$. Comme X est supposé non nul, nécessairement $|x_{i_0}| > 0$.

$$\text{On a } -a_{i_0, i_0} x_{i_0} = \sum_{\substack{j=1 \\ j \neq i_0}}^n a_{i_0, j} x_j, \text{ d'où } |a_{i_0, i_0}| |x_{i_0}| \leq \sum_{\substack{j=1 \\ j \neq i_0}}^n |a_{i_0, j} x_j| \leq \sum_{\substack{j=1 \\ j \neq i_0}}^n |a_{i_0, j}| |x_{i_0}|.$$

Comme $|x_{i_0}| \neq 0$, on en déduit que

$$|a_{i_0, i_0}| \leq \sum_{\substack{j=1 \\ j \neq i_0}}^n |a_{i_0, j}|.$$

Cette inégalité contredit l'hypothèse selon laquelle A est une matrice à diagonale strictement dominante. On en conclut donc que $X = 0$ et par voie de conséquence que la matrice A est inversible. $\square$

Remarque 1.9 Une matrice à diagonale dominante n'est pas nécessairement inversible. Par exemple, la matrice nulle est à diagonale dominante mais elle n'est pas inversible. De même, une matrice à diagonale fortement dominante n'est pas nécessairement inversible. La matrice $A = \begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix}$ est à diagonale fortement dominante sans être inversible. Nous avons toutefois un résultat d'inversibilité d'une matrice à diagonale fortement dominante moyennant une hypothèse supplémentaire sur la matrice, ce qui fait l'objet des résultats qui suivent.

DÉFINITION 1.2 (Matrice irréductible)

✕ Une matrice carrée $A = (a_{i,j})_{i,j \in \{1, \dots, n\}}$ de $\mathcal{M}_n(\mathbb{K})$ est dite *réductible* s'il existe une partition de $\{1, \dots, n\}$ en deux parties non vides $\mathcal{I}$ et $\mathcal{J}$ (non vides) tel que $\forall i \in \mathcal{I} \forall j \in \mathcal{J} a_{i,j} = 0$.

✕ Une matrice qui n'est pas réductible est dite *irréductible*.

Remarque 1.10 Il résulte de la définition 1.2 qu'une matrice $A = (a_{i,j})_{i,j \in \{1, \dots, n\}}$ de $\mathcal{M}_n(\mathbb{K})$ est irréductible si pour toute partition de l'ensemble $\{1, \dots, n\}$ en deux sous-ensembles non vides $\mathcal{I}$ et $\mathcal{J}$, on a

$$\exists i \in \mathcal{I} \quad \exists j \in \mathcal{J} \quad a_{i,j} \neq 0.$$

(Considérer la négation de l'assertion définissant une matrice réductible.)

Exemples 1.3

1. La matrice tridiagonale

$$A = \begin{pmatrix} 2 & -1 & & & \\ -1 & 2 & -1 & & \\ & \ddots & \ddots & \ddots & \\ & & -1 & 2 & -1 \\ & & & -1 & 2 \end{pmatrix}$$

est irréductible.

Pour l'établir, raisonnons par l'absurde et supposons la matrice A réductible. Considérons une partition de l'ensemble $\{1, \dots, n\}$ en deux sous-ensembles non vides $\mathcal{I}$ et $\mathcal{J}$. Soit $i_0 \in \mathcal{I}$. On a $a_{i_0, i_0+1} = a_{i_0, i_0-1} = 2 \neq 0$, donc nécessairement i_0+1 et i_0-1 ne peuvent pas appartenir à $\mathcal{J}$. En reproduisant le raisonnement avec i_0+1 puis avec i_0-1 , on établit que i_0+2 et i_0-2 ne peuvent pas non plus appartenir à $\mathcal{J}$. En poursuivant ce raisonnement de proche en proche, on montre que $\mathcal{J}$ est l'ensemble vide car $\mathcal{I} = \{1, \dots, n\}$. Cela contredit le fait que $\mathcal{J}$ est supposé non vide.

Plus généralement, on montre que toute matrice tridiagonale dont aucun des termes sur la sur-diagonale et sur la sous-diagonale n'est nul est irréductible.

2. Une matrice triangulaire (inférieure ou supérieure) de $\mathcal{M}_n(\mathbb{K})$ est réductible : prendre $\mathcal{I} = \{1\}$ et $\mathcal{J} = \{2, \dots, n\}$ dans le cas d'une matrice triangulaire inférieure et prendre $\mathcal{I} = \{n\}$ et $\mathcal{J} = \{1, \dots, n-1\}$ dans le cas d'une matrice triangulaire supérieure.

3. La matrice

$$A = \begin{pmatrix} 2 & -1 & 0 & 0 & 0 \\ -1 & 2 & 0 & 0 & 0 \\ 0 & -1 & 2 & -1 & 0 \\ 0 & 0 & -1 & 2 & -1 \\ 0 & 0 & 0 & -1 & 2 \end{pmatrix}$$

est réductible. En effet, en posant $\mathcal{I} = \{1, 2\}$ et $\mathcal{J} = \{3, 4, 5\}$, on a $a_{i,j} = 0$ pour tout $i \in \mathcal{I}$ et pour tout $j \in \mathcal{J}$.

Nous avons la caractérisation suivante des matrices réductibles (voir par ex. [10, T.1 p. 33]).

LEMME 1.1 Une matrice A de $\mathcal{M}_n(\mathbb{K})$ est réductible si, et seulement si, il existe une matrice de permutation S telle que ${}^tSAS = S^{-1}AS$ soit de la forme $\begin{pmatrix} B & 0 \\ D & C \end{pmatrix}$ où B et C sont des matrices carrées de dimension non nulle.

Remarque 1.11 Dans le lemme 1.1, la condition essentielle est que les matrices B et C soient carrées.

Précisons ce que l'on entend par matrice de permutation.

Matrice de permutation

Rappelons ⁽⁹⁾ qu'étant donné un entier naturel non nul n , on appelle *permutation* de $\{1, 2, \dots, n\}$ toute application bijective de l'ensemble $\{1, 2, \dots, n\}$ dans lui-même.

DÉFINITION 1.3 (Matrice de permutation)

On appelle matrice de permutation une matrice carrée qui vérifie les propriétés suivantes :

- les coefficients valent 0 ou 1 ;
- il y a un et un seul 1 par ligne ;
- il y a un et un seul 1 par colonne.

L'ensemble des matrices de permutation de taille n est en bijection avec l'ensemble $\mathfrak{S}_n$ des permutations de l'ensemble $\{1, 2, \dots, n\}$. Si σ est une permutation de l'ensemble $\{1, 2, \dots, n\}$, la matrice de permutation correspondante est la matrice P de terme général

$$p_{ij} = \delta_{i, \sigma(j)} = \begin{cases} 1 & \text{si } i = \sigma(j) \\ 0 & \text{sinon} \end{cases}$$

Exemple 1.4 Considérons la permutation σ de l'ensemble $\{1, 2, 3, 4\}$ qui à 1 associe 4, à 2 associe 3, à 3 associe 1 et à 4 associe 2 ; on la note symboliquement

$$\sigma = \begin{bmatrix} 1 & 2 & 3 & 4 \\ 4 & 3 & 1 & 2 \end{bmatrix}.$$

La matrice de permutation qui lui est associée est

$$P = \begin{pmatrix} 0 & 0 & 0 & 1 \\ 0 & 0 & 1 & 0 \\ 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \end{pmatrix}$$

⁽⁹⁾. Voir [4], définition 2.23 du chap. 2.

Rappelons que la permutation ⁽⁹⁾ $\tau_{i,j}$, où i, j désignent deux entiers naturels distincts compris entre 1 et n , définie par

$$\tau_{i,j}(i) = j, \quad \tau_{i,j}(j) = i \quad \text{et} \quad \tau_{i,j}(k) = k \quad \text{si} \quad k \in \{1, 2, \dots, n\} \setminus \{i, j\}$$

est une permutation particulière appelée *transposition*. La matrice de permutation associée à la transposition $\tau_{i,j}$ est

$$P_{[i,j]} = \begin{pmatrix} & & & & \\ & \ddots & & & \\ & & 0 & 1 & \\ & & & \ddots & \\ & 1 & & 0 & \\ & & & & \ddots \end{pmatrix} \begin{array}{l} \leftarrow \text{ ligne } i \\ \leftarrow \text{ ligne } j \end{array}$$

colonne $i \uparrow$ $\uparrow$ colonne j

où tous les éléments non figurés de la diagonale de la matrice valent 1 et où tous les autres éléments non figurés de la matrice valent 0. On parle de matrice de *permutation élémentaire*.

De même que toute permutation peut s'écrire comme un produit de transpositions, ⁽¹⁰⁾ toute matrice de permutation peut s'écrire comme un produit de matrices de permutations élémentaires.

PROPOSITION 1.3 (Propriétés des matrices de permutation)

Une matrice est permutation est une matrice orthogonale. ⁽¹¹⁾ En particulier,

✕ l'inverse d'une matrice de permutation est égale à la transposée de la matrice ;

✕ le déterminant d'une matrice de permutation est +1 ou -1.

Démonstration Compte tenu de la forme très simple d'une matrice de permutation, il est aisé d'établir par un calcul que si P est une matrice de permutation alors $P P^\top = I$ et par conséquent que la matrice P est orthogonale. On déduit de la relation $P P^\top = I$ et des propriétés des déterminants ⁽¹²⁾ que

$$1 = \det(I) = \det(P P^\top) = \det(P) \det(P^\top) = \det(P)^2.$$

La relation $\det(P)^2 = 1$ implique que le déterminant d'une matrice de permutation est +1 ou -1. Comme ce déterminant est non nul, la matrice P est inversible et la relation $P P^\top = I$, compte tenu de l'unicité de l'inverse d'une matrice inversible, implique que $P^{-1} = P^\top$. $\square$

Les matrices de permutation jouent un rôle particulier en analyse matricielle. En effet, multiplier à gauche (respectivement à droite) une matrice A par une matrice de permutation élémentaire $P_{[i,j]}$ revient à faire l'échange de deux lignes (resp. deux colonnes) i et j de la matrice A . Plus généralement, multiplier à droite une matrice A par une matrice de permutation P revient à permuer les colonnes de la matrice A , en suivant la permutation correspondant à la matrice P . Multiplier à gauche une matrice A par une matrice de permutation P revient à permuer les lignes de la matrice A , en suivant la permutation inverse de celle définie par P .

Illustrons ces propriétés sur un exemple avec MATLAB. On définit la matrice P de $\mathcal{M}_5(\mathbb{R})$ associée à la transposition τ_{24} de l'ensemble $\{1, 2, 3, 4, 5\}$. On échange les colonnes 2 et 4, puis les lignes 2 et 4, de la matrice A correspondant au carré magique d'ordre 5.

⁽¹⁰⁾. Voir le *Cours de mathématiques de première année* [?], section 2.2.4 du chap. 2.

⁽¹¹⁾. Voir la définition 8.19 du *Cours de mathématiques de deuxième année* [?].

⁽¹²⁾. Voir le chp. 6 du *Cours de mathématiques de première année* [?].

```

>> P=eye(5):
>> P(2,4)=1: P(4,2)=1: P(2,2)=0: P(4,4)=0;
P =
    1     0     0     0     0
    0     0     0     1     0
    0     0     1     0     0
    0     1     0     0     0
    0     0     0     0     1
>> A=magic(5)
A =
    17    24     1     8    15
    23     5     7    14    16
     4     6    13    20    22
    10    12    19    21     3
    11    18    25     2     9

>> A*P % permutation des colonnes 2 et 4
ans =
    17     8     1    24    15
    23    14     7     5    16
     4    20    13     6    22
    10    21    19    12     3
    11     2    25    18     9

>> P*A % permutation des lignes 2 et 4
ans =
    17    24     1     8    15
    10    12    19    21     3
     4     6    13    20    22
    23     5     7    14    16
    11    18    25     2     9

```

Nous admettons le résultat suivant, dont on trouvera une preuve dans [10, T.1 p. 61].

THÉORÈME 1.8 *Une matrice à diagonale fortement dominante et irréductible est inversible.*

Exemple 1.5 Considérons la matrice tridiagonale de $\mathcal{M}_{J-1}(\mathbb{R})$

$$A = \begin{pmatrix} 2 & -1 & & & \\ -1 & 2 & -1 & & \\ & \ddots & \ddots & \ddots & \\ & & -1 & 2 & -1 \\ & & & -1 & 2 \end{pmatrix}$$

qui au facteur $1/h^2$ près est la matrice de la discrétisation par différences finies du problème modèle donnée en (1.39) pour des données qui sont $\alpha = 1$, $\beta = \gamma = 0$. Montrons que cette matrice est définie positive. Notons que cette matrice est une matrice à diagonale fortement dominante et irréductible. D'après le lemme de Hadamard, elle est donc inversible.

Pour montrer que la matrice A est définie positive, nous allons établir que toutes ses valeurs propres sont des réels strictement positifs. Raisonnons par l'absurde et supposons que cette matrice admette une valeur propre λ strictement négative (la matrice étant symétrique, ses valeurs propres sont toutes réelles et comme elle est inversible, 0 n'est pas valeur propre). Dans ce cas, un vecteur propre associé à cette valeur propre est un vecteur $X \in \mathbb{R}^{J-1}$ *non nul* tel que $AX = \lambda X$, autrement dit tel que $(A - \lambda I)X = 0$. Or, λ étant strictement négatif, $\lambda = -|\lambda|$ et la matrice $M = A - \lambda I$ a pour expression

$$M = \begin{pmatrix} 2+|\lambda| & -1 & & & \\ -1 & 2+|\lambda| & -1 & & \\ & \ddots & \ddots & \ddots & \\ & & -1 & 2+|\lambda| & -1 \\ & & & -1 & 2+|\lambda| \end{pmatrix}.$$

Comme $\lambda \neq 0$, cette matrice est à diagonale strictement dominante. Elle est donc inversible. Donc, le système linéaire $AX = \lambda X$ admet une unique solution. Cette solution est $X = 0$. Cela contredit le fait que X est un vecteur propre de A , donc que $X \neq 0$.

Nous sommes à présent en mesure d'établir l'existence et l'unicité de la solution au problème discret formé par les équations (1.36) – (1.37).

PROPOSITION 1.4 (Existence et unicité de la solution au problème discret)

On suppose que pour tout $j \in \{1, \dots, J-1\}$ on a

$$-\alpha(x_j) > 0 \text{ et } \gamma(x_j) \geq 0;$$

$$-\alpha(x_j) \pm \frac{h}{2}\beta(x_j) > 0.$$

Sous ces hypothèses, le système linéaire (1.38) admet une unique solution.

Démonstration Nous avons établi à la proposition 1.2 que, sous les hypothèses de la proposition 1.4, la matrice A est à diagonale fortement dominante. D'après le théorème 1.8, si la matrice A est irréductible alors elle est inversible et par conséquent le système linéaire (1.38) est un système de Cramer possédant une unique solution.

La seconde des hypothèses mentionnées ci-dessus assure que les termes de la matrice A appartenant à la sur-diagonale et à la sous-diagonale sont non nuls. La matrice A n'est donc pas réductible. $\square$

Remarque 1.12 Si la fonction α est strictement positive sur $[a, b]$ alors pour un pas de subdivision h suffisamment petit, la seconde condition de la proposition 1.4 est automatiquement satisfaite.

Cas particulière d'une équation différentielle à coefficients constants

Dans le cas où les coefficients α, β et γ de l'équation différentielle du problème modèle sont des fonctions constantes, le schéma d'approximation par différences finies étudié s'écrit matriciellement sous la forme $AU = F$ où

$$A = \frac{\alpha}{h^2} A_1 + \frac{\beta}{2h} A_2 + \gamma I$$

avec A_1 et A_2 les matrices de $\mathcal{M}_{J-1}(\mathbb{R})$ définies par

$$A_1 = \begin{pmatrix} 2 & -1 & 0 & \cdots & \cdots & 0 \\ -1 & 2 & -1 & \ddots & & \vdots \\ 0 & -1 & \ddots & \ddots & \ddots & \vdots \\ \vdots & \ddots & \ddots & \ddots & -1 & 0 \\ \vdots & & \ddots & -1 & 2 & -1 \\ 0 & \cdots & \cdots & 0 & -1 & 2 \end{pmatrix} \quad \text{et} \quad A_2 = \begin{pmatrix} 0 & 1 & 0 & \cdots & \cdots & 0 \\ -1 & 0 & 1 & \ddots & & \vdots \\ 0 & -1 & \ddots & \ddots & \ddots & \vdots \\ \vdots & \ddots & \ddots & \ddots & 1 & 0 \\ \vdots & & \ddots & -1 & 0 & 1 \\ 0 & \cdots & \cdots & 0 & -1 & 0 \end{pmatrix}.$$

Nous avons vu que la matrice A_1 est une matrice symétrique et définie positive.

Montrons à présent que pour tout $X \in \mathbb{R}^{J-1}$ on a $X^\top A_2 X = 0$. En désignant par $x_1, \dots, x_{J-1}$ les composantes du vecteur X de $\mathbb{R}^{J-1}$, on a $\langle A_2 X, X \rangle = X^\top A_2 X = \sum_{k=1}^{J-1} x_k (A_2 X)_k$ où $(A_2 X)_k$ désigne la k -ième composante du vecteur $A_2 X$. Par ailleurs, pour $k = 2, \dots, J-2$, on a

$$(A_2 X)_k = \sum_{\ell=1}^{J-1} a_{k\ell} x_\ell = -x_{k-1} + x_{k+1}$$

et $(A_2 X)_1 = x_2$, $(A_2 X)_{J-1} = -x_{J-2}$. Ainsi,

$$\begin{aligned} \langle A_2 X, X \rangle &= x_2 x_1 + \sum_{k=2}^{J-2} (-x_{k-1} + x_{k+1}) x_k - x_{J-2} x_{J-1} \\ &= x_1 x_2 - x_{J-2} x_{J-1} - \sum_{k=2}^{J-2} x_{k-1} x_k + \sum_{k=2}^{J-2} x_{k+1} x_k \\ &= x_1 x_2 - x_{J-2} x_{J-1} - \sum_{k=2}^{J-2} x_{k-1} x_k + \sum_{k=3}^{J-1} x_k x_{k-1} \\ &= 0. \end{aligned}$$

Cela permet d'en conclure que, sous les hypothèses de positivité des coefficients α, β et γ , la matrice A est symétrique définie positive.

Par conséquent, le système linéaire $AU = F$ peut être résolu efficacement en exploitant la structure tridiagonale de la matrice. En effet, une matrice tridiagonale symétrique définie positive $A \in \mathcal{M}_{J-1}(\mathbb{K})$, de terme générique $a_{i,j}$, $(i,j) \in \{1, \dots, J-1\}^2$ avec $a_{i,j} = 0$ pour tous (i,j) tel que $|i-j| > 1$, admet une décomposition⁽¹³⁾ $LDL^\top$ avec

$$L = \begin{pmatrix} 1 & & & & \\ \ell_1 & 1 & & & \\ & \ell_2 & 1 & & \\ & & \ddots & \ddots & \\ & & & \ell_{N-2} & 1 \end{pmatrix} \quad \text{et} \quad D = \begin{pmatrix} d_1 & & & & \\ & d_2 & & & \\ & & d_3 & & \\ & & & \ddots & \\ & & & & d_{N-1} \end{pmatrix}$$

où les coefficients des matrices L et D sont donnés par

$$\begin{cases} d_1 &= a_{1,1} \\ d_i &= a_{i,i} - \ell_{i-1}^2 d_{i-1} & \text{pour } i = 2, \dots, N-1 \\ \ell_i &= a_{i,i+1}/d_i & \text{pour } i = 1, \dots, N-2 \end{cases}.$$

Résoudre le système linéaire $AU = F$ revient à résoudre successivement les deux systèmes linéaires triangulaires « creux » $LV = F$ puis $L^\top U = D^{-1}V$. La solution de chacun de ces deux systèmes linéaires peut être facilement explicitée.

1.4.4 Dépendance continue de la solution du problème discret vis à vis des données

Commençons par quelques compléments d'algèbre matriciel.

DÉFINITION 1.4 (Matrice monotone)

Une matrice A de $\mathcal{M}_n(\mathbb{R})$ est dite monotone si A est inversible et si A^{-1} est positive (i.e. tous ses coefficients sont des réels positifs).

Un vecteur $X \in \mathbb{R}^n$ est dit positif (on note $X \geq 0$) si toutes ses composantes sont des réels positifs. On a la caractérisation suivante d'une matrice monotone.

PROPOSITION 1.5 Une matrice A de $\mathcal{M}_n(\mathbb{R})$ est monotone si, et seulement si, pour tout $X \in \mathbb{R}^n$, on a

$$AX \geq 0 \implies X \geq 0.$$

Démonstration ✕ Supposons que la matrice A soit monotone. Elle est donc inversible et A^{-1} est positive. Ses éléments, notés $\alpha_{i,j}$, $i, j \in \{1, \dots, n\}$, sont des réels positifs. Pour tout $X \in \mathbb{R}^n$ on a $X = A^{-1}(AX)$. Si $Y = AX \geq 0$ alors la i -ième composante du vecteur X qui est donnée par

$$x_i = \sum_{j=1}^n \underbrace{\alpha_{i,j}}_{\geq 0} \underbrace{y_j}_{\geq 0}$$

est une somme de réels positifs. C'est donc un réel positif. Par conséquent, $X \geq 0$.

✕ Supposons à présent que, pour tout $X \in \mathbb{R}^n$, on ait la propriété : $AX \geq 0 \implies X \geq 0$ et montrons que A est monotone.

⁽¹³⁾. Cette décomposition est apparentée à la décomposition de Choleski. Du point de vue du calcul numérique, on préfère cette décomposition à la décomposition de Choleski $LL^\top$ car elle évite l'extraction de racines carrées pour le calcul des coefficients de la matrice L .

Vérifions tout d'abord que A est inversible en montrant que son noyau $\ker(A)$ est réduit au seul vecteur nul.⁽¹⁴⁾ Soit X un vecteur de $\ker(A)$. On a $A X = 0$, donc $A X \geq 0$ ce qui implique, d'après notre hypothèse, que $X \geq 0$. Mais $A X = 0$ implique aussi que $A X \leq 0$, ce que l'on peut encore écrire $A(-X) \geq 0$. On a donc aussi $-X \geq 0$, i.e. $X \leq 0$. Cela laisse pour seule possibilité $X = 0$. Ainsi, le noyau de A ne contient que le vecteur nul.

Reste à vérifier que A^{-1} est positive. Notons $\alpha_{i,j}$, $i, j \in \{1, \dots, n\}$ les éléments de la matrice A^{-1} . Considérons le i -ième vecteur de la base canonique de $\mathbb{R}^n$ donné par $\mathbf{e}_i = (0 \ \dots \ 0 \ 1 \ 0 \ \dots \ 0)^\top$ dont toutes les composantes sont nulles sauf la i -ième composante qui vaut 1. Ce vecteur est positif et on a $A(A^{-1}\mathbf{e}_i) = \mathbf{e}_i \geq 0$. D'après notre hypothèse, cela implique que $A^{-1}\mathbf{e}_i \geq 0$. Or $B = A^{-1}\mathbf{e}_i$ est un vecteur dont les composantes sont

$$\forall j \in \{1, \dots, n\} \quad b_j = \sum_{k=1}^n \alpha_{j,k} \underbrace{\mathbf{e}_{ik}}_{=\delta_{ik}} = \sum_{k=1}^n \alpha_{j,k} \delta_{ik} = \alpha_{j,i}$$

où δ_{ik} désigne le symbole de Kronecker ($\delta_{ik} = 1$ si $i = k$ et 0 sinon). On en conclut que $\alpha_{j,i} \geq 0$ pour tous $i, j \in \{1, \dots, n\}$. $\square$

Remarque 1.13 On ne confondra pas la notion de matrice monotone avec celle de matrice définie positive. Une matrice $A \in \mathcal{M}_n(\mathbb{R})$ est définie positive si

1. $\forall X \in \mathbb{R}^n \quad X^\top A X \geq 0$;
2. $(\forall X \in \mathbb{R}^n \quad X^\top A X = 0) \implies X = 0$.

Par exemple, on vérifiera sans peine que la matrice

$$A = \begin{pmatrix} 2 & 1 & 0 & 0 \\ 1 & 2 & 1 & 0 \\ 0 & 1 & 2 & 1 \\ 0 & 0 & 1 & 1 \end{pmatrix}$$

est définie positive mais qu'elle n'est pas monotone puisque, pour $X = \begin{pmatrix} 1 \\ -1 \\ 1 \\ -1 \end{pmatrix}$ on a $A X = \begin{pmatrix} 1 \\ 0 \\ 0 \\ 0 \end{pmatrix} \geq 0$

bien que X ne soit pas positif.

Inversement, la matrice $A = \begin{pmatrix} 2 & -1 \\ -99 & 100 \end{pmatrix}$ est monotone, voir la proposition 1.6 ci-après, mais elle n'est pas définie positive car pour $X = \begin{pmatrix} 10 \\ 1 \end{pmatrix}$, on a $X^\top A X = -700 < 0$.

Rappelons que l'on appelle *rayon spectral* d'une matrice $M \in \mathcal{M}_n(\mathbb{K})$, et que l'on note $\rho(M)$, la plus grande valeur du module des valeurs propres $\lambda_i, i = 1, \dots, n$ de la matrice,⁽¹⁵⁾ i.e.

$$\rho(M) = \max_{i=1, \dots, n} |\lambda_i|.$$

On a les relations suivantes entre la valeur du rayon spectral et les différentes normes matricielles usuelles de la matrice M : $\|M\|_2 = \sqrt{\rho(M M^*)}$ et $\rho(M) \leq \|M\|_\infty$, $\rho(M) \leq \|M\|_1$.

Le lemme suivant nous sera utile par la suite. Par convention, pour toute matrice $M \in \mathcal{M}_n(\mathbb{K})$, on pose $M^0 = I$ (la matrice identité), $M^1 = M$, puis par récurrence, on définit les puissances successives de la matrice M : $M^2 = M \times M$, $M^3 = M^2 \times M$, etc.

LEMME 1.2 Soit $M \in \mathcal{M}_n(\mathbb{K})$ tel que $\rho(M) < 1$. La série $\sum_{k=0}^{\infty} M^k$ converge et a pour somme $(I - M)^{-1}$.

⁽¹⁴⁾. Voir [4], chap. 10.

⁽¹⁵⁾. Dans $\mathbb{C}$, une matrice carrée de taille n admet n valeurs propres comptées avec multiplicité.

Démonstration Voir [10, T.1]. □

PROPOSITION 1.6 (Condition suffisante de monotonie)

Soit $A = (a_{i,j})_{i,j=1,\dots,n}$ une matrice de $\mathcal{M}_n(\mathbb{R})$ telle que

- $\forall i, j \in \{1, \dots, n\} \quad (i \neq j \implies a_{i,j} \leq 0)$;
- $\forall i \in \{1, \dots, n\} \quad \sum_{j=1}^n a_{i,j} > 0$.

(Les éléments de la matrice A qui ne sont pas sur la diagonale sont négatifs ou nuls et la somme des éléments de chaque ligne de la matrice est un réel strictement positif.)

Sous ces hypothèses, la matrice A est monotone.

Remarque 1.14 D'après les hypothèses de la proposition (1.6), on a nécessairement $a_{i,i} > 0$ pour tout $i \in \{1, \dots, n\}$. De plus, comme $\sum_{j=1}^n a_{i,j} > 0$ pour tout $i \in \{1, \dots, n\}$ et que les coefficients hors diagonale sont négatifs, on a

$$|a_{i,i}| = a_{i,i} > - \sum_{\substack{j=1 \\ j \neq i}}^n a_{i,j} = \sum_{\substack{j=1 \\ j \neq i}}^n |a_{i,j}|.$$

On en déduit que sous les hypothèses de la proposition (1.6) la matrice A est à diagonale strictement dominante. Elle est donc en particulier inversible d'après le lemme de Hadamard.

Démonstration (de la proposition (1.6)) Commençons par remarquer que, d'après les hypothèses de la proposition (1.6), on a nécessairement $a_{i,i} > 0$ pour tout $i \in \{1, \dots, n\}$. Considérons la matrice diagonale D formée des éléments diagonaux de A (i.e. $D = \text{diag}(A)$). Comme les éléments diagonaux de A sont non nuls, D est inversible et son inverse est la matrice diagonale dont les éléments sont $1/a_{i,i}, i = 1, \dots, n$. En particulier, cette matrice est positive : $D^{-1} \geq 0$.

Introduisons la matrice $M \in \mathcal{M}_n(\mathbb{R})$ telle que $A = D(I - M)$. Cette matrice a pour éléments $m_{i,j}, i, j = 1, \dots, n$, où

- $m_{i,i} = 0$ pour tout $i \in \{1, \dots, n\}$;
- $m_{i,j} = -a_{i,j}/a_{i,i}$ pour tout $i, j \in \{1, \dots, n\}$ avec $j \neq i$.

D'après les hypothèses de la proposition, $m_{i,j} \geq 0$ pour tout $i, j \in \{1, \dots, n\}$. Par ailleurs,

$$\|A\|_\infty = \max_{i=1,\dots,n} \sum_{j=1}^n |m_{i,j}| = \max_{i=1,\dots,n} \sum_{j=1}^n m_{i,j} = \max_{i=1,\dots,n} \sum_{\substack{j=1 \\ j \neq i}}^n \frac{-a_{i,j}}{a_{i,i}} < 1$$

car pour tout $i \in \{1, \dots, n\}$, la seconde des hypothèses de la proposition implique que $a_{i,i} + \sum_{\substack{j=1 \\ j \neq i}}^n a_{i,j} > 0$ et donc que $\sum_{\substack{j=1 \\ j \neq i}}^n \frac{-a_{i,j}}{a_{i,i}} < 1$. On a donc $\rho(M) < 1$ et par conséquent, d'après le lemme 1.2, la matrice $I - M$ est inversible avec $I - M = \sum_{k=0}^{\infty} M^k$. De la relation $A = D(I - M)$, on déduit alors que

$$A^{-1} = (I - M)^{-1} D^{-1} = \left(\sum_{k=0}^{\infty} M^k \right) D^{-1}.$$

Comme les matrices M et D sont positives, on en conclut que A^{-1} est elle aussi positive. La matrice A est donc bien monotone. □

Nous avons vu que sous les hypothèses de la proposition (1.6) la matrice A est monotone et elle est aussi à diagonale strictement dominante. On sera toutefois attentif au fait que les hypothèses de la proposition (1.6) sont des conditions suffisantes pour qu'une matrice A soit monotone. Et par conséquent, il ne faudrait pas penser que toute matrice monotone est à diagonale strictement dominante. Par exemple, la matrice

$$A = \begin{pmatrix} 1 & -2 & 1 \\ -1 & 2 & 0 \\ 1 & 1 & -3 \end{pmatrix} \quad \text{d'inverse} \quad A^{-1} = \frac{1}{3} \begin{pmatrix} 6 & 5 & 2 \\ 3 & 4 & 1 \\ 3 & 3 & 0 \end{pmatrix}$$

est monotone mais n'est pas à diagonale strictement dominante (considérer la première ligne de la matrice A).

Inversement, une matrice à diagonale strictement dominante n'est pas nécessairement une matrice monotone. Par exemple, la matrice

$$A = \begin{pmatrix} 3 & -1 & 1 \\ -1 & 2 & 0 \\ 1 & 1 & -3 \end{pmatrix} \quad \text{d'inverse} \quad A^{-1} = \frac{1}{18} \begin{pmatrix} 6 & 2 & 2 \\ 3 & 10 & 1 \\ 3 & 4 & -5 \end{pmatrix}$$

est à diagonale strictement dominante mais n'est pas monotone.

On peut affaiblir la seconde condition de la proposition 1.6 en exigeant seulement que la somme des éléments de chaque ligne de la matrice soit un réel positif ou nul au lieu de devoir être strictement positif. On sera attentif toutefois à la condition supplémentaire exigeant que la matrice A soit inversible car cette propriété n'est plus assurée par les seules nouvelles hypothèses sur les coefficients. Précisément, on a le résultat suivant.

PROPOSITION 1.7 (Autre condition suffisante de monotonie)

Soit $A = (a_{i,j})_{i,j=1,\dots,n}$ une matrice de $\mathcal{M}_n(\mathbb{R})$ telle que

- A est inversible ;
- $\forall i, j \in \{1, \dots, n\} \quad (i \neq j \implies a_{i,j} \leq 0)$;
- $\forall i \in \{1, \dots, n\} \quad \sum_{j=1}^n a_{i,j} \geq 0$.

Sous ces hypothèses, la matrice A est monotone.

Démonstration Pour tout réel $\varepsilon > 0$, la matrice $A + \varepsilon I$ vérifie les conditions de la proposition 1.6. Par conséquent, la matrice $A + \varepsilon I$ est monotone : $(A + \varepsilon I)^{-1}$ existe et est positive. Il s'ensuit que $A^{-1} = \lim_{\varepsilon \rightarrow 0} (A + \varepsilon I)^{-1} \geq 0$. $\square$

Remarque 1.15 L'hypothèse que A est inversible est indispensable dans l'énoncé de la proposition 1.7. La matrice nulle vérifie bien les deux conditions sur les coefficients, mais elle ne peut être monotone car elle n'est pas inversible...

PROPOSITION 1.8 On suppose que, pour tout $j \in \{1, \dots, J-1\}$, on a

- $\alpha(x_j) > 0$;
- $\alpha(x_j) \pm \frac{h}{2} \tilde{\beta}(x_j) > 0$;
- $\gamma(x_j) \geq 0$.

Sous ces hypothèses, la matrice A définie en (1.39) est monotone.

Démonstration Sous les hypothèses de la proposition 1.8, on déduit de la proposition 1.4 que la matrice A est inversible. La matrice A est une matrice tridiagonale dont les termes tridiagonaux sont donnés par

$$\begin{aligned} a_{j,j} &= \frac{2}{h^2} \alpha(x_j) + \gamma(x_j) & \forall j \in \{1, \dots, J-1\}, \\ a_{j,j-1} &= -\frac{1}{h^2} \alpha(x_j) - \frac{1}{2h} \tilde{\beta}(x_j) & \forall j \in \{2, \dots, J-1\}, \\ a_{j,j+1} &= -\frac{2}{h^2} \alpha(x_j) + \frac{1}{2h} \tilde{\beta}(x_j) & \forall j \in \{1, \dots, J-2\}, \end{aligned}$$

La seconde des hypothèses de la proposition 1.8 implique que la première des hypothèses de la proposition 1.7 est satisfaite. Pour tout $j \in \{2, \dots, J-2\}$, on a

$$\sum_{k=1}^n a_{j,k} = a_{j,j-1} + a_{j,j} + a_{j,j+1} = \gamma(x_j)$$

et cette quantité est positive d'après la troisième des hypothèses de la proposition 1.8. De plus, pour $j = 1$, on a

$$\sum_{k=1}^n a_{1,k} = a_{1,1} + a_{1,2} = \frac{1}{h^2} \alpha(x_1) + \frac{1}{2h} \tilde{\beta}(x_1) + \gamma(x_1)$$

et cette quantité est positive d'après les hypothèses de la proposition. Enfin, pour $j = J-1$, on a

$$\sum_{k=1}^n a_{J-1,k} = a_{J-1,J-1} + a_{J-1,J-2} = \frac{1}{h^2} \alpha(x_{J-1}) - \frac{1}{2h} \tilde{\beta}(x_{J-1}) + \gamma(x_{J-1})$$

et cette quantité est aussi positive d'après les hypothèses de la proposition. D'après la proposition 1.7, la matrice A définie en (1.39) est monotone. $\square$

PROPOSITION 1.9 *On suppose que :*

- il existe $\alpha_0 > 0$ tel que pour tout $x \in [a, b]$ on ait $\alpha(x) \geq \alpha_0$;
- $\alpha(x_j) \pm \frac{h}{2} \tilde{\beta}(x_j) > 0$ pour tout $j \in \{1, \dots, J-1\}$;
- $\gamma(x_j) \geq 0$ pour tout $j \in \{1, \dots, J-1\}$.

Sous ces hypothèses, le problème discret (1.38) $AU = F$ admet une unique solution $U = (u_1, \dots, u_{J-1})^\top$ qui vérifie

$$\|U\|_\infty \leq \frac{C}{2\alpha_0} \left(\frac{b-a}{2} \right)^2 \|F\|_\infty$$

où C est une constante positive qui ne dépend que des données α, β et γ .

Démonstration $\supseteq$ L'existence et l'unicité de la solution a été établie à la proposition 1.4.

$\supseteq$ Pour établir l'estimation *a priori*, on se restreint au cas où $\tilde{\beta} = 0$ sur $[a, b]$. Le problème discret (1.36) – (1.37) s'écrit sous la forme matricielle $AU = F$ où la matrice A est définie en (1.39) et le vecteur F est défini en (1.40) p. 19. Considérons la fonction polynomiale $\psi : x \in \mathbb{R} \mapsto \frac{1}{2\alpha_0}(x-a)(b-x)\|F\|_\infty$ qui est positive sur $[a, b]$ et désignons par Ψ le vecteur $(\psi(x_1), \dots, \psi(x_{J-1}))^\top$. Pour tout $x \in]a, b[$, on a

$$-(\alpha(x)\psi'(x))' + \beta(x)\psi'(x) + \gamma(x)\psi(x) = g(x)$$

où

$$g(x) = \underbrace{\left(\frac{\alpha(x)}{\alpha_0} \right)}_{\geq 1} + \frac{1}{2\alpha_0} \underbrace{(\beta(x) - \alpha'(x))}_{=\tilde{\beta}(x)=0} (a+b-2x) + \frac{1}{2\alpha_0} \underbrace{\gamma(x)(x-a)(b-x)}_{\geq 0} \quad \|F\|_\infty \geq \|F\|_\infty \quad (1.41)$$

et on a les conditions aux limites $\psi(a) = \psi(b) = 0$. Utilisons le même schéma de discrétisation par différences finies pour le problème aux limites dont ψ est solution que celui utilisé pour le problème $(\mathcal{P})$. Remarquons, c'est essentiel ici, que comme ψ est une fonction polynomiale de degré 2, l'approximation donnée par le schéma aux différences finies est en fait exacte pour ψ . On a donc $A\Psi = G$ où G est le vecteur de $\mathbb{R}^{J-1}$ dont les composantes sont $G_j = g(x_j)$ pour $j = 1, \dots, J-1$.

Comme $AU = F$ et $A\Psi = G$, on en déduit que

$$A(\Psi - U) = G - F \quad \text{et} \quad A(\Psi + U) = G + F.$$

Compte tenu de (1.41), on a $A(\Psi - U) \geq 0$ et $A(\Psi + U) \geq 0$. Sous les hypothèses de la proposition, la matrice A est monotone. Par conséquent, on a $\Psi - U \geq 0$ et $\Psi + U \geq 0$. Autrement dit, pour tout $j \in \{1, \dots, J-1\}$, on a $-\psi(x_j) \leq u_j \leq \psi(x_j)$, c'est à dire $|u_j| \leq \psi(x_j)$. Ainsi,

$$|u_j| \leq \frac{1}{2\alpha_0} (x_j - a)(b - x_j) \|F\|_\infty.$$

L'étude de la fonction polynomiale $x \mapsto (x - a)(b - x)$ sur l'intervalle $[a, b]$ montre qu'elle atteint son maximum en $\frac{a+b}{2}$ et que celui-ci vaut $\left(\frac{b-a}{2}\right)^2$. On obtient donc bien le résultat annoncé.

⊇ Le résultat dans le cas général où $\tilde{\beta} \neq 0$ est admis.

□

La proposition 1.9 exprime la « stabilité » du problème discret, au sens où si les données du problème aux limites ($\mathcal{P}$) (qui interviennent dans l'écriture sous forme matricielle du problème discret dans le vecteur F) sont perturbées d'une quantité ne dépassant par ε , alors la solution approchée obtenue en résolvant le problème discret sera perturbée d'une quantité ne dépassant pas $\frac{1}{2\alpha_0} \left(\frac{b-a}{2}\right)^2$ fois ε . Cela nous conduit à introduire la définition suivante.

DÉFINITION 1.5 (Stabilité d'un schéma aux différences finies)

On dit qu'un schéma aux différences finies se traduisant sous la forme du système linéaire $AU = F$ est stable pour la norme infinie s'il existe une constante $C > 0$ ne dépendant que des données telle que

$$\|U\|_\infty \leq C \|F\|_\infty.$$

Remarque 1.16 Pour une matrice A inversible telle que $AU = F$, on a $U = A^{-1}F$. On en déduit que

$$\|U\|_\infty = \|A^{-1}F\|_\infty \leq \|A^{-1}\|_\infty \|F\|_\infty$$

où $\|A^{-1}\|_\infty$ désigne la norme matricielle subordonnée à la norme vectorielle infinie.⁽¹⁶⁾ Une condition nécessaire et suffisante pour que le schéma aux différences finies conduisant au système linéaire $AU = F$ soit stable est qu'il existe une constante $C > 0$ ne dépendant pas de h telle que $\|A^{-1}\|_\infty \leq C$.

Sous l'hypothèse que la matrice A est monotone, on peut estimer $\|A^{-1}\|_\infty$ de la manière suivante. Désignons pas $\alpha_{i,j}$, $(i, j) \in \{1, \dots, J-1\}^2$ les composantes de la matrice A^{-1} . On a

$$\|A^{-1}\|_\infty = \max_{i \in \{1, \dots, J-1\}} \sum_{j=1}^{J-1} |\alpha_{i,j}|.$$

Comme la matrice A est monotone, on a $\alpha_{i,j} \geq 0$ et par conséquent

$$\|A^{-1}\|_\infty = \max_{i \in \{1, \dots, J-1\}} \sum_{j=1}^{J-1} \alpha_{i,j} = \max_{i \in \{1, \dots, J-1\}} w_i$$

où $w_i = \sum_{j=1}^{J-1} \alpha_{i,j} = \sum_{j=1}^{J-1} \alpha_{i,j} \times 1$ peut s'interpréter comme la i -ième composante du vecteur $A^{-1} \mathbb{1}$ où $\mathbb{1}$ désigne le vecteur de $\mathbb{R}^{J-1}$ dont toutes les composantes valent 1. Le vecteur $A^{-1} \mathbb{1}$ étant à composantes positives car A est monotone, on a

$$\|A^{-1}\|_\infty = \max_{i \in \{1, \dots, J-1\}} |w_i| = \|A^{-1} \mathbb{1}\|_\infty.$$

1.4.5 Majoration d'erreur

Nous venons d'établir que la version discrète (1.36) – (1.37) du problème aux limites (1.1)–(1.2) admettait une unique solution. Pour que ce schéma de discrétisation ait un intérêt, il reste à vérifier que la solution du problème discret (1.36) – (1.37) constitue une approximation de la solution du problème aux limites (1.1)–(1.2). Nous souhaitons au minimum que lorsque le pas h de la subdivision tend vers 0, la solution du problème discret tende vers la solution du problème aux limites.

⁽¹⁶⁾. Voir [3], proposition 7.5 et section 7.2.

Notion de consistance d'un schéma aux différences finies

Dans l'étude des propriétés d'un schéma aux différences finies, un point essentiel est l'étude de la consistance du schéma. Cette étude consiste à regarder la « qualité » de l'approximation par différences finies de l'équation à résoudre.

Pour étudier la consistance d'un schéma aux différences finies, on introduit la notion *d'erreur de consistance*. L'erreur de consistance estime l'erreur produite par l'approximation des dérivées par des différences finies. Plus précisément, elle mesure la manière dont la solution exacte satisfait le schéma discret. Pour notre problème, l'erreur de consistance au nœud x_j pour $j \in \{1, \dots, J-1\}$, notée ε_j , vérifie d'après (1.36)

$$-\alpha(x_j) \frac{u(x_{j+1}) - 2u(x_j) + u(x_{j-1}))}{h^2} + \tilde{\beta}(x_j) \frac{u(x_{j+1}) - u(x_{j-1}))}{2h} + \gamma(x_j) u(x_j) = f(x_j) + \boxed{\varepsilon_j} \quad (1.42)$$

où $u(x_j)$ désigne la solution exacte de l'équation (1.1) au nœud x_j . Bien entendu, dans le cas de notre problème modèle avec condition de Dirichlet, l'erreur de consistance est nulle aux nœuds x_0 et x_J .

DÉFINITION 1.6 (Consistance d'un schéma aux différences finies)

Un schéma aux différences finies sera dit consistant avec l'équation (1.1) si l'erreur de consistance en chaque nœud tend vers 0 lorsque le pas h de la subdivision tend vers 0, autrement dit si

$$\lim_{h \rightarrow 0} \max_{j=0, \dots, J} |\varepsilon_j| = 0.$$

Vérifions que notre schéma de différences finies est consistant. Pour cela, nous allons supposer que u est de classe $\mathcal{C}^4$ sur $[a, b]$. Soit $j \in \{1, \dots, J-1\}$; d'après la formule de Taylor-Lagrange à l'ordre 3 appliquée à la solution u du problème aux limites (1.1)–(1.2) entre x_j et $x_{j+1} = x_j + h$, il existe $\theta_1 \in]0, 1[$ tel que

$$u(x_j + h) = u(x_j) + h u'(x_j) + \frac{1}{2} h^2 u''(x_j) + \frac{1}{6} h^3 u^{(3)}(x_j + \theta_1 h).$$

Par ailleurs, d'après la formule de Taylor-Lagrange à l'ordre 3 appliquée à la solution u du problème aux limites (1.1)–(1.2) entre x_j et $x_{j-1} = x_j - h$, il existe $\theta_2 \in]-1, 0[$ tel que

$$u(x_j - h) = u(x_j) - h u'(x_j) + \frac{1}{2} h^2 u''(x_j) - \frac{1}{6} h^3 u^{(3)}(x_j + \theta_2 h).$$

Par différence entre ces deux expressions, nous obtenons

$$\frac{u(x_{j+1}) - u(x_{j-1}))}{2h} = u'(x_j) + \frac{1}{6} h^2 (u^{(3)}(x_j + \theta_1 h) + u^{(3)}(x_j + \theta_2 h)). \quad (1.43)$$

Considérons à présent la formule de Taylor-Lagrange à l'ordre 4 appliquée à la solution u du problème aux limites (1.1)–(1.2) entre x_j et $x_{j+1} = x_j + h$. Il existe $\theta_3 \in]0, 1[$ tel que

$$u(x_j + h) = u(x_j) + h u'(x_j) + \frac{1}{2} h^2 u''(x_j) + \frac{1}{6} h^3 u^{(3)}(x_j) + \frac{1}{24} h^4 u^{(4)}(x_j + \theta_3 h).$$

Par ailleurs, d'après la formule de Taylor-Lagrange à l'ordre 4 appliquée à la solution u du problème aux limites (1.1)–(1.2) entre x_j et $x_{j-1} = x_j - h$, il existe $\theta_4 \in]-1, 0[$ tel que

$$u(x_j - h) = u(x_j) - h u'(x_j) + \frac{1}{2} h^2 u''(x_j) - \frac{1}{6} h^3 u^{(3)}(x_j) + \frac{1}{24} h^4 u^{(4)}(x_j + \theta_4 h).$$

En sommant ces deux expressions, nous obtenons

$$\frac{u(x_{j+1}) - 2u(x_j) + u(x_{j-1}))}{h^2} = u''(x_j) + \frac{1}{24} h^2 (u^{(4)}(x_j + \theta_3 h) + u^{(4)}(x_j + \theta_4 h)). \quad (1.44)$$

En combinant (1.42) avec (1.43) et (1.44), nous obtenons

$$\begin{aligned} \varepsilon_j &= -\alpha(x_j) \left(u''(x_j) + \frac{1}{24} h^2 (u^{(4)}(x_j + \theta_3 h) + u^{(4)}(x_j + \theta_4 h)) \right) \\ &\quad + \tilde{\beta}(x_j) \left(u'(x_j) + \frac{1}{6} h^2 (u^{(3)}(x_j + \theta_1 h) - u^{(3)}(x_j + \theta_2 h)) \right) + \gamma(x_j) u(x_j) - f(x_j) \\ &= -\frac{1}{24} h^2 \alpha(x_j) (u^{(4)}(x_j + \theta_3 h) + u^{(4)}(x_j + \theta_4 h)) + \frac{1}{6} h^2 \tilde{\beta}(x_j) (u^{(3)}(x_j + \theta_1 h) + u^{(3)}(x_j + \theta_2 h)), \end{aligned}$$

la dernière égalité exploitant le fait que u étant solution de (1.1), on a $-\alpha(x_j)u''(x_j) + \tilde{\beta}(x_j)u'(x_j) + \gamma(x_j)u(x_j) = f(x_j)$. Comme les fonctions α et β sont continues sur $[a, b]$, elles sont bornées et par conséquent

$$|\varepsilon_j| \leq \frac{1}{24}h^2 \|\alpha\|_\infty |u^{(4)}(x_j + \theta_3 h) + u^{(4)}(x_j + \theta_4 h)| + \frac{1}{6}h^2 \|\tilde{\beta}\|_\infty |u^{(3)}(x_j + \theta_1 h) + u^{(3)}(x_j + \theta_2 h)|.$$

D'après le théorème des valeurs intermédiaires, il existe θ_5 et θ_6 dans $] -1, 1[$ tels que

$$|\varepsilon_j| \leq \frac{1}{12}h^2 \|\alpha\|_\infty |u^{(4)}(x_j + \theta_5 h)| + \frac{1}{3}h^2 \|\tilde{\beta}\|_\infty |u^{(3)}(x_j + \theta_6 h)|.$$

Finalement, la fonction u étant supposée de classe $\mathcal{C}^4$ sur $[a, b]$, ses dérivées troisième et quatrième sont bornées sur $[a, b]$ et en notant $M_3 = \sup_{x \in [a, b]} |u^{(3)}(x)|$ et $M_4 = \sup_{x \in [a, b]} |u^{(4)}(x)|$, il vient

$$|\varepsilon_j| \leq h^2 \left(\frac{M_4}{12} \|\alpha\|_\infty + \frac{M_3}{6} \|\tilde{\beta}\|_\infty \right). \quad (1.45)$$

On en conclut que le schéma est consistant.

DÉFINITION 1.7 (Ordre de consistance d'un schéma aux différences finies)

On dit qu'un schéma aux différences finies est d'ordre de consistance p avec $p \in \mathbb{N}$ s'il existe $C > 0$ tel que l'erreur de consistance ε_j en chaque nœud $x_j, j \in \{0, \dots, J\}$ vérifie

$$|\varepsilon_j| \leq C h^p.$$

Remarque 1.17 Dans le cas où la subdivision de l'intervalle $[a, b]$ n'est pas uniforme, la définition 1.7 est à considérer avec $h = \max_{j=0, \dots, J-1} h_j$ où $h_j = |x_{j+1} - x_j|$.

Pour le schéma d'approximation du problème aux limites (1.1)–(1.2) que nous avons construit, on déduit de la relation (1.45) le résultat suivant.

PROPOSITION 1.10

Si la solution du problème aux limites (1.1)–(1.2) est suffisamment régulière, par exemple de classe $\mathcal{C}^4$ sur $[a, b]$, alors il existe un réel strictement positif C tel que l'erreur de consistance du schéma aux différences finies (1.36) vérifie :

$$\forall j \in \{0, \dots, J\} \quad |\varepsilon_j| \leq C h^2. \quad (1.46)$$

Le schéma de différences finies est donc consistant et d'ordre de consistance 2.

Notion de convergence pour un schéma aux différences finies

L'erreur d'approximation au nœud x_j pour $j \in \{0, \dots, J\}$ est donnée par $e_j = u(x_j) - u_j$. Le schéma aux différences finies sera dit *convergent* si

$$\lim_{h \rightarrow 0} \max_{j=0, \dots, J} |e_j| = 0.$$

PROPOSITION 1.11

Si la solution u du problème aux limites (1.1)–(1.2) est suffisamment régulière, par exemple de classe $\mathcal{C}^4$ sur $[a, b]$, alors le schéma aux différences finies (1.36) est convergent et l'erreur d'approximation au nœud x_j pour tout $j \in \{0, \dots, J\}$ vérifie

$$|e_j| \leq h^2 \frac{C}{2\alpha_0} \left(\frac{b-a}{2} \right)^2 \left(\frac{M_4}{12} \|\alpha\|_\infty + \frac{M_3}{6} \|\tilde{\beta}\|_\infty \right) \quad (1.47)$$

où $M_3 = \sup_{x \in [a, b]} |u^{(3)}(x)|$, $M_4 = \sup_{x \in [a, b]} |u^{(4)}(x)|$ et C désigne la constante introduite à la proposition 1.9.

Démonstration En exploitant le fait que le schéma aux différences finies que nous avons introduit est stable et consistant, montrons qu'il est convergent. Désignons par E le vecteur de $\mathbb{R}^{J-1}$ dont les composantes sont e_j où $j = 1, \dots, J-1$. (Rappelons que $e_0 = u(x_0) - u_0 = u(a) - u_0 = 0$ et $e_J = u(x_J) - u_J = u(b) - u_J = 0$.) Désignons aussi par V le vecteur de $\mathbb{R}^{J-1}$ dont les composantes sont données par la valeur de la solution exacte du problème $(\mathcal{P})$ aux nœuds x_j pour $j \in \{1, \dots, J-1\}$. On a $E = V - U$ où U est le vecteur de composantes $u_1, \dots, u_{J-1}$ solution du système linéaire $AU = F$ correspondant à l'écriture matricielle du problème discret. Ainsi,

$$A E = A V - A U = A V - F.$$

Or, d'après (1.42), on a $A V = F + \varepsilon$ où ε est le vecteur de $\mathbb{R}^{J-1}$ dont les composantes sont les valeurs de l'erreur de consistance aux nœuds x_j pour $j \in \{1, \dots, J-1\}$. On a donc $A E = \varepsilon$. Comme le schéma aux différences finies considéré est stable, d'après la proposition 1.9, on en déduit que

$$\|E\|_\infty \leq \frac{1}{2\alpha_0} \left(\frac{b-a}{2} \right)^2 \|\varepsilon\|_\infty$$

Comme par ailleurs, le schéma aux différences finies est consistant, on déduit de la proposition 1.9 que

$$\|E\|_\infty \leq h^2 \frac{C}{2\alpha_0} \left(\frac{b-a}{2} \right)^2 \left(\frac{M_4}{12} \|\alpha\|_\infty + \frac{M_3}{6} \|\tilde{\beta}\|_\infty \right)$$

où $M_3 = \sup_{x \in [a,b]} |u^{(3)}(x)|$ et $M_4 = \sup_{x \in [a,b]} |u^{(4)}(x)|$. La proposition est démontrée. $\square$

Remarque 1.18 D'après la proposition 1.1 p. 9, une condition suffisante pour que la solution u du problème aux limites (1.1)–(1.2) soit de classe $\mathcal{C}^4$ sur $[a, b]$ est que les applications β , γ et f soient de classe $\mathcal{C}^2$ sur $[a, b]$ et que α soit de classe $\mathcal{C}^3$ sur $[a, b]$.

Interprétons la relation (1.47).

- Toutes choses égales par ailleurs, si l'on divise le pas de la subdivision par 2 (autrement dit, on double le nombre de nœuds de discrétisation) alors la relation (1.47) indique que l'on divisera l'erreur d'approximation par $2^2 = 4$. L'erreur d'approximation décroît de manière quadratique avec h .
- Pour une même subdivision de l'intervalle $[a, b]$, l'erreur de discrétisation peut être plus ou moins importante selon les données, plus précisément selon la valeur de $\|\alpha\|_\infty/\alpha_0$ et $\|\tilde{\beta}\|_\infty/\alpha_0$. L'erreur de discrétisation peut être plus ou moins importante selon les valeurs de M_3 et M_4 , c'est-à-dire selon les valeurs prises par les dérivées successives de la solution (valeurs qui indirectement dépendent des données).

DÉFINITION 1.8 (Ordre de convergence d'un schéma aux différences finies)

On dit qu'un schéma aux différences finies est d'ordre de convergence p avec $p \in \mathbb{N}$ s'il existe $C > 0$ tel que l'erreur d'approximation e_j en chaque nœud $x_j, j \in \{0, \dots, J\}$ vérifie

$$|e_j| \leq C h^p.$$

Principe de Lax

La proposition 1.11 exprime un principe général concernant l'approximation par un schéma aux différences finies d'une équation aux dérivées partielles connu sous le nom de *Principe de Lax* : si un schéma est stable et consistant d'ordre p alors il est convergent d'ordre (au moins) p . Ce principe se démontre ici très simplement. En reprenant les notations introduites dans la preuve de la proposition 1.11, on a $A E = \varepsilon$. Si le schéma est stable, alors d'après la définition 1.5, il existe $C_1 > 0$ tel que $\|E\|_\infty \leq C_1 \|\varepsilon\|_\infty$. Et si le schéma est consistant d'ordre p alors d'après la définition 1.7, il existe $C_2 > 0$ tel que $\|\varepsilon\|_\infty \leq C_2 h^p$. En combinant ces deux estimations, on en déduit que $\|E\|_\infty \leq C_1 C_2 h^p$, ce qui signifie d'après la définition 1.8 que le schéma est convergent d'ordre p .

Remarque 1.19 On sera vigilant au fait qu'un schéma stable et consistant d'ordre p est convergent mais que l'ordre de convergence peut dans certains cas être supérieur à p (par exemple $p + 1$). Bien entendu, dans ce cas, établir l'ordre de convergence nécessite des développements plus conséquents que ceux donnés ici.

1.5 Classification des équations aux dérivées partielles linéaires d'ordre 2

Nous allons poursuivre le cours en prenant en considération des équations posées en dimension supérieure. Nous continuerons à nous restreindre à des équations linéaires. Cela va nous obliger à distinguer plusieurs types d'équations aux dérivées partielles (EDP) et pour chaque type d'équation à introduire des outils mathématiques spécifique pour l'étude de ces équations ainsi que des méthodes d'approximation numérique de ces équations différentielles.

1.5.1 Formulation d'une équation aux dérivées partielles linéaire d'ordre inférieur ou égal à 2

Commençons par définir ce que nous entendons par équation aux dérivées partielles linéaire d'ordre inférieur ou égal à 2.

DÉFINITION 1.9 On appelle équation aux dérivées partielles linéaire d'ordre inférieur ou égal à 2 dans un ouvert $\mathcal{O}$ de $\mathbb{R}^d$, une équation d'inconnue u de la forme

$$\sum_{i,j=1}^d \alpha_{ij}(\zeta) \frac{\partial^2 u(\zeta)}{\partial \zeta_i \partial \zeta_j} + \sum_{i=1}^d \beta_i(\zeta) \frac{\partial u(\zeta)}{\partial \zeta_i} + \gamma(\zeta) u(\zeta) = f(\zeta) \quad \forall \zeta \in \mathcal{O} \quad (1.48)$$

où α, β, γ et f sont des fonctions données.

Rappelons que pour une fonction u de classe $\mathcal{C}^2$ sur $\mathcal{O}$, on a ⁽¹⁷⁾

$$\frac{\partial^2 u}{\partial \zeta_i \partial \zeta_j} = \frac{\partial^2 u}{\partial \zeta_j \partial \zeta_i}. \quad (1.49)$$

Cela nous conduit à supposer que $a_{ij} = a_{ji}$ pour tous $i, j \in \{1, \dots, d\}$, $i \neq j$.

Pour tout $\zeta \in \mathcal{O}$, désignons par $A(\zeta)$ la matrice symétrique de $\mathcal{M}_d(\mathbb{K})$ de coefficients $a_{ij}(\zeta)$, $i, j \in \{1, \dots, d\}$ et par $B(\zeta)$ le vecteur de $\mathbb{K}^d$ dont les coefficients sont $\beta_i(\zeta)$, $i \in \{1, \dots, d\}$. Avec ces notations, l'équation (1.48) se réécrit

$$\text{Tr}(H_u(\zeta) A(\zeta)) + J_u(\zeta) B(\zeta) + \gamma(\zeta) u(\zeta) = f(\zeta) \quad \forall \zeta \in \mathcal{O} \quad (1.50)$$

où $H_u(\zeta)$ désigne la matrice Hessienne de u en ζ (il s'agit d'une matrice symétrique compte tenu de (1.49)), $J_u(\zeta)$ désigne la matrice Jacobienne de u en ζ (il s'agit d'une matrice ligne ici) et Tr désigne l'opérateur trace d'une matrice.

Exemples 1.6

1. L'équation des ondes (ou équation des cordes vibrantes) introduite p. 3, qui s'écrit

$$\mu(x) \frac{\partial^2 u}{\partial t^2}(x, t) - T(t) \frac{\partial^2 u}{\partial x^2}(x, t) = f(x, t)$$

correspond, en posant $\zeta = (x, t)$, à $A(x, t) = \begin{pmatrix} -T(t) & 0 \\ 0 & \mu(x) \end{pmatrix}$ et $B = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$. On a $\gamma = 0$.

2. L'équation de la chaleur introduite p. 4, qui s'écrit

$$\rho c \frac{\partial T}{\partial t}(x, t) - \frac{\partial}{\partial x} \left(\lambda(x) \frac{\partial T}{\partial x}(x, t) \right) = f(x, t)$$

correspond, en posant $\zeta = (x, t)$, à $A(x, t) = \begin{pmatrix} -\lambda(x) & 0 \\ 0 & 0 \end{pmatrix}$ et $B(x, t) = \begin{pmatrix} -\lambda'(x) \\ \rho c \end{pmatrix}$. On a $\gamma = 0$.

⁽¹⁷⁾. C'est le théorème de Schwarz, voir par exemple [3], théorème 10.3.

1.5.2 Rappels sur la classifications des coniques

On appelle *conique* l'ensemble des points $(x, y) \in \mathbb{R}^2$ tels que

$$ax^2 + by^2 + 2cxy + \ell x + my + h = 0$$

où $(a, b, c, \ell, m, h) \in \mathbb{R}^6$ et $(a, b, c) \neq (0, 0, 0)$.

Posons

$$A = \begin{pmatrix} a & c \\ c & b \end{pmatrix}, \quad B = \begin{pmatrix} \ell \\ m \end{pmatrix}, \quad X = \begin{pmatrix} x \\ y \end{pmatrix}.$$

L'expression matricielle de l'équation de la conique devient :

$$X^\top A X + B^\top X + h = 0.$$

La matrice symétrique A possède deux valeurs propres réelles λ_+ et λ_-

$$\lambda_{\pm} = \frac{1}{2} \left((a+b) \pm \sqrt{(a-b)^2 + 4c^2} \right). \quad (1.51)$$

On montre, voir par exemple [3] chap. 8, le résultat suivant.

PROPOSITION 1.12 (Classification des coniques)

Soit $\mathcal{C}$ une conique d'équation $ax^2 + by^2 + 2cxy + \ell x + my + h = 0$.

✕ Si $ab - c^2 > 0$ alors la matrice A admet deux valeurs propres non nulles de même signe et la conique $\mathcal{C}$ est une ellipse.

✕ Si $ab - c^2 = 0$ alors la matrice A admet une valeur propre nulle et la conique $\mathcal{C}$ est une parabole.

✕ Si $ab - c^2 < 0$ alors la matrice A admet deux valeurs propres de signe opposé et la conique $\mathcal{C}$ est une hyperbole.

1.5.3 Équations aux dérivées partielles elliptiques

DÉFINITION 1.10 (Équation elliptique)

Une équation aux dérivées partielles linéaire du second ordre de la forme (1.48) définie sur un ouvert $\mathcal{O}$ de $\mathbb{R}^d$ est dite elliptique en $\zeta \in \mathcal{O}$ si la matrice $A(\zeta)$ dans l'écriture de l'équation sous la forme (1.50) n'admet que des valeurs propres non nulles et qui sont toutes de même signe.

Remarque 1.20 Une équation aux dérivées partielles elliptique modélise en général un problème d'équilibre ou un problème stationnaire.

Exemple 1.7 L'équation de Laplace $\Delta u = 0$ dans $\mathbb{R}^3$ correspond à

$$A(x_1, x_2, x_3) = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix}.$$

Cette matrice admet 1 pour valeur propre triple. L'équation de Laplace est donc une équation elliptique.

1.5.4 Équations aux dérivées partielles paraboliques

DÉFINITION 1.11 (Équation parabolique)

Une équation aux dérivées partielles linéaire du second ordre de la forme (1.48) définie sur un ouvert $\mathcal{O}$ de $\mathbb{R}^d$ est dite parabolique en $\zeta \in \mathcal{O}$ si la matrice $A(\zeta)$ dans l'écriture de l'équation sous la forme (1.50) admet $d - 1$ valeurs propres non nulles de même signe et une valeur propre nulle.

Remarque 1.21 Dans le cas où l'équation aux dérivées partielles est parabolique sur tout le domaine d'étude, elle modélise en général un phénomène de diffusion.

Exemple 1.8 L'équation de la chaleur introduite p. 4, correspond, en posant $\zeta = (x, t)$ à $A(x, t) = \begin{pmatrix} -\lambda(x) & 0 \\ 0 & 0 \end{pmatrix}$ où $\lambda(x)$ désigne la conductivité thermique du matériau au point d'abscisse x de la barre. Pour tout $x \in [a, b]$, le réel $\lambda(x)$ est strictement positif. Pour tout (x, t) , la matrice $A(x, t)$ possède donc une valeur propre strictement positive et une valeur propre nulle. On a une équation parabolique.

1.5.5 Équations aux dérivées partielles hyperboliques

DÉFINITION 1.12 (Équation hyperbolique)

Une équation aux dérivées partielles linéaire du second ordre de la forme (1.48) définie sur un ouvert $\mathcal{O}$ de $\mathbb{R}^d$ est dite hyperbolique en $\zeta \in \mathcal{O}$ si la matrice $A(\zeta)$ dans l'écriture de l'équation sous la forme (1.50) admet

- $d - 1$ des valeurs propres non nulles de même signe
- et une valeur propre non nulle de signe opposé.

Remarque 1.22 Une équation aux dérivées partielles hyperbolique modélise en général un problème de propagation d'une onde.

Exemple 1.9 Pour l'équation des ondes (ou équation des cordes vibrantes), voir l'équation (1.7) p. 3, nous avons $A(x, t) = \begin{pmatrix} -T(t) & 0 \\ 0 & \mu(x) \end{pmatrix}$ où pour tout temps t et tout $x \in [a, b]$ les réels $T(t)$ et $\mu(x)$ qui représentent la tension (supposée d'intensité constante le long de la corde) et la densité linéique de masse au point d'abscisse x sont strictement positifs. La matrice étant diagonale, ses 2 valeurs propres sont $-T(t)$ et $\mu(x)$. Il s'agit de 2 valeurs propres non nulles de signe opposé. On a une équation hyperbolique.

Remarques 1.23

1. Certaines équations ont un type variable suivant le point considéré. Ainsi, l'équation de Tricomi

$$\frac{\partial^2 u}{\partial x^2}(x, y) + x \frac{\partial^2 u}{\partial y^2}(x, y) = 0$$

qui modélise par exemple les écoulements transsoniques non visqueux, est elliptique en tout point (x, y) tel que $x > 0$, parabolique en tout point $(0, y)$ et hyperbolique en tout point (x, y) tel que $x < 0$.

2. La classification ne couvre pas l'ensemble des équations aux dérivées partielles linéaires d'ordre 2. Par exemple, l'équation de Schrödinger ne rentre dans aucune de ces catégories, car elle est à coefficients non réels.

Problèmes aux limites elliptiques

2.1 Modélisation de phénomènes physiques conduisant à des problèmes aux limites elliptiques

2.1.1 Un problème de magnétostatique en imagerie par résonance magnétique

Description du problème

Nous nous intéressons aux artefacts (brouillage de l'image) qui apparaissent sur les clichés IRM lorsqu'un implant métallique *paramagnétique*⁽¹⁾ est présent dans l'échantillon étudié. Ces artefacts sont qualifiés d'*artefacts de susceptibilité magnétique*. Nous envisageons donc la situation suivante : un objet métallique aux propriétés physiques connues et de géométrie donnée se trouve à l'intérieur de tissus biologiques ; l'ensemble est soumis aux champs magnétiques utilisés lors d'une expérience IRM. Des considérations physiques permettent de préciser et de simplifier le modèle mathématique donné par les équations de Maxwell. Nous faisons les hypothèses suivantes.




FIG. 1 Un scanner IRM.

- Les différents phénomènes observés sont indépendants du temps.
- Nous négligeons tous les phénomènes électromagnétiques ayant pour origine le milieu biologique (activité neuronale, etc). Nous supposons aussi qu'il n'existe ni courant ni charge à l'intérieur des milieux, ni aux surfaces de séparation de ces milieux.
- Parmi les différents champs électromagnétiques utilisés au cours d'une expérience IRM nous ne prendrons en compte que le champ magnétique principal $\mathbf{B}_0$. Nous négligerons les gradients de champ magnétique : ceux-ci ont une intensité 10^4 fois plus faible que le champ $\mathbf{B}_0$. Nous négligerons aussi le champ radio-fréquence $\mathbf{B}_1$.
- Les différents tissus biologiques ne jouant pas de rôle essentiel en ce qui concerne l'étude des artefacts de susceptibilité magnétique, nous supposerons par la suite que l'implant est entouré d'un milieu homogène quant à ses propriétés magnétiques. Ceci se justifie par le fait que les différences de *susceptibilité magnétique*⁽²⁾ entre les tissus biologiques sont très faibles comparées à la différence existant avec la susceptibilité magnétique de l'implant métallique. On pourra assimiler ce milieu biologique homogène au vide car les tissus biologiques sont des milieux *diamagnétiques*⁽³⁾ à susceptibilité magnétique très faible (de l'ordre de -10^{-6}). Le champ magnétique induit par le milieu

(1). Le paramagnétisme désigne le comportement d'un milieu matériel qui ne possède pas d'aimantation spontanée mais qui, sous l'effet d'un champ magnétique extérieur, acquiert une aimantation dirigée dans le même sens que ce champ d'excitation. Cette aimantation disparaît lorsque le champ d'excitation est coupé.

(2). La susceptibilité magnétique d'un milieu paramagnétique est une constante caractéristique du milieu correspondant au facteur de proportionnalité entre l'aimantation du milieu et le champ magnétique exciteur.

(3). Le diamagnétisme est une propriété générale de la matière soumise à un champ magnétique se traduisant par l'apparition d'un champ magnétique d'intensité très faible, opposé au champ magnétique appliqué. La susceptibilité magnétique des matériaux diamagnétiques est négative et très petite.




FIG. 2 Exemple d'artefacts de susceptibilité magnétique engendré par un implant dentaire.

biologique sera donc négligeable devant celui de l'implant paramagnétique. (Notons toutefois que ce sont les propriétés magnétiques des tissus qui sont utilisées afin de créer l'image IRM ...).

Signalons enfin que l'on peut traiter d'une façon analogue les artefacts liés à la présence d'une cavité remplie d'air à l'intérieur des tissus (par exemple les poumons ou les fosses nasales). Il suffit de considérer à la place de la cavité un implant métallique dont la susceptibilité magnétique (fictive ici) est choisie de telle sorte à conserver la différence de susceptibilité magnétique existant entre la cavité (air) et les tissus.

Le modèle mathématique

On désigne par $\bar{\Omega}$ le domaine de $\mathbb{R}^3$ occupé par l'implant où Ω désigne un ouvert borné et régulier. On désigne par Ω' le complémentaire dans $\mathbb{R}^3$ de l'adhérence de Ω et par Σ la frontière de Ω , voir la figure 3. Cet implant métallique est soumis à une induction magnétique constante (de l'ordre de 1 Tesla) que l'on notera $\mathbf{B}_0$ afin de nous conformer à la notation utilisée en IRM.




FIG. 3 Notations utilisées.

Sous les hypothèses précédentes, notre étude se ramène à résoudre le problème de magnétostatique sui-

vant [9, 14] : trouver le champ magnétique $\mathbf{H}$ et l'induction magnétique $\mathbf{B}$ solutions de

$$\begin{cases} \mathbf{rot} \mathbf{H} &= \mathbf{0} & \text{dans } \Omega \text{ et } \Omega', \\ \operatorname{div} \mathbf{B} &= 0 & \text{dans } \Omega \text{ et } \Omega', \\ [\mathbf{H} \wedge \mathbf{n}] &= \mathbf{0} & \text{à travers } \Sigma, \\ [\mathbf{B} \cdot \mathbf{n}] &= 0 & \text{à travers } \Sigma, \end{cases} \quad (2.1)$$

avec pour condition à l'infini,

$$\lim_{\substack{|x| \rightarrow +\infty \\ x \in \mathbb{R}^3}} \mathbf{B}(x) = \mathbf{B}_0. \quad (2.2)$$

La notation $[u]$ désigne le saut de u à travers l'interface surfacique Σ : $[u] = u|_{\Omega} - u|_{\Omega'}$.

Dans le milieu Ω , les champs $\mathbf{B}$ et $\mathbf{H}$ sont liés par la relation

$$\mathbf{B} = \mathbf{H} + \mathbf{M}, \quad (2.3)$$

où $\mathbf{M}$ désigne le vecteur aimantation du milieu. Pour un milieu paramagnétique, $\mathbf{M}$ et $\mathbf{H}$ sont liés par la loi de comportement

$$\mathbf{M} = \chi_m \mathbf{H} \quad (2.4)$$

où χ_m est une constante caractéristique du milieu appelée susceptibilité magnétique. Dans le vide, l'aimantation $\mathbf{M}$ est nulle.

Les relations (2.3) et (2.4) nous permettent d'écrire le problème (2.1) en fonction du seul champ $\mathbf{H}$:

$$\begin{cases} \mathbf{rot} \mathbf{H} &= \mathbf{0} & \text{dans } \Omega \text{ et } \Omega', \\ \operatorname{div} \mathbf{H} &= 0 & \text{dans } \Omega \text{ et } \Omega', \\ [\mathbf{H} \wedge \mathbf{n}] &= \mathbf{0} & \text{à travers } \Sigma, \\ [\mathbf{H} \cdot \mathbf{n}] &= -\mathbf{M} \cdot \mathbf{n} & \text{à travers } \Sigma, \end{cases} \quad (2.5)$$

avec pour condition à l'infini,

$$\lim_{\substack{|x| \rightarrow +\infty \\ x \in \mathbb{R}^3}} \mathbf{H}(x) = \mathbf{H}_0 = \frac{1}{\mu_0} \mathbf{B}_0. \quad (2.6)$$

En effectuant un « relèvement de la condition à l'infini », on se ramène à un problème où l'inconnue est le champ magnétique induit $\mathbf{H}' = \mathbf{H} - \mathbf{H}_0$: trouver $\mathbf{H}' \in \mathbb{L}^2(\mathbb{R}^3)^3$ solution de

$$\begin{cases} \mathbf{rot} \mathbf{H}' &= \mathbf{0} & \text{dans } \mathbb{R}^3, \\ \operatorname{div} \mathbf{H}' &= 0 & \text{dans } \Omega \text{ et } \Omega', \\ [\mathbf{H}' \wedge \mathbf{n}] &= \mathbf{0} & \text{à travers } \Sigma, \\ [\mathbf{H}' \cdot \mathbf{n}] &= -\mathbf{M} \cdot \mathbf{n} & \text{à travers } \Sigma. \end{cases} \quad (2.7)$$

À l'infini, on a

$$\lim_{\substack{|x| \rightarrow +\infty \\ x \in \mathbb{R}^3}} \mathbf{H}'(x) = \mathbf{0}. \quad (2.8)$$

Nous allons simplifier le problème (2.7) en faisant une hypothèse supplémentaire sur la loi de comportement (2.4) du milieu Ω . On a

$$\mathbf{M} = \chi_m \mathbf{H} = \chi_m (\mathbf{H}' + \mathbf{H}_0), \quad (2.9)$$

où $\mathbf{H}'$ désigne le champ magnétique induit et $\mathbf{H}_0 = \frac{1}{\mu_0} \mathbf{B}_0$ le champ magnétique inducteur. Pour un milieu paramagnétique, le champ magnétique induit est très faible devant le champ inducteur $\mathbf{H}_0$ (le rapport des intensités est de l'ordre de 10^3). Nous allons donc supposer que

$$\mathbf{M} \approx \mathbf{M}_0 = \chi_m \mathbf{H}_0, \quad (2.10)$$

autrement dit, l'aimantation sera supposée constante dans le milieu Ω et devient une donnée du problème.

La première équation du système (2.7) nous assure qu'il existe une fonction scalaire φ dans un espace fonctionnel adéquat⁽⁴⁾ unique, telle que

$$\mathbf{H}' = -\nabla\varphi. \quad (2.11)$$

La fonction φ est appelée potentiel magnétique scalaire. Le signe $-$ est mis pour se conformer aux conventions usuelles en électromagnétisme. Signalons dès à présent une propriété utile par la suite : le potentiel magnétique est continu dans $\mathbb{R}^3$.

Le potentiel magnétique scalaire est solution du problème suivant déduit de (2.7) : trouver φ tel que

$$\begin{cases} \Delta\varphi = 0 & \text{dans } \Omega, \\ \Delta\varphi = 0 & \text{dans } \Omega', \\ \frac{\partial\varphi}{\partial n}\Big|_{\Omega} - \frac{\partial\varphi}{\partial n}\Big|_{\Omega'} = \chi_m(\mathbf{H}_0 \cdot \mathbf{n}) & \text{à travers } \Sigma. \end{cases} \quad (2.12)$$

On peut démontrer mathématiquement la propriété suivante : le potentiel magnétique φ solution du problème (2.12) vérifie

$$\varphi(x) = \mathcal{O}\left(\frac{1}{\|x\|^2}\right) \quad \text{quand } \|x\| \rightarrow \infty. \quad (2.13)$$

Il s'agit de la traduction d'un résultat bien connu en électromagnétisme : "le champ magnétique induit décroît en $1/r^3$ ".

Réduction à un problème en domaine borné

Si nous souhaitons résoudre le problème (2.12) par une méthode numérique comme la méthode des différences finies ou la méthode des éléments finis, la difficulté principale réside dans le fait que le domaine d'étude, qui est $\mathbb{R}^3$, n'est pas borné.

Différentes approches sont envisageables pour obtenir un problème équivalent au problème (2.12), ou un problème approchant le problème (2.12), posé dans un domaine borné.

- On peut utiliser une transformation géométrique bijective. Le domaine extérieur est alors transformé en un domaine borné et les équations dans le domaine extérieur sont transformées en de nouvelles équations valables dans le domaine borné.⁽⁵⁾
- On peut borner le domaine de calcul en introduisant une frontière artificielle et construire une condition aux limites exacte sur cette frontière à partir d'une formule de représentation intégrale de la solution.⁽⁶⁾
- Il est également possible de tronquer le domaine extérieur en introduisant une frontière artificielle sur laquelle est imposée une condition aux limites approchée rendant compte du comportement à l'infini de la solution.

Nous allons détailler ici la troisième approche. D'après (2.13), le potentiel magnétique tend vers 0 à l'infini ; on peut envisager pour résoudre numériquement le problème de tronquer le domaine extérieur à une certaine distance $r = R$ et d'imposer sur la frontière artificielle introduite la condition aux limites $\varphi = 0$. En général, une telle condition aux limites est trop imprécise. Nous allons utiliser une condition

⁽⁴⁾. Par exemple, l'espace de Sobolev à poids $\mathbb{W}_0^1(\mathbb{R}^3)$.

⁽⁵⁾. On pourra consulter à ce sujet l'article suivant : Y. El Ouazzani, F. Rioux-Damidaou, X. Brunotte, and G. Meunier. *Finite element modeling of unbounded problems : use of a geometrical transformation and comparison with the boundary integral method. IEEE Trans. Magn.*, 32 :1401–1404, 1996.

⁽⁶⁾. Cette approche est détaillée dans la référence suivante pour un problème de magnétostatique similaire au problème (2.12) : S. Balac and G. Caloz *Magnetostatic field computations based on the coupling of finite element and integral representation methods. IEEE Trans. Magn.* 38(2) :393-396, 2002. [<http://perso.univ-rennes1.fr/stephane.balac/publis/ieee2.pdf>]




FIG. 4 Le domaine de calcul.

aux limites de type Robin, plus précise. Cette condition aux limites est construite à partir du résultat suivant : ⁽⁷⁾ le potentiel magnétique φ solution du problème (2.12) vérifie,

$$\frac{\partial \varphi}{\partial r}(x) + \frac{2}{r}\varphi(x) = \mathcal{O}\left(\frac{1}{r^4}\right) \quad \text{quand } r = \|x\| \rightarrow \infty. \quad (2.14)$$

Pour borner le domaine de calcul, nous introduisons pour frontière artificielle la sphère $S(0, R)$ de centre O et de rayon R . D'après ce qui précède, le potentiel magnétique φ solution du problème (2.12) vérifie sur la frontière artificielle $\Gamma_R = S(0, R)$

$$\frac{\partial \varphi}{\partial r}(x) + \frac{2}{R}\varphi(x) = \mathcal{O}\left(\frac{1}{R^4}\right). \quad (2.15)$$

Nous considérons donc le problème (2.12) posé dans le domaine borné délimité par la sphère Γ_R et imposons sur la frontière artificielle Γ_R la condition aux limites

$$\frac{\partial \phi}{\partial r}(x) + \frac{2}{R}\phi(x) = 0. \quad (2.16)$$

Nous notons B_R la boule ouverte centrée à l'origine, de rayon R et $\Omega'_R = B_R \setminus \overline{\Omega}$. Ainsi $B_R = \Omega'_R \cup \overline{\Omega}$, voir la figure 4. Nous considérons le problème suivant posé dans le domaine borné B_R : trouver ϕ_R tel que

$$\begin{cases} \Delta \phi_R = 0 & \text{dans } \Omega \text{ et dans } \Omega'_R, \\ \left[\frac{\partial \phi_R}{\partial n} \right] = g = \chi_m \mathbf{H}_0 \cdot \mathbf{n} & \text{à travers } \Sigma, \\ \frac{\partial \phi_R}{\partial r}(x) + \frac{2}{R}\phi_R(x) = 0 & \text{sur } \Gamma_R \end{cases} \quad (2.17)$$

D'un point de vue pratique, se pose la question de savoir à quelle distance placer la frontière artificielle servant à borner le domaine de calcul. Placée trop près de Ω , elle aura une influence non négligeable sur la qualité de l'approximation de la solution. Placée trop loin de Ω , elle induira des calculs inutiles dans une zone étendue. La question est difficile à traiter. On peut néanmoins se baser sur quelques résultats théoriques d'estimation d'erreur. Intéressons nous à l'erreur commise en tronquant le domaine à l'aide

⁽⁷⁾. Voir la référence suivante p. 39 : S. Balac. *Artefacts de susceptibilité magnétique en IRM : étude du problème de magnétostatique et simulation numérique*. Thèse de l'Université de Rennes 1, 1997. [<http://perso.univ-rennes1.fr/stephane.balac/fichiers/these.pdf>]

d'une sphère Γ_R de rayon R et en y imposant la condition aux limites (2.16). On a l'estimation ponctuelle de l'erreur $e_R(x) = \varphi(x) - \phi_R(x)$ suivante : ⁽⁸⁾ il existe une constante C indépendante de R , telle que

$$\|e_R\|_{\mathbb{L}^\infty(B_R)} \leq \frac{C}{R^3}.$$

On a également l'estimation d'erreur suivante pour la norme de l'énergie : ⁽⁹⁾ il existe une constante C indépendante de R , telle que

$$\|e_R\|_{\mathbb{L}^2(B_R)} \leq \frac{C}{R^{\frac{3}{2}}} \left(\int_{\Sigma} g^2(y) \, ds \right)^{\frac{1}{2}}.$$

2.1.2 Champ électrique à l'intérieur d'un réservoir partiellement rempli par un hydrocarbure

On considère un hydrocarbure liquide contenu dans un réservoir métallique partiellement rempli. Lors du processus de raffinage, cet hydrocarbure a pu se charger électriquement auquel cas il existe dans le réservoir un potentiel électrique qui peut être important. La partie du réservoir vide d'hydrocarbure étant occupée par des gaz inflammables, la situation est potentiellement dangereuse. On s'intéresse au calcul de ce potentiel électrique. Nous faisons l'hypothèse que le réservoir est de géométrie cylindrique et que la densité volumique de charge dans l'hydrocarbure est constante. ⁽¹⁰⁾

Modélisation du problème physique

Les phénomènes électrostatiques sont décrits à l'aide de deux fonctions vectorielles définies sur $\mathbb{R}^3$, le champ électrique $\mathbf{E}$ et le déplacement électrique $\mathbf{D}$. Ces champs sont liés à la densité de charge ρ par les équations suivantes qui découlent des équations de Maxwell,

$$\begin{cases} \operatorname{rot} \mathbf{E} = 0 \\ \operatorname{div} \mathbf{D} = \rho \end{cases} \quad (2.18)$$

ces équations devant être considérées au sens des distributions.




FIG. 5 La géométrie considérée.

⁽⁸⁾. Voir S. Balac, Thèse de l'Université de Rennes 1 (*op. cit.*), p. 46.

⁽⁹⁾. Voir S. Balac, Thèse de l'Université de Rennes 1 (*op. cit.*), p. 47.

⁽¹⁰⁾. Cette application est proposée dans K. Asano. *Electrostatic potential and field in a cylindrical tank containing charged liquid*. Proc. IEE, vol. 124(12), 1977.

Nous notons Ω_c l'ouvert représentant l'intérieur du réservoir et respectivement Ω_ℓ et Ω_g les ouverts correspondants à la partie de la cuve occupée par le liquide et à la partie occupée par les gaz, voir la figure 5. Nous notons Γ_0 le bord du réservoir et Σ l'interface liquide-gaz.

Le champ électrique $\mathbf{E}$ et le déplacement électrique $\mathbf{D}$ sont des champs de vecteurs réguliers (de classe $\mathcal{C}^\infty$) dans chaque domaine homogène quant à ses propriétés électriques. En supposant l'absence de charge électrique à l'interface entre l'hydrocarbure et les gaz, on déduit de (2.18) que les champs $\mathbf{E}$ et $\mathbf{D}$ solutions de notre problème vérifient les équations suivantes,

$$\begin{cases} \mathbf{rot} \mathbf{E} = 0 & \text{dans } \Omega_\ell \text{ et } \Omega_g \\ \operatorname{div} \mathbf{D} = \rho & \text{dans } \Omega_\ell \\ \operatorname{div} \mathbf{D} = 0 & \text{dans } \Omega_g \\ [\mathbf{D} \cdot \mathbf{n}] = 0 & \text{à travers } \Sigma \\ [\mathbf{E} \wedge \mathbf{n}] = 0 & \text{à travers } \Sigma \end{cases} \quad (2.19)$$

où $[u]$ désigne le saut de la quantité u à travers l'interface Σ , i.e. $[u] = u|_{\Omega_\ell} - u|_{\Omega_g}$.

Le réservoir étant supposé relié à la masse, on a les conditions aux limites suivantes sur le bord Γ_0 du réservoir,

$$\begin{cases} \mathbf{E} \wedge \mathbf{n} = 0 \\ \mathbf{D} \cdot \mathbf{n} = 0 \end{cases} \quad (2.20)$$

Par ailleurs, les champs $\mathbf{E}$ et $\mathbf{D}$ sont liés dans chacun des milieux Ω_ℓ et Ω_g par une relation, appelée *loi de comportement*, que l'on obtient par des considérations physiques et qui décrit les propriétés électriques des milieux. Nous supposons que l'hydrocarbure est un milieu électrique parfait (homogène et isotrope) pour lequel on a une loi de comportement de la forme

$$\mathbf{D} = \epsilon_0 \epsilon_\ell \mathbf{E}, \quad (2.21)$$

où $\epsilon_0 = 8.85410^{-12} F/m$ est la permittivité électrique du vide et où ϵ_ℓ est la permittivité électrique relative de l'hydrocarbure. La valeur de ϵ_ℓ est en général voisine de 2 pour un hydrocarbure. Nous supposons que dans la partie formée par le gaz nous avons une loi de comportement de la forme

$$\mathbf{D} = \epsilon_0 \mathbf{E}. \quad (2.22)$$

En utilisant les relations (2.21) et (2.22), nous pouvons formuler le problème (2.19) à l'aide de la seule inconnue $\mathbf{E}$. On cherche $\mathbf{E}$ vérifiant

$$\begin{cases} \mathbf{rot} \mathbf{E} = 0 & \text{dans } \Omega_\ell \text{ et } \Omega_g \\ \operatorname{div} \mathbf{E} = \frac{\rho}{\epsilon_\ell} & \text{dans } \Omega_\ell \\ \operatorname{div} \mathbf{E} = 0 & \text{dans } \Omega_g \\ [\epsilon \mathbf{E} \cdot \mathbf{n}] = 0 & \text{à travers } \Sigma \\ \mathbf{E} \wedge \mathbf{n} = 0 & \text{sur } \Gamma_0 \\ \mathbf{E} \cdot \mathbf{n} = 0 & \text{sur } \Gamma_0 \end{cases} \quad (2.23)$$

Il est assez naturel d'imposer à $\mathbf{E}$ d'appartenir à l'espace $\mathbb{L}^2(\Omega_c)$ des fonctions de carré sommable, traduisant ainsi le fait que l'énergie électrique dans le dispositif est finie. Le champ électrique $\mathbf{E} \in \mathbb{L}^2(\Omega_c)$ vérifie $\mathbf{rot} \mathbf{E} = 0$ dans Ω_c . D'après le « Lemme de Poincaré dans un ouvert borné », voir [6], on en déduit qu'il existe une fonction φ continue dans $\overline{\Omega_c}$, unique à une constante additive près, telle que $\mathbf{E} = -\nabla \varphi$. Cette fonction φ est le potentiel électrique. On vérifie aisément qu'il est solution du problème suivant issu

de (2.23),

$$\begin{cases} \Delta\varphi = 0 & \text{dans } \Omega_g \\ \Delta\varphi = -\frac{\rho}{\epsilon_\ell} & \text{dans } \Omega_\ell \\ \left[\epsilon \frac{\partial\varphi}{\partial n} \right] = 0 & \text{à travers } \Sigma \\ \varphi = 0 & \text{sur } \Gamma_0 \end{cases} \quad (2.24)$$

Formulation du problème sous l'hypothèse d'axisymétrie

Dans la situation considérée ici, le domaine Ω_c possède une symétrie cylindrique. Il est possible de tirer partie de cette symétrie pour transformer le problème (2.24) pour l'inconnue φ posé dans un domaine tridimensionnel en un problème équivalent posé dans un domaine bidimensionnel.

Considérons un système de coordonnées cylindriques (r, θ, z) avec son repère naturel associé $(\mathbf{e}_r, \mathbf{e}_\theta, \mathbf{e}_z)$. Le domaine étant à géométrie cylindrique et les données étant indépendantes de la variable angulaire θ , le potentiel électrique φ solution du problème (2.24) ne dépend que des variables r et z dans la base des coordonnées cylindriques.




FIG. 6 Le domaine bidimensionnel.

On associe au potentiel φ la fonction ϕ définie sur $\mathbb{R}^+ \times \mathbb{R}$ par

$$\phi(r, z) = \varphi(r \cos \theta_0, r \sin \theta_0, z) \quad \text{avec } \theta_0 \in [0, 2\pi] \text{ fixé.} \quad (2.25)$$

Notons respectivement $\tilde{\Omega}_c$, $\tilde{\Omega}_g$ et $\tilde{\Omega}_\ell$ la trace dans le plan azimutal des ouverts Ω_c , Ω_g et Ω_ℓ et $\tilde{\Sigma}$, $\tilde{\Gamma}_0$ la trace des surfaces Σ et Γ_0 , voir la figure 6. On désigne par $\tilde{\Gamma}_1$ l'axe de symétrie du réservoir.

En utilisant l'expression du laplacien en coordonnées cylindriques et la relation (2.25), on obtient le

problème suivant issu de (2.24) pour le potentiel ϕ ,

$$\left\{ \begin{array}{ll} \frac{1}{r} \frac{\partial}{\partial r} \left(r \frac{\partial \phi}{\partial r} \right) + \frac{\partial^2 \phi}{\partial z^2} = 0 & \text{dans } \tilde{\Omega}_g \\ \frac{1}{r} \frac{\partial}{\partial r} \left(r \frac{\partial \phi}{\partial r} \right) + \frac{\partial^2 \phi}{\partial z^2} = -\frac{\rho}{\epsilon_\ell} & \text{dans } \tilde{\Omega}_\ell \\ \left[\epsilon \frac{\partial \phi}{\partial n} \right] = 0 & \text{à travers } \tilde{\Sigma} \\ [\phi] = 0 & \text{à travers } \tilde{\Sigma} \\ \phi = 0 & \text{sur } \tilde{\Gamma}_0 \end{array} \right. \quad (2.26)$$

Sur la frontière $\tilde{\Gamma}_1$ qui est axe de symétrie, on impose la condition de Neumann,

$$\frac{\partial \phi}{\partial r} = 0.$$

On peut remarquer que le problème (2.24) est posé dans un domaine tridimensionnel avec un opérateur différentiel qui est le laplacien alors que le problème (2.26) est posé dans un domaine bidimensionnel mais avec un opérateur différentiel un peu moins simple à discrétiser. Du point de vue mise en œuvre numérique, le gain en terme de facilité de mise en oeuvre informatique et de temps de calcul est néanmoins appréciable.

2.1.3 Un problème de thermique stationnaire




FIG. 7 Plaque considérée pour le problème de thermique stationnaire.

Nous considérons une plaque de faible épaisseur dont la température est imposée à sa base. Nous cherchons à étudier la distribution de température dans la plaque une fois l'équilibre thermique établi. Compte tenu de la faible épaisseur de la plaque, nous supposons que la température est constante dans son épaisseur. On peut donc considérer que la plaque occupe un domaine rectangulaire Ω dans le plan. Nous nous intéressons à la situation où la température de la plaque est imposée sur la partie Γ_1 du bord et que les autres parties du bord, notées Γ_2 , sont isolées thermiquement ; il n'y a pas de transfert de chaleur à travers Γ_2 . Nous supposons également que la plaque est placée dans l'air ambiant et que celui-ci est à une température notée T_a . Nous supposons que des échanges de chaleur entre la plaque et le milieu ambiant ont lieu à la fois par convection et par radiation.

— La quantité de chaleur, par unité de surface, échangée par convection avec le milieu ambiant à travers les 2 faces de la plaque, notée Q_c , s'exprime sous la forme

$$Q_c = h_c(T - T_a),$$

où T_a désigne la température ambiante, T la température en un point donné de la plaque et h_c est le coefficient de convection thermique.

- La quantité de chaleur, par unité de surface, échangée par radiation avec le milieu ambiant à travers les 2 faces de la plaque, notée Q_r , s'exprime sous la forme

$$Q_r = \epsilon\sigma(T^4 - T_a^4),$$

où ϵ est le coefficient d'émissivité thermique et σ est la constante de Stefan-Boltzmann ($\sigma = 5.670\,373 \cdot 10^{-8} \text{ W} \cdot \text{m}^{-2} \cdot \text{K}^{-4}$).

Pour le cuivre, nous avons par exemple

- conductivité thermique en $\text{W}/(\text{mK})$: $k = 400$
- coefficient de convection thermique en $\text{W}/(\text{m}^2\text{K})$: $h_c = 1$
- coefficient d'émissivité thermique : $\epsilon = 0.5$

Une fois le régime d'équilibre thermique établi dans la plaque, la température dans la plaque est régie par l'équation aux dérivées partielles

$$-ke_z\Delta T + 2Q_c + 2Q_r = 0$$

où e_z est l'épaisseur de la plaque et le facteur 2 devant les contributions liées aux échanges par convection et par radiation est mis pour prendre en compte les transferts par les 2 faces de la plaque. Le problème aux limites se formule donc ainsi : trouver $T : \bar{\Omega} \mapsto \mathbb{R}$ tel que

$$\left\{ \begin{array}{ll} -ke_z\Delta T + 2h_c(T - T_a) + 2\epsilon\sigma(T^4 - T_a^4) = 0 & \text{dans } \Omega \\ T = T_b & \text{sur } \Gamma_1 \\ \frac{\partial T}{\partial n} = 0 & \text{sur } \Gamma_2 \end{array} \right. \quad (2.27)$$

Ce problème est un problème aux limites non linéaire. Dans le cas où la quantité de chaleur échangée par radiation avec le milieu ambiant est négligeable par rapport aux échanges par convection, nous obtenons le problème aux limites linéaire suivant :

$$\left\{ \begin{array}{ll} -ke_z\Delta T + 2h_c(T - T_a) = 0 & \text{dans } \Omega \\ T = T_b & \text{sur } \Gamma_1 \\ \frac{\partial T}{\partial n} = 0 & \text{sur } \Gamma_2 \end{array} \right. \quad (2.28)$$

2.2 Etude d'un problème modèle

2.2.1 Formulation du problème

Commençons par un peu de terminologie.

On appelle *domaine* de $\mathbb{R}^2$ (resp. de $\mathbb{R}^3$), un ouvert Ω de $\mathbb{R}^2$ (resp. de $\mathbb{R}^3$), connexe (*i.e.* d'un seul tenant). Nous supposons dans ce chapitre que ce domaine est borné et « régulier », c'est-à-dire que le bord Σ de l'ouvert Ω est « paramétrisable » par une fonction régulière, par exemple de classe $\mathcal{C}^1$. Le bord de Σ de l'ouvert Ω pourra être « régulier par morceaux », c'est-à-dire admettre une partition en morceaux qui sont réguliers, ce qui inclut la possibilité d'un nombre finis de points (resp. d'arêtes) pour lesquels il peut y avoir présence de coins d'angle non nuls.

DÉFINITION 2.1 On se place sous les hypothèses données en préambule concernant la régularité de l'ouvert Ω .

✂ On appelle *normale au domaine Ω de $\mathbb{R}^d$* , un champ de vecteur $\mathbf{n}$ défini sur le bord Σ de Ω tel qu'en tout point x de Σ où le bord est régulier, le vecteur $\mathbf{n}(x)$ de $\mathbb{R}^d$ est orthogonal au bord et de norme euclidienne égale à 1.

✂ On appelle *normale extérieure au domaine Ω de $\mathbb{R}^d$* , une normale au domaine Ω tel que en tout point x de Σ où le bord est régulier, le vecteur $\mathbf{n}(x)$ est orienté vers « l'extérieur » du domaine Ω .

✂ Étant donnée une fonction u de classe $\mathcal{C}^1$ sur $\overline{\Omega}$, on appelle *dérivée normale de u sur le bord Σ de Ω de $\mathbb{R}^d$* , la fonction définie, en tout point x de Σ où le bord est régulier, par

$$\frac{\partial u}{\partial n}(x) = \nabla u(x) \cdot \mathbf{n}(x)$$

où $\mathbf{n}$ désigne la normale extérieure au domaine Ω .

Dans la suite de ce chapitre nous focaliserons notre étude sur le problème modèle que nous décrivons dans cette partie. On note Ω l'ouvert $]0, 1[\times]0, 1[$. La frontière Σ de l'ouvert Ω est constituée de deux morceaux Σ_0 et Σ_1 disjoints formés à partir des quatre cotés $\Gamma_1 =]0, 1[\times \{0\}$, $\Gamma_2 = \{1\} \times]0, 1[$, $\Gamma_3 =]0, 1[\times \{1\}$ et $\Gamma_4 = \{0\} \times]0, 1[$, voir la figure 8. On a donc $\Sigma = \Sigma_0 \cup \Sigma_1 = \Gamma_1 \cup \Gamma_2 \cup \Gamma_3 \cup \Gamma_4$ et éventuellement $\Sigma_0 = \emptyset$ ou $\Sigma_1 = \emptyset$.




FIG. 8 Domaine géométrique associé au problème modèle.

Étant données les fonctions f et a_0 continues sur $\overline{\Omega}$, f_1 continue sur Σ_1 et u_0 continue sur Σ_0 , on cherche à résoudre le problème suivant : trouver $u \in \mathcal{C}^2(\overline{\Omega})$ tel que

$$(\mathcal{P}) \quad \begin{cases} -\Delta u + a_0 u = f & \text{dans } \Omega \\ \frac{\partial u}{\partial n} = f_1 & \text{sur } \Sigma_1 \\ u = u_0 & \text{sur } \Sigma_0 \end{cases} \quad (2.29)$$

Un tel problème est qualifié de *problème aux limites de Dirichlet-Neumann*. La condition sur le bord $u = u_0$ est qualifiée de *condition aux limites de Dirichlet*. Elle consiste à imposer sur une partie de la frontière du domaine les valeurs de la solution. La condition sur le bord $\frac{\partial u}{\partial n} = f_1$ est qualifiée de *condition aux limites de Neumann*.⁽¹¹⁾

Signalons que notre problème modèle inclut les deux situations particulières suivantes.

⁽¹¹⁾. Carl Gottfried Neumann (7 mai 1832 à Königsberg - 27 mars 1925 à Leipzig) est un mathématicien allemand. Il fut l'un des pionniers de la théorie des équations intégrales.

LEJEUNE DIRICHLET, Johann Peter Gustav (1805, Düren - 1859, Göttingen).



Mathématicien allemand. Dirichlet vint en France pour suivre ses études supérieures où il fut en contact avec les plus grands mathématiciens français de l'époque, dont Legendre, Laplace ou Fourier. Il retourna ensuite en 1825 en Allemagne où il travailla avec Gauss, dont il reprendra la chaire à l'Université de Göttingen, et avec Jacobi. Il eut entre autres comme élève Riemann. Les travaux de Dirichlet ont surtout porté sur les séries de Fourier et l'arithmétique, où on lui doit l'essentiel de la démonstration du dernier théorème de Fermat pour le cas où l'exposant est égal à 5.

Le cas $\Sigma_0 = \emptyset$ où le problème $(\mathcal{P})$ consiste à trouver $u \in \mathcal{C}^2(\Omega) \cap \mathcal{C}^1(\overline{\Omega})$ tel que

$$(\mathcal{P}_N) \quad \begin{cases} -\Delta u + a_0 u = f & \text{dans } \Omega \\ \frac{\partial u}{\partial n} = f_1 & \text{sur } \Sigma \end{cases} \quad (2.30)$$

Ce problème aux limites est qualifié de *problème de Neumann*.

Le cas $\Sigma_1 = \emptyset$ où le problème $(\mathcal{P})$ consiste à trouver $u \in \mathcal{C}^2(\Omega) \cap \mathcal{C}^0(\overline{\Omega})$ tel que

$$(\mathcal{P}_D) \quad \begin{cases} -\Delta u + a_0 u = f & \text{dans } \Omega \\ u = u_0 & \text{sur } \Sigma \end{cases} \quad (2.31)$$

Ce problème aux limites est qualifié de *problème de Dirichlet*.

2.2.2 Principe du Maximum

Nous désignons par $\mathcal{L}$ l'opérateur linéaire de $\mathcal{C}^2(\Omega)$ dans $\mathcal{C}^0(\Omega)$ défini par

$$\forall x \in \Omega \quad \mathcal{L}v(x) = -\Delta v(x) + a_0(x)v(x). \quad (2.32)$$

THÉORÈME 2.1 (Principe du maximum)

Soit Ω un ouvert borné de $\mathbb{R}^d$, connexe, de frontière Σ régulière. Soit $v \in \mathcal{C}^2(\Omega) \cap \mathcal{C}^0(\overline{\Omega})$ tel que pour tout $x \in \Omega$ on ait $\mathcal{L}v(x) \leq 0$.

- Si $a_0 = 0$ alors pour tout $x \in \Omega$, on a $v(x) \leq \max_{x \in \Sigma} v(x)$.
- Si $a_0 \geq 0$ alors, pour tout $x \in \Omega$, on a $v(x) \leq \max(0, \max_{x \in \Sigma} v(x))$.

Démonstration On procède par disjonction de cas.

$\geq$ On s'intéresse tout d'abord au cas particulier où $a_0 = 0$ et on considère une fonction $v \in \mathcal{C}^2(\Omega) \cap \mathcal{C}^0(\overline{\Omega})$ telle que pour tout $x \in \Omega$ on ait $\mathcal{L}v(x) = -\Delta v(x) < 0$. Nous allons montrer que pour tout $x \in \Omega$, on a $v(x) \leq \max_{x \in \Sigma} v(x)$ en raisonnant par l'absurde. Supposons qu'il existe $\zeta = (\zeta_1, \zeta_2) \in \Omega$ tel que $v(\zeta) = \max_{x \in \overline{\Omega}} v(x)$, autrement dit que la fonction v réalise son maximum à l'intérieur du domaine considéré en un point ζ . On a dans ce cas

$$\frac{\partial v}{\partial x_1}(\zeta_1, \zeta_2) = \frac{\partial v}{\partial x_2}(\zeta_1, \zeta_2) = 0.$$

Comme $\mathcal{L}v(\zeta) = -\Delta v(\zeta) < 0$, on a nécessairement soit $\frac{\partial^2 v}{\partial x_1^2}(\zeta_1, \zeta_2) > 0$, soit $\frac{\partial^2 v}{\partial x_2^2}(\zeta_1, \zeta_2) > 0$. Supposons que $\frac{\partial^2 v}{\partial x_1^2}(\zeta_1, \zeta_2) > 0$; le même raisonnement s'applique dans l'autre cas. Comme v est de classe $\mathcal{C}^2$ sur Ω , il

existe une boule de centre ζ et de rayon R telle que l'on ait $\frac{\partial^2 v}{\partial x_1^2}(x_1, x_2) > 0$ pour tout $x \in B(\zeta, R)$. Pour $h > 0$ assez petit, le point $x = (\zeta_1 + h, \zeta_2)$ appartient à $B(\zeta, R)$ et, d'après la formule de Taylor-Lagrange, il existe $\theta \in]0, 1[$ tel que

$$v(\zeta_1 + h, \zeta_2) = v(\zeta_1, \zeta_2) + h \frac{\partial v}{\partial x_1}(\zeta_1, \zeta_2) + \frac{h^2}{2} \frac{\partial^2 v}{\partial x_1^2}(\zeta_1 + \theta h, \zeta_2).$$

On a $\frac{\partial v}{\partial x_1}(\zeta_1, \zeta_2) = 0$ et, comme le point $(\zeta_1 + \theta h, \zeta_2)$ est dans $B(\zeta, R)$, on a $\frac{\partial^2 v}{\partial x_1^2}(\zeta_1 + \theta h, \zeta_2) > 0$. Comme $v(\zeta_1, \zeta_2) = \max_{x \in \bar{\Omega}} v(x)$, on en déduit que $v(\zeta_1 + h, \zeta_2)$ est supérieur à la valeur maximale de v sur $\bar{\Omega}$, ce qui est clairement impossible. On aboutit à une contradiction.

$\supseteq$ Toujours dans le cas particulier où $a_0 = 0$, considérons une fonction $v \in \mathcal{C}^2(\Omega) \cap \mathcal{C}^0(\bar{\Omega})$ telle que pour tout $x \in \Omega$ on ait $\mathcal{L}v(x) = -\Delta v(x) \leq 0$. Étant donné un réel strictement positif ε , considérons la fonction v_ε définie sur $\bar{\Omega}$ par $v_\varepsilon(x_1, x_2) = v(x_1, x_2) - \varepsilon e^{x_1 + x_2}$. Pour tout $x = (x_1, x_2) \in \Omega$, on a

$$\mathcal{L}v_\varepsilon(x_1, x_2) = -\Delta v_\varepsilon(x_1, x_2) = \underbrace{-\Delta v(x_1, x_2)}_{\leq 0} - \underbrace{\varepsilon e^{x_1 + x_2}}_{> 0} < 0.$$

On peut donc appliquer la première partie de la démonstration à la fonction v_ε : il en résulte que pour tout $x \in \Omega$, on a

$$v_\varepsilon(x) \leq \max_{x \in \Sigma} v_\varepsilon(x) = \max_{(x_1, x_2) \in \Sigma} (v(x_1, x_2) - \underbrace{\varepsilon e^{x_1 + x_2}}_{> 0}) \leq \max_{(x_1, x_2) \in \Sigma} v(x_1, x_2).$$

En passant à la limite quand ε tend vers 0, l'inégalité est respectée et on obtient

$$v(x) = \lim_{\substack{\varepsilon \rightarrow 0 \\ \varepsilon > 0}} v_\varepsilon(x) \leq \max_{x \in \Sigma} v(x).$$

On a donc établi la première assertion de la proposition : si $a_0 = 0$ alors pour tout $x \in \Omega$, on a $v(x) \leq \max_{x \in \Sigma} v(x)$.

$\supseteq$ Intéressons nous à présent au cas où la fonction a_0 n'est pas identiquement nulle. Soit $v \in \mathcal{C}^2(\Omega) \cap \mathcal{C}^0(\bar{\Omega})$ telle que pour tout $x \in \Omega$ on ait $\mathcal{L}v(x) = -\Delta v(x) + a_0(x)v(x) \leq 0$. Désignons par m le maximum de la fonction v sur Ω .

Si $m \leq 0$ alors la seconde assertion de la proposition est une évidence : pour tout $x \in \Omega$, on a :

$$v(x) \leq \max_{x \in \Omega} v(x) \leq 0 \leq \max(0, \max_{x \in \Sigma} v(x)).$$

Reste à considérer le cas où $m > 0$. Soit $\Omega_+ = \{x \in \Omega ; v(x) > 0\}$. On a bien entendu $m = \max_{x \in \Omega} v(x) = \max_{x \in \Omega_+} v(x)$. Comme Ω est ouvert et que v est continue sur Ω , l'ensemble Ω_+ est ouvert. Il n'est pas vide car $m = \max_{x \in \Omega} v(x) > 0$. De plus, comme v est continue sur Ω , la frontière de Ω_+ , que nous notons Σ_+ correspond à des points x pour lesquels $v(x) = 0$ ou à des points appartenant à la frontière Σ de Ω . Pour tout $x \in \Omega_+$, on a

$$\mathcal{L}v(x) = -\Delta v(x) + \underbrace{a_0(x)v(x)}_{\geq 0} \leq 0.$$

On a donc $-\Delta v(x) \leq 0$ pour tout $x \in \Omega_+$. On se retrouve donc dans la situation précédente avec un ouvert qui est Ω_+ . On en déduit que

$$\max_{x \in \Omega_+} v(x) \leq \max_{x \in \Sigma_+} v(x).$$

Comme $\Sigma_+ \subset \{x \in \Omega ; v(x) = 0\} \cup \Sigma$, on a $\max_{x \in \Sigma_+} v(x) \leq \max(0, \max_{x \in \Sigma} v(x))$. On en conclut que

$$m = \max_{x \in \Omega} v(x) = \max_{x \in \Omega_+} v(x) \leq \max_{x \in \Sigma_+} v(x) \leq \max(0, \max_{x \in \Sigma} v(x)).$$

Le théorème est démontré. $\square$

2.2.3 Étude du problème de Dirichlet

Le principe du maximum permet d'établir l'estimation *a priori* suivante de la solution du problème de Dirichlet (2.31). Les résultats de cette partie sont valables pour un ouvert Ω borné et connexe quelconque, de frontière Σ régulière.

PROPOSITION 2.1 Soit $u \in \mathcal{C}^2(\Omega) \cap \mathcal{C}^0(\overline{\Omega})$ une solution du problème de Dirichlet (2.31) sous les hypothèses suivantes :

- f est une fonction continue sur $\overline{\Omega}$;
- u_0 est une fonction continue sur Σ ;
- a_0 est une fonction continue sur $\overline{\Omega}$ et est positive.

Il existe un réel $C > 0$ tel que

$$\|u\|_{\infty, \Omega} \leq C \|f\|_{\infty, \Omega} + \|u_0\|_{\infty, \Sigma}$$

où $\|f\|_{\infty, \Omega} = \sup_{x \in \Omega} |f(x)|$ et $\|u_0\|_{\infty, \Sigma} = \sup_{x \in \Sigma} |u_0(x)|$.

Démonstration L'ouvert Ω étant borné, il existe un réel $R > 0$ tel que Ω soit inclus dans la boule $B(0, R)$. Considérons la fonction $v \in \mathcal{C}^\infty(\overline{\Omega})$ définie par

$$\forall x = (x_1, x_2) \in \overline{\Omega} \quad v(x_1, x_2) = \frac{1}{4} (R^2 - (x_1^2 + x_2^2)) \|f\|_{\infty, \Omega} + \|u_0\|_{\infty, \Sigma}.$$

Il s'agit d'une fonction positive telle que $v(x) \geq \|u_0\|_{\infty, \Sigma}$ pour tout $x \in \Sigma$. De plus, pour tout $x \in \Omega$,

$$\mathcal{L}v(x) = -\Delta v(x) + a_0(x) v(x) = \|f\|_{\infty, \Omega} + a_0(x) v(x) \geq \|f\|_{\infty, \Omega}.$$

$\supseteq$ Par conséquent, la fonction $u - v \in \mathcal{C}^2(\Omega) \cap \mathcal{C}^0(\overline{\Omega})$ vérifie

$$\mathcal{L}(u - v) = \mathcal{L}u - \mathcal{L}v = f - \mathcal{L}v \leq f - \|f\|_{\infty, \Omega} \leq 0.$$

D'après le principe du maximum, on en déduit que

$$\forall x \in \Omega \quad (u - v)(x) \leq \max \left(0, \max_{x \in \Sigma} (u - v)(x) \right). \quad (2.33)$$

Or, pour tout $x \in \Sigma$, on a $(u - v)(x) = u_0(x) - v(x) \leq u_0(x) - \|u_0\|_{\infty, \Sigma} \leq 0$. On déduit donc de (2.33) que $u(x) \leq v(x)$ pour tout $x \in \Omega$.

$\supseteq$ Considérons à présent la fonction $-u - v \in \mathcal{C}^2(\Omega) \cap \mathcal{C}^0(\overline{\Omega})$. Elle vérifie

$$\mathcal{L}(-u - v) = -\mathcal{L}u - \mathcal{L}v = -f - \mathcal{L}v \leq -f - \|f\|_{\infty, \Omega} \leq 0.$$

D'après le principe du maximum, on en déduit que

$$\forall x \in \Omega \quad (-u - v)(x) \leq \max \left(0, \max_{\zeta \in \Sigma} (-u - v)(\zeta) \right). \quad (2.34)$$

Or, pour tout $x \in \Sigma$, on a $(-u - v)(x) = -u_0(x) - v(x) \leq -u_0(x) - \|u_0\|_{\infty, \Sigma} \leq 0$. On déduit donc de (2.34) que $-u(x) \leq v(x)$ pour tout $x \in \Omega$.

$\supseteq$ Ainsi, pour tout $x \in \Omega$, on a $-v(x) \leq u(x) \leq v(x)$, autrement dit, $|u(x)| \leq v(x)$. On en déduit que

$$|u(x)| \leq \frac{1}{4} (R^2 - (x_1^2 + x_2^2)) \|f\|_{\infty, \Omega} + \|u_0\|_{\infty, \Sigma}$$

et par conséquent,

$$\|u\|_{\infty, \Omega} \leq C \|f\|_{\infty, \Omega} + \|u_0\|_{\infty, \Sigma}$$

où $C = \frac{1}{4} \max_{(x_1, x_2) \in \Omega} (R^2 - (x_1^2 + x_2^2))$. La proposition est démontrée. $\square$

PROPOSITION 2.2 (Unicité de la solution du problème de Dirichlet)

On suppose que

- f est une fonction continue sur $\overline{\Omega}$;
- u_0 est une fonction continue sur Σ ;
- a_0 est une fonction continue sur $\overline{\Omega}$ et est positive.

Si elle existe, la solution du problème de Dirichlet (2.31) est unique.

Démonstration Supposons que le problème de Dirichlet (2.31) admette deux solutions u_1 et u_2 dans $\mathcal{C}^2(\Omega) \cap \mathcal{C}^0(\overline{\Omega})$. La fonction $v = u_1 - u_2$ appartient à $\mathcal{C}^2(\Omega) \cap \mathcal{C}^0(\overline{\Omega})$ et vérifie

$$\begin{cases} -\Delta v + a_0 v = 0 & \text{dans } \Omega \\ v = 0 & \text{sur } \Sigma \end{cases}.$$

Elle est donc solution d'un problème de Dirichlet de la forme étudiée correspondant à un second membre f nul et à une donnée de Dirichlet u_0 elle aussi nulle. D'après la proposition 2.1, il existe $C > 0$ tel que

$$\|v\|_{\infty, \Omega} \leq C \|0\|_{\infty, \Omega} + \|0\|_{\infty, \Sigma} = 0,$$

ce qui implique que $\|v\|_{\infty, \Omega} = 0$ et donc que $v = 0$. On a donc $u_1 = u_2$ et on en conclut que la solution du problème de Dirichlet (2.31) est unique. $\square$

Nous admettons, provisoirement, l'existence d'une solution au problème de Dirichlet dans le cas général. Nous allons néanmoins établir l'existence d'une solution au problème de Dirichlet dans l'ouvert $\Omega =]0, 1[\times]0, 1[$ lorsque a_0 est une fonction constante et f est la fonction nulle en utilisant une méthode de résolution d'une équation aux dérivées partielles appelée *méthode de résolution par variables séparées*.

2.2.4 Recherche d'une solution à variables séparées au problème de Dirichlet

Intéressons-nous à la recherche d'une solution explicite au problème de Dirichlet dans le cas particulier où a_0 et f sont nuls. Dans un premier temps, pour simplifier un peu les choses, nous supposons que la donnée au bord u_0 est de classe $\mathcal{C}^1$, qu'elle vaut g_3 sur le bord Γ_3 d'équation $x_2 = 1$ et qu'elle vaut 0 sur les trois autres cotés. (Nous généraliserons dans un deuxième temps.) Nous considérons donc le problème de Dirichlet suivant : trouver $u \in \mathcal{C}^2(\overline{\Omega})$ tel que

$$\begin{cases} -\Delta u = 0 & \text{dans } \Omega =]0, 1[\times]0, 1[\\ v = 0 & \text{sur } \Gamma_1, \Gamma_2 \text{ et } \Gamma_4 \\ v = g_3 & \text{sur } \Gamma_3 \end{cases}.$$

Compte tenu de la forme particulière de l'ouvert Ω (l'intérieur d'un carré dont les cotés sont parallèles aux axes de coordonnées) et du fait que les données sont constantes, on recherche une solution u du problème de Dirichlet qui soit de la forme

$$u(x_1, x_2) = u_1(x_1) \times u_2(x_2).$$

On parle de fonction à variables séparées. Ainsi, pour tout $(x_1, x_2) \in \Omega$,

$$-\Delta u(x_1, x_2) = -u_1''(x_1) u_2(x_2) - u_1(x_1) u_2''(x_2) = 0.$$

En divisant chaque membre de l'équation par $u(x_1) u(x_2)$ (on suppose pour cela que la solution u ne s'annule pas⁽¹²⁾ sur Ω), on obtient

$$\forall (x_1, x_2) \in \Omega \quad -\frac{u_1''(x_1)}{u_1(x_1)} = \frac{u_2''(x_2)}{u_2(x_2)}. \quad (2.35)$$

⁽¹²⁾. Ce qui pourra être justifié *a posteriori* une fois l'expression de la solution obtenue.

Le membre de gauche de l'équation ne dépend que de x_1 alors que le membre de droite ne dépend que de x_2 . Cela implique que chacun de ces deux termes est constant et égal à une même constante que nous notons λ^2 . De la relation (2.35), on déduit d'une part que

$$\forall x_1 \in]0, 1[\quad u_1''(x_1) + \lambda^2 u_1(x_1) = 0.$$

Cette équation différentielle linéaire du second ordre admet pour solutions :

- $u_1(x_1) = C_1 e^{|\lambda|x_1} + C_1' e^{-|\lambda|x_1}$ si $\lambda^2 < 0$;
- $u_1(x_1) = C_1 x_1 + C_1'$ si $\lambda^2 = 0$;
- $u_1(x_1) = C_1 \cos(|\lambda|x_1) + C_1' \sin(|\lambda|x_1)$ si $\lambda^2 > 0$.

Noter que l'on peut se restreindre à la valeur $|\lambda|$ dans les expressions précédentes compte tenu du fait que les constantes restent indéterminées à ce stade. En considérant l'autre possibilité donnée par $-|\lambda|$, nous obtenons les mêmes expressions. Les valeurs des constantes C_1 et C_1' sont obtenues grâce aux conditions aux limites. Dans notre cas, on a $u_1(0) = 0$ et $u_1(1) = 0$. Si $\lambda^2 < 0$ ou si $\lambda^2 = 0$, ces conditions impliquent que $C_1 = C_1' = 0$ et par conséquent u_1 est la fonction nulle. Si $\lambda^2 > 0$, ces conditions s'écrivent

$$\begin{aligned} C_1 &= 0 \\ C_1 \cos(|\lambda|) + C_1' \sin(|\lambda|) &= 0 \end{aligned}$$

et impliquent que $C_1 = C_1' = 0$ et donc $u_1 = 0$, sauf si $|\lambda|$ est un multiple de π ($|\lambda| = k\pi$, $k \in \mathbb{N}^*$) auquel cas il peut exister des solutions non identiquement nulles qui sont les fonctions u_1 de la forme

$$u_1(x_1) = C_1' \sin(k\pi x_1), \quad \forall C_1' \in \mathbb{R}, \forall k \in \mathbb{N}^*.$$

Pour $|\lambda| = k\pi$, $k \in \mathbb{N}^*$ avec $\lambda^2 > 0$, on a $\lambda = \pm k\pi$ et on déduit de la relation (2.35), que

$$\forall x_2 \in]0, 1[\quad u_2''(x_2) - (k\pi)^2 u_2(x_2) = 0.$$

Cette équation différentielle linéaire du second ordre admet pour solutions :

$$u_2 : x_2 \in [0, 1] \mapsto C_2 e^{k\pi x_2} + C_2' e^{-k\pi x_2}$$

où les valeurs des constantes C_2 et C_2' sont obtenues grâce aux conditions aux limites. La condition $u_2(0) = 0$ impose que $C_2' = -C_2$ et par conséquent les solutions s'écrivent

$$u_2(x_2) = C_2 (e^{k\pi x_2} - e^{-k\pi x_2}) = 2C_2 \operatorname{sh}(k\pi x_2), \quad \forall C_2 \in \mathbb{R}, \forall k \in \mathbb{N}^*.$$

Les solutions à variables séparées de l'équation de Laplace $\Delta u = 0$ dans Ω qui s'annulent sur les bords Γ_1, Γ_2 et Γ_4 sont donc toutes les fonctions de la forme

$$u_k : (x_1, x_2) \in \overline{\Omega} \mapsto C_k \operatorname{sh}(k\pi x_2) \sin(k\pi x_1), \quad \forall C_k \in \mathbb{R}, \forall k \in \mathbb{N}^*.$$

Par linéarité, on obtient encore une solution en les sommant toutes. Ainsi, la fonction suivante est solution de l'équation de Laplace⁽¹³⁾ :

$$u : (x_1, x_2) \in \overline{\Omega} \mapsto \sum_{k=1}^{+\infty} C_k \operatorname{sh}(k\pi x_2) \sin(k\pi x_1).$$

Cette expression reste formelle tant que la convergence de la série n'est pas établie. Cette convergence ne peut être étudiée qu'une fois l'expression des coefficients C_k connue.

Intéressons-nous à présent à la condition aux limites sur Γ_3 qui s'écrit $u(x_1, 1) = g_3(x_1)$ pour tout $x_1 \in [0, 1]$. On doit donc avoir

$$\forall x_1 \in [0, 1] \quad \sum_{k=1}^{+\infty} C_k \operatorname{sh}(k\pi) \sin(k\pi x_1) = g_3(x_1).$$

(13). Sous réserve que la série converge.

La série formant le membre de droite de cette équation est une série de Fourier d'une fonction impaire.⁽¹⁴⁾ Considérons donc la fonction $\tilde{g}_3$ impaire et périodique de période 2 égale à g_3 en restriction à l'intervalle $[0, 1]$. La série de Fourier de $\tilde{g}_3$ s'écrit⁽¹⁵⁾

$$\sum_{k=1}^{+\infty} b_k \sin(k\pi x_1) \quad \text{où} \quad b_k = \int_0^2 \tilde{g}_3(x_1) \sin(k\pi x_1) dx_1 = 2 \int_0^1 g_3(x_1) \sin(k\pi x_1) dx_1.$$

Comme g_3 est supposée de classe $\mathcal{C}^1$ sur $[0, 1]$, $\tilde{g}_3$ est de classe $\mathcal{C}^1$ par morceaux sur $\mathbb{R}$ et d'après le théorème de Dirichlet⁽¹⁶⁾ la série de Fourier de $\tilde{g}_3$ converge en tout $x_1 \in]0, 1[$ vers $g_3(x_1)$. On a donc

$$\forall x_1 \in [0, 1] \quad g_3(x_1) = \sum_{k=1}^{+\infty} C_k \operatorname{sh}(k\pi) \sin(k\pi x_1) = \sum_{k=1}^{+\infty} b_k \sin(k\pi x_1),$$

ce qui, par unicité de la série de Fourier d'une application, implique que

$$\forall k \in \mathbb{N}^* \quad C_k = \frac{1}{\operatorname{sh}(k\pi)} b_k = \frac{2}{\operatorname{sh}(k\pi)} \int_0^1 g_3(x_1) \sin(k\pi x_1) dx_1.$$

On en conclut que la solution à variables séparées de l'équation de Laplace $\Delta u = 0$ dans Ω et s'annulant sur les bords Γ_1, Γ_2 et Γ_4 et valant g_3 sur Γ_3 est la fonction u définie par

$$u(x_1, x_2) = \sum_{k=1}^{+\infty} C_k \operatorname{sh}(k\pi x_2) \sin(k\pi x_1) \quad \text{où} \quad \forall k \in \mathbb{N}^* \quad C_k = \frac{2}{\operatorname{sh}(k\pi)} \int_0^1 g_3(x_1) \sin(k\pi x_1) dx_1.$$

Pour être complet, il reste à établir que la série $\sum_k C_k \operatorname{sh}(k\pi x_2) \sin(k\pi x_1)$ converge pour tout $(x_1, x_2) \in \bar{\Omega}$. Pour tout $(x_1, x_2) \in \Omega$ fixé, on a

$$|C_k \operatorname{sh}(k\pi x_2) \sin(k\pi x_1)| \leq 2 \frac{\operatorname{sh}(k\pi x_2)}{\operatorname{sh}(k\pi)} \underbrace{|\sin(k\pi x_1)|}_{\leq 1} \int_0^1 |g_3(x_1)| \underbrace{|\sin(k\pi x_1)|}_{\leq 1} dx_1 \leq 2A \frac{\operatorname{sh}(k\pi x_2)}{\operatorname{sh}(k\pi)}$$

où $A = \int_0^1 |g_3(x_1)| dx_1$. Or, $\operatorname{sh}(k\pi x_2) \underset{k \rightarrow +\infty}{\sim} \frac{1}{2} e^{k\pi x_2}$ et $\operatorname{sh}(k\pi) \underset{k \rightarrow +\infty}{\sim} \frac{1}{2} e^{k\pi}$, de sorte que

$$\frac{\operatorname{sh}(k\pi x_2)}{\operatorname{sh}(k\pi)} \underset{k \rightarrow +\infty}{\sim} \frac{e^{k\pi x_2}}{e^{k\pi}} = e^{k\pi(x_2-1)}.$$

Comme $x_2 \in]0, 1[$, on a $x_2 - 1 < 0$ et par conséquent, la série numérique de terme général $e^{k\pi(x_2-1)}$ converge. (On peut l'établir aisément en utilisant la Règle de D'Alembert.⁽¹⁷⁾) Les critères de comparaison⁽¹⁸⁾ pour les séries numériques, permettent de conclure que la série $\sum_k C_k \operatorname{sh}(k\pi x_2) \sin(k\pi x_1)$ converge pour tout $(x_1, x_2) \in \Omega$. Reste à considérer la convergence pour $(x_1, x_2) \in \Sigma$. Pour Γ_1, Γ_2 et Γ_4 , on a soit $x_1 = 0$, soit $x_1 = 1$, soit $x_2 = 0$ donc la série est la série nulle : elle converge vers la fonction nulle qui correspond à la donnée de Dirichlet sur ces bords. Pour $(x_1, x_2) \in \Gamma_3$, $x_2 = 1$ et la série $\sum_k C_k \operatorname{sh}(k\pi x_2) \sin(k\pi x_1)$ n'est autre que la série de Fourier de $\tilde{g}_3$ dont on a établi qu'elle convergeait vers g_3 pour tout $x_1 \in [0, 1]$.

Extension au problème de Dirichlet complet

On pourra sans trop de difficulté étendre le développement qui vient d'être effectué au cas où la fonction a_0 est une fonction constante.

⁽¹⁴⁾. Voir [3], corollaire 6.1.

⁽¹⁵⁾. Voir [3], section 6.2.

⁽¹⁶⁾. Voir [3], théorème 6.1.

⁽¹⁷⁾. Voir [3], proposition 1.13.

⁽¹⁸⁾. Voir [3], théorème 1.2.

On se convaincra aussi que ce qui vient d'être fait avec une donnée de Dirichlet non nulle sur Γ_3 peut aussi être effectué avec une donnée non nulle sur l'un quelconque des quatre cotés (les trois autres cotés correspondant à une donnée de Dirichlet nulle).

On peut obtenir une solution à variables séparées du problème de Dirichlet « complet » (*i.e.* avec des données de Dirichlet non nulles sur les quatre bords) en remarquant que la somme $u^{(1)} + u^{(2)} + u^{(3)} + u^{(4)}$ où $u^{(\ell)}$ désigne la solution du problème

$$\begin{cases} \Delta u^{(\ell)} = 0 & \text{dans } \Omega \\ u^{(\ell)} = g_\ell & \text{sur } \Gamma_\ell \\ u^{(\ell)} = 0 & \text{sur } \Sigma \setminus \Gamma_\ell \end{cases}$$

est solution du problème

$$\begin{cases} \Delta u = 0 & \text{dans } \Omega \\ u = g_\ell & \text{sur } \Gamma_\ell \text{ pour } \ell = 1, 2, 3, 4 \end{cases}$$

2.3 Approximation du problème modèle par la méthode des différences finies

La méthode des différences finies que nous avons introduite au chapitre 1 pour calculer une approximation de la solution du problème aux limites unidimensionnel modèle peut être généralisée pour approcher la solution du problème aux limites elliptique. Nous nous contenterons ici de montrer comment l'approximation des dérivées partielles par des différences divisées peut permettre de calculer une solution approchée au problème aux limites bidimensionnel modèle (2.29) dans l'ouvert $]0, 1[^2$ de $\mathbb{R}^2$.

2.3.1 Approximation des dérivées partielles

Approximation d'une dérivée partielle première

Considérons une fonction f de $\mathbb{R}^d$ dans $\mathbb{R}$ de classe $\mathcal{C}^1$ sur un ouvert Ω de $\mathbb{R}^d$. En un point $a = (a_1, \dots, a_d)$ de Ω , la fonction f admet des dérivées partielles premières. La i -ième dérivée partielle première de f en a notée $\partial_i f(a)$ ou $\frac{\partial f}{\partial x_i}(a)$ est définie comme la dérivée directionnelle de f en a dans la direction du i -ième vecteur $\mathbf{e}_i$ de la base canonique de $\mathbb{R}^d$ et correspond aussi à la dérivée en a_i de la i -ième fonction partielle de f en a . On a donc

$$\partial_i f(a) = \lim_{\substack{h \rightarrow 0 \\ h \in \mathbb{R}}} \frac{f(a + h \mathbf{e}_i) - f(a)}{h} \quad (2.36)$$

où $f(a + h \mathbf{e}_i) = f(a_1, \dots, a_{i-1}, a_i + h, a_{i+1}, \dots, a_n)$. On peut donc obtenir une valeur approchée de la i -ième dérivée partielle première de f en a en considérant pour une valeur h « assez petite » la quantité

$$\delta_i^{[1p]} f(a) = \frac{f(a + h \mathbf{e}_i) - f(a)}{h}. \quad (2.37)$$

Remarquons que comme a appartient à Ω qui est un ensemble ouvert, on est assuré que pour des valeurs de h suffisamment petites le point $a + h \mathbf{e}_i$ appartient lui aussi à Ω et par conséquent que la quantité $f(a + h \mathbf{e}_i)$ est bien définie.

D'après la formule de Taylor-Young à l'ordre 1, on a

$$f(a + h \mathbf{e}_i) = f(a) + h \partial_i f(a) + \mathcal{O}_0(h^2) \quad (2.38)$$

On en déduit que

$$\partial_i f(a) = \frac{f(a + h \mathbf{e}_i) - f(a)}{h} + \mathcal{O}_0(h). \quad (2.39)$$

L'erreur commise en approchant la i -ième dérivée partielle première de f en a par la quantité $\delta_i^{[1p]} f(a)$ définie par la relation (2.37) est donc comparable à h . On dit que la formule d'approximation (2.37) est précise à l'ordre 1. Cette formule d'approximation est qualifiée de *formule de différence finie progressive d'ordre 1*.

Bien entendu, d'après la formule (2.36), on a aussi⁽¹⁹⁾

$$\partial_i f(a) = \lim_{\substack{h \rightarrow 0 \\ h \in \mathbb{R}}} \frac{f(a) - f(a - h \mathbf{e}_i)}{h}. \quad (2.40)$$

Reprenant le raisonnement précédent, nous obtenons que la i -ième dérivée partielle première de f en a peut être approchée avec une erreur elle aussi comparable à h par la quantité

$$\delta_i^{[1r]} f(a) = \frac{f(a) - f(a - h \mathbf{e}_i)}{h}. \quad (2.41)$$

Cette formule d'approximation est qualifiée de *formule de différence finie rétrograde d'ordre 1*.

Exercice 2.1 On suppose que l'application f est de classe $\mathcal{C}^2$ sur Ω . Montrer que la i -ième dérivée partielle première de f en a peut être approchée avec une erreur proportionnelle à h^2 par la quantité

$$\delta_i^{[1c]} f(a) = \frac{f(a + h \mathbf{e}_i) - f(a - h \mathbf{e}_i)}{2h}. \quad (2.42)$$

Cette formule d'approximation est qualifiée de *formule de différence finie centrée d'ordre 1* (de dérivation).

Approximation d'une dérivée partielle seconde

Considérons à présent une fonction f de $\mathbb{R}^d$ dans $\mathbb{R}$ de classe $\mathcal{C}^2$ sur un ouvert Ω de $\mathbb{R}^d$. En un point $a = (a_1, \dots, a_d)$ de Ω , la fonction f admet des dérivées partielles secondes que l'on peut définir comme étant les dérivées partielles premières en a des fonctions dérivées partielles premières de f . Ainsi, pour tout $(i, j) \in \{1, \dots, n\}^2$, la dérivée partielle seconde de f en a d'indice (i, j) , que l'on note $\partial_{ij}^2 f(a)$ ou $\frac{\partial^2 f}{\partial x_i \partial x_j}(a)$, est définie par

$$\partial_{ij}^2 f(a) = \partial_i(\partial_j f)(a). \quad (2.43)$$

D'après le théorème de Schwarz,⁽²⁰⁾ sous l'hypothèse que f est de classe $\mathcal{C}^2$, on a $\partial_{ij}^2 f(a) = \partial_{ji}^2 f(a)$.

Nous cherchons à présent à construire des formules d'approximation pour les dérivées partielles secondes de f en a . Reprenant les idées introduites pour l'approximation des dérivées partielles premières de f , considérons cette fois-ci la formule de Taylor-Young à l'ordre 3 appliquée à f , que l'on suppose ici de classe $\mathcal{C}^3$, entre $a + h \mathbf{e}_i$ et a ; on a

$$f(a + h \mathbf{e}_i) = f(a) + h \partial_i f(a) + \frac{h^2}{2} \partial_{ii}^2 f(a) + \frac{h^3}{6} \partial_{iii}^3 f(a) + \mathcal{O}_0(h^4) \quad (2.44)$$

De la même manière, la formule de Taylor-Young à l'ordre 3 appliquée à f entre $a - h \mathbf{e}_i$ et a indique que

$$f(a - h \mathbf{e}_i) = f(a) - h \partial_i f(a) + \frac{h^2}{2} \partial_{ii}^2 f(a) - \frac{h^3}{6} \partial_{iii}^3 f(a) + \mathcal{O}_0(h^4). \quad (2.45)$$

En sommant les relations (2.44) et (2.45), on obtient

$$f(a + h \mathbf{e}_i) + f(a - h \mathbf{e}_i) = 2f(a) + h^2 \partial_{ii}^2 f(a) + \mathcal{O}_0(h^4). \quad (2.46)$$

On en déduit que la dérivée partielle seconde de f en a d'indices (i, i) peut être approchée, avec une erreur comparable à h^2 , par la quantité

$$\delta_i^{[2c]} f(a) = \frac{f(a + h \mathbf{e}_i) - 2f(a) + f(a - h \mathbf{e}_i)}{h^2}. \quad (2.47)$$

⁽¹⁹⁾. Par simple changement de variable dans la limite de h en $-h$.

⁽²⁰⁾. Voir [3], théorème 10.3.

Cette formule d'approximation est qualifiée de formule de différence finie centrée d'ordre 2 (de dérivation).

Exercice 2.2 On suppose que l'application f est de classe $\mathcal{C}^4$ sur Ω . Montrer que la dérivée partielle seconde de f en a d'indices (i, i) peut être approchée avec une erreur comparable à h^4 par la quantité

$$\delta_i^{[2,4]} f(a) = \frac{-f(a + 2h \mathbf{e}_i) + 16f(a + h \mathbf{e}_i) - 30f(a) + 16f(a - h \mathbf{e}_i) - f(a - 2h \mathbf{e}_i)}{12h^2}. \quad (2.48)$$

2.3.2 Approximation par différences finies du problème de Dirichlet

On considère un maillage uniforme du domaine $\bar{\Omega} = [0, 1]^2$ de $\mathbb{R}^2$, voir la figure 11, dont les nœuds ont pour coordonnées $(x_i, y_j) = (i h_1, j h_2)$ pour $0 \leq i \leq J_1$ et $0 \leq j \leq J_2$ avec $h_1 = 1/J_1$ et $h_2 = 1/J_2$. On désigne par $h = \max(h_1, h_2)$ le *pas du maillage*.

On approche le problème (2.26) par un schéma différences finies basé sur la formule de différence finie centrée (2.47) pour approcher chacune des dérivées partielles secondes. Au nœud (i, j) pour $i \in \{1, \dots, J_1 - 1\}$ et $j \in \{1, \dots, J_2 - 1\}$, on a

$$\begin{aligned} \frac{\partial^2 u}{\partial x^2}(x_i, y_j) &\approx \frac{u(x_i + h_1, y_j) - 2u(x_i, y_j) + u(x_i - h_1, y_j)}{h_1^2} \\ \frac{\partial^2 u}{\partial y^2}(x_i, y_j) &\approx \frac{u(x_i, y_j + h_2) - 2u(x_i, y_j) + u(x_i, y_j - h_2)}{h_2^2} \end{aligned}$$

On en déduit l'approximation suivante du laplacien de u en (x_i, y_j)

$$\begin{aligned} \Delta u(x_i, y_j) &\approx \frac{u(x_i + h_1, y_j) - 2u(x_i, y_j) + u(x_i - h_1, y_j)}{h_1^2} + \frac{u(x_i, y_j + h_2) - 2u(x_i, y_j) + u(x_i, y_j - h_2)}{h_2^2} \\ &\stackrel{\text{déf.}}{=} \Delta_h u(x_i, y_j). \end{aligned} \quad (2.49)$$

En désignant par $P_{i,j}$ le nœud du maillage de coordonnées (x_i, y_j) , cette approximation, qualifiée de *schéma différences finies centrées à 5 points*, est schématisé à la figure 9.




FIG. 9 Position des nœuds pour la discrétisation différences finies centrées à 5 points.

Désignons par $u_{i,j}$ l'approximation au nœud (x_i, y_j) de la solution du problème aux limites modèle (2.29). Le schéma différences finies centrées à cinq points nous conduit à approcher l'équation aux dérivées partielles

$$-\Delta u + a_0 u = f \quad (2.50)$$

au nœud (x_i, y_j) par l'équation discrète suivante :

$$-\frac{u_{i+1,j} - 2u_{i,j} + u_{i-1,j}}{h_1^2} - \frac{u_{i,j+1} - 2u_{i,j} + u_{i,j-1}}{h_2^2} + a_0(x_i, y_j) u_{i,j} = f(x_i, y_j) \quad (2.51)$$

que l'on peut ré-écrire

$$-\frac{u_{i+1,j} + u_{i-1,j}}{h_1^2} - \frac{u_{i,j+1} + u_{i,j-1}}{h_2^2} + \left(\frac{2}{h_1^2} + \frac{2}{h_2^2} + a_0(x_i, y_j) \right) u_{i,j} = f(x_i, y_j) \quad (2.52)$$

pour $i = 2, \dots, J_1 - 2$ et $j = 2, \dots, J_2 - 2$. Pour $i = 1$, l'équation discrète prend en compte la condition de Dirichlet sur le bord Γ_4 d'équation $x = 0$ et s'écrit pour tout $j \in \{2, \dots, J_2 - 2\}$

$$-\frac{u_{2,j}}{h_1^2} - \frac{u_{1,j+1} + u_{1,j-1}}{h_2^2} + \left(\frac{2}{h_1^2} + \frac{2}{h_2^2} + a_0(x_1, y_j) \right) u_{1,j} = f(x_1, y_j) + \frac{1}{h_1^2} u_0(x_0, y_j). \quad (2.53)$$

De même, pour $i = J_1 - 1$, l'équation discrète prend en compte la condition de Dirichlet sur le bord Γ_2 d'équation $x = 1$ et s'écrit pour tout $j \in \{2, \dots, J_2 - 2\}$

$$-\frac{u_{J_1-2,j}}{h_1^2} - \frac{u_{J_1-1,j+1} + u_{J_1-1,j-1}}{h_2^2} + \left(\frac{2}{h_1^2} + \frac{2}{h_2^2} + a_0(x_{J_1-1}, y_j) \right) u_{J_1-1,j} = f(x_{J_1-1}, y_j) + \frac{1}{h_1^2} u_0(x_{J_1}, y_j). \quad (2.54)$$

Pour $j = 1$, l'équation discrète prend en compte la condition de Dirichlet sur le bord Γ_1 d'équation $y = 0$ et s'écrit pour tout $i \in \{2, \dots, J_1 - 2\}$

$$-\frac{u_{i+1,1} + u_{i-1,1}}{h_1^2} - \frac{u_{i,2}}{h_2^2} + \left(\frac{2}{h_1^2} + \frac{2}{h_2^2} + a_0(x_i, y_1) \right) u_{i,1} = f(x_i, y_1) + \frac{1}{h_2^2} u_0(x_i, y_0). \quad (2.55)$$

Enfin, pour $j = J_2 - 1$, l'équation discrète prend en compte la condition de Dirichlet sur le bord Γ_3 d'équation $y = 1$ et s'écrit pour tout $i \in \{2, \dots, J_1 - 2\}$

$$-\frac{u_{i+1,J_2-1} + u_{i-1,J_2-1}}{h_1^2} - \frac{u_{i,J_2-2}}{h_2^2} + \left(\frac{2}{h_1^2} + \frac{2}{h_2^2} + a_0(x_i, y_{J_2-1}) \right) u_{i,J_2-1} = f(x_i, y_{J_2-1}) + \frac{1}{h_2^2} u_0(x_i, y_{J_2}). \quad (2.56)$$

Pour être complet, il reste à considérer les cas particuliers des quatre points (x_1, y_1) , (x_1, y_{J_2-1}) , (x_{J_1-1}, y_1) et (x_{J_1-1}, y_{J_2-1}) pour lesquels interviennent des conditions aux limites de Dirichlet sur deux cotés.

Consistance de l'approximation

Dans l'étude des propriétés d'un schéma aux différences finies, un point essentiel est l'étude de la *consistance du schéma*. Cette étude a pour but de regarder la « qualité » de l'approximation par différences finies du problème aux limites à résoudre.

Pour étudier la consistance d'un schéma aux différences finies, on introduit la notion d'*erreur de consistance*. L'erreur de consistance estime l'erreur produite par l'approximation des dérivées partielles par des différences finies. Plus précisément, elle mesure la manière dont la solution exacte satisfait au schéma discret. Pour notre problème, l'erreur de consistance au nœud (x_i, y_j) pour $i \in \{2, \dots, J_1 - 2\}$ et $j \in \{2, \dots, J_2 - 2\}$, notée $\varepsilon_{i,j}$, vérifie d'après (2.51)

$$\begin{aligned} & -\frac{u(x_{i+1}, y_j) - 2u(x_i, y_j) + u(x_{i-1}, y_j))}{h_1^2} - \frac{u(x_i, y_{j+1}) - 2u(x_i, y_j) + u(x_i, y_{j-1}))}{h_2^2} \\ & + a_0(x_i, y_j) u(x_i, y_j) = f(x_i, y_j) + \boxed{\varepsilon_{i,j}} \end{aligned} \quad (2.57)$$

où $u(x_i, y_j)$ désigne la solution exacte de l'équation (2.50) au nœud (x_i, y_j) . Pour $i \in \{1, J_1 - 1\}$ et $j \in \{1, J_2 - 1\}$, la définition de l'erreur de consistance donnée par (2.57) doit être adaptée en tenant compte de la forme (2.53)–(2.56) du schéma en ces nœuds.

DÉFINITION 2.2 (Consistance d'un schéma aux différences finies)

Un schéma aux différences finies sera dit consistant avec l'équation (2.50) si l'erreur de consistance en chaque nœud tend vers 0 lorsque le pas h du maillage tend vers 0, autrement dit, si

$$\lim_{h \rightarrow 0} \max_{\substack{i=1, \dots, J_1-1 \\ j=1, \dots, J_2-1}} |\varepsilon_{i,j}| = 0.$$

Vérifions que notre schéma de différences finies est consistant. Pour cela, nous allons supposer que u est de classe $\mathcal{C}^4$ sur $\bar{\Omega}$. D'après la formule de Taylor-Lagrange à l'ordre 3, pour tout $i \in \{1, \dots, J_1\}$ et pour tout $j \in \{1, \dots, J_2 - 1\}$, il existe $\theta_1, \theta_2 \in]0, 1[$ tels que

$$\begin{aligned} u(x_{i+1}, y_j) &= u(x_i, y_j) + h_1 \partial_1 u(x_i, y_j) + \frac{1}{2} h_1^2 \partial_{11}^2 u(x_i, y_j) + \frac{1}{6} h_1^3 \partial_{111}^3 u(x_i, y_j) + \frac{1}{24} h_1^4 \partial_{1111}^4 u(x_i + \theta_1 h_1, y_j) \\ u(x_{i-1}, y_j) &= u(x_i, y_j) - h_1 \partial_1 u(x_i, y_j) + \frac{1}{2} h_1^2 \partial_{11}^2 u(x_i, y_j) - \frac{1}{6} h_1^3 \partial_{111}^3 u(x_i, y_j) + \frac{1}{24} h_1^4 \partial_{1111}^4 u(x_i - \theta_2 h_1, y_j) \end{aligned}$$

En sommant ces deux relations, il vient

$$\begin{aligned} -\frac{u(x_{i+1}, y_j) - 2u(x_i, y_j) + u(x_{i-1}, y_j))}{h_1^2} &= -\partial_{11}^2 u(x_i, y_j) \\ &\quad - \frac{1}{24} h_1^2 (\partial_{1111}^4 u(x_i + \theta_1 h_1, y_j) + \partial_{1111}^4 u(x_i - \theta_2 h_1, y_j)). \end{aligned} \quad (2.58)$$

À nouveau, d'après la formule de Taylor-Lagrange à l'ordre 3, pour tout $i \in \{1, \dots, J_1\}$ et pour tout $j \in \{1, \dots, J_2 - 1\}$, il existe $\theta_3, \theta_4 \in]0, 1[$ tels que

$$\begin{aligned} u(x_i, y_{j+1}) &= u(x_i, y_j) + h_2 \partial_2 u(x_i, y_j) + \frac{1}{2} h_2^2 \partial_{22}^2 u(x_i, y_j) + \frac{1}{6} h_2^3 \partial_{222}^3 u(x_i, y_j) + \frac{1}{24} h_2^4 \partial_{2222}^4 u(x_i, y_j + \theta_3 h_2), \\ u(x_i, y_{j-1}) &= u(x_i, y_j) - h_2 \partial_2 u(x_i, y_j) + \frac{1}{2} h_2^2 \partial_{22}^2 u(x_i, y_j) - \frac{1}{6} h_2^3 \partial_{222}^3 u(x_i, y_j) + \frac{1}{24} h_2^4 \partial_{2222}^4 u(x_i, y_j - \theta_4 h_2). \end{aligned}$$

En sommant ces deux relations, il vient

$$\begin{aligned} -\frac{u(x_i, y_{j+1}) - 2u(x_i, y_j) + u(x_i, y_{j-1}))}{h_2^2} &= -\partial_{22}^2 u(x_i, y_j) \\ &\quad - \frac{1}{24} h_2^2 (\partial_{2222}^4 u(x_i, y_j + \theta_3 h_2) + \partial_{2222}^4 u(x_i, y_j - \theta_4 h_2)). \end{aligned} \quad (2.59)$$

On déduit alors de (2.58) et (2.59) que pour $i \in \{2, \dots, J_1 - 2\}$ et $j \in \{2, \dots, J_2 - 2\}$, on a

$$\begin{aligned} \Delta u(x_i, y_j) &= \partial_{11}^2 u(x_i, y_j) + \partial_{22}^2 u(x_i, y_j) \\ &= \Delta_h u(x_i, y_j) + \frac{1}{24} h_1^2 (\partial_{1111}^4 u(x_i + \theta_1 h_1, y_j) + \partial_{1111}^4 u(x_i - \theta_2 h_1, y_j)) \\ &\quad + \frac{1}{24} h_2^2 (\partial_{2222}^4 u(x_i, y_j + \theta_3 h_2) + \partial_{2222}^4 u(x_i, y_j - \theta_4 h_2)). \end{aligned} \quad (2.60)$$

Ainsi, la relation (2.57) se ré-écrit

$$\begin{aligned} \varepsilon_{i,j} &= -\partial_{11}^2 u(x_i, y_j) - \partial_{22}^2 u(x_i, y_j) + a_0(x_i, y_j) u(x_i, y_j) - f(x_i, y_j) \\ &\quad - \frac{1}{24} h_1^2 (\partial_{1111}^4 u(x_i + \theta_1 h_1, y_j) + \partial_{1111}^4 u(x_i - \theta_2 h_1, y_j)) \\ &\quad - \frac{1}{24} h_2^2 (\partial_{2222}^4 u(x_i, y_j + \theta_3 h_2) + \partial_{2222}^4 u(x_i, y_j - \theta_4 h_2)). \end{aligned}$$

Comme u est solution de l'équation (2.50), on a plus simplement

$$\begin{aligned} \varepsilon_{i,j} &= -\frac{1}{24} h_1^2 (\partial_{1111}^4 u(x_i + \theta_1 h_1, y_j) + \partial_{1111}^4 u(x_i - \theta_2 h_1, y_j)) \\ &\quad - \frac{1}{24} h_2^2 (\partial_{2222}^4 u(x_i, y_j + \theta_3 h_2) + \partial_{2222}^4 u(x_i, y_j - \theta_4 h_2)). \end{aligned}$$

On en déduit que

$$|\varepsilon_{i,j}| \leq \frac{1}{12} (h_1^2 + h_2^2) M_4 \leq \frac{h^2}{6} M_4 \quad (2.61)$$

où $M_4 = \max_{(x,y) \in \bar{\Omega}} (|\partial_{1111}^4 u(x, y)|, |\partial_{2222}^4 u(x, y)|)$.

Pour $i \in \{1, J_1 - 1\}$ et $j \in \{1, J_2 - 1\}$, en prenant la définition de l'erreur de consistance tenant compte de la forme (2.53)–(2.56) du schéma en ces nœuds, nous obtenons une estimation analogue à (2.61). On en conclut que le schéma est consistant.

DÉFINITION 2.3 (Ordre d'un schéma aux différences finies)

On dit qu'un schéma aux différences finies est d'ordre p avec $p \in \mathbb{N}$ s'il existe $C > 0$ tel que

$$\forall i \in \{1, \dots, J_1 - 1\} \quad \forall j \in \{1, \dots, J_2 - 1\} \quad |\varepsilon_{i,j}| \leq C h^p.$$

On déduit de la relation (2.61) le résultat suivant.

PROPOSITION 2.3

Si la solution u du problème de Dirichlet est de classe C^4 sur $\overline{\Omega}$ alors l'erreur de consistance du schéma aux différences finies (2.52) vérifie :

$$\forall i \in \{1, \dots, J_1 - 1\} \quad \forall j \in \{1, \dots, J_2 - 1\} \quad |\varepsilon_{i,j}| \leq \frac{h^2}{6} M_4$$

$$\text{où } M_4 = \max_{(x,y) \in \overline{\Omega}} (|\partial_{1111}^4 u(x,y)|, |\partial_{2222}^4 u(x,y)|).$$

Le schéma de différences finies est donc consistant et d'ordre 2.

Remarque 2.1 On se convaincra sans peine que si le maillage du domaine $\overline{\Omega}$ n'est pas de pas constant selon chacune des directions correspondant à l'axe des abscisses et des ordonnées, il est nettement plus compliqué d'avoir un schéma d'approximation qui soit consistant. On montre néanmoins que le schéma aux différences finies correspondant à l'équation discrète (voir la figure 10 pour les notations)

$$\begin{aligned} & 2 \left(\frac{1}{h_{1,i}h_{1,i+1}} + \frac{1}{h_{2,j}h_{2,j+1}} \right) u_{i,j} - \frac{2}{h_{1,i+1}(h_{1,i+1} + h_{1,i})} u_{i+1,j} - \frac{2}{h_{2,j+1}(h_{2,j+1} + h_{2,j})} u_{i,j+1} \\ & - \frac{2}{h_{1,i-1}(h_{1,i-1} + h_{1,i})} u_{i-1,j} - \frac{2}{h_{2,j-1}(h_{2,j-1} + h_{2,j})} u_{i,j-1} + a_0(x_i, y_j) u_{i,j} = f(x_i, y_j) \end{aligned}$$

pour approcher la solution u de l'équation (2.50) est consistant. Par contre, il est d'ordre 1 si $h_{1,i} \neq h_{1,i+1}$ ou si $h_{2,i} \neq h_{2,i+1}$. Si $h_{1,i} = h_{1,i+1}$ et si $h_{2,j} = h_{2,j+1}$, ce schéma coïncide avec le schéma étudié précédemment et il est d'ordre 2 (de consistance).




FIG. 10 Notation et position des nœuds pour la discrétisation par un schéma de différences finies centrées à 5 points dans le cas d'un maillage à pas non constant.

Écriture de l'équation discrétisée sous forme d'un système linéaire

On adopte une numérotation des nœuds de gauche à droite et de bas en haut, voir la figure 11. Le point $P_{i,j}$ de coordonnées (ih_1, jh_2) où $i \in \{1, \dots, J_1 - 1\}$ et $j \in \{1, \dots, J_2 - 1\}$ a pour numéro

$$k = i + (j - 1)(J_1 - 1). \quad (2.62)$$

On désignera également par P_k le point $P_{i,j}$ dans la suite du document.




FIG. 11 Maillage du domaine $\bar{\Omega}$ considéré.

Le problème discret s'écrit sous la forme matricielle $A U = G$ où la matrice A est une matrice carrée de taille $N = (J_1 - 1) \times (J_2 - 1)$, tridiagonale par blocs, de la forme $A = A_0 + A_1$ où

$$A_1 = \begin{pmatrix} D & E & 0 & & \\ E & D & E & 0 & \\ 0 & E & D & E & 0 \\ & \ddots & \ddots & \ddots & \\ 0 & & E & D & E \\ & & 0 & E & D \end{pmatrix} \quad (2.63)$$

où les blocs, de taille $J_1 - 1$, sont

$$E = -\frac{1}{h_2^2} \begin{pmatrix} 1 & & & \\ & 1 & & \\ & & \ddots & \\ & & & 1 \\ & & & & 1 \end{pmatrix} \quad \text{et} \quad D = -\frac{1}{h_1^2} \begin{pmatrix} 0 & 1 & & \\ 1 & 0 & 1 & \\ & \ddots & \ddots & \\ & & 1 & 0 & 1 \\ & & & 1 & 0 \end{pmatrix} + \left(\frac{2}{h_1^2} + \frac{2}{h_2^2} \right) \begin{pmatrix} 1 & & & \\ & 1 & & \\ & & \ddots & \\ & & & 1 \\ & & & & 1 \end{pmatrix}$$

et où

$$A_0 = \begin{pmatrix} D_1 & & \\ & D_2 & \\ & & \ddots \\ & & & D_{J_1-1} \end{pmatrix}$$

avec, pour tout $i = 1, \dots, J_1 - 1$,

$$D_i = \begin{pmatrix} a_0(x_1, y_i) & & & \\ & a_0(x_2, y_i) & & \\ & & \ddots & \\ & & & a_0(x_{J_1-2}, y_i) \\ & & & & a_0(x_{J_1-1}, y_i) \end{pmatrix}.$$

Le second membre est le vecteur de $\mathbb{R}^N$ formé de $J_2 - 1$ blocs de taille $J_1 - 1$

$$G = \begin{pmatrix} G_1 \\ G_2 \\ \vdots \\ G_{J_2-2} \\ G_{J_2-1} \end{pmatrix} = F + \partial F = \begin{pmatrix} F_1 \\ F_2 \\ \vdots \\ F_{J_2-2} \\ F_{J_2-1} \end{pmatrix} + \begin{pmatrix} \partial F_1 \\ \partial F_2 \\ \vdots \\ \partial F_{J_2-2} \\ \partial F_{J_2-1} \end{pmatrix} \quad (2.64)$$

où

$$\begin{aligned}
 G_1 &= \begin{pmatrix} f(x_1, y_1) + \frac{1}{h_2^2} u_0(x_1, y_0) + \frac{1}{h_1^2} u_0(x_0, y_1) \\ f(x_2, y_1) + \frac{1}{h_2^2} u_0(x_2, y_0) \\ \vdots \\ f(x_{J_1-2}, y_1) + \frac{1}{h_2^2} u_0(x_{J_1-2}, y_0) \\ f(x_{J_1-1}, y_1) + \frac{1}{h_2^2} u_0(x_{J_1-1}, y_0) + \frac{1}{h_1^2} u_0(x_{J_1}, y_1) \end{pmatrix} \\
 &= \begin{pmatrix} f(x_1, y_1) \\ f(x_2, y_1) \\ \vdots \\ f(x_{J_1-2}, y_1) \\ f(x_{J_1-1}, y_1) \end{pmatrix} + \begin{pmatrix} \frac{1}{h_2^2} u_0(x_1, y_0) + \frac{1}{h_1^2} u_0(x_0, y_1) \\ \frac{1}{h_2^2} u_0(x_2, y_0) \\ \vdots \\ \frac{1}{h_2^2} u_0(x_{J_1-2}, y_0) \\ \frac{1}{h_2^2} u_0(x_{J_1-1}, y_0) + \frac{1}{h_1^2} u_0(x_{J_1}, y_1) \end{pmatrix} = F_1 + \partial F_1,
 \end{aligned}$$

pour tout $j = 2, \dots, J_2 - 2$

$$\begin{aligned}
 G_j &= \begin{pmatrix} f(x_1, y_j) + \frac{1}{h_1^2} u_0(x_0, y_j) \\ f(x_2, y_j) \\ \vdots \\ f(x_{J_1-2}, y_j) \\ f(x_{J_1-1}, y_j) + \frac{1}{h_1^2} u_0(x_{J_1}, y_j) \end{pmatrix} = \begin{pmatrix} f(x_1, y_j) \\ f(x_2, y_j) \\ \vdots \\ f(x_{J_1-2}, y_j) \\ f(x_{J_1-1}, y_j) \end{pmatrix} + \begin{pmatrix} \frac{1}{h_1^2} u_0(x_0, y_j) \\ 0 \\ \vdots \\ 0 \\ \frac{1}{h_1^2} u_0(x_{J_1}, y_j) \end{pmatrix} = F_j + \partial F_j
 \end{aligned}$$

et

$$\begin{aligned}
 G_{J_2-1} &= \begin{pmatrix} f(x_1, y_{J_2-1}) + \frac{1}{h_2^2} u_0(x_1, y_{J_2}) + \frac{1}{h_1^2} u_0(x_0, y_{J_2-1}) \\ f(x_2, y_{J_2-1}) + \frac{1}{h_2^2} u_0(x_2, y_{J_2}) \\ \vdots \\ f(x_{J_1-2}, y_{J_2-1}) + \frac{1}{h_2^2} u_0(x_{J_1-2}, y_{J_2}) \\ f(x_{J_1-1}, y_{J_2-1}) + \frac{1}{h_2^2} u_0(x_{J_1-1}, y_{J_2}) + \frac{1}{h_1^2} u_0(x_{J_1}, y_{J_2-1}) \end{pmatrix} \\
 &= \begin{pmatrix} f(x_1, y_{J_2-1}) \\ f(x_2, y_{J_2-1}) \\ \vdots \\ f(x_{J_1-2}, y_{J_2-1}) \\ f(x_{J_1-1}, y_{J_2-1}) \end{pmatrix} + \begin{pmatrix} \frac{1}{h_2^2} u_0(x_1, y_{J_2}) + \frac{1}{h_1^2} u_0(x_0, y_{J_2-1}) \\ \frac{1}{h_2^2} u_0(x_2, y_{J_2}) \\ \vdots \\ \frac{1}{h_2^2} u_0(x_{J_1-2}, y_{J_2}) \\ \frac{1}{h_2^2} u_0(x_{J_1-1}, y_{J_2}) + \frac{1}{h_1^2} u_0(x_{J_1}, y_{J_2-1}) \end{pmatrix} = F_{J_2-1} + \partial F_{J_2-1}.
 \end{aligned}$$

Remarques 2.2

1. On notera que la matrice A du système linéaire est creuse. Cela permet, en utilisant un stockage adapté des éléments de la matrice, d'économiser de la place en mémoire, mais également d'améliorer le temps de résolution du système linéaire par rapport à la résolution de ce système avec une matrice stockée sous forme pleine en utilisant des algorithmes spécifiques aux matrices creuses.

2. On sera attentif au fait que la forme du système linéaire est déterminé par le choix de numérotation des nœuds du maillage. D'autres choix de numérotation, par exemple colonne après colonne, ou diagonale après diagonale, conduiraient à une matrice et à un second membre différents. La matrice resterait néanmoins une matrice creuse.

PROPOSITION 2.4 *On suppose que la fonction a_0 est positive ou nulle. La matrice A définie en (2.63) est inversible.*

Démonstration On vérifie sans peine à partir de l'expression des coefficients de la matrice A qu'il s'agit d'une matrice à diagonale fortement dominante, voir la définition 1.1 p. 19. Il s'agit par ailleurs d'une matrice irréductible, voir la définition 1.2 p. 21. D'après le théorème 1.8 p. 24, une matrice à diagonale fortement dominante et irréductible est inversible. $\square$

Stabilité de la méthode de discrétisation

PROPOSITION 2.5 *On suppose que la fonction a_0 est positive ou nulle. La matrice A définie en (2.63) est monotone.*

Démonstration Pour établir ce résultat, on a recours à la proposition 1.7 p. 29. La matrice A est inversible. Les éléments non diagonaux de la matrice sont clairement négatifs ou nuls. La somme des éléments d'une ligne vaut

$$\begin{aligned} & -\frac{2}{h_2^2} - \frac{2}{h_1^2} + \left(\frac{2}{h_2^2} + \frac{2}{h_1^2} \right) + a_0(x_i, y_j) = a_0(x_i, y_j) \geq 0 \\ \text{ou} \quad & -\frac{2}{h_2^2} - \frac{1}{h_1^2} + \left(\frac{2}{h_2^2} + \frac{2}{h_1^2} \right) + a_0(x_i, y_j) = \frac{1}{h_1^2} + a_0(x_i, y_j) \geq 0. \end{aligned}$$

La matrice est donc bien monotone. $\square$

PROPOSITION 2.6 *Soit A la matrice issue de la discrétisation du problème de Dirichlet par le schéma aux différences finies basé sur la formule à cinq points (2.49) et Θ un vecteur de $\mathbb{R}^N$. Si $a_0 \geq 0$ et si $W \in \mathbb{R}^N$ vérifie $AW = \Theta$ alors il existe une constante $C > 0$ telle que*

$$\|W\|_\infty \leq C \|\Theta\|_\infty.$$

Démonstration Considérons la fonction $v \in \mathcal{C}^\infty(\overline{\Omega})$ définie par

$$\forall (x, y) \in \overline{\Omega} \quad v(x, y) = \frac{1}{4} (2 - (x^2 + y^2)) \|\Theta\|_\infty.$$

Remarquons que $-\Delta v = \|\Theta\|_\infty$ et que pour tout $P = (x, y) \in \overline{\Omega}$, on a $(2 - (x^2 + y^2)) \geq 0$. (Le carré $[0, 1]^2$ est en effet inscrit dans le disque centré à l'origine et de rayon $\sqrt{2}$.) Notons V le vecteur de $\mathbb{R}^N$ dont les composantes sont $v(P_1), \dots, v(P_N)$ où $P_1, \dots, P_N$ désignent les noeuds de la discrétisation introduite à la Fig. 11, et intéressons-nous à AV . Compte tenu de la manière dont a été construite la matrice A , cela nous conduit à devoir distinguer le cas où le point P_k de coordonnées (x_i, y_j) est voisin d'un point du bord (c'est-à-dire que l'un des points de coordonnées (x_{i+1}, y_j) , (x_{i-1}, y_j) , (x_i, y_{j+1}) , (x_i, y_{j-1}) appartient Σ), où nous avons tenu compte de la condition aux limites de Dirichlet pour construire l'équation discrète, et le cas où le point P_k ne l'est pas.

$\supseteq$ Considérons un point $P_k = (x_i, y_j)$ qui n'est pas voisin d'un point de la frontière Σ . Comme v est une fonction polynomiale de degré 2, on déduit de la proposition 2.3 et plus particulièrement de la relation (2.60), que

$$\Delta v(x_i, y_j) = \Delta_h v(x_i, y_j)$$

où $\Delta_h v(x_i, y_j)$ désigne l'approximation de $\Delta v(x_i, y_j)$ définie en (2.49). On a donc

$$\begin{aligned} (AV)_k &= -\Delta_h v(x_i, y_j) + a_0(x_i, y_j) v(x_i, y_j) = -\Delta v(x_i, y_j) + a_0(x_i, y_j) v(x_i, y_j) \\ &= \|\Theta\|_\infty + \underbrace{a_0(x_i, y_j)}_{\geq 0} \underbrace{v(x_i, y_j)}_{\geq 0} \geq \|\Theta\|_\infty. \end{aligned}$$

$\supseteq$ Considérons à présent un point $P_k = (x_i, y_j)$ qui est voisin d'un point de la frontière Σ et pour fixer les choses, nous supposons que P_k est voisin d'un point du segment de droite Γ_4 d'équation $x = x_0$. (Un raisonnement similaire s'applique aux trois autres cotés de la frontière Σ .) Compte tenu de la condition aux limites de Dirichlet qui a été utilisée dans la construction du schéma au point P_k , on a

$$(AV)_k = -\Delta_h^0 v(x_i, y_j) + a_0(x_i, y_j) v(x_i, y_j)$$

où on a noté

$$\begin{aligned}\Delta_h^0 v(x_i, y_j) &= \frac{v(x_i + h_1, y_j) - 2v(x_i, y_j)}{h_1^2} + \frac{v(x_i, y_j + h_2) - 2v(x_i, y_j) + v(x_i, y_j - h_2)}{h_2^2} \\ &= \Delta_h v(x_i, y_j) - \frac{1}{h_1^2} v(x_0, y_j) \\ &= -\|\Theta\|_\infty - \frac{1}{h_1^2} \left(\frac{1}{4} (2 - (x_0^2 + y_j^2)) \right) \|\Theta\|_\infty + h^2 \|\theta\|_\infty.\end{aligned}$$

On en déduit que

$$(A V)_k = \left(1 + \frac{1}{4h_1^2} \underbrace{(2 - (x_0^2 + y_j^2))}_{\geq 0} \right) \|\Theta\|_\infty + \underbrace{a_0(x_0, y_j) v(x_0, y_j)}_{\geq 0} \geq \|\Theta\|_\infty.$$

$\supseteq$ On déduit de ce qui précède

$$A V \geq \|\Theta\|_\infty \begin{pmatrix} 1 \\ \vdots \\ 1 \end{pmatrix}.$$

Par suite,

$$A (V - W) = A V - \Theta \geq \|\Theta\|_\infty \begin{pmatrix} 1 \\ \vdots \\ 1 \end{pmatrix} - \Theta \geq 0. \quad (2.65)$$

On a aussi,

$$A (W + V) = \Theta + A V \geq \Theta + \|\Theta\|_\infty \begin{pmatrix} 1 \\ \vdots \\ 1 \end{pmatrix} \geq 0. \quad (2.66)$$

Comme par hypothèse $a_0 \geq 0$, il résulte de la proposition 2.5 que la matrice A est monotone. D'après la proposition 1.5 p. 26, on déduit des relations (2.65) et (2.66) que $W - V \geq 0$ et $W + V \geq 0$. On a donc $-V \leq W \leq V$. On en déduit que pour tout $k \in \{1, \dots, N\}$, on a

$$|w_k| \leq v_k = v(P_k) = \frac{1}{4} (2 - (x_i^2 + y_j^2)) \|\Theta\|_\infty \leq C_k \|\Theta\|_\infty.$$

En posant $C = \max_{k \in \{1, \dots, N\}} C_k$, on en conclut que

$$\|W\|_\infty \leq C \|\Theta\|_\infty.$$

Le résultat est démontré. $\square$

COROLLAIRE 2.1 (Stabilité du schéma aux différences finies)

On suppose que la fonction a_0 est positive ou nulle. Le schéma aux différences finies basé sur la formule à cinq points (2.49) conduisant au système linéaire $AU = G$, où la matrice A est définie en (2.63) et le second membre G est défini en (2.64), est stable pour la norme infinie.

Démonstration D'après la proposition 2.6 appliquée au système linéaire $AU = G$, il existe une constante $C > 0$ telle que

$$\|U\|_\infty \leq C \|G\|_\infty.$$

On en déduit, voir la définition 1.5 p. 31, que le schéma aux différences finies est stable pour la norme infinie. $\square$

Etude de l'erreur d'approximation

L'erreur d'approximation au nœud $P_k = (x_i, y_j)$ pour $i \in \{1, \dots, J_1 - 1\}$ et $j \in \{1, \dots, J_2 - 1\}$ est donnée par $e_k = u(x_i, y_j) - u_{i,j}$.

PROPOSITION 2.7 (Convergence du schéma aux différences finies)

On suppose que la fonction a_0 est positive ou nulle. Si la solution u du problème de Dirichlet est suffisamment régulière alors le schéma aux différences finies est convergent et il existe une constante $C > 0$ telle que, pour tout $k \in \{1, \dots, N\}$, l'erreur d'approximation au nœud P_k vérifie :

$$|e_k| \leq C h^2 M_4$$

$$\text{où } M_4 = \max_{(x,y) \in \Omega} (|\partial_{1111}^4 u(x,y)|, |\partial_{2222}^4 u(x,y)|).$$

Démonstration En exploitant le fait que le schéma aux différences finies que nous avons introduit est stable et consistant, montrons qu'il est convergent. Désignons par E le vecteur de $\mathbb{R}^N$ dont les composantes sont e_k , $k = 1, \dots, N$. Désignons aussi par V le vecteur de $\mathbb{R}^N$ dont les composantes sont données par la valeur de la solution exacte du problème de Dirichlet (2.31) aux nœuds P_k pour $k \in \{1, \dots, N\}$. On a $E = V - U$ où U est le vecteur de composantes $u_1, \dots, u_N$ solution du système linéaire $A U = G$ correspondant à l'écriture matricielle du problème discret. Ainsi,

$$A E = A V - A U = A V - G.$$

Or, d'après (2.57), on a $A V = G + \varepsilon$ où ε est le vecteur de $\mathbb{R}^N$ dont les composantes sont les valeurs de l'erreur de consistance aux nœuds P_k pour $k \in \{1, \dots, N\}$. On a donc $A E = \varepsilon$. Comme le schéma aux différences finies considéré est stable, d'après la proposition 2.1, on en déduit qu'il existe $C > 0$ tel que

$$\|E\|_\infty \leq C \|\varepsilon\|_\infty.$$

D'après la proposition 2.3, le schéma aux différences finies est consistant et

$$\forall i \in \{1, \dots, J_1 - 1\} \quad \forall j \in \{1, \dots, J_2 - 1\} \quad |\varepsilon_{i,j}| \leq \frac{h^2}{6} M_4$$

où $M_4 = \max_{(x,y) \in \Omega} (|\partial_{1111}^4 u(x,y)|, |\partial_{2222}^4 u(x,y)|)$. On en déduit que

$$\|E\|_\infty \leq C \frac{h^2}{6} M_4.$$

La proposition est démontrée. □

Problèmes aux limites paraboliques

3.1 Modélisation de phénomènes physiques conduisant à des problèmes aux limites paraboliques

3.1.1 Phénomènes thermiques dans les lasers solides

Nous présentons ici un modèle mathématique décrivant les phénomènes thermiques apparaissant dans certains lasers.⁽¹⁾

Ces dernières années, les lasers dits à *état solide* ont été très étudiés dans le but de réaliser des lasers à haute puissance ayant un faisceau de bonne qualité. Un laser est formé de trois composants principaux : le « milieu actif », la « source pompe » et le « résonateur optique ». Dans le cas d'un laser à état solide, le milieu actif qui est constitué d'un verre spécial ou d'un cristal, est placé à l'intérieur du résonateur optique et il reçoit de l'énergie d'une source optique extérieure sous forme d'un faisceau laser dit *de pompe*, voir la figure 1. Le milieu actif peut alors émettre un faisceau laser amplifié possédant une énergie et une longueur d'onde spécifique.⁽²⁾ Le phénomène de transfert d'énergie de la source externe au milieu actif est appelé *pompage laser*. Les faisceaux lasers de pompe de qualité sont produits par des diodes lasers.

Le processus de pompage laser est réalisé selon deux méthodes qui sont le pompage laser à émission continue et le pompage laser à impulsions. Une configuration courante utilisée dans les lasers solides est celle où le pompage par diode destinée à délivrer le faisceau de pompe est effectué à la pompe d'extrémité du cristal. Le faisceau de pompage est dans l'axe du faisceau laser du résonateur ce qui conduit à des lasers aux faisceaux de bonne qualité. Dans ce type de dispositif, le faisceau de pompe issu de la diode laser est transmis à l'extrémité du milieu actif par des lentilles optiques focalisantes ou par des fibres optiques. Afin d'être dans des conditions d'appariement optimales entre le faisceau du résonateur et celui du laser de pompe, le faisceau de pompe est focalisé dans le milieu actif avec une largeur de faisceau très petite. Cela engendre localement une source de chaleur intense, entraînant l'existence d'un important gradient de l'indice optique qui peut dégrader la qualité du faisceau laser et diminuer la puissance optique délivrée.⁽³⁾ De plus, dans les lasers à très haute puissance, la distribution de chaleur dans le cristal est en général inhomogène, ce qui a pour conséquence d'augmenter les contraintes et déformations mécaniques dans le cristal.⁽⁴⁾

Nous nous intéressons plus spécifiquement ici au cas du *laser à fibre* où le milieu amplificateur est constitué d'une fibre et où le faisceau laser de pompe fourni par une diode laser est injecté à l'une ou aux deux extrémités de la fibre, voir la figure 1. Il est important de noter que la lumière laser se propage uniquement dans le cœur de la fibre et, en tant que telle, la propagation de la lumière dans la fibre ne joue aucun rôle dans le processus de génération de chaleur. Celle-ci est liée, comme nous l'avons vu, à l'injection du faisceau laser de pompe dans la fibre.

Il existe deux manières d'introduire le faisceau laser de pompe dans la fibre qui sont respectivement désignées sous les termes « pompage de cœur » et « pompage de gaine », voir la figure 2. La méthode

(1). Pour une description plus complète, voir : V. Ashoori, M. Shayganmanesh, and R. Radmard. *Heat Generation and Removal in Solid State Lasers*, chapter 12 of “An overview of heat transfer phenomena”, S. Kazi Ed. InTech, 2012. [www.intechopen.com/books/an-overview-of-heat-transfer-phenomena].

(2). K. Thyagarajan and u. Ghatak. *Lasers : Fundamentals and applications*. Graduate Texts in Physics. Springer, 2010.

(3). W. Koechner. *Solid-state laser engineering. : 5th edition*. Springer series in optical sciences. Springer, 1999.

(4). R. Weber, B. Neuenschwander, M. Mac Donald, M.B. Roos, and H.P. Weber. Cooling schemes for longitudinally diode laser-pumped Nd :YAG rods. *Quantum Electronics, IEEE Journal of*, 34(6) :1046–1053, Jun 1998.




FIG. 1 Un laser à fibre est constitué d'une fibre de cœur généralement entourée par deux fibres coaxiales de gaine et le faisceau laser de pompe est fourni par une diode laser et injecté à l'une ou aux deux extrémités. [illust. Science Magazine].




FIG. 2 Illustration du pompage de gaine.

traditionnelle de pompage de cœur a été initialement utilisée pour la réalisation de lasers monomodes avec des fibres à cœur de très petit diamètre. Toutefois, le fait de disposer d'une fibre à cœur de très petit diamètre entraîne des limitations importantes sur la puissance acceptable pour le laser de pompe. La petite taille du cœur conduit localement à de fortes intensités laser à l'extrémité de la fibre conduisant à des dégradations de celle-ci d'origine thermique. Le pompage de gaine s'est donc imposé comme étant la solution permettant d'injecter un faisceau de pompe de forte puissance. Dans cette configuration, le faisceau laser de pompe est injecté, et se propage, dans la partie interne de la gaine en étant absorbé progressivement par le cœur de la fibre limitant ainsi l'effet des phénomènes thermiques néfastes. On notera toutefois que dans ce cas aussi, c'est dans le cœur de la fibre que les phénomènes thermiques d'intérêt se produisent.

Dans la plupart des cas, le refroidissement des lasers à fibre ne nécessite pas de dispositif spécifique ; c'est l'air entourant le laser qui dissipe la chaleur par convection. On parle dans ce cas de procédé de refroidissement passif. Cependant, dans les lasers à fibre de forte puissance, un système de refroidissement actif doit être envisagé pour améliorer l'efficacité du processus de dissipation de la chaleur. Pour cela, tout ou partie du laser à fibre peut être placée dans un liquide et le refroidissant du dispositif s'opère par convection entre la périphérie de la fibre et le milieu environnant. Cette technique est surtout employée lorsque le laser est assez long. Pour des lasers de taille plus petite, une autre technique utilisée est le refroidissement thermo-électrique (TEC, *thermoelectric cooling system* en anglais). Dans ce cas, la fibre est entourée d'un dispositif dissipateur de chaleur en cuivre et l'échange de chaleur s'effectue cette fois ci par conduction thermique.




FIG. 3 Vue de coupe et de profil d'un laser à fibre. Notations utilisées.

Modélisation mathématique dans le cas de pompage à émission continue

Intéressons-nous à un laser à fibre ayant une forme cylindrique comme représenté à la figure 3. Nous désignons par a le rayon du cœur de la fibre, par b celui de la gaine et par L la longueur de la fibre.

L'utilisation du pompage à émission continue conduit à devoir considérer des phénomènes thermiques dans le cœur de la fibre qui sont dépendant du temps. L'évolution de la température à l'intérieur de la fibre (cœur et gaine) est régie par l'équation de la chaleur, voir la section 1.1.2 du chap. 1,

$$-k_c \Delta T = Q$$

où Q représente la densité de la source de chaleur exprimée en $[W m^{-3}]$ et k_c est la conductivité thermique du milieu exprimée en $[W m^{-1} K^{-1}]$. Compte tenu de la forme cylindrique de la fibre, il est légitime d'introduire la base des coordonnées cylindriques. On note $\Omega_a =]0, a[\times]0, L[$ l'ouvert correspondant au cœur de la fibre et par $\Omega_b =]a, b[\times]0, L[$ l'ouvert correspondant à la gaine dans le plan $\theta = 0$ en coordonnées cylindriques. Sous l'hypothèse que la densité de la source de chaleur Q ne dépend pas de la variable angulaire θ , on est conduit à l'équation aux dérivées partielles suivante

$$\frac{1}{r} \frac{\partial}{\partial r} \left(r \frac{\partial T(r, z)}{\partial r} \right) + \frac{\partial^2 T(r, z)}{\partial z^2} = -\frac{Q(r, z)}{k_c} \quad (3.1)$$

dans chacun des domaines Ω_a et Ω_b .

L'expression de la densité de la source de chaleur se déduit de l'expression de l'intensité de la source laser pompe. La variation spatiale de l'intensité de la source laser pompe correspond généralement à une gaussienne ou à celle d'une fonction « chapeau ». Par exemple, quand la fibre est pompée par deux diodes laser couplées aux deux extrémités, la variation spatiale dans la direction transverse de l'intensité de pompe peut être approchée de manière correcte par une fonction chapeau. La propagation du faisceau laser de pompe dans le cœur de la fibre s'accompagne d'une décroissance exponentielle de l'intensité de celui-ci dans la direction axiale. Par conséquent, la densité de la source de chaleur dans la fibre peut être modélisée de la manière suivante⁽⁵⁾

$$Q(r, z) = \begin{cases} \frac{1}{\pi a^2 L_{\text{eff}}} \zeta P_o e^{-\alpha z} & \text{si } r \leq a \\ 0 & \text{si } a < r \leq b \end{cases} \quad (3.2)$$

où P_o est la puissance de pompe, ζ est la charge thermique, α est le coefficient d'absorption de pompe, $L_{\text{eff}} = \frac{1}{\alpha}(1 - e^{-\alpha L})$ est la longueur de fibre efficace et L est la longueur de fibre réelle.

En supposant la surface externe de la fibre située à $r = b$ en contact direct avec un liquide ou un gaz comme l'air, nous avons sur cette frontière une condition aux limites correspondant à un phénomène de convection thermique qui s'exprime sous la forme de la condition aux limites suivante

$$k_c \frac{\partial T}{\partial n}(b, z) = h(T_c - T(b, z)) \quad (3.3)$$

(5). Voir V. ushoori, M. Shayganmanesh, and R. Radmard. *Heat Generation and Removal in Solid State Lasers*, chapter 12 of "An overview of heat transfer phenomena", S. Kazi Ed. InTech, 2012.




FIG. 4 Représentation schématique d'un laser à fibre de courte longueur où l'impulsion laser de pompe et de l'impulsion du laser à fibre se propagent dans des directions propa et contra-propagatives.

où h est le coefficient de transfert thermique, T_c est la température du milieu ambiant ou du liquide de refroidissement et k_c est le coefficient de conductivité thermique du milieu. Cette condition aux limites exprime le fait que le flux thermique radial arrivant à la périphérie de la fibre par conduction thermique est absorbé par le milieu extérieur par un phénomène de convection. Une condition aux limites plus générale serait

$$k_c \frac{\partial T}{\partial n}(b, z) = h(T_c - T(b, z)) + \varepsilon \sigma (T_c - T(b, z))^4 \quad (3.4)$$

où $\sigma = 5.670373 \cdot 10^{-8} \text{ W m}^{-2} \text{ K}^{-4}$ est la constante de Stefan-Boltzmann et ε est l'émissivité (ou émittance) thermique de la fibre (on a typiquement $\varepsilon = 0.95$).

A l'interface entre le cœur de la fibre et la gaine, la température varie de manière continue, de même que le flux de thermique dans la direction normale :

$$\forall z \in [0, L] \quad [T(a, z)] = 0 \quad \text{et} \quad \left[\frac{\partial T}{\partial n}(a, z) \right] = 0 \quad (3.5)$$

où les crochets indiquent q=le saut de la quantité entre crochets à travers l'interface (ainsi, $[T] = T|_{\Omega_b} - T|_{\Omega_a}$).

Aux deux extrémités de la fibre, on impose les conditions de Neumann

$$\forall r \in [0, b] \quad \frac{\partial T}{\partial n}(r, 0) = 0 \quad \text{et} \quad \frac{\partial T}{\partial n}(r, L) = 0 \quad (3.6)$$

qui expriment un transfert de chaleur négligeable des extrémités de la fibre vers l'air ambiant.

Si la fibre est de courte longueur, l'énergie du faisceau laser pompe n'est pas complètement absorbée lors de sa propagation dans la fibre et par conséquent est en partie réfléchi à la seconde extrémité de la fibre et joue le rôle d'une source laser pompe à cette seconde extrémité. La source de chaleur à prendre en compte est dans ce cas composée d'une fraction de l'énergie du laser pompe se propageant dans chacune des deux directions. Sous l'hypothèse que la variation spatiale de l'intensité de la source laser pompe est correspond à une gaussienne, la densité de chaleur source a pour expression ⁽⁶⁾

$$Q(r, z) = \frac{2}{\pi \omega_p^2} \left((\alpha \eta + \alpha_{ps}) (P_p^+(z) + P_p^-(z)) + \alpha_s (P_s^+(z) + P_s^-(z)) \right) e^{-2r^2/\omega_p^2} \quad (3.7)$$

où $P_p^\pm$ et $P_s^\pm$ désignent respectivement la puissance de l'impulsion laser de pompe et de l'impulsion du laser à fibre dans les directions propagatrices et contra-propagatrices, α_{ps} et α_s sont les coefficients de perte par diffusion à la longueur d'onde du laser de pompe et du laser à fibre, η est le coefficient de dégagement de chaleur et ω_p est le rayon du faisceau laser de pompe. L'expression (3.7) remplace dans ce cas (3.2) au second membre de l'équation (3.1).

Modélisation mathématique dans le cas du pompage laser à impulsions

Dans le cas du pompage laser à impulsions, la température est régie par l'équation suivante ⁽⁶⁾

$$-\frac{\rho c}{k_c} \frac{\partial}{\partial t} T(r, z, t) + \frac{1}{r} \frac{\partial}{\partial r} \left(r \frac{\partial}{\partial r} T(r, z, t) \right) + \frac{\partial^2}{\partial z^2} T(r, z, t) = -\frac{Q(r, z, t)}{k_c} \quad (3.8)$$

⁽⁶⁾. T. Liu, Z. M. Yang, and S. H. Xu. 3-dimensional heat analysis in short-length er3+/yb3+ co-doped phosphate fiber laser with upconversion. *Opt. Express*, 17(1) :235–247, Jan 2009.

où Q est la densité de chaleur source exprimée en $[W m^{-3}]$, k_c est le coefficient de conductivité thermique, ρ et c sont respectivement la densité du milieu laser actif exprimé en $[kg m^{-3}]$ et la chaleur spécifique exprimée en $[J kg^{-1} ^\circ C]$. La densité de chaleur source a pour expression

$$Q(r, z, t) = \frac{2\eta\alpha P_{in}}{\pi\omega_p^2} e^{-\frac{2r^2}{\omega_p^2} - \alpha z} g(t) \quad (3.9)$$

où P_{in} est l'énergie du pulse laser pompe, g est la forme temporelle de ce pulse, ω_p est le « rayon » du pulse supposé gaussien, η est le coefficient thermique et α est le coefficient d'absorption. Il est courant de supposer une dépendance temporelle du laser pompe de la forme

$$g(t) = \begin{cases} 1 & \text{si } (n-1)T_0 \leq t \leq (n-1)T + t_0 \\ 0 & \text{si } (n-1)T_0 + t_0 \leq t \leq nT \end{cases} \quad (3.10)$$

où n désigne le nombre de pulses, t_0 est la durée du pulse et T_0 est la période du pulse. Les conditions aux limites sont données par les relations (3.3), (3.5), (3.6). Par ailleurs, le dispositif laser est supposé être à l'équilibre thermique avec le milieu ambiant avant que ne débute le processus de pompage, de sorte que l'on ait la condition initiale suivante :

$$\forall z \in [0, L] \quad \forall r \in [0, b] \quad T(r, t, 0) = T_c \quad (3.11)$$

où T_c désigne la température de l'air ambiant.

3.1.2 Propagation d'une onde dans une fibre optique

L'équation non-linéaire de Schrödinger

La propagation d'une onde dans une fibre optique caractérisée par un indice de groupe n_g est décrite par l'équation non-linéaire de Schrödinger (NLS), voir par ex. [1]. Cette forme particulière de l'équation de Schrödinger est obtenue à partir des équations de Maxwell en exploitant un certain nombre d'hypothèses rendues possibles par les caractéristiques très particulières de la propagation d'une onde dans un milieu comme une fibre optique. Une première hypothèse consiste à supposer que l'onde optique est quasi-monochromatique, ce qui signifie que le spectre de l'onde, centré sur la fréquence ν_0 , a une largeur spectrale faible devant ν_0 . Une autre hypothèse est que l'onde optique maintient sa polarisation au cours de sa propagation dans la fibre. Par ailleurs, une hypothèse essentielle connue sous le nom *d'approximation de l'enveloppe lentement variable* [1] stipule que le champ électrique $\mathbf{E}$ de l'onde optique est polarisée linéairement dans une direction $\mathbf{e}_x$ transverse à la direction de propagation $\mathbf{e}_z$ définie par la fibre et peut être représentée comme une fonction du temps τ et de la position $\mathbf{r} = (x, y, z)$ sous la forme

$$\mathbf{E}(\mathbf{r}, \tau) = A(z, t) F(x, y) e^{-i(\omega_0\tau - kz)} \mathbf{e}_x \quad (3.12)$$

où $A(z, t)$ désigne l'enveloppe lentement variable de l'onde, $F(x, y)$ représente la variation transverse de l'onde, k est le nombre d'onde, $\omega_0 = 2\pi\nu_0$ est la pulsation de l'onde et $t = \tau - z/v_g$ est le temps local au repère mobile se déplaçant avec l'onde à la vitesse de groupe $v_g = c/n_g$. Lorsque la fibre optique a une section transverse de géométrie simple, l'expression de F peut être calculée explicitement en utilisant les méthodes usuelles de séparation de variables pour les équations aux dérivées partielles.

Sous ces hypothèses, on établit, voir par ex. [1, 2], que l'évolution temporelle de l'enveloppe lentement variable $A(z, t)$ est gouvernée par la forme suivante de l'équation de Schrödinger

$$\frac{\partial}{\partial z} A(z, t) = -\alpha A(z, t) - \frac{i\beta_2}{2} \frac{\partial^2}{\partial t^2} A(z, t) + i\gamma A(z, t) |A(z, t)|^2 \quad (3.13)$$

pour $t \in \mathbb{R}$ et $z \in [0, L]$, L désignant la longueur de la fibre. Les phénomènes physiques pris en compte dans l'équation (3.13) sont les suivants. L'atténuation linéaire intervient via le terme αu où α est la constante d'atténuation de la fibre et la dispersion linéaire via le coefficient de dispersion chromatique β_2 . Les effets Kerr instantanés se manifestent à travers le terme non linéaire $\gamma A |A|^2$. Signalons que d'autres effets linéaires et non-linéaires comme la contribution Raman retardée peuvent également être pris en compte, donnant lieu à ce qui est communément appelée équation non-linéaire généralisée de Schrödinger (GNLS), voir [1, 2] pour une présentation détaillée.

L'équation (3.13) est considérée conjointement avec une donnée initiale correspondant à l'expression de l'enveloppe lentement variable A à l'entrée de la fibre. Autrement dit, on se donne une fonction A_0 de $\mathbb{R}$ dans $\mathbb{C}$ décrivant l'évolution temporelle de A en $z = 0$, i.e.

$$\forall t \in \mathbb{R} \quad A(z = 0, t) = A_0(t). \quad (3.14)$$

Afin de disposer d'un problème mathématiquement bien posé, un cadre mathématique adéquat doit être introduit. On montre⁽⁷⁾ que si $A_0 \in \mathbb{H}^2(\mathbb{R}, \mathbb{C})$ alors il existe une unique solution appartenant à l'espace fonctionnel $\mathcal{C}^0([0, L[; \mathbb{H}^2(\mathbb{R}, \mathbb{C})) \cap \mathcal{C}^1([0, L[; \mathbb{L}^2(\mathbb{R}, \mathbb{C}))$ solution du problème aux dérivées partielles constitué de notre problème modèle ($\mathcal{P}$) et de la condition initiale (3.14).

Solutions particulières de l'équation NLS : les solitons

Dans le cas où $\alpha = 0$ et $\beta_2 < 0$, notre problème modèle ($\mathcal{P}$) admet une solution exacte connue sous le nom de *soliton optique*. Plus précisément, si la condition initiale est

$$A_0 : t \in \mathbb{R} \mapsto \frac{N_s}{\sqrt{\gamma L_D}} \frac{1}{\text{ch}(t/T_0)} \quad (3.15)$$

où N_s est un entier naturel non nul appelé *ordre du soliton*, T_0 est un réel positif appelé largeur à mi-hauteur de l'onde soliton et $L_D = -T_0^2/\beta_2$ est connue sous le nom de longueur de dispersion alors, dans le cas où $N_s = 1$, la solution de l'équation NLS (3.13) est donnée pour tout $z \in [0, L]$ et pour tout $t \in \mathbb{R}$ par

$$A(z, t) = \frac{N_s}{\sqrt{\gamma L_D}} \frac{e^{iz/2L_D}}{\text{ch}(t/T_0)}. \quad (3.16)$$

Par ailleurs, lorsque $N_s \geq 2$ la relation (3.16) coïncide avec l'expression de la solution exacte de l'équation NLS (3.13) en des positions z le long de la fibre qui sont multiples de $\frac{\pi}{2}L_D$.

Résolution de l'équation linéaire de Schrödinger

On considère l'équation linéaire de Schrödinger qui correspond à notre problème modèle ($\mathcal{P}$) dans le cas où $\gamma = 0$. Le problème aux dérivées partielles à résoudre s'écrit : trouver $u \in \mathcal{C}^0([0, L[; \mathbb{H}^2(\mathbb{R}, \mathbb{C})) \cap \mathcal{C}^1([0, L[; \mathbb{L}^2(\mathbb{R}, \mathbb{C}))$ tel que

$$\begin{cases} \frac{\partial}{\partial z} A(z, t) + \alpha A(z, t) + i \frac{\beta}{2} \frac{\partial^2}{\partial t^2} A(z, t) = 0 & \forall z \in]0, L[\quad \forall t \in \mathbb{R} \\ A(0, t) = A_0(t) & \forall t \in \mathbb{R} \end{cases} \quad (3.17)$$

où $a_0 \in \mathbb{H}^2(\mathbb{R}, \mathbb{C})$ est donnée.

Considérons la transformée de Fourier $\hat{A}$ de la fonction inconnue A relativement à la variable de temps t pour une valeur fixée de la variable d'espace z :

$$\hat{A} : (z, \nu) \in [0, L] \times \mathbb{R} \mapsto \mathcal{F}[t \mapsto A(z, t)](\nu) \quad (3.18)$$

où $\mathcal{F}$ représente l'opérateur de Fourier de $\mathbb{L}^2(\mathbb{R}, \mathbb{C})$ dans $\mathbb{L}^2(\mathbb{R}, \mathbb{C})$ défini par prolongement continu de l'opérateur de Fourier pour les fonctions de $\mathbb{L}^1(\mathbb{R}, \mathbb{C})$ et calculé pour toute fonction ψ dans $\mathbb{L}^2(\mathbb{R}, \mathbb{C})$ de la manière suivante

$$\forall \nu \in \mathbb{R} \quad \hat{\psi}(\nu) = \lim_{T \rightarrow +\infty} \int_a^b \psi(t) e^{-2i\pi\nu t} dt.$$

On déduit de (3.17) que $\hat{A}$ vérifie pour tout $\nu \in \mathbb{R}$

$$\begin{cases} \frac{\partial}{\partial z} \hat{A}(z, \nu) + \alpha \hat{A}(z, \nu) + i \frac{\beta}{2} (-2i\pi\nu)^2 \hat{A}(z, \nu) = 0 & \forall z \in [0, L] \\ \hat{A}(0, \nu) = \hat{A}_0(\nu) & \forall \nu \in \mathbb{R} \end{cases} \quad (3.19)$$

⁽⁷⁾. Voir par exemple T. Cazenave et A. Haraux. *Introduction aux problèmes d'évolution semi-linéaires*. Ellipses, Paris, 1990.

Le problème (3.19) pour une valeur de ν fixée est un problème de Cauchy pour une équation différentielle ordinaire du premier ordre à coefficients constants. Son unique solution s'exprime sous la forme

$$\widehat{A}(z, \nu) = \widehat{A}_0(\nu) e^{\widehat{d}_\nu z} \quad \text{où} \quad \widehat{d}_\nu = -\alpha + 2i\pi^2 \nu^2 \beta_2. \quad (3.20)$$

On en déduit que

$$\forall z \in [0, L] \quad \forall t \in \mathbb{R} \quad A(z, t) = \mathcal{F}^{-1}[\nu \mapsto \widehat{A}_0(\nu) e^{\widehat{d}_\nu z}](t) \quad (3.21)$$

où $\mathcal{F}^{-1}$ représente l'opérateur de Fourier inverse. Il est bien entendu impossible de calculer explicitement cette transformée de Fourier mais un calcul numérique à l'aide de la méthode de transformée de Fourier rapide (méthode FFT pour Fast Fourier Transform en anglais) est envisageable.

Précisons le lien existant entre l'expression de la transformée de Fourier d'une fonction $f \in \mathbb{L}^1(\mathbb{R}, \mathbb{C}) \cup \mathbb{L}^2(\mathbb{R}, \mathbb{C})$ et l'algorithme FFT qui est destiné à effectuer le calcul d'une transformée de Fourier discrète. Supposons qu'il existe un réel T strictement positif tel que en dehors de l'intervalle $[a, b]$ la fonction f prend des valeurs dont les parties réelle et imaginaire sont inférieures à la précision machine (ou inférieures à la précision souhaitée pour le calcul). D'un point de vue numérique, on peut donc supposer que la fonction f est à support dans $[a, b]$. En utilisant la formule de quadrature du point milieu, on obtient l'approximation suivante

$$\forall \nu \in [0, \frac{n}{T}] \quad \widehat{f}(\nu) \approx \int_a^b f(t) e^{-2i\pi \nu t} dt \approx \frac{T}{n} e^{i\pi \nu T} \sum_{k=0}^{n-1} f(\frac{2k-n}{2n} T) e^{-2i\pi \nu T k/n} \quad (3.22)$$

où le réel $\nu_N = n/T$ est connu comme la *fréquence de Nyquist*. Il n'est pas inutile de remarquer que la fonction de la variable ν correspondant au terme de droite de la relation précédente est une fonction périodique, de période ν_N . Il est donc illusoire de vouloir exploiter cette relation pour obtenir une valeur approchée de $\widehat{f}(\nu)$ est des points en dehors de l'intervalle $[0, \frac{n}{T}]$. La seule option possible pour obtenir une valeur approchée de $\widehat{f}(\nu')$ pour une valeur de ν' qui n'est pas dans l'intervalle $[0, \nu_N]$ consiste à choisir n un peu plus grand de sorte que $\nu' \leq \nu_N$.

Considérons une subdivision de l'intervalle $[0, \frac{n}{T}]$ de la forme $\sigma = (\nu_j)_{j=0, \dots, n}$ où $\nu_j = j/T$. D'après (3.22), on a

$$\widehat{f}(\nu_j) \approx \frac{T}{n} \underbrace{e^{i\pi j}}_{=(-1)^j} \sum_{k=0}^{n-1} f(\frac{2k-n}{2n} T) e^{-2i\pi j k/n} = \frac{T}{n} (-1)^j \sum_{k=0}^{n-1} f_k e^{-2i\pi j k/n} \quad (3.23)$$

où on a posé $f_k = f(\frac{2k-n}{2n} T)$. La somme $S_j(f_0, \dots, f_{n-1}) = \sum_{k=0}^{n-1} f_k e^{-2i\pi j \frac{k}{n}}$ s'interprète comme le j -ième terme de la transformée de Fourier discrète de $f_0, \dots, f_{n-1}$ et cette somme peut être très efficacement calculée par l'algorithme FFT. Schématiquement,

$$\forall j \in \{0, \dots, n-1\} \quad f(\frac{j}{T}) \approx \frac{T}{n} (-1)^j \text{FFT}_j(f_0, \dots, f_{n-1}) \quad (3.24)$$

où $\text{FFT}_j(f_0, \dots, f_{n-1})$ désigne le j -ième terme de la transformée de Fourier discrète de $f_0, \dots, f_{n-1}$.

Bien entendu, la transformée de Fourier inverse peut être calculée de manière très similaire. Sous MATLAB, le calcul d'une transformée de Fourier discrète par la méthode FFT est réalisée par la commande `fft` alors que la transformée de Fourier discrète inverse s'obtient par la commande `ifft`. Comme il n'existe pas d'expression mathématique universellement acceptée comme définition de la transformée de Fourier, on sera vigilant quant aux conventions choisies par l'outil de calcul numérique utilisé.

Dans le cas général, notre problème modèle ($\mathcal{P}$) doit être résolu par une autre approche. Il existe plusieurs méthodes numériques envisageables et couramment utilisées, qui d'ailleurs ne sont pas propres à la résolution de l'équation de Schrödinger mais permettent de résoudre numériquement un grand nombre d'équations aux dérivées partielles. Nous allons détailler dans la suite de ce chapitre, la méthode des différences finies qui est la plus simple des méthodes de résolution numérique d'équations aux dérivées partielles. Les autres méthodes courantes sont la méthode des éléments finis, et la méthode de split-step dont on pourra trouver la présentation de son utilisation en optique dans [2].

3.2 Étude d'un problème modèle

On considère le problème modèle suivant : trouver u tel que

$$(\mathcal{P}) \quad \begin{cases} \frac{\partial u}{\partial t}(t, x) = \alpha \frac{\partial^2 u}{\partial x^2}(t, x) + \beta u(t, x) + f(t, x) & \forall x \in [a, b] \quad \forall t \in \mathbb{R}_+^* \\ u(t, a) = u(t, b) = 0 & \forall t \in \mathbb{R}_+^* \\ u(0, x) = u_0(x) & \forall x \in [a, b] \end{cases} \quad (3.25)$$

où α désigne un réel strictement positif, β un réel⁽⁸⁾, f une fonction continue sur $\mathbb{R}^+ \times [a, b]$ et u_0 une fonction réelle de la variable réelle continue. La condition $u(0, x) = u_0(x)$ pour tout $x \in [a, b]$ est qualifiée de *condition initiale*. On doit bien entendu avoir compatibilité de la donnée initiale avec la donnée au bord, i.e. on doit avoir $u_0(a) = u_0(b) = 0$.

Les conditions aux limites de Dirichlet correspondent ici à des conditions homogènes mais on peut toujours se ramener à cette situation par un changement d'inconnue (on parle de *relèvement de la condition de Dirichlet*). Par exemple, si $u(a, t) = C_a$ et $u(b, t) = C_b$ pour tout $t > 0$, où C_a et C_b désignent deux constantes réelles, alors la fonction v définie par $v(t, x) = u(t, x) - C_a - (C_b - C_a) \frac{x-a}{b-a}$ vérifie le problème modèle $(\mathcal{P})$ où u_0 est remplacée par v_0 telle que $v_0(x) = u_0(x) - C_a - (C_b - C_a) \frac{x-a}{b-a}$ pour tout $x \in [a, b]$ et f est remplacé par la fonction g définie par $g(t, x) = f(t, x) - \beta \left(C_a + (C_b - C_a) \frac{x-a}{b-a} \right)$.



FIG. 5 Domaine de calcul considéré pour le problème modèle.

Un exemple : phénomènes thermiques dans un fil métallique

On considère un fil métallique de longueur L supposée très grande devant son rayon R . On suppose que la température à l'intérieur de la barre est homogène sur toute une section de sorte que la température dans la barre ne dépend que de la position x le long de celle-ci et on note $T(x)$ la température de la barre à l'abscisse x . À l'instant initial $t = 0$, la température dans la barre est une fonction connue T_i de la position, i.e. $T(0, x) = T_i(x)$ pour tout $x \in [0, L]$. Le long de la barre, un échange de chaleur par convection a lieu avec le milieu ambiant qui est à une température constante T_a . La température dans la barre est régie par l'équation suivante dite « équation de la chaleur »

$$\rho c_p \frac{\partial T}{\partial t}(t, x) = \kappa \frac{\partial^2 T}{\partial x^2}(t, x) - \frac{h_c}{2R} (T(t, x) - T_a) \quad (3.26)$$

où ρ désigne la masse volumique du métal (unité Kg m^{-3}), c_p sa chaleur massique (unité $\text{J Kg}^{-1} \text{K}^{-1}$) et κ sa conductivité thermique (unité $\text{W m}^{-1} \text{K}^{-1}$); h_c est le coefficient de convection thermique (unité $\text{W m}^{-2} \text{K}^{-1}$). Le terme $\kappa \frac{\partial^2 T}{\partial x^2}$ dans l'équation (3.26) prend en compte la diffusion thermique au sein de la

(8). Nous verrons ultérieurement qu'il conviendra d'imposer que β soit négatif pour que le problème soit bien posé au sens de Hadamard.

barre alors que le terme $\frac{h}{2R} (T(t, x) - T_a)$ modélise la convection thermique avec le milieu extérieur. En supposant qu'aux deux extrémités de la barre, celle-ci est isolée thermiquement, on a les conditions aux limites suivantes :

$$\forall t \in \mathbb{R}_+^* \quad \frac{\partial T}{\partial x}(t, 0) = 0 \quad \text{et} \quad \frac{\partial T}{\partial x}(t, L) = 0. \quad (3.27)$$

On complète (3.26) et (3.27) par une *condition initiale* donnant la température en tout point dans la barre à l'instant choisi comme instant initial.

L'équation (3.26) est de la forme de l'équation aux dérivées partielles de notre problème modèle puisqu'elle se ré-écrit :

$$\frac{\partial T}{\partial t}(t, x) = \frac{\kappa}{\rho c_p} \frac{\partial^2 T}{\partial x^2}(t, x) - \frac{h_c}{2R \rho c_p} T(t, x) + \frac{h_c}{2R \rho c_p} T_a.$$

On notera que $\alpha = \frac{\kappa}{\rho c_p} > 0$ et $\beta = -\frac{h_c}{2R \rho c_p} < 0$.

3.2.1 Étude de l'existence d'une solution : méthode de la séparation des variables

Compte tenu de la forme du domaine de calcul (un rectangle aux cotés parallèles aux axes de coordonnées x et t) et de l'expression des données, nous allons rechercher une solution au problème ($\mathcal{P}$) par la méthode de séparation des variables dans le cas où f est la fonction nulle. Cette méthode consiste à rechercher une solution u qui se décompose sous la forme $u(t, x) = u_1(x) u_2(t)$. En substituant cette expression dans l'équation aux dérivées partielles du problème (3.25), on obtient formellement

$$u_1(x) u_2'(t) = \alpha u_1''(x) u_2(t) + \beta u_1(x) u_2(t) \quad \forall x \in [a, b] \quad \forall t \in \mathbb{R}_+^*,$$

c'est-à-dire, si l'on suppose que u_1 et u_2 ne s'annulent jamais,

$$\frac{u_1''(x)}{u_1(x)} = \frac{u_2'(t)}{\alpha u_2(t)} - \frac{\beta}{\alpha} \quad \forall x \in [a, b] \quad \forall t \in \mathbb{R}_+^*.$$

Le membre de gauche de cette équation ne dépend que de la variable x alors que le membre de droite ne dépend lui que de la variable t . Ces deux quantités sont donc égales à une même constante K .

Considérons l'équation $u_1''(x) - K u_1(x) = 0$ pour tout $x \in [a, b]$. Selon les valeurs de K , la solution générale de cette équation est :

- pour $K > 0$, $u_1(x) = C_1 e^{\lambda x} + C_2 e^{-\lambda x}$ où $\lambda = \sqrt{K}$;
- pour $K = 0$, $u_1(x) = C_1 x + C_2$;
- pour $K < 0$, $u_1(x) = C_1 \cos(\lambda x) + C_2 \sin(\lambda x)$ où $\lambda = -\sqrt{|K|}$.

Les conditions aux limites imposent $u_1(a) = u_1(b) = 0$. Pour $K \geq 0$, cela implique que $C_1 = C_2 = 0$; on obtient $u_1 = 0$, ce qui n'est pas compatible avec l'hypothèse que u_1 ne s'annule jamais. Pour $K < 0$, les conditions aux limites impliquent

$$\begin{cases} C_1 \cos(\lambda a) + C_2 \sin(\lambda a) = 0 \\ C_1 \cos(\lambda b) + C_2 \sin(\lambda b) = 0 \end{cases}$$

Le déterminant du système linéaire vaut

$$\cos(\lambda a) \sin(\lambda b) - \cos(\lambda b) \sin(\lambda a) = \sin(\lambda(b - a)).$$

Il est non-nul, et par conséquent $C_1 = C_2 = 0$ sauf si $\lambda = \frac{k\pi}{b-a}$, $k \in \mathbb{N}^*$ et dans ce cas $C_2 = -\cotan(\lambda a) C_1$, C_1 prenant une valeur réelle quelconque. Les solutions s'expriment donc sous la forme

$$\begin{aligned} u_1(x) &= C_1 (\cos(\lambda x) - \cotan(\lambda a) \sin(\lambda x)) \\ &= \frac{C_1}{\sin(\lambda a)} (\cos(\lambda x) \sin(\lambda a) - \cos(\lambda a) \sin(\lambda x)) \\ &= -\frac{C_1}{\sin(\lambda a)} \sin(\lambda(x - a)). \end{aligned}$$

Pour $\lambda = \frac{k\pi}{b-a}$, c'est-à-dire pour $K = -\frac{k^2\pi^2}{(b-a)^2}$, la fonction u_2 vérifie l'équation différentielle

$$u_2'(t) + (\alpha\lambda^2 - \beta)u_2(t) = 0 \quad \forall t \in \mathbb{R}_+^*.$$

Les solutions sont

$$u_2 : t \in]0, +\infty[\mapsto C_3 e^{(\beta - \alpha\lambda^2)t}$$

où C_3 est une constante réelle quelconque. Les solutions à variables séparées sont donc toutes les fonctions de la forme

$$u_k : (t, x) \in [a, b] \times \mathbb{R}_+^* \mapsto C_k \sin(\lambda(x - a)) e^{(\beta - \alpha\lambda^2)t}$$

où $k \in \mathbb{N}$. La linéarité du problème aux limites ($\mathcal{P}$) implique que leur somme (infinie), c'est-à-dire la fonction u suivante

$$u : (t, x) \in [a, b] \times \mathbb{R}_+^* \mapsto \sum_{k=0}^{+\infty} C_k \sin(\lambda(x - a)) e^{(\beta - \alpha\lambda^2)t} \quad (3.28)$$

vérifie, au moins formellement,⁽⁹⁾ l'équation aux dérivées partielles et la condition aux limites. Reste à déterminer dans quels cas une telle fonction vérifie la condition initiale $u(x, 0) = u_0(x)$ pour tout $x \in [a, b]$. On a

$$u(x, 0) = \sum_{k=0}^{+\infty} C_k \sin(\lambda(x - a))$$

et cette série trigonométrique correspond au translaté de a de la série de Fourier d'une fonction impaire et périodique de période $2(b - a)$. La fonction u_0 est définie sur $[a, b]$ et s'annule en a et b en raison des conditions de compatibilité des données. Considérons la fonction $\chi_{-a}u_0 : x \in [0, b - a] \mapsto u_0(x + a)$. On peut prolonger cette fonction sur $[-b + a, b - a]$ en une fonction impaire, puis la prolonger à $\mathbb{R}$ en une fonction v_0 périodique, de période $2(b - a)$. Cette fonction v_0 admet un développement en série de Fourier qui s'écrit

$$\sum_{k=0}^{+\infty} b_k \sin(k\pi \frac{x}{b-a}) \quad \text{où} \quad b_k = \int_0^{b-a} v_0(x) \sin(k\pi \frac{x}{b-a}) dx.$$

Si nous supposons u_0 de classe $\mathcal{C}^1$ sur $[a, b]$ alors, d'après le théorème de Dirichlet,⁽¹⁰⁾ la somme de cette série de Fourier sur $[0, b - a]$ est $v_0 = \chi_{-a}u_0$. Pour satisfaire la condition initiale, on doit donc avoir

$$\forall x \in [a, b] \quad u(0, x) = \sum_{k=0}^{+\infty} C_k \sin(k\pi \frac{x-a}{b-a}) = u_0(x) = \sum_{k=0}^{+\infty} b_k \sin(k\pi \frac{x-a}{b-a})$$

où

$$b_k = \int_0^{b-a} v_0(x) \sin(k\pi \frac{x}{b-a}) dx = \int_a^b v_0(x - a) \sin(k\pi \frac{x-a}{b-a}) dx = \int_a^b u_0(x) \sin(k\pi \frac{x-a}{b-a}) dx.$$

Par unicité du développement en série de Fourier d'une fonction, on a donc $C_k = b_k$ pour tout $k \in \mathbb{N}$.

Pour être complet, il reste à vérifier que la série de fonctions $\sum_{k \in \mathbb{N}} b_k \sin(\lambda(x - a)) e^{(\beta - \alpha\lambda^2)t}$ converge sur $[a, b] \times \mathbb{R}^+$ et que les séries correspondant aux dérivées partielles par rapport à t et x convergent normalement sur $[a, b] \times [t_0, T]$ pour tout $t_0 > 0$. Cela permet de justifier⁽¹¹⁾ les dérivations « sous le signe somme » et permet d'établir que la série est bien solution de l'équation aux dérivées partielles du problème (3.25). Cette vérification est laissée à titre d'exercice. Signalons, un autre point qui mérite une vérification (celle-ci est délicate et nous l'admettons) : l'expression de la solution donnée par (3.28) est valable pour $t > 0$; il convient d'établir que pour tout $x \in [a, b]$ fixé, cette quantité tend vers $u_0(x)$ quand t tend vers 0 par valeurs supérieures.

⁽⁹⁾. Il faudra se poser, une fois obtenue l'expression de la constante C_k , la question de la convergence de cette série de fonctions.

⁽¹⁰⁾. Voir [3], théorème 6.1.

⁽¹¹⁾. Voir [3], théorème 3.9.

3.2.2 Énergie du système du physique modélisé en l'absence de terme source

Soit u la solution du problème aux limites (3.25) considéré en l'absence de terme source, c'est-à-dire dans le cas où $f = 0$. Pour tout $t \in \mathbb{R}^+$, la quantité

$$E(t) = \int_a^b u^2(t, x) \, dx = \|u(\cdot, t)\|_{\mathbb{L}^2([a, b])}^2 \quad (3.29)$$

peut être interprétée comme l'énergie du système physique modélisé par le problème modèle ($\mathcal{P}$). Cette quantité est toujours positive. En supposant que le théorème de dérivabilité d'une fonction définie par une intégrale⁽¹²⁾ s'applique, on obtient

$$E'(t) = \int_a^b \frac{\partial}{\partial t} u^2(t, x) \, dx = 2 \int_a^b u(t, x) \frac{\partial}{\partial t} u(t, x) \, dx = 2\alpha \int_a^b u(t, x) \frac{\partial^2}{\partial x^2} u(t, x) \, dx + 2\beta \int_a^b u(t, x)^2 \, dx,$$

la dernière égalité étant liée au fait que u est solution du problème aux limites (3.25). Comme u s'annule en a et b pour tout $t \in \mathbb{R}^+$, en intégrant par parties, on obtient

$$E'(t) = -2\alpha \int_a^b \left(\frac{\partial}{\partial x} u(t, x) \right)^2 \, dx + 2\beta \int_a^b u(t, x)^2 \, dx = -2\alpha \int_a^b \left(\frac{\partial}{\partial x} u(t, x) \right)^2 \, dx + 2\beta E(t).$$

En multipliant membre de droite et membre de gauche par $e^{-2\beta t}$, on en déduit que

$$\left(e^{-2\beta t} E(t) \right)' = E'(t) e^{-2\beta t} - 2\beta e^{-2\beta t} E(t) = -2\alpha e^{-2\beta t} \int_a^b \left(\frac{\partial}{\partial x} u(t, x) \right)^2 \, dx$$

Comme $\alpha > 0$, on en déduit que pour tout $t \in \mathbb{R}^+$, on a $(e^{-2\beta t} E(t))' \leq 0$, autrement dit que la fonction $F : t \in \mathbb{R}^+ \mapsto e^{-2\beta t} E(t)$ est décroissante. En particulier, pour tout $t \in \mathbb{R}^+$, on a

$$F(t) = e^{-2\beta t} E(t) \leq F(0) = E(0) = \|u_0\|_{\mathbb{L}^2([a, b])}^2 \quad (3.30)$$

et donc $E(t) \leq e^{2\beta t} \|u_0\|_{\mathbb{L}^2([a, b])}^2$. Ainsi, dans le cas où $\beta \leq 0$ l'énergie E du système décroît au cours du temps et

$$\forall t \in \mathbb{R}_+^* \quad 0 \leq E(t) \leq E(0) = \|u_0\|_{\mathbb{L}^2([a, b])}^2. \quad (3.31)$$

Comme le terme source f est nul, c'est le comportement physique auquel on s'attend. Remarquons que si $\beta > 0$, alors il se peut que l'énergie du système croisse en l'absence de sources, ce qui est absurde d'un point de vue physique. *Il convient donc de supposer que $\beta \leq 0$ pour que le problème aux limites (3.25) soit bien posé.* On notera que c'est bien le cas pour la situation décrite à la section ?? où l'équation (3.26) correspond à notre équation modèle avec $\beta = -\frac{h_c}{2R}$ où h_c est le coefficient de convection thermique et R le rayon du barreau métallique. C'est également le cas dans la situation décrite à la section 3.1.2 où l'équation (3.13) correspond à notre équation modèle où β est l'opposé de la constante d'atténuation de la fibre.

3.2.3 Unicité de la solution au problème modèle

Supposons que le problème aux limites (3.25) admette deux solutions u_1 et u_2 et considérons la fonction $v = u_2 - u_1$. Cette fonction vérifie

$$\begin{cases} \frac{\partial v}{\partial t}(t, x) = \alpha \frac{\partial^2 v}{\partial x^2}(t, x) + \beta v(t, x) & \forall x \in [a, b] \, \forall t \in \mathbb{R}_+^* \\ v(t, a) = v(t, b) = 0 & \forall t \in \mathbb{R}_+^* \\ v(0, x) = 0 & \forall x \in [a, b] \end{cases}$$

qui est un problème de la forme de notre problème modèle avec une donnée initiale nulle et un second membre f nul. La relation (3.30) indique que pour ce problème $0 \leq F(t) \leq F(0) = 0$ pour tout $t \in \mathbb{R}_+$, autrement dit, que $F(t) = e^{-2\beta t} \|v(\cdot, t)\|_{\mathbb{L}^2([a, b])}^2 = 0$ pour tout $t \in \mathbb{R}_+^*$. On en déduit donc que $v(t, \cdot)$ est nulle pour tout $t \in \mathbb{R}_+$. La fonction v est donc la fonction nulle, ce qui implique que $u_1 = u_2$. Ainsi, la solution de notre problème modèle est unique.

⁽¹²⁾. Voir [15], théorème 2.3.

Remarques 3.1

1. Signalons que la méthode de séparation des variables nous a fourni une unique solution, mais rien n'indiquait qu'une autre méthode de résolution ne pouvait pas fournir une solution différente. On vient d'établir que ce n'est pas le cas : toute méthode de résolution fournirait la solution que nous avons construite. Par ailleurs, même dans le cas où la fonction f est quelconque et donc dans le cas où la méthode de séparation des variables ne s'applique pas, le raisonnement qui vient d'être fait indique que la solution est unique.
2. On remarquera aussi que le raisonnement qui vient d'être fait indique que la solution est unique quelle que soit le signe de β .

3.2.4 Problème bien posé au sens de Hadamard

Terminons en remarquant que dans le cas où $\beta \leq 0$, la relation (3.31) indique que

$$\forall t \in \mathbb{R}^+ \quad \|u(t, \cdot)\|_{\mathbb{L}^2([a,b])} \leq \|u_0\|_{\mathbb{L}^2([a,b])}$$

ce qui traduit que la solution en tout temps dépend continûment de la donnée u_0 . On peut en conclure que dans le cas où $\beta \leq 0$, le problème modèle est bien posé au sens de Hadamard : il admet une unique solution qui dépend continûment des données.

Par contre, dans le cas où $\beta > 0$, la relation (3.30) indique que

$$\forall t \in \mathbb{R}^+ \quad \|u(t, \cdot)\|_{\mathbb{L}^2([a,b])} \leq e^{\beta t} \|u_0\|_{\mathbb{L}^2([a,b])}$$

et $\lim_{t \rightarrow +\infty} e^{\beta t} \|u_0\|_{\mathbb{L}^2([a,b])} = +\infty$. La solution ne va pas être bornée, ce que l'on observe sur l'expression (3.28) de la solution obtenue par la méthode de séparation de variables.

3.3 Approximation par un schéma différences finies explicite du problème modèle

3.3.1 Construction du schéma différences finies

Considérons une subdivision uniforme $(x_j)_{j=0,\dots,J}$ de l'intervalle $[a,b]$ de pas $h_x = \frac{b-a}{J}$ constant. Nous considérons également un intervalle de temps de la forme $[0, T]$ où $T > 0$. Nous allons chercher à déterminer une valeur approchée de la solution du problème modèle ($\mathcal{P}$) en chaque nœud x_j de la subdivision pour tout $t \in [0, T]$. On pourra remarquer que compte tenu des conditions de Dirichlet homogènes, il n'est pas nécessaire d'effectuer un calcul pour les nœuds x_0 et x_J : les valeurs prises par la solution en ces nœuds sont connues ; il s'agit de la valeur 0.

Pour tout $t \in [0, T]$ et pour tout $j \in \{1, \dots, J-1\}$, on considère l'approximation par différence finie centrée

$$\frac{\partial^2}{\partial x^2} u(t, x_j) \approx \frac{u(t, x_{j-1}) - 2u(t, x_j) + u(t, x_{j+1}))}{h_x^2}. \quad (3.32)$$

Bien entendu, compte tenu des conditions de Dirichlet homogènes pour $x = x_1$, la formule d'approximation se simplifie en

$$\frac{\partial^2}{\partial x^2} u(t, x_1) \approx \frac{u(t, x_2) - 2u(t, x_1)}{h_x^2} \quad (3.33)$$

et pour $x = x_{J-1}$ elle se simplifie en

$$\frac{\partial^2}{\partial x^2} u(t, x_{J-1}) \approx \frac{u(t, x_{J-2}) - 2u(t, x_{J-1})}{h_x^2}. \quad (3.34)$$

Il nous faut à présent introduire la « discrétisation » relativement à la seconde variable : la variable d'espace t . Considérons une subdivision uniforme $(t_n)_{n=0,\dots,N}$ de l'intervalle $[0, T]$ de pas $h_t = \frac{T}{N}$ constant et utilisons l'approximation par différence finie progressive

$$\frac{\partial}{\partial t} u(t_n, x) \approx \frac{u(t_{n+1}, x) - u(t_n, x)}{h_t}. \quad (3.35)$$

Nous sommes à présent en mesure d'écrire la forme discrète prise, après introduction des schémas d'approximation par différences finies (3.32) et (3.35), par notre problème modèle ($\mathcal{P}$) aux noeuds $(t_n, x_j)_{n \in \{0, \dots, N\}, j \in \{0, \dots, J\}}$ du « maillage » de notre domaine de calcul $[0, T] \times [a, b]$. La manière la plus naturelle de procéder est de considérer la formule d'approximation (3.32) en t_n et la formule d'approximation (3.35) en x_j . Le problème discret va consister à trouver une approximation $u_j^{[n]}$ de $u(t_n, x_j)$ pour tous $n \in \{0, \dots, N-1\}$, $j \in \{1, \dots, J-1\}$ tel que

$$\frac{u_j^{[n+1]} - u_j^{[n]}}{h_t} = \alpha \frac{u_{j-1}^{[n]} - 2u_j^{[n]} + u_{j+1}^{[n]}}{h_x^2} + \beta u_j^{[n]} + f(t_n, x_j). \quad (3.36)$$

avec $u_j^{[0]} = u_0(x_j)$ pour tout $j \in \{0, \dots, J\}$ et $u_0^{[n]} = u_J^{[n]} = 0$ pour tout $n \in \{0, \dots, N-1\}$. On a donc pour tout $j \in \{1, \dots, J-1\}$

$$u_j^{[n+1]} = \frac{\alpha h_t}{h_x^2} u_{j-1}^{[n]} + \left(1 + \beta h_t - \frac{2\alpha h_t}{h_x^2}\right) u_j^{[n]} + \frac{\alpha h_t}{h_x^2} u_{j+1}^{[n]} + h_t f(t_n, x_j). \quad (3.37)$$

Afin d'obtenir une forme plus facilement exploitable de ce schéma d'approximation, introduisons les vecteurs de $\mathbb{C}^{J-1}$ suivants pour $n \in \{0, \dots, N-1\}$

$$U^{[n]} = \begin{pmatrix} u_1^{[n]} \\ \vdots \\ u_{J-1}^{[n]} \end{pmatrix} \quad \text{et} \quad F^{[n]} = h_t \begin{pmatrix} f(t_n, x_1) \\ \vdots \\ f(t_n, x_{J-1}) \end{pmatrix}. \quad (3.38)$$

Sous forme matricielle, l'équation (3.37) s'écrit, pour tout $n \in \{0, \dots, N-1\}$,

$$U^{[n+1]} = \left((1 + \beta h_t) \mathbf{I} - \frac{\alpha h_t}{h_x^2} \mathbf{M} \right) U^{[n]} + F^{[n]} \quad (3.39)$$

où la matrice $\mathbf{M}$ est la matrice de $\mathcal{M}_{J-1}(\mathbb{R})$ donnée par

$$\mathbf{M} = \begin{pmatrix} 2 & -1 & & & \\ -1 & 2 & -1 & & \\ & -1 & \ddots & \ddots & \\ & & \ddots & \ddots & -1 \\ & & & -1 & 2 \end{pmatrix}. \quad (3.40)$$

On dispose ainsi d'un schéma numérique explicite pour calculer une solution approchée de notre problème modèle ($\mathcal{P}$). On effectue l'initialisation suivante à partir de la donnée initiale u_0 :

$$U^{[0]} = \begin{pmatrix} u_0(t_1) \\ \vdots \\ u_0(t_{J-1}) \end{pmatrix} \quad (3.41)$$

puis on calcule les termes $1, \dots, N$ de la suite $(U^{[n]})_n$ de vecteurs de $\mathbb{C}^{J-1}$ par la relation de récurrence (3.39) :

$$U^{[n+1]} = \left((1 + \beta h_t) \mathbf{I} - \frac{\alpha h_t}{h_x^2} \mathbf{M} \right) U^{[n]} + F^{[n]}. \quad (3.42)$$

Les valeurs des composantes du vecteur $U^{[n]}$ fournissent les valeurs aux noeuds $x_j, j = 1, \dots, J-1$ d'une solution approchée du problème modèle au temps t_n .

Le programme MATLAB suivant met en oeuvre le schéma différences finies (3.41)–(3.42) pour résoudre le problème modèle ($\mathcal{P}$). On calcule en tout noeud t_n de discrétisation en temps, une approximation de la

norme de la solution dans $L^2([a, b])$ calculée par la formule des rectangles à gauche de la manière suivante :

$$\begin{aligned} \|u(t_n, \cdot)\|_{L^2([a, b])} &= \left(\int_a^b u(t_n, x)^2 dx \right)^{\frac{1}{2}} = \left(\sum_{j=0}^{J-1} \int_{x_j}^{x_{j+1}} u(t_n, x)^2 dx \right)^{\frac{1}{2}} \\ &\approx \left(\sum_{j=0}^{J-1} h_x u(t_n, x_j)^2 dx \right)^{\frac{1}{2}} = \sqrt{h_x} \|U^{[n]}\|_2 \quad (\text{car } u(t_n, a) = 0). \end{aligned}$$

```
% Données
a=0; b=1;
T=1;
alpha=1;
beta=0;
sigma=0.1; % paramètre pour la donnée initiale
u0=@(x)exp(-(x-(a+b)/2).^2/(2*sigma^2)); % donnée initiale : une gaussienne
f=@(x,t) 0;
% Paramètres de discrétisation
J=input('Nombre de subdivision de [a,b] : ');
hx=(b-a)/J;
X=a+hx:hx:b-hx;
N=input('Nombre de subdivision de [0,T] : ');
ht=T/N;
% Construction de la matrice d'itération
M=2*eye(J-1)-diag(ones(1,J-2),1)-diag(ones(1,J-2),-1);
D=(1+beta*ht)*eye(J-1) - (alpha*ht/(hx^2))*M;
% on affiche la solution au temps initial
U=transpose(u0(X));
plot(X,U)
hold on
disp(['norme de la donnée initiale : ', num2str(sqrt(hx)*norm(U),6)]);
% Boucle sur les noeuds de discrétisation temporelle
for n=1:N
    F=ht*f(X,n*ht);
    U=D*U+F;
    disp(['norme de la solution à la ', num2str(n), 'e itération : ', num2str(sqrt(hx)*norm(U),6)]);
    plot(X,U) % on affiche la solution au temps courant
end
```

Testons le schéma différences finies pour résoudre le problème modèle.

```
> main
Nombre de subdivision de [a,b] : 100
Nombre de subdivision de [0,T] : 20
norme de la donnée initiale : 0.421005
norme de la solution à la 1e itération : 1.61297
norme de la solution à la 2e itération : 23.8702
norme de la solution à la 3e itération : 710.37
norme de la solution à la 4e itération : 632969
norme de la solution à la 5e itération : 1.06763e+09
norme de la solution à la 6e itération : 1.85883e+12
norme de la solution à la 7e itération : 3.30667e+15
norme de la solution à la 8e itération : 5.97537e+18
norme de la solution à la 9e itération : 1.0928e+22
norme de la solution à la 10e itération : 2.0175e+25
norme de la solution à la 11e itération : 3.75319e+28
norme de la solution à la 12e itération : 7.02617e+31
norme de la solution à la 13e itération : 1.3223e+35
```

```

norme de la solution à la 14e itération : 2.49972e+38
norme de la solution à la 15e itération : 4.74389e+41
norme de la solution à la 16e itération : 9.03317e+44
norme de la solution à la 17e itération : 1.72516e+48
norme de la solution à la 18e itération : 3.30337e+51
norme de la solution à la 19e itération : 6.34014e+54
norme de la solution à la 20e itération : 1.21941e+58

```

Il y a donc visiblement un problème ! On pourra effectuer d'autres exécutions avec des valeurs différentes des paramètres physiques et numériques et on s'apercevra que la situation observée se reproduit assez systématiquement et n'est donc pas spécifique au jeu de paramètres choisi. Par ailleurs, on aura beau rechercher une éventuelle erreur dans le programme MATLAB, on n'en trouvera pas. Nous allons voir que le phénomène observé est inhérent à la méthode des différences finies pour le schéma d'approximation choisi ici et relève de la notion de stabilité.

3.3.2 Notion de stabilité pour un schéma de différences finies

Le schéma différence finie (3.36) pour calculer une approximation de la solution du problème modèle (3.25) pour $t \in [0, T]$, avec $T > 0$ fixé, s'écrit sous la forme suivante : $U^{[0]}$ étant défini par (3.41), pour tout $n \in \{0, \dots, N-1\}$,

$$U^{[n+1]} = D U^{[n]} + F^{[n]} \quad (3.43)$$

où la matrice D est la matrice de $\mathcal{M}_{J-1}(\mathbb{R})$ donnée par

$$D = (1 + \beta h_t) I - \frac{\alpha h_t}{h_x^2} M$$

avec la matrice M définie en (3.40) et

$$U^{[n]} = \begin{pmatrix} u_1^{[n]} \\ \vdots \\ u_{J-1}^{[n]} \end{pmatrix} \quad \text{et} \quad F^{[n]} = h_t \begin{pmatrix} f(t_n, x_1) \\ \vdots \\ f(t_n, x_{J-1}) \end{pmatrix}$$

sont deux vecteurs de $\mathbb{R}^{J-1}$. Plus généralement, nous pouvons envisager un schéma d'approximation différences finies pour le problème modèle (3.25) qui soit de la forme $U^{[0]}$ étant défini par (3.41), pour tout $n \in \{0, \dots, N-1\}$,

$$D_1 U^{[n+1]} = D_2 U^{[n]} + F^{[n]} \quad (3.44)$$

où D_1 et D_2 sont deux matrice de $\mathcal{M}_{J-1}(\mathbb{R})$.

Définissons à présent la notion de stabilité pour un schéma d'approximation numérique du problème modèle (3.25) de la forme (3.44).

DÉFINITION 3.1 *Considérons un schéma d'approximation numérique du problème modèle (3.25) où $t \in [0, T]$, avec $T > 0$ fixé, défini pour $J, N \in \mathbb{N}^*$ fixés par : $U^{[0]} \in \mathbb{K}^{J-1}$ et pour tout $n \in \{0, \dots, N-1\}$, $D_1 U^{[n+1]} = D_2 U^{[n]} + F^{[n]}$ où D_1 et D_2 sont deux matrice de $\mathcal{M}_{J-1}(\mathbb{R})$ et $F^{[n]}$ un vecteur de $\mathbb{K}^{J-1}$.*

— *On dit que le schéma est inconditionnellement stable pour une norme $\|\cdot\|$ de $\mathbb{K}^{J-1}$, s'il existe $C_1, C_2 \in \mathbb{R}^+$ tel que pour tout $J, N \in \mathbb{N}^*$*

$$\forall n \in \{1, \dots, N\} \quad \|U^{[n]}\| \leq C_1 \|U^{[0]}\| + C_2 \max_{n \in \{1, \dots, N\}} \|F^{[n]}\|.$$

— *Soit $\mathcal{S}$ un sous-ensemble de $\mathbb{R}_+^* \times \mathbb{R}_+^*$ tel que $(0, 0) \in \overline{\mathcal{S}}$. On dit que le schéma est stable sous la condition $(h_x, h_t) \in \mathcal{S}$ s'il existe $C_1, C_2 \in \mathbb{R}^+$ tel que pour tout $J, N \in \mathbb{N}^*$ tels que $(h_x, h_t) = (\frac{b-a}{J}, \frac{T}{N}) \in \mathcal{S}$, on a*

$$\forall n \in \{1, \dots, N\} \quad \|U^{[n]}\| \leq C_1 \|U^{[0]}\| + C_2 \max_{n \in \{1, \dots, N\}} \|F^{[n]}\|.$$

Remarques 3.2

1. Le fait qu'un schéma numérique itératif est stable assure que les erreurs (les erreurs sur les données, les erreurs de la méthode ou les erreurs d'arrondis) ne vont pas, au cours des itérations, être amplifiées de manière trop importantes.
2. On notera que la notion de stabilité d'un schéma aux différences finies n'est pas liée au problème aux limites pour lequel ce schéma fournit une solution approchée. La notion de stabilité fait uniquement référence au schéma lui-même et dans ce cas précis à la manière dont la solution croît au cours des itérations du schéma qui doit être contrôlée par la donnée initiale $U^{[0]}$ et le second membre $F^{[n]}$ du schéma.

Pour l'étude de la stabilité du schéma de différences finies (3.41)–(3.42), nous aurons recours au lemme suivant.

LEMME 3.1 *Les valeurs propres de la matrice $M \in \mathcal{M}_{J-1}(\mathbb{R})$ définie à la relation (3.40) sont les $J-1$ réels strictement positifs distincts donnés par*

$$\lambda_k = 2 \left(1 - \cos\left(\frac{k\pi}{J}\right)\right) \quad \forall k \in \{1, \dots, J-1\}.$$

L'espace propre associé à la valeur propre λ_k admet pour vecteur de base le vecteur $U^{[k]} \in \mathbb{R}^{J-1}$ dont les composantes sont

$$u_j^{[k]} = \sin(k\pi \frac{j}{J}) \quad \forall j \in \{1, \dots, J-1\}.$$

Démonstration La matrice M est une matrice symétrique définie positive de dimension $J-1$, voir le chap. 1 p. 24. Elle admet donc $J-1$ valeurs propres réelles (cette propriété résulte du fait que M est symétrique) et ces réels sont strictement positifs (cette propriété résulte du fait que M est définie positive). Soit λ une valeur propre de M et U un vecteur propre associé. La relation $M U = \lambda U$ s'écrit sous la forme du système linéaire

$$\begin{cases} (2-\lambda)u_1 - u_2 &= 0 \\ -u_{j-1} + (2-\lambda)u_j - u_{j+1} &= 0 \quad \forall j = 2, \dots, J-2 \\ -u_{J-2} + (2-\lambda)u_{J-1} &= 0 \end{cases} \quad (3.45)$$

Cherchons une solution de ce système linéaire sous la forme ⁽¹³⁾

$$u_j = C_1 e^{ij\beta} + C_2 e^{-ij\beta} \quad \forall j = 1, \dots, J-1 \quad (3.46)$$

où C_1, C_2 et β sont des constantes réelles et $i = \sqrt{-1}$. De la relation (3.46), on déduit que pour tout $j \in \{2, \dots, J-2\}$,

$$-u_{j-1} + (2-\lambda)u_j - u_{j+1} = (C_1 e^{ij\beta} + C_2 e^{-ij\beta}) \left(-e^{-i\beta} + (2-\lambda) - e^{i\beta} \right).$$

On a donc $-u_{j-1} + (2-\lambda)u_j - u_{j+1} = 0$ (voir système (3.45)) si, et seulement si, β est choisi tel que

$$-e^{-i\beta} + (2-\lambda) - e^{i\beta} = 0.$$

On a dans ce cas

$$\lambda = 2 \left(1 - \cos(\beta)\right).$$

Considérons à présent la première équation du système (3.45). Compte tenu de (3.46), elle s'écrit

$$(2-\lambda) \left(C_1 e^{i\beta} + C_2 e^{-i\beta} \right) - \left(C_1 e^{2i\beta} + C_2 e^{-2i\beta} \right) = 0 \quad (3.47)$$

⁽¹³⁾. On pourra remarquer que l'on a une suite récurrente d'ordre 2 de la forme $u_{j+1} = -u_{j-1} + (2-\lambda)u_j$ pour tout $j \geq 1$ (en posant $u_0 = 0$) et on peut utiliser le cadre mathématique correspondant à l'étude de telles suites. L'expression suggérée ici pour rechercher une solution est directement inspirée de ce cadre théorique.

avec $2 - \lambda = e^{i\beta} + e^{-i\beta} = 2\cos(\beta)$. En développant (3.47), il vient

$$C_1 + C_2 = 0. \quad (3.48)$$

Considérons enfin la dernière équation du système (3.45). Compte tenu de (3.46), elle s'écrit

$$-u_{J-2} + (2 - \lambda)u_{J-1} = -C_1 e^{i(J-2)\beta} - C_2 e^{-i(J-2)\beta} + (e^{i\beta} + e^{-i\beta}) (C_1 e^{i(J-1)\beta} + C_2 e^{-i(J-1)\beta}) = 0.$$

En développant et en simplifiant cette expression, il vient

$$C_1 e^{iJ\beta} + C_2 e^{-iJ\beta} = 0. \quad (3.49)$$

On déduit des relations (3.48) et (3.49) que

$$C_1 (e^{iJ\beta} + e^{-iJ\beta}) = 2iC_1 \sin(J\beta) = 0.$$

Pour que cette relation soit satisfaite, il faut soit que $C_1 = 0$, soit que β soit tel que $\sin(J\beta) = 0$. La première possibilité impliquerait que $U = 0$, ce qui est impossible pour un vecteur propre. On a donc nécessairement $\sin(J\beta) = 0$, autrement dit

$$\beta = \frac{k\pi}{J} \quad \text{avec } k \in \mathbb{Z}.$$

On en déduit que les valeurs propres de la matrice M sont de la forme

$$\lambda = 2(1 - \cos(\beta)) = 2(1 - \cos(\frac{k\pi}{J})) \quad \text{avec } k \in \mathbb{Z}.$$

Notons que compte tenu de la périodicité de la fonction sinus, les valeurs distinctes obtenues pour les valeurs propres de la matrice M sont

$$\lambda_k = 2(1 - \cos(\frac{k\pi}{J})) \quad \text{où } k \in \{0, \dots, J\}.$$

Notons par ailleurs que pour $k = 0$, on obtient $\lambda_0 = 0$. Comme la matrice M est symétrique définie positive, elle est inversible et 0 ne peut être valeur propre. Notons enfin que pour $k = J$, on a $\beta = \pi$ (et $\lambda_J = 4$) et les éventuels vecteurs propres associés ont pour composantes

$$u_j = C_1 e^{ij\beta} + C_2 e^{-ij\beta} = C_1 (e^{ij\pi} - e^{-ij\pi}) = 2\pi i C_1 \sin(j\pi) = 0 \quad \text{avec } C_1 \in \mathbb{R}.$$

Cette possibilité doit donc être également exclue car un vecteur propre ne peut être nul. Finalement, les $J - 1$ valeurs propres distinctes de la matrice M sont

$$\lambda_k = 2(1 - \cos(\frac{k\pi}{J})) \quad \text{où } k \in \{1, \dots, J - 1\}.$$

On déduit finalement de la relation (3.46) que l'espace propre associé à la valeur propre λ_k admet pour vecteur de base le vecteur $U^{[k]}$ dont les composantes sont

$$u_j^{[k]} = \sin(k\pi \frac{j}{J}) \quad j = 1, \dots, J - 1.$$

□

Le résultat suivant indique que le schéma de différences finies (3.41)–(3.42) n'est pas *inconditionnellement stable*. Pour avoir stabilité du schéma numérique, le pas de discrétisation en espace h_x et le pas de discrétisation en temps h_t doivent vérifier une certaine condition. Si cette condition n'est pas satisfaite, la suite des itérés $U^{[n]}$ est susceptible de diverger.

PROPOSITION 3.1 *On suppose que $\alpha > 0$ et que $\beta \leq 0$. Le schéma de différences finies (3.41)–(3.42) est stable pour la norme euclidienne si le pas de discrétisation en espace h_x et le pas de discrétisation en temps h_t vérifient la condition :*

$$h_t \left(\frac{4\alpha}{h_x^2} - \beta \right) \leq 2. \quad (3.50)$$

Démonstration Désignons par D la matrice de notre schéma de différences finies (3.41)–(3.42), i.e.

$$D = \left((1 + \beta h_t) I - \frac{\alpha h_t}{h_x^2} M \right) = \mu I - \nu M$$

où μ et ν sont les deux réels définis par

$$\mu = 1 + \beta h_t \quad \text{et} \quad \nu = \frac{\alpha h_t}{h_x^2}.$$

Un raisonnement par récurrence immédiat permet d'établir, à partir de la relation (3.42), que pour tout $n \in \mathbb{N}^*$ on a

$$U^{[n]} = D^n U^{[0]} + \sum_{k=0}^{n-1} D^k F^{[n-k]}$$

On en déduit que pour toute norme vectorielle $\| \cdot \|$ sur $\mathbb{R}^{J-1}$, on a

$$\begin{aligned} \|U^{[n]}\| &\leq \|D^n\| \|U^{[0]}\| + \sum_{k=0}^{n-1} \|D^k\| \|F^{[n-k]}\| \\ &\leq \|D\|^n \|U^{[0]}\| + \sum_{k=0}^{n-1} \|D\|^k \|F^{[n-k]}\| \\ &\leq \|D\|^n \|U^{[0]}\| + \left(\sum_{k=0}^{n-1} \|D\|^k \right) \max_{\ell \in \{0, \dots, n-1\}} \|F^{[\ell]}\| \end{aligned}$$

où $\|D\|$ désigne la norme matricielle subordonnée⁽¹⁴⁾ à la norme vectorielle $\| \cdot \|$ de $\mathbb{R}^{J-1}$. Notons que la somme $\sum_{k=0}^{n-1} \|D\|^k$ correspond à la somme des n premiers termes d'une progression géométrique. On a donc

$$\sum_{k=0}^{n-1} \|D\|^k = \begin{cases} \frac{1 - \|D\|^n}{1 - \|D\|} & \text{si } \|D\| \neq 1 \\ n & \text{si } \|D\| = 1 \end{cases}$$

et cette quantité diverge quand n tend vers $+\infty$ si $\|D\| \geq 1$. On en déduit que

- Si f est nul et si $\|D\| \leq 1$ alors le schéma sera stable pour la norme $\| \cdot \|$;
- Si f est non nul et si $\|D\| < 1$ alors le schéma sera stable pour la norme $\| \cdot \|$.

Par simplicité des calculs, considérons la norme euclidienne $\| \cdot \|_2$ de $\mathbb{R}^{J-1}$. Nous sommes donc conduit à déterminer la norme spectrale de la matrice D telle que

$$\|D\|_2 = \sup_{X \in \mathbb{R}^{J-1}} \frac{\|DX\|_2}{\|X\|_2} = \sqrt{\rho(DD^*)}$$

où le réel positif $\rho(DD^*)$ désigne le rayon spectral de la matrice DD^* . La matrice D étant une matrice symétrique réelle, elle n'admet que des valeurs propres réelles et on a

$$\|D\|_2 = \rho(D)$$

où le réel positif $\rho(D)$ désigne le rayon spectral de la matrice D . Il s'agit donc de déterminer la plus grande valeur prise, en module, par les valeurs propres de la matrice D . Comme $D = \mu I - \nu M$, le scalaire λ est valeur propre de D si, et seulement si, $\frac{1}{\nu}(\mu - \lambda)$ est valeur propre de M . D'après le lemme 3.1, les valeurs propres de la matrice M sont les $J - 1$ réels

$$\lambda_j^M = 2 \left(1 - \cos\left(\frac{j\pi}{J}\right) \right) \quad j = 1, \dots, J - 1.$$

⁽¹⁴⁾. Voir [3], chap. 9.

On en déduit que les valeurs propres λ de la matrice D sont les réels $\lambda_j = \mu - \nu \lambda_j^M$ où $j = 1, \dots, J-1$. Pour tout $j = 1, \dots, J-1$, on a

$$\lambda_j = \mu - 2\nu \left(1 - \cos\left(\frac{j\pi}{J}\right)\right) = (1 + \beta h_t) - \frac{2\alpha h_t}{h_x^2} \left(1 - \cos\left(\frac{j\pi}{J}\right)\right).$$

Comme pour tout $j = 1, \dots, J-1$, on a

$$0 < 1 - \cos\left(\frac{\pi}{J}\right) \leq 1 - \cos\left(\frac{j\pi}{J}\right) \leq 1 - \cos\left(\frac{(J-1)\pi}{J}\right) < 2$$

et comme $\nu > 0$, on en déduit l'encadrement suivant des valeurs propres de D ,

$$(1 + \beta h_t) - \frac{4\alpha h_t}{h_x^2} < (1 + \beta h_t) - \frac{2\alpha h_t}{h_x^2} \left(1 - \cos\left(\frac{(J-1)\pi}{J}\right)\right) \leq \lambda_j \leq (1 + \beta h_t) - \frac{2\alpha h_t}{h_x^2} \left(1 - \cos\left(\frac{\pi}{J}\right)\right) < 1 + \beta h_t.$$

Ainsi, pour que toutes les valeurs propres de D soient, en valeur absolue, strictement inférieures à 1, il suffit que

$$1 + \beta h_t \leq 1 \quad \text{et} \quad (1 + \beta h_t) - \frac{4\alpha h_t}{h_x^2} \geq -1.$$

La première condition est réalisée pour $\beta \leq 0$. La seconde condition impose $(1 + \beta h_t) - \frac{4\alpha h_t}{h_x^2} \leq 2$. Cette condition de stabilité se ré-écrit

$$h_t \left(\frac{4\alpha}{h_x^2} - \beta \right) \leq 2.$$

La condition suffisante de stabilité est démontrée. □

Remarque 3.3 La démonstration précédente indique bien que la condition CFL (3.50) est une condition suffisante de stabilité. Compte tenu des majorations effectuées, il se peut que dans certaines situations le schéma soit stable même si la condition n'est pas satisfaite.

COROLLAIRE 3.1 Dans le cas où $\beta = 0$, la condition de stabilité s'écrit

$$\frac{\alpha h_t}{h_x^2} \leq \frac{1}{2}.$$

et elle est connu sous le nom de condition de Courant-Fischer-Lax (CFL).

Remarque 3.4 Nous sommes à présent en mesure de comprendre les résultats observés à l'exemple numérique de la page 80 concernant la résolution de notre problème modèle ($\mathcal{P}$). On est dans une situation où $\beta = 0$, ce qui d'après la proposition 3.1 et compte tenu des valeurs prises pour h_t et h_x , correspond à une situation où le schéma différences finies (3.41)–(3.42) est instable.

La condition (3.50) peut être considérée comme extrêmement contraignante. En effet, si le terme source u_0 nécessite, pour être bien représenté, d'introduire une discrétisation spatiale fine alors h_x est petit et si α n'est pas trop petit, le pas de la discrétisation temporelle h_t qui doit vérifier la condition $h_t \leq h_x^2/2|\alpha|$ devient extrêmement petit, entraînant un temps de calcul pour la résolution de notre problème modèle ($\mathcal{P}$) extrêmement long. Nous allons dans la partie suivante voir comment il est possible d'obtenir un schéma de différences finies inconditionnellement stable, c'est-à-dire dont la stabilité est assurée sans qu'aucune condition n'ait à être imposée sur les tailles respectives des pas des discrétisation spatiale et temporelle.

3.3.3 Notion de consistance d'un schéma de différences finies

Dans l'étude des propriétés d'un schéma de différences finies, outre la stabilité, un point essentiel est l'étude de la consistance du schéma. De manière simplifiée, cette étude consiste à regarder la manière dont la solution exacte du problème étudié satisfait au schéma numérique. L'idée sous-jacente étant que si la solution exacte ne satisfait pas suffisamment bien au schéma, celui-ci pourra difficilement en fournir une approximation de bonne qualité.

Pour le schéma (3.36) étudié dans cette partie, l'erreur de consistance au nœud (t_n, x_j) pour $n \in \{0, \dots, N\}$ et $j \in \{0, \dots, J\}$, notée $\varepsilon_j^{[n]}$, est donnée par la relation suivante directement issue de (3.36)

$$\begin{aligned} \frac{u(t_{n+1}, x_j) - u(t_n, x_j)}{h_t} = & \alpha \frac{u(t_n, x_{j-1}) - 2u(t_n, x_j) + u(t_n, x_{j+1}))}{h_x^2} \\ & + \beta u(t_n, x_j) + f(t_n, x_j) + \boxed{\varepsilon_j^{[n]}} \end{aligned} \quad (3.51)$$

où $u(t_n, x_j)$ désigne la solution exacte de notre problème modèle (3.25) au nœud (t_n, x_j) .

Un schéma sera dit consistant si l'erreur de consistance tend vers 0 lorsque les pas de discrétisation en temps h_t et en espace h_x tendent vers 0.

Formalisons un peu les choses. Désignons par $\varepsilon^{[n]}$ le vecteur de $\mathbb{K}^{J-1}$ dont les composantes $\varepsilon_j^{[n]}$ sont les erreurs de consistance de ce schéma aux nœuds (t_n, x_j) , $j \in \{1, \dots, J-1\}$. (Compte tenu des conditions de Dirichlet considérées dans le problème modèle (3.25), l'erreur de consistance aux nœuds (t_n, x_0) et aux nœuds (t_n, x_J) est nulle.) Un schéma sera dit consistant si pour une norme $\|\cdot\|$ donnée sur $\mathbb{K}^{J-1}$, la quantité $\|\varepsilon^{[n]}\|$ tend vers 0 quand h_t et h_x tendent vers 0. On notera que quand h_x décroît vers 0, J augmente et donc on ne peut considérer une norme $\|\cdot\|$ sur $\mathbb{K}^{J-1}$... On est donc amené à considérer une famille $\{\|\cdot\|_J\}_{J \in \mathbb{N}^*}$ de normes indicée par J où l'élément J de la famille est une norme sur $\mathbb{K}^J$. Par exemple en utilisant la norme infini, la famille $\{\|\cdot\|_J\}_{J \in \mathbb{N}^*}$ sera donnée

$$\forall J \in \mathbb{N}^* \quad \|\varepsilon^{[n]}\|_J = \|\varepsilon^{[n]}\|_{\infty, \mathbb{K}^J} = \max_{j=1, \dots, J} |\varepsilon_j^{[n]}|.$$

DÉFINITION 3.2 (Consistance d'un schéma de différences finies)

Considérons un schéma d'approximation numérique du problème modèle (3.25) où $t \in [0, T]$, avec $T > 0$ fixé, défini pour $J, N \in \mathbb{N}^*$ fixés par :

$$U^{[0]} \in \mathbb{K}^{J-1} \text{ et pour tout } n \in \{0, \dots, N-1\}, D_1 U^{[n+1]} = D_2 U^{[n]} + F^{[n]}$$

où D_1 et D_2 sont deux matrices de $\mathcal{M}_{J-1}(\mathbb{R})$ et $F^{[n]}$ un vecteur de $\mathbb{K}^{J-1}$.

Ce schéma sera dit consistant avec le problème modèle (3.25) pour la famille de $\{\|\cdot\|_J\}_{J \in \mathbb{N}^*}$ de normes si

$$\lim_{\substack{h_x \rightarrow 0^+ \\ h_t \rightarrow 0^+}} \max_{n=0, \dots, N} \|\varepsilon^{[n]}\|_J = 0$$

où h_x et h_t sont respectivement donnés par $h_x = \frac{b-a}{J}$ et $h_t = \frac{T}{N}$ et pour $n \in \{0, \dots, N\}$ fixé, $\varepsilon^{[n]}$ est le vecteur des erreurs de consistance aux nœuds (x_j, t_n) pour $j = 1, \dots, J-1$.

Vérifions que le schéma aux différences finies (3.36) est consistant. Comme u est solution de notre problème modèle ($\mathcal{P}$), on a

$$\frac{\partial}{\partial t} u(t_n, x_j) = \alpha \frac{\partial^2}{\partial x^2} u(t_n, x_j) + \beta u(t_n, x_j) + f(t_n, x_j)$$

et par conséquent $\varepsilon_j^{[n]} = \varepsilon_1 + \alpha \varepsilon_2$ où

$$\begin{aligned} \varepsilon_1 &= \frac{u(t_{n+1}, x_j) - u(t_n, x_j)}{h_t} - \frac{\partial u}{\partial t}(t_n, x_j) \\ \varepsilon_2 &= \frac{u(t_n, x_{j-1}) - 2u(t_n, x_j) + u(t_n, x_{j+1}))}{h_x^2} - \frac{\partial^2 u}{\partial x^2}(t_n, x_j). \end{aligned} \quad (3.52)$$

En supposant la fonction u suffisamment régulière, la formule de Taylor-Lagrange fournit l'existence d'un réel $\tau_n \in]t_n, t_{n+1}[$ tel que

$$u(t_{n+1}, x_j) = u(t_n, x_j) + h_t \frac{\partial u}{\partial t}(t_n, x_j) + \frac{h_t^2}{2} \frac{\partial^2 u}{\partial t^2}(\tau_n, x_j)$$

et par conséquent on a

$$|\varepsilon_1| = \frac{h_t}{2} \left| \frac{\partial^2 u}{\partial t^2}(\tau_n, x_j) \right|.$$

Si u admet une dérivée partielle seconde relativement à t qui est bornée sur $\mathbb{R}^+ \times [a, b]$ alors

$$|\varepsilon_1| \leq C_1 h_t \quad \text{où} \quad C_1 = \frac{1}{2} \sup_{(t,x) \in \mathbb{R}^+ \times [a,b]} \left| \frac{\partial^2 u}{\partial t^2}(t, x) \right|.$$

Par ailleurs, toujours en supposant la fonction u suffisamment régulière, la formule de Taylor-Lagrange fournit l'existence d'un réel $\chi_1 \in]x_{j-1}, x_j[$ et d'un réel $\chi_2 \in]x_j, x_{j+1}[$ tels que

$$\begin{aligned} u(t_n, x_{j-1}) &= u(t_n, x_j) - h_x \frac{\partial u}{\partial x}(t_n, x_j) + \frac{h_x^2}{2} \frac{\partial^2 u}{\partial x^2}(t_n, x_j) - \frac{h_x^3}{6} \frac{\partial^3 u}{\partial x^3}(t_n, x_j) + \frac{h_x^4}{24} \frac{\partial^4 u}{\partial x^4}(t_n, \chi_1) \\ u(t_n, x_{j+1}) &= u(t_n, x_j) + h_x \frac{\partial u}{\partial x}(t_n, x_j) + \frac{h_x^2}{2} \frac{\partial^2 u}{\partial x^2}(t_n, x_j) + \frac{h_x^3}{6} \frac{\partial^3 u}{\partial x^3}(t_n, x_j) + \frac{h_x^4}{24} \frac{\partial^4 u}{\partial x^4}(t_n, \chi_2) \end{aligned}$$

et par conséquent

$$|\varepsilon_2| = \frac{h_x^2}{24} \left(\frac{\partial^2 u}{\partial x^2}(t_n, \chi_1) + \frac{\partial^2 u}{\partial x^2}(t_n, \chi_2) \right).$$

Si u admet une dérivée partielle quatrième relativement à x qui est continue sur $\mathbb{R}^+ \times [a, b]$ alors

$$|\varepsilon_2| \leq C_2 h_x^2 \quad \text{où} \quad C_2 = \frac{1}{12} \sup_{(t,x) \in [0,T] \times [a,b]} \left| \frac{\partial^4 u}{\partial x^4}(t, x) \right|.$$

On a donc établi le résultat suivant.

PROPOSITION 3.2 (Consistance du schéma de différences finies)

Si la solution du problème modèle (3.25) est suffisamment régulière⁽¹⁵⁾ alors il existe deux réels strictement positifs C_1 et C_2 tels que, pour tous $n \in \{0, \dots, N\}$ et $j \in \{0, \dots, J\}$, l'erreur de consistance du schéma différences finies (3.41)–(3.42) vérifie :

$$|\varepsilon_j^{[n]}| \leq C_1 h_t + C_2 h_x^2. \quad (3.53)$$

Le schéma de différences finies est donc consistant, d'ordre 2 en espace et d'ordre 1 en temps.

La proposition 3.2 permet l'interprétation suivante. L'erreur de consistance est la somme de deux types d'erreur : celle liée à l'approximation des dérivées partielles pour la variable temporelle et celle liée à l'approximation des dérivées partielles pour la variable d'espace. La valeur de ces deux types d'erreurs est directement liée à la valeur des pas des discrétisations temporelle et spatiale. Il est donc inutile de « raffiner » de manière excessive l'une des deux discrétisations spatiale ou temporelle sans se préoccuper de l'autre, cette dernière risquant de devenir « facteur limitant » pour l'amélioration de la précision des résultats.

On notera également, d'après la proposition 3.2, que si le nombre de points de discrétisation de l'intervalle de temps est doublé (dans ce cas le pas de discrétisation est donc divisé par 2) alors l'erreur de consistance sera divisée par 2 (dans la mesure où l'erreur liée à la discrétisation spatiale n'a pas un rôle limitant). Mais si le nombre de points de discrétisation de l'intervalle $[a, b]$ est doublé (dans ce cas le pas de discrétisation

⁽¹⁵⁾. Par exemple, u admet une dérivée partielle seconde relativement à t qui est continue sur $[0, T] \times [a, b]$ et une dérivée partielle quatrième relativement à x qui est continue sur $[0, T] \times [a, b]$.

est donc divisé par 2) alors l'erreur de consistance sera divisée par $2^2 = 4$ (dans la mesure où l'erreur liée à la discrétisation temporelle n'a pas un rôle limitant).

Plus généralement, on a la définition suivante.

DÉFINITION 3.3 (Ordre de consistance d'un schéma de différences finies)

Avec les notations de la définition 3.2, un schéma aux différences finies consistant avec le problème modèle (3.25) pour la famille de $\{\|\cdot\|_J\}_{J \in \mathbb{N}^*}$ de normes sera dit d'ordre (de consistance) p en espace et q en temps s'il existe une constante C (ne dépendant que des données et de la solution du problème modèle (3.25) tel que si

$$\max_{n=0,\dots,N} \|\varepsilon^{[n]}\|_J \leq C (h_x^p + h_t^q).$$

3.3.4 Notion de convergence pour un schéma différences finies

L'erreur d'approximation au nœud (t_n, x_j) pour $n \in \{0, \dots, N\}$ et $j \in \{0, \dots, J\}$ est donnée par $e_j^{[n]} = |u(t_n, x_j) - u_j^{[n]}|$. Contrairement à l'erreur de consistance, l'erreur d'approximation mesure donc l'écart entre la solution exacte et la solution approchée en chaque nœud de calcul de la discrétisation du domaine physique et du temps. Un schéma sera qualifié de *convergent* si l'erreur d'approximation en chaque nœuds tend vers 0 quand les pas de discrétisation en espace h_x et en temps h_t tendent vers 0. D'une manière générale, l'étude de la convergence d'un schéma de différences finies peut être compliquée à effectuer directement. Toutefois, en s'appuyant sur les résultats de stabilité et de consistance d'un schéma donné, on peut établir plus facilement la propriété de convergence de ce schéma en vertu d'un principe dû à Peter Lax.⁽¹⁶⁾

PRINCIPE 3.1 (Principe de Lax)

Un schéma aux différences finies qui est stable et consistant est convergent.

Il ne s'agit là que d'un principe correspondant à une propriété qui peut être démontrée pour de nombreux schémas. Une démonstration en a par exemple été publiée dans le cas d'un problème évolutif avec condition initiale par P. Lax et R. Richtmyer en 1956 (*Survey of the stability of linear finite difference equations*, Comm. Pure Appl. Math., vol. 9, 1956, p. 267-293) sous la forme suivante : un schéma numérique consistant, la stabilité du schéma est une condition nécessaire et suffisante pour assurer sa convergence. Ainsi, le principe de Lax donne une condition suffisante à la convergence d'un schéma mais des schémas non consistants peuvent par exemple être convergent.

Précisons la définition de la notion de convergence pour un schéma aux différences finies.

⁽¹⁶⁾. Peter Lax, né le 1er mai 1926 à Budapest, est un mathématicien hongrois de nationalité américaine. Le prix Abel 2005 lui a été décerné pour l'ensemble de sa contribution en mathématiques pures et appliquées, et en particulier pour son travail sur les équations aux dérivées partielles.

DÉFINITION 3.4 Considérons un schéma aux différences finies d'approximation de la solution du problème modèle (3.25) où $t \in [0, T]$, avec $T > 0$ fixé, défini pour $J, N \in \mathbb{N}^*$ fixés par :

$$U^{[0]} \in \mathbb{K}^{J-1} \text{ et pour tout } n \in \{0, \dots, N-1\}, D_1 U^{[n+1]} = D_2 U^{[n]} + F^{[n]}$$

où D_1 et D_2 sont deux matrices de $\mathcal{M}_{J-1}(\mathbb{R})$ et $F^{[n]}$ un vecteur de $\mathbb{K}^{J-1}$.

— Ce schéma sera dit convergent pour la famille de $\{\| \cdot \|_J\}_{J \in \mathbb{N}^*}$ de normes si

$$\lim_{(h_x, h_t) \rightarrow (0^+, 0^+)} \max_{n=0, \dots, N} \|E^{[n]}\|_J = 0$$

où h_x et h_t sont respectivement donnés par $h_x = \frac{b-a}{J}$ et $h_t = \frac{T}{N}$ et pour $n \in \{0, \dots, N\}$ fixé et $E^{[n]}$ est le vecteur des erreurs d'approximation aux nœuds (x_j, t_n) pour $j = 1, \dots, J-1$.

— Soit $\mathcal{S}$ un sous-ensemble de $\mathbb{R}_+^* \times \mathbb{R}_+^*$ tel que $(0, 0) \in \overline{\mathcal{S}}$. On dit que le schéma est convergent sous la condition $(h_x, h_t) \in \mathcal{S}$ pour la famille de $\{\| \cdot \|_J\}_{J \in \mathbb{N}^*}$ de normes si

$$\lim_{\substack{(h_x, h_t) \rightarrow (0^+, 0^+) \\ (h_x, h_t) \in \mathcal{S}}} \max_{n=0, \dots, N} \|E^{[n]}\|_J = 0$$

Intéressons-nous au cas particulier du schéma d'approximation introduit en (3.36) pour notre problème modèle. Avec les notations introduites en (3.43) pour ce schéma, on a pour tout $n \in \{0, \dots, N-1\}$

$$U^{[n+1]} = D U^{[n]} + F^{[n]}. \quad (3.54)$$

Pour tout $n \in \{0, \dots, N\}$, désignons par $V^{[n]}$ le vecteur de $\mathbb{R}^{J-1}$ de composantes

$$V^{[n]} = \begin{pmatrix} u(x_1, t_n) \\ \vdots \\ u(x_{J-1}, t_n) \end{pmatrix}.$$

Par définition de l'erreur de consistance, on a

$$V^{[n+1]} = D V^{[n]} + F^{[n]} + \epsilon^{[n]}. \quad (3.55)$$

Pour tout $n \in \{0, \dots, N-1\}$ le vecteur $E^{[n]} = V^{[n]} - U^{[n]}$ des erreurs d'approximation aux nœuds (x_j, t_n) pour $j = 1, \dots, J-1$, vérifie donc par différence de (3.55) et de (3.54)

$$E^{[n+1]} = D E^{[n]} + \epsilon^{[n]} \quad (3.56)$$

et on a bien entendu $E^{[0]} = V^{[0]} - U^{[0]} = 0$. Cette relation (3.56) peut être interprétée comme un schéma d'approximation du problème modèle (3.25) où le second membre f est remplacé par une fonction g telle que pour tout $n \in \{0, \dots, N\}$ et pour tout $j = 1, \dots, J-1$, $g(x_j, t_n) = \epsilon(x_j, t_n)$. Ce schéma est le schéma (3.36) pour une donnée au second membre du problème modèle (3.25) différente. D'après la stabilité du schéma (3.36) établie à la proposition 3.1, il existe $C_2 > 0$ tel que pour tout $J, N \in \mathbb{N}^*$ tels que (h_x, h_t) vérifie la condition (3.50) $h_t \left(\frac{4\alpha}{h_x^2} - \beta \right) \leq 2$, on a

$$\forall n \in \{1, \dots, N\} \quad \|E^{[n]}\|_J \leq C_2 \max_{n \in \{1, \dots, N\}} \|\epsilon^{[n]}\|_J.$$

D'après la proposition 3.2, il existe $C > 0$ tel que

$$\max_{n=0, \dots, N} \|\epsilon^{[n]}\|_J \leq C (h_x^2 + h_t).$$

On en déduit que

$$\forall n \in \{1, \dots, N\} \quad \|E^{[n]}\|_J \leq K (h_x^2 + h_t)$$

où $K = C C_2 > 0$. On en conclut que sous la condition (3.50), le schéma (3.36) est convergent et d'ordre de convergence 1 en temps et 2 en espace.

Plus généralement, on a la définition suivante.

DÉFINITION 3.5 (Ordre de convergence d'un schéma de différences finies)

Avec les notations de la définition 3.4, un schéma aux différences finies d'approximation de la solution du problème modèle (3.25) sera dit convergent pour la famille de $\{\|\cdot\|_J\}_{J \in \mathbb{N}^*}$ de normes avec pour ordre (de convergence) p en espace et q en temps s'il existe une constante C (ne dépendant que des données et de la solution du problème modèle (3.25) tel que si

$$\max_{n=0,\dots,N} \|E^{[n]}\|_J \leq C (h_x^p + h_t^q).$$

3.4 Approximation par un schéma différences finies implicite du problème modèle**3.4.1 Construction du schéma différences finies implicite**

À la section 3.3, nous avons considérée la formule d'approximation (3.32) en t_n et la formule d'approximation (3.35) en x_j . Une autre possibilité est de considérer la formule d'approximation (3.32) en t_{n+1} (et par conséquent de considérer une approximation par différence finie « rétrograde » et non plus « progressive » de la dérivée en temps) et à nouveau la formule d'approximation (3.35) en x_j . Désignons, pour $j \in \{0, \dots, J\}$ et $n \in \{0, \dots, N\}$, par $u_j^{[n]}$ la valeur approchée de la solution $u(t_n, x_j)$ de notre problème modèle ($\mathcal{P}$) au noeud (t_n, x_j) obtenue par cette approche. On obtient pour tous $j \in \{1, \dots, J-1\}$ et $n \in \{1, \dots, N-1\}$ le schéma suivant

$$\frac{u_j^{[n+1]} - u_j^{[n]}}{h_t} = \alpha \frac{u_{j-1}^{[n+1]} - 2u_j^{[n+1]} + u_{j+1}^{[n+1]}}{h_x^2} + \beta u_j^{[n+1]} + f(t_{n+1}, x_j). \quad (3.57)$$

initialisé à partir de la condition initiale : $u_j^{[0]} = u_0(x_j)$ pour tout $j \in \{1, \dots, J-1\}$. L'équation (3.57) s'écrit encore

$$-\frac{\alpha h_t}{h_x^2} u_{j-1}^{[n+1]} + \left(1 - h_t \left(\beta - \frac{\alpha}{h_x^2}\right)\right) u_j^{[n+1]} - \frac{\alpha h_t}{2h_x^2} u_{j+1}^{[n+1]} = u_j^{[n]} + h_t f(t_{n+1}, x_j) \quad (3.58)$$

et en reprenant les notations introduites à la section 3.3, on obtient l'écriture matricielle suivante du schéma

$$\left((1 - \beta h_t) \mathbf{I} + \frac{\alpha h_t}{h_x^2} \mathbf{M} \right) U^{[n+1]} = U^{[n]} + F^{[n+1]} \quad \forall n \in \{0, \dots, N-1\}. \quad (3.59)$$

On dispose cette fois-ci d'un schéma *implicite* pour calculer une solution approchée de notre problème modèle ($\mathcal{P}$). Une fois calculé le vecteur $U^{[n]}$, on obtient le vecteur $U^{[n+1]}$ correspondant à l'itéré suivant en résolvant un système linéaire dont la matrice est

$$\mathbf{D} = (1 - \beta h_t) \mathbf{I} + \frac{\alpha h_t}{h_x^2} \mathbf{M}. \quad (3.60)$$

LEMME 3.2 La matrice $\mathbf{D}$ est inversible et par conséquent que le système linéaire (3.59) est un système de Cramer.

Démonstration Posons $\mu = 1 - \beta h_t$ et $\nu = \frac{\alpha h_t}{h_x^2}$. Notons que comme $\beta \leq 0$, on a $\mu \geq 0$ et que comme $\alpha > 0$, on a $\nu > 0$. La relation (3.60) se réécrit

$$\mathbf{D} = \nu \left(\mathbf{M} + \frac{\mu}{\nu} \mathbf{I} \right). \quad (3.61)$$

La matrice $\mathbf{D}$ est inversible si son noyau est réduit au vecteur nul. Raisonnons par l'absurde et supposons qu'il existe $X \in \mathbb{R}^{J-1}$ non nul tel que $\mathbf{D}X = 0$. Compte tenu de (3.61), on aurait $\mathbf{M}X = -\frac{\mu}{\nu}X$. Cela signifierait que la matrice $\mathbf{M}$ posséderait une valeur propre négative. Cela est impossible car la matrice $\mathbf{M}$ est symétrique définie positive : toutes ses valeurs propres sont des réels strictement positifs. On en conclut que la matrice $\mathbf{D}$ est inversible. $\square$

Décomposition LU de la matrice différences finies

La matrice D n'est pas modifiée au cours des itérations successives du schéma de résolution par différences finies de notre problème modèle $(\mathcal{P})$. On peut donc effectuer sa décomposition LU au cours d'une phase préliminaire à la résolution, ce qui permet par la suite de calculer de manière itérative les termes $1, \dots, N$ de la suite $(U^{[n]})_n$ définie par la relation de récurrence (3.59) avec un coût limité au coût de la phase de remontée de la méthode de Gauss.

On effectue l'initialisation suivante à partir de la donnée initiale u_0 :

$$U^{[0]} = \begin{pmatrix} u_0(t_0, x_1) \\ \vdots \\ u_0(t_0, x_{J-1}) \end{pmatrix} \quad \text{et} \quad F^{[0]} = h_t \begin{pmatrix} f(t_0, x_1) \\ \vdots \\ f(t_0, x_{J-1}) \end{pmatrix} \quad (3.62)$$

puis on calcule les termes $1, \dots, N$ de la suite $(U^{[n]})_n$ de vecteurs de $\mathbb{R}^{J-1}$ en résolvant à chaque étape les deux systèmes linéaires triangulaires :

$$\begin{aligned} L_D X &= U^{[n]} + F^{[n+1]} \\ V_D U^{[n+1]} &= X \end{aligned} \quad (3.63)$$

où L_D et V_D désignent respectivement les deux matrices triangulaire inférieure et triangulaire supérieure issues de la décomposition LU de la matrice D .

Les valeurs des composantes du vecteur $U^{[n]}$ fournissent les valeurs aux nœuds $x_j, j = 1, \dots, J-1$ de la solution u au temps t_n .

3.4.2 Étude de la stabilité du schéma implicite

On se place pour simplifier dans le cas où f est nulle. La suite des itérés correspondant à notre schéma de différences finies est donc définie à partir de la donnée du terme $U^{[0]}$ par la relation de récurrence

$$\forall n \in \{1, \dots, N\} \quad D U^{[n]} = U^{[n-1]}. \quad (3.64)$$

Nous avons la proposition suivante.

PROPOSITION 3.3 (Stabilité du schéma de différences finies implicite)

On rappelle que $\alpha > 0$ et que $\beta \leq 0$. Le schéma de différences finies (3.64) est inconditionnellement stable, c'est-à-dire qu'il est stable sans qu'il soit nécessaire d'imposer de condition sur les pas des discrétisations spatiale et temporelle.

Démonstration Nous nous plaçons dans le cas particulier où le second membre f du problème au limite modèle parabolique est nul. On pourrait sur le même principe traité le cas où ce second membre est non nul comme cela a été fait dans la démonstration de la proposition 3.1.

La matrice D étant inversible, pour tout $n \in \{1, \dots, N\}$, on a

$$U^{[n]} = D^{-1} U^{[n-1]} = (D^{-1})^n U^{[0]}.$$

On en déduit que

$$\|U^{[n]}\|_2 \leq \|D^{-1}\|_2^n \|U^{[0]}\|_2.$$

Intéressons-nous à la norme spectrale de la matrice D^{-1} . On a

$$D = (1 - \beta h_t) I + \frac{\alpha h_t}{h_x^2} M = \mu I + \nu M$$

où on a posé $\mu = 1 - \beta h_t$ et $\nu = \frac{\alpha h_t}{h_x^2}$. Comme la matrice D est une matrice symétrique réelle, il en va de même de la matrice D^{-1} et par conséquent

$$\|D^{-1}\|_2 = \rho(D^{-1}) = \max \{|\lambda| ; \lambda \text{ est valeur propre de } D^{-1}\}$$

Or, λ est valeur propre de D^{-1} si, et seulement si, $1/\lambda$ est valeur propre de D . On en déduit que

$$\|D^{-1}\|_2 = 1/\min\{|\lambda|; \lambda \text{ est valeur propre de } D\}. \quad (3.65)$$

Les valeurs propres λ de D sont telles que $(\lambda - \mu)/\nu$ est valeur propre de M . Or les valeurs propres de M sont les $J - 1$ réels positifs $\lambda_j^M = 2(1 - \cos(j\pi/J))$ où $j = 1, \dots, J - 1$. Les valeurs propres de D sont donc

$$\lambda_j = \mu + 2\nu(1 - \cos(j\pi/J)), \quad j \in \{1, \dots, J - 1\}.$$

Pour $\beta \leq 0$, on a $\mu \geq 1$ et comme $\alpha > 0$, on a clairement $\lambda_j \geq 1$ pour tout $j \in \{1, \dots, J - 1\}$. On déduit de (3.65) que dans ce cas $\|D^{-1}\|_2 \leq 1$ et la définition 3.1 permet de conclure que le schéma de différences finies (3.64) est inconditionnellement stable. $\square$

3.4.3 Étude de la consistance du schéma implicite

Intéressons-nous à présent à la consistance du schéma implicite de différences finies (3.59)–(3.62).

PROPOSITION 3.4 (Consistance du schéma de différences finies)

Si la solution du problème modèle ($\mathcal{P}$) est suffisamment régulière alors il existe deux réels strictement positifs C_1 et C_2 tels que pour tous $n \in \{0, \dots, N\}$ et $j \in \{0, \dots, J\}$ l'erreur de consistance du schéma différences finies (3.59)–(3.62) vérifie :

$$|\varepsilon_j^{[n]}| \leq C_1 h_t + C_2 h_x^2. \quad (3.66)$$

Le schéma différences finies est donc consistant, d'ordre 2 en espace et d'ordre 1 en temps.

Démonstration L'erreur de consistance au nœud (t_n, x_j) pour $n \in \{0, \dots, N\}$ et $j \in \{0, \dots, J\}$, notée $\varepsilon_j^{[n]}$, vérifie

$$\begin{aligned} \frac{u(t_{n+1}, x_j) - u(t_n, x_j)}{h_t} &= \alpha \frac{u(t_{n+1}, x_{j-1}) - 2u(t_{n+1}, x_j) + u(t_{n+1}, x_{j+1}))}{h_x^2} \\ &\quad + \beta u(t_{n+1}, x_j) + f(t_n, x_j) + \varepsilon_j^{[n]}. \end{aligned}$$

Comme u est solution du problème modèle ($\mathcal{P}$), on a

$$\frac{\partial u}{\partial t}(t_{n+1}, x_j) = \beta u(t_{n+1}, x_j) + \alpha \frac{\partial^2 u}{\partial x^2}(t_{n+1}, x_j) + f(t_{n+1}, x_j)$$

et par conséquent $\varepsilon_j^{[n]} = \varepsilon_1 - \alpha \varepsilon_2$ où

$$\begin{aligned} \varepsilon_1 &= \frac{u(t_{n+1}, x_j) - u(t_n, x_j)}{h_t} - \frac{\partial}{\partial t} u(t_{n+1}, x_j) \\ \varepsilon_2 &= \frac{u(t_{n+1}, x_{j-1}) - 2u(t_{n+1}, x_j) + u(t_{n+1}, x_{j+1}))}{h_x^2} - \frac{\partial^2}{\partial x^2} u(t_{n+1}, x_j). \end{aligned}$$

En supposant pour tout $x \in [a, b]$ la première fonction partielle de u en x , i.e. $t \in \mathbb{R}^+ \mapsto u(x, t)$, de classe C^2 , la formule de Taylor-Lagrange fournit l'existence d'un réel $\tau_n \in]t_n, t_{n+1}[$ tel que

$$u(t_n, x_j) = u(t_{n+1}, x_j) - h_t \frac{\partial u}{\partial t}(t_{n+1}, x_j) + \frac{h_t^2}{2} \frac{\partial^2 u}{\partial t^2}(\tau_n, x_j)$$

et par conséquent, on a

$$|\varepsilon_1| = \frac{h_t}{2} \left| \frac{\partial^2 u}{\partial t^2}(\tau_n, x_j) \right|.$$

On en déduit que

$$|\varepsilon_1| \leq \frac{M_{2,t}}{2} h_t \quad \text{où} \quad M_{2,t} = \sup_{(t,x) \in [0,T] \times [a,b]} \left| \frac{\partial^2 u}{\partial t^2}(t, x) \right|.$$

En supposant pour tout $t \in \mathbb{R}^+$ la seconde fonction partielle de u en t , i.e. $x \in [a, b] \mapsto u(x, t)$, de classe $\mathcal{C}^4$, la formule de Taylor-Lagrange fournit l'existence d'un réel $\chi_{1,j} \in]x_{j-1}, x_j[$ et d'un réel $\chi_{2,j} \in]x_j, x_{j+1}[$ tels que

$$\begin{aligned} u(t_{n+1}, x_{j-1}) &= u(t_{n+1}, x_j) - h_x \frac{\partial u}{\partial x}(t_{n+1}, x_j) + \frac{h_x^2}{2} \frac{\partial^2 u}{\partial x^2}(t_{n+1}, x_j) - \frac{h_x^3}{6} \frac{\partial^3 u}{\partial x^3}(t_{n+1}, x_j) + \frac{h_x^4}{24} \frac{\partial^4 u}{\partial x^4}(t_{n+1}, \chi_{1,j}) \\ u(t_{n+1}, x_{j+1}) &= u(t_{n+1}, x_j) + h_x \frac{\partial u}{\partial x}(t_{n+1}, x_j) + \frac{h_x^2}{2} \frac{\partial^2 u}{\partial x^2}(t_{n+1}, x_j) + \frac{h_x^3}{6} \frac{\partial^3 u}{\partial x^3}(t_{n+1}, x_j) + \frac{h_x^4}{24} \frac{\partial^4 u}{\partial x^4}(t_{n+1}, \chi_{2,j}) \end{aligned}$$

et par conséquent, on a

$$|\varepsilon_2| = \frac{h_x^2}{24} \left(\frac{\partial^4 u}{\partial x^4}(t_{n+1}, \chi_{1,j}) + \frac{\partial^4 u}{\partial x^4}(t_{n+1}, \chi_{2,j}) \right).$$

On en déduit que

$$|\varepsilon_2| \leq \frac{M_{4,x}}{12} h_x^2 \quad \text{où} \quad M_{4,x} = \sup_{(t,x) \in [0,T] \times [a,b]} \left| \frac{\partial^4 u}{\partial x^4}(t, x) \right|.$$

Le résultat est démontré. $\square$

3.5 Le schéma différences finies de Crank et Nicolson

L'idée du schéma de différences finies de Crank et Nicolson⁽¹⁷⁾ est d'inclure un peu « d'implicite » et un peu « d'explicite » dans la construction du schéma de différences finies pour le calcul d'une solution approchée de notre problème modèle ($\mathcal{P}$). L'autre particularité de ce schéma est qu'il est consistant d'ordre 2 en temps et en espace.

3.5.1 Construction du schéma

D'une part, à la section 3.3 nous avons considéré la formule d'approximation (3.32) en x_j et la formule d'approximation (3.35) en t_n ce qui a donné lieu à un schéma différences finis explicite d'ordre 1 en temps et d'ordre 2 en espace stable sous une condition de type CFL. D'autre part, à la section 3.4 nous avons considéré la formule d'approximation (3.32) en x_j et la formule d'approximation (3.35) en t_{n+1} ce qui a donné lieu à un schéma différences finis implicite d'ordre 1 en temps et d'ordre 2 en espace inconditionnellement stable. Nous allons dans à présent envisager une approche intermédiaire consistant à utiliser un schéma mêlant une partie d'implicite avec une partie d'explicite. Pour une valeur du paramètre $\theta \in [0, 1]$, considérons les approximations suivantes au noeud (t_n, x_j) pour $n \in \{0, \dots, N\}$ et $j \in \{1, \dots, J-1\}$

$$\begin{aligned} \frac{\partial^2 u}{\partial x^2}(t_n, x_j) &\approx \theta \frac{u(t_{n+1}, x_{j-1}) - 2u(t_{n+1}, x_j) + u(t_{n+1}, x_{j+1}))}{h_x^2} \\ &\quad + (1 - \theta) \frac{u(t_n, x_{j-1}) - 2u(t_n, x_j) + u(t_n, x_{j+1}))}{h_x^2} \end{aligned} \quad (3.67)$$

et

$$\frac{\partial u}{\partial t}(t_n, x_j) \approx \frac{u(t_{n+1}, x_j) - u(t_n, x_j)}{h_t}. \quad (3.68)$$

On désigne pour tous $n \in \{0, \dots, N\}$ et $j \in \{1, \dots, J-1\}$ par $u_j^{[n]}$ la valeur approchée de $u(t_n, x_j)$ issue du schéma différences finies exploitant les approximations (3.67) et (3.68). Considérant notre problème

⁽¹⁷⁾. Ce schéma a été publiée en 1947 par la mathématicienne Phyllis Nicolson (1917 – 1968) et le physicien John Crank (1916–2006) pour la résolution de l'équation de la chaleur : *A practical method for numerical evaluation of solutions of partial differential equations of the heat-conduction type*. Mathematical Proceedings of the Cambridge Philosophical Society, 43(1), 50-67, 1947. doi :10.1017/S0305004100023197

modèle $(\mathcal{P})$, on s'intéresse au schéma suivant

$$\begin{aligned} \frac{u_j^{[n+1]} - u_j^{[n]}}{h_t} = & \theta \alpha \frac{u_{j-1}^{[n+1]} - 2u_j^{[n+1]} + u_{j+1}^{[n+1]}}{h_x^2} \\ & + (1 - \theta) \alpha \frac{u_{j-1}^{[n]} - 2u_j^{[n]} + u_{j+1}^{[n]}}{h_x^2} - \theta \beta u_j^{[n+1]} - (1 - \theta) \beta u_j^{[n]} + f(t_n, x_j). \end{aligned} \quad (3.69)$$

On a donc pour tout $j \in \{1, \dots, J-1\}$

$$\begin{aligned} & - \frac{\alpha \theta h_t}{h_x^2} u_{j-1}^{[n+1]} + \left(1 + h_t \theta \left(-\beta + \frac{2\alpha}{h_x^2} \right) \right) u_j^{[n+1]} - \frac{\alpha \theta h_t}{h_x^2} u_{j+1}^{[n+1]} \\ = & \frac{\alpha(1-\theta)h_t}{h_x^2} u_{j-1}^{[n]} + \left(1 + h_t(1-\theta) \left(\beta - \frac{2\alpha}{h_x^2} \right) \right) u_j^{[n]} + \frac{\alpha(1-\theta)h_t}{h_x^2} u_{j+1}^{[n]} + h_t f(t_n, x_j). \end{aligned} \quad (3.70)$$

En posant pour tout $n \in \{0, \dots, N\}$

$$U^{[n]} = \begin{pmatrix} u_1^{[n]} \\ \vdots \\ u_{J-1}^{[n]} \end{pmatrix} \quad \text{et} \quad F^{[n]} = h_t \begin{pmatrix} f(t_n, x_1) \\ \vdots \\ f(t_n, x_{J-1}) \end{pmatrix}$$

et en notant M la matrice de $\mathcal{M}_{J-1}(\mathbb{R})$ donnée par

$$M = \begin{pmatrix} 2 & -1 & & \\ -1 & 2 & -1 & \\ & -1 & \ddots & \ddots \\ & & \ddots & \ddots & -1 \\ & & & -1 & 2 \end{pmatrix}$$

l'équation (3.70) s'écrit

$$\left((1 - \beta \theta h_t) I + \theta \frac{\alpha h_t}{h_x^2} M \right) U^{[n+1]} = \left((1 + \beta(1 - \theta) h_t) I - (1 - \theta) \frac{\alpha h_t}{h_x^2} M \right) U^{[n]} + F^{[n]}. \quad (3.71)$$

Posons $\mu = 1 - \theta \beta h_t$, $\nu = 1 + (1 - \theta) \beta h_t$ et $v = \alpha h_t / h_x^2$ et introduisons les matrices

$$D_1 = \mu I + \theta v M \quad \text{et} \quad D_2 = \nu I - (1 - \theta) v M.$$

Le schéma prend la forme suivante :

1. on effectue l'initialisation suivante à partir de la donnée initiale u_0 :

$$U^{[0]} = \begin{pmatrix} u_0(x_1) \\ \vdots \\ u_0(x_{J-1}) \end{pmatrix} \quad \text{et} \quad F^{[0]} = h_t \begin{pmatrix} f(t_0, x_1) \\ \vdots \\ f(t_0, x_{J-1}) \end{pmatrix} \quad (3.72)$$

2. puis on calcule les termes $1, \dots, N$ de la suite $(U^{[n]})_n$ de vecteurs de $\mathbb{C}^{J-1}$ par la relation de récurrence

$$D_1 U^{[n+1]} = D_2 U^{[n]} + F^{[n]}. \quad (3.73)$$

On dispose à nouveau d'un schéma implicite pour calculer une solution approchée de notre problème modèle $(\mathcal{P})$ qui nécessite à chaque itération (i.e. à chaque pas de temps) de résoudre un système linéaire. Toutefois, la matrice D_1 n'étant pas modifiée au cours des itérations, on peut effectuer sa décomposition LU au cours d'une phase préliminaire aux itérations ce qui permet par la suite de calculer de manière itérative les termes $1, \dots, N$ de la suite $(U^{[n]})_n$ définie par la relation de récurrence (3.71) avec un coût

limité au coût de la phase de remontée de la méthode de Gauss. Il suffit en effet de résoudre à chaque itération les deux systèmes linéaires triangulaires

$$\begin{aligned} L_D X &= D_2 U^{[n]} + F^{[n]} \\ V_D U^{[n+1]} &= X \end{aligned} \quad (3.74)$$

où L_D et V_D désignent les deux matrices triangulaires (respectivement inférieure et supérieure) issues de la décomposition LU de la matrice D_1 .

Remarque 3.5 Dans le cas où $\theta = 0$, le schéma de Crank-Nicolson coïncide avec le schéma différences finies explicite étudié précédemment alors que dans le cas où $\theta = 1$ il coïncide avec le schéma différences finies implicite.

3.5.2 Étude de la stabilité du schéma de Crank-Nicolson

Afin d'étudier la stabilité du schéma de différences finies défini par les relations (3.71)–(3.72), nous supposons que la fonction f est nulle. La suite des itérés correspondant à notre schéma de différences finies est donc définie à partir de la donnée du terme $U^{[0]}$ par la relation de récurrence

$$\forall n \in \{1, \dots, N\} \quad D_1 U^{[n]} = D_2 U^{[n-1]}. \quad (3.75)$$

Nous avons la proposition suivante.

PROPOSITION 3.5 (Stabilité du schéma de différences finies de Crank-Nicolson)

On suppose $\alpha > 0$ et $\beta \leq 0$.

- Si $\theta \in [\frac{1}{2}, 1]$ alors le schéma de différences finies (3.75) est inconditionnellement stable.
- Si $\theta \in [0, \frac{1}{2}[$ alors le schéma de différences finies (3.75) est stable sous la condition

$$(1 - 2\theta)h_t \left(\frac{2\alpha}{h_x^2} - \beta \right) \leq 2. \quad (3.76)$$

Démonstration La matrice D_1 étant inversible, pour tout $n \in \{1, \dots, N\}$, on a

$$U^{[n]} = D_1^{-1} D_2 U^{[n-1]} = (D_1^{-1} D_2)^n U^{[0]}.$$

On en déduit que

$$\|U^{[n]}\|_2 \leq \|D_1^{-1} D_2\|_2^n \|U^{[0]}\|_2.$$

Intéressons-nous à la norme spectrale de la matrice $D = D_1^{-1} D_2$. Comme les matrices D_1 et D_2 sont des matrices réelles symétriques, on a

$$\|D\|_2 = \rho(D) = \max \{ |\lambda| ; \lambda \text{ est valeur propre de } D \}.$$

On est donc conduit à devoir déterminer les valeurs propres λ de la matrice D . Les propriétés du déterminant permettent d'écrire :

$$\det(D - \lambda I) = \det(D_1^{-1} D_2 - \lambda I) = \det(D_1^{-1} (D_2 - \lambda D_1)) = \det(D_1^{-1}) \det(D_2 - \lambda D_1).$$

Or,

$$D_2 - \lambda D_1 = (\nu - \lambda\mu) I - v(1 + \theta(\lambda - 1)) M = -v(1 + \theta(\lambda - 1)) \left(M - \frac{\nu - \lambda\mu}{v(1 + \theta(\lambda - 1))} I \right)$$

donc les valeurs propres λ de D sont telles que $\lambda^M = \frac{\nu - \lambda\mu}{v(1 + \theta(\lambda - 1))}$ est valeur propre de M . Les valeurs propres de la matrice M sont données au lemme 3.1 p. 82. On en déduit que

$$\lambda \in \left\{ \frac{\nu - v(1 - \theta)\lambda_j^M}{\mu + v\theta\lambda_j^M} ; j \in \{1, \dots, J - 1\} \right\}$$

où $\lambda_j^M = 2(1 - \cos(j\pi/J))$, $j \in \{1, \dots, J-1\}$, désignent les $J-1$ valeurs propres de M.

Pour $\beta \leq 0$, on a $\mu \geq 1$. Comme $\lambda_j^M \in]0, 2[$ pour tout $j \in \{1, \dots, J-1\}$ et comme $v > 0$, il en résulte que $\mu + v\theta\lambda_j^M > 0$ et on a $|\lambda| \leq 1$ si, et seulement si, pour tout $j \in \{1, \dots, J-1\}$

$$-\mu - \theta v \lambda_j^M \leq \nu - (1 - \theta)v \lambda_j^M \leq \mu + \theta v \lambda_j^M \quad (3.77)$$

Intéressons-nous à la seconde inégalité dans (3.77). Elle se ré-écrit, compte tenu de l'expression de μ et ν , sous la forme $\beta h_t \leq v \lambda_j^M$. Comme $v > 0$, que $\lambda_j^M > 0$ et que $\beta \leq 0$, cette condition est toujours satisfaite. Intéressons-nous à la première inégalité dans (3.77). Elle se ré-écrit

$$2 + \beta(1 - 2\theta)h_t \geq (1 - 2\theta)\alpha \frac{h_t}{h_x^2} \lambda_j^M. \quad (3.78)$$

Si $\theta \geq \frac{1}{2}$ alors $1 - 2\theta \leq 0$ et cette inégalité est toujours satisfaite puisque le membre de gauche est positif alors que celui de droite est négatif.

Si $\theta < \frac{1}{2}$ alors $1 - 2\theta > 0$ et l'inégalité (3.78) peut ne pas être satisfaite. Comme les valeurs propres de la matrice M sont comprises entre 0 et 2, l'inégalité (3.78) sera satisfaite pour tout $j \in \{1, \dots, J-1\}$ si

$$2 + \beta(1 - 2\theta)h_t \geq 2(1 - 2\theta)\alpha \frac{h_t}{h_x^2}$$

autrement dit, si

$$(1 - 2\theta)h_t \left(\frac{2\alpha}{h_x^2} - \beta \right) \leq 2.$$

□

Remarque 3.6 Nous avons mentionné que dans le cas où $\theta = 0$, le schéma de Crank-Nicolson (3.75) coïncide avec le schéma différences finies explicite étudié à la section 3.3. On notera que la condition de stabilité (3.76) pour $\theta = 0$ n'est autre que la condition de stabilité donné à la proposition 3.1.

Par ailleurs, dans le cas où $\theta = 1$, le schéma de Crank-Nicolson (3.75) coïncide avec le schéma différences finies implicite étudié à la section 3.4. On retrouve bien le résultat énoncé à la proposition 3.3 de stabilité sans condition.

3.5.3 Étude de la consistance du schéma de Crank-Nicolson

Intéressons-nous à présent à la consistance du schéma implicite de Crank-Nicolson.

PROPOSITION 3.6 (Consistance du schéma de Crank-Nicolson)

On suppose que la solution de notre problème modèle (P) est suffisamment régulière.

- Si $\theta = 1/2$ alors il existe deux réels strictement positifs C_1 et C_2 tel que pour tous $n \in \{0, \dots, N\}$ et $j \in \{0, \dots, J\}$ l'erreur de consistance du schéma de Crank-Nicolson (3.71)–(3.72) vérifie :

$$|\varepsilon_j^{[n]}| \leq C_1 h_t^2 + C_2 h_x^2. \quad (3.79)$$

Le schéma de Crank-Nicolson est donc consistant, d'ordre 2 en espace et d'ordre 2 en temps.

- Si $\theta \neq 1/2$ alors il existe deux réels strictement positifs C_1 et C_2 tel que pour tous $n \in \{0, \dots, N\}$ et $j \in \{0, \dots, J\}$ l'erreur de consistance du schéma de Crank-Nicolson (3.71)–(3.72) vérifie :

$$|\varepsilon_j^{[n]}| \leq C_1 h_t + C_2 h_x^2. \quad (3.80)$$

Le schéma de Crank-Nicolson est donc consistant, d'ordre 1 en espace et d'ordre 2 en temps.

Démonstration Pour simplifier un peu les calculs, nous supposons ici que la fonction f est nulle. Pour notre problème, l'erreur de consistance au noeud (t_n, x_j) pour $n \in \{0, \dots, N\}$ et $j \in \{0, \dots, J\}$ notée $\varepsilon_j^{[n]}$ vérifie

$$\begin{aligned} \frac{u(t_{n+1}, x_j) - u(t_n, x_j)}{h_t} = & \alpha \theta \frac{u(t_{n+1}, x_{j-1}) - 2u(t_{n+1}, x_j) + u(t_{n+1}, x_{j+1}))}{h_x^2} \\ & + \alpha(1 - \theta) \frac{u(t_n, x_{j-1}) - 2u(t_n, x_j) + u(t_n, x_{j+1}))}{h_x^2} \\ & + \beta \theta u(t_{n+1}, x_j) + \beta(1 - \theta) u(t_n, x_j) + \varepsilon_j^{[n]}. \end{aligned} \quad (3.81)$$

Comme u est solution du problème modèle $(\mathcal{P})$, on a

$$\begin{aligned} \frac{\partial}{\partial t} u(t_{n+1}, x_j) &= \beta u(t_{n+1}, x_j) + \alpha \frac{\partial^2}{\partial x^2} u(t_{n+1}, x_j), \\ \frac{\partial}{\partial t} u(t_n, x_j) &= \beta u(t_n, x_j) + \alpha \frac{\partial^2}{\partial x^2} u(t_n, x_j). \end{aligned}$$

En multipliant la première relation par θ , la seconde par $1 - \theta$ et en combinant ces relations avec (3.81), on obtient que $\varepsilon_j^{[n]} = \varepsilon_1 + \alpha \varepsilon_2$ où

$$\begin{aligned} \varepsilon_1 &= \frac{u(t_{n+1}, x_j) - u(t_n, x_j)}{h_t} - \theta \frac{\partial}{\partial t} u(t_{n+1}, x_j) - (1 - \theta) \frac{\partial}{\partial t} u(t_n, x_j) \\ \varepsilon_2 &= \theta \left(\frac{u(t_{n+1}, x_{j-1}) - 2u(t_{n+1}, x_j) + u(t_{n+1}, x_{j+1}))}{h_x^2} - \frac{\partial^2}{\partial x^2} u(t_{n+1}, x_j) \right) \\ &+ (1 - \theta) \left(\frac{u(t_n, x_{j-1}) - 2u(t_n, x_j) + u(t_n, x_{j+1}))}{h_x^2} - \frac{\partial^2}{\partial x^2} u(t_n, x_j) \right). \end{aligned}$$

En supposant que u est suffisamment régulière, d'après la formule de Taylor-Lagrange il existe deux réels $\tau_{1,n}$ et $\tau_{2,n}$ dans $]t_n, t_{n+1}[$ tels que

$$\begin{aligned} u(t_n, x_j) &= u(t_{n+1}, x_j) - h_t \frac{\partial}{\partial t} u(t_{n+1}, x_j) + \frac{h_t^2}{2} \frac{\partial^2}{\partial t^2} u(t_{n+1}, x_j) - \frac{h_t^3}{6} \frac{\partial^3}{\partial t^3} u(\tau_{1,n}, x_j), \\ u(t_{n+1}, x_j) &= u(t_n, x_j) + h_t \frac{\partial}{\partial t} u(t_n, x_j) + \frac{h_t^2}{2} \frac{\partial^2}{\partial t^2} u(t_n, x_j) + \frac{h_t^3}{6} \frac{\partial^3}{\partial t^3} u(\tau_{2,n}, x_j). \end{aligned}$$

En multipliant la première relation par θ et la seconde par $1 - \theta$ et en considérant la différence de ces deux relations, on obtient

$$\begin{aligned} u(t_{n+1}, x_j) - u(t_n, x_j) &= h_t \left(\theta \frac{\partial}{\partial t} u(t_{n+1}, x_j) + (1 - \theta) \frac{\partial}{\partial t} u(t_n, x_j) \right) \\ &- \frac{h_t^2}{2} \left(\theta \frac{\partial^2}{\partial t^2} u(t_{n+1}, x_j) - (1 - \theta) \frac{\partial^2}{\partial t^2} u(t_n, x_j) \right) \\ &+ \frac{h_t^3}{6} \left(\theta \frac{\partial^3}{\partial t^3} u(\tau_{1,n}, x_j) + (1 - \theta) \frac{\partial^3}{\partial t^3} u(\tau_{2,n}, x_j) \right). \end{aligned}$$

On en déduit que

$$\begin{aligned} \varepsilon_1 &= \frac{h_t}{2} \left(\theta \frac{\partial^2}{\partial t^2} u(t_{n+1}, x_j) - (1 - \theta) \frac{\partial^2}{\partial t^2} u(t_n, x_j) \right) \\ &+ \frac{h_t^2}{6} \left(\theta \frac{\partial^3}{\partial t^3} u(\tau_{1,n}, x_j) + (1 - \theta) \frac{\partial^3}{\partial t^3} u(\tau_{2,n}, x_j) \right). \end{aligned} \quad (3.82)$$

Notons $t_{n+\frac{1}{2}} = t_n + \frac{h_t}{2}$. D'après la formule de Taylor-Lagrange, il existe un réel $\tau_{3,n} \in]t_{n+\frac{1}{2}}, t_{n+1}[$ et un réel $\tau_{4,n} \in]t_n, t_{n+\frac{1}{2}}[$ tels que

$$\begin{aligned} \frac{\partial^2}{\partial t^2} u(t_{n+1}, x_j) &= \frac{\partial^2}{\partial t^2} u(t_{n+\frac{1}{2}}, x_j) + \frac{h_t}{2} \frac{\partial^3}{\partial t^3} u(\tau_{3,n}, x_j), \\ \frac{\partial^2}{\partial t^2} u(t_n, x_j) &= \frac{\partial^2}{\partial t^2} u(t_{n+\frac{1}{2}}, x_j) - \frac{h_t}{2} \frac{\partial^3}{\partial t^3} u(\tau_{4,n}, x_j). \end{aligned}$$

En multipliant la première relation par θ et la seconde par $1 - \theta$ et en considérant la différence de ces deux relations, on obtient

$$\begin{aligned} \theta \frac{\partial^2}{\partial t^2} u(t_{n+1}, x_j) - (1 - \theta) \frac{\partial^2}{\partial t^2} u(t_n, x_j) &= (2\theta - 1) \frac{\partial^2}{\partial t^2} u(t_{n+\frac{1}{2}}, x_j) \\ &+ \frac{h_t}{2} \left(\theta \frac{\partial^3}{\partial t^3} u(\tau_{3,n}, x_j) + (1 - \theta) \frac{\partial^3}{\partial t^3} u(\tau_{4,n}, x_j) \right). \end{aligned}$$

Si $\theta = \frac{1}{2}$ alors $2\theta - 1 = 0$ et d'après (3.82) on a

$$\varepsilon_1 = \frac{h_t^2}{12} \left(\frac{\partial^3}{\partial t^3} u(\tau_{1,n}, x_j) + \frac{\partial^3}{\partial t^3} u(\tau_{3,n}, x_j) + \frac{\partial^3}{\partial t^3} u(\tau_{2,n}, x_j) + \frac{\partial^3}{\partial t^3} u(\tau_{4,n}, x_j) \right).$$

Si u admet une dérivée partielle troisième relativement à t qui est continue sur $[0, T] \times [a, b]$ alors

$$|\varepsilon_1| \leq C_1 h_t^2 \quad \text{où} \quad C_1 = \frac{1}{3} \sup_{(t,x) \in [0,T] \times [a,b]} \left| \frac{\partial^3}{\partial t^3} u(t, x) \right|.$$

Si $\theta \neq \frac{1}{2}$ alors d'après (3.82) on a

$$|\varepsilon_1| \leq C_1 h_t \quad \text{où} \quad C_1 = \sup_{(t,x) \in [0,T] \times [a,b]} \left| \frac{\partial^2}{\partial t^2} u(t, x) \right|.$$

Intéressons-nous à présent à une majoration du terme ε_2 . Pour tout $t \in [0, T]$, la formule de Taylor-Lagrange fournit l'existence d'un réel $\chi_{1,j} \in]x_{j-1}, x_j[$ et d'un réel $\chi_{2,j} \in]t_j, x_{j+1}[$ tels que

$$\begin{aligned} u(t, x_{j-1}) &= u(t, x_j) - h_x \frac{\partial}{\partial x} u(t, x_j) + \frac{h_x^2}{2} \frac{\partial^2}{\partial x^2} u(t, x_j) - \frac{h_x^3}{6} \frac{\partial^3}{\partial x^3} u(t, x_j) + \frac{h_x^4}{24} \frac{\partial^4}{\partial x^4} u(t, \chi_{1,j}), \\ u(t, x_{j+1}) &= u(t, x_j) + h_x \frac{\partial}{\partial x} u(t, x_j) + \frac{h_x^2}{2} \frac{\partial^2}{\partial x^2} u(t, x_j) + \frac{h_x^3}{6} \frac{\partial^3}{\partial x^3} u(t, x_j) + \frac{h_x^4}{24} \frac{\partial^4}{\partial x^4} u(t, \chi_{2,j}). \end{aligned}$$

On en déduit que

$$\frac{u(t, x_{j-1}) - 2u(t, x_j) + u(t, x_{j+1}))}{h_x^2} - \frac{\partial^2}{\partial x^2} u(t, x_j) = \frac{h_x^2}{24} \left(\frac{\partial^4}{\partial x^4} u(t, \chi_{1,j}) + \frac{\partial^4}{\partial x^4} u(t, \chi_{2,j}) \right).$$

En considérant d'une part cette relation multipliée par θ pour $t = t_{n+1}$ et d'autre part cette relation multipliée par $1 - \theta$ pour $t = t_n$, on établit que

$$\varepsilon_2 = \frac{h_x^2}{24} \left(\theta \left(\frac{\partial^4}{\partial x^4} u(t_{n+1}, \chi_{1,j}) + \frac{\partial^4}{\partial x^4} u(t_{n+1}, \chi_{2,j}) \right) + (1 - \theta) \left(\frac{\partial^4}{\partial x^4} u(t_n, \tau'_{1,j}) + \frac{\partial^4}{\partial x^4} u(t_n, \tau'_{2,j}) \right) \right).$$

Si u admet une dérivée partielle quatrième relativement à x qui est continue sur $[0, T] \times [a, b]$ alors

$$|\varepsilon_2| \leq C_2 h_x^2 \quad \text{où} \quad C_2 = \frac{1}{6} \sup_{(t,x) \in [0,T] \times [a,b]} \left| \frac{\partial^4}{\partial x^4} u(t, x) \right|.$$

Le résultat est démontré. □

3.5.4 Convergence du schéma de Crank-Nicolson

On établit que le schéma de Crank-Nicolson est convergent pour toute valeur du paramètre θ comprise entre $\frac{1}{2}$ et 1 en exploitant la stabilité inconditionnelle et la consistance du schéma selon la même approche que celle détaillée à la section 3.3.4. Bien entendu, de la même manière, on établit que dans le cas où $\theta \in [0, \frac{1}{2}]$, le schéma de Crank-Nicolson est convergent sous la condition (3.76).

Ainsi, on voit que le schéma de Crank-Nicolson est particulièrement intéressant pour la valeur $\frac{1}{2}$ du paramètre θ : il est inconditionnellement stable et d'ordre 2 en temps et en espace.

Problèmes aux limites hyperboliques du premier ordre

L'équation d'advection (à vitesse constante) est la plus simple des équations hyperboliques modélisant un phénomène de transport. Elle constitue un problème modèle pour l'étude des schémas numériques permettant la résolution numérique des équations de propagation. Nous étudions dans ce chapitre, l'équation d'advection dans le cas où la vitesse est constante en introduisant la notion de droite caractéristique. Cette notion de courbe caractéristique est généralisée dans un second temps pour étudier l'équation d'advection à vitesse non constante. Nous présenterons ensuite quelques schémas numériques de type *différences finies* pour résoudre l'équation d'advection en détaillant tout particulièrement les notions de consistance et stabilité de ces schémas. Nous élargirons dans une dernière partie le propos en abordant le cas de l'équation des ondes. Nous commençons par décrire quelques phénomènes physiques modélisés par l'équation de transport.

4.1 Modélisation mathématique de phénomènes physiques par une équation de transport

Commençons par établir deux lemmes qui seront utiles dans cette partie consacrée à la modélisation mathématique de phénomènes physiques.

LEMME 4.1 Soit φ est une fonction continue sur $\mathbb{R}$. Pour tout $x_1 \in \mathbb{R}$ fixé, on a

$$\lim_{x_2 \rightarrow x_1} \frac{1}{x_2 - x_1} \int_{x_1}^{x_2} \varphi(x) \, dx = \varphi(x_1).$$

Démonstration Désignons par F la fonction définie pour tout réel x par $F(x) = \int_0^x \varphi(y) \, dy$. Comme φ est continue sur $\mathbb{R}$, la fonction F est une fonction de classe $\mathcal{C}^1$ sur $\mathbb{R}$ telle que $F'(x) = \varphi(x)$ pour tout $x \in \mathbb{R}$. On a

$$\frac{1}{x_2 - x_1} \int_{x_1}^{x_2} \varphi(x) \, dx = \frac{F(x_2) - F(x_1)}{x_2 - x_1}$$

ce qui s'interprète comme le taux d'accroissement de F entre x_2 et x_1 . Par définition de la dérivée en tant que limite du taux d'accroissement, nous avons

$$\lim_{x_2 \rightarrow x_1} \frac{F(x_2) - F(x_1)}{x_2 - x_1} = F'(x_1),$$

d'où le résultat. □

LEMME 4.2 Si φ est une fonction continue sur $\mathbb{R}$, telle que pour tous réels x_1, x_2 , on ait $\int_{x_1}^{x_2} \varphi(x) \, dx = 0$ alors la fonction φ est la fonction nulle.

Démonstration D'après les hypothèses, pour tous réels x_1, x_2 avec $x_1 \neq x_2$, on a

$$0 = \frac{1}{x_2 - x_1} \int_{x_1}^{x_2} \varphi(x) \, dx.$$

D'après le lemme 4.1, on a

$$\lim_{x_2 \rightarrow x_1} \frac{1}{x_2 - x_1} \int_{x_1}^{x_2} \varphi(x) \, dx = \varphi(x_1).$$

Ainsi, pour tout $x_1 \in \mathbb{R}$, on a $\varphi(x_1) = 0$. Le résultat est démontré. $\square$

4.1.1 Un modèle de trafic routier

On s'intéresse au déplacement de voitures sur une route à une seule voie sans possibilité de dépassement, ni possibilité d'entrer ou de sortir de la route à un échangeur. Nous supposons que la vitesse v des véhicules est identique.

La route est assimilée à un segment de droite. Nous désignons par $\rho(x, t)$ la densité linéique de voitures à la position x au temps t (exprimée en nombre de voitures par unité de longueur) et par $q(x, t)$ le flux de voitures passant au point x au temps t (exprimé en nombre de voitures par unité de temps). Nous supposons que les deux fonctions ρ et q sont des fonctions de classe $\mathcal{C}^1$ sur $\mathbb{R} \times \mathbb{R}$. Ces deux fonctions sont liées à la vitesse v par la relation

$$q(x, t) = v(x, t) \times \rho(x, t). \quad (4.1)$$

Le nombre N de voitures sur une portion $[x_1, x_2]$ de la route entre les temps t_1 et t_2 vaut

$$N = \underbrace{\int_{x_1}^{x_2} \rho(x, t_2) \, dx}_{\text{nb de voitures sur le tronçon } [x_1, x_2] \text{ au temps } t_2} - \underbrace{\int_{x_1}^{x_2} \rho(x, t_1) \, dx}_{\text{nb de voitures sur le tronçon } [x_1, x_2] \text{ au temps } t_1}. \quad (4.2)$$

D'après le principe de conservation du nombre de voitures issu de nos hypothèses, ce nombre N de voitures sur la portion $[x_1, x_2]$ de la route entre les temps t_1 et t_2 coïncide avec la différence entre le flux de véhicules entrant en x_1 entre les temps t_1 et t_2 et celui sortant en x_2 entre les temps t_1 et t_2 .

$$N = \underbrace{\int_{t_1}^{t_2} q(x_1, t) \, dt}_{\text{flux de véhicules entrant en } x_1 \text{ entre } t_1 \text{ et } t_2} - \underbrace{\int_{t_1}^{t_2} q(x_2, t) \, dt}_{\text{flux de véhicules sortant en } x_2 \text{ entre } t_1 \text{ et } t_2}. \quad (4.3)$$

On en déduit que pour tous réels t_1, t_2 avec $t_1 \neq t_2$, on a

$$\int_{x_1}^{x_2} \frac{\rho(x, t_2) - \rho(x, t_1)}{t_2 - t_1} \, dx = \frac{1}{t_2 - t_1} \int_{t_1}^{t_2} (q(x_1, t) - q(x_2, t)) \, dt. \quad (4.4)$$

En passant à la limite quand t_2 tend vers t_1 , on obtient la relation suivante⁽¹⁾ pour tous $t_1 \in \mathbb{R}^+$, $x_1, x_2 \in \mathbb{R}$,

$$\int_{x_1}^{x_2} \partial_t \rho(x, t_1) \, dx = q(x_1, t_1) - q(x_2, t_1). \quad (4.5)$$

Or,

$$q(x_1, t_1) - q(x_2, t_1) = - \int_{x_1}^{x_2} \partial_x q(x, t_1) \, dx. \quad (4.6)$$

On en déduit donc que pour tous $t_1 \in \mathbb{R}^+$, $x_1, x_2 \in \mathbb{R}$, on a

$$\int_{x_1}^{x_2} (\partial_t \rho(x, t_1) + \partial_x q(x, t_1)) \, dx = 0. \quad (4.7)$$

(1). Voir le lemme 4.1.



FIG. 1 Illustration de la propagation d'une fumée rejetée dans l'air par une usine de traitement des déchets ménagers.

Cette relation étant vraie pour tous réels x_1, x_2 , on a finalement⁽²⁾

$$\forall x \in \mathbb{R} \quad \forall t \in \mathbb{R}^+ \quad \partial_t \rho(x, t) + \partial_x q(x, t) = 0 \quad (4.8)$$

autrement dit, compte tenu de (4.1),

$$\forall x \in \mathbb{R} \quad \forall t \in \mathbb{R}^+ \quad \partial_t \rho(x, t) + \partial_x (v(x, t) \rho(x, t)) = 0. \quad (4.9)$$

Si on suppose que toutes les voitures roulent à la vitesse maximale autorisée c , cette équation prend la forme de l'équation de transport

$$\forall x \in \mathbb{R} \quad \forall t \in \mathbb{R}^+ \quad \partial_t \rho(x, t) + c \partial_x \rho(x, t) = 0. \quad (4.10)$$

4.1.2 Transport d'un polluant

On s'intéresse⁽³⁾ à une usine qui à un instant donné pris comme instant initial rejette une fumée chargée de polluant qui, sous l'effet du vent, se propage vers des habitations voisines, voir la fig. 1. On souhaite connaître la concentration de la fumée en tout point et en tout temps pour en estimer sa nocivité. On suppose que la fumée ne se propage que dans une direction. Au point $x \in \mathbb{R}$ et au temps $t \in \mathbb{R}^+$, on note $\rho(x, t)$ la concentration en fumée toxique et $v(x, t)$ la vitesse du vent. On suppose que $\rho \in \mathcal{C}^2(\mathbb{R} \times \mathbb{R}^+)$ et que $v \in \mathcal{C}^2(\mathbb{R} \times \mathbb{R}^+)$.

La quantité de polluant sur la portion de trajet située entre x_1 et x_2 et entre les temps t_1 et t_2 vaut

$$Q = \underbrace{\int_{x_1}^{x_2} \rho(x, t_2) \, dx}_{\text{quantité de polluant sur le tronçon } [x_1, x_2] \text{ au temps } t_2} - \underbrace{\int_{x_1}^{x_2} \rho(x, t_1) \, dx}_{\text{quantité de polluant sur le tronçon } [x_1, x_2] \text{ au temps } t_1}. \quad (4.11)$$

La quantité de polluant sur la portion $[x_1, x_2]$ du trajet entre les temps t_1 et t_2 coïncide avec la différence entre le flux de polluant entrant en x_1 entre les temps t_1 et t_2 et celui sortant en x_2 entre les temps t_1 et t_2 . Par ailleurs, le flux de polluant à la position x et au temps t est

⁽²⁾. On applique le lemme 4.2 à la fonction $\varphi : x \mapsto \partial_t \rho(x, t_1) + \partial_x q(x, t_1)$ pour t_1 fixé.

⁽³⁾. Exemple présenté dans A. Friedman, W. Littman, *Industrial mathematics, a course in solving real-world problems*, Society for Industrial and Applied Mathematics (SIAM), 1994.

- d'une part proportionnel à la concentration de polluant $\rho(x, t)$ transportée par le vent à la vitesse $v(x, t)$ selon la loi

$$q(x, t) = \rho(x, t) \times v(x, t); \quad (4.12)$$

- d'autre part lié au phénomène de diffusion qui tend, même en l'absence de vent, à ce que le nuage de fumée s'étale dans l'espace. On dispose d'une loi empirique, la loi de Fick, qui précise le comportement du flux de polluant par diffusion au temps t et à la position x , noté $j(x, t)$. Cette loi exprime la tendance de la fumée à se déplacer des endroits de forte concentration vers ceux de faible concentration de la manière suivante :

$$j(x, t) = -k \partial_x \rho(x, t) \quad (4.13)$$

où le réel k est appelé coefficient de diffusion, et dépend du type de fumée ainsi que du milieu de propagation.

On obtient ainsi

$$Q = \underbrace{\int_{t_1}^{t_2} (q(x_1, t) + j(x_1, t)) \, dt}_{\text{flux de polluant entrant en } x_1 \text{ entre } t_1 \text{ et } t_2} - \underbrace{\int_{t_1}^{t_2} (q(x_2, t) + j(x_2, t)) \, dt}_{\text{flux de polluant sortant en } x_2 \text{ entre } t_1 \text{ et } t_2}. \quad (4.14)$$

On déduit de (4.11) et (4.14) que

$$\int_{x_1}^{x_2} \frac{\rho(x, t_2) - \rho(x, t_1)}{t_2 - t_1} \, dx = \frac{1}{t_2 - t_1} \int_{t_1}^{t_2} \left((q(x_1, t) + j(x_1, t)) - (q(x_2, t) + j(x_2, t)) \right) dt.$$

En passant à la limite quand t_2 tend vers t_1 , on obtient ⁽⁴⁾ pour tous réels x_1, x_2 et pour tout réel t_1

$$\int_{x_1}^{x_2} \partial_t \rho(x, t_1) \, dx = (q(x_1, t_1) + j(x_1, t_1)) - (q(x_2, t_1) + j(x_2, t_1)).$$

Or,

$$(q(x_1, t_1) + j(x_1, t_1)) - (q(x_2, t_1) + j(x_2, t_1)) = - \int_{x_1}^{x_2} \partial_x (q(x, t_1) + j(x, t_1)) \, dx.$$

On a donc, pour tout $t \in \mathbb{R}_+^*$ et pour tous réels x_1, x_2

$$\int_{x_1}^{x_2} \left(\partial_t \rho(x, t) + \partial_x (q(x, t) + j(x, t)) \right) dx = 0.$$

En passant à la limite quand x_2 tend vers x_1 , on établit ⁽⁵⁾ que pour tout $t \in \mathbb{R}_+^*$ et pour tout $x \in \mathbb{R}$,

$$\partial_t \rho(x, t) + \partial_x q(x, t) + \partial_x j(x, t) = 0,$$

autrement dit,

$$\partial_t \rho(x, t) + \partial_x (v(x, t) \rho(x, t)) - k \partial_{xx}^2 \rho(x, t) = 0. \quad (4.15)$$

Cette équation est appelée *équation d'advection-diffusion* ou *équation de transport-diffusion*.

4.1.3 Vieillessement des populations : équation de McKendric et von Fœrster

On s'intéresse ⁽⁶⁾ à une population structurée physiologiquement par âge pour laquelle on veut modéliser le vieillissement des individus ainsi que leur division en deux nouveaux individus d'âge zéro. Cette approche est particulièrement utilisée pour la modélisation d'une population de cellules en division.

⁽⁴⁾. Voir le lemme 4.1.

⁽⁵⁾. Voir le lemme 4.2.

⁽⁶⁾. Voir par exemple : J.D. Murray, Mathematical Biology, tome 1, Springer, 2001, section 1.7 p. 36

On note $\rho(x, t)$ la densité d'individus d'âge x au temps t (c'est-à-dire le nombre d'individus d'âge compris entre x et $x + dx$ au temps t). Dans le modèle de McKendrick⁽⁷⁾-Von Foerster⁽⁸⁾, l'évolution de ρ est donné par

$$\partial_x \rho(x, t) + \partial_t \rho(x, t) + d(x) \rho(x, t) = 0 \quad \forall x \in \mathbb{R}_+^* \quad \forall t \in \mathbb{R}_+^* \quad (4.16a)$$

$$\rho(0, t) = 2 \int_0^{+\infty} b(x) \rho(x, t) dx \quad (4.16b)$$

$$\rho(x, 0) = \rho_0(x) \quad (4.16c)$$

L'équation (4.16a) est une équation de transport en âge qui rend compte du vieillissement de la population à la vitesse $c = 1$ avec un terme de mortalité en fonction de l'âge qui est $d(x)$ et qui correspond à la disparition des cellules qui se divisent. Le terme de bord (4.16b) en $x = 0$ représente les naissances de nouveaux individus d'âge zéro dues à la division de la cellule mère d'âge x . Le taux de division dans la population d'âge x est $b(x)$. Par ailleurs, $\rho_0(x)$ est la densité d'individus d'âge x à l'instant pris comme instant initial.

Le taux de division $d(x)$ a une interprétation probabiliste. En effet la probabilité qu'une cellule ne se soit pas divisée avant l'âge x est donnée par

$$P(x) = \exp \left(- \int_0^x d(y) dy \right). \quad (4.17)$$

Ainsi, si l'on veut modéliser une population dans laquelle toutes les cellules se divisent à un moment ou à un autre, on est amené à faire l'hypothèse suivante sur le taux de division

$$\lim_{x \rightarrow +\infty} \int_0^x d(y) dy = +\infty. \quad (4.18)$$

Ce modèle est étudié dans : Pierre Gabriel, *Équations structurées en dynamique des populations*, ENS Cachan (2014), voir cel.archives-ouvertes.fr/cel-00918869v2 et dans J.D. Murray, *Mathematical Biology*, tome 1, Springer, 2001, section 1.7 p. 36.

4.1.4 Différentes formes pour l'équation du transport

D'un point de vue physique, l'advection est le transport d'une certaine grandeur (telle que la chaleur, des éléments chimiques, des charges électriques, etc.) par le mouvement du milieu environnant. Si la grandeur physique considérée est représentée par une fonction scalaire u de la position $\mathbf{x}$ et du temps t , et qu'elle est transportée par advection à la vitesse $\mathbf{v}$, alors elle est régie par l'équation aux dérivées partielles

$$\frac{\partial u}{\partial t}(\mathbf{x}, t) + \operatorname{div} (u(\mathbf{x}, t) \mathbf{v}(\mathbf{x}, t)) = f(\mathbf{x}, t) \quad (4.19)$$

où f est une fonction donnée. Dans le cas où le flux est incompressible, c'est-à-dire que $\operatorname{div} \mathbf{v} = 0$ alors en utilisant la formule de calcul vectoriel $\operatorname{div} (u \mathbf{v}) = u \operatorname{div} \mathbf{v} + \nabla u \cdot \mathbf{v}$, l'équation d'advection (4.19) se ré-écrit

$$\frac{\partial u}{\partial t}(\mathbf{x}, t) + \mathbf{v}(\mathbf{x}, t) \cdot \nabla u(\mathbf{x}, t) = f(\mathbf{x}, t) \quad (4.20)$$

En dimension 1 d'espace, nous obtenons la forme suivante pour l'équation (4.20)

$$\frac{\partial u}{\partial t}(x, t) + v(x, t) \frac{\partial u}{\partial x}(x, t) = f(x, t) \quad (4.21)$$

Le transport d'une grandeur étudiée dans un milieu donné résulte le plus souvent d'une combinaison d'un phénomène d'advection (appelé encore convection) et d'un phénomène de diffusion. La diffusion

(7). Anderson Gray McKendrick (1876 - 1943) est un physicien et épidémiologiste écossais pionnier dans l'utilisation de méthodes mathématiques en épidémiologie.

(8). Heinz von Foerster (1911 - 2002) est un scientifique austro-américain situé à la croisée de la physique et de la philosophie.

correspond à la tendance « naturelle » de la grandeur observée à aller des régions à forte concentration de celle-ci vers les régions où elle est le moins présente. On modélise l'évolution au cours du temps dans le milieu considéré de la grandeur étudiée par l'équation suivante appelée *équation d'advection-diffusion* ou *équation de convection-diffusion*⁽⁹⁾ où un terme de diffusion est ajouté à l'équation d'advection (4.19)

$$\frac{\partial u}{\partial t}(\mathbf{x}, t) + \operatorname{div}(u(\mathbf{x}, t) \mathbf{v}(\mathbf{x}, t)) - \operatorname{div}(\kappa \nabla u(\mathbf{x}, t)) = f(\mathbf{x}, t) \quad (4.22)$$

où κ est une constante positive caractéristique du milieu.⁽¹⁰⁾ En dimension 1 d'espace, nous obtenons la forme suivante pour l'équation d'advection-diffusion (4.22)

$$\frac{\partial u}{\partial t}(x, t) + v(x, t) \frac{\partial u}{\partial x}(x, t) - \kappa \frac{\partial^2 u}{\partial x^2}(x, t) = f(x, t) \quad (4.23)$$

4.2 Étude de l'équation d'advection à vitesse constante

4.2.1 Cas de l'équation homogène

On s'intéresse au problème modèle suivant : trouver u tel que

$$\partial_t u(x, t) + c \partial_x u(x, t) = 0 \quad \forall x \in \mathbb{R} \quad \forall t \in \mathbb{R}_+^* \quad (4.24)$$

sous la condition initiale

$$u(x, t = 0) = u_0(x) \quad \forall x \in \mathbb{R} \quad (4.25)$$

où c est une constante réelle non nulle.

DÉFINITION 4.1 On dit que u est une solution classique de l'équation (4.24) si $u \in \mathcal{C}^1(\mathbb{R} \times \mathbb{R}^+)$ et si elle satisfait en tout $(x, t) \in \mathbb{R} \times \mathbb{R}^+$ l'équation (4.24).

Nous avons le résultat d'existence suivant pour le problème d'advection (4.24)–(4.25).

THÉORÈME 4.1 Si $u_0 \in \mathcal{C}^1(\mathbb{R})$ alors le problème d'advection (4.24)–(4.25) admet une solution $u \in \mathcal{C}^1(\mathbb{R} \times \mathbb{R}^+)$ donnée par

$$\forall t \in \mathbb{R}^+ \quad \forall x \in \mathbb{R} \quad u(x, t) = u_0(x - ct). \quad (4.26)$$

Démonstration Nous procédons par analyse-synthèse. Supposons qu'il existe une solution u au problème d'advection (4.24)–(4.25) qui soit de classe $\mathcal{C}^1$ sur $\mathbb{R}^+ \times \mathbb{R}$.

▷ Cherchons à déterminer une fonction X dépendant de la variable de temps t telle que u soit constante le long de la courbe $\mathcal{C}$ du plan paramétrée par $\gamma : s \in \mathbb{R} \mapsto (X(s), s) \in \mathbb{R}^2$. Posons $U(t) = u(X(t), t)$ pour tout $t \in \mathbb{R}^+$. La fonction U coïncide avec la fonction u le long de la courbe $\mathcal{C}$. Cela signifie que u est constante le long la courbe $\mathcal{C}$ si, et seulement si, U est une fonction constante de la variable réelle. Pour tout $t \in \mathbb{R}^+$, on a

$$\begin{aligned} U'(t) &= X'(t) \partial_1 u(X(t), t) + \partial_2 u(X(t), t) \\ &= X'(t) \partial_1 u(X(t), t) - c \partial_1 u(X(t), t) && \text{d'après (4.24)} \\ &= (X'(t) - c) \partial_1 u(X(t), t) \end{aligned}$$

⁽¹⁰⁾. Dans le passé, on utilisait indifféremment le terme de mouvement advectif et de mouvement convectif pour désigner le mouvement du milieu dans son ensemble. Le terme advection semble s'imposer actuellement. Voir à ce sujet : Francis Albarède, *Advection et convection*, Planet Terre - ISSN 2552-9250, <https://planet-terre.ens-lyon.fr/ressource/advection-convection.xml>, 2005.




FIG. 2 Une droite caractéristique.

où la notation ∂_i fait référence à la dérivation de la fonction par rapport à la i -ième variable dont dépend la fonction. On en déduit que U est constante si et seulement si $X'(t) = c$. On a donc $X : s \in \mathbb{R}^+ \mapsto cs + cste$ où $cste$ désigne un réel quelconque et la courbe $\mathcal{C}$ est paramétrée par $s \in \mathbb{R} \mapsto (cs + cste, s) \in \mathbb{R}^2$. Il s'agit d'une droite d'équation cartésienne $x = ct + cste$.

Les droites d'équation cartésienne $x = ct + cste$ ainsi obtenues sont appelées *courbes caractéristiques* (ou plus simplement, *caractéristiques*) de l'équation d'advection (4.24).

$\triangleright$ Considérons un point générique $(x_1, t_1) \in \mathbb{R} \times \mathbb{R}^+$ et une droite caractéristique $\mathcal{C}$ d'équation $x = ct + cste$ passant par ce point, voir la Fig. 2. Cette droite passe aussi par le point $(cste, 0)$. Comme u est constante le long de cette droite, on a

$$u(x_1, t_1) = u(cste, 0) = u_0(cste) = u_0(x - ct).$$

Cette relation étant vraie pour tout $(x_1, t_1) \in \mathbb{R} \times \mathbb{R}^+$, on a donc établi que si le problème d'advection (4.24)–(4.25) admet une solution de classe $\mathcal{C}^1$, celle-ci vérifie

$$\forall t \in \mathbb{R}^+ \quad \forall x \in \mathbb{R} \quad u(x, t) = u_0(x - ct). \quad (4.27)$$

Reste à établir l'existence. Considérons la fonction $u : (x, t) \mapsto u_0(x - ct)$. Pour tout $x \in \mathbb{R}$ et pour tout $t \in \mathbb{R}^+$, en utilisant la formule de dérivation composée, on obtient

$$\partial_t u(x, t) + c \partial_x u(x, t) = -c u'_0(x - ct) + c u'_0(x - ct) = 0.$$

Le problème d'advection (4.24)–(4.25) admet donc une solution. $\square$

Interprétons ce résultat (cela sera utile ultérieurement pour comprendre la construction des schémas numériques). Pour tout $t \in \mathbb{R}^+$ et pour tout $x \in \mathbb{R}$, on a $u(x, t) = u_0(x - ct) = u_0(\chi)$ où on a posé $\chi = x - ct$. La solution en tout temps est donc la translatée selon l'axe des abscisses de la solution au temps initial d'une quantité ct . De plus, si u_0 est à support borné avec $\text{supp}(u_0) \subset [a, b]$ alors au temps t la solution a un support inclus dans $[a + ct, b + ct]$.

THÉORÈME 4.2 Si $u_0 \in \mathcal{C}^1(\mathbb{R}) \cap \mathbb{L}^2(\mathbb{R})$ alors la solution u du problème d'advection (4.24)–(4.25) est unique et elle vérifie

$$\forall t \in \mathbb{R}^+ \quad \|u(\cdot, t)\|_{\mathbb{L}^2(\mathbb{R})} = \|u_0\|_{\mathbb{L}^2(\mathbb{R})}.$$

Démonstration $\triangleright$ Supposons que u_0 de classe $\mathcal{C}^1$ sur $\mathbb{R}$ appartienne à l'espace $\mathbb{L}^2(\mathbb{R})$, ce qui traduit physiquement le fait que la donnée initiale est d'énergie finie. Dans ce cas, d'après la relation (4.26), pour tout $t \in \mathbb{R}^+$ la solution au temps t , c'est-à-dire la fonction $u(\cdot, t) : x \in \mathbb{R} \mapsto u(x, t)$ appartient à l'espace $\mathbb{L}^2(\mathbb{R})$ et

$$\|u(\cdot, t)\|_{\mathbb{L}^2(\mathbb{R})}^2 = \int_{\mathbb{R}} u_0(x - ct)^2 dx = \int_{\mathbb{R}} u_0(y)^2 dy = \|u_0\|_{\mathbb{L}^2(\mathbb{R})}^2.$$

Il y a donc conservation au cours du temps de la norme $\mathbb{L}^2(\mathbb{R})$ de la solution du problème (4.24)–(4.25).

⊇ Pour établir l'unicité de la solution au problème d'advection (4.24)–(4.25), considérons deux solutions u_1 et u_2 à ce problème. On vérifie sans peine que la fonction $v = u_2 - u_1$ satisfait

$$\partial_t v(x, t) + c \partial_x v(x, t) = 0 \quad \forall x \in \mathbb{R} \quad \forall t \in \mathbb{R}_+^*$$

sous la condition initiale $v(x, t = 0) = 0$ pour tout $x \in \mathbb{R}$. Le problème satisfait par v est un problème d'advection de la forme (4.24)–(4.25) pour une donnée initiale nulle. D'après la première partie de la preuve, on en déduit que $\|v(\cdot, t)\|_{\mathbb{L}^2(\mathbb{R})} = \|0\|_{\mathbb{L}^2(\mathbb{R})} = 0$ pour tout $t \in \mathbb{R}^+$. On en conclut que $v = 0$ et donc que $u_2 = u_1$. Le problème d'advection (4.24)–(4.25) a donc au plus une solution. $\square$

Régularité de la solution

On déduit de la relation (4.26) que si u_0 est de classe $\mathcal{C}^k$ sur $\mathbb{R}$, $k \in \mathbb{N}^* \cup \{\infty\}$, alors, pour tout $t \in \mathbb{R}^+$, la solution $u(\cdot, t)$ au temps t est aussi de classe $\mathcal{C}^k$ sur $\mathbb{R}$. Inversement, la relation (4.26) définissant u a un sens même si la donnée u_0 n'est pas de classe $\mathcal{C}^1$ sur $\mathbb{R}$. Mais dans ce cas se pose la question de savoir en quel sens u est solution de l'équation d'advection (4.24). En particulier, si u_0 possède une singularité en $x_0 \in \mathbb{R}$ (i.e. si u'_0 n'est pas continue en x_0 et par conséquent que u_0 n'est que de classe $\mathcal{C}^1$ par morceaux) alors la relation (4.26) indique que la singularité se propage à la vitesse c le long de la caractéristique issue de x_0 .

Supposons par exemple u_0 localement intégrable sur $\mathbb{R}$ ($u_0 \in \mathbb{L}_{\text{loc}}^1(\mathbb{R})$). Dans ce cas, la fonction u définie par la relation (4.26) est elle aussi localement intégrable sur $\mathbb{R} \times \mathbb{R}^+$. Considérons une fonction φ quelconque de classe $\mathcal{C}^1$ sur $\mathbb{R} \times \mathbb{R}^+$ à support compact ($\varphi \in \mathcal{C}_c^1(\mathbb{R} \times \mathbb{R}^+)$) et multiplions chaque membre de l'équation d'advection (4.24) par φ puis intégrons. Il vient

$$\int_0^{+\infty} \int_{-\infty}^{+\infty} \partial_t u(x, t) \varphi(x, t) \, dx \, dt + c \int_0^{+\infty} \int_{-\infty}^{+\infty} \partial_x u(x, t) \varphi(x, t) \, dx \, dt = 0.$$

En utilisant la formule d'intégration par parties, nous obtenons

$$\int_0^{+\infty} \int_{-\infty}^{+\infty} u(x, t) (\partial_t \varphi(x, t) + c \partial_x \varphi(x, t)) \, dx \, dt + \int_{-\infty}^{+\infty} u_0(x) \varphi(x, 0) \, dx = 0. \quad (4.28)$$

DÉFINITION 4.2 (Solution au sens faible)

Soit $u_0 \in \mathbb{L}_{\text{loc}}^1(\mathbb{R})$. On dit que $u \in \mathbb{L}_{\text{loc}}^1(\mathbb{R} \times \mathbb{R}^+)$ est solution au sens faible du problème d'advection (4.24)–(4.25) si, pour tout $\varphi \in \mathcal{C}_c^1(\mathbb{R} \times \mathbb{R}^+)$, on a

$$\int_0^{+\infty} \int_{-\infty}^{+\infty} u(x, t) (\partial_t \varphi(x, t) + c \partial_x \varphi(x, t)) \, dx \, dt + \int_{-\infty}^{+\infty} u_0(x) \varphi(x, 0) \, dx = 0.$$

On vérifie que toute solution au sens faible du problème d'advection est solution de l'équation (4.24) au sens des distributions (il s'agit d'une distribution régulière). Par ailleurs, toute solution de classe $\mathcal{C}^1$ du problème d'advection (4.24)–(4.25) est bien entendu solution au sens faible du problème d'advection et, inversement, toute solution au sens faible du problème d'advection qui est de classe $\mathcal{C}^1$ est une solution du problème d'advection (4.24)–(4.25) (au sens classique). Enfin, on démontre que si $u_0 \in \mathbb{L}_{\text{loc}}^1(\mathbb{R})$ alors la fonction u définie par la relation (4.26) est l'unique solution au sens faible du problème d'advection dans $\mathbb{L}_{\text{loc}}^1(\mathbb{R} \times \mathbb{R}^+)$.

Semi-groupe de l'équation d'advection

Pour $t \in \mathbb{R}^+$ fixé, définissons l'opérateur $T_{(t)}$ tel que

$$T_{(t)} : u_0 \in \mathcal{C}^1(\mathbb{R}) \mapsto u(\cdot, t) \in \mathcal{C}^1(\mathbb{R})$$

où $u(\cdot, t) : x \in \mathbb{R} \mapsto u_0(x - ct) \in \mathbb{R}$ désigne la première fonction partielle de la solution classique u du problème d'advection (4.24)–(4.25). L'opérateur $T_{(t)}$ est clairement un opérateur linéaire. De plus, pour tous $s, t \in \mathbb{R}^+$, on a

- (a) $T_{(t)} \circ T_{(s)} = T_{(s+t)}$ car pour tout $u_0 \in \mathcal{C}^1(\mathbb{R})$, on a $T_{(s)}u_0 = u_0(\cdot - cs)$ donc $T_{(t)} \circ T_{(s)}u_0 = u_0(\cdot - c(s+t)) = T_{(s+t)}u_0$
 (b) $T_{(0)} = Id$ car pour tout $u_0 \in \mathcal{C}^1(\mathbb{R})$, on a $T_{(0)}u_0 = u(\cdot, 0)$ et $u(\cdot, 0) : x \in \mathbb{R} \mapsto u_0(x) \in \mathbb{R}$, donc $T_{(0)}u_0 = u_0$.
 (c) $T_{(t)} \circ T_{(-t)} = Id$.

Compte tenu de ces deux propriétés, l'opérateur linéaire $T_{(t)}$ est appelé *semi-groupe* de l'équation d'advection. Si on autorise le temps à prendre des valeurs négatives, alors on vérifie de plus que

$$(c) \quad T_{(t)} \circ T_{(-t)} = Id.$$

On parle dans ce cas du *groupe* de l'équation d'advection.

Désignons par $\mathcal{C}_b^1(\mathbb{R})$ l'espace vectoriel des applications bornées sur $\mathbb{R}$, à dérivées bornées sur $\mathbb{R}$. On munit cet espace vectoriel de la norme définie par

$$\|v\|_{\mathcal{C}_b^1(\mathbb{R})} = \|v\|_{\infty, \mathbb{R}} + \|v'\|_{\infty, \mathbb{R}}.$$

Pour tout $t \in \mathbb{R}^+$, l'opérateur linéaire $T_{(t)}$ est continu de $\mathcal{C}_b^1(\mathbb{R})$ dans lui même.

4.2.2 Cas d'une équation non homogène

On s'intéresse au problème modèle suivant : trouver u tel que

$$\partial_t u(x, t) + c \partial_x u(x, t) = f(x, t) \quad \forall x \in \mathbb{R} \quad \forall t \in \mathbb{R}_+^* \quad (4.29)$$

sous la condition initiale

$$u(x, t = 0) = u_0(x) \quad \forall x \in \mathbb{R} \quad (4.30)$$

où c est une constante réelle, u_0 est une application de classe $\mathcal{C}^1$ sur $\mathbb{R}$ et f est une application continue sur $\mathbb{R} \times \mathbb{R}^+$.

Pour résoudre cette équation, considérons un point (x, t) du plan et la droite caractéristique $\mathcal{C}$ passant par ce point dont une paramétrisation est $\gamma : s \in \mathbb{R} \mapsto (X(s), s) \in \mathbb{R}^2$ où $X(s) = x + c(s - t)$. Supposons que le problème d'advection (4.29)–(4.30) admette une solution u .

Pour tout $s \in \mathbb{R}$, on a

$$\partial_s u(X(s), s) = X'(s) \partial_1 u(X(s), s) + \partial_2 u(X(s), s).$$

D'après (4.29), on a $\partial_2 u(X(s), s) = f(X(s), s) - c \partial_1 u(X(s), s)$, d'où

$$\partial_s u(X(s), s) = \underbrace{(X'(s) - c)}_{=0} \partial_1 u(X(s), s) + f(X(s), s) = f(X(s), s).$$

On en déduit que

$$u(X(t), t) = \underbrace{u(X(0), 0)}_{=u_0(X(0))} + \int_0^t f(X(s), s) \, ds.$$

Comme $X(s) = x + c(s - t)$, on obtient finalement,

$$u(x, t) = u_0(x - ct) + \int_0^t f(x + c(s - t), s) \, ds. \quad (4.31)$$

Donc, si le problème d'advection (4.29)–(4.30) admet une solution u , celle-ci est nécessairement de la forme (4.31). Inversement, on vérifie sans peine que la fonction u définie en (4.31) est bien solution du problème d'advection (4.29)–(4.30). On a donc démontré le résultat suivant.

THÉORÈME 4.3 (Formule de Duhamel⁽¹¹⁾)

Si $u_0 \in \mathcal{C}^1(\mathbb{R})$ et $f \in \mathcal{C}^0(\mathbb{R} \times \mathbb{R}^+)$ alors le problème d'advection (4.29)–(4.30) admet une unique solution $u \in \mathcal{C}^1(\mathbb{R} \times \mathbb{R}^+)$ donnée par la formule de Duhamel

$$\forall t \in \mathbb{R}^+ \quad \forall x \in \mathbb{R} \quad u(x, t) = u_0(x - ct) + \int_0^t f(x + c(s - t), s) \, ds.$$

Remarque 4.1 Noter que dans la relation (4.31) donnant l'expression de la solution du problème d'advection (4.29)–(4.30), le premier terme correspond à la solution du problème d'advection homogène (4.24)–(4.25). La formule de Duhamel joue un rôle analogue pour l'équation d'advection (qui est une équation hyperbolique d'ordre 1) à la formule issue de la méthode de la variation de la constante pour les équations différentielles linéaire du premier ordre.

4.3 Étude de l'équation d'advection à vitesse variable

4.3.1 Cas de l'équation homogène

On s'intéresse au problème modèle suivant : trouver u tel que

$$\partial_t u(x, t) + c(x, t) \partial_x u(x, t) = 0 \quad \forall x \in \mathbb{R} \quad \forall t \in \mathbb{R}_+^* \quad (4.32)$$

sous la condition initiale

$$u(x, t = 0) = u_0(x) \quad \forall x \in \mathbb{R} \quad (4.33)$$

où $u_0 \in \mathcal{C}^1(\mathbb{R})$ et c est une fonction continue sur $\mathbb{R} \times \mathbb{R}$ (nous autorisons le temps à être négatif) dont on précisera les propriétés ultérieurement.

Pour résoudre l'équation d'advection à vitesse variable (4.32), nous allons généraliser l'approche utilisée dans la preuve du théorème 4.1. On cherche des courbes du plan telles que toute solution classique de l'équation d'advection (4.32) soit constante le long ces courbes. Considérons une paramétrisation de ces courbes, où le temps est le paramètre, de la forme

$$\gamma : s \in \mathbb{R} \mapsto (X(s), s) \in \mathbb{R}^2 \quad (4.34)$$

où X est une fonction dérivable à déterminer.

Soit u une solution classique de l'équation d'advection (4.32) et $U = u \circ \gamma$. Pour tout $s \in \mathbb{R}$, on a $U(s) = u(X(s), s)$ et

$$U'(s) = X'(s) \partial_x u(X(s), s) + \partial_t u(X(s), s).$$

Comme u est une solution de (4.32), on a

$$\forall s \in \mathbb{R} \quad U'(s) = (X'(s) - c(X(s), s)) \partial_x u(X(s), s).$$

Ainsi, si on impose à la fonction X d'être solution sur $\mathbb{R}$ de l'équation différentielle

$$y'(s) = c(y(s), s) \quad \forall s \in \mathbb{R} \quad (4.35)$$

alors toute solution classique de l'équation d'advection (4.32) sera constante le long des courbes paramétrées considérées. En d'autres termes, si la fonction X est telle que $X'(s) = c(X(s), s)$ pour tout $s \in \mathbb{R}$ alors une solution u de l'équation du transport (4.32) est constante le long de la courbe $\mathcal{C}$ paramétrée par la fonction γ définie en (4.34).

L'équation différentielle (4.35) étant une équation différentielle du premier ordre, on a le résultat suivant qui découle du théorème de Cauchy-Lipschitz.

⁽¹¹⁾. DUHAMEL, Jean-Marie (1797, Saint-Malo - 1872, Paris). Mathématicien et physicien français auteur de travaux sur les équations aux dérivées partielles, sur l'acoustique et la propagation de la chaleur. Une rue du centre-ville de Rennes porte son nom.

LEMME 4.3 *On suppose que la fonction c est continue sur $\mathbb{R} \times \mathbb{R}$ et lipschitzienne par rapport à la première variable, uniformément par rapport à la seconde, i.e.*

$$\exists L \in \mathbb{R}^+ \quad \forall t \in \mathbb{R} \quad \forall (x_1, x_2) \in \mathbb{R}^2 \quad |c(x_1, t) - c(x_2, t)| \leq L |x_2 - x_1|.$$

Pour tout $(x, t) \in \mathbb{R}^2$, le problème de Cauchy : trouver $y \in C^1(\mathbb{R})$ tel que

$$\begin{cases} y'(s) = c(y(s), s) & \forall s \in \mathbb{R} \\ y(t) = x \end{cases} \quad (4.36)$$

admet une unique solution.

Ainsi, pour tout $(x, t) \in \mathbb{R}^2$ fixé, il existe une unique courbe paramétrée dont une paramétrisation est de la forme (4.34) où X est tel que $X'(s) = c(X(s), s)$ pour tout $s \in \mathbb{R}$ et qui passe par le point (x, t) . Le long d'une telle courbe, une solution de l'équation d'advection (4.32) est constante et c'est l'unique courbe passant par le point $(x, t) \in \mathbb{R}^2$ qui vérifie cette propriété.

Nous allons à présent étudier les propriétés de ces courbes. Pour cela, pour tout $(x, t) \in \mathbb{R}^2$ fixé, désignons par $X(\cdot; x, t)$ la solution du problème de Cauchy

$$\begin{cases} X'(s; x, t) = c(X(s; x, t), s) & \forall s \in \mathbb{R} \\ X(t; x, t) = x \end{cases} \quad (4.37)$$

Sous les hypothèses du lemme 4.3, le problème (4.37) admet une unique solution.

DÉFINITION 4.3 *Soit c une fonction continue sur $\mathbb{R} \times \mathbb{R}$ et lipschitzienne par rapport à la première variable, uniformément par rapport à la seconde. On appelle flot de l'équation différentielle $y'(s) = c(y(s), s) \quad \forall s \in \mathbb{R}$, la fonction $X : (s, x, t) \in \mathbb{R}^3 \mapsto X(s; x, t) \in \mathbb{R}$ où $X(\cdot; x, t)$ est la solution du problème de Cauchy*

$$\begin{cases} X'(s; x, t) = c(X(s; x, t), s) & \forall s \in \mathbb{R} \\ X(t; x, t) = x \end{cases}$$

Il résulte de ce qui précède que le flot X associé à l'équation du transport (4.32) est tel que l'application $\gamma : s \in \mathbb{R} \mapsto (X(s; x, t), s) \in \mathbb{R}^2$ est une paramétrisation de l'unique courbe passant par le point (x, t) le long de laquelle une solution u de l'équation (4.32) est constante.

DÉFINITION 4.4 *On appelle courbes caractéristiques de l'équation d'advection (4.32) les courbes du plan $\mathcal{C}(x, t)$ où $(x, t) \in \mathbb{R} \times \mathbb{R}$, définies par*

$$\mathcal{C}(x, t) = \left\{ (y, s) \in \mathbb{R} \times \mathbb{R} ; y = X(s; x, t) \right\}$$

où $X(\cdot; x, t)$ est la solution du problème de Cauchy (4.37).

La courbe caractéristique $\mathcal{C}(x, t)$ passe par le point (x, t) , ce qui justifie la notation utilisée.

PROPOSITION 4.1 (Propriétés des courbes caractéristiques)

On suppose que la fonction c dans l'équation d'advection (4.32) est continue sur $\mathbb{R} \times \mathbb{R}$ et lipschitzienne par rapport à la première variable, uniformément par rapport à la seconde variable.

✕ Deux courbes caractéristiques $\mathcal{C}(x_1, t_1)$ et $\mathcal{C}(x_2, t_2)$ de l'équation d'advection (4.32) sont égales si et seulement si (x_1, t_1) et (x_2, t_2) appartiennent à la même courbe intégrale de l'équation différentielle (4.35), i.e.

$$\mathcal{C}(x_1, t_1) = \mathcal{C}(x_2, t_2) \iff x_2 = X(t_2; x_1, t_1) \iff x_1 = X(t_1; x_2, t_2).$$

✕ Pour $t \in \mathbb{R}$ fixé, l'ensemble des courbes caractéristiques $\mathcal{C}(x, t)$ lorsque x parcourt $\mathbb{R}$ forme un ensemble de courbes disjointes du plan qui remplissent le plan,⁽¹²⁾ i.e.

$$(a) \quad \forall (x_1, x_2) \in \mathbb{R}^2 \quad (x_1 \neq x_2 \implies \mathcal{C}(x_1, t) \cap \mathcal{C}(x_2, t) = \emptyset),$$

$$(b) \quad \bigcup_{x \in \mathbb{R}} \mathcal{C}(x, t) = \mathbb{R}^2.$$

Démonstration On a

$$\mathcal{C}(x_1, t_1) = \{(X(s; x_1, t_1), s) ; s \in \mathbb{R}\} \quad \text{et} \quad \mathcal{C}(x_2, t_2) = \{(X(s'; x_2, t_2), s') ; s' \in \mathbb{R}\}.$$

$\supseteq$ Supposons que $\mathcal{C}(x_1, t_1) = \mathcal{C}(x_2, t_2)$. Pour tout $s \in \mathbb{R}$, on a $(X(s; x_1, t_1), s) \in \mathcal{C}(x_2, t_2)$. Donc, il existe $s' \in \mathbb{R}$ tel que

$$(X(s; x_1, t_1), s) = (X(s'; x_2, t_2), s').$$

Cela implique que $s' = s$ et que

$$\forall s \in \mathbb{R} \quad X(s; x_1, t_1) = X(s; x_2, t_2). \quad (4.38)$$

Or, $X(\cdot; x_1, t_1)$ est l'unique solution du problème de Cauchy suivant (voir (4.37)) :

$$\begin{cases} X'(s; x_1, t_1) = c(X(s; x_1, t_1), s) & \forall s \in \mathbb{R} \\ X(t_1; x_1, t_1) = x_1 \end{cases} \quad (4.39a)$$

$$X(t_1; x_1, t_1) = x_1 \quad (4.39b)$$

On a donc $x_1 = X(t_1; x_1, t_1)$ d'après (4.39b) et $X(t_1; x_1, t_1) = X(t_1; x_2, t_2)$ d'après (4.38), ce qui implique que $x_1 = X(t_1; x_2, t_2)$. On a donc montré que :

$$\mathcal{C}(x_1, t_1) = \mathcal{C}(x_2, t_2) \implies x_1 = X(t_1; x_2, t_2).$$

Par le même raisonnement, on a aussi $X(\cdot; x_2, t_2)$ qui est l'unique solution du problème de Cauchy

$$\begin{cases} X'(s; x_2, t_2) = c(X(s; x_2, t_2), s) & \forall s \in \mathbb{R} \\ X(t_2; x_2, t_2) = x_2 \end{cases} \quad (4.40a)$$

$$X(t_2; x_2, t_2) = x_2 \quad (4.40b)$$

On a donc $x_2 = X(t_2; x_2, t_2)$ d'après (4.40b) et $X(t_2; x_2, t_2) = X(t_2; x_1, t_1)$ d'après (4.38), ce qui implique que $x_2 = X(t_2; x_1, t_1)$. On a donc aussi

$$\mathcal{C}(x_1, t_1) = \mathcal{C}(x_2, t_2) \implies x_2 = X(t_2; x_1, t_1).$$

$\supseteq$ Réciproquement, supposons que $x_2 = X(t_2; x_1, t_1)$ et montrons que $\mathcal{C}(x_1, t_1) = \mathcal{C}(x_2, t_2)$. Soit $s \in \mathbb{R}$ tel que $(X(s; x_1, t_1), s) \in \mathcal{C}(x_1, t_1)$; montrons que $(X(s; x_1, t_1), s) \in \mathcal{C}(x_2, t_2)$. La fonction $X(\cdot; x_1, t_1)$ est solution du problème de Cauchy (4.39) donc

$$\forall \sigma \in \mathbb{R} \quad X'(\sigma; x_1, t_1) = c(X(\sigma; x_1, t_1), \sigma).$$

⁽¹²⁾. On dit qu'elles forment un *fibrage* du plan.

De plus, comme par hypothèse $x_2 = X(t_2; x_1, t_1)$, on en déduit que $X(\cdot; x_1, t_1)$ est solution du problème de Cauchy (4.40). Comme le problème de Cauchy (4.40) admet une unique solution qui est $X(\cdot; x_2, t_2)$, on en déduit que

$$X(\cdot; x_1, t_1) = X(\cdot; x_2, t_2),$$

ce qui implique que $(X(s; x_1, t_1), s) \in \mathcal{C}(x_2, t_2)$ car $(X(s; x_2, t_2), s) \in \mathcal{C}(x_2, t_2)$.

En échangeant les rôles de (x_1, t_1) et (x_2, t_2) dans le raisonnement précédent, on établit que si $x_1 = X(t_1; x_2, t_2)$ alors $\mathcal{C}(x_1, t_1) = \mathcal{C}(x_2, t_2)$, ce qui achève la preuve de la première partie de la proposition.

⊇ Montrons la première assertion de la seconde partie de la proposition. Raisonnons par contraposition. Soit $t \in \mathbb{R}$ fixé; supposons qu'il existe x_1 et x_2 tel que $\mathcal{C}(x_1, t) \cap \mathcal{C}(x_2, t) \neq \emptyset$ et montrons que $x_1 = x_2$. Puisque $\mathcal{C}(x_1, t) \cap \mathcal{C}(x_2, t) \neq \emptyset$, il existe un couple (x, t) appartenant à $\mathcal{C}(x_1, t)$ et à $\mathcal{C}(x_2, t)$, autrement dit tel que

$$\exists s_1 \in \mathbb{R} \quad (x, t) = (X(s_1; x_1, t), s_1) \quad \text{et} \quad \exists s_2 \in \mathbb{R} \quad (x, t) = (X(s_2; x_2, t), s_2).$$

On a donc par égalité des ordonnées $s_1 = s_2 = t$ et $x = X(s_1; x_1, t) = X(s_2; x_2, t)$ par égalité des abscisses. Ceci implique notamment que

$$x = X(t; x_1, t) = X(t; x_2, t). \quad (4.41)$$

Par définition des courbes caractéristiques, les fonctions $X_1 : s \in \mathbb{R} \mapsto X(s; x_1, t)$ et $X_2 : s \in \mathbb{R} \mapsto X(s; x_2, t)$ sont solutions de l'équation différentielle

$$y'(s) = c(y(s), s)$$

respectivement, sous la condition $X_1(t) = x_1$ et $X_2(t) = x_2$. Ce sont les uniques solutions de ces deux problèmes de Cauchy d'après le lemme 4.3. Or, $X_1(t) = X(t; x_1, t)$ et $X_2(t) = X(t; x_2, t)$ et d'après (4.41), on a $X(t; x_1, t) = X(t; x_2, t)$. On en conclut donc que $x_1 = x_2$. Le résultat est établi.

⊇ On a bien évidemment $\bigcup_{x \in \mathbb{R}} \mathcal{C}(x, t) \subset \mathbb{R}^2$, de sorte qu'il reste à vérifier que $\mathbb{R}^2 \subset \bigcup_{x \in \mathbb{R}} \mathcal{C}(x, t)$. Pour $t \in \mathbb{R}$ fixé, considérons un point (ζ, τ) quelconque de $\mathbb{R}^2$. Soit $X(\cdot; \zeta, \tau) \in \mathcal{C}^1(\mathbb{R})$ l'unique solution du problème de Cauchy :

$$\begin{cases} X'(s; \zeta, \tau) = c(X(s; \zeta, \tau), s) & \forall s \in \mathbb{R} \\ X(\tau; \zeta, \tau) = \zeta \end{cases} \quad (4.42)$$

Désignons par x le réel $x = X(t; \zeta, \tau)$. D'après la première partie de la proposition, la relation $x = X(t; \zeta, \tau)$ implique que $\mathcal{C}(\zeta, \tau) = \mathcal{C}(x, t)$. On en déduit que le point (ζ, τ) appartient à $\mathcal{C}(x, t)$, ce qui permet de conclure que $\mathbb{R}^2 \subset \bigcup_{x \in \mathbb{R}} \mathcal{C}(x, t)$. $\square$

PROPOSITION 4.2 (Propriétés du flot)

✕ Pour tout $s \in \mathbb{R}$ fixé, la fonction $(x, t) \in \mathbb{R}^2 \mapsto X(s; x, t)$ vérifie⁽¹³⁾

$$\partial_3 X(s; x, t) + c(x, t) \partial_2 X(s; x, t) = 0 \quad \forall (x, t) \in \mathbb{R}^2. \quad (4.43)$$

✕ Pour tout $(s, t) \in \mathbb{R}^2$, l'application $x \mapsto X(s; x, t)$ est une bijection de $\mathbb{R}$ dans $\mathbb{R}$. La bijection réciproque est l'application $x \mapsto X(t; x, s)$.

Démonstration ⊇ Considérons une courbe caractéristique passant par les points (x_1, t_1) et (x_2, t_2) . Dans ce cas, l'égalité $\mathcal{C}(x_1, t_1) = \mathcal{C}(x_2, t_2)$ implique d'une part, voir (4.38), que pour tout réel s on a $X(s; x_1, t_1) = X(s; x_2, t_2)$. D'autre part, d'après la première propriété de la proposition 4.1, on a $x_2 = X(t_2; x_1, t_1)$. On en déduit que

$$\forall (t_1, t_2) \in \mathbb{R}^2 \quad \forall s \in \mathbb{R} \quad X(s; x_1, t_1) = X(s; X(t_2; x_1, t_1), t_2).$$

⁽¹³⁾. On note ∂_k la dérivée par rapport à la k -ième variable.

En dérivant cette relation par rapport à t_2 pour x_1, x_2, t_1, s fixés, on obtient

$$0 = \partial_1 X(t_2; x_1, t_1) \partial_2 X(s; \underbrace{X(t_2; x_1, t_1)}_{= x_2}, t_2) + \partial_3 X(s; \underbrace{X(t_2; x_1, t_1)}_{= x_2}, t_2). \quad (4.44)$$

Or, d'après (4.37), on a $\partial_1 X(t_2; x_1, t_1) = c(X(t_2; x_1, t_1), t_2) = c(x_2, t_2)$. La relation (4.44) donne le résultat voulu :

$$\forall (x_2, t_2, s) \in \mathbb{R}^3 \quad \partial_3 X(s; x_2, t_2) + c(x_2, t_2) \partial_2 X(s; x_2, t_2) = 0.$$

$\supseteq$ La seconde propriété découle directement de la seconde partie de la proposition 4.1. L'assertion (a) dans la proposition 4.1 traduit l'injectivité de $F : x \mapsto X(s; x, t)$ et l'assertion (b) la surjectivité de F .

Déterminons la bijection réciproque F^{-1} . Supposons que $y = F(x) = X(s; x, t)$. D'après la première partie de la proposition 4.1, nous en déduisons que $x = X(t; y, s)$. On a donc $F^{-1} : y \in \mathbb{R} \mapsto X(t; y, s)$. La proposition est démontrée. $\square$

Supposons que l'équation d'advection (4.32) avec la condition initiale (4.33) admette une solution u . Nous avons établi l'existence de courbes caractéristiques le long desquelles u est constante. Ces courbes caractéristiques, voir la définition (4.4), sont les courbes du plan

$$\mathcal{C}(x, t) = \left\{ (y, s) \in \mathbb{R} \times \mathbb{R} ; y = X(s; x, t) \right\}$$

où (x, t) désigne un point du plan et où la fonction $X(\cdot; x, t)$ est l'unique solution du problème de Cauchy (4.37).

Considérons la restriction de u à la courbe caractéristique $\mathcal{C}(x, t)$ pour (x, t) fixé. Comme u est constante selon ces courbes, pour tout $s \in \mathbb{R}$, on a

$$u(X(s; x, t), s) = u(X(0; x, t), 0) = u_0(X(0; x, t))$$

et, d'après (4.37),

$$u(X(s; x, t), s) = u(X(t; x, t), t) = u(x, t).$$

On en déduit que si l'équation d'advection (4.32) avec la condition initiale (4.33) admet une solution u , alors celle-ci est de la forme

$$u : (x, t) \in \mathbb{R} \times \mathbb{R}^+ \mapsto u_0(X(0; x, t)) \quad (4.45)$$

où $X(\cdot; x, t)$ est la solution du problème de Cauchy (4.37).

Reste à vérifier que u définie en (4.45) est bien solution de l'équation d'advection (4.32). Pour tout $(x, t) \in \mathbb{R} \times \mathbb{R}^+$, on a

$$\partial_t u(x, t) + c(x, t) \partial_x u(x, t) = (\partial_3 X(0; x, t) + c(x, t) \partial_2 X(0; x, t)) u(x, t).$$

Or, d'après la proposition 4.2, pour tout $(x, t) \in \mathbb{R}^2$ on a $\partial_3 X(0; x, t) + c(x, t) \partial_2 X(0; x, t) = 0$. On en conclut que u définie en (4.45) est effectivement solution de l'équation d'advection (4.32). On a donc démontré le théorème suivant.

THÉORÈME 4.4 Soient $u_0 \in \mathcal{C}^1(\mathbb{R})$ et c une fonction continue sur $\mathbb{R} \times \mathbb{R}$, lipschitzienne par rapport à la première variable, uniformément par rapport à la seconde, i.e.

$$\exists L \in \mathbb{R}^+ \quad \forall t \in \mathbb{R} \quad \forall (x_1, x_2) \in \mathbb{R}^2 \quad |c(x_1, t) - c(x_2, t)| \leq L |x_2 - x_1|.$$

Le problème trouver u tel que

$$\partial_t u(x, t) + c(x, t) \partial_x u(x, t) = 0 \quad \forall x \in \mathbb{R} \quad \forall t \in \mathbb{R}_+^*$$

sous la condition initiale

$$u(x, t = 0) = u_0(x) \quad \forall x \in \mathbb{R}$$

admet une unique solution qui est donnée par

$$\forall x \in \mathbb{R} \quad \forall t \in \mathbb{R}^+ \quad u(x, t) = u_0(X(0; x, t)) \quad (4.46)$$

où $X(\cdot; x, t)$ est le flot de l'équation différentielle $y'(s) = c(y(s), s)$ $\forall s \in \mathbb{R}$.

4.3.2 Cas de l'équation non homogène

On s'intéresse à présent au problème suivant : trouver $u \in \mathcal{C}^1(\mathbb{R} \times \mathbb{R}^+)$ tel que

$$\partial_t u(x, t) + c(x, t) \partial_x u(x, t) = f(x, t) \quad \forall x \in \mathbb{R} \quad \forall t \in \mathbb{R}_+^* \quad (4.47)$$

sous la condition initiale

$$u(t = 0, x) = u_0(x) \quad \forall x \in \mathbb{R} \quad (4.48)$$

où $u_0 \in \mathcal{C}^1(\mathbb{R})$ et f est une fonction continue sur $\mathbb{R} \times \mathbb{R}^+$. On suppose que la fonction c est continue sur $\mathbb{R} \times \mathbb{R}$ et lipschitzienne par rapport à la première variable, uniformément par rapport à la seconde.

Reprenons l'approche développée dans le cas de l'équation homogène et considérons une courbe caractéristique $\mathcal{C}(x, t) = \{(y, s) \in \mathbb{R} \times \mathbb{R} ; y = X(s; x, t)\}$ de l'équation (4.32) qui est l'équation homogène associée à l'équation (4.47). Désignons par $u \in \mathcal{C}^1(\mathbb{R} \times \mathbb{R}^+)$ une solution du problème (4.47)–(4.48) (on admet à ce stade du raisonnement qu'une telle solution existe) et considérons la fonction φ définie pour tout $s \in \mathbb{R}^+$ par

$$\varphi(s) = u(X(s; x, t), s). \quad (4.49)$$

Compte tenu des hypothèses, φ est dérivable sur $\mathbb{R}^+$ et pour tout $s \in \mathbb{R}^+$, on a

$$\varphi'(s) = X'(s; x, t) \partial_1 u(X(s; x, t), s) + \partial_2 u(X(s; x, t), s).$$

Comme u est solution de (4.47), on a

$$\partial_2 u(X(s; x, t), s) = f(X(s; x, t), s) - c(X(s; x, t), s) \partial_1 u(X(s; x, t), s)$$

d'où, d'après la définition du flot X

$$\varphi'(s) = \underbrace{[X'(s; x, t) - c(X(s; x, t), s)]}_{=0} \partial_1 u(X(s; x, t), s) + f(X(s; x, t), s) = f(X(s; x, t), s).$$

On en déduit que pour tout $s \in \mathbb{R}^+$, on a

$$\varphi(s) = \varphi(0) + \int_0^s f(X(\tau; x, t), \tau) \, d\tau,$$

autrement dit,

$$\begin{aligned} u(X(s; x, t), s) &= \underbrace{u(X(0; x, t), 0)}_{= u_0(X(0; x, t))} + \int_0^s f(X(\tau; x, t), \tau) \, d\tau. \end{aligned}$$

On a donc, pour tout $t \in \mathbb{R}^+$,

$$u(x, t) = u(X(t; x, t), t) = u_0(X(0; x, t)) + \int_0^t f(X(\tau; x, t), \tau) \, d\tau. \quad (4.50)$$

On a donc démontré le résultat suivant.

THÉORÈME 4.5 (Formule de Duhamel pour l'équation du transport à vitesse variable)

Si $u_0 \in \mathcal{C}^1(\mathbb{R})$ et $f \in \mathcal{C}^0(\mathbb{R} \times \mathbb{R}^+)$ alors le problème du transport à vitesse variable (4.32)–(4.33) admet une unique solution $u \in \mathcal{C}^1(\mathbb{R} \times \mathbb{R}^+)$ donnée par la formule de Duhamel

$$\forall t \in \mathbb{R}^+ \quad \forall x \in \mathbb{R} \quad u(x, t) = u_0(X(0; x, t)) + \int_0^t f(X(s; x, t), s) \, ds$$

où X désigne le flot associé à l'équation du transport (4.32).

4.4 Approximation par différences finies de l'équation d'advection

Pour introduire les schémas aux différences finies pour calculer une approximation de la solution de l'équation d'advection, nous nous restreignons par soucis de simplicité au cas où la vitesse est constante.

Nous nous plaçons dans le cas où u_0 est de classe $\mathcal{C}^1$ sur $\mathbb{R}$. On introduit une subdivision $(t_n)_{n \in \mathbb{N}}$ de l'intervalle de temps $[0, +\infty]$ de pas constant h_t ainsi qu'une subdivision $(x_j)_{j \in \mathbb{Z}}$ de l'intervalle $] -\infty, \infty[$ associée à la variable d'espace de pas constant h_x . Cette subdivision de la droite réelle est introduite pour les besoins de l'analyse mathématique des schémas numériques. D'un point de vue pratique, nous savons que sous l'hypothèse $\text{supp}(u_0) \subset [a, b]$, nous avons pour tout $t \in [0, T]$ le support de la fonction $x \mapsto u(x, t)$ qui reste inclus dans l'intervalle $[a + ct, b + ct]$ et par conséquent que pour $c > 0$ (resp. $c < 0$) il suffit de considérer une subdivision de l'intervalle $[a, b + cT]$ (resp. $[a - cT, b]$) pour être en mesure de construire une approximation de la solution du problème d'advection (4.24)–(4.25) sur l'intervalle de temps $[0, T]$.

Pour construire cette approximation, on cherche à remplacer l'équation d'advection (4.24) par une équation discrète s'appuyant sur les subdivisions venant d'être introduites où les opérateurs différentiels seront remplacés par des approximations aux différences finies. Dans cette partie, nous allons présenter les concepts clés associés à ce type d'approximation en s'appuyant sur un exemple simple : le schéma Upwind.

4.4.1 Un premier schéma : le schéma Upwind

Supposons la solution de notre problème suffisamment régulière (de classe $\mathcal{C}^1$ suffit ici) et supposons que l'on connaisse cette solution (ou une approximation de celle-ci) au temps t_n . Partons de la formule de Taylor-Young à l'ordre 1 pour $t \mapsto u(x_j, t)$ entre t_n et $t_{n+1} = t_n + h_t$:

$$u(x_j, t_n + h_t) = u(x_j, t_n) + h_t \partial_t u(x_j, t_n) + \mathcal{O}(h_t^2).$$

On en déduit l'approximation suivante de l'opérateur différentiel portant sur la dérivée en temps :

$$\partial_t u(x_j, t_n) \approx \frac{u(x_j, t_{n+1}) - u(x_j, t_n)}{h_t}. \quad (4.51)$$

Intéressons-nous à présent à l'approximation de l'opérateur différentiel portant sur la dérivée en espace. La formule de Taylor-Young à l'ordre 1 pour $x \mapsto u(x, t_n)$ entre x_j et $x_{j+1} = x_j + h_x$ indique que

$$u(x_j + h_x, t_n) = u(x_j, t_n) + h_x \partial_x u(x_j, t_n) + \mathcal{O}(h_x^2),$$




FIG. 3 Choix du type de schéma aux différences finies pour l'approximation de l'opérateur de discrétisation en espace selon le signe de la vitesse c : cas $c < 0$ à gauche et cas $c > 0$ à droite.

d'où l'approximation suivante de l'opérateur différentiel portant sur la dérivée en espace :

$$\partial_x u(x_j, t_n) \approx \frac{u(x_{j+1}, t_n) - u(x_j, t_n)}{h_x}. \quad (4.52)$$

On parle de *formule de différences finies progressive*. Notons que ce choix d'approximation ne s'impose pas de lui-même car en considérant la formule de Taylor-Young à l'ordre 1 pour $x \mapsto u(x, t_n)$ entre x_j et $x_{j-1} = x_j - h_x$, on a

$$u(x_j - h_x, t_n) = u(x_j, t_n) - h_x \partial_x u(x_j, t_n) + \mathcal{O}(h_x^2),$$

d'où une autre approximation de l'opérateur différentiel portant sur la dérivée en espace donnée par :

$$\partial_x u(x_j, t_n) \approx \frac{u(x_j, t_n) - u(x_{j-1}, t_n)}{h_x}. \quad (4.53)$$

On parle de *formule de différences finies rétrograde*. D'où la question naturelle que l'on peut se poser : laquelle des deux approximations (4.52) ou (4.53) faut-il mieux choisir ? Une réponse est fournie en considérant le fait que la solution initiale est transportée le long des caractéristiques d'équation $x = ct + cste$. Par conséquent, voir la figure 3,

- si $c > 0$ alors les droites caractéristiques sont orientées vers la droite et par conséquent il convient mieux d'approcher $\partial_x u(x_j, t_n)$ à partir de la donnée de $u(x_j, t_n)$ et $u(x_{j-1}, t_n)$, ce qui correspond à la formule (4.53) ;
- si $c < 0$ alors les droites caractéristiques sont orientées vers la gauche et par conséquent il convient mieux d'approcher $\partial_x u(x_j, t_n)$ à partir de la donnée de $u(x_j, t_n)$ et $u(x_{j+1}, t_n)$, ce qui correspond à la formule (4.52).

Pour simplifier les choses, nous ne considérerons plus que le cas où $c > 0$ par la suite. En combinant (4.51) et (4.53) avec l'équation d'advection, nous avons

$$\frac{u(x_j, t_{n+1}) - u(x_j, t_n)}{h_t} + c \frac{u(x_j, t_n) - u(x_{j-1}, t_n)}{h_x} \approx 0. \quad (4.54)$$

Nous sommes donc conduit à notre premier schéma d'approximation pour l'équation d'advection dit *schéma Upwind* :

$$\frac{u_j^{[n+1]} - u_j^{[n]}}{h_t} + c \frac{u_j^{[n]} - u_{j-1}^{[n]}}{h_x} = 0. \quad (4.55)$$

D'un point de vue calculatoire, connaissant les valeurs de $u_j^{[0]} = u(x_j, t_0) = u_0(t_j)$ pour $j \in \mathbb{Z}$, on calcule de proche en proche pour tout $n \in \mathbb{N}^*$ les valeurs approchées $u_j^{[n]}$ de $u(x_j, t_n)$ pour $j \in \mathbb{Z}$ par la relation suivante déduite de (4.55) :

$$u_j^{[n+1]} = u_j^{[n]} - c \frac{h_t}{h_x} (u_j^{[n]} - u_{j-1}^{[n]}) \quad \forall j \in \mathbb{Z}. \quad (4.56)$$




FIG. 4 Exemple de représentation graphique des valeurs de la suite $(u_j)_{j \in \mathbb{Z}}$ et de la fonction $u_{h_x}^{[n]}$ de V_{h_x} qui lui est associée.

4.4.2 Convergence d'un schéma aux différences finies

Pour un schéma aux différences finies, on s'attend au minimum à ce que la solution du problème discret approche la solution du problème initial et que l'approximation soit d'autant meilleure à mesure que h_x et h_t se rapprochent de 0. Un schéma vérifiant ces propriétés (énoncées de manière très informelles ici) est dit *convergent*.

Par commodité (cela apparaîtra clair au moment de l'étude de la stabilité d'un schéma par la méthode de Fourier–Von Neumann), nous supposons que nous cherchons une solution à l'équation d'advection définie pour $x \in \mathbb{R}$. (Dans le cas où la solution est recherchée sur un intervalle $[a, b]$, on peut toujours prolonger cette solution à $\mathbb{R}$ par la fonction nulle).

Pour procéder à l'étude mathématique d'un schéma aux différences finies comme le schéma Upwind (4.55), il est pratique d'introduire les reformulations suivantes du schéma.

Reformulations du schéma Upwind

À une suite $(u_j)_{j \in \mathbb{Z}}$, on associe une fonction réelle de la variable réelle, notée u_{h_x} et définie sur $\mathbb{R}$, en considérant le polynôme d'interpolation de degré 1 par morceaux des points (x_j, u_j) , voir la figure 4. On a donc

- $u_{h_x}|_{[x_j, x_{j+1}]} \in \mathbb{P}_1(\mathbb{R})$ pour tout $j \in \mathbb{Z}$;
- $u_{h_x}(x_j) = u_j$ pour tout $j \in \mathbb{Z}$.

On montre sans difficulté que la fonction u_{h_x} qui, en restriction à l'intervalle $[x_j, x_{j+1}]$, est polynomiale de degré 1 et vérifie $u_{h_x}(x_j) = u_j$ et $u_{h_x}(x_{j+1}) = u_{j+1}$, est donnée par

$$u_{h_x}(x) = u_j + (u_{j+1} - u_j) \frac{x - x_j}{h_x} \quad \forall x \in [x_j, x_{j+1}]. \quad (4.57)$$

On note V_{h_x} l'espace vectoriel des fonctions continues qui en restriction à chaque sous-intervalle $[x_j, x_{j+1}]$ de la subdivision $(x_j)_{j \in \mathbb{Z}}$ sont polynomiales de degré 1 :

$$V_{h_x} = \{v_{h_x} \in \mathcal{C}^0(\mathbb{R}) ; \forall j \in \mathbb{Z} \quad v_{h_x}|_{[x_j, x_{j+1}]} \in \mathbb{P}_1(\mathbb{R})\}$$

et par Π_{h_x} l'opérateur d'interpolation linéaire de $\mathcal{C}^0(\mathbb{R})$ dans V_{h_x} qui, à une fonction $u \in \mathcal{C}^0(\mathbb{R})$, associe son interpolé $u_{h_x} \in V_{h_x}$:

$$\begin{aligned} \Pi_{h_x} : u \in \mathcal{C}^0(\mathbb{R}) &\longmapsto u_{h_x} \in V_{h_x} \\ \text{ou } \forall x \in [x_j, x_{j+1}] \quad \Pi_{h_x}(u)(x) &\stackrel{\text{def}}{=} u_{h_x}(x) = u(x_j) + (u(x_{j+1}) - u(x_j)) \frac{x - x_j}{h_x} \end{aligned}$$

LEMME 4.4 Si $u \in \mathcal{C}^0(\mathbb{R}) \cap \mathbb{H}^2(\mathbb{R})$ alors on a les estimations d'interpolation suivantes :

- $\|u - \Pi_{h_x}(u)\|_{\mathbb{L}^2(\mathbb{R})} \leq h_x^2 \|u''\|_{\mathbb{L}^2(\mathbb{R})}$
- $\|\Pi_{h_x}(u)\|_{\mathbb{L}^2(\mathbb{R})} \leq 2 \|u\|_{\mathbb{L}^2(\mathbb{R})}$

Démonstration On a

$$\|u - \Pi_{h_x}(u)\|_{\mathbb{L}^2(\mathbb{R})}^2 = \int_{\mathbb{R}} |u(x) - \Pi_{h_x}(u)(x)|^2 dx = \sum_{j \in \mathbb{Z}} \int_{x_j}^{x_{j+1}} |u(x) - \Pi_{h_x}(u)(x)|^2 dx.$$

D'après (4.57), on a donc

$$\begin{aligned} \|u - \Pi_{h_x}(u)\|_{\mathbb{L}^2(\mathbb{R})}^2 &= \sum_{j \in \mathbb{Z}} \int_{x_j}^{x_{j+1}} \left| u(x) - u_j - \frac{u_{j+1} - u_j}{h_x} (x - x_j) \right|^2 dx \\ &= h_x \sum_{j \in \mathbb{Z}} \int_0^1 \left| u(x_j + th_x) - u_j - (u_{j+1} - u_j)t \right|^2 dt, \end{aligned}$$

la seconde égalité résultant du changement de variable $x = x_j + th_x$. D'une part, on a

$$u(x_j + th_x) = u(x_j) + \int_{x_j}^{x_j + th_x} u'(s) ds = u_j + \int_{x_j}^{x_j + th_x} u'(s) ds,$$

et d'autre part, on a

$$(u_{j+1} - u_j)t = \int_{x_j}^{x_j + th_x} \frac{u_{j+1} - u_j}{h_x} ds.$$

On a donc

$$\|u - \Pi_{h_x}(u)\|_{\mathbb{L}^2(\mathbb{R})}^2 = h_x \sum_{j \in \mathbb{Z}} \int_0^1 \left| \int_{x_j}^{x_j + th_x} \left(u'(s) - \frac{u_{j+1} - u_j}{h_x} \right) ds \right|^2 dt.$$

D'après la formule des accroissements finis, il existe $\zeta_j \in]x_j, x_{j+1}[$ tel que

$$u_{j+1} - u_j = u(x_{j+1}) - u(x_j) = h_x u'(\zeta_j) = u_j + h_x u'(\zeta_j)$$

de sorte que

$$\|u - \Pi_{h_x}(u)\|_{\mathbb{L}^2(\mathbb{R})}^2 = h_x \sum_{j \in \mathbb{Z}} \int_0^1 \left| \int_{x_j}^{x_j + th_x} (u'(s) - u'(\zeta_j)) ds \right|^2 dt.$$

Or, $u'(s) = u'(\zeta_j) + \int_{\zeta_j}^s u''(\eta) d\eta$ donc

$$\|u - \Pi_{h_x}(u)\|_{\mathbb{L}^2(\mathbb{R})}^2 = h_x \sum_{j \in \mathbb{Z}} \int_0^1 \left| \int_{x_j}^{x_j + th_x} \left(\int_{\zeta_j}^s u''(\eta) d\eta \right) ds \right|^2 dt.$$

Il nous reste à majorer :

$$\forall t \in [0, 1] \quad \left| \int_{x_j}^{x_j + th_x} \left(\int_{\zeta_j}^s u''(\eta) d\eta \right) ds \right| \leq \int_{x_j}^{x_{j+1}} \left| \int_{\zeta_j}^s u''(\eta) d\eta \right| ds$$

et comme $\zeta_j \in]x_j, x_{j+1}[$

$$\forall s \in]x_j, x_{j+1}[\quad \left| \int_{\zeta_j}^s u''(\eta) d\eta \right| \leq \int_{x_j}^{x_{j+1}} |u''(\eta)| d\eta \leq \sqrt{h_x} \left(\int_{x_j}^{x_{j+1}} |u''(\eta)|^2 d\eta \right)^{\frac{1}{2}}$$

la dernière majoration étant obtenue grâce à l'inégalité de Cauchy-Schwarz. On a donc

$$\begin{aligned} \|u - \Pi_{h_x}(u)\|_{\mathbb{L}^2(\mathbb{R})}^2 &\leq h_x^4 \sum_{j \in \mathbb{Z}} \int_0^1 \left(\int_{x_j}^{x_{j+1}} |u''(\eta)|^2 d\eta \right)^2 dt = h_x^4 \sum_{j \in \mathbb{Z}} \left(\int_{x_j}^{x_{j+1}} |u''(\eta)|^2 d\eta \right)^2 \\ &= h_x^4 \|u''\|_{\mathbb{L}^2(\mathbb{R})}^2. \end{aligned}$$

La première estimation est démontrée. Reste à établir la seconde estimation. On a

$$\begin{aligned}\|\Pi_{h_x}(u)\|_{\mathbb{L}^2(\mathbb{R})} &= \|\Pi_{h_x}(u) - u + u\|_{\mathbb{L}^2(\mathbb{R})} \leq \|\Pi_{h_x}(u) - u\|_{\mathbb{L}^2(\mathbb{R})} + \|u\|_{\mathbb{L}^2(\mathbb{R})} \\ &\leq h_x^2 \|u''\|_{\mathbb{L}^2(\mathbb{R})} + \|u\|_{\mathbb{L}^2(\mathbb{R})}.\end{aligned}$$

Pour h_x assez petit, on a $h_x^2 \|u''\|_{\mathbb{L}^2(\mathbb{R})} \leq \|u\|_{\mathbb{L}^2(\mathbb{R})}$, d'où le résultat. $\square$

LEMME 4.5 Soit $(u_j)_{j \in \mathbb{Z}}$ une suite réelle et u_{h_x} la fonction de V_{h_x} telle que $u_{h_x}(x_j) = u_j$ pour tout $j \in \mathbb{Z}$. On a $(u_j)_{j \in \mathbb{Z}} \in \ell^2(\mathbb{Z})$ si, et seulement si, $u_{h_x} \in \mathbb{L}^2(\mathbb{R})$ et

$$\sqrt{\frac{h_x}{3}} \|(u_j)_{j \in \mathbb{Z}}\|_{\ell^2(\mathbb{Z})} \leq \|u_{h_x}\|_{\mathbb{L}^2(\mathbb{R})} \leq \sqrt{h_x} \|(u_j)_{j \in \mathbb{Z}}\|_{\ell^2(\mathbb{Z})}.$$

Démonstration Supposons que $u_{h_x} \in \mathbb{L}^2(\mathbb{R})$. D'après la relation de Chasles, on a

$$\|u_{h_x}\|_{\mathbb{L}^2(\mathbb{R})}^2 = \int_{\mathbb{R}} u_{h_x}^2(x) \, dx = \sum_{j \in \mathbb{Z}} \int_{x_j}^{x_{j+1}} u_{h_x}^2(x) \, dx.$$

En utilisant l'expression de u_{h_x} donnée par la relation (4.57), on obtient

$$\|u_{h_x}\|_{\mathbb{L}^2(\mathbb{R})}^2 = \sum_{j \in \mathbb{Z}} \int_{x_j}^{x_{j+1}} \left(u_j + (u_{j+1} - u_j) \frac{x - x_j}{h_x} \right)^2 \, dx = \frac{h_x}{3} \sum_{j \in \mathbb{Z}} (u_{j+1}^2 + u_{j+1}u_j + u_j^2).$$

On a d'une part $u_{j+1}^2 + u_{j+1}u_j + u_j^2 \leq \frac{3}{2}(u_{j+1}^2 + u_j^2)$. (On vérifie aisément que la différence des deux membres est positives en formant un carré parfait.) Par conséquent,

$$\|u_{h_x}\|_{\mathbb{L}^2(\mathbb{R})}^2 \leq \frac{h_x}{2} \sum_{j \in \mathbb{Z}} (u_{j+1}^2 + u_j^2) = h_x \sum_{j \in \mathbb{Z}} u_j^2 = h_x \|(u_j)_{j \in \mathbb{Z}}\|_{\ell^2(\mathbb{Z})}^2. \quad (4.58a)$$

On a d'autre part, $u_{j+1}^2 + u_{j+1}u_j + u_j^2 \geq \frac{1}{2}(u_{j+1}^2 + u_j^2)$. (On vérifie aisément que la différence des deux membres est positives en formant un carré parfait.) Par conséquent,

$$\|u_{h_x}\|_{\mathbb{L}^2(\mathbb{R})}^2 \geq \frac{h_x}{6} \sum_{j \in \mathbb{Z}} (u_{j+1}^2 + u_j^2) = \frac{h_x}{3} \sum_{j \in \mathbb{Z}} u_j^2 = \frac{h_x}{3} \|(u_j)_{j \in \mathbb{Z}}\|_{\ell^2(\mathbb{Z})}^2. \quad (4.58b)$$

On a donc $(u_j)_{j \in \mathbb{Z}} \in \ell^2(\mathbb{Z})$ et l'estimation du lemme démontrée. Réciproquement, si l'on suppose que $(u_j)_{j \in \mathbb{Z}} \in \ell^2(\mathbb{Z})$ alors la relation (4.58a) montre que $u_{h_x} \in \mathbb{L}^2(\mathbb{R})$. $\square$

Désignons par $\mathcal{A}_{h_x}$ l'opérateur linéaire

$$\mathcal{A}_{h_x} : \begin{array}{ccc} V_{h_x} & \longrightarrow & V_{h_x} \\ v_{h_x} & \longmapsto & w_{h_x} \end{array} \quad \text{où} \quad w_{h_x} : x \in \mathbb{R} \mapsto c \frac{v_{h_x}(x) - v_{h_x}(x - h_x)}{h_x}.$$

Il est immédiat que si $v_{h_x} \in \mathbb{L}^2(\mathbb{R}) \cap V_{h_x}$ alors $\mathcal{A}_{h_x} v_{h_x} \in \mathbb{L}^2(\mathbb{R}) \cap V_{h_x}$.

Avec ces notations, le schéma Upwind (4.55) se réécrit : étant donnée $u_{h_x}^{[0]} = \Pi_{h_x} u_0 \in V_{h_x}$, trouver pour tout $n \in \mathbb{N}$ la fonction $u_{h_x}^{[n]} \in V_{h_x}$ vérifiant

$$\frac{u_{h_x}^{[n+1]} - u_{h_x}^{[n]}}{h_t} + \mathcal{A}_{h_x} u_{h_x}^{[n]} = 0. \quad (4.59)$$

Et on vérifie facilement par récurrence que si $u_{h_x}^{[0]} \in \mathbb{L}^2(\mathbb{R}) \cap V_{h_x}$ alors pour tout $n \in \{1, \dots, N\}$, on a $u_{h_x}^{[n]} \in \mathbb{L}^2(\mathbb{R}) \cap V_{h_x}$.




FIG. 5 Cas où la vitesse de propagation de la solution exacte est supérieure à la vitesse de propagation de la solution du schéma d'approximation. Le domaine d'influence numérique est en grisé. La partie de la solution exacte se situant en dehors du domaine d'influence numérique est approchée par 0.

Nous pouvons également ré-écrire l'expression du schéma Upwind donnée par la relation (4.56) sous la forme

$$u_{h_x}^{[n+1]} = \mathcal{S}_{h_x, h_t} u_{h_x}^{[n]} \quad (4.60)$$

où l'opérateur linéaire $\mathcal{S}_{h_x, h_t}$ sur $\mathbb{L}^2(\mathbb{R}) \cap V_{h_x}$ est défini par $\mathcal{S}_{h_x, h_t} = \text{Id} + h_t \mathcal{A}_{h_x}$.

Notation Désignons par $\mathbb{L}^\infty([0, T], \mathbb{L}^2(\mathbb{R}))$ l'espace des fonctions $u : (x, t) \in \mathbb{R} \times [0, T] \mapsto u(x, t) \in \mathbb{R}$ telles que pour tout $t \in [0, T]$ la première fonction partielle $u(\cdot, t) : x \in \mathbb{R} \mapsto u(x, t)$ soit de carré intégrable sur $\mathbb{R}$ et telles que la fonction $t \in [0, T] \mapsto \|u(\cdot, t)\|_{\mathbb{L}^2(\mathbb{R})}$ soit bornée sur $[0, T]$.

DÉFINITION 4.5 (Convergence d'un schéma)

On dit qu'un schéma aux différences finies produisant une suite $(u_{h_x}^{[n]})_{n \in \mathbb{N}}$ avec pour tout $n \in \mathbb{N}$ $u_{h_x}^{[n]} \in \mathbb{L}^2(\mathbb{R}) \cap V_{h_x}$, visant à approcher la solution u de l'équation d'advection (4.24) converge dans $\mathbb{L}^\infty([0, T], \mathbb{L}^2(\mathbb{R}))$, si pour toute donnée initiale $u_0 \in \mathbb{L}^2(\mathbb{R})$, on a

$$\lim_{(h_x, h_t) \rightarrow (0, 0)} \sup_{n \in \mathbb{N}} \|u(\cdot, t_n) - u_{h_x}^{[n]}\|_{\mathbb{L}^2(\mathbb{R})} = 0.$$

Condition nécessaire de convergence pour le schéma Upwind

Nous avons vu que sous l'hypothèse que $\text{supp}(u_0) \subset [a, b]$, nous avons le support de la fonction $x \mapsto u(x, t_n)$, où u désigne la solution de l'équation d'advection (4.24), qui est inclus dans l'intervalle $[a + ct_n, b + ct_n]$. En d'autres termes, le support de la solution de l'équation d'advection se déplace à la vitesse c .

Considérons la solution calculée à l'aide du schéma Upwind (4.56) pour $c > 0$. On établit facilement par récurrence que si la donnée initiale considérée aux nœuds de la subdivision en espace a un support $[a, b]$ correspondant aux indices $j \in \{J_1, \dots, J_2\}$ alors au temps t_n le support de la solution du schéma Upwind correspond aux indices $j \in \{J_1, \dots, J_2 + n\}$, c'est-à-dire à l'intervalle $[J_1 h_x, (J_2 + n) h_x] = [a, b + n h_x]$.

Il paraît évident que pour que l'on soit en mesure de calculer à l'aide du schéma Upwind une approximation de la solution du problème (4.24)–(4.25), il est nécessaire qu'au temps t_n pour tout $n \in \mathbb{N}^*$, on considère pour la variable d'espace un intervalle sur lequel on calcule la solution approchée qui inclut l'intervalle $[a + ct_n, b + ct_n] = [a + cn h_t, b + cn h_t]$ dans lequel est localisée la solution exacte. Cela conduit à imposer à h_t et h_x de vérifier la condition $n h_x \geq cn h_t$. On met ainsi en évidence la condition nécessaire de

convergence suivante pour le schéma Upwind :

$$\frac{h_x}{h_t} \geq c. \quad (4.61)$$

Condition suffisante de convergence d'un schéma aux différences finies pour l'équation d'advection

Établir qu'un schéma d'approximation d'une équation d'advection est convergent par une approche directe n'est en général pas une chose aisée. Toutefois, il existe deux concepts plus simples à manipuler et à établir : la *consistance* et la *stabilité*. Lorsqu'un schéma aux différences finies possède ces deux propriétés, on est assuré grâce au théorème de Lax (énoncé plus loin) que le schéma est convergent. Notons que l'on retrouve là des notions déjà introduites dans les chapitres précédents pour l'approximation par différences finies de problèmes elliptiques et paraboliques.

4.4.3 Consistance d'un schéma aux différences finies

Pour disposer d'un schéma d'approximation qui soit convergent, il est indispensable d'approcher correctement l'équation aux dérivées partielles. C'est l'idée contenue dans la notion de consistance. Notons tout de suite que la propriété de consistance est nécessaire mais n'est pas suffisante pour assurer la convergence d'un schéma. Il faut aussi contrôler le comportement de la solution approchée calculée à partir de ce schéma. Il s'agit là d'une propriété liée à la notion de stabilité du schéma.

À l'instar de ce qui est fait lors de l'étude de schémas d'approximation d'équations différentielles ordinaires et de ce qui a été fait dans les chapitres précédents pour l'étude de schémas d'approximation différences finies de problèmes elliptiques et paraboliques, nous allons introduire la notion d'erreur de consistance comme étant une mesure de la manière dont la solution exacte de l'équation d'advection, supposée suffisamment régulière, vérifie le schéma d'approximation considéré (ici le schéma Upwind). L'erreur de consistance dans le cas du schéma Upwind (4.55) est donc définie comme la suite $(\varepsilon_j^{[n]})_{j,n}$ à double indice j, n tel que

$$\varepsilon_j^{[n]} = \frac{u(x_j, t_{n+1}) - u(x_j, t_n)}{h_t} + c \frac{u(x_j, t_n) - u(x_{j-1}, t_n)}{h_x}. \quad (4.62)$$

Notons qu'en général $\varepsilon_j^{[n]} \neq 0$ (voir p. 115 la manière dont a été obtenu le schéma Upwind). Il n'y a aucune raison pour que la suite correspondant aux valeurs de la solution exacte aux nœuds (x_j, t_n) satisfasse (4.55).

DÉFINITION 4.6 (Schéma consistant)

On dit qu'un schéma aux différences finies est consistant avec l'équation d'advection (4.24) si pour toute solution u suffisamment régulière, on a

$$\lim_{(h_x, h_t) \rightarrow (0,0)} \sup_{n \in \mathbb{N}} \sup_{j \in \mathbb{Z}} |\varepsilon_j^{[n]}| = 0.$$

Intéressons-nous au schéma Upwind. Supposons que la solution de l'équation d'advection (4.24) soit de classe $\mathcal{C}^2$ en temps et en espace. Partons de la formule de Taylor-Lagrange à l'ordre 2 pour $t \mapsto u(x_j, t)$ entre t_n et $t_{n+1} = t_n + h_t$: il existe $\theta_t \in]0, 1[$ tel que

$$u(x_j, t_n + h_t) = u(x_j, t_n) + h_t \partial_t u(x_j, t_n) + \frac{h_t^2}{2} \partial_{tt}^2 u(x_j, t_n + \theta_t h_t).$$

On en déduit que

$$\frac{u(x_j, t_n + h_t) - u(x_j, t_n)}{h_t} = \partial_t u(x_j, t_n) + \frac{h_t}{2} \partial_{tt}^2 u(x_j, t_n + \theta_t h_t). \quad (4.63)$$

Considérons à présent la formule de Taylor-Lagrange à l'ordre 2 pour $x \mapsto u(x, t_n)$ entre x_{j-1} et $x_j = x_{j-1} + h_x$: il existe $\theta_x \in]0, 1[$ tel que

$$u(x_j - h_x, t_n) = u(x_j, t_n) - h_x \partial_x u(x_j, t_n) + \frac{h_x^2}{2} \partial_{xx}^2 u(x_j - \theta_x h_x, t_n).$$

On en déduit que

$$\frac{u(x_j - h_x, t_n) - u(x_j, t_n)}{h_x} = -\partial_x u(x_j, t_n) + \frac{h_x}{2} \partial_{xx}^2 u(x_j - \theta_x h_x, t_n). \quad (4.64)$$

En combinant (4.63) et (4.64), l'erreur de consistance définie en (4.62) vérifie

$$\varepsilon_j^{[n]} = \left[\partial_t u(x_j, t_n) + c \partial_x u(x_j, t_n) \right] + \left[\frac{h_t}{2} \partial_{tt}^2 u(x_j, t_n) + \theta_t h_t - c \frac{h_x}{2} \partial_{xx}^2 u(x_j - \theta_x h_x, t_n) \right]. \quad (4.65)$$

Comme u désigne la solution de l'équation d'advection (4.24), le premier terme entre crochets est nul. Supposons que la solution u admette des dérivées partielles secondes relativement aux variables x et t qui soient bornées sur $\mathbb{R} \times [0, +\infty[$ et désignons par M_1 et M_2 les réels

$$M_1 = \sup_{t \in [0, +\infty[} \sup_{x \in \mathbb{R}} |\partial_{tt}^2 u(x, t)| \quad \text{et} \quad M_2 = \sup_{t \in [0, +\infty[} \sup_{x \in \mathbb{R}} |\partial_{xx}^2 u(x, t)|,$$

Nous déduisons de (4.65) que

$$|\varepsilon_j^{[n]}| \leq \frac{1}{2} \max(M_1, c M_2) (h_t + h_x). \quad (4.66)$$

On a donc

$$\lim_{(h_x, h_t) \rightarrow (0,0)} \sup_{n \in \mathbb{N}} \sup_{j \in \mathbb{Z}} |\varepsilon_j^{[n]}| = 0,$$

et par conséquent le schéma Upwind est consistant.

DÉFINITION 4.7 (Ordre de consistance d'un schéma)

On dit qu'un schéma d'approximation de l'équation d'advection (4.24) est d'ordre de consistance p en temps et d'ordre q en espace s'il existe une constante $C > 0$, ne dépendant pas des pas de discrétisation en temps h_t et en espace h_x , tel que pour tout $n \in \mathbb{N}$ et pour tout $j \in \mathbb{Z}$, on ait

$$|\varepsilon_j^{[n]}| \leq C (h_t^p + h_x^q).$$

On déduit de la relation (4.66) que le schéma Upwind est d'ordre 1 en espace et en temps.

On déduit de la majoration (4.65) que pour tout $n \in \mathbb{N}$

$$\|(\varepsilon_j^{[n]})_{j \in \mathbb{Z}}\|_{\ell^\infty(\mathbb{Z})}^2 \stackrel{\text{def}}{=} \sup_{j \in \mathbb{Z}} |\varepsilon_j^{[n]}|^2 \leq \frac{1}{2} \max(M_1, c M_2) (h_t + h_x). \quad (4.67)$$

On déduit aussi de la majoration (4.65) que pour tout $n \in \mathbb{N}$

$$\|(\varepsilon_j^{[n]})_{j \in \mathbb{Z}}\|_{\ell^2(\mathbb{Z})}^2 \stackrel{\text{def}}{=} \sum_{j \in \mathbb{Z}} |\varepsilon_j^{[n]}|^2 \leq \sum_{j \in \mathbb{Z}} \left(\frac{h_t}{2} (m_{1,j}^{[n]})^2 + c \frac{h_x}{2} (m_{2,j}^{[n]})^2 \right) \leq \frac{h_t^2}{2} \sum_{j \in \mathbb{Z}} (m_{1,j}^{[n]})^2 + c^2 \frac{h_x^2}{2} \sum_{j \in \mathbb{Z}} (m_{2,j}^{[n]})^2$$

où, $m_{1,j}^{[n]} = \sup_{\tau \in [t_n, t_{n+1}]} |\partial_{tt}^2 u(x_j, \tau)|$ et $m_{2,j}^{[n]} = \sup_{\chi \in [x_j, x_{j+1}]} |\partial_{xx}^2 u(\chi, t_n)|$, sous réserve de convergence des deux séries $\sum_{j \in \mathbb{Z}} (m_{1,j}^{[n]})^2$ et $\sum_{j \in \mathbb{Z}} (m_{2,j}^{[n]})^2$. On a donc

$$\|(\varepsilon_j^{[n]})_{j \in \mathbb{Z}}\|_{\ell^2(\mathbb{Z})} \leq K (h_x + h_t) \quad (4.68)$$

$$\text{où } K = \sqrt{\frac{1}{2} \max \left(\sum_{j \in \mathbb{Z}} (m_{1,j}^{[n]})^2, c^2 \sum_{j \in \mathbb{Z}} (m_{2,j}^{[n]})^2 \right)}$$

Pour l'étude de la convergence du schéma Upwind, il est utile d'introduire « une version continue en espace » de l'erreur de consistance. En reprenant les notations introduites page 116, on associe à la suite $(\varepsilon_j^{[n]})_{j \in \mathbb{Z}} \in \ell^2(\mathbb{Z})$, la fonction $\varepsilon_{h_x}^{[n]} \in V_h \cap \mathbb{L}^2(\mathbb{R})$. D'après le lemme 4.5 p. 118, nous avons

$$\|\varepsilon_{h_x}^{[n]}\|_{\mathbb{L}^2(\mathbb{R})} \leq \sqrt{h_x} \|(\varepsilon_j^{[n]})_{j \in \mathbb{Z}}\|_{\ell^2(\mathbb{Z})} \leq K \sqrt{h_x} (h_x + h_t). \quad (4.69)$$

Une propriété du schéma Upwind pour l'équation homogène d'advection à vitesse constante

Intéressons-nous à l'approximation de la solution du problème $(\mathcal{P})$ défini par les équations (4.24)–(4.25) correspondant à l'équation homogène d'advection à vitesse constante par le schéma Upwind lorsque les pas des subdivisions en temps et en espace sont tels que $h_x = ch_t$.

Intéressons-nous à l'erreur de consistance du schéma Upwind donnée par la relation (4.62) dans ce cas particulier. Supposons que la solution du problème $(\mathcal{P})$ soit de classe $\mathcal{C}^\infty$ en temps et en espace. La formule de Taylor-Lagrange à l'ordre $K-1$ pour $t \mapsto u(x_j, t)$ entre t_n et $t_{n+1} = t_n + h_t$: il existe $\theta_t \in]0, 1[$ tel que

$$u(x_j, t_n + h_t) = \sum_{k=0}^{K-1} \frac{h_t^k}{k!} \partial_t^k u(x_j, t_n) + \frac{h_t^K}{K!} \partial_t^K u(x_j, t_n + \theta_t h_t).$$

On en déduit que

$$\frac{u(x_j, t_n + h_t) - u(x_j, t_n)}{h_t} = \sum_{k=1}^{K-1} \frac{h_t^{k-1}}{k!} \partial_t^k u(x_j, t_n) + \frac{h_t^{K-1}}{K!} \partial_t^K u(x_j, t_n + \theta_t h_t). \quad (4.70)$$

Considérons à présent la formule de Taylor-Lagrange à l'ordre $K-1$ pour $x \mapsto u(x, t_n)$ entre x_{j-1} et $x_j = x_{j-1} + h_x$: il existe $\theta_x \in]0, 1[$ tel que

$$u(x_j - h_x, t_n) = \sum_{k=0}^{K-1} \frac{(-h_x)^k}{k!} \partial_x^k u(x_j, t_n) + \frac{(-h_x)^K}{K!} \partial_x^K u(x_j + \theta_x h_x, t_n).$$

On en déduit que

$$\frac{u(x_j - h_x, t_n) - u(x_j, t_n)}{h_x} = \sum_{k=1}^{K-1} \frac{(-h_x)^{k-1}}{k!} \partial_x^k u(x_j, t_n) + \frac{(-h_x)^{K-1}}{K!} \partial_x^K u(x_j + \theta_x h_x, t_n). \quad (4.71)$$

En combinant (4.70) et (4.71), l'erreur de consistance définie en (4.62) vérifie

$$\varepsilon_j^{[n]} = \sum_{k=1}^{K-1} \frac{1}{k!} \left(h_t^{k-1} \partial_t^k u(x_j, t_n) + c (-h_x)^{k-1} \partial_t^x u(x_j, t_n) \right) + R_K$$

où $R_K = \frac{1}{K!} (h_t^{K-1} \partial_t^K u(x_j, t_n + \theta_t h_t) + c (-h_x)^{K-1} \partial_x^K u(x_j + \theta_x h_x, t_n))$ est le terme associé aux restes des développements de Taylor-Lagrange.

Rappelons que dans le cas où la vitesse c est constante, nous connaissons la solution exacte du problème $(\mathcal{P})$ défini par les équations (4.24)–(4.25). Cette solution est $u : (x, t) \in \mathbb{R} \times \mathbb{R}^+ \mapsto u_0(x - ct)$. On a donc pour tout $k \in \mathbb{N}$

$$\partial_x^k u(x, t) = u_0^{(k)}(x - ct) \quad \text{et} \quad \partial_t^k u(x, t) = (-c)^k u_0^{(k)}(x - ct).$$

L'erreur de consistance se ré-écrit donc sous la forme

$$\varepsilon_j^{[n]} = \sum_{k=1}^{K-1} \frac{(-1)^k}{k!} \left((-c)^k h_t^{k-1} + c (-h_x)^{k-1} \right) u_0(x_j - ct_n) + R_K$$

Dans le cas où les pas des subdivisions en temps et en espace sont tels que $h_x = ch_t$, on a $(-c)^k h_t^{k-1} + c (-h_x)^{k-1} = 0$ et par conséquent, $\varepsilon_j^{[n]} = R_K$. Dans ce cas particulier, le schéma est consistant d'ordre $K-1$ pour tout $K \in \mathbb{N}^*$. Cela signifie que l'erreur de consistance est nulle et donc que la solution u du problème $(\mathcal{P})$ satisfait exactement le schéma. En d'autres termes, le schéma Upwind fournit la solution exacte du problème $(\mathcal{P})$!

Ce résultat est de faible intérêt pratique car nous disposons de l'expression de la solution exacte du problème $(\mathcal{P})$. Cette solution est $u : (x, t) \in \mathbb{R} \times \mathbb{R}^+ \mapsto u_0(x - ct)$. Ce développement illustre toutefois le fait que l'on peut dans certains cas avoir des phénomènes de « super-convergence » de schémas numériques, au sens où le comportement de l'erreur est bien meilleur que ce qui est attendu dans le cas général.

4.4.4 Stabilité d'un schéma aux différences finies

La notion de stabilité, énoncée dans la définition suivante dans le cadre de l'espace $\mathbb{L}^2$, se généralise au cas des espaces $\mathbb{L}^p$, $p \in \mathbb{N}^* \cup \{\infty\}$. Nous nous contentons du cas particulier de l'espace $\mathbb{L}^2$ car nous disposons dans ce cas d'une méthode pratique d'analyse de la stabilité d'un schéma d'approximation de l'équation d'advection : la méthode de Fourier – Von Neumann⁽¹⁴⁾. Par ailleurs, rappelons que l'espace $\mathbb{L}^2$ joue un rôle bien particulier en physique : une solution dans $\mathbb{L}^2$ est « d'énergie finie ».

DÉFINITION 4.8 (Stabilité d'un schéma)

On dit qu'un schéma aux différences finies produisant une suite de fonctions $(u_{h_x}^{[n]})_{n=0,\dots,N}$ où $u_{h_x}^{[n]} \in \mathbb{L}^2(\mathbb{R})$ visant à approcher la solution $u \in \mathbb{L}^\infty([0, T], \mathbb{L}^2(\mathbb{R}))$ de l'équation d'advection (4.24) est $\mathbb{L}^2$ -stable si, pour toute donnée initiale $u_0 \in \mathbb{L}^2(\mathbb{R})$, il existe une constante C ne dépendant ni de h_x , ni de h_t , telle que

$$\forall n \in \mathbb{N} \quad \|u_{h_x}^{[n]}\|_{\mathbb{L}^2(\mathbb{R})} \leq C \|u_0\|_{\mathbb{L}^2(\mathbb{R})}.$$

Remarque 4.2 La condition de stabilité exprime le fait que la suite $(u_{h_x}^{[n]})_n$ de fonctions de $\mathbb{L}^2(\mathbb{R})$ est bornée puisque

$$\max_{n \in \mathbb{N}} \|u_{h_x}^{[n]}\|_{\mathbb{L}^2(\mathbb{R})} \leq C \|u_0\|_{\mathbb{L}^2(\mathbb{R})}.$$

Nous savons qu'une condition nécessaire pour qu'une suite converge est qu'elle soit bornée. Il est donc tout naturel de s'attendre à ce que la stabilité d'un schéma numérique soit une condition nécessaire pour que celui-ci converge.

Un outil : la transformée de Fourier

Il existe plusieurs définitions de la transformée de Fourier d'une fonction. Pour une fonction $f \in \mathbb{L}^1(\mathbb{R})$, nous désignons par *transformée de Fourier de f* la fonction $\hat{f}$ de $\mathcal{C}^0(\mathbb{R}) \cap \mathbb{L}^\infty(\mathbb{R})$ définie par

$$\forall \nu \in \mathbb{R} \quad \hat{f}(\nu) = \int_{-\infty}^{+\infty} f(t) e^{-2\pi i \nu t} dt. \quad (4.72)$$

L'application $\mathcal{F} : f \in \mathbb{L}^1(\mathbb{R}) \mapsto \hat{f} \in \mathcal{C}^0(\mathbb{R}) \cap \mathbb{L}^\infty(\mathbb{R})$ est injective et si $\hat{f} \in \mathbb{L}^1(\mathbb{R})$ alors on a la formule d'inversion

$$\forall t \in \mathbb{R} \quad f(t) = \int_{-\infty}^{+\infty} \hat{f}(\nu) e^{2\pi i \nu t} dt. \quad (4.73)$$

Nous ferons usage de la propriété de la transformée de Fourier vis à vis des translations. Pour $t_0 \in \mathbb{R}$ fixé, on a $\widehat{\tau_{t_0} f}(\nu) = e^{-2\pi i t_0 \nu} \hat{f}(\nu)$ pour tout $\nu \in \mathbb{R}$ où τ_{t_0} désigne l'opérateur de translation : $\tau_{t_0} f : t \in \mathbb{R} \mapsto f(t - t_0)$.

Rappelons enfin que l'on peut étendre la notion de transformée de Fourier aux fonctions de $\mathbb{L}^2(\mathbb{R})$ et que dans ce cas on a la formule de Plancherel : pour tout $f \in \mathbb{L}^2(\mathbb{R})$ on a $\hat{f} \in \mathbb{L}^2(\mathbb{R})$ et $\|\hat{f}\|_{\mathbb{L}^2(\mathbb{R})} = \|f\|_{\mathbb{L}^2(\mathbb{R})}$.

Analyse de la stabilité du schéma Upwind par la méthode de Fourier - Von Neumann

Considérons la forme (4.59) du schéma Upwind pour l'équation d'advection (4.24) : étant donnée $u_{h_x}^{[0]}$ dans $V_{h_x} \cap \mathbb{L}^2(\mathbb{R})$, pour tout $n \in \mathbb{N}$, trouver la fonction $u_{h_x}^{[n]} \in V_{h_x} \cap \mathbb{L}^2(\mathbb{R})$ vérifiant

$$\frac{u_{h_x}^{[n+1]} - u_{h_x}^{[n]}}{h_t} + \frac{c}{h_x} (u_{h_x}^{[n]} - \tau_{h_x} u_{h_x}^{[n]}) = 0. \quad (4.74)$$

⁽¹⁴⁾. John von Neumann, né Neumann János Lajos (Budapest, 1903– Washington, 1957) est un mathématicien et physicien américano-hongrois. Il a apporté d'importantes contributions tant en mécanique quantique, qu'en analyse fonctionnelle, en théorie des ensembles, en informatique, en sciences économiques ainsi que dans beaucoup d'autres domaines des mathématiques et de la physique.

Pour tout $n \in \mathbb{N}$, désignons par $\widehat{u}_{h_x}^{[n]}$ la transformée de Fourier de $u_{h_x}^{[n]}$ (bien entendu, relativement à la variable d'espace!). En considérant la transformée de Fourier des deux membres de l'équation (4.74), nous obtenons

$$\frac{\widehat{u}_{h_x}^{[n+1]} - \widehat{u}_{h_x}^{[n]}}{h_t} + \frac{c}{h_x} (\widehat{u}_{h_x}^{[n]} - \widehat{\tau_{h_x} u_{h_x}^{[n]}}) = 0.$$

On en déduit que

$$\forall \zeta \in \mathbb{R} \quad \widehat{u}_{h_x}^{n+1}(\zeta) = \left(1 - c \frac{h_t}{h_x} (1 - e^{-2\pi i h_x \zeta})\right) \widehat{u}_{h_x}^{[n]}(\zeta).$$

D'après la formule de Plancherel, on a donc

$$\|u_{h_x}^{[n+1]}\|_{\mathbb{L}^2(\mathbb{R})} = \|\widehat{u}_{h_x}^{[n+1]}\|_{\mathbb{L}^2(\mathbb{R})} \leq M \|\widehat{u}_{h_x}^{[n]}\|_{\mathbb{L}^2(\mathbb{R})} = M \|u_{h_x}^{[n]}\|_{\mathbb{L}^2(\mathbb{R})}$$

où $M = \sup_{\zeta \in \mathbb{R}} \left|1 - c \frac{h_t}{h_x} (1 - e^{-2\pi i h_x \zeta})\right|$. Il est alors immédiat que pour tout $n \in \mathbb{N}$, on a

$$\|u_{h_x}^{[n]}\|_{\mathbb{L}^2(\mathbb{R})} \leq M^n \|u_{h_x}^{[0]}\|_{\mathbb{L}^2(\mathbb{R})}. \quad (4.75)$$

D'après la définition 4.8, pour que le schéma Upwind soit stable, il faut et il suffit que $M \leq 1$.

On a $M = \sup_{\zeta \in \mathbb{R}} |S(\zeta)|$ où

$$S(\zeta) = 1 - c \frac{h_t}{h_x} (1 - e^{-2\pi i h_x \zeta}) = 1 - c \frac{h_t}{h_x} \left((1 - \cos(2\pi h_x \zeta)) + i \sin(2\pi h_x \zeta) \right).$$

Un simple calcul permet d'établir que

$$|S(\zeta)|^2 = 1 - 2c \underbrace{\frac{h_t}{h_x}}_{\geq 0} \left(1 - c \frac{h_t}{h_x}\right) \underbrace{(1 - \cos(2\pi h_x \zeta))}_{\geq 0}. \quad (4.76)$$

Dans le cas où $c > 0$, pour que $|S(\zeta)|$ soit inférieur à 1 pour tout réel ζ , il faut et il suffit que $1 - c \frac{h_t}{h_x} \geq 0$, autrement dit, que

$$c \frac{h_t}{h_x} \leq 1. \quad (4.77)$$

On en conclut que le schéma Upwind est stable à la condition, nécessaire et suffisante, que les pas de discrétisation en temps h_t et en espace h_x soient choisis de sorte de satisfaire la condition (4.77). Cette condition est appelée *condition CFL* (pour Courant-Friedrichs-Lewy).⁽¹⁵⁾ Le réel $c h_t/h_x$ est appelé *nombre CFL*.

Du point de vue pratique, la condition CFL (4.77) indique que si les variations en espace de la donnée initiale, puis de la solution, nécessitent d'avoir un pas h_x assez petit, il faut ajuster le pas de temps h_t de sorte que $h_t \leq \frac{1}{c} h_x$ sans quoi le schéma est instable.

Remarques 4.3

1. La condition CFL correspond exactement à la condition nécessaire de convergence pour le schéma Upwind donnée par la relation (4.61) qui indique que la vitesse de propagation de la solution approchée calculée par le schéma Upwind doit être supérieure à la vitesse de propagation de la solution exacte.

2. On notera que la condition CFL (4.77) que nous obtenons pour le schéma Upwind appliqué à l'équation d'advection est beaucoup moins contraignante que la condition CFL que nous avons pour l'approximation par différences finies du problème parabolique modèle où, voir le lemme 3.1 p. 85, le pas de discrétisation en temps h_t devait être ajusté au pas de discrétisation en espace h_x de sorte que $h_t \leq \frac{1}{2\alpha} h_x^2$. Dans ce

⁽¹⁵⁾. Richard Courant (1888 – 1972), Kurt Friedrichs (1901 – 1982) et Hans Lewy (1904 – 1988) sont trois mathématiciens américains nés en Allemagne. Kurt Friedrichs est le cofondateur avec Richard Courant du Courant Institute de l'université de New York, l'un des centres de recherche les plus réputés dans le monde en mathématiques appliquées.

dernier cas, la condition CFL est beaucoup plus contraignante puisque si les variations en espace de la donnée initiale, puis de la solution, nécessitent d'avoir un pas h_x assez petit, il faut ajuster le pas de temps h_t proportionnellement à h_x^2 au lieu de h_x pour le schéma Upwind appliqué à l'équation d'advection. Cela implique que h_t devient très petit et que le nombre d'étapes pour calculer la solution sur une durée T devient vite prohibitif eu égard au temps de calcul. On retiendra que contrairement au cas des problèmes paraboliques approchés par des schémas aux différences finies où le recours à des schémas implicites est parfois nécessaire pour contourner une condition CFL, les problèmes hyperboliques peuvent plus facilement être résolus en utilisant des schémas explicites avec condition CFL dans la mesure où celle-ci est nettement moins contraignante.

3. Dans le cas où $c < 0$, la relation (4.76) indique que le schéma Upwind (4.55) est instable. Cela confirme l'analyse heuristique qui a été effectuée à la section 4.4.1 p. 115 sur le choix de la formulation du schéma Upwind en fonction du signe de c .

On appelle *domaine de stabilité* du schéma Upwind, l'ensemble

$$S = \left\{ (h_x, h_t) \in \mathbb{R}_+^* \times \mathbb{R}_+^* ; c \frac{h_t}{h_x} \leq 1 \right\}.$$

Remarque 4.4 On notera que d'après la relation (4.75), on doit avoir $M \leq 1$ pour avoir la stabilité $\mathbb{L}^2$ du schéma Upwind. Toutefois, plus M sera petit et moins bien sera satisfaite au niveau de la solution approchée la propriété de conservation de la norme $\mathbb{L}^2$ de la solution exacte. La relation (4.76) indique que M sera voisin de 1 lorsque le nombre CFL $c h_t / h_x$ sera proche de 1 (ou de 0!).

4.4.5 Étude de la convergence du schéma Upwind

Nous déduisons de l'étude précédente de stabilité et de consistance du schéma Upwind le résultat de convergence suivante du schéma. Rappelons que la notion de convergence pour un schéma d'approximation a été définie à la définition 4.5 p. 119.

PROPOSITION 4.3 Si le pas h_x de la subdivision en espace et le pas h_t de la subdivision en temps vérifient la condition CFL

$$c \frac{h_t}{h_x} \leq 1$$

alors le schéma Upwind pour l'équation d'advection (4.56), dans le cas où la vitesse c est constante et positive, est convergent d'ordre 1 en temps et en espace.

Démonstration Nous cherchons à estimer $\|u(\cdot, t_n) - u_{h_x}^{[n]}\|_{\mathbb{L}^2(\mathbb{R})}$ en tout temps t_n où $u(\cdot, t_n)$ désigne la solution exacte du problème d'advection au temps t_n et $u_{h_x}^{[n]}$ la solution approchée au temps t_n obtenue par le schéma Upwind. Pour tout $n \in \mathbb{N}$ et pour tout $j \in \mathbb{Z}$, l'erreur d'approximation au noeud (x_j, t_{n+1}) s'exprime comme $e_j^{[n+1]} = u(x_j, t_{n+1}) - u_j^{n+1}$. Compte tenu du fait que u_j^{n+1} est obtenu par le schéma Upwind et que la solution exacte satisfait au schéma Upwind avec une erreur qui, par définition, est l'erreur de consistance $\varepsilon_j^{[n]}$, nous avons

$$\begin{aligned} u(x_j, t_{n+1}) &= u(x_j, t_n) - c \frac{h_t}{h_x} (u(x_j, t_n) - u(x_{j-1}, t_n)) + h_t \varepsilon_j^{[n]}, \\ u_j^{n+1} &= u_j^{[n]} - c \frac{h_t}{h_x} (u_j^{[n]} - u_{j-1}^{[n]}), \end{aligned}$$

et par conséquent

$$e_j^{[n+1]} = u(x_j, t_{n+1}) - u_j^{n+1} = \left(1 - c \frac{h_t}{h_x}\right) e_j^{[n]} + c \frac{h_t}{h_x} e_{j-1}^{[n]} + h_t \varepsilon_j^{[n]}.$$

En associant à la suite $(e_j^n)_{j \in \mathbb{Z}} \in \ell^2(\mathbb{Z})$, la fonction $e_{h_x}^{[n]} \in V_h \cap \mathbb{L}^2(\mathbb{R})$ selon le principe indiqué page 116, et à la suite $(\varepsilon_j^n)_{j \in \mathbb{Z}} \in \ell^2(\mathbb{Z})$, la fonction $\varepsilon_{h_x}^{[n]} \in V_h \cap \mathbb{L}^2(\mathbb{R})$, nous obtenons pour tout $x \in \mathbb{R}$

$$e_{h_x}^{[n+1]}(x) = \left(1 - c \frac{h_t}{h_x}\right) e_{h_x}^{[n]}(x) + c \frac{h_t}{h_x} \tau_{h_x} e_{h_x}^{[n]}(x) + h_t \varepsilon_{h_x}^{[n]}(x)$$

où τ_{h_x} désigne l'opérateur de translation introduit page 123. On en déduit que

$$\|e_{h_x}^{[n+1]}\|_{\mathbb{L}^2(\mathbb{R})} \leq \left|1 - c \frac{h_t}{h_x}\right| \|e_{h_x}^{[n]}\|_{\mathbb{L}^2(\mathbb{R})} + \left|c \frac{h_t}{h_x}\right| \|\tau_{h_x} e_{h_x}^{[n]}\|_{\mathbb{L}^2(\mathbb{R})} + h_t \|\varepsilon_{h_x}^{[n]}\|_{\mathbb{L}^2(\mathbb{R})}.$$

Notons que $\|\tau_{h_x} e_{h_x}^{[n]}\|_{\mathbb{L}^2(\mathbb{R})} = \|e_{h_x}^{[n]}\|_{\mathbb{L}^2(\mathbb{R})}$, de sorte que sous l'hypothèse CFL $c h_t/h_x \leq 1$, on obtient

$$\|e_{h_x}^{[n+1]}\|_{\mathbb{L}^2(\mathbb{R})} \leq \|e_{h_x}^{[n]}\|_{\mathbb{L}^2(\mathbb{R})} + h_t \|\varepsilon_{h_x}^{[n]}\|_{\mathbb{L}^2(\mathbb{R})}.$$

Un raisonnement par récurrence immédiat permet d'en déduire que

$$\|e_{h_x}^{[n+1]}\|_{\mathbb{L}^2(\mathbb{R})} \leq h_t \sum_{k=0}^n \|\varepsilon_{h_x}^{[k]}\|_{\mathbb{L}^2(\mathbb{R})}$$

car $\|e_{h_x}^{[0]}\|_{\mathbb{L}^2(\mathbb{R})} = 0$. D'après l'étude menée sur la consistance du schéma Upwind, on déduit de la relation (4.69), qu'il existe une constante K ne dépendant ni de h_x , ni de h_t , telle que $\|\varepsilon_{h_x}^{[k]}\|_{\mathbb{L}^2(\mathbb{R})} \leq K \sqrt{h_x} (h_x + h_t)$. On a donc

$$\|e_{h_x}^{[n+1]}\|_{\mathbb{L}^2(\mathbb{R})} \leq K \underbrace{(n+1) h_t}_{= t_{n+1} \leq T} \sqrt{h_x} (h_x + h_t).$$

Ainsi, on a établi que, pour tout $n \in \mathbb{N}$ et pour tout (h_x, h_t) tel que $ch_t/h_x \leq 1$

$$\|e_{h_x}^{[n]}\|_{\mathbb{L}^2(\mathbb{R})} \leq KT \sqrt{h_x} (h_x + h_t).$$

Pour conclure, d'après le lemme 4.5 p. 118, nous avons

$$\|(e_j^{[n]})_{j \in \mathbb{Z}}\|_{\ell^2(\mathbb{Z})} \leq \sqrt{\frac{3}{h_x}} \|e_{h_x}^{[n]}\|_{\mathbb{L}^2(\mathbb{R})} \leq \sqrt{3} KT (h_x + h_t)$$

et par conséquent

$$\lim_{(h_x, h_t) \rightarrow (0,0)} \sup_{n \in \mathbb{N}} \left(\sum_{j \in \mathbb{Z}} |u(x_j, t_n) - u_j^{[n]}|^2 \right)^{\frac{1}{2}} = 0.$$

Le schéma Upwind est donc convergent sous la condition CFL $ch_t/h_x \leq 1$, d'ordre 1 de convergence en temps et en espace. $\square$

Nous avons établi que le schéma Upwind appliqué au problème d'advection (4.24)–(4.25) pour une vitesse c positive et constante est convergent sous la condition CFL $ch_t/h_x \leq 1$ et d'ordre 1 de convergence en temps et en espace. Nous avons vu que dans le cas où la vitesse c est négative, le schéma Upwind était instable mais, comme indiqué p. 115, en considérant le schéma modifié

$$\frac{u_j^{[n+1]} - u_j^{[n]}}{h_t} + c \frac{u_{j+1}^{[n]} - u_j^{[n]}}{h_x} = 0 \quad (4.78)$$

nous obtenons un schéma similaire au schéma Upwind adapté au cas $c < 0$.

Le schéma de Lax-Friedrichs dont nous proposons l'étude dans l'exercice suivant est lui aussi convergent d'ordre 1 de convergence en temps et en espace lorsqu'il est utilisé pour le problème d'advection (4.24)–(4.25) à vitesse constante mais contrairement au schéma Upwind, il ne nécessite pas que la vitesse soit positive et peut donc être utilisé indifféremment aux cas $c > 0$ et $c < 0$.

Exercice 4.1 *Le schéma de Lax-Friedrichs* ⁽¹⁶⁾

On considère le problème d'advection (4.24)–(4.25) à vitesse constante. On introduit une discrétisation en espace de pas constant h_x dont les nœuds sont donnés par $x_j = j h_x$ pour tout $j \in \mathbb{Z}$ ainsi qu'une discrétisation en temps de pas constant h_t dont les nœuds sont donnés par $t_n = n h_t$ pour tout $n \in \mathbb{N}$. Pour tout $j \in \mathbb{Z}$, on note $u_j^{[0]} = u_0(x_j)$ et pour tous $n \in \mathbb{N}^*$ et $j \in \mathbb{Z}$, on désigne par $u_j^{[n]}$ la valeur approchée de $u(x_j, t_n)$ obtenue par le schéma numérique suivant : pour tout $n \in \mathbb{N}$

$$\frac{2u_j^{[n+1]} - u_{j+1}^{[n]} - u_{j-1}^{[n]}}{2h_t} + c \frac{u_{j+1}^{[n]} - u_{j-1}^{[n]}}{2h_x} = 0 \quad \forall j \in \mathbb{Z}. \quad (4.79)$$

1 - Montrer que si le rapport h_x/h_t reste constant quand h_x et h_t tendent vers 0 et si la solution du problème $(\mathcal{P})$ est suffisamment régulière, alors le schéma (4.79) est consistant d'ordre 1 en temps et en espace avec le problème $(\mathcal{P})$.

2 - Pour tout $n \in \mathbb{N}$, on désigne par $u_{h_x}^{[n]}$ la fonction constante par morceaux telle que $u_{h_x}^{[n]}(x) = u_j^{[n]}$ pour tout $x \in [x_j - \frac{1}{2}h_x, x_j + \frac{1}{2}h_x[$ et pour tout $j \in \mathbb{Z}$. On suppose que pour tout $n \in \mathbb{N}$, la suite $(u_j^{[n]})_{j \in \mathbb{Z}}$ appartient à $\ell^2(\mathbb{Z})$. On désigne par $\hat{u}_{h_x}^{[n]}$ la transformée de Fourier de $u_{h_x}^{[n]}$. Montrer qu'il existe une fonction $S : \mathbb{R} \rightarrow \mathbb{R}$ (dont on déterminera l'expression) telle que, pour tout $n \in \mathbb{N}$, on ait

$$\forall \zeta \in \mathbb{R} \quad \hat{u}_{h_x}^{[n+1]}(\zeta) = S(\zeta) \hat{u}_{h_x}^{[n]}(\zeta).$$

3 - En déduire une condition de stabilité dans $\ell^2(\mathbb{Z})$ du schéma numérique (4.79).

⁽¹⁶⁾. FRIEDRICHS, Kurt (1901, Kiel, Allemagne - 1982, Nouvelle-Rochelle, USA). Mathématicien germano-américain. Il émigra en 1937 aux USA pour fuir le régime Nazi. Ses travaux ont portés sur l'étude théorique et numérique des équations différentielles ordinaires et des équations aux dérivées partielles. Il fut le directeur de thèse de Peter Lax.

4.4.6 Mise en œuvre du schéma Upwind et illustration de ses propriétés

Nous considérons l'équation d'advection pour $c = 1$ considérée sur l'intervalle $[a, b] = [-10, 20]$ en espace et sur l'intervalle de temps $[0, T]$ où $T = 10$. La donnée initiale est la fonction gaussienne $u_0 : x \in \mathbb{R} \mapsto \frac{1}{\sqrt{2\pi}\sigma} \exp(-x^2/2\sigma^2)$ où $\sigma > 0$ est un paramètre que nous prenons égal à 1 dans les simulations.

Pour la discrétisation par le schéma Upwind, nous prenons $N = 250$ et un nombre CFL valant $1/2$ ce qui correspond à $J = 375$. La figure 6 donne l'évolution de la solution de l'équation d'advection en temps et en espace selon deux angles de vue différents. On observe que la solution au cours du temps correspond à une translation de la donnée initiale selon les droites caractéristiques (vers la droite ici car $c > 0$) comme attendu.




FIG. 6 Évolution de la solution de l'équation d'advection pour une CFL de 0.5 et $N = 250$ en temps et en espace.

Bien que le schéma Upwind soit stable et consistant pour les valeurs numériques considérées dans cet exemple, on peut remarquer à la figure 7 deux particularités de la solution calculée.

- Tout d'abord sur la représentation de gauche à la figure 7 où est représentée la solution exacte et la solution approchée au temps final $t = T$, on observe que la forme gaussienne de la solution se « tasse » lorsque l'on considère la solution approchée. Il s'agit là de la conséquence d'un phénomène connu sous le nom de *diffusion numérique*.
- Par ailleurs, sur la figure de droite où on a représenté l'évolution au cours du temps de la norme $\mathbb{L}^2$ de la solution approchée $u_{h_x}^{[n]}$ en la comparant à la norme de la donnée initiale, on observe qu'il n'y a pas conservation de cette norme. Au temps final T , la solution approchée a une norme $\mathbb{L}^2$ qui est 7% inférieure à la norme de la donnée initiale. Cela est gênant car le théorème 4.2 indique qu'il y a conservation de la norme $\mathbb{L}^2$ de la solution de l'équation d'advection au cours du temps.

Ces phénomènes peuvent être atténués en augmentant le nombre de points de discrétisation en espace et en temps. On a représenté à la figure 8 les mêmes courbes qu'à la figure 7 pour la même valeur CFL dans le cas où $N = 2500$ et $J = 3750$.

Comme indiqué à la remarque 4.4, pour que la solution du schéma Upwind vérifie au mieux la condition de conservation de la norme $\mathbb{L}^2$, il faut que le nombre CFL soit égal à 1. Nous avons représenté à la figure 9 les mêmes courbes qu'à la figure 7 pour $N = 200$ et un nombre CFL valant 1 (on a $J = 664$). On observe que le seul fait de changer la valeur du nombre CFL sans modifier le nombre de points de discrétisation en temps (mais en doublant le nombre de points de discrétisation en espace compte tenu de la modification de la valeur du nombre CFL) améliore grandement la qualité de la solution approchée. Notons que prendre un nombre CFL valant 1 revient à imposer que la vitesse de propagation de la solution numérique soit égale à la vitesse de propagation de la solution exacte. On peut se convaincre qu'on est dans ce cas dans une configuration optimale pour approcher correctement la solution de l'équation d'advection.




FIG. 7 Solution de l'équation d'advection pour une CFL de 0.5 et $N = 200$.




FIG. 8 Solution de l'équation d'advection pour une CFL de 0.5 et $N = 2500$.




FIG. 9 Solution de l'équation d'advection pour une CFL de 1 et $N = 250$.

Interprétation du phénomène de diffusion numérique

Pour tenter de comprendre l'origine du phénomène de diffusion observé à la figure 7, le fait qu'il diminue quand h_x diminue, voir la figure 8 et disparaît dans le cas où le nombre CFL vaut 1, voir la figure 9, nous allons ré-interpréter le schéma Upwind :

$$u_j^{[n+1]} = u_j^{[n]} - c \frac{h_t}{h_x} (u_j^{[n]} - u_{j-1}^{[n]}) \quad \forall j \in \mathbb{Z} \quad (4.80)$$

Soit u une fonction suffisamment régulière définie sur $\mathbb{R} \times [0, T]$ satisfaisant une certaine équation aux dérivées partielles dont (4.80) constitue un schéma d'approximation d'ordre 2 en temps et en espace. Le terme u_j^{n+1} est l'approximation de $u(x_j, t_{n+1})$ et

$$u(x_j, t_{n+1}) = u(x_j, t_n) + h_t \partial_t u(x_j, t_n) + \frac{1}{2} h_t^2 \partial_{tt}^2 u(x_j, t_n) + \mathcal{O}(h_t^3).$$

De même, le terme $u_j^n - u_{j-1}^{[n]}$ est l'approximation de $u(x_j, t_n) - u(x_{j-1}, t_n)$ et

$$u(x_j, t_n) - u(x_{j-1}, t_n) = h_x \partial_x u(x_j, t_n) - \frac{1}{2} h_x^2 \partial_{xx}^2 u(x_j, t_n) + \mathcal{O}(h_x^3).$$

On en déduit que (4.80) constitue un schéma d'approximation de l'équation aux dérivées partielles

$$\begin{aligned} u(x, t) + h_t \partial_t u(x, t) + \frac{1}{2} h_t^2 \partial_{tt}^2 u(x, t) + \mathcal{O}(h_t^3) = & u(x, t) \\ & - c \frac{h_t}{h_x} \left(h_x \partial_x u(x, t) - \frac{1}{2} h_x^2 \partial_{xx}^2 u(x, t) + \mathcal{O}(h_x^3) \right). \end{aligned}$$

En supposant que $h_x = \mathcal{O}(h_t)$, cette équation se ré-écrit

$$\partial_t u(x, t) + c \partial_x u(x, t) = -\frac{1}{2} h_t \partial_{tt}^2 u(x, t) + \frac{1}{2} c h_x \partial_{xx}^2 u(x, t) + \mathcal{O}(h_t^2). \quad (4.81)$$

On a donc

$$\partial_t u(x, t) + c \partial_x u(x, t) = \mathcal{O}(h_t) \quad (4.82)$$

et en re-dérivant cette expression par rapport à la variable t , il vient

$$\begin{aligned} \partial_{tt}^2 u(x, t) &= -c \partial_{tx}^2 u(x, t) + \mathcal{O}(h_t) = -c \partial_x (\partial_t u(x, t)) + \mathcal{O}(h_t) \\ &= c^2 \partial_{xx}^2 u(x, t) + \mathcal{O}(h_t), \end{aligned}$$

la dernière expression ayant été obtenue en exploitant à nouveau la relation (4.82). On peut donc ré-écrire (4.81) sous la forme

$$\partial_t u(x, t) + c \partial_x u(x, t) = \frac{1}{2} c h_x \left(1 - c \frac{h_t}{h_x} \right) \partial_{xx}^2 u(x, t) + \mathcal{O}(h_t^2). \quad (4.83)$$

Finalement, le schéma Upwind (4.80) s'interprète aussi comme étant le schéma d'approximation d'une équation d'advection-diffusion de la forme (4.22) avec une vitesse constante et un coefficient de diffusion

$$\kappa = \frac{1}{2} c h_x \left(1 - c \frac{h_t}{h_x} \right). \quad (4.84)$$

Ici, le coefficient de diffusion κ n'est pas d'origine physique mais est purement d'origine numérique. C'est la raison pour laquelle le phénomène d'aplatissement de la solution calculée observé à la figure 7 est qualifié de *diffusion numérique*. Remarquons que le fait que ce phénomène de diffusion numérique diminue quand h_x diminue comme observé à la figure 8 s'interprète très bien à partir de la formule (4.84) : lorsque h_x diminue, le coefficient de diffusion numérique κ diminue d'autant. On comprend aussi pourquoi ce phénomène n'était plus observé à la figure 9 correspondant à une situation où le nombre CFL vaut 1 : lorsque le nombre CFL vaut 1, le coefficient de diffusion numérique est nul d'après la formule (4.84).




FIG. 10 Solution de l'équation d'advection pour une CFL de 1.08 et $N = 250$ correspondant à un schéma instable.

Importance de la condition CFL

Pour conclure, notons que la condition de stabilité du schéma Upwind exprimée sous la forme d'un nombre CFL inférieur à 1 est assez stricte. Nous avons représenté la figure 10 la solution de l'équation d'advection pour une CFL de 1.08 et $N = 250$ ce qui correspond à une situation où le schéma Upwind est instable. On a restreint la simulation à l'intervalle $[0, T]$ avec $T = 10$. La solution du schéma d'approximation n'est pas bornée uniformément en temps et on observe bien la tendance de la solution à « exploser » lorsque le temps augmente.

4.5 Autres schémas d'approximation de l'équation d'advection

4.5.1 Un schéma d'ordre 2 en espace

Nous avons établi que le schéma Upwind était d'ordre 1 en temps et en espace. Dans le cas où $c > 0$, il a été obtenu en approchant la dérivée partielle en espace par une différence finie progressive correspondant à la formule d'approximation (4.53). On peut penser améliorer la précision du schéma, à coût constant, en approchant la dérivée partielle en espace par une différence finie « centrée en espace » correspondant à l'approximation

$$\partial_x u(x_j, t_n) \approx \frac{u(x_{j+1}, t_n) - u(x_{j-1}, t_n)}{2h_x}. \quad (4.85)$$

Reprenant les notations introduites dans le cas du schéma Upwind, nous obtenons un nouveau schéma qui s'écrit sous la forme

$$u_j^{[n+1]} = u_j^{[n]} - c \frac{h_t}{2h_x} (u_{j+1}^{[n]} - u_{j-1}^{[n]}) \quad \forall j \in \mathbb{Z} \quad (4.86)$$

que l'on pourra comparer à la formulation correspondante (4.86) du schéma Upwind pour constater que le coût en termes de calculs à effectuer pour ce nouveau schéma est identique à celui du schéma Upwind.

Étude de la consistance du schéma

Nous reprenons les notations introduites à la section 4.4.3 pour l'étude du schéma Upwind. Le schéma (4.86) se ré-écrit

$$\frac{u_i^{[n+1]} - u_i^{[n]}}{h_t} + c \frac{u_{i+1}^{[n]} - u_{i-1}^{[n]}}{2h_x} = 0 \quad \forall i \in \mathbb{Z}, \forall n \in \mathbb{N}.$$

et l'erreur de consistance ε_j^n au nœud (x_j, t_n) pour tous $j \in \mathbb{Z}$ et $n \in \mathbb{N}$ est donnée par

$$\varepsilon_j^{[n]} = \frac{u(x_j, t_{n+1}) - u(x_j, t_n)}{h_t} + c \frac{u(x_{j+1}, t_n) - u(x_{j-1}, t_n)}{2h_x}. \quad (4.87)$$

Supposons que la solution de l'équation d'advection soit de classe $\mathcal{C}^2$ en temps et de classe $\mathcal{C}^3$ en espace. Partons de la formule de Taylor-Lagrange à l'ordre 2 pour $t \mapsto u(x_j, t)$ entre t_n et $t_{n+1} = t_n + h_t$: il existe $\theta_t \in]0, 1[$ tel que

$$u(x_j, t_n + h_t) = u(x_j, t_n) + h_t \partial_t u(x_j, t_n) + \frac{h_t^2}{2} \partial_{tt}^2 u(x_j, t_n + \theta_t h_t).$$

On en déduit que

$$\frac{u(x_j, t_n + h_t) - u(x_j, t_n)}{h_t} = \partial_t u(x_j, t_n) + \frac{h_t}{2} \partial_{tt}^2 u(x_j, t_n + \theta_t h_t). \quad (4.88)$$

Considérons à présent la formule de Taylor-Lagrange à l'ordre 2 pour $x \mapsto u(x, t_n)$ entre x_{j-1} et $x_j = x_{j-1} + h_x$: il existe $\theta_x^{(1)} \in]0, 1[$ tel que

$$u(x_j - h_x, t_n) = u(x_j, t_n) - h_x \partial_x u(x_j, t_n) + \frac{h_x^2}{2} \partial_{xx}^2 u(x_j, t_n) + \frac{h_x^3}{6} \partial_{xxx}^3 u(x_j - \theta_x^{(1)} h_x, t_n), \quad (4.89)$$

puis la formule de Taylor-Lagrange à l'ordre 3 pour $x \mapsto u(x, t_n)$ entre x_j et $x_{j+1} = x_j + h_x$: il existe $\theta_x^{(2)} \in]0, 1[$ tel que

$$u(x_j + h_x, t_n) = u(x_j, t_n) + h_x \partial_x u(x_j, t_n) + \frac{h_x^2}{2} \partial_{xx}^2 u(x_j, t_n) + \frac{h_x^3}{6} \partial_{xxx}^3 u(x_j + \theta_x^{(2)} h_x, t_n). \quad (4.90)$$

Par différence entre (4.89) et (4.90), on en déduit que

$$\begin{aligned} \frac{u(x_j + h_x, t_n) - u(x_j - h_x, t_n)}{2h_x} &= \partial_x u(x_j, t_n) \\ &+ \frac{h_x^2}{12} \left(\partial_{xxx}^3 u(x_j - \theta_x^{(1)} h_x, t_n) + \partial_{xxx}^3 u(x_j + \theta_x^{(2)} h_x, t_n) \right). \end{aligned}$$

D'après le théorème des valeurs intermédiaires, il existe $\theta \in]-1, 1[$ tel que

$$\frac{u(x_j + h_x, t_n) - u(x_j - h_x, t_n)}{2h_x} = \partial_x u(x_j, t_n) + \frac{h_x^2}{6} \partial_{xxx}^3 u(x_j + \theta_x h_x, t_n). \quad (4.91)$$

En combinant (4.88) et (4.91), l'erreur de consistance définie en (4.87) vérifie

$$\varepsilon_j^{[n]} = \left[\partial_t u(x_j, t_n) + c \partial_x u(x_j, t_n) \right] + \left[\frac{h_t}{2} \partial_{tt}^2 u(x_j, t_n + \theta_t h_t) + c \frac{h_x^2}{6} \partial_{xxx}^3 u(x_j + \theta_x h_x, t_n) \right].$$

Comme u désigne la solution de l'équation d'advection (4.24), le premier terme entre crochets est nul. Supposons que la solution u admette une dérivée partielle seconde relativement à la variable t qui soit bornée sur $\mathbb{R} \times [0, +\infty[$ et une dérivée troisième relativement à la variable x qui soit bornée sur $\mathbb{R} \times [0, +\infty[$ et désignons par M_1 et M_2 les réels

$$M_1 = \sup_{t \in [0, T]} \sup_{x \in \mathbb{R}} |\partial_{tt}^2 u(x, t)|, \quad \text{et} \quad M_2 = \sup_{t \in [0, T]} \sup_{x \in \mathbb{R}} |\partial_{xxx}^3 u(x, t)|.$$

Nous obtenons

$$|\varepsilon_j^{[n]}| \leq \frac{1}{2} \max(M_1, c M_2) (h_t + h_x^2) \quad (4.92)$$

et

$$\lim_{(h_x, h_t) \rightarrow (0, 0)} \sup_{n \in \{0, \dots, N\}} \sup_{j \in \mathbb{Z}} |\varepsilon_j^{[n]}| = 0,$$

Le schéma centré en espace est donc consistant, d'ordre 1 en temps et d'ordre 2 en espace.

Ainsi, sans coût supplémentaire par rapport au schéma Upwind, nous disposons d'un schéma plus précis : il est d'ordre 2 en espace au lieu d'être d'ordre 1.

Étude de la stabilité du schéma

Nous pouvons écrire le schéma centré en espace sous une forme analogue à celle introduite en (4.74) pour le schéma Upwind : étant donnée $u_{h_x}^{[0]} \in V_{h_x} \cap \mathbb{L}^2(\mathbb{R})$, trouver pour tout $n \in \mathbb{N}$ la fonction $u_{h_x}^{[n]} \in V_{h_x} \cap \mathbb{L}^2(\mathbb{R})$ vérifiant

$$\frac{u_{h_x}^{[n+1]} - u_{h_x}^{[n]}}{h_t} + \mathcal{A}_{h_x} \cdot u_{h_x}^{[n]} = 0 \quad (4.93)$$

où cette fois-ci l'opérateur linéaire $\mathcal{A}_{h_x}$ sur $\mathbb{L}^2(\mathbb{R}) \cap V_{h_x}$ est défini pour tout $u_{h_x}^{[n]} \in V_{h_x} \cap \mathbb{L}^2(\mathbb{R})$ par

$$\mathcal{A}_{h_x} \cdot u_{h_x}^{[n]} : x \in \mathbb{R} \mapsto \frac{1}{h_x} (u_{h_x}^{[n]}(x + h_x) - u_{h_x}^{[n]}(x - h_x)).$$

Pour tout $n = 0, \dots, N$, désignons par $\widehat{u}_{h_x}^{[n]}$ la transformée de Fourier de $u_{h_x}^{[n]}$ relativement à la variable d'espace. En considérant la transformée de Fourier des deux membres de l'équation (4.74), nous obtenons

$$\frac{\widehat{u}_{h_x}^{[n+1]} - \widehat{u}_{h_x}^{[n]}}{h_t} + \frac{c}{2h_x} (\widehat{\tau_{-h_x} u_{h_x}^{[n]}} - \widehat{\tau_{h_x} u_{h_x}^{[n]}}) = 0.$$

On en déduit que

$$\begin{aligned} \forall \zeta \in \mathbb{R} \quad \widehat{u}_{h_x}^{[n+1]}(\zeta) &= \left(1 - c \frac{h_t}{2h_x} (e^{2\pi i h_x \zeta} - e^{-2\pi i h_x \zeta}) \right) \widehat{u}_{h_x}^{[n]}(\zeta) \\ &= \left(1 + i c \frac{h_t}{h_x} \sin(2\pi h_x \zeta) \right) \widehat{u}_{h_x}^{[n]}(\zeta) \end{aligned}$$

En notant $\alpha(\zeta) = 1 + i c \frac{h_t}{h_x} \sin(2\pi h_x \zeta)$ le coefficient d'amplification, on obtient par une récurrence immédiate, pour tout $n \in \mathbb{N}^*$,

$$\forall \zeta \in \mathbb{R} \quad \widehat{u}_{h_x}^{[n]}(\zeta) = \alpha(\zeta)^n \widehat{u}_{h_x}^{[0]}(\zeta)$$

D'après la formule de Plancherel, on a $\|u_{h_x}^{[n]}\|_{\mathbb{L}^2(\mathbb{R})}^2 = \|\widehat{u}_{h_x}^{[n]}\|_{\mathbb{L}^2(\mathbb{R})}^2$ et par conséquent

$$\|u_{h_x}^{[n]}\|_{\mathbb{L}^2(\mathbb{R})}^2 = \int_{\mathbb{R}} |\alpha(\zeta)|^{2n} |\widehat{u}_{h_x}^{[0]}(\zeta)|^2 d\zeta. \quad (4.94)$$

Considérons la fonction $u_0 : x \in \mathbb{R} \mapsto \text{sinc}(ax)$ où sinc désigne la fonction sinus cardinal.⁽¹⁷⁾ On a⁽¹⁸⁾ $\widehat{u}_0 : \zeta \in \mathbb{R} \mapsto \frac{1}{|a|} \Pi(\frac{\zeta}{a})$ où Π désigne la fonction porte qui coïncide avec l'indicatrice de l'intervalle $[-\frac{1}{2}, \frac{1}{2}]$. Pour cette donnée initiale u_0 , la relation (4.94) s'écrit donc :

$$\|u_{h_x}^{[n]}\|_{\mathbb{L}^2(\mathbb{R})}^2 = \int_{-a/2}^{a/2} |\alpha(\zeta)|^{2n} d\zeta = \int_{-a/2}^{a/2} (1 + \kappa^2 \sin^2(2\pi h_x \zeta))^n d\zeta$$

où on a posé $\kappa = c \frac{h_t}{h_x}$. En faisant le choix de prendre $a = 1/h_x$, on obtient par le changement de variables $y = 2\pi h_x \zeta$,

$$\|u_{h_x}^{[n]}\|_{\mathbb{L}^2(\mathbb{R})}^2 = \frac{1}{2\pi h_x} \int_{-\pi}^{\pi} (1 + \kappa^2 \sin^2(y))^n d\zeta.$$

L'intégrant étant positif, on a

$$\|u_{h_x}^{[n]}\|_{\mathbb{L}^2(\mathbb{R})}^2 \geq \frac{1}{2\pi h_x} \int_{\pi/4}^{3\pi/4} (1 + \kappa^2 \sin^2(y))^n d\zeta \geq \frac{1}{8h_x} (1 + \frac{1}{2}\kappa^2)^n$$

car, sur l'intervalle $[\frac{\pi}{4}, \frac{3\pi}{4}]$, la fonction sinus est minorée par $\frac{1}{\sqrt{2}}$. Comme $\kappa > 0$, on a

$$\lim_{n \rightarrow +\infty} \frac{1}{8h_x} (1 + \frac{1}{2}\kappa^2)^n = +\infty$$

et on en conclut que $\lim_{n \rightarrow +\infty} \|u_{h_x}^{[n]}\|_{\mathbb{L}^2(\mathbb{R})}^2 = +\infty$. D'après la définition 4.8, cela indique que le schéma centré en espace est inconditionnellement instable.

Remarque 4.5 Il est pas inutile de constater que bien que le schéma centré en espace soit « plus précis » que le schéma Upwind pour un coût identique, il n'est d'aucune utilité pratique puisqu'il est instable.

4.5.2 Le schéma de Lax-Wendroff

Le schéma de Lax-Wendroff est très utilisé en pratique car il offre un bon compromis entre coût et précision des calculs. Dans le but de construire le schéma de Lax-Wendroff, considérons une solution u de l'équation d'advection (4.24) qui soit de classe $\mathcal{C}^3$ en temps et en espace. Sous cette hypothèse, considérons la formule de Taylor-Young appliquée à u entre $x_j - h_x$ et x_j d'une part et appliquée à u entre x_j et $x_j + h_x$ d'autre part pour un temps t_n donné. On a

$$\begin{aligned} u(t_n, x_j + h_x) &= u(t_n, x_j) + h_x \partial_x u(t_n, x_j) + \frac{1}{2} h_x^2 \partial_{xx}^2 u(t_n, x_j) + \frac{1}{6} h_x^3 \partial_{xxx}^3 u(t_n, x_j) + \mathcal{O}(h_x^4), \\ u(t_n, x_j - h_x) &= u(t_n, x_j) - h_x \partial_x u(t_n, x_j) + \frac{1}{2} h_x^2 \partial_{xx}^2 u(t_n, x_j) - \frac{1}{6} h_x^3 \partial_{xxx}^3 u(t_n, x_j) + \mathcal{O}(h_x^4). \end{aligned}$$

En soustrayant ces deux expressions, nous obtenons

$$\partial_x u(t_n, x_j) = \frac{u(t_n, x_{j+1}) - u(t_n, x_{j-1}))}{2h_x} + \mathcal{O}(h_x^2). \quad (4.95)$$

Et en les additionnant, nous obtenons

$$\partial_{xx}^2 u(t_n, x_j) = \frac{u(t_n, x_{j+1}) - 2u(t_n, x_j) + u(t_n, x_{j-1}))}{h_x^2} + \mathcal{O}(h_x^3). \quad (4.96)$$

(17). La fonction sinc est définie par $\text{sinc}(x) = \frac{\sin(x)}{x}$.

(18). Voir par exemple [15].

Considérons à présent la formule de Taylor-Young appliquée à u entre t_n et $t_{n+1} = t_n + h_t$ pour une valeur de la variable d'espace x_j fixée. On a

$$u(t_{n+1}, x_j) = u(t_n, x_j) + h_t \partial_t u(t_n, x_j) + \frac{1}{2} h_t^2 \partial_{tt}^2 u(t_n, x_j) + \mathcal{O}(h_t^3). \quad (4.97)$$

Comme u est solution de l'équation d'advection (4.24), on a aussi $\partial_t u(t_n, x_j) = -c \partial_x u(t_n, x_j)$, d'où on déduit que

$$\partial_{tt}^2 u(t_n, x_j) = c^2 \partial_{xx}^2 u(t_n, x_j). \quad (4.98)$$

En substituant (4.95), (4.96) et (4.98) dans (4.97), on obtient

$$\begin{aligned} u(t_{n+1}, x_j) &\approx u(t_n, x_j) - \frac{\alpha}{2} (u(t_n, x_{j+1}) - u(t_n, x_{j-1})) \\ &\quad + \frac{\alpha^2}{2} (u(t_n, x_{j+1}) - 2u(t_n, x_j) + u(t_n, x_{j-1})) \end{aligned} \quad (4.99)$$

où on a posé $\alpha = c h_t / h_x$. L'expression du schéma de Lax-Wendroff est la suivante : connaissant les valeurs de $u_j^{[0]} = u(x_j, 0) = u_0(x_j)$ pour $j \in \mathbb{Z}$, calculer de proche en proche pour tout $n \in \mathbb{N}$ les valeurs approchées $u_j^{[n]}$ de $u(x_j, t_n)$ pour $j \in \mathbb{Z}$ par la relation

$$u_j^{[n+1]} = u_j^{[n]} - \frac{\alpha}{2} (u_{j+1}^{[n]} - u_{j-1}^{[n]}) + \frac{\alpha^2}{2} (u_{j+1}^{[n]} - 2u_j^{[n]} + u_{j-1}^{[n]}). \quad (4.100)$$

On démontre que le schéma de Lax-Wendroff est consistant, d'ordre 2 en temps et en espace. On démontre aussi qu'il est stable sous la condition CFL $|c| h_t / h_x \leq 1$.

4.5.3 Le schéma saute-mouton (ou leapfrog)

Le schéma « saute-mouton » est défini par :

$$u_i^{[n+1]} = u_i^{[n-1]} - c \frac{h_t}{h_x} (u_{i+1}^{[n]} - u_{i-1}^{[n]}) \quad \forall i \in \mathbb{Z}, \forall n \in \mathbb{N}. \quad (4.101)$$

La particularité du schéma « saute-mouton » est qu'il s'agit d'un schéma à deux niveaux : le calcul de la solution approchée au temps t_{n+1} nécessite d'exploiter la solution au temps t_n et t_{n-1} . Cela implique que le schéma « saute-mouton » doit être initialisé par le calcul d'une solution approchée aux temps t_0 et t_1 . Cela ne pose pas de difficulté pour le temps $t_0 = 0$ puisque l'on dispose de la condition de Cauchy. Il faut par contre être vigilant pour initialiser le schéma au temps t_1 par une approximation qui soit d'ordre suffisant pour ne pas pénaliser l'ordre de convergence du schéma (d'ordre 2 en temps et en espace comme démontré ci-dessous).

Montrons que ce schéma est consistant. Il se ré-écrit

$$\frac{u_i^{[n+1]} - u_i^{[n-1]}}{2h_t} + c \frac{u_{i+1}^{[n]} - u_{i-1}^{[n]}}{2h_x} = 0 \quad \forall i \in \mathbb{Z}, \forall n \in \mathbb{N}, \quad (4.102)$$

ce qui permet de définir l'erreur de consistance $\varepsilon_j^{[n]}$ au nœud (x_j, t_n) pour tous $j \in \mathbb{Z}$ et $n \in \mathbb{N}$ par

$$\varepsilon_j^{[n]} = \frac{u(x_j, t_{n+1}) - u(x_j, t_{n-1})}{2h_t} + c \frac{u(x_{j+1}, t_n) - u(x_{j-1}, t_n)}{2h_x}. \quad (4.103)$$

Supposons que la solution du problème $(\mathcal{P})$ soit de classe $\mathcal{C}^3$ en temps et en espace. Partons de la formule de Taylor-Lagrange à l'ordre 2 pour $t \mapsto u(x_j, t)$ entre t_n et $t_{n+1} = t_n + h_t$: il existe $\theta^{(1)} \in]0, 1[$ tel que

$$u(x_j, t_n + h_t) = u(x_j, t_n) + h_t \partial_t u(x_j, t_n) + \frac{h_t^2}{2} \partial_{tt}^2 u(x_j, t_n) + \frac{h_t^3}{6} \partial_{ttt}^3 u(x_j, t_n + \theta^{(1)} h_t). \quad (4.104)$$

Considérons ensuite la formule de Taylor-Lagrange à l'ordre 2 pour $t \mapsto u(x_j, t)$ entre $t_{n-1} = t_n - h_t$ et t_n : il existe $\theta^{(2)} \in]-1, 0[$ tel que

$$u(x_j, t_n - h_t) = u(x_j, t_n) - h_t \partial_t u(x_j, t_n) + \frac{h_t^2}{2} \partial_t^2 u(x_j, t_n) - \frac{h_t^3}{6} \partial_t^3 u(x_j, t_n + \theta^{(2)} h_t). \quad (4.105)$$

Par différence entre (4.104) et (4.105), on en déduit que

$$\frac{u(x_j, t_n + h_t) - u(x_j, t_n - h_t)}{2h_t} = \partial_t u(x_j, t_n) + \frac{h_t^2}{12} \left(\partial_t^3 u(x_j, t_n + \theta^{(1)} h_t) + \partial_t^3 u(x_j, t_n + \theta^{(2)} h_t) \right). \quad (4.106)$$

Considérons à présent la formule de Taylor-Lagrange à l'ordre 2 pour $x \mapsto u(x, t_n)$ entre x_{j-1} et $x_j = x_{j-1} + h_x$: il existe $\theta^{(3)} \in]-1, 0[$ tel que

$$u(x_j - h_x, t_n) = u(x_j, t_n) - h_x \partial_x u(x_j, t_n) + \frac{h_x^2}{2} \partial_x^2 u(x_j, t_n) + \frac{h_x^3}{6} \partial_x^3 u(x_j + \theta^{(3)} h_x, t_n), \quad (4.107)$$

puis la formule de Taylor-Lagrange à l'ordre 3 pour $x \mapsto u(x, t_n)$ entre x_j et $x_{j+1} = x_j + h_x$: il existe $\theta^{(4)} \in]0, 1[$ tel que

$$u(x_j + h_x, t_n) = u(x_j, t_n) + h_x \partial_x u(x_j, t_n) + \frac{h_x^2}{2} \partial_x^2 u(x_j, t_n) + \frac{h_x^3}{6} \partial_x^3 u(x_j + \theta^{(4)} h_x, t_n). \quad (4.108)$$

Par différence entre (4.107) et (4.108), on en déduit que

$$\frac{u(x_j + h_x, t_n) - u(x_j - h_x, t_n)}{2h_x} = \partial_x u(x_j, t_n) + \frac{h_x^2}{12} \left(\partial_x^3 u(x_j + \theta^{(3)} h_x, t_n) + \partial_x^3 u(x_j + \theta^{(4)} h_x, t_n) \right). \quad (4.109)$$

En combinant (4.106) et (4.109), l'erreur de consistance définie en (4.103) vérifie

$$\begin{aligned} \varepsilon_j^{[n]} &= \left[\partial_t u(x_j, t_n) + c \partial_x u(x_j, t_n) \right] + \frac{h_t^2}{12} \left(\partial_t^3 u(x_j, t_n + \theta^{(1)} h_t) + \partial_t^3 u(x_j, t_n + \theta^{(2)} h_t) \right) \\ &\quad + \frac{h_x^2}{12} \left(\partial_x^3 u(x_j + \theta^{(3)} h_x, t_n) + \partial_x^3 u(x_j + \theta^{(4)} h_x, t_n) \right). \end{aligned}$$

Comme u désigne la solution du problème d'advection (4.24)–(4.25), le premier terme entre crochets est nul. En supposant que la solution u admet une dérivée partielle seconde en temps et une dérivée partielle troisième bornées sur $\mathbb{R} \times \mathbb{R}^+$ et en notant

$$M_1 = \sup_{t \in \mathbb{R}^+} \sup_{x \in \mathbb{R}} |\partial_t^2 u(x, t)|, \quad \text{et} \quad M_2 = \sup_{t \in \mathbb{R}^+} \sup_{x \in \mathbb{R}} |\partial_x^3 u(x, t)|,$$

il vient

$$|\varepsilon_j^{[n]}| \leq \frac{1}{6} \max(M_1, c M_2) (h_t^2 + h_x^2). \quad (4.110)$$

On en déduit que

$$\lim_{(h_x, h_t) \rightarrow (0,0)} \sup_{n \in \mathbb{N}} \sup_{j \in \mathbb{Z}} |\varepsilon_j^{[n]}| = 0,$$

autrement dit, que le schéma centré en espace est consistant. De plus, il est d'ordre 2 en temps et d'ordre 2 en espace.

Intéressons-nous à présent à la stabilité du schéma saute-mouton. La relation (4.101) définissant le schéma implique que pour tout $x \in \mathbb{R}$ et pour tout $n \in \mathbb{N}$, on a

$$u^{[n+1]}(x) = u^{[n-1]}(x) - c \frac{h_t}{h_x} (u^{[n]}(x + h_x) - u^{[n]}(x - h_x))$$

que l'on peut ré-écrire en introduisant l'opérateur de translation τ_{t_0} tel que $\tau_{t_0} f : t \in \mathbb{R} \mapsto f(t - t_0)$, sous la forme

$$u^{[n+1]}(x) = u^{[n-1]}(x) - c \frac{h_t}{h_x} (\tau_{-h_x} u^{[n]}(x) - \tau_{h_x} u^{[n]}(x)).$$

La transformée de Fourier étant un opérateur linéaire, pour tout $n \in \mathbb{N}$, on a

$$\forall \zeta \in \mathbb{R} \quad \widehat{u}^{[n+1]}(\zeta) = \widehat{u}^{[n-1]}(\zeta) - c \frac{h_t}{h_x} \left(\widehat{\tau_{-h_x} u}^{[n]}(\zeta) - \widehat{\tau_{h_x} u}^{[n]}(\zeta) \right).$$

En utilisant les propriétés de la transformée de Fourier (voir p. 123), en particulier le fait que $t_0 \in \mathbb{R}$ fixé, on a $\widehat{\tau_{t_0} f}(\zeta) = e^{-2\pi i t_0 \zeta} \widehat{f}(\zeta)$, on obtient

$$\begin{aligned} \forall \zeta \in \mathbb{R} \quad \widehat{u}^{[n+1]}(\zeta) &= \widehat{u}^{[n-1]}(\zeta) - c \frac{h_t}{h_x} \left(e^{2\pi i h_x \zeta} \widehat{u}^{[n]}(\zeta) - e^{-2\pi i h_x \zeta} \widehat{u}^{[n]}(\zeta) \right) \\ &= \widehat{u}^{[n-1]}(\zeta) - 2ic \frac{h_t}{h_x} \sin(2\pi h_x \zeta) \widehat{u}^{[n]}(\zeta) \end{aligned}$$

Contrairement aux schémas précédents, on est conduit à une relation de récurrence d'ordre 2 et non d'ordre 1, ce qui va nécessiter quelques ajustement dans le raisonnement. Pour tout $n \in \mathbb{N}^*$ et pour tout $\zeta \in \mathbb{R}$, posons

$$\widehat{U}^{[n]}(\zeta) = \begin{pmatrix} \widehat{u}^{[n]}(\zeta) \\ \widehat{u}^{[n-1]}(\zeta) \end{pmatrix}.$$

Les relations

$$\begin{cases} \widehat{u}^{[n+1]}(\zeta) = \widehat{u}^{[n-1]}(\zeta) - 2ic \frac{h_t}{h_x} \sin(2\pi h_x \zeta) \widehat{u}^{[n]}(\zeta) \\ \widehat{u}^{[n]}(\zeta) = \widehat{u}^{[n]}(\zeta) \end{cases}$$

se traduisent sous la forme matricielle

$$\widehat{U}^{[n+1]}(\zeta) = A_\zeta \widehat{U}^{[n]}(\zeta) \tag{4.111}$$

où A_ζ est la matrice

$$A_\zeta = \begin{pmatrix} -2ic \frac{h_t}{h_x} \sin(2\pi h_x \zeta) & 1 \\ 1 & 0 \end{pmatrix}.$$

On a donc

$$\forall n \in \mathbb{N}^* \quad \forall \zeta \in \mathbb{R} \quad \widehat{U}^{[n]}(\zeta) = (A_\zeta)^n \widehat{U}^{[0]}(\zeta).$$

On en déduit que

$$|\widehat{u}^{[n]}(\zeta)| \leq \|\widehat{U}^{[n]}(\zeta)\|_2 = \|(A_\zeta)^n \widehat{U}^{[0]}(\zeta)\|_2 \leq \|A_\zeta\|_2^n \|\widehat{U}^{[0]}(\zeta)\|_2.$$

La matrice A étant symétrique, elle est normale, et par conséquent $\|A_\zeta\|_2 = \rho(A_\zeta)$ où $\rho(A_\zeta)$ désigne le rayon spectral de A . Ainsi, si pour tout $\zeta \in \mathbb{R}$, on a $\rho(A_\zeta) \leq 1$, on pourra en déduire que

$$\forall \zeta \in \mathbb{R} \quad |\widehat{u}^{[n]}(\zeta)|^2 \leq \|\widehat{U}^{[0]}(\zeta)\|_2^2 = |\widehat{u}^{[0]}(\zeta)|^2 + |\widehat{u}^{[1]}(\zeta)|^2.$$

Par suite, en intégrant pour $\zeta \in \mathbb{R}$,

$$\|\widehat{u}^{[n]}\|_{\mathbb{L}^2(\mathbb{R})}^2 \leq \|\widehat{u}^{[0]}\|_{\mathbb{L}^2(\mathbb{R})}^2 + \|\widehat{u}^{[1]}\|_{\mathbb{L}^2(\mathbb{R})}^2.$$

La formule de Parseval permet alors d'en conclure que

$$\|u^{[n]}\|_{\mathbb{L}^2(\mathbb{R})}^2 \leq \|u^{[0]}\|_{\mathbb{L}^2(\mathbb{R})}^2 + \|u^{[1]}\|_{\mathbb{L}^2(\mathbb{R})}^2$$

c'est-à-dire à la stabilité du schéma.

Intéressons-nous au rayon spectral de la matrice A_ζ . Le polynôme caractéristique de la matrice A_ζ est

$$P_\zeta(\lambda) = \lambda^2 + 2i\mu_\zeta \lambda - 1$$

où on a posé $\mu_\zeta = c \frac{h_t}{h_x} \sin(2\pi h_x \zeta)$.

On distingue trois cas selon le signe de $\mu_\zeta^2 - 1$.

1. Si $\mu_\zeta^2 > 1$ alors la matrice A_ζ admet deux valeurs propres distinctes imaginaires pures

$$\lambda_\pm = -i(\mu_\zeta \mp \sqrt{\mu_\zeta^2 - 1}).$$

Notons que l'une de ces deux valeurs propres est toujours de module strictement supérieur à 1.

2. Si $\mu_\zeta^2 < 1$ alors la matrice A_ζ admet deux valeurs propres distinctes complexes conjuguées

$$\lambda_\pm = \pm \sqrt{1 - \mu_\zeta^2} - i\mu_\zeta.$$

Notons que ces deux valeurs propres sont de module 1.

3. Si $\mu_\zeta^2 = 1$ alors la matrice A_ζ admet une valeur propre double qui est $-i\mu_\zeta$. Notons que cette valeur propre est de module 1.

Dans les cas 2 et 3, on est donc assuré d'avoir $\rho(A_\zeta) \leq 1$ pour tout $\zeta \in \mathbb{R}$ et donc stabilité du schéma. Ces deux cas correspondent à $\mu_\zeta^2 \leq 1$, c'est-à-dire à

$$c^2 \frac{h_t^2}{h_x^2} \sin^2(2\pi h_x \zeta) \leq 1.$$

On en conclut que si $|c| \frac{h_t}{h_x} \leq 1$ alors le schéma saute-moutons est stable.

Remarque 4.6 Bien entendu, on peut se poser si la condition $|c| \frac{h_t}{h_x} \leq 1$ est suffisante. On peut en fait démontrer qu'une condition nécessaire pour qu'un schéma s'écrivant sous la forme (4.111) (après en avoir considéré la transformée de Fourier) soit stable est qu'il existe deux constantes positives C et H telles que

$$\forall \zeta \in \mathbb{R} \quad \forall h_t \in]0, H[\quad \rho(A_\zeta) \leq 1 + CH. \quad (4.112)$$

De plus, si la matrice A_ζ est normale pour tout $\zeta \in \mathbb{R}$ alors la condition (4.112) est aussi une condition suffisante de stabilité du schéma. Ce résultat est par exemple démontré dans [12, p. 272].

4.5.4 Les schémas implicites

Reprenons les éléments ayant conduit à la construction du schéma Upwind en nous plaçant pour simplifier dans le cas où c est positif. Nous avons construit l'approximation (4.52) de l'opérateur différentiel portant sur la dérivée en espace en considérant la formule de Taylor-Young à l'ordre 1 pour $x \mapsto u(x, t_n)$ entre x_j et $x_{j+1} = x_j + h_x$. Nous aurions tout aussi bien pu faire le choix d'exprimer la fonction u en t_{n+1} au lieu de t_n . Cela nous aurait conduit à l'approximation suivante de l'opérateur différentiel portant sur la dérivée en espace :

$$\partial_x u(x_j, t_{n+1}) \approx \frac{u(x_j, t_{n+1}) - u(x_{j-1}, t_{n+1})}{h_x}. \quad (4.113)$$

Nous considérons alors pour approximation de l'opérateur différentiel portant sur la dérivée en temps, l'expression (4.51) considérée en t_{n+1} au lieu de t_n , i.e.

$$\partial_t u(x_j, t_{n+1}) \approx \frac{u(x_j, t_{n+1}) - u(x_j, t_n)}{h_t}. \quad (4.114)$$

Cela nous conduit au schéma d'approximation suivant pour l'équation d'advection (4.24) :

$$\frac{u_j^{[n+1]} - u_j^{[n]}}{h_t} + c \frac{u_j^{[n+1]} - u_{j-1}^{[n+1]}}{h_x} = 0, \quad (4.115)$$

que l'on peut ré-exprimer sous la forme

$$u_j^{[n+1]} \left(1 + c \frac{h_t}{h_x} \right) - c \frac{h_t}{h_x} u_{j-1}^{[n+1]} = u_j^{[n]} \quad \forall j \in \mathbb{Z}. \quad (4.116)$$

On remarque que contrairement au schéma Upwind, avec ce nouveau schéma la solution au temps t_{n+1} ne s'exprime pas explicitement en fonction de la solution calculée au temps t_n . Le passage du temps t_n au temps t_{n+1} nécessite la résolution d'un système d'équations linéaires de taille infinie.

Comme évoqué lorsque nous avons introduit le schéma Upwind, nous pouvons nous placer dans le cas où la donnée initiale est à support dans l'intervalle $[a, b]$. Dans ce cas, la solution en tout temps t est à support dans l'intervalle $[a + ct, b + ct]$. Par conséquent, si l'on s'intéresse à la solution dans un intervalle de temps borné $[0, T]$, nous savons que la solution quel que soit le temps considéré restera avec un support inclus dans l'intervalle $[a, b + cT]$. On impose alors les conditions aux limites $u(a, t) = u(b + cT, t) = 0$ pour tout $t \in [0, T]$ aux extrémités de l'intervalle pris en considération pour la variable d'espace. Dans ce cas particulier, le système infini (4.116) n'est à considérer que pour $j \in \{0, \dots, J\}$ et non pas pour tout $j \in \mathbb{Z}$ et il s'écrit sous la forme matricielle suivante :

$$\mathcal{M} U^{[n+1]} = U^{[n]} \quad (4.117)$$

où $U^{[n]}$ est le vecteur de composantes $u_0^{[n]}, \dots, u_J^{[n]}$ et $\mathcal{M}$ est la matrice

$$\mathcal{M} = \begin{pmatrix} 1 + \alpha & & & \\ -\alpha & 1 + \alpha & & \\ & \ddots & \ddots & \\ & & -\alpha & 1 + \alpha \end{pmatrix}$$

où on a posé $\alpha = c h_t / h_x$. Ainsi, le calcul de la solution approchée au temps t_{n+1} à partir de la solution obtenue au temps t_n nécessite la résolution du système linéaire (4.117). Il est facile de constater que la matrice $\mathcal{M}$ est inversible et la résolution du système linéaire (4.117) est facilitée par le fait que le système est triangulaire inférieur. On peut par ailleurs vérifier que la matrice $\mathcal{M}^{-1}$ est une matrice triangulaire inférieure (pleine) dont les termes de la k -ième sous-diagonale, $k \in \{0, \dots, J\}$, sont constants et valent $\frac{\alpha^k}{(1+\alpha)^{k+1}}$. Par ailleurs,

$$\|U^{[n+1]}\|_2 = \|\mathcal{M}^{-1} U^{[n]}\|_2 \leq \|\mathcal{M}^{-1}\|_2 \|U^{[n]}\|_2 \leq \sqrt{\|\mathcal{M}^{-1}\|_1 \|\mathcal{M}^{-1}\|_\infty} \|U^{[n]}\|_2$$

et

$$\begin{aligned} \|\mathcal{M}^{-1}\|_1 = \|\mathcal{M}^{-1}\|_\infty &= \sum_{k=0}^J \frac{\alpha^k}{(1+\alpha)^{k+1}} = \frac{1}{\alpha} \sum_{k=1}^{J+1} \left(\frac{\alpha}{1+\alpha} \right)^k \\ &\leq \frac{1}{\alpha} \sum_{k=1}^{\infty} \left(\frac{\alpha}{1+\alpha} \right)^k = \frac{1}{\alpha} \frac{\alpha}{1+\alpha} \frac{1}{1 - \frac{\alpha}{1+\alpha}} = 1. \end{aligned}$$

On a donc

$$\|U^{[n+1]}\|_2 \leq \|U^{[n]}\|_2 \leq \|U_0\|_2.$$

D'après la définition (4.8), on en conclut que ce schéma implicite est inconditionnellement stable (autrement dit, il est stable quelles que soient les valeurs de h_t et h_x). Une étude en tout point analogue à celle qui a été menée pour établir la consistance du schéma Upwind, permettrait d'établir que ce schéma implicite est lui aussi consistant et d'ordre 1 en temps et en espace.

Exercice 4.2 On considère le problème d'advection (4.24)–(4.25) à vitesse constante. On introduit une discrétisation en espace de pas constant h_x dont les nœuds sont donnés par $x_j = j h_x$ pour tout $j \in \mathbb{Z}$ ainsi qu'une discrétisation en temps de pas constant h_t dont les nœuds sont donnés par $t_n = n h_t$ pour tout $n \in \mathbb{N}$. Pour tout $j \in \mathbb{Z}$, on note $u_j^{[0]} = u_0(x_j)$ et pour tous $n \in \mathbb{N}^*$ et $j \in \mathbb{Z}$, on désigne par $u_j^{[n]}$ la valeur approchée de $u(x_j, t_n)$ obtenue par le schéma numérique suivant :

$$u_i^{[n+1]} = u_i^{[n]} - c \frac{h_t}{2h_x} (u_{i+1}^{[n+1]} - u_{i-1}^{[n+1]}) \quad \forall i \in \mathbb{Z}, \forall n \in \mathbb{N}. \quad (4.118)$$

- 1 - Montrer que le schéma est consistant et est d'ordre 2 en espace et d'ordre 1 en temps.
- 2 - Montrer que le schéma est stable pour la norme usuelle de $\mathbb{L}^2(\mathbb{R})$.
- 3 - Montrer que le schéma est convergent, d'ordre 2 en espace et d'ordre 1 en temps.

On retiendra que les schémas implicites sont plus coûteux en calculs que les schémas explicites mais qu'ils ont la particularité d'être inconditionnellement stables.

Problèmes aux limites hyperboliques du second ordre

On s'intéresse dans ce chapitre à l'équation des cordes vibrantes, aussi appelée *équation des ondes*. Cette équation décrit les mouvements de vibration d'une corde homogène tendue que l'on fait vibrer transversalement. Cette équation est obtenue à partir du principe fondamental de la dynamique en exploitant certaines hypothèses dont notamment celle dite des « petites perturbations ». La description complète du modèle a été faite à la section 1.1.1 où l'équation des cordes vibrantes pour l'inconnue u décrivant le déplacement vertical de la corde au cours du temps a été obtenue p. 3 (voir l'équation (1.7)).

Une équation en tout point analogue est obtenue en acoustique où elle prend le nom d'*équation des tuyaux sonores*. Cette équation décrit les variations de la pression atmosphérique dans un tuyau sonore (flûte, pipeau, clarinette, ...). Les étapes de la modélisation sont décrites dans [8, section 1.2 p. 77]. Elle est obtenue à partir du principe fondamental de la dynamique et de l'équation de conservation de la masse sous l'hypothèse d'un écoulement adiabatique et thermodynamiquement réversible, là aussi sous l'hypothèse dite des « petites perturbations ».

5.1 Étude des propriétés de l'équation des ondes

Étant donnés un réel c non nul, deux fonctions réelles de la variable réelle u_0 et u_1 telles que $u_0 \in \mathcal{C}^2(\mathbb{R})$ et $u_1 \in \mathcal{C}^1(\mathbb{R})$ et une fonction f de $\mathbb{R} \times \mathbb{R}^+$ dans $\mathbb{R}$ continue, nous nous intéressons au problème suivant : trouver $u : \mathbb{R} \times \mathbb{R}^+ \rightarrow \mathbb{R}$ de classe $\mathcal{C}^2$ telle que

$$(\mathcal{P}) \quad \begin{cases} \frac{\partial^2 u}{\partial t^2}(x, t) - c^2 \frac{\partial^2 u}{\partial x^2}(x, t) = f(x, t) & \forall x \in \mathbb{R} \quad \forall t \in \mathbb{R}_+^* & (5.1a) \\ u(x, 0) = u_0(x) & \forall x \in \mathbb{R} & (5.1b) \\ \frac{\partial u}{\partial t}(x, 0) = u_1(x) & \forall x \in \mathbb{R} & (5.1c) \end{cases}$$

Remarques 5.1

1. À la section 1.1.1, voir l'équation (1.7), l'équation des cordes vibrantes pour l'inconnue u décrivant le déplacement vertical de la corde au cours du temps prenait la forme $\mu \frac{\partial^2 u}{\partial t^2} - \tau \frac{\partial^2 u}{\partial x^2} = f$ où μ désigne la masse linéique de la corde, τ la tension et f la densité linéique de force s'exerçant sur celle-ci. On obtient l'équation (5.1a) en divisant chaque membre par la densité linéique μ et on a $c^2 = \frac{\tau}{\mu}$. La masse linéique μ est homogène à une masse par unité de longueur (M L^{-1}) et la tension τ , qui est une force, est homogène à M L T^{-2} (T pour l'unité de temps). On en déduit que c^2 est homogène à $\text{L}^2 \text{T}^{-2}$. Par conséquent, c est homogène à une vitesse (L T^{-1}).

2. Le problème $(\mathcal{P})$ défini en (5.1) peut être considéré comme l'analogue d'un problème de Cauchy pour une équation différentielle d'ordre 2 en temps (il suffit pour cela de considérer des données u_0 , u_1 et f indépendantes de la variable d'espace x). Cela explique pourquoi on impose une condition initiale sur u et une condition initiale sur $\partial_t u$ pour (espérer) avoir un problème bien posé.

3. L'équation des ondes correspond le plus souvent à une équation posée en domaine non borné en espace. C'est le cas ici puisque la variable d'espace x varie dans $\mathbb{R}$. On peut bien entendu aussi considérer l'équation des ondes en domaine borné ; c'est le cas par exemple pour un problème d'acoustique dans une salle. On doit dans ce cas ajouter au problème $(\mathcal{P})$ défini en (5.1) des conditions aux limites.

Nous allons voir qu'à l'instar d'une équation différentielle d'ordre 2 qui peut être ramenée à un système différentiel du premier ordre,⁽¹⁾ on peut ramener le problème $(\mathcal{P})$ défini en (5.1), qui est d'ordre 2 de dérivation en temps, à un système de deux équations de transport qui sont d'ordre 1 de dérivation en temps. Pour cela, on introduit les deux fonctions suivantes :

$$v = \frac{\partial u}{\partial t} \quad \text{et} \quad w = c \frac{\partial u}{\partial x}. \quad (5.2)$$

On a d'une part

$$\frac{\partial^2 u}{\partial t^2} - c^2 \frac{\partial^2 u}{\partial x^2} = \frac{\partial v}{\partial t} - c \frac{\partial w}{\partial x}$$

et d'autre part, d'après le théorème de Schwarz⁽²⁾

$$\frac{\partial v}{\partial x} = \frac{\partial^2 u}{\partial x \partial t} = \frac{\partial^2 u}{\partial t \partial x} = \frac{1}{c} \frac{\partial w}{\partial t}.$$

Les fonctions v et w vérifient donc les équations suivantes :

$$\begin{cases} \frac{\partial v}{\partial t}(x, t) - c \frac{\partial w}{\partial x}(x, t) = f(x, t) & \forall x \in \mathbb{R} \quad \forall t \in \mathbb{R}_+^* \\ \frac{\partial w}{\partial t}(x, t) - c \frac{\partial v}{\partial x}(x, t) = 0 & \forall x \in \mathbb{R} \quad \forall t \in \mathbb{R}_+^* \end{cases} \quad (5.3a)$$

$$(5.3b)$$

On a par ailleurs les conditions initiales suivantes déduites de (5.1b) et (5.1c)

$$v(x, 0) = \frac{\partial u}{\partial t}(x, 0) = u_1(x) \quad \forall x \in \mathbb{R} \quad (5.4a)$$

$$w(x, 0) = c \frac{\partial u}{\partial x}(x, 0) = c u'_0(x) \quad \forall x \in \mathbb{R} \quad (5.4b)$$

Désignons par U et par F les fonctions de $\mathbb{R} \times \mathbb{R}^+$ dans $\mathbb{R}^2$ définies par

$$U(x, t) = \begin{pmatrix} v(x, t) \\ w(x, t) \end{pmatrix}, \quad F(x, t) = \begin{pmatrix} f(x, t) \\ 0 \end{pmatrix}.$$

On déduit immédiatement de (5.3a)–(5.3b) que

$$\frac{\partial U}{\partial t}(x, t) + A \frac{\partial U}{\partial x}(x, t) = F(x, t) \quad \forall x \in \mathbb{R} \quad \forall t \in \mathbb{R}_+^* \quad (5.5a)$$

où A est la matrice de $\mathcal{M}_2(\mathbb{R})$ définie par

$$A = \begin{pmatrix} 0 & -c \\ -c & 0 \end{pmatrix}.$$

On déduit par ailleurs de (5.4a)–(5.4b) que

$$\forall x \in \mathbb{R} \quad U(x, 0) = U_0(x) \quad \text{où} \quad U_0(x) = \begin{pmatrix} u_1(x) \\ c u'_0(x) \end{pmatrix}. \quad (5.5b)$$

D'après les hypothèses sur u_0 et u_1 , la fonction U_0 est de classe $\mathcal{C}^1$ sur $\mathbb{R}$.

(1). Voir par exemple [4, chap. 20, section 20.3.4].

(2). Voir par exemple [3, théorème 10.3, chap. 10].

La matrice A est diagonalisable sous la forme suivante $A = P D P^{-1}$ où

$$P = \begin{pmatrix} -1 & 1 \\ 1 & 1 \end{pmatrix}, \quad P^{-1} = \frac{1}{2} \begin{pmatrix} -1 & 1 \\ 1 & 1 \end{pmatrix} \quad \text{et} \quad D = \begin{pmatrix} c & 0 \\ 0 & -c \end{pmatrix}.$$

Posons $V = P^{-1} U$ et $V_0 = P^{-1} U_0$. On déduit de (5.5a)–(5.5b) que

$$\begin{cases} \frac{\partial V}{\partial t}(x, t) + D \frac{\partial V}{\partial x}(x, t) = P^{-1} F(x, t) & \forall x \in \mathbb{R} \quad \forall t \in \mathbb{R}_+^* \\ V(x, 0) = V_0(x) & \forall x \in \mathbb{R} \end{cases} \quad (5.6a)$$

$$(5.6b)$$

L'équation (5.6a) se ré-écrit sous la forme du système différentiel :

$$\begin{cases} \frac{\partial v_1}{\partial t}(x, t) + c \frac{\partial v_1}{\partial x}(x, t) = -\frac{1}{2} f(x, t) & \forall x \in \mathbb{R} \quad \forall t \in \mathbb{R}_+^* \\ \frac{\partial v_2}{\partial t}(x, t) - c \frac{\partial v_2}{\partial x}(x, t) = \frac{1}{2} f(x, t) & \forall x \in \mathbb{R} \quad \forall t \in \mathbb{R}_+^* \end{cases} \quad (5.7a)$$

$$(5.7b)$$

avec les conditions initiales

$$\begin{cases} v_1(x, 0) = \frac{1}{2}(-u_1(x) + c u_0'(x)) & \forall x \in \mathbb{R} \\ v_2(x, 0) = \frac{1}{2}(u_1(x) + c u_0'(x)) & \forall x \in \mathbb{R} \end{cases} \quad (5.8a)$$

$$(5.8b)$$

On dispose donc de deux systèmes découplés correspondant chacun à une équation de transport. D'après la formule de Duhamel pour l'équation du transport, voir le théorème 4.3 p. 107, la solution du problème formé par les équations (5.7a)–(5.8a) est

$$v_1(x, t) = \frac{1}{2}(-u_1(x - ct) + c u_0'(x - ct)) - \frac{1}{2} \int_0^t f(x + c(s - t), s) \, ds. \quad (5.9)$$

De même, la solution du problème formé par les équations (5.7b)–(5.8b) est donnée par (on sera attentif au fait qu'il faut changer c en $-c$ dans la formule de Duhamel dans ce cas)

$$v_2(x, t) = \frac{1}{2}(u_1(x + ct) + c u_0'(x + ct)) + \frac{1}{2} \int_0^t f(x - c(s - t), s) \, ds. \quad (5.10)$$

Comme $U = P V$, on en déduit que

$$U(x, t) = \begin{pmatrix} v(x, t) \\ w(x, t) \end{pmatrix} = P V(x, t) = \begin{pmatrix} v_2(x, t) - v_1(x, t) \\ v_2(x, t) + v_1(x, t) \end{pmatrix}$$

c'est-à-dire

$$\begin{aligned} v(x, t) &= \frac{1}{2}(u_1(x + ct) + u_1(x - ct)) + \frac{1}{2}c(u_0'(x + ct) - u_0'(x - ct)) \\ &\quad + \frac{1}{2} \int_0^t (f(x - c(s - t), s) + f(x + c(s - t), s)) \, ds, \end{aligned} \quad (5.11a)$$

$$\begin{aligned} w(x, t) &= \frac{1}{2}(u_1(x + ct) - u_1(x - ct)) + \frac{1}{2}c(u_0'(x + ct) + u_0'(x - ct)) \\ &\quad - \frac{1}{2} \int_0^t (f(x - c(s - t), s) + f(x + c(s - t), s)) \, ds. \end{aligned} \quad (5.11b)$$

On a $v = \frac{\partial u}{\partial t}$, d'où

$$u(x, t) = u(x, 0) + \int_0^t v(x, \tau) \, d\tau \quad (5.12)$$

et par suite, l'expression de u en substituant l'expression de v donnée par (5.11a) dans (5.12). Des simplifications s'opèrent. Notons que

$$u_0'(x + ct) - u_0'(x - ct) = \frac{1}{c} \frac{\partial}{\partial t} (u_0(x + ct) + u_0(x - ct))$$

de sorte que

$$\begin{aligned} \frac{1}{2}c \int_0^t (u'_0(x+c\tau) - u'_0(x-c\tau)) \, d\tau &= \frac{1}{2} \left[u_0(x+c\tau) + u_0(x-c\tau) \right]_0^t \\ &= \frac{1}{2} (u_0(x+ct) + u_0(x-ct)) - u_0(x). \end{aligned} \quad (5.13)$$

Par ailleurs, en considérant le changement de variable $s = x + c\tau$, on établit que

$$\int_0^t u_1(x+c\tau) \, d\tau = \frac{1}{c} \int_x^{x+ct} u_1(s) \, ds \quad (5.14a)$$

et en considérant le changement de variable $s = x - c\tau$, on établit que

$$\int_0^t u_1(x-c\tau) \, d\tau = -\frac{1}{c} \int_x^{x-ct} u_1(s) \, ds. \quad (5.14b)$$

En substituant l'expression de v donnée par (5.11a) dans (5.12) et en utilisant les relations (5.13), (5.14a) et (5.14b), on obtient

$$\begin{aligned} u(x, t) &= \frac{1}{2} (u_0(x+ct) + u_0(x-ct)) + \frac{1}{2c} \int_{x-ct}^{x+ct} u_1(s) \, ds \\ &\quad + \frac{1}{2} \int_0^t \left(\int_0^\tau (f(x-c(s-\tau), s) + f(x+c(s-\tau), s)) \, ds \right) d\tau. \end{aligned} \quad (5.15)$$

Considérons l'intégrale

$$\int_0^t \left(\int_0^\tau f(x-c(s-\tau), s) \, ds \right) d\tau = \iint_D f(x-c(s-\tau), s) \, ds \, d\tau$$

où D désigne le domaine de $\mathbb{R}^2$ défini par $D = \{(\tau, s) ; 0 \leq \tau \leq t, 0 \leq s \leq \tau\}$. Soit la fonction de changement de variables ϕ définie par

$$\phi : (y, \sigma) \in \Delta^- \subset \mathbb{R}^2 \mapsto (\tau, s) \in D \subset \mathbb{R}^2$$

où

$$\phi(y, \sigma) = \begin{pmatrix} \frac{y-x}{c} + \sigma \\ \sigma \end{pmatrix} = \begin{pmatrix} \tau \\ s \end{pmatrix} \quad \forall (y, \sigma) \in \Delta^-.$$

La fonction ϕ est une fonction affine; elle définit un $\mathcal{C}^1$ -difféomorphisme⁽³⁾ de $\Delta^- = \phi^{-1}(D)$ sur D et

$$\phi^{-1}(\tau, s) = \begin{pmatrix} x + c(\tau - s) \\ s \end{pmatrix}.$$

Le domaine D correspondant à un triangle dans le plan et la fonction ϕ^{-1} étant affine, le domaine $\Delta^- = \phi^{-1}(D)$ correspond lui aussi à un triangle dont les sommets sont les images par ϕ^{-1} des sommets du triangle D . Les sommets de D sont les points $S_1^D = (0, 0)$, $S_2^D = (t, 0)$ et $S_3^D = (t, t)$. Leur image respective par ϕ^{-1} sont les points $S_1^{\Delta^-} = (x, 0)$, $S_2^{\Delta^-} = (x+ct, 0)$ et $S_3^{\Delta^-} = (x, t)$, voir la figure 1. On calcule par ailleurs sans difficulté le jacobien de ϕ ; il vaut $1/c$. La formule de changement de variables pour une intégrale double,⁽⁴⁾ indique que

$$\int_0^t \left(\int_0^\tau f(x-c(s-\tau), s) \, ds \right) d\tau = \frac{1}{c} \iint_{\Delta^-} f(y, \sigma) \, dy \, d\sigma.$$

Considérons à présent la fonction de changement de variables ψ définie par

(3). On rappelle qu'un $\mathcal{C}^1$ -difféomorphisme de Δ^- sur D est une bijection de Δ^- sur D qui est de classe $\mathcal{C}^1$ de même que sa bijection réciproque.

(4). Voir par exemple [3, théorème 12.2, chap. 12].




FIG. 1 Représentation graphique des domaines correspondant aux changements de variables ϕ et ψ .

$$\psi : (y, \sigma) \in \Delta^+ \subset \mathbb{R}^2 \mapsto (\tau, s) = \begin{pmatrix} \frac{x-y}{c} + \sigma \\ \sigma \end{pmatrix} \in D \subset \mathbb{R}^2 \in \Delta^+.$$

La fonction ψ est une fonction affine; elle définit un $\mathcal{C}^1$ -difféomorphisme de $\Delta^+ = \psi^{-1}(D)$ sur D dont la jacobien vaut $-1/c$ et

$$\psi^{-1}(\tau, s) = \begin{pmatrix} x + c(s - \tau) \\ s \end{pmatrix}.$$

Les sommets du triangle Δ^+ sont $S_1^{\Delta^+} = \psi^{-1}(0, 0) = (x, 0) = S_1^{\Delta^-}$, $S_2^{\Delta^+} = \psi^{-1}(t, 0) = (x - ct, 0)$ et $S_3^{\Delta^+} = \psi^{-1}(x, t) = (x, t) = S_3^{\Delta^-}$, voir la figure 1. La formule de changement de variables pour une intégrale double indique que

$$\int_0^t \left(\int_0^\tau f(x + c(s - \tau), s) ds \right) d\tau = \iint_D f(x + c(s - \tau), s) ds d\tau = \frac{1}{c} \iint_{\Delta^+} f(y, \sigma) dy d\sigma.$$

On en déduit que

$$\begin{aligned} \int_0^t \left(\int_0^\tau \left(f(x - c(s - \tau), s) + f(x + c(s - \tau), s) \right) ds \right) d\tau &= \frac{1}{c} \iint_{\Delta^-} f(y, \sigma) ds d\tau + \frac{1}{c} \iint_{\Delta^+} f(y, \sigma) dy d\sigma \\ &= \frac{1}{c} \iint_{\Delta} f(y, \sigma) dy d\sigma. \end{aligned}$$

où $\Delta = \Delta^- \cup \Delta^+ = \{(y, \sigma) \in \mathbb{R}^2 ; |y - x| \leq c(t - \sigma)\}$. Finalement, de la relation (5.15), on déduit que

$$u(x, t) = \frac{1}{2} (u_0(x + ct) + u_0(x - ct)) + \frac{1}{2c} \int_{x-ct}^{x+ct} u_1(s) ds + \frac{1}{2c} \iint_{\Delta} f(y, \sigma) dy d\sigma.$$

Nous avons donc obtenu le résultat suivant connu sous le nom de formule de d'Alembert. ⁽⁵⁾

THÉORÈME 5.1 (Formule de d'Alembert)

Si $u_0 \in \mathcal{C}^2(\mathbb{R})$, $u_1 \in \mathcal{C}^1(\mathbb{R})$ et $f \in \mathcal{C}^0(\mathbb{R} \times \mathbb{R}^+)$, la solution du problème $(\mathcal{P})$ défini en (5.1) admet une solution donnée pour tout $(x, t) \in \mathbb{R} \times \mathbb{R}^+$ par la formule suivante :

$$u(x, t) = \frac{1}{2} (u_0(x + ct) + u_0(x - ct)) + \frac{1}{2c} \int_{x-ct}^{x+ct} u_1(s) ds + \frac{1}{2c} \iint_{\Delta} f(y, s) dy ds \quad (5.16)$$

où $\Delta = \{(y, s) \in \mathbb{R} \times \mathbb{R}^+ ; |y - x| \leq c(t - s)\}$.

⁽⁵⁾. Jean Le Rond d'Alembert est un mathématicien, physicien et philosophe français, né à Paris en 1717 et mort en 1783. D'Alembert est connu pour sa participation à la rédaction de l'Encyclopédie où il est l'auteur de la plupart des articles sur les mathématiques, l'astronomie et la physique.




FIG. 2 Représentation graphique de la zone d'influence des données pour la solution au point (x, t) .

Le domaine $\Delta = \{(y, s) \in \mathbb{R} \times \mathbb{R}^+ ; |y - x| \leq c(t - s)\}$ est le domaine hachuré, réunion de Δ^- et de Δ^+ , représenté à la figure 1, à droite.

Remarque 5.2 On notera que les hypothèses « u_0 de classe $\mathcal{C}^2$ sur $\mathbb{R}$ et u_0 de classe $\mathcal{C}^1$ sur $\mathbb{R}$ » sont bien nécessaires pour que la fonction u définie par la relation (5.16) soit de classe $\mathcal{C}^2$ sur $\mathbb{R} \times \mathbb{R}^+$. Réciproquement, si u_0 est de classe $\mathcal{C}^2$ sur $\mathbb{R}$ et u_0 est de classe $\mathcal{C}^1$ sur $\mathbb{R}$, u est de classe $\mathcal{C}^2$ sur $\mathbb{R} \times \mathbb{R}^+$ si la fonction $(x, t) \mapsto \iint_{\Delta} f(y, s) dy ds$ est de classe $\mathcal{C}^2$ sur $\mathbb{R} \times \mathbb{R}^+$. On peut démontrer que si f est continue sur $\mathbb{R} \times \mathbb{R}^+$ alors c'est bien le cas (utiliser le théorème de dérivation sous le signe somme pour les intégrales à paramètres).

Notion de zone d'influence

Considérons un point $(x, t) \in \mathbb{R} \times \mathbb{R}^+$ et la solution u en ce point donnée par la formule de D'Alembert (5.16). La valeur de $u(x, t)$ dépend de la valeur de u_0 en $x - ct$ et $x + ct$ c'est-à-dire de la valeur de u au deux points de coordonnées $P_- = (x - ct, 0)$ et $P_+ = (x + ct, 0)$. Elle dépend aussi de la valeur de u_1 entre $x - ct$ et $x + ct$, c'est-à-dire des valeurs de $\partial_t u$ le long du segment $[P_-, P_+]$. Enfin, la valeur de $u(x, t)$ dépend des valeurs prises par f dans tout le domaine Δ .

Ainsi, la valeur de la solution en un point (x, t) dépend uniquement des valeurs prises par les données dans un domaine triangulaire dont les sommets sont les points $P_- = (x - ct, 0)$, $P_+ = (x + ct, 0)$ et le point M de coordonnées (x, t) , voir la figure 2. Cela implique par exemple que si l'on modifie la valeur de u_0 en un point y n'appartenant pas à l'intervalle $[x - ct, x + ct]$, cela sera sans influence sur la valeur de la solution en (x, t) . Le triangle de sommets P_- , P_+ et S correspond à la zone où des modifications des données ont un effet sur la solution en (x, t) . On parle de *zone d'influence des données*.

Conservation de l'énergie

On définit l'énergie au temps t associée à une solution u du problème $(\mathcal{P})$ défini en (5.1) par

$$\mathcal{E}(t) = \frac{1}{2}\mu \int_{\mathbb{R}} \left((\partial_t u(x, t))^2 + c^2 (\partial_x u(x, t))^2 \right) dx \quad (5.17)$$

où μ désigne la masse linéique du matériau constituant le domaine physique. Dans le cas du problème de la corde vibrante détaillé à la section 1.1.1, la masse linéique pour une corde de guitare peut être estimée à 10 g/m. L'inconnue u est dans cet exemple un déplacement vertical, c'est-à-dire une quantité homogène à une longueur (L). On en déduit que $\partial_t u$ est homogène à une longueur par unité de temps ($L T^{-1}$) et que $\partial_x u$ est une quantité sans dimension. Comme c est une quantité homogène à une vitesse, c'est-à-dire à une longueur par unité de temps ($L T^{-1}$), on en déduit que $(\partial_t u)^2 + c^2 (\partial_x u)^2$ est homogène à $L^2 T^{-1}$. Après intégration en x (une longueur L) et multiplication par μ homogène à une masse par unité de longueur

(M L⁻¹), on en conclut que $\mathcal{E}(t)$ est homogène à M L² T⁻². Dans le système international (SI), $\mathcal{E}(t)$ est donc homogène à des joules,⁽⁶⁾ le joule étant l'unité pour exprimer une énergie (1 joule = 1 kg m² s⁻²). La définition (5.17) de l'énergie pour le problème considéré est donc bien cohérente. Cette énergie se scinde en deux quantités :

$$\begin{aligned} - \mathcal{E}_c(t) &= \frac{1}{2}\mu \int_{\mathbb{R}} (\partial_t u(x, t))^2 dx \text{ qui est l'énergie cinétique du système étudié;} \\ - \mathcal{E}_p(t) &= \frac{1}{2}\mu \int_{\mathbb{R}} c^2 (\partial_x u(x, t))^2 dx \text{ qui est l'énergie potentielle du système.} \end{aligned}$$

Par la suite, pour ne pas alourdir les notations, nous supposons que $\mu = 1$ (ou de manière équivalente nous considérerons non pas l'énergie mais le quotient par μ de l'énergie).

Intéressons-nous au problème ($\mathcal{P}$) défini en (5.1) dans le cas où le second membre f est nul (absence de terme source). Dérivons par rapport au temps l'énergie donnée par l'équation (5.17). Nous supposons que la solution u du problème ($\mathcal{P}$) est telle que les hypothèses pour permuter l'intégrale et la dérivation sont satisfaites. On obtient

$$\begin{aligned} \mathcal{E}'(t) &= \frac{1}{2} \int_{\mathbb{R}} \frac{\partial}{\partial t} \left((\partial_t u(x, t))^2 \right) dx + \frac{c^2}{2} \int_{\mathbb{R}} \frac{\partial}{\partial t} \left((\partial_x u(x, t))^2 \right) dx \\ &= \int_{\mathbb{R}} \partial_t u(x, t) \partial_{tt}^2 u(x, t) dx + c^2 \int_{\mathbb{R}} \partial_{tx}^2 u(x, t) \partial_x u(x, t) dx. \end{aligned}$$

En supposant u suffisamment régulière pour que le théorème de Schwarz⁽⁷⁾ s'applique, on a $\partial_{tx}^2 u = \partial_{xt}^2 u$ et effectuant une intégration par parties sur la dernière des intégrales, on en déduit que

$$\begin{aligned} \mathcal{E}'(t) &= \int_{\mathbb{R}} \partial_t u(x, t) \partial_{tt}^2 u(x, t) dx - c^2 \int_{\mathbb{R}} \partial_{xx}^2 u(x, t) \partial_t u(x, t) dx \\ &= \int_{\mathbb{R}} \partial_t u(x, t) \left(\partial_{tt}^2 u(x, t) - c^2 \partial_{xx}^2 u(x, t) \right) dx. \end{aligned}$$

Comme u est solution de (5.1), dans le cas où $f = 0$ on a établi que $\mathcal{E}'(t) = 0$ pour tout $t \in \mathbb{R}^+$. Cela signifie que l'énergie $\mathcal{E}$ reste inchangée au cours du temps lorsque $f = 0$; en l'absence de terme source, il y a donc conservation de l'énergie.

PROPOSITION 5.1 (Conservation de l'énergie)

Soit u une solution « régulière » du problème ($\mathcal{P}$) défini en (5.1) en l'absence de terme source ($f = 0$) et soit $\mathcal{E}$ l'énergie définie par

$$\mathcal{E}(t) = \frac{1}{2} \int_{\mathbb{R}} \left((\partial_t u(x, t))^2 + c^2 (\partial_x u(x, t))^2 \right) dx \quad \forall t \in \mathbb{R}^+. \quad (5.18)$$

Pour tout $t \in \mathbb{R}^+$, on a $\mathcal{E}(t) = \mathcal{E}(0) = \frac{1}{2} \|u'_0\|_{L^2(\mathbb{R})}^2 + \frac{1}{2} \|u_1\|_{L^2(\mathbb{R})}^2$.

On déduit de la proposition 5.1 le résultat suivant.

PROPOSITION 5.2 (Unicité de la solution)

Sous les hypothèses $u_0 \in C^2(\mathbb{R})$, $u_1 \in C^1(\mathbb{R})$ et $f \in C^0(\mathbb{R} \times \mathbb{R}^+)$, la solution du problème ($\mathcal{P}$) défini en (5.1) est unique.

(6). L'unité doit son nom au physicien anglais James Prescott Joule (1818-1889) qui a énoncé la relation existant entre le courant traversant une résistance et la chaleur dissipée par celle-ci, appelée depuis la loi de Joule.

(7). Voir par ex. [3, théorème 10.3 du chap. 10].

Démonstration Supposons que le problème $(\mathcal{P})$ possède deux solutions v et w et désignons par u leur différence $v - w$. D'après les hypothèses, on a $v, w \in \mathcal{C}^2(\mathbb{R} \times \mathbb{R}^+)$. Par linéarité, il est immédiat que $u \in \mathcal{C}^2(\mathbb{R} \times \mathbb{R}^+)$ est solution du problème suivant

$$\begin{cases} \frac{\partial^2 u}{\partial t^2}(x, t) - c^2 \frac{\partial^2 u}{\partial x^2}(x, t) = 0 & \forall x \in \mathbb{R} \quad \forall t \in \mathbb{R}_+^* \\ u(x, 0) = 0 & \forall x \in \mathbb{R} \\ \frac{\partial u}{\partial t}(x, 0) = 0 & \forall x \in \mathbb{R} \end{cases}$$

Ce problème correspond au problème $(\mathcal{P})$ en l'absence de terme source et avec des données initiales nulles. On déduit de la proposition 5.1 que pour tout $t \in \mathbb{R}^+$, on a $\mathcal{E}(t) = \mathcal{E}(0) = 0$. Cela implique, compte tenu de la définition de l'énergie, que

$$\forall x \in \mathbb{R} \quad \forall t \in \mathbb{R}^+ \quad \partial_t u(x, t) = 0 \quad \text{et} \quad \partial_x u(x, t) = 0.$$

Par conséquent, la fonction u qui est de classe $\mathcal{C}^2$ sur $\mathbb{R} \times \mathbb{R}^+$ ne varie ni en temps, ni en espace. C'est donc une fonction constante. Comme la fonction est nulle à l'instant initial, elle est nulle en tout temps. On en conclut que $v = w$. La solution du problème $(\mathcal{P})$ est bien unique. $\square$

5.2 Schéma aux différences finies pour l'équation des ondes

5.2.1 Construction du schéma

Considérons une subdivision uniforme $(x_j)_{j \in \mathbb{Z}}$ de pas h_x constant de la droite réelle pour la variable d'espace et une subdivision uniforme $(t_n)_{n \in \mathbb{N}}$ de pas h_t constant de la demi-droite réelle $[0, +\infty[$ pour la variable de temps.

Pour tout $n \in \mathbb{N}$ et pour tout $j \in \mathbb{Z}$, on considère les approximations par différences finies centrées suivantes :

$$\frac{\partial^2 u}{\partial x^2}(x_j, t_n) \approx \frac{u(x_{j-1}, t_n) - 2u(x_j, t_n) + u(x_{j+1}, t_n))}{h_x^2} \quad (5.19a)$$

$$\frac{\partial^2 u}{\partial t^2}(x_j, t_n) \approx \frac{u(x_j, t_{n-1}) - 2u(x_j, t_n) + u(x_j, t_{n+1}))}{h_t^2} \quad (5.19b)$$

L'équation (5.1a) au nœud (x_j, t_n) est alors approchée par

$$\frac{u_j^{[n-1]} - 2u_j^{[n]} + u_j^{[n+1]}}{h_t^2} - c^2 \frac{u_{j-1}^{[n]} - 2u_j^{[n]} + u_{j+1}^{[n]}}{h_x^2} = f(x_j, t_n) \quad (5.20)$$

où pour tout $n \in \mathbb{N}$ et pour tout $j \in \mathbb{Z}$, $u_j^{[n]}$ désigne la valeur approchée de $u(x_j, t_n)$. Comme nous l'avons vu précédemment, les approximations (5.19) sont d'ordre 2 de précision. La condition initiale (5.1b) $u(x, 0) = u_0(x)$ pour tout $x \in \mathbb{R}$ conduit à poser

$$u_j^{[0]} = u_0(x_j) \quad \forall j \in \mathbb{Z}. \quad (5.21)$$

Pour approcher la condition initiale (5.1c), il serait naturel de vouloir considérer l'approximation par différence finie progressive

$$\frac{\partial u}{\partial t}(x_j, 0) \approx \frac{u(x_j, h_t) - u(x_j, 0)}{h_t} \quad (5.22)$$

ce qui conduirait à poser

$$u_j^{[1]} = u_0(x_j) + h_t u_1(x_j) \quad \forall j \in \mathbb{Z}$$

Toutefois, on notera que l'approximation (5.22) n'est que d'ordre 1 de précision. L'utiliser pour initialiser notre schéma numérique dégraderait sa précision. On procède donc autrement pour prendre en compte la condition initiale (5.1c) dans le schéma.

Introduisons un point fictif $t_{-1} = -h_t$ et prolongeons l'équation (5.1a) en $t = 0$. Au nœud (x_j, t_0) , le schéma (5.20) s'écrit

$$\frac{u_j^{[-1]} - 2u_j^{[0]} + u_j^{[1]}}{h_t^2} - c^2 \frac{u_{j-1}^{[0]} - 2u_j^{[0]} + u_{j+1}^{[0]}}{h_x^2} = f(x_j, t_0) \quad (5.23)$$

avec $u_j^{[0]}$ donné d'après (5.21) par $u_j^{[0]} = u_0(x_j)$ pour tout $j \in \mathbb{Z}$. On approche par ailleurs la condition initiale (5.1c) par la différence finie centrée d'ordre 2 de précision

$$\frac{\partial u}{\partial t}(x_j, 0) \approx \frac{u(x_j, h_t) - u(x_j, -h_t)}{2h_t} \quad (5.24)$$

ce qui conduit à poser

$$u_j^{[-1]} = u_j^{[1]} - 2h_t u_1(x_j) \quad \forall j \in \mathbb{Z}. \quad (5.25)$$

En combinant (5.23) et (5.25) de façon à éliminer $u_j^{[-1]}$, l'approximation au point fictif introduit, nous obtenons

$$u_j^{[1]} = u_0(x_j) + h_t u_1(x_j) + \frac{c^2 h_t^2}{2h_x^2} (u_0(x_{j-1}) - 2u_0(x_j) + u_0(x_{j+1})) + \frac{1}{2} h_t^2 f(x_j, 0). \quad (5.26)$$

Notre schéma d'approximation du problème ($\mathcal{P}$) défini en (5.1) est donc formé des relations (5.21) et (5.26) qui permettent d'initialiser le schéma aux temps t_0 et t_1 et de la relation (5.20) qui permet de calculer l'approximation au temps t_{n+1} connaissant la solution aux temps t_{n-1} et t_n : pour tout $n \geq 1$ et pour tout $j \in \mathbb{Z}$,

$$u_j^{[n+1]} = -u_j^{[n-1]} + 2 \left(1 - c^2 \frac{h_t^2}{h_x^2} \right) u_j^{[n]} + c^2 \frac{h_t^2}{h_x^2} (u_{j-1}^{[n]} + u_{j+1}^{[n]}) + h_t^2 f(x_j, t_n). \quad (5.27)$$

Notons qu'il s'agit d'un schéma explicite.

5.2.2 Mise en œuvre du schéma

Bien entendu pour une mise en œuvre informatique de ce schéma d'approximation, il convient de tronquer la suite à double indice $(u_j^{[n]})_{j \in \mathbb{Z}, n \in \mathbb{N}}$. Cela peut passer dans un premier par la donnée d'une durée T sur laquelle la simulation numérique doit être réalisée. On considère dans ce cas l'équation (5.1a) sur l'intervalle de temps borné $[0, T]$ et on désigne par N l'entier tel que $T = Nh_t$. Dans un deuxième temps, en supposant que la fonction u_0 est à support borné, on spécifie un intervalle borné $[a, b]$ tel qu'en tout temps $t \in [0, T]$, la solution u ait un support qui reste strictement inclus dans $[a, b]$. On considère dans ce cas le problème ($\mathcal{P}$) défini en (5.1) sur l'intervalle $[a, b]$ pour la variable d'espace. On suppose dans ce cas que $x_0 = a$ et on désigne par J l'entier tel que $b = a + Jh_x$. Sous l'hypothèse que le support de la solution u reste strictement inclus dans $[a, b]$ en tout temps $t \in [0, T]$, on a les conditions de Dirichlet homogène

$$u(a, t) = u(b, t) = 0 \quad \forall t \in [0, T]. \quad (5.28)$$

Dans ces conditions, désignons pour tout $n \in \{0, \dots, N\}$ par $U^{[n]}$ le vecteur de $\mathbb{R}^{J-1}$ de composantes $u_j^{[n]}, j = 1, \dots, J-1$. (Compte tenu des conditions aux limites (5.28) en a et en b , il est inutile de calculer une approximation de la solution en $x_0 = a$ et $x_J = b$.) Le schéma d'approximation formé des relations (5.27), (5.21), (5.26) et (5.28) s'écrit sous la forme matricielle :

$$U^{[n+1]} = \left(2I - c^2 \frac{h_t^2}{h_x^2} M \right) U^{[n]} - U^{[n-1]} + h_t^2 F^{[n]} \quad (5.29)$$

où $F^{[n]}$ désigne le vecteur de $\mathbb{R}^{J-1}$ de composantes $f(x_j, t_n), j = 1, \dots, J-1$, I désigne la matrice identité de $\mathcal{M}_{J-1}(\mathbb{R})$ et M désigne la matrice de $\mathcal{M}_{J-1}(\mathbb{R})$ suivante :

$$M = \begin{pmatrix} 2 & -1 & & & \\ -1 & 2 & -1 & & \\ & -1 & \ddots & \ddots & \\ & & \ddots & \ddots & -1 \\ & & & -1 & 2 \end{pmatrix}. \quad (5.30)$$

En posant $A = 2I - c^2 \frac{h_t^2}{h_x^2} M$, la relation s'écrit

$$U^{[n+1]} = A U^{[n]} - U^{[n-1]} + h_t^2 F^{[n]}. \quad (5.31)$$

Le schéma est initialisé par la donnée des vecteurs suivants dont l'expression est déduite de (5.21) et de (5.26) :

$$U^{[0]} = \begin{pmatrix} u_0(x_1) \\ \vdots \\ u_0(x_{J-1}) \end{pmatrix} \quad \text{et} \quad U^{[1]} = \left(I - c^2 \frac{h_t^2}{2h_x^2} M \right) U^{[0]} + h_t V_1 + \frac{1}{2} h_t^2 F^{[0]} \quad (5.32)$$

où V_1 est le vecteur de $\mathbb{R}^{J-1}$ de composantes $u_1(x_j), j = 1, \dots, J-1$. Notons que l'on a

$$U^{[1]} = \frac{1}{2} A U^{[0]} + h_t V_1 + \frac{1}{2} h_t^2 F^{[0]}. \quad (5.33)$$

5.3 Consistance du schéma aux différences finies

D'après (5.20), l'erreur de consistance $\varepsilon_j^{[n]}$ du schéma aux différences finies étudié au nœud (x_j, t_n) pour $j \in \mathbb{Z}$ et $n \geq 2$ est donnée par

$$\begin{aligned} \varepsilon_j^{[n]} &= \frac{u(x_j, t_{n-1}) - 2u(x_j, t_n) + u(x_j, t_{n+1}))}{h_t^2} \\ &\quad - c^2 \frac{u(x_{j-1}, t_n) - 2u(x_j, t_n) + u(x_{j+1}, t_n)}{h_x^2} - f(x_j, t_n). \end{aligned} \quad (5.34)$$

Supposons que u est de classe $\mathcal{C}^4$ sur $\mathbb{R} \times \mathbb{R}^+$ et que ses dérivées partielles à tout ordre sont bornées sur $\mathbb{R} \times \mathbb{R}^+$. D'après la formule de Taylor-Lagrange à l'ordre 3 appliquée à la solution u du problème $(\mathcal{P})$ défini en (5.1) entre (x_j, t_{n+1}) et (x_j, t_n) , il existe $\theta_1 \in]0, 1[$ tel que

$$u(x_j, t_n + h_t) = u(x_j, t_n) + h_t \partial_t u(x_j, t_n) + \frac{1}{2} h_t^2 \partial_t^2 u(x_j, t_n) + \frac{1}{6} h_t^3 \partial_t^3 u(x_j, t_n) + \frac{1}{24} h_t^4 \partial_t^4 u(x_j, t_n + \theta_1 h_t).$$

Par ailleurs, d'après la formule de Taylor-Lagrange à l'ordre 3 appliquée à u entre (x_j, t_{n-1}) et (x_j, t_n) , il existe $\theta_2 \in]-1, 0[$ tel que

$$u(x_j, t_n - h_t) = u(x_j, t_n) - h_t \partial_t u(x_j, t_n) + \frac{1}{2} h_t^2 \partial_t^2 u(x_j, t_n) - \frac{1}{6} h_t^3 \partial_t^3 u(x_j, t_n) + \frac{1}{24} h_t^4 \partial_t^4 u(x_j, t_n + \theta_2 h_t).$$

En sommant ces deux expressions, nous obtenons

$$\begin{aligned} \frac{u(x_j, t_{n+1}) - 2u(x_j, t_n) + u(x_j, t_{n-1}))}{h_t^2} &= \partial_t^2 u(x_j, t_n) \\ &\quad + \frac{1}{24} h_t^2 (\partial_t^4 u(x_j, t_n + \theta_1 h_t) + \partial_t^4 u(x_j, t_n + \theta_2 h_t)). \end{aligned} \quad (5.35)$$

D'après la formule de Taylor-Lagrange à l'ordre 3 appliquée à u entre $(x_j + h_x, t_n)$ et (x_j, t_n) , il existe $\theta_3 \in]0, 1[$ tel que

$$u(x_j + h_x, t_n) = u(x_j, t_n) + h_x \partial_x u(x_j, t_n) + \frac{1}{2} h_x^2 \partial_x^2 u(x_j, t_n) + \frac{1}{6} h_x^3 \partial_x^3 u(x_j, t_n) + \frac{1}{24} h_x^4 \partial_x^4 u(x_j + \theta_3 h_x, t_n).$$

Par ailleurs, d'après la formule de Taylor-Lagrange à l'ordre 3 appliquée à la solution u du problème $(\mathcal{P})$ entre $(x_j - h_x, t_n)$ et (x_j, t_n) , il existe $\theta_4 \in]-1, 0[$ tel que

$$u(x_j - h_x, t_n) = u(x_j, t_n) - h_x \partial_x u(x_j, t_n) + \frac{1}{2} h_x^2 \partial_x^2 u(x_j, t_n) - \frac{1}{6} h_x^3 \partial_x^3 u(x_j, t_n) + \frac{1}{24} h_x^4 \partial_x^4 u(x_j + \theta_4 h_x, t_n).$$

En sommant ces deux expressions, nous obtenons

$$\begin{aligned} \frac{u(x_{j+1}, t_n) - 2u(x_j, t_n) + u(x_{j-1}, t_n)}{h_x^2} &= \partial_x^2 u(x_j, t_n) \\ &\quad + \frac{1}{24} h_x^2 (\partial_x^4 u(x_j + \theta_3 h_x, t_n) + \partial_x^4 u(x_j + \theta_4 h_x, t_n)). \end{aligned} \quad (5.36)$$

Les relations (5.35) et (5.36), combinées avec (5.34), indiquent que

$$\begin{aligned} \varepsilon_j^{[n]} &= \partial_t^2 u(x_j, t_n) - c^2 \partial_x^2 u(x_j, t_n) - f(x_j, t_n) \\ &\quad + \frac{1}{24} h_t^2 (\partial_t^4 u(x_j, t_n + \theta_1 h_t) + \partial_t^4 u(x_j, t_n + \theta_2 h_t)) - c^2 \frac{1}{24} h_x^2 (\partial_x^4 u(x_j + \theta_3 h_x, t_n) + \partial_x^4 u(x_j + \theta_4 h_x, t_n)). \end{aligned}$$

Comme u est solution du problème $(\mathcal{P})$ défini en (5.1), on a $\partial_t^2 u(x_j, t_n) - c^2 \partial_x^2 u(x_j, t_n) = f(x_j, t_n)$ pour tous $j \in \mathbb{Z}, n \in \mathbb{N}^*$ et par conséquent

$$\varepsilon_j^{[n]} = \frac{1}{24} h_t^2 (\partial_t^4 u(x_j, t_n + \theta_1 h_t) + \partial_t^4 u(x_j, t_n + \theta_2 h_t)) - c^2 \frac{1}{24} h_x^2 (\partial_x^4 u(x_j + \theta_3 h_x, t_n) + \partial_x^4 u(x_j + \theta_4 h_x, t_n)).$$

Finalement, on en conclut que pour tous $j \in \mathbb{Z}, n \in \mathbb{N}^*$, on a

$$|\varepsilon_j^{[n]}| \leq \frac{1}{12} M_t^{(4)} h_t^2 + \frac{1}{12} c^2 M_x^{(4)} h_x^2 \quad (5.37)$$

où $M_t^{(4)} = \sup_{(x,t) \in \mathbb{R} \times \mathbb{R}^+} |\partial_t^4 u(x, t)|$ et $M_x^{(4)} = \sup_{(x,t) \in \mathbb{R} \times \mathbb{R}^+} |\partial_x^4 u(x, t)|$. Le schéma défini par (5.31) est donc consistant d'ordre 2 en temps et en espace.

LEMME 5.1 Dans le cas où $f = 0$, si les pas de discrétisation en espace h_x et en temps h_t sont tels que $\frac{ch_t}{h_x} = 1$, alors l'erreur de consistance $\varepsilon_j^{[n]}$ au nœud (x_j, t_n) est nulle pour tous $j \in \mathbb{Z}$ et $n \geq 2$.

Démonstration On part de l'expression de la solution du problème $(\mathcal{P})$ donnée par la formule de D'Alembert, voir la relation (5.16) : pour tout $(x, t) \in \mathbb{R} \times \mathbb{R}^+$

$$u(x, t) = \frac{1}{2} w_1(x, t) + \frac{1}{2c} (w_2(x, t) + w_3(x, t)) \quad (5.38)$$

où

$$w_1(x) = u_0(x + ct) + u_0(x - ct), \quad w_2(x) = \int_{x-ct}^{x+ct} u_1(s) \, ds, \quad w_3(x) = \iint_{\Delta} f(y, s) \, dy \, ds$$

avec $\Delta = \{(y, s) \in \mathbb{R} \times \mathbb{R}^+ ; |y - x| \leq c(t - s)\}$. Notons que sous l'hypothèse $f = 0$, on a $w_3 = 0$. Dans le cas où $\frac{ch_t}{h_x} = 1$, l'erreur de consistance $\varepsilon_j^{[n]}$ au nœud (x_j, t_n) donnée par la relation (5.34) se simplifie en

$$\varepsilon_j^{[n]} = \frac{1}{h_t^2} (u(x_j, t_{n-1}) + u(x_j, t_{n+1}) - u(x_{j-1}, t_n) - u(x_{j+1}, t_n)) = \frac{1}{h_t^2} (A_j^{[n]} + B_j^{[n]}) \quad (5.39)$$

où

$$\begin{aligned} A_j^{[n]} &= w_1(x_j, t_{n-1}) + w_1(x_j, t_{n+1}) - w_1(x_{j-1}, t_n) - w_1(x_{j+1}, t_n) \\ B_j^{[n]} &= w_2(x_j, t_{n-1}) + w_2(x_j, t_{n+1}) - w_2(x_{j-1}, t_n) - w_2(x_{j+1}, t_n). \end{aligned}$$

Sous l'hypothèse $\frac{ch_t}{h_x} = 1$, on a

$$\begin{aligned} A_j^{[n]} &= u_0(x_j + ct_{n-1}) + u_0(x_j - ct_{n-1}) + u_0(x_j + ct_{n+1}) + u_0(x_j - ct_{n+1}) \\ &\quad - u_0(x_{j-1} + ct_n) - u_0(x_{j-1} - ct_n) - u_0(x_{j+1} + ct_n) - u_0(x_{j+1} - ct_n) \\ &= u_0(x_j + ct_n - h_x) + u_0(x_j - ct_n + h_x) + u_0(x_j + ct_n + h_x) + u_0(x_j - ct_n - h_x) \\ &\quad - u_0(x_{j-1} - h_x + ct_n) - u_0(x_{j-1} - h_x - ct_n) - u_0(x_{j+1} + h_x + ct_n) - u_0(x_{j+1} + h_x - ct_n). \end{aligned}$$

On voit que les termes s'annulent deux à deux et par conséquent $A_j^{[n]} = 0$.

Considérons à présent la quantité $B_j^{[n]}$. D'après la relation de Chasles, on peut regrouper d'une part $w_2(x_j, t_{n-1})$ et $w_2(x_{j-1}, t_n)$ et d'autre part $w_2(x_j, t_{n+1})$ et $w_2(x_{j+1}, t_n)$ pour obtenir l'expression suivante

$$B_j^{[n]} = \int_{x_j - h_x - ct_n}^{x_j - h_x + ct_n} u_1(s) \, ds - \int_{x_j - h_x - ct_n}^{x_j - h_x + ct_n} u_1(s) \, ds = 0.$$

On en conclut donc que dans le cas où f est nulle, l'erreur de consistance $\varepsilon_j^{[n]}$ au nœud (x_j, t_n) est nulle. $\square$




FIG. 3 Domaines pour l'intégrale double définissant $C_j^{[n]}$.

Remarque 5.3 Considérons à présent le cas où $f \neq 0$. Reprenons les notations de la preuve du lemme 5.1. Désignons par $C_j^{[n]}$ la quantité $C_j^{[n]} = w_3(x_j, t_{n+1}) + w_3(x_j, t_{n-1}) - w_3(x_{j-1}, t_n) - w_3(x_{j+1}, t_n)$. On a

$$C_j^{[n]} = \iint_{\Delta(x_j, t_{n+1})} f(y, s) dy ds + \iint_{\Delta(x_j, t_{n-1})} f(y, s) dy ds - \iint_{\Delta(x_{j+1}, t_n)} f(y, s) dy ds - \iint_{\Delta(x_{j-1}, t_n)} f(y, s) dy ds$$

où pour tout (x, t) on note $\Delta(x, t) = \{(y, s) \in \mathbb{R} \times \mathbb{R}^+ ; |y - x| \leq c(t - s)\}$. D'après la relation de Chales, on a $C_j^{[n]} = \iint_D f(y, s) dy ds$ où $D = (\Delta(x_j, t_{n+1}) \cup \Delta(x_j, t_{n-1})) \setminus (\Delta(x_{j+1}, t_n) \cup \Delta(x_{j-1}, t_n))$ est le domaine représenté en hachuré sur la figure 3. On en déduit que $C_j^{[n]}$ n'est en général pas nul. L'erreur de consistance est donnée dans ce cas par

$$\varepsilon_j^{[n]} = \frac{1}{2ch_t^2} \left(\iint_D f(y, s) dy ds - 2 \frac{h_x^2}{c} f(x_j, t_n) \right).$$

Notons que la quantité $2 \frac{h_x^2}{c} f(x_j, t_n)$ coïncide avec le produit de l'aire du losange D par la valeur de f au barycentre de D . Il s'agit donc de la valeur approchée de $\iint_D f(y, s) dy ds$ obtenue par la méthode de quadrature du point milieu en dimension 2. On en déduit que l'erreur de consistance sera nulle dans tous les cas où f sera une fonction dont l'intégrale est calculée exactement par la formule de quadrature du point milieu en dimension 2, notamment lorsque f sera une fonction affine.

5.4 Stabilité du schéma aux différences finies

Procédons comme à la section 4.4.2 pour le schéma Upwind ; pour tout $n \in \mathbb{N}$ fixé, associons à la suite $(u_j^{[n]})_{j \in \mathbb{Z}}$, la fonction $u_{h_x}^{[n]}$ polynomiale de degré 1 par morceaux définie sur $\mathbb{R}$ de la manière suivante : pour tout $j \in \mathbb{Z}$, on a

- $u_{h_x}^{[n]}|_{[x_j, x_{j+1}]} \in \mathbb{P}_1(\mathbb{R})$
- $u_{h_x}^{[n]}(x_j) = u_j^{[n]}$.

On note $V_{h_x} = \{v_{h_x} \in C^0(\mathbb{R}) ; \forall j \in \mathbb{Z} \quad v_{h_x}|_{[x_j, x_{j+1}]} \in \mathbb{P}_1(\mathbb{R})\}$. Rappelons que $(u_j^{[n]})_{j \in \mathbb{Z}} \in \ell^2(\mathbb{Z})$ si, et seulement si, $u_{h_x}^{[n]} \in \mathbb{L}^2(\mathbb{R}) \cap V_{h_x}$ et qu'il existe des constantes C_1 et C_2 indépendantes de h_x telles que pour tout $(u_j)_{j \in \mathbb{Z}} \in \ell^2(\mathbb{Z})$ on ait

$$C_1 \sqrt{h_x} \|(u_j^{[n]})_{j \in \mathbb{Z}}\|_{\ell^2(\mathbb{Z})} \leq \|u_{h_x}^{[n]}\|_{\mathbb{L}^2(\mathbb{R})} \leq C_2 \sqrt{h_x} \|(u_j^{[n]})_{j \in \mathbb{Z}}\|_{\ell^2(\mathbb{Z})}.$$

À l'instar de ce qui a été vu pour la stabilité du schéma Upwind pour l'équation d'advection, voir la définition 4.8 p. 123, le schéma aux différences finies (5.20)–(5.21)–(5.26) sera $\mathbb{L}^2$ -stable si, pour toutes données initiales $u_0, u_1 \in \mathbb{L}^2(\mathbb{R})$, il existe une constante C ne dépendant ni de h_x , ni de h_t , telle que

$$\forall n \in \mathbb{N} \quad \|u_{h_x}^{[n]}\|_{\mathbb{L}^2(\mathbb{R})} \leq C \left(\|u_0\|_{\mathbb{L}^2(\mathbb{R})} + \|u_1\|_{\mathbb{L}^2(\mathbb{R})} \right).$$

D'après la formule de Plancherel, nous avons $\|u_{h_x}^{[n]}\|_{\mathbb{L}^2(\mathbb{R})} = \|\widehat{u}_{h_x}^{[n]}\|_{\mathbb{L}^2(\mathbb{R})}$ où $\widehat{u}_{h_x}^{[n]}$ désigne la transformée de Fourier de $u_{h_x}^{[n]}$. Nous allons donc estimer $\|\widehat{u}_{h_x}^{[n]}\|_{\mathbb{L}^2(\mathbb{R})}$. On fait l'hypothèse que $f = 0$ afin de simplifier la présentation et on pose

$$\alpha = c \frac{h_t}{h_x}.$$

On déduit de (5.27) que pour tout $n \geq 1$, on a

$$u_{h_x}^{[n+1]}(x) = -u_{h_x}^{[n-1]}(x) + 2(1 - \alpha^2) u_{h_x}^{[n]}(x) + \alpha^2 (u_{h_x}^{[n]}(x - h_x) + u_{h_x}^{[n]}(x + h_x)) \quad \forall x \in \mathbb{R}. \quad (5.40a)$$

De plus, les relations (5.21) et (5.26) impliquent

$$u_{h_x}^{[0]}(x) = (\Pi_{h_x} u_0)(x) \quad \forall x \in \mathbb{R} \quad (5.40b)$$

et

$$u_{h_x}^{[1]}(x) = (\Pi_{h_x} u_0)(x) + h_t (\Pi_{h_x} u_1)(x) + \frac{\alpha^2}{2} \left((\Pi_{h_x} u_0)(x - h_x) - 2(\Pi_{h_x} u_0)(x) + (\Pi_{h_x} u_0)(x + h_x) \right) \quad (5.40c)$$

où Π_{h_x} désigne l'opérateur d'interpolation linéaire de $\mathcal{C}^0(\mathbb{R})$ dans V_{h_x} .

Effectuons une transformation de Fourier relativement à la variable d'espace x sur chaque membre de l'équation (5.40b) :

$$\widehat{u}_{h_x}^{[n+1]}(\zeta) = -\widehat{u}_{h_x}^{[n-1]}(\zeta) + 2(1 - \alpha^2) \widehat{u}_{h_x}^{[n]}(\zeta) + \alpha^2 (e^{2i\pi h_x \zeta} + e^{-2i\pi h_x \zeta}) \widehat{u}_{h_x}^{[n]}(\zeta) \quad \forall \zeta \in \mathbb{R}.$$

On a $e^{2i\pi h_x \zeta} + e^{-2i\pi h_x \zeta} = 2 \cos(2\pi h_x \zeta)$ et $1 - \cos(2\pi h_x \zeta) = 2 \sin^2(\pi h_x \zeta)$, d'où

$$\widehat{u}_{h_x}^{[n+1]}(\zeta) = -\widehat{u}_{h_x}^{[n-1]}(\zeta) + 2(1 - \mu_\zeta^2) \widehat{u}_{h_x}^{[n]}(\zeta) \quad (5.41)$$

où μ_ζ est tel que

$$\mu_\zeta^2 = 2\alpha^2 \sin^2(\pi h_x \zeta).$$

Pour tout $\zeta \in \mathbb{R}$ fixé, la suite $(\widehat{u}_{h_x}^{[n]}(\zeta))_{n \in \mathbb{N}}$ est une suite récurrente d'ordre 2 définie par la relation (5.41). Nous allons ramener l'étude à celle d'une suite récurrente d'ordre 1 en introduisant le vecteur

$$V_\zeta^{[n]} = \begin{pmatrix} \widehat{u}_{h_x}^{[n]}(\zeta) \\ \widehat{u}_{h_x}^{[n-1]}(\zeta) \end{pmatrix}.$$

On déduit de la relation de récurrence (5.41) que pour tout $n \in \mathbb{N}^*$

$$V_\zeta^{[n+1]} = B_\zeta V_\zeta^{[n]} \quad (5.42)$$

où B_ζ est la matrice de $\mathcal{M}_2(\mathbb{C})$ donnée par

$$B_\zeta = \begin{pmatrix} 2(1 - \mu_\zeta^2) & -1 \\ 1 & 0 \end{pmatrix}.$$

Un raisonnement par récurrence immédiat permet de déduire de la relation (5.42) que pour tout $n \in \mathbb{N}^*$ et pour tout $\zeta \in \mathbb{R}$

$$V_\zeta^{[n]} = B_\zeta^{n-1} V_\zeta^{[1]}. \quad (5.43)$$

Ainsi,

$$|u^{[n]}(\zeta)| \leq \|V_\zeta^{[n+1]}\|_2 \leq \|B_\zeta\|_2^n \|V_\zeta^{[1]}\|_2. \quad (5.44)$$

On pourra remarquer que la matrice B_ζ n'est pas une matrice normale car en notant $b = 2(1 - \mu_\zeta^2)$, on a

$$B_\zeta B_\zeta^* = \begin{pmatrix} b^2 + 1 & b \\ b & 1 \end{pmatrix} \neq B_\zeta^* B_\zeta = \begin{pmatrix} b^2 + 1 & -b \\ -b & 1 \end{pmatrix}.$$

On a donc ⁽⁸⁾ $\|B_\zeta\|_2 = \sqrt{\rho(B_\zeta B_\zeta^*)}$ où $\rho(B_\zeta B_\zeta^*)$ désigne le rayon spectral de la matrice $B_\zeta B_\zeta^*$. Le polynôme caractéristique associé à la matrice $B_\zeta B_\zeta^*$ est $\lambda^2 - (2 + b^2)\lambda + 1$. Le discriminant Δ est positif et par conséquent $B_\zeta B_\zeta^*$ admet deux valeurs propres réelles distinctes λ_+ et λ_- telles que ⁽⁹⁾ $\lambda_+ \lambda_- = 1$ si $\Delta > 0$ et une valeur propre double qui vaut $1 + \frac{1}{2}b^2$ si $\Delta = 0$. Dans les deux cas, la matrice $B_\zeta B_\zeta^*$ possède une valeur propre strictement supérieure à 1 et par conséquent $\|B_\zeta\|_2 > 1$. Il n'est donc pas possible d'obtenir à partir de la relation (5.44) une majoration de $|u^{[n]}(\zeta)|$ indépendante de n . Nous allons devoir obtenir une majoration de $|u^{[n]}(\zeta)|$ de manière plus fine que celle utilisée pour obtenir (5.44).

Nous allons repartir de la relation (5.43) et diagonaliser la matrice B_ζ . Les valeurs propres λ de la matrice B_ζ sont les racines du polynôme caractéristique donné par

$$P(\lambda) = \lambda^2 + 2(\mu_\zeta^2 - 1)\lambda + 1. \quad (5.45)$$

On distingue trois cas. ⁽¹⁰⁾

— Si $\mu_\zeta^2 > 2$ alors la matrice B_ζ admet deux racines réelles distinctes λ_+ et λ_- telles que $\lambda_+ \lambda_- = 1$ données par

$$\lambda_\pm = (1 - \mu_\zeta^2) \pm \mu_\zeta \sqrt{\mu_\zeta^2 - 2}.$$

— Si $\mu_\zeta^2 < 2$ alors la matrice B_ζ admet deux racines complexes conjuguées distinctes λ_+ et λ_- telles que $|\lambda_+| = |\lambda_-| = 1$ données par

$$\lambda_\pm = (1 - \mu_\zeta^2) \pm i\mu_\zeta \sqrt{2 - \mu_\zeta^2}.$$

— Si $\mu_\zeta^2 = 2$ alors la matrice B_ζ admet une racine double qui vaut $\lambda = 1 - \mu_\zeta^2 = -1$.

Dans les deux premiers cas, la matrice B_ζ est clairement diagonalisable : il existe $P_\zeta \in \text{GL}_2(\mathbb{C})$ tel que $B_\zeta = P_\zeta D_\zeta P_\zeta^{-1}$ avec

$$D_\zeta = \begin{pmatrix} \lambda_- & 0 \\ 0 & \lambda_+ \end{pmatrix}$$

On déduit de (5.43) que

$$V_\zeta^{[n]} = P_\zeta D_\zeta^{n-1} P_\zeta^{-1} V_\zeta^{[1]} = P_\zeta \begin{pmatrix} \lambda_-^{n-1} & 0 \\ 0 & \lambda_+^{n-1} \end{pmatrix} P_\zeta^{-1} V_\zeta^{[1]} \quad (5.46)$$

Étudions à présent les trois cas $\mu_\zeta^2 > 2$, $\mu_\zeta^2 < 2$ et $\mu_\zeta^2 = 2$.

Cas 1 $\mu_\zeta^2 > 2$. Notons que dans le cas $\mu_\zeta^2 > 2$, l'une des deux valeurs propres est strictement supérieure à 1. La relation (5.53) indique que $u^{[n]}(\zeta)$ qui coïncide avec la première composante de $V_\zeta^{[n]}$ tend vers

⁽⁸⁾. Et non pas $\|B_\zeta\|_2 = \rho(B_\zeta)$ comme cela aurait été le cas avec une matrice normale.

⁽⁹⁾. Rappelons que pour un polynôme de degré n de la forme $a_n X^n + a_{n-1} X^{n-1} + \dots + a_1 X + a_0$, le produit des racines est égal à $(-1)^n a_0 / a_n$ alors que la somme des racines est égal à $-a_{n-1} / a_n$, voir par exemple [4, section 6.5.4].

⁽¹⁰⁾. On considère ici que $\zeta \neq 0$. En effet, dans le cas où $\zeta = 0$, on a $\mu_\zeta = 0$ et la matrice $B_0 = \begin{pmatrix} 2 & -1 \\ 1 & 0 \end{pmatrix}$ admet la valeur propre 1 comme valeur propre double. Elle n'est pas diagonalisable mais est trigonalisable. On a par exemple $B_0 = P T P^{-1}$ avec

$$T = \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix} \quad \text{et} \quad P = \begin{pmatrix} 1 & 1 \\ 1 & 0 \end{pmatrix}.$$

l'infini de façon géométrique. On ne peut majorer $|u^{[n]}(\zeta)|$ par une quantité indépendante de n dans ce cas. Il n'y a donc pas stabilité du schéma si $\mu_\zeta^2 > 2$.

Cas 2 $\mu_\zeta^2 < 2$. Intéressons-nous au cas où $0 < \mu_\zeta^2 < 2$. La matrice B_ζ possède deux valeurs propres distinctes, complexes conjuguées l'une de l'autre et de module 1. Ces deux valeurs propres sont donc de la forme $\lambda_\pm = e^{\pm i\theta_\zeta}$ pour un réel $\theta_\zeta \in [0, \pi[$ et la relation (5.53) donne

$$V_\zeta^{[n]} = P_\zeta \begin{pmatrix} e^{-i(n-1)\theta_\zeta} & 0 \\ 0 & e^{i(n-1)\theta_\zeta} \end{pmatrix} P_\zeta^{-1} V_\zeta^{[1]}$$

La matrice P_ζ est obtenue en calculant les vecteurs propres associés à ces deux valeurs propres. On obtient

$$P_\zeta = \begin{pmatrix} e^{-i\theta_\zeta} & e^{i\theta_\zeta} \\ 1 & 1 \end{pmatrix} \quad \text{et} \quad P_\zeta^{-1} = \frac{1}{e^{i\theta_\zeta} - e^{-i\theta_\zeta}} \begin{pmatrix} -1 & e^{i\theta_\zeta} \\ 1 & -e^{-i\theta_\zeta} \end{pmatrix}$$

On a

$$P_\zeta D_\zeta^{n-1} P_\zeta^{-1} = \frac{1}{\sin(\theta)} \begin{pmatrix} \sin(n\theta_\zeta) & -\sin((n-1)\theta_\zeta) \\ \sin((n-1)\theta_\zeta) & -\sin((n-2)\theta_\zeta) \end{pmatrix}$$

de sorte que

$$\hat{u}_{h_x}^{[n]}(\zeta) = \frac{1}{\sin(\theta_\zeta)} (\sin(n\theta_\zeta) \hat{u}_{h_x}^{[1]}(\zeta) - \sin((n-1)\theta_\zeta) \hat{u}_{h_x}^{[0]}(\zeta)). \quad (5.47)$$

Comme

$$\hat{u}_{h_x}^{[0]}(\zeta) = \widehat{\Pi_{h_x} u_0}(\zeta) \quad \forall \zeta \in \mathbb{R} \quad (5.48a)$$

et

$$\begin{aligned} \hat{u}_{h_x}^{[1]}(\zeta) &= h_t \widehat{\Pi_{h_x} u_1}(\zeta) + (1 - 2\alpha^2 \sin^2(\pi\zeta h_x)) \widehat{\Pi_{h_x} u_0}(\zeta) \\ &= h_t \widehat{\Pi_{h_x} u_1}(\zeta) + (1 - \mu_\zeta^2) \widehat{\Pi_{h_x} u_0}(\zeta) \end{aligned} \quad (5.48b)$$

on déduit de (5.47) en utilisant les égalités trigonométriques que

$$\hat{u}_{h_x}^{[n]}(\zeta) = h_t \frac{\sin(n\theta_\zeta)}{\sin(\theta_\zeta)} \widehat{\Pi_{h_x} u_1}(\zeta) + \cos(n\theta_\zeta) \widehat{\Pi_{h_x} u_0}(\zeta). \quad (5.49)$$

Pour tout $n \in \mathbb{N}$, on a $|\cos(n\theta_\zeta)| \leq 1$ et

$$\left| \frac{\sin(n\theta_\zeta)}{\sin(\theta_\zeta)} \right| = \left| \frac{1 - e^{2in\theta_\zeta}}{1 - e^{2i\theta_\zeta}} \right| = \left| \sum_{k=0}^{n-1} e^{2ik\theta_\zeta} \right| \leq \sum_{k=0}^{n-1} |e^{2ik\theta_\zeta}| = n.$$

On a donc ⁽¹¹⁾

$$\|\hat{u}_{h_x}^{[n]}\|_{\mathbb{L}^2(\mathbb{R})} \leq \underbrace{n h_t}_{=t_n} \|\widehat{\Pi_{h_x} u_1}\|_{\mathbb{L}^2(\mathbb{R})} + \|\widehat{\Pi_{h_x} u_0}\|_{\mathbb{L}^2(\mathbb{R})} \quad (5.50)$$

puis en utilisant l'égalité de Parseval,

$$\|u_{h_x}^{[n]}\|_{\mathbb{L}^2(\mathbb{R})} \leq t_n \|\Pi_{h_x} u_1\|_{\mathbb{L}^2(\mathbb{R})} + \|\Pi_{h_x} u_0\|_{\mathbb{L}^2(\mathbb{R})} \quad (5.51)$$

Le schéma est donc stable sur tout intervalle borné $[0, T]$.

Remarque 5.4 La relation (5.41) indique que pour tout $\zeta \in \mathbb{R}$, la suite $(\hat{u}_{h_x}^{[n+1]}(\zeta))_{n \in \mathbb{N}}$ est une suite récurrente d'ordre 2. Les suites récurrentes vérifiant la relation (5.41) forment un espace vectoriel de dimension 2. Une alternative à l'approche qui vient d'être présentée est de rechercher une base de cet espace vectoriel sous la forme de deux suites géométriques $(r^n)_{n \in \mathbb{N}}$ où $r \in \mathbb{C}$, $r \neq 0$. La relation (5.41) impose que

$$r^2 - 2(1 - \mu_\zeta^2)r + 1 = 0. \quad (5.52)$$

Cette équation coïncide avec l'équation caractéristique (5.45). On distingue trois cas.

⁽¹¹⁾. Noter ici que le cas particulier correspondant $\zeta = 0$ n'a pas besoin d'être pris en compte, $\{0\}$ correspondant à un ensemble de mesure de Lebesgue nulle.

- Si $\mu_\zeta^2 > 2$ alors l'équation (5.52) a deux racines réelles distinctes r_+ et r_- telles que $r_+ r_- = 1$ données par

$$r_\pm = (1 - \mu_\zeta^2) \pm \mu_\zeta \sqrt{\mu_\zeta^2 - 2}.$$

Les suites récurrentes vérifiant la relation (5.41) sont dans ce cas de la forme

$$\widehat{u}_{h_x}^{[n]}(\zeta) = A_\zeta \lambda_-^n + B_\zeta \lambda_+^n$$

avec $A_\zeta, B_\zeta \in \mathbb{R}$. Notons que comme λ_- et λ_+ sont des réels distincts tels que $\lambda_+ \lambda_- = 1$, on a nécessairement l'un de ces deux réels dont la valeur absolue est strictement supérieure à 1. Cela implique que $\widehat{u}_{h_x}^{[n]}(\zeta)$ n'est pas bornée quand n tend vers $+\infty$. Il ne peut y avoir stabilité dans ce cas.

- Si $\mu_\zeta^2 < 2$ alors l'équation (5.52) admet deux racines complexes conjuguées distinctes r_+ et r_- telles que $|r_+| = |r_-| = 1$ données par

$$r_\pm = (1 - \mu_\zeta^2) \pm i \mu_\zeta \sqrt{2 - \mu_\zeta^2}.$$

On désigne par θ_ζ un réel non nul tel que $\lambda_\pm = e^{\pm i\theta_\zeta}$. Les suites récurrentes vérifiant la relation (5.41) sont dans ce cas de la forme

$$\widehat{u}_{h_x}^{[n]}(\zeta) = A_\zeta e^{-in\theta_\zeta} + B_\zeta e^{in\theta_\zeta}$$

avec $A_\zeta, B_\zeta \in \mathbb{R}$. On notera que pour tout $\zeta \in \mathbb{R}$, la suite $(\widehat{u}_{h_x}^{[n]}(\zeta))_{n \in \mathbb{N}}$ est bornée.

- Si $\mu_\zeta^2 = 2$ alors l'équation (5.52) admet une racine double qui vaut $\lambda = 1 - \mu_\zeta^2 = -1$. Les suites récurrentes vérifiant la relation (5.41) sont dans ce cas de la forme

$$\widehat{u}_{h_x}^{[n]}(\zeta) = A_\zeta r^n + B_\zeta n r^n = A_\zeta (-1)^n + B_\zeta (-1)^n n$$

avec $A_\zeta, B_\zeta \in \mathbb{R}$.

Dans les relations précédentes, les valeurs de A_ζ et B_ζ sont déterminées par les conditions initiales (5.40b) et (5.40c) auxquelles on applique une transformée de Fourier, c'est-à-dire à partir des relations (5.48b) et (5.48b). Intéressons-nous au cas $\mu_\zeta^2 < 2$. On a

$$\begin{cases} \widehat{u}_{h_x}^{[0]}(\zeta) = A_\zeta + B_\zeta \\ \widehat{u}_{h_x}^{[1]}(\zeta) = A_\zeta e^{-i\theta_\zeta} + B_\zeta e^{i\theta_\zeta} \end{cases}$$

En résolvant ce système, il vient

$$\begin{aligned} A_\zeta &= \frac{\widehat{u}_{h_x}^{[0]}(\zeta) e^{i\theta_\zeta} - \widehat{u}_{h_x}^{[1]}(\zeta)}{2i \sin(\theta_\zeta)} \\ &= \frac{i}{2 \sin(\theta_\zeta)} \left(h_t \widehat{\Pi_{h_x} u_1}(\zeta) + (1 - \mu_\zeta^2 - e^{i\theta_\zeta}) \widehat{\Pi_{h_x} u_0}(\zeta) \right) \\ B_\zeta &= \widehat{u}_{h_x}^{[0]}(\zeta) - A_\zeta \\ &= -\frac{i}{2 \sin(\theta_\zeta)} h_t \widehat{\Pi_{h_x} u_1}(\zeta) + \left(1 + \frac{1 - \mu_\zeta^2 - e^{i\theta_\zeta}}{2i \sin(\theta_\zeta)} \right) \widehat{\Pi_{h_x} u_0}(\zeta). \end{aligned}$$

Notons que $r = e^{i\theta_\zeta}$ est solution de l'équation (5.52), dont on déduit que

$$1 - \mu_\zeta^2 = \frac{r^2 + 1}{2r} = \frac{1}{2} (r + r^{-1}) = \frac{1}{2} (e^{i\theta_\zeta} + e^{-i\theta_\zeta}) = \cos(\theta_\zeta),$$

de sorte que $1 - \mu_\zeta^2 - e^{i\theta_\zeta} = -i \sin(\theta_\zeta)$. On en déduit que

$$\widehat{u}_{h_x}^{[n]}(\zeta) = A_\zeta e^{-in\theta_\zeta} + B_\zeta e^{in\theta_\zeta} = h_t \frac{\sin(n\theta_\zeta)}{\sin(\theta_\zeta)} \widehat{\Pi_{h_x} u_1}(\zeta) + \cos(n\theta_\zeta) \widehat{\Pi_{h_x} u_0}(\zeta)$$

On retrouve la relation (5.49) et on peut conclure de la même manière que précédemment.

Cas 3 $\mu_\zeta^2 = 2$. Il nous reste à présent à étudier le cas où $\mu_\zeta^2 = 2$. La situation est un peu différente des précédentes dans la mesure où la matrice B_ζ n'est pas diagonalisable. Elle s'écrit

$$B_\zeta = \begin{pmatrix} -2 & -1 \\ 1 & 0 \end{pmatrix}.$$

Le réel -1 est valeur propre double et le sous-espace propre associé, qui est engendré par le vecteur $Y = \begin{pmatrix} 1 \\ -1 \end{pmatrix}$, est de dimension 1. La matrice B_ζ est trigonalisable.⁽¹²⁾ Complétons le vecteur Y par le vecteur $Z = \begin{pmatrix} -1 \\ 0 \end{pmatrix}$ afin de disposer d'une base de $\mathbb{R}^2$. On a $B_\zeta Z = \begin{pmatrix} 2 \\ -1 \end{pmatrix} = Y - Z$, de sorte que $B_\zeta = P T P^{-1}$ avec

$$T = \begin{pmatrix} -1 & 1 \\ 0 & -1 \end{pmatrix}, \quad P = \begin{pmatrix} 1 & -1 \\ -1 & 0 \end{pmatrix} \quad \text{et} \quad P^{-1} = \begin{pmatrix} 0 & -1 \\ -1 & -1 \end{pmatrix}.$$

Un raisonnement par récurrence immédiat permet d'établir que pour tout $n \in \mathbb{N}^*$, on a

$$T^n = (-1)^n \begin{pmatrix} 1 & -n \\ 0 & 1 \end{pmatrix}.$$

On obtient alors

$$V_\zeta^{[n]} = P T^{n-1} P^{-1} V_\zeta^{[1]} = (-1)^{n+1} \begin{pmatrix} n & n-1 \\ 1-n & 2-n \end{pmatrix} V_\zeta^{[1]} \quad (5.53)$$

puis, en considérant la première des composantes,

$$\widehat{u}_{h_x}^{[n]}(\zeta) = (-1)^{n+1} n \widehat{u}_{h_x}^{[1]}(\zeta) + (-1)^{n+1} (n-1) \widehat{u}_{h_x}^{[0]}(\zeta).$$

En utilisant les relations (5.48a) et (5.48b) donnant $\widehat{u}_{h_x}^{[1]}(\zeta)$ et $\widehat{u}_{h_x}^{[0]}(\zeta)$, on obtient finalement

$$\widehat{u}_{h_x}^{[n]}(\zeta) = (-1)^{n+1} n h_t \widehat{\Pi_{h_x} u_1}(\zeta) + (-1)^n \widehat{\Pi_{h_x} u_0}(\zeta).$$

On en conclut que

$$\|\widehat{u}_{h_x}^{[n]}\|_{\mathbb{L}^2(\mathbb{R})} = n h_t \|\widehat{\Pi_{h_x} u_1}\|_{\mathbb{L}^2(\mathbb{R})} + \|\widehat{\Pi_{h_x} u_0}\|_{\mathbb{L}^2(\mathbb{R})},$$

puis en utilisant l'égalité de Parseval, que

$$\|u_{h_x}^{[n]}\|_{\mathbb{L}^2(\mathbb{R})} = t_n \|\Pi_{h_x} u_1\|_{\mathbb{L}^2(\mathbb{R})} + \|\Pi_{h_x} u_0\|_{\mathbb{L}^2(\mathbb{R})}. \quad (5.54)$$

Le schéma est donc stable sur tout intervalle de temps borné.

5.5 Erreur sur l'initialisation du schéma

Il nous reste à étudier l'erreur commise à l'initialisation du schéma. L'erreur sur l'initialisation au temps t_0 est nulle puisque $u_j^{[0]} = u_0(x_j)$ pour tout $j \in \mathbb{Z}$. Intéressons-nous à l'erreur commise au temps t_1 qui est donnée par $e_j^{[1]} = u(x_j, t_1) - u_j^{[1]}$ pour tout $j \in \mathbb{Z}$ où, d'après (5.26), on a

$$u_j^{[1]} = u_0(x_j) + h_t u_1(x_j) + \frac{c^2 h_t^2}{2h_x^2} (u_0(x_{j-1}) - 2u_0(x_j) + u_0(x_{j+1})) + \frac{1}{2} h_t^2 f(x_j, 0).$$

Appliquons la formule de Taylor-Lagrange à l'ordre 3 entre 0 et h_t en un point x_j fixé. Il existe $\theta_1 \in]0, 1[$ tel que

$$\begin{aligned} u(x_j, h_t) &= u(x_j, 0) + h_t \partial_t u(x_j, 0) + \frac{1}{2} h_t^2 \partial_t^2 u(x_j, 0) + \frac{1}{6} h_t^3 \partial_t^3 u(x_j, \theta_1 h_t) \\ &= u_0(x_j) + h_t u_1(x_j) + \frac{1}{2} h_t^2 \partial_t^2 u(x_j, 0) + \frac{1}{6} h_t^3 \partial_t^3 u(x_j, \theta_1 h_t). \end{aligned}$$

⁽¹²⁾. Voir par exemple [4, section 12.4.3] pour des rappels sur la trigonalisation de matrices.

On a donc

$$\begin{aligned} e_j^{[1]} &= \frac{1}{2} h_t^2 \partial_t^2 u(x_j, 0) + \frac{1}{6} h_t^3 \partial_t^3 u(x_j, \theta_1 h_t) - \frac{c^2 h_t^2}{2 h_x^2} (u_0(x_{j-1}) - 2u_0(x_j) + u_0(x_{j+1})) - \frac{1}{2} h_t^2 f(x_j, 0) \\ &= \frac{c^2 h_t^2}{2} \partial_x^2 u(x_j, 0) - \frac{c^2 h_t^2}{2 h_x^2} (u_0(x_{j-1}) - 2u_0(x_j) + u_0(x_{j+1})) + \frac{1}{6} h_t^3 \partial_t^3 u(x_j, \theta_1 h_t) \end{aligned} \quad (5.55)$$

car comme u est solution de classe $\mathcal{C}^4$ du problème $(\mathcal{P})$, on a $\partial_{tt}^2 u(x_j, 0) - c^2 \partial_x^2 u(x_j, 0) = f(x_j, 0)$.

D'après la formule de Taylor-Lagrange à l'ordre 3 appliquée à la donnée u_0 entre x_j et $x_{j+1} = x_j + h_x$, il existe $\theta_2 \in]0, 1[$ tel que

$$u_0(x_j + h_x) = u_0(x_j) + h_x u_0'(x_j) + \frac{1}{2} h_x^2 u_0''(x_j) + \frac{1}{6} h_x^3 u_0^{(3)}(x_j) + \frac{1}{24} h_x^4 u_0^{(4)}(x_j + \theta_2 h_x).$$

Par ailleurs, d'après la formule de Taylor-Lagrange à l'ordre 3 appliquée à la donnée u_0 entre x_j et $x_{j-1} = x_j - h_x$, il existe $\theta_3 \in]-1, 0[$ tel que

$$u_0(x_j - h_x) = u_0(x_j) - h_x u_0'(x_j) + \frac{1}{2} h_x^2 u_0''(x_j) - \frac{1}{6} h_x^3 u_0^{(3)}(x_j) + \frac{1}{24} h_x^4 u_0^{(4)}(x_j + \theta_3 h_x).$$

En sommant ces deux expressions, nous obtenons

$$\frac{u_0(x_{j+1}) - 2u_0(x_j) + u_0(x_{j-1}))}{h_x^2} = u_0''(x_j) + \frac{1}{24} h_x^2 (u_0^{(4)}(x_j + \theta_2 h_x) + u_0^{(4)}(x_j + \theta_3 h_x)) \quad (5.56)$$

avec $u_0''(x_j) = \partial_x^2 u(x_j, 0)$.

D'après (5.55), on a donc

$$e_j^{[1]} = \frac{1}{6} h_t^3 \partial_t^3 u(x_j, \theta_1 h_t) - \frac{1}{48} c^2 h_t^2 h_x^2 (u_0^{(4)}(x_j + \theta_2 h_x) + u_0^{(4)}(x_j + \theta_3 h_x)).$$

On en déduit que pour tout $j \in \mathbb{Z}$,

$$|e_j^{[1]}| \leq \frac{1}{6} h_t^2 \left(M_t^{(3)} h_t^2 + \frac{c^2}{4} M_{x,0}^{(4)} h_x^2 \right) \quad (5.57)$$

où $M_{x,0}^{(4)} = \sup_{x \in \mathbb{R}} |\partial_x^4 u(x, 0)|$ et $M_t^{(3)} = \sup_{(x,t) \in \mathbb{R} \times \mathbb{R}^+} |\partial_t^3 u(x, t)|$.

5.6 Illustrations numériques

On s'intéresse à la résolution du problème $(\mathcal{P})$ défini en (5.1) par le schéma d'approximation $(\mathcal{S})$ formé des relations (5.31)–(5.32) pour les données suivantes : $u_0(x, t) = \frac{1}{\sqrt{2\pi}} \exp(-\frac{1}{2}x^2)$, $u_1 \equiv 0$, $f \equiv 0$. On prend un intervalle de temps pour la simulation valant $T = 10$ et une subdivision uniforme de $[0, T]$ en $N = 100$ sous-intervalles. En tout temps $t \in [0, T]$, le support de la solution reste strictement inclus dans l'intervalle $[a, b]$ pour $a = -15$ et $b = 15$. On considère une subdivision uniforme de $[a, b]$ en $J = 200$ sous-intervalles. On a représenté à la figure 4 les variations de la solution en temps et en espace dans le domaine $[a, b] \times [0, T]$. On voit clairement la solution initiale u_0 se scinder en deux ondes, l'une se dirigeant vers la droite et l'autre se dirigeant vers la gauche. Comme $u_1 \equiv 0$, $f \equiv 0$, la formule de D'Alembert, voir la relation (5.16), indique que pour tout $(x, t) \in \mathbb{R} \times \mathbb{R}^+$ on a $u(x, t) = \frac{1}{2} (u_0(x + ct) + u_0(x - ct))$. L'onde se dirigeant vers la gauche correspond à $\frac{1}{2} u_0(x + ct)$ alors que l'onde se dirigeant vers la droite correspond à $\frac{1}{2} u_0(x - ct)$.

5.6.1 Étude de l'erreur commise

On s'intéresse à présent à l'erreur relative ϵ commise où

$$\epsilon^2 = \frac{\sum_{n=1}^N \sum_{j=1}^{J-1} |u(x_j, t_n) - u_j^{[n]}|^2}{\sum_{n=1}^N \sum_{j=1}^{J-1} |u(x_j, t_n)|^2}.$$




FIG. 4 Évolution au cours du temps de la solution de l'équation des ondes pour $u_0(x, t) = \frac{1}{\sqrt{2\pi}} \exp(-\frac{1}{2}x^2)$, $u_1 \equiv 0$, $f \equiv 0$. A droite vue du dessus.




FIG. 5 Erreur relative ϵ en fonction de la valeur du nombre CFL α en échelle logarithmique.

où la solution exacte est obtenue par la formule de D'Alembert.

Dans le cas où $N = 100$ et $J = 200$, l'erreur relative ϵ vaut 0.396% alors qu'en prenant $N = 1000$ et $J = 2000$, elle vaut 0.00394%. Notons que dans ces deux cas, la condition CFL est satisfaite et le nombre CFL est le même et vaut $\alpha = \frac{ch_t}{h_x} = \frac{2}{3}$. On observe que l'erreur relative calculée globalement sur $[a, b] \times [0, T]$ décroît de 10^2 ce qui est conforme à ce qui est attendu, les pas ayant décru de 10 entre les deux simulations et le schéma étant d'ordre 2 en temps et en espace.

On s'intéresse à présent à l'évolution de l'erreur relative ϵ en fonction du nombre CFL $\alpha = c \frac{h_t}{h_x}$. On reprend l'exemple précédent et on fixe le nombre N de sous-intervalles de la subdivision en temps à $N = 1000$. On a représenté à la figure 5 l'erreur relative ϵ en fonction de la valeur du nombre CFL α en échelle logarithmique.

La pente de la droite de régression linéaire est de -2.1551 . Cette valeur de la pente est cohérente avec la théorie. On a fixé $N = 1000$, ce qui donne $h_t = 10^{-2}$ et on fait varier h_x . Partant du résultat : il existe $C > 0$ tel que pour tout $n \in \{0, \dots, N\}$ on ait $\|e_{h_x}^{[n]}\|_{L^2(\mathbb{R})} \leq C(h_x^2 + h_t^2)$, et de la relation $h_x = \alpha^{-1}ch_t$,

on obtient

$$\|e_{h_x}^{[n]}\|_{\mathbb{L}^2(\mathbb{R})} \leq Ch_t^2(1 + c^2\alpha^{-2})$$

avec $c = 1$. On en déduit que

$$\log\left(\|e_{h_x}^{[n]}\|_{\mathbb{L}^2(\mathbb{R})}\right) \leq \log(Ch_t^2) + \log(1 + \alpha^{-2})$$

Pour α petit devant 1, on a $\log(1 + \alpha^{-2}) \approx \log(\alpha^{-2}) = -2 \log(\alpha)$.

On notera que pour $\alpha = 1$, l'erreur est nettement plus petite. Cela peut être mis en relation avec le fait que pour $\alpha = 1$, on montre que pour $f \equiv 0$, l'erreur de consistance est nulle, voir le lemme 5.1.

À l'inverse, on notera que l'erreur croît de façon très forte dès que la condition CFL n'est plus respectée, c'est-à-dire pour $\alpha > 1$. La condition de stabilité $\alpha \leq 1$ est une condition stricte. On observe sur la figure 5 que pour la valeur $\alpha = 1.000333$, l'erreur relative est de 10^6 .

5.6.2 Étude des variations de l'énergie

L'énergie au temps t_n associée à une solution u du problème $(\mathcal{P})$ est donnée par, voir la relation (5.18)

$$\mathcal{E}(t_n) = \frac{1}{2} \int_{\mathbb{R}} \left[\left(\frac{\partial u}{\partial t}(x, t_n) \right)^2 + c^2 \left(\frac{\partial u}{\partial x}(x, t_n) \right)^2 \right] dx.$$

Pour obtenir une expression approchée de cette énergie dans le cas de l'exemple considéré, on restreint l'intégrale à l'intervalle $[a, b]$ puisqu'en tout temps la solution est à support strictement inclus dans $[a, b]$, puis en se basant sur la subdivision $(x_j)_{j=0, \dots, J}$ de l'intervalle $[a, b]$, on utilise la formule des trapèzes. On obtient ainsi,

$$\mathcal{E}(t_n) = \frac{1}{2} \sum_{j=0}^{J-1} \int_{x_j}^{x_{j+1}} g(x, t_n) dx \approx \frac{h_x}{4} \sum_{j=0}^{J-1} (g(x_j, t_n) + g(x_{j+1}, t_n)) = \frac{h_x}{2} \sum_{j=1}^{J-1} g(x_j, t_n)$$

où on a noté $g(x, t_n) = \left(\frac{\partial u}{\partial t}(x, t_n) \right)^2 + c^2 \left(\frac{\partial u}{\partial x}(x, t_n) \right)^2$ et exploité le fait que $g(a, t_n) = g(b, t_n) = 0$.

Pour calculer $g(x, t_n)$, on approche les dérivées partielles par des différences divisées basées sur la subdivision $(x_j)_{j=0, \dots, J}$ de l'intervalle $[a, b]$ et la subdivision $(t_n)_{n=0, \dots, N}$ de l'intervalle $[0, T]$. Ainsi,

$$\begin{aligned} \frac{\partial u}{\partial t}(x_j, t_n) &\approx \frac{u(x_j, t_{n+1}) - u(x_j, t_{n-1})}{2h_t} \approx \frac{u_j^{[n+1]} - u_j^{[n-1]}}{2h_t} \\ \frac{\partial u}{\partial x}(x_j, t_n) &\approx \frac{u(x_{j+1}, t_n) - u(x_{j-1}, t_n)}{2h_x} \approx \frac{u_{j+1}^{[n]} - u_{j-1}^{[n]}}{2h_x} \end{aligned}$$

On en déduit que

$$\mathcal{E}(t_n) \approx \frac{h_x}{8} \sum_{j=1}^{J-1} \left(\frac{1}{h_t^2} (u_j^{[n+1]} - u_j^{[n-1]})^2 + \frac{c^2}{h_x^2} (u_{j+1}^{[n]} - u_{j-1}^{[n]})^2 \right). \quad (5.58)$$

On a représenté à la figure 6 les variations de l'énergie autour de sa valeur moyenne au cours du temps pour l'exemple considéré avec $N = 100$ et $J = 200$ pour la représentation graphique de gauche et $N = 500$ et $J = 1000$ pour la représentation graphique de droite. On observe une petite fluctuation des valeurs de l'énergie en début de simulation par rapport à la valeur moyenne sur la durée de la simulation. Cette fluctuation est de l'ordre de 1% sur la figure de gauche et de l'ordre de 0.005% sur celle de droite. L'amplitude de ces variations diminue lorsque les pas h_x et h_t diminuent. Ces résultats sont conformes à la propriété de conservation de l'énergie au cours du temps en l'absence de terme source ($f \equiv 0$) qui a été établi à la proposition 5.1.




FIG. 6 Variations de l'énergie autour de sa valeur moyenne au cours du temps pour l'exemple considéré. On a une discrétisation avec $N = 100$ et $J = 200$ pour la figure de gauche et $N = 500$ et $J = 1000$ pour la figure de droite.

Bibliographie

- [1] G. Agrawal. *Nonlinear fiber optics*. Academic Press, 2001.
- [2] S. Balac. *Selected topics on mathematical modeling in photonics*. Lecture notes of the first summer school in computational science and applications to photonics, Rennes, 2015.
- [3] S. Balac and L. Chupin. *Analyse et algèbre, cours de mathématiques deuxième année avec exercices corrigés*. Collection Metis Lyon Tech. Presses Polytechnique et Universitaires Romandes, Lausanne, 2007.
- [4] S. Balac and F. Sturm. *Algèbre et analyse, cours de mathématiques première année avec exercices corrigés*. Collection Metis Lyon Tech. Presses Polytechnique et Universitaires Romandes, Lausanne, 2014. Troisième édition.
- [5] M. Crouzeix and A.L. Mignot. *Analyse numérique des équations différentielles*. Collection mathématiques appliquées pour la maîtrise. Masson, 1992.
- [6] R. Dautray and J.L. Lions. *Analyse mathématique et calcul numérique pour les sciences et les techniques*. Masson, 1987.
- [7] J.P. Demailly. *Analyse numérique et équations différentielles*. Collection Grenoble sciences. EDP Sciences, 2006.
- [8] D. Euvrard. *Résolution numérique des équations aux dérivées partielles de la physique, de la mécanique et des sciences de l'ingénieur : différences finies, éléments finis, problèmes en domaine non borné*. Enseignement de la physique. Masson, 1994.
- [9] R.P. Feynman, R.B. Leighton, and M.L. Sands. *Le cours de physique de Feynman : Électromagnétisme 1 & 2*. Dunod, 2013.
- [10] P. Lascaux and R. Théodor. *Analyse numérique matricielle appliquée à l'art de l'ingénieur (2 vol.)*. Dunod, 2004.
- [11] V. Lefèvre and P. Zimmermann. Arithmétique flottante. Research Report RR-5105, INRIA, 2004.
- [12] B. Lucquin and O. Pironneau. *Introduction au calcul scientifique*. Collection Mathématiques appliquées pour la maîtrise. Masson, 1996.
- [13] J.-M. Muller. *Elementary Functions : Algorithms and Implementation*. Birkhauser, 2005.
- [14] J.P. Pérez, C. Lagoute, J.Y. Fourniols, and S. Bouhours. *Électronique. Fondements et applications*. Dunod, 2012.
- [15] P. Struillou. *Analyse de Fourier : Théorie et applications pour l'ingénieur et le physicien, Cours et exercices corrigés*. Technosup. Ellipses, 2012.

Index

- Advection, [103](#)
- Cauchy-Lipschitz
 - théorème, [5](#)
- CFL
 - nombre, [124](#)
- Condition
 - aux limites de Dirichlet, [49](#)
 - aux limites de Neumann, [49](#)
 - initiale, [74](#)
- Conservation de l'énergie, [146](#)
- Consistance, [32](#), [59](#)
- D'Alembert, formule, [145](#)
- Diffusion, [103](#)
- Différence finie
 - centrée d'ordre 1, [57](#)
 - progressive d'ordre 1, [56](#)
 - rétrograde d'ordre 1, [57](#)
- Dirichlet
 - condition aux limites, [49](#)
 - problème, [50](#)
- Domaine
 - de stabilité, [125](#)
- Définie positive
 - matrice, [27](#)
- Ellipse, [37](#)
- Elliptique
 - équation, [37](#)
- Erreur
 - de consistance, [32](#), [59](#)
- Formule
 - différence finie centrée d'ordre 1, [57](#)
 - différence finie progressive d'ordre 1, [56](#)
 - différence finie rétrograde d'ordre 1, [57](#)
- Formule de d'Alembert, [145](#)
- Fourier
 - loi, [4](#)
- Hadamard, [6](#)
 - lemme, [20](#)
- Hyperbole, [37](#)
- Hyperbolique
 - équation, [38](#)
- Lax
 - principe de, [34](#)
- Lemme
 - de Hadamard, [20](#)
- Loi
 - de comportement, [45](#)
 - de Fourier, [4](#)
- Matrice
 - définie positive, [27](#)
 - irréductible, [21](#)
 - monotone, [26](#)
 - réductible, [21](#)
 - à diagonale dominante, [19](#)
 - à diagonale fortement dominante, [19](#)
 - à diagonale strictement dominante, [19](#)
- Maximum
 - principe, [50](#)
 - principe du, [10](#)
- Monotone
 - matrice, [26](#)
- Neumann
 - condition aux limites, [49](#)
 - problème, [50](#)
- Newton
 - deuxième loi, [2](#)
- Nombre
 - CFL, [124](#)
- Ordre
 - d'un schéma aux différences finies, [33](#), [34](#), [60](#)
- Parabole, [37](#)
- Parabolique
 - équation, [38](#)
- Permutation, [22](#)
- Principe
 - de Lax, [34](#)
 - du Maximum, [10](#)
 - du maximum, [50](#)
- Problème
 - bien posé, [6](#)
 - de Dirichlet, [50](#)
 - de Dirichlet-Neumann, [49](#)
 - de Neumann, [50](#)
- Rayon spectral, [27](#)
- Schrödinger, [38](#)
- semi-groupe, [107](#)
- Stabilité
 - domaine, [125](#)
- Théorème
 - de Cauchy-Lipschitz, [5](#)
- Tricomi, [38](#)

Zone d'influence, [146](#)

Équation

d'advection, [103](#)

d'advection-diffusion, [103](#)

de convection-diffusion, [103](#)

de la chaleur, [4](#)

de Schrödinger, [38](#)

de Tricomi, [38](#)

des cordes vibrantes, [3](#)

des ondes, [3](#)

elliptique, [37](#)

hyperbolique, [38](#)

parabolique, [38](#)