Chapitre 2

Approximation par la méthode des éléments finis d'un problème de thermique en régime dynamique

2.1 Modélisation mathématique de problèmes de thermique

Considérons un objet isotrope occupant un domaine [(1)] Ω de $\mathbb{R}^3$. Le mécanisme de transfert de chaleur par conduction peut être décrit par l'équation suivante ayant pour inconnue la température T, fonction de la variable d'espace $x \in \Omega$ et de temps $t \in \mathbb{R}^+$:

$$\rho\, c_p\, \frac{\partial T}{\partial t}(x,t) - \mathrm{div}_x(k\, \nabla_x T(x,t)) = Q(x,t) \qquad \forall x \in \Omega \quad \forall t \in \mathbb{R}^+ \tag{2.1}$$

où ρ désigne la densité volumique du matériau (unité SI $[\mathrm{Kg\,m^{-3}}]$), k désigne sa conductivité thermique (unité $[\mathrm{W\,m^{-1}\,K^{-1}}]$), c_p désigne sa capacité calorifique spécifique (unité $[\mathrm{J\,Kg^{-1}\,K^{-1}}]$) et Q désigne la densité de chaleur générée par unité de volume $[\mathrm{W\,m^{-3}}]$. On sera attentif au fait que dans l'équation (2.1), couramment appelée *equation de la chaleur*, la dérivation pour les opérateurs divergence et gradient est relative à la variable d'espace uniquement (d'où la notation div_x et ∇_x adoptée). La conductivité thermique k peut avoir des valeurs variant en fonction de la position, par exemple dans le cas d'un domaine qui ne serait pas homogène.

On introduit par ailleurs le flux de chaleur $\mathbf{q}$ tel que

$$\mathbf{q}(x,t) = -k\, \nabla_x T(x,t). \tag{2.2}$$

Il convient de préciser les conditions aux limites à la frontière Σ de l'ouvert Ω. Ces conditions aux limites peuvent prendre des formes différentes selon le type d'échange thermique entre le domaine Ω est le domaine extérieur que l'on souhaite prendre en compte.

1. On peut par exemple avoir une condition de Dirichlet de la forme

$$T(x,t) = T_a(x,t) \qquad \forall x \in \Sigma \quad \forall t \in \mathbb{R}^+ \tag{2.3}$$

   où T_a désigne une température imposée.

2. Il est toutefois plus fréquent en pratique de devoir imposer le flux de chaleur à travers Σ sous la forme

$$\mathbf{q} \cdot \mathbf{n} = -\alpha\, q_s$$

   où q_s est un flux de chaleur donné par unité de surface et α est le coefficient absorption surfacique du matériau. Compte tenu de (2.2), cette condition aux limites correspond à une condition de Neumann

$$\frac{\partial T}{\partial n}(x,t) = -\alpha\, q_s(x,t) \qquad \forall x \in \Sigma \quad \forall t \in \mathbb{R}^+. \tag{2.4}$$

(1). C'est-à-dire un ouvert connexe de $\mathbb{R}^3$.

3. On peut enfin vouloir prendre en compte un phénomène de convection avec le milieu extérieur (par exemple, convection avec l'air extérieur). Cela se traduit par la condition aux limites

$$\mathbf{q}\cdot\mathbf{n} = h(T - T_a)$$

où T_a est la température ambiante extérieure et h est le coefficient de convection thermique (unité $[\mathrm{W\,m^{-2}\,K^{-1}}]$). Cette condition aux limites correspond à la condition aux limites de Fourier suivante pour T :

$$\frac{\partial T}{\partial n}(x,t) - h\,T(x,t) = h\,T_a(x,t) \qquad \forall x \in \Sigma \quad \forall t \in \mathbb{R}^+. \tag{2.5}$$

Ces conditions aux limites peuvent être mêlées en étant imposées sur différentes parties du bord formant une partition de Σ. Il doit dans ce cas y avoir une condition aux limites et une seule sur chaque partie du bord.

On pourra noter que dans le cas où le milieu Ω est un milieu homogène, la conductivité thermique est constante et l'équation de la chaleur prend la forme

$$\rho\,c_p\,\frac{\partial T}{\partial t}(x,t) - k\,\Delta_x T(x,t) = Q(x,t) \qquad \forall x \in \Omega \quad \forall t \in \mathbb{R}^+ \tag{2.6}$$

Par ailleurs, considérons le changement de variables défini par

$$\widetilde{x} = \frac{x}{L}, \qquad \widetilde{t} = \frac{k}{L^2\rho\,c_p}\,t \tag{2.7}$$

où L désigne une distance caractéristique du domaine Ω (par exemple, le rayon de la sphère inscrite dans Ω). On vérifiera sans difficulté que $\widetilde{x}$ et $\widetilde{t}$ sont des variables sans dimension. En désignant par $\widetilde{T}$ la nouvelle fonction inconnue telle que $\widetilde{T}(\widetilde{x},\widetilde{t}) = T(x,t)$, on déduit de (2.6) que $\widetilde{T}$ vérifie

$$\frac{\partial \widetilde{T}}{\partial \widetilde{t}}(\widetilde{x},\widetilde{t}) - \Delta_{\widetilde{x}}\widetilde{T}(\widetilde{x},\widetilde{t}) = \frac{L^2}{k}\,Q(\widetilde{x},\widetilde{t}) \qquad \forall \widetilde{x} \in \widetilde{\Omega} \quad \forall \widetilde{t} \in \mathbb{R}^+ \tag{2.8}$$

où $\widetilde{\Omega}$ désigne le domaine de $\mathbb{R}^3$ tel que $\widetilde{x} \in \widetilde{\Omega} \;\Leftrightarrow\; x \in \Omega$. En d'autres termes, moyennant le changement de variables (2.7), on pourra considérer pour l'étude mathématique du problème de thermique envisagé ici, l'équation de la chaleur (2.6) avec des constantes physiques valant 1.

Dans le cas d'une condition aux limites de Dirichlet (2.3), en désignant par $\check{T}_a$ une fonction régulière telle que $\check{T}_a|_\Sigma = T_a$ et en effectuant le changement d'inconnue $S = T - T_a$, on se ramène au problème de la thermique avec une condition de Dirichlet homogène. Cela induit un modification du second membre de l'équation de la chaleur qui devient $Q(x,t) - \rho\,c_p\,\dfrac{\partial \check{T}_a}{\partial t}(x,t) - k\,\Delta_x \check{T}_a(x,t)$.

Pour l'étude mathématique du problème de la thermique dans la partie suivante, nous supposerons donc que les constantes k, ρ et c_p valent 1 et nous considérerons uniquement le cas d'une donnée de Dirichlet nulle au bord.

2.2 Cadre mathématique

2.2.1 Formulation forte de l'équation de la chaleur avec condition de Dirichlet

Étant donné un ouvert Ω borné dans $\mathbb{R}^d$ ($d = 2$ ou 3) de frontière Σ de classe $\mathcal{C}^1$ par morceaux, on s'intéresse au problème suivant : trouver $u : (x,t) \in \Omega\times]0,T[\longrightarrow u(x,t) \in \mathbb{R}$ tel que

$$\begin{cases} \dfrac{\partial u}{\partial t}(x,t) - \Delta u(x,t) = f(x,t) \qquad \forall x \in \Omega \quad \forall t \in]0,T[& \text{(2.9a)} \\ u(x,t) = 0 \qquad \forall x \in \Sigma \quad \forall t \in]0,T[& \text{(2.9b)} \\ u(x,t=0) = u_0(x) \qquad \forall x \in \Omega & \text{(2.9c)} \end{cases}$$

où u_0 est une fonction de Ω dans $\mathbb{R}$ donnée, f est une fonction de $\Omega\times]0,T[$ dans $\mathbb{R}$ et le laplacien est considérée relativement à la variable d'espace x uniquement.

Les variables de temps t et d'espace x jouant des rôles différents dans le problème (2.9), on est amené à les considérer de manière distincte. Étant donnée une fonction $u : (x,t) \in \overline{\Omega}\times[0,T] \mapsto u(x,t)$, on désigne pour tout $t \in [0,T]$ par $\check{u}(t)$ la fonction

$$\check{u}(t) : x \in \overline{\Omega} \longmapsto u(x,t) \in \mathbb{R}$$

correspondant à sa seconde fonction partielle. Pour donner un sens à $\Delta u(x,t)$ dans le cadre de la dérivation des fonctions, on doit supposer que $\check{u}(t) \in \mathcal{C}^2(\Omega)$. [(2)] L'équation (2.9) se ré-écrit encore pour tout $t \in]0,T[$

$$\frac{\partial}{\partial t}\check{u}(t) - \Delta\check{u}(t) = f(\cdot,t) \tag{2.10}$$

Notons que la fonction u s'identifie à la fonction

$$\check{u} : t \in [0,T] \longmapsto \check{u}(t) \in \mathcal{C}^2(\Omega)$$

et que l'on doit exiger que $\check{u}$ soit dérivable (ou $\mathcal{C}^1$ pour simplifier) pour que l'équation (2.10) ait un sens. Ces deux conditions de régularité pour u sont prises en compte en imposant que la fonction $\check{u}$, ou plus simplement u, vérifie

$$u \in \mathcal{C}^1(]0,T[,\mathcal{C}^2(\Omega)).$$

On devrait d'ailleurs écrire $u \in \mathcal{C}^1(]0,T[,\mathcal{C}^2(\Omega,\mathbb{R}))$ par soucis de cohérence mais nous allégerons les notations. Notons que pour que $u \in \mathcal{C}^1(]0,T[,\mathcal{C}^2(\Omega))$, la donnée f soit vérifier $f \in \mathcal{C}^0(]0,T[,\mathcal{C}^0(\Omega))$.

Notons aussi que pour que la condition aux limites (2.9b) puisse être vérifiée par u, on doit avoir $u(t) \in \mathcal{C}^0(\overline{\Omega})$ pour tout $t \in]0,T[$. Enfin, pour que la condition initiale (2.9c) puisse être satisfaite par u, on doit avoir également $u \in \mathcal{C}^0([0,T],\mathcal{C}^0(\overline{\Omega}))$ et $u_0 \in \mathcal{C}^0(\Omega)$.

On supposera donc $f \in \mathcal{C}^0(]0,T[,\mathcal{C}^0(\Omega))$, $u_0 \in \mathcal{C}^0(\Omega)$ et on sera amené à chercher

$$u \in \mathcal{C}^1(]0,T[,\mathcal{C}^2(\Omega)) \cap \mathcal{C}^0([0,T],\mathcal{C}^0(\overline{\Omega}))$$

solution du problème de la chaleur (2.9).

Dans le cas où f est identiquement nulle, on pourrait chercher à obtenir une solution à variables séparées du problème (2.9) sous la forme

$$u(x,t) = w(x)\ \varphi(t)$$

où w et φ désignent deux fonctions réelles de la variable réelle. L'équation (2.9a) conduit alors (au moins formellement) à

$$\frac{\varphi'(t)}{\varphi(t)} = \frac{\Delta w(x)}{w(x)} \qquad \forall t \in]0,T[\quad \forall x \in \Omega.$$

Le membre de gauche de cette égalité dépend de la variable t uniquement alors que le membre de droite ne dépend que de la variable x. Il s'ensuit que chacun de ces deux quantités est constante. Notons $-\lambda$ cette constante avec $\lambda \in \mathbb{R}$. On en déduit d'une part que $\varphi'(t) + \lambda\,\varphi(t) = 0$ pour tout $t \in]0,T[$, autrement dit que $\varphi(t) = C\,\mathrm{e}^{-\lambda t}$ où C désigne une constante réelle. On en déduit d'autre part que w est solution de

$$\begin{cases} -\Delta w(x) = \lambda\, w(x) & \forall x \in \Omega \qquad (2.11a) \\ w(x) = 0 & \forall x \in \Sigma \qquad (2.11b) \end{cases}$$

Le problème (2.11) est qualifié de *problème spectral* : on cherche à déterminer les valeurs $\lambda \in \mathbb{R}$ telles qu'il existe une solution w_λ non nulle à (2.11). Si un tel couple (λ, w_λ) existe, on dit que λ est *valeur propre* de l'opérateur Laplace-Dirichlet et w_λ est une *fonction propre* relative à la valeur propre λ. On notera que les fonctions w_λ sont déterminées à une constante multiplicative près : si w_λ est fonction propre relative à

(2). On pourrait se contenter de supposer $\check{u}(t)$ deux fois différentiable en tout point de Ω.

la valeur propre λ alors, pour tout $\alpha \in \mathbb{R}^*$, la fonction $\alpha\, w_\lambda$ est encore fonction propre relative à la valeur propre λ.

Les solutions à variables séparées du problème (2.9) dans le cas où f est nulle s'expriment donc sous la forme :

$$u(x,t) = \sum_\lambda w_\lambda(x)\, \mathrm{e}^{-\lambda t} \qquad \forall t \in]0,T[\quad \forall x \in \Omega \tag{2.12}$$

où la somme est prise sur les valeurs propres λ du problème spectral (2.11). La condition initiale implique que l'on a $u_0(x) = \sum_\lambda w_\lambda(x)$ pour tout $x \in \Omega$.

2.2.2 Formulation variationnelle

La formulation variationnelle du problème (2.9) s'obtient de la manière classique pour un problème aux limites faisant intervenir un laplacien comme indiqué au chap. 1.

Soit v une fonction quelconque dans $\mathbb{H}^1_0(\Omega)$, jouant ici le rôle de fonction test. En multipliant chaque membre de l'équation (2.9a) par v et en intégrant sur Ω, nous obtenons pour tout $t \in [0,T]$

$$\int_\Omega \frac{\partial u}{\partial t}(x,t)\, v(x)\, \mathrm{d}x - \int_\Omega \Delta u(x,t)\, v(x)\, \mathrm{d}x = \int_\Omega f(x,t)\, v(x)\, \mathrm{d}x. \tag{2.13a}$$

En utilisant la deuxième formule de Green, voir la proposition 1.9, nous obtenons

$$\int_\Omega \Delta u(x,t)\, v(x)\, \mathrm{d}x = -\int_\Omega \nabla u(x,t)\, \nabla v(x)\, \mathrm{d}x. \tag{2.13b}$$

Par ailleurs, sous réserve de pouvoir permuter la dérivation par rapport au temps et l'intégration, nous avons formellement

$$\int_\Omega \frac{\partial u}{\partial t}(x,t)\, v(x)\, \mathrm{d}x = \frac{\mathrm{d}}{\mathrm{d}t}\int_\Omega u(x,t)\, v(x)\, \mathrm{d}x. \tag{2.13c}$$

Combinant (2.13b) et (2.13c) avec (2.13a), nous obtenons pour tout $t \in [0,T]$

$$\frac{\mathrm{d}}{\mathrm{d}t}\int_\Omega u(x,t)\, v(x)\, \mathrm{d}x + \int_\Omega \nabla u(x,t)\cdot\nabla v(x)\, \mathrm{d}x = \int_\Omega f(x,t)\, v(x)\, \mathrm{d}x. \tag{2.14}$$

Intéressons-nous à présent au cadre fonctionnel dans lequel la formulation variationnelle (2.14) a un sens. Compte tenu de la condition aux limites (2.9b), il est naturel de prendre $u(t) \in \mathbb{H}^1_0(\Omega)$ afin d'assurer un sens à la seconde intégrale dans (2.14). Intéressons-nous à la première intégrale. En imposant que $u \in \mathbb{L}^2(]0,T[, \mathbb{H}^1_0(\Omega))$, la fonction $w : t \in]0,T[\mapsto \int_\Omega u(x,t)\, v(x)\, \mathrm{d}x$ est une fonction de $\mathbb{L}^2(]0,T[)$ car

$$\int_0^T |w(t)|^2\, \mathrm{d}t = \int_0^T \langle u(t), v\rangle_{0,\Omega}\, \mathrm{d}t \leqslant \|v\|_{0,\Omega} \int_0^T \|u(t)\|_{0,\Omega}\, \mathrm{d}t \leqslant \|v\|_{1,\Omega} \int_0^T \|u(t)\|_{1,\Omega}\, \mathrm{d}t < \infty$$

et par conséquent, elle est dérivable au sens des distributions. La relation (2.14) a donc un sens pour $u \in \mathbb{L}^2(]0,T[, \mathbb{H}^1_0(\Omega))$ et $f \in \mathbb{L}^2(]0,T[, \mathbb{L}^2(\Omega))$.

Pour donner un sens à la condition initiale (2.9c), il convient en outre que $u \in \mathcal{C}^0([0,T], \mathbb{L}^2(\Omega))$. En supposant $u_0 \in \mathbb{L}^2(\Omega)$, la condition initiale (2.9c) est vérifiée presque partout sur Ω.

La formulation variationnelle du problème (2.9) est donc la suivante : trouver $u \in \mathbb{L}^2(]0,T[, \mathbb{H}^1_0(\Omega)) \cap \mathcal{C}^0([0,T], \mathbb{L}^2(\Omega))$ tel que

$$\begin{cases} \forall t \in]0,T[\quad \forall v \in \mathbb{H}^1_0(\Omega) \qquad \dfrac{\mathrm{d}}{\mathrm{d}t}\langle u(t), v\rangle_{0,\Omega} + a(u(t), v) = \langle f(t), v\rangle_{0,\Omega} & \text{(2.15a)} \\ u(t=0) = u_0 & \text{(2.15b)} \end{cases}$$

où $f \in \mathbb{L}^2(]0,T[, \mathbb{L}^2(\Omega))$ et $u_0 \in \mathbb{L}^2(\Omega)$ sont des fonctions données et où a désigne la forme bilinéaire symétrique sur $\mathbb{H}^1_0(\Omega)$ définie par

$$a(u,v) = \int_\Omega \nabla u(x)\cdot\nabla v(x)\, \mathrm{d}x \tag{2.16}$$

Remarque Dans l'équation (2.15) la dérivation de la fonction $w : t \in [0,T] \mapsto \langle u(t), v\rangle_{0,\Omega}$ doit être comprise au sens des distributions. L'hypothèse $u \in \mathbb{L}^2(]0,T[, \mathbb{H}^1_0(\Omega))$ implique que $w \in \mathbb{L}^2(]0,T[, \mathbb{R})$ et cette fonction définit donc une distribution régulière [6, 1]. Par ailleurs, on a

$$\forall \psi \in \mathcal{D}(]0,T[) \qquad \langle \frac{\mathrm{d}}{\mathrm{d}t} w, \psi\rangle = -\langle w, \psi'\rangle = -\int_0^T \psi'(t) \left(\int_\Omega u(x,t) v(x)\ \mathrm{d}x \right)\ \mathrm{d}t.$$

D'après le théorème de Fubini,

$$\langle \frac{\mathrm{d}}{\mathrm{d}t} w, \psi\rangle = -\int_\Omega v(x) \left(\int_0^T \psi'(t) u(x,t)\ \mathrm{d}t \right)\ \mathrm{d}x = -\int_\Omega v(x)\ \langle u(x,\cdot), \psi'\rangle\ \mathrm{d}x = \int_\Omega v(x)\ \langle \frac{\partial}{\partial t} u(x,\cdot), \psi\rangle\ \mathrm{d}x.$$

Si on suppose que $\frac{\partial}{\partial t} u \in \mathbb{L}^2(]0,T[, \mathbb{H}^1_0(\Omega))$ alors à nouveau par le théorème de Fubini, on obtient

$$\langle \frac{\mathrm{d}}{\mathrm{d}t} w, \psi\rangle = \int_0^T \left(\int_\Omega \frac{\partial u}{\partial t}(x,t)\, v(x)\ \mathrm{d}x \right)\ \psi(t)\ \mathrm{d}t$$

et on en déduit la relation (2.13c) dans $\mathcal{D}'(]0,T[)$. ◇

2.2.3 Résultat d'existence - unicité d'une solution au problème variationnel

La preuve de l'existence et de l'unicité d'une solution au problème variationnel (2.15) découle de résultats de la théorie spectrale de problèmes aux limites. On pourra consulter [5, Chap. 6] pour une introduction à cette théorie dans le cadre qui nous occupe.

Commençons par quelques rappels d'analyse hilbertienne. Étant donné un espace de Hilbert V muni d'un produit scalaire noté $\langle\ ,\ \rangle_V$, on appelle *base hilbertienne* de V une famille $(e_i)_{i\in I}$ d'éléments de V telle que

- la famille est orthogonale : $\forall (i,j) \in I^2 \quad i \neq j \Longrightarrow \langle e_i, e_j\rangle_V = 0$;
- la famille est normée : $\forall i \in I \quad \langle e_i, e_i\rangle_V = 1$;
- la famille est totale : l'adhérence dans V du sous-espace vectoriel engendré par la famille $(e_i)_{i\in I}$ est V, *i.e.* $\overline{\mathrm{Vect}\{e_i, i \in I\}} = V$.

Rappelons que l'on peut avoir recours au procédé de Gram-Schmidt [(3)] pour construire une base hilbertienne. Par ailleurs, tout espace de Hilbert possède une base hilbertienne.

Un cas particulier d'espace de Hilbert qui nous intéresse plus particulièrement dans ce cours est celui des espaces de Sobolev $\mathbb{H}^m(\Omega)$. Ces espaces sont des espaces de Hilbert *séparables*, c'est-à-dire qu'ils contiennent un sous-ensemble dense et dénombrable (ou fini). Une propriété des espaces de Hilbert séparables est qu'ils possèdent une base hilbertienne *dénombrable* $(w_n)_{n\in\mathbb{N}}$. Dans ce cas, pour tout $v \in v$, on a d'une part

$$v = \sum_{n\in\mathbb{N}} \langle v, w_n\rangle_V\ w_n \tag{2.17a}$$

et d'autre part l'inégalité de Parseval [(4)]

$$\|v\|_V^2 = \sum_{n\in\mathbb{N}} |\langle v, w_n\rangle_V|^2 \tag{2.17b}$$

Nous nous placerons exclusivement dans le cadre des espaces de Hilbert séparables par la suite.

Rappelons que si F désigne un sous-espace vectoriel complet (notamment un sous-espace vectoriel fermé ou un sous-espace vectoriel de dimension finie) de l'espace de Hilbert V alors pour tout $v \in V$ il existe un unique élément $\nu \in F$ tel que

$$\|v - \nu\|_V = \inf_{\mu\in F} \|v - \mu\|_V.$$

(3). Voir par exemple [2, chap. 8].
(4). Parseval des Chênes, Marc-Antoine (1755, 1836 - Rosières-aux-Salines, Paris).

L'application P_F ainsi définie $P_F : v \in V \mapsto \nu \in F$ est une application linéaire continue appelée *projection hilbertienne sur* F (elle est idempotente : $P_F \circ P_F = P_F$). On montre que pour tout $v \in V$, l'élément $\nu = P_F(v)$ est caractérisé par $\nu \in F$ et $\langle v - \nu, \mu \rangle_V = 0$ pour tout $\mu \in F$.

En particulier, si F est le sous-espace vectoriel engendrée par une famille *finie* orthonormée $(w_n)_{n=1,\dots,N}$, le projecteur orthogonal sur F est donné par

$$P_F : v \in V \longmapsto \sum_{n=1}^{N} \langle v, w_n \rangle_V \, w_n.$$

Donnons également quelques résultats d'injection compacte pour les espaces de Sobolev utiles par la suite.

Théorème 2.1 (Théorème de Rellich)
Soit Ω un ouvert borné de $\mathbb{R}^d$ de classe $\mathcal{C}^1$. L'injection canonique de $\mathbb{H}^m(\Omega)$ dans $\mathbb{L}^2(\Omega)$ est compacte, en d'autres termes, de toute suite bornée de $\mathbb{H}^m(\Omega)$ on peut extraire une sous-suite convergente dans $\mathbb{L}^2(\Omega)$. On note $\mathbb{H}^m(\Omega) \underset{c}{\hookrightarrow} \mathbb{L}^2(\Omega)$.

On trouvera une preuve de ce résultat par exemple dans [4, chap. 9]. On sera attentif au fait que l'hypothèse que l'ouvert est borné est indispensable pour que le théorème 2.1 soit vrai. Ainsi, l'injection canonique de $\mathbb{H}^m(\mathbb{R}^d)$ dans $\mathbb{L}^2(\mathbb{R}^d)$ n'est pas compacte.

En complément au théorème de Rellich, on a aussi les résultats d'injection compacte suivants en fonction de la dimension du domaine Ω.

Proposition 2.1 *Soit Ω un ouvert borné de $\mathbb{R}^d$ de classe $\mathcal{C}^1$.*
- *En dimension $d = 1$, $\mathbb{H}^m(\Omega) \underset{c}{\hookrightarrow} \mathcal{C}^0(\overline{\Omega})$.*
- *En dimension $d = 2$, $\mathbb{H}^m(\Omega) \underset{c}{\hookrightarrow} \mathbb{L}^k(\Omega)$ pour tout $k \in \mathbb{N}^*$.*
- *En dimension $d \geqslant 3$, $\mathbb{H}^m(\Omega) \underset{c}{\hookrightarrow} \mathbb{L}^k(\Omega)$ pour tout $k \in \mathbb{N}^*$ tel que $k < \frac{2d}{d-2}$.*

Nous sommes à présent en mesure de formuler le résultat suivant de théorie spectrale, utile pour établir l'existence et l'unicité d'une solution au problème variationnel (2.15).

Théorème 2.2 *Soient V et H deux espaces de Hilbert tels que l'injection canonique de V dans H soit compacte ($V \underset{c}{\hookrightarrow} H$) et soit a une forme bilinéaire symétrique continue sur $V \times V$ et V-elliptique.*
On considère le problème spectral : trouver $\lambda \in \mathbb{R}$ tel qu'il existe $u \in V$, $u \neq 0$, solution de

$$\forall v \in V \qquad a(u, v) = \lambda \, \langle u, v \rangle_H.$$

Les réels λ solutions (qui sont appelés valeurs propres *de a) forment une suite croissante de réels strictement positifs $(\lambda_m)_{m\in\mathbb{N}}$ tendant vers $+\infty$ et il existe une base hilbertienne $(w_m)_{m\in\mathbb{N}}$ orthonormale de H formée de fonctions $w_m \in V$ tel que*

$$\forall m \in \mathbb{N} \quad \forall v \in V \qquad a(w_m, v) = \lambda_m \, \langle w_m, v \rangle_V.$$

(La fonction w_m est appelé fonction propre relative à la valeur propre λ_m.)
De plus, la famille $(\lambda_m^{-\frac{1}{2}} w_m)_{m\in\mathbb{N}}$ forme une base hilbertienne orthonormale de V pour le produit scalaire défini par a.

La forme bilinéaire a définie en (2.16) est clairement symétrique. On munit $V = \mathbb{H}_0^1(\Omega)$ du produit scalaire défini pour tous $u, v \in \mathbb{H}_0^1(\Omega)$ par $\langle u, v \rangle_V = \int_\Omega \nabla u(x) \cdot \nabla v(x) \, \mathrm{d}x$. On rappelle que sur $\mathbb{H}_0^1(\Omega)$ la norme $|\ |_{1,\Omega}$

subordonnée à ce produit scalaire est une norme équivalente à la norme de $\mathbb{H}^1(\Omega)$, voir le corollaire 1.1 p. 4. La forme bilinéaire a est continue sur V puisque pour tous $u, v \in V$

$$|a(u,v)| = \Big| \int_\Omega \nabla u(x) \cdot \nabla v(x)\ \mathrm{d}x \Big| \leqslant |u|_{1,\Omega}\, |v|_{1,\Omega}.$$

Elle est aussi V-elliptique puisque pour tout $u \in V$

$$a(v,v) = \int_\Omega \big|\nabla v(x)\big|^2\ \mathrm{d}x = |v|^2_{1,\Omega}.$$

Par ailleurs, d'après le théorème de Rellich, dans le cas où l'ouvert Ω est de classe $\mathcal{C}^1$, l'injection canonique de $\mathbb{H}^1(\Omega)$ (et donc de $\mathbb{H}^1_0(\Omega)$) dans $H = \mathbb{L}^2(\Omega)$ est compacte. Ainsi, d'après le théorème 2.2, on a le résultat suivant.

Proposition 2.2 *Soit a la forme bilinéaire sur $\mathbb{H}^1_0(\Omega)$ définie par $a(u,v) = \int_\Omega \nabla u(x) \cdot \nabla v(x)\ \mathrm{d}x$. Il existe une suite croissante de réels strictement positifs $(\lambda_m)_{m\in\mathbb{N}}$ tendant vers $+\infty$ et il existe une base hilbertienne $(w_m)_{m\in\mathbb{N}}$ orthonormale de $\mathbb{L}^2(\Omega)$ formée de fonctions $w_m \in \mathbb{H}^1_0(\Omega)$ tel que*

$$\forall m \in \mathbb{N} \quad \forall v \in \mathbb{H}^1_0(\Omega) \qquad a(w_m, v) = \lambda_m\, \langle w_m, v\rangle_{0,\Omega}.$$

Procédons à présent par analyse-synthèse et supposons que le problème (2.15) admette une solution u dans $\mathbb{L}^2(]0,T[, \mathbb{H}^1_0(\Omega)) \cap \mathcal{C}^0([0,T], \mathbb{L}^2(\Omega))$. Cette solution peut être décomposée dans la base hilbertienne $(w_m)_{m\in\mathbb{N}}$ sous la forme

$$u(t) = \sum_{m\in\mathbb{N}} \rho_m(t)\, w_m \qquad \text{où} \qquad \rho_m(t) = \langle u(t), w_m\rangle_{0,\Omega}. \tag{2.18}$$

La base $(w_m)_{m\in\mathbb{N}}$ étant orthonormale, on déduit de (2.15a) que, pour tout $m \in \mathbb{N}$, on a

$$\frac{\mathrm{d}}{\mathrm{d}t}\rho_m(t) + \lambda_m\, \rho_m(t) = \underbrace{\langle f(t), w_m\rangle_{0,\Omega}}_{\stackrel{\text{def}}{=}\, g(t)} \tag{2.19a}$$

avec, d'après (2.15b),

$$\rho_m(0) = \langle u_0, w_m\rangle_{0,\Omega}. \tag{2.19b}$$

La solution du problème de Cauchy (2.19) d'inconnue ρ_n, où l'équation différentielle (2.19a) est linéaire d'ordre 1 à coefficient constant, s'obtient par la *méthode de la variation de la constante* [(5)] et s'exprime sous la forme

$$\rho_m(t) = \rho_m(0)\, \mathrm{e}^{-\lambda_m t} + \int_0^t g(s)\, \mathrm{e}^{-\lambda_m(t-s)}\ \mathrm{d}s = \langle u_0, w_m\rangle_{0,\Omega}\, \mathrm{e}^{-\lambda_m t} + \int_0^t \langle f(s), w_m\rangle_{0,\Omega}\, \mathrm{e}^{-\lambda_m(t-s)}\ \mathrm{d}s. \tag{2.20}$$

Donc, si le problème (2.15) admet une solution, celle-ci s'exprime sous la forme $u(t) = \sum_{m\in\mathbb{N}} \rho_m(t)\, w_m$ pour tout $t \in [0,T]$ avec ρ_m donné par (2.20). En particulier, cela implique que si la solution existe alors elle est unique.

Il reste à établir l'existence de la solution. Cela peut être obtenu en établissant que la série $\sum_{m\in\mathbb{N}} \rho_m(t)\, w_m$ converge pour tout $t \in [0,T]$, pour tout $f \in \mathbb{L}^2(]0,T[, \mathbb{L}^2(\Omega))$ et pour tout $u_0 \in \mathbb{L}^2(\Omega)$. La démonstration que cette propriété est établie dans [5, chap. 7]. Nous avons donc le résultat suivant.

(5). Voir par exemple [3, proposition 20.2].

Proposition 2.3 *Étant données $f \in \mathbb{L}^2(\Omega\times]0,T[)$ et $u_0 \in \mathbb{L}^2(\Omega)$, il existe une unique solution $u \in \mathbb{L}^2(]0,T[,\mathbb{H}^1_0(\Omega)) \cap \mathcal{C}^0([0,T],\mathbb{L}^2(\Omega))$ au problème (2.15).*
Cette solution est donnée par

$$u(t) = \sum_{m\in\mathbb{N}} \left(\langle u_0, w_m\rangle_{0,\Omega}\, \mathrm{e}^{-\lambda_m t} + \int_0^t \langle f(s), w_m\rangle_{0,\Omega}\, \mathrm{e}^{-\lambda_m (t-s)}\, \mathrm{d}s \right) w_m$$

où la suite de réels strictement positifs $(\lambda_m)_{m\in\mathbb{N}}$ et la suite de fonctions $(w_m)_{m\in\mathbb{N}}$ de $\mathbb{H}^1_0(\Omega)$ sont solutions du problème spectral

$$\forall v \in \mathbb{H}^1_0(\Omega) \qquad a(w_m, v) = \lambda_m \langle w_m, v\rangle_{0,\Omega}.$$

2.3 Approximation du problème de thermique

2.3.1 Semi-discrétisation en espace

On considère un sous-espace vectoriel V_h de dimension finie de $V = \mathbb{H}^1_0(\Omega)$ et on note J_h ou plus simplement J la dimension de V_h. On suppose que l'espace V_h dépend d'un paramètre $h > 0$ destiné à tendre vers 0 et que $\lim_{h\to 0} J_h = +\infty$. Par exemple, cette situation correspond au cas où V_h est l'espace d'approximation élément-fini de Lagrange de type (1) construit à partir d'un maillage de Ω, le paramètre h désignant le pas du maillage tel qu'introduit par exemple à la section 1.2.1.

La forme bilinéaire a étant symétrique et V-elliptique, elle définit un produit scalaire sur V. On désigne par $\Pi_h \in \mathcal{L}(V, V_h)$ l'opérateur de projection orthogonale de V sur V_h pour le produit scalaire défini par a. Cet opérateur est appelé *opérateur de projection elliptique*. Pour $v \in V$, on a $\Pi_h v \in V_h$ tel que

$$a(v - \Pi_h v, v_h) = 0 \qquad \forall v_h \in V_h. \tag{2.21}$$

L'opérateur de projection elliptique est tel que, pour tout $v \in V$,

$$\|v - \Pi_h v\|_{1,\Omega} \leqslant \frac{M}{\alpha} \inf_{v_h\in V_h} \|v - v_h\|_{1,\Omega} \tag{2.22}$$

où α désigne la constante de V-ellipticité de la forme bilinéaire a et M sa constante de continuité, voir le théorème de Lax-Milgram p. 12. En effet, on obtient en exploitant successivement la V-ellipticité de a, la relation (2.21) et la continuité de a que pour tout $v_h \in V_h$

$$\begin{aligned}\|v - \Pi_h v\|^2_{1,\Omega} &\leqslant \frac{1}{\alpha}\, a(v - \Pi_h v, v - \Pi_h v) = \frac{1}{\alpha}\, a(v - \Pi_h v, v - v_h) + \frac{1}{\alpha}\, a(v - \Pi_h v, v_h - \Pi_h v)\\ &= \frac{1}{\alpha}\, a(v - \Pi_h v, v - v_h) \leqslant \frac{M}{\alpha}\, \|v - \Pi_h v\|_{1,\Omega}\, \|v - v_h\|_{1,\Omega}.\end{aligned}$$

Les propriétés d'approximation de l'opérateur de projection elliptique sont les suivantes.

Lemme 2.1 *On suppose qu'il existe $k \in \mathbb{N}^*$ et $C \in \mathbb{R}^*_+$ tel que pour tout $\ell \in \{1,\dots,k\}$ et pour tout $v \in \mathbb{H}^{\ell+1}(\Omega)$, on ait*

$$\inf_{v_h\in V_h} (\|v - v_h\|_{0,\Omega} + h\,|v - v_h|_{1,\Omega}) \leqslant C\, h^{\ell+1}\, \|v\|_{\ell+1,\Omega}.$$

Sous cette hypothèse, il existe $C \in \mathbb{R}^*_+$ tel que pour tout $\ell \in \{1,\dots,k\}$ et pour tout $v \in \mathbb{H}^{\ell+1}(\Omega)$, on ait

$$\|v - \Pi_h v\|_{1,\Omega} \leqslant C h^{\ell}\, \|v\|_{\ell+1,\Omega}.$$

En supposant de plus que l'ouvert Ω est polyédrique et convexe, il existe $C \in \mathbb{R}^*_+$ tel que pour tout $\ell \in \{1,\dots,k\}$ et pour tout $v \in \mathbb{H}^{\ell+1}(\Omega)$, on ait

$$\|v - \Pi_h v\|_{0,\Omega} \leqslant C h^{\ell+1}\, \|v\|_{\ell+1,\Omega}.$$

Démonstration Soient $\ell \in \{1, \dots, k\}$ et $v \in \mathbb{H}^{\ell+1}(\Omega)$. D'après (2.22), pour tout $v_h \in V_h$, on a

$$\|v - \Pi_h v\|_{1,\Omega} \leqslant \frac{M}{\alpha} \|v - v_h\|_{1,\Omega} = \frac{M}{\alpha} \left(\|v - v_h\|_{0,\Omega}^2 + |v - v_h|_{1,\Omega}^2\right)^{\frac{1}{2}}.$$

D'après l'hypothèse du lemme 2.1, $\|v - v_h\|_{0,\Omega} \leqslant C\, h^{\ell+1} \|v\|_{\ell+1,\Omega}$ et $|v - v_h|_{1,\Omega} \leqslant C\, h^{\ell} \|v\|_{\ell+1,\Omega}$. On en déduit que

$$\|v - \Pi_h v\|_{1,\Omega} \leqslant \left(\frac{M}{\alpha} C \sqrt{1 + h^2}\right) h^{\ell} \|v\|_{\ell+1,\Omega}$$

ce qui établit la première estimation donnée au lemme 2.1.

La seconde estimation donnée au lemme 2.1 est nettement plus difficile à obtenir et nous admettrons ce résultat dont on trouvera une preuve dans [5, p. 152]. On pourra néanmoins remarquer que l'estimation que nous venons d'établir implique que $\|v - \Pi_h v\|_{0,\Omega} \leqslant C h^{\ell} \|v\|_{\ell+1,\Omega}$. Ainsi, sous l'hypothèse que l'ouvert Ω est polyédrique et convexe, on peut en fait démontrer que l'approximation de v par l'opérateur de projection elliptique est plus précise que cela, avec un gain d'une puissance de h supplémentaire. □

On désigne par $u_{h,0}$ une approximation de u_0 appartenant à V_h. On s'intéresse au problème suivant : trouver une fonction $u_h : t \in [0, T] \mapsto u_h(t) \in V_h$ telle que

$$\begin{cases} \forall t \in]0, T[\quad \forall v_h \in V_h \qquad \dfrac{\mathrm{d}}{\mathrm{d}t} \langle u_h(t), v_h \rangle_{0,\Omega} + a(u_h(t), v_h) = \langle f(t), v_h \rangle_{0,\Omega} & \text{(2.23a)} \\ u_h(t = 0) = u_{h,0} & \text{(2.23b)} \end{cases}$$

En ayant recours à une variante du théorème 2.2 dans le cas d'un sous-espace de dimension finie, on établit le résultat suivant.

Proposition 2.4 *Soit a la forme bilinéaire sur $\mathbb{H}_0^1(\Omega)$ définie par $a(u, v) = \int_\Omega \nabla u(x) \cdot \nabla v(x)\, \mathrm{d}x$. Il existe une suite finie croissante de réels strictement positifs $(\lambda_{h,j})_{j=1,\dots,J}$ et une base $(w_{h,j})_{j=1,\dots,J}$ de V_h, orthonormale dans $\mathbb{L}^2(\Omega)$, tel que*

$$\forall j \in \{1, \dots, J\} \quad \forall v_h \in V_h \qquad a(w_{h,j}, v_h) = \lambda_{h,j} \langle w_{h,j}, v_h \rangle_{0,\Omega}.$$

On établit alors, comme pour le problème continu (2.15), qu'il existe une unique solution $u_h \in \mathcal{C}^0([0, T], V_h)$ au problème (2.23) et que celle-ci est donnée par

$$u_h(t) = \sum_{j=1}^{J} \left(\langle u_{h,0}, w_{h,j} \rangle_{0,\Omega}\, \mathrm{e}^{-\lambda_j t} + \int_0^t \langle f(s), w_{h,j} \rangle_{0,\Omega}\, \mathrm{e}^{-\lambda_j (t-s)}\, \mathrm{d}s \right) w_{h,j}. \tag{2.24}$$

Intéressons-nous à l'erreur commise en remplaçant le problème (2.15) par le problème (2.23). On montre, voir par exemple [5, théorème 7.4.2 & corollaire 7.4.1], le résultat d'approximation suivant.

Proposition 2.5 *Si la solution u du problème (2.15) appartient à $\mathcal{C}^1([0, T], \mathbb{H}_0^1(\Omega))$ et si l'espace d'approximation V_h est tel que*

1. $\forall v \in \mathbb{H}_0^1(\Omega) \lim\limits_{h \to 0} \inf\limits_{v_h \in V_h} \|v - v_h\|_{1,\Omega} = 0$
2. $\lim_{h \to 0} \|u_0 - u_{0,h}\|_{0,\Omega} = 0$

alors on a

$$\forall t \in [0, T] \quad \lim_{h \to 0} \|u(t) - u_h(t)\|_{0,\Omega} = 0$$

en d'autres termes la solution $u_h(t)$ du problème (2.23) correspondant à la semi-discrétisation en espace du problème (2.15) converge dans $\mathbb{L}^2(\Omega)$ vers la solution $u(t)$ de ce dernier pour tout $t \in [0, T]$.

D'un point de vue numérique, on pourrait penser exploiter la relation (2.24) pour obtenir une approximation de la solution du problème (2.15). On pourrait calculer les premiers éléments propres $(\lambda_j, w_{h,j})$ du problème spectral introduit à la proposition 2.4 et tronquer la somme dans (2.24) à ses premiers termes. Comme la suite $(\lambda_{h,j})_{j=1,\dots,J}$ est une suite croissante de réels strictement positifs, les termes $\mathrm{e}^{-\lambda_j t}$ impliquent que la contribution des différents termes de la somme sont de plus en plus petits et qu'une telle troncature a bien un sens. Numériquement, cela a néanmoins l'inconvénient du coût du calcul des éléments propres de la matrice issue de l'écriture matricielle du problème (2.23) combiné à la nécessite de ré-évaluer la somme dans (2.24) pour obtenir la valeur de la solution en chaque instant t.

Écriture matricielle du problème semi-discrétisé en espace

Nous allons par conséquent envisager une autre approche numérique. Considérons une base $(\varphi)_{j=1,\dots,J}$ de V_h et désignons pour $t \in [0,T]$ fixé, par $u_1(t), \dots, u_J(t)$ les composantes de $u_h(t)$ dans cette base et par $u_{0,1}, \dots, u_{0,J}$ celles de $u_{0,h}$. On a $u_h(x,t) = \sum_{j=1}^J u_j(t)\,\varphi_j(x)$, $u_{0,h}(x) = \sum_{j=1}^J u_{0,j}\,\varphi_j(x)$ et on déduit de (2.23) que

$$\begin{cases} \forall t \in]0,T[\quad \forall i \in \{1,\dots,J\} \qquad \displaystyle\sum_{j=1}^J \langle \varphi_j, \varphi_i\rangle_{0,\Omega} \frac{\mathrm{d}}{\mathrm{d}t} u_j(t) + \sum_{j=1}^J a(\varphi_j,\varphi_i) u_j(t) = \langle f(t), \varphi_i\rangle_{0,\Omega} & \text{(2.25a)} \\ \forall i \in \{1,\dots,J\} \qquad u_i(t=0) = u_{0,i} & \text{(2.25b)} \end{cases}$$

Désignons par M la matrice de $\mathcal{M}_J(\mathbb{R})$ dont les termes sont $m_{i,j} = \langle \varphi_j, \varphi_i\rangle_{0,\Omega}$ pour $i,j = 1,\dots,J$ et par R la matrice de $\mathcal{M}_J(\mathbb{R})$ dont les termes sont $r_{i,j} = a(\varphi_j,\varphi_i)$ pour $i,j = 1,\dots,J$. Ces matrices sont deux matrices symétriques dans la situation qui nous intéresse. De plus, la forme bilinéaire a étant V-elliptique, la matrice R est définie positive, voir le lemme 1.2 p. 17. En désignant par $F(t)$ le vecteur de $\mathbb{R}^J$ dont les composantes sont $\langle f(t), \varphi_j\rangle_{0,\Omega}$ pour $j = 1,\dots,J$, l'équation (2.25a) s'écrit sous forme matricielle

$$\mathrm{M}\frac{\mathrm{d}}{\mathrm{d}t} U(t) + \mathrm{R}\,U(t) = F(t) \tag{2.26a}$$

où $U(t)$ est le vecteur de $\mathbb{R}^J$ dont les composantes sont $u_j(t)$, $j = 1,\dots,J$. La condition initiale (2.25b) s'écrit quant à elle sous la forme

$$U(0) = U_0 \tag{2.26b}$$

où U_0 est le vecteur de $\mathbb{R}^J$ dont les composantes sont $u_{0,j}(t)$, $j = 1,\dots,J$.

2.3.2 Discrétisation totale par un schéma d'Euler

Nous sommes donc conduit à devoir résoudre le système différentiel (2.26a) de dimension J avec donnée de Cauchy (2.26b). On a recours pour cela à un schéma numérique. On introduit une subdivision $(t_n)_{n=0,\dots,N}$ de l'intervalle $[0,T]$. Par simplicité, on supposera la subdivision uniforme et on désignera par δ_t le pas de cette subdivision. On peut par exemple utiliser le schéma d'Euler. En désignant par U_n l'approximation de $U(t_n)$, le schéma d'Euler appliqué au système différentiel (2.26a) s'exprime sous la forme

$$\mathrm{M}\,U_{n+1} = \big(\mathrm{M} - \delta_t \mathrm{R}\big)\,U_n + \delta_t\,F(t_n) \qquad \forall n = 0,\dots,N-1. \tag{2.27}$$

Partant de la donnée initiale U_0, on est donc conduit à résoudre à chaque pas de temps un système linéaire pour obtenir de proche en proche une approximation de $U(t)$ en chaque nœuds t_n de la subdivision de l'intervalle de temps.

Remarque sur la résolution du système linéaire (2.27). Lorsque la base $(\varphi_j)_{j=1,\dots,J}$ de V_h est orthogonale, la matrice M est diagonale. La formule de récurrence (2.27) permet de calculer U_{n+1} à partir de U_n sans nécessiter la résolution d'un système linéaire. Dans le cas général, la matrice M du système linéaire devant être résolu à chaque pas de temps reste inchangée. Il est donc possible de gagner en efficacité en effectuant une factorisation de cette matrice et n'avoir ainsi à résoudre à chaque pas de temps que des systèmes linéaires triangulaires. La matrice M étant symétrique définie positive, on peut

considérer sa décomposition de Cholesky. Soit L une matrice triangulaire inférieure telle que $\mathrm{M} = \mathrm{L}\,\mathrm{L}^\top$. À chaque pas de temps, on est amené à résoudre les deux systèmes linéaires triangulaires

$$\begin{aligned} &\mathrm{L}\,V = \big(\mathrm{M} - \delta_t \mathrm{R}\big)\,U_n + \delta_t\,F(t_n) \\ &\mathrm{L}^\top\,U_{n+1} = V \end{aligned}$$

◇

Pour l'analyse du schéma issu de la discrétisation totale par la méthode d'Euler, nous reformulons le problème discret (2.27) en considérant la formulation (2.23) du problème semi-discrétisé en espace. Pour tout $n \in \{0,\ldots,N\}$, en désignant pas u_h^n l'approximation de $u_h(t_n)$, nous sommes conduit à trouver les fonctions $u_h^0,\ldots,u_h^n$ de V_h telles que

$$\left\{\begin{array}{ll} \forall n \in \{0,\ldots,N-1\} \quad \forall v_h \in V_h \qquad \frac{1}{\delta_t}\langle u_h^{n+1} - u_h^n, v_h\rangle_{0,\Omega} + a(u_h^n, v_h) = \langle f(t_n), v_h\rangle_{0,\Omega} & \text{(2.28a)} \\ u_h^0 = u_{h,0} & \text{(2.28b)} \end{array}\right.$$

On introduit l'erreur e_h^n au temps t_n, $n \in \{0,\ldots,N\}$ telle que

$$e_h^n \stackrel{\text{def}}{=} u_h^n - \Pi_h u(t_n) \ \in V_h \tag{2.29}$$

où Π_h désigne l'opérateur de projection elliptique défini en (2.21). En substituant $u_h^n = e_h^n + \Pi_h u(t_n)$ dans (2.28), on établit que les fonctions $e_h^0,\ldots,e_h^n$ de V_h sont telles que

$$\left\{\begin{array}{ll} \forall n \in \{0,\ldots,N-1\} \quad \forall v_h \in V_h \qquad \frac{1}{\delta_t}\langle e_h^{n+1} - e_h^n, v_h\rangle_{0,\Omega} + a(e_h^n, v_h) = \langle \varepsilon_h^n, v_h\rangle_{0,\Omega} & \text{(2.30a)} \\ e_h^0 = u_{h,0} - \Pi_h u(t_0) & \text{(2.30b)} \end{array}\right.$$

où $\varepsilon_h^n \in V_h$ est défini pour tout $n \in \{0,\ldots,N\}$ par

$$\forall v_h \in V_h \qquad \langle \varepsilon_h^n, v_h\rangle_{0,\Omega} = \langle f(t_n), v_h\rangle_{0,\Omega} - \tfrac{1}{\delta_t}\langle \Pi_h u(t_{n+1}) - \Pi_h u(t_n), v_h\rangle_{0,\Omega} - a(\Pi_h u(t_n), v_h). \tag{2.31}$$

La fonction ε_h^n s'interprète donc comme l'erreur de consistance du schéma (2.28). On notera que d'après (2.21), on a $a(\Pi_h u(t_n), v_h) = a(u(t_n), v_h)$ pour tout $v_h \in V_h$.

Pour obtenir une majoration de l'erreur e_h^n au temps t_n, nous procédons en deux étapes. La première étape consistera à obtenir les conditions de stabilité d'un schéma de la forme (2.30). La seconde étape consistera à établir une estimation de l'erreur de consistance ε_h^n. En combinant les résultats de ces deux étapes, nous établirons que le schéma (2.28) est convergent (sous une condition de stabilité, ce qui n'est guère surprenant pour un schéma d'Euler explicite).

Première étape. Considérons la suite finie de réels strictement positifs $(\lambda_{h,j})_{j=0,\ldots,J}$ et la base de V_h orthonormale $(w_{h,j})_{j=0,\ldots,J}$ introduites à la proposition 2.4. Décomposons l'erreur e_h^n et l'erreur de consistance ε_h^n dans cette base. Il existe $(e_j^n)_{j=0,\ldots,J} \in \mathbb{R}^J$ et il existe $(\varepsilon_j^n)_{j=0,\ldots,J} \in \mathbb{R}^J$ tel que

$$e_h^n = \sum_{j=1}^{J} e_j^n\,w_{h,j}, \qquad \varepsilon_h^n = \sum_{j=1}^{J} \varepsilon_j^n\,w_{h,j}.$$

On déduit de (2.30a) considérée avec $v_h = w_i$ que

$$\forall i \in \{1,\ldots,J\} \qquad \tfrac{1}{\delta_t}\big(e_i^{n+1} - e_i^n\big) + \lambda_{h,i}\,e_i^n = \varepsilon_i^n$$

On a donc pour tout $n \in \mathbb{N}$,

$$\forall i \in \{1,\ldots,J\} \qquad e_i^{n+1} = (1 + \delta_t\,\lambda_{h,i})\,e_i^n + \delta_t \varepsilon_i^n.$$

On en déduit par récurrence que

$$\forall i \in \{1,\ldots,J\} \qquad e_i^{n+1} = (1 + \delta_t\,\lambda_{h,i})^{n+1}\,e_i^0 + \delta_t\ \sum_{\ell=0}^{n} (1 + \delta_t\,\lambda_{h,i})^{\ell}\,\varepsilon_i^{n-\ell}. \tag{2.32}$$

On en conclut que pour que e_i^{n+1} reste borné pour tout $i \in \{1, \dots, J\}$ et pour tout $n \in \mathbb{N}$, il faut et il suffit que $|1 + \delta_t \, \lambda_{h,i}| \leqslant 1$. Cette condition est assurée si, et seulement si, $\delta_t \, \lambda_{h,i} \leqslant 2$ pour tout $i \in \{1, \dots, J\}$. Comme la suite de réels strictement positifs $(\lambda_{h,j})_{j=0,\dots,J}$ est croissante, la condition de stabilité équivaut encore à

$$\delta_t \, \lambda_{h,J} \leqslant 2. \tag{2.33}$$

Lorsque cette condition est satisfaite, on déduit de (2.32) que

$$\forall n \in \mathbb{N} \quad \forall i \in \{1, \dots, J\} \qquad |e_i^n| \leqslant |e_i^0| + \delta_t \sum_{k=0}^{n-1} |\varepsilon_i^k|. \tag{2.34}$$

D'après l'inégalité de Parseval (2.17b), on a $\|e_h^n\|_{\mathbb{L}^2(\Omega)} = \Big(\sum_{j=1}^J (e_j^n)^2 \Big)^{\frac{1}{2}}$. On déduit donc de (2.34) que

$$\|e_h^n\|_{\mathbb{L}^2(\Omega)} \leqslant \Big(\sum_{j=1}^J \Big(|e_i^0| + \delta_t \sum_{k=0}^{n-1} |\varepsilon_i^k| \Big)^2 \Big)^{\frac{1}{2}}$$

Rappelons l'inégalité de Minkowski [(6)] : pour tous $n, p \in \mathbb{N}^*$

$$\forall (x_k)_{k=1,\dots,n} \in \mathbb{R}^n \quad \forall (y_k)_{k=1,\dots,n} \in \mathbb{R}^n \qquad \left(\sum_{k=1}^n |x_k + y_k|^p \right)^{1/p} \leq \left(\sum_{k=1}^n |x_k|^p \right)^{1/p} + \left(\sum_{k=1}^n |y_k|^p \right)^{1/p}.$$

que nous utilisons ici avec $p = 2$, $n = J$ et les réels $(|e_i^0|)_{i=1,\dots,J} \in \mathbb{R}^J$, $\Big(\delta_t \ \sum_{k=0}^n |\varepsilon_i^k| \Big)^2 \Big)_{i=1,\dots,J} \in \mathbb{R}^J$, nous obtenons

$$\|e_h^n\|_{\mathbb{L}^2(\Omega)} \leqslant \Big(\sum_{j=1}^J |e_i^0|^2 \Big)^{\frac{1}{2}} + \delta_t \, \Big(\sum_{j=1}^J \Big(\sum_{k=0}^{n-1} |\varepsilon_i^k| \Big)^2 \Big)^{\frac{1}{2}}.$$

En utilisant à nouveau l'inégalité de Minkowski avec $p = 2$, $n = J$ mais avec une somme répétée cette fois-ci, on obtient

$$\left(\sum_{j=1}^J \Big(\sum_{k=0}^{n-1} |\varepsilon_i^k| \Big)^2 \right)^{\frac{1}{2}} \leqslant \sum_{k=0}^{n-1} \Big(\sum_{j=1}^J |\varepsilon_i^k|^2 \Big)^{\frac{1}{2}} = \sum_{k=0}^{n-1} \|\varepsilon_h^k\|_{\mathbb{L}^2(\Omega)}$$

la dernière égalité résultant une nouvelle fois de l'égalité de Parceval. D'après cette même égalité de Parceval, on a $\Big(\sum_{j=1}^J |e_i^0|^2 \Big)^{\frac{1}{2}} = \|e_h^0\|_{\mathbb{L}^2(\Omega)}$. Ainsi,

$$\|e_h^n\|_{\mathbb{L}^2(\Omega)} \leqslant \|e_h^0\|_{\mathbb{L}^2(\Omega)} + \delta_t \sum_{k=0}^{n-1} \|\varepsilon_h^k\|_{\mathbb{L}^2(\Omega)}. \tag{2.35}$$

Deuxième étape. Il nous reste à présent à obtenir une estimation de $\|\varepsilon_h^k\|_{\mathbb{L}^2(\Omega)}$ pour tout $k \in \{0, \dots, n-1\}$. Pour cela, nous allons supposer u suffisamment régulière. Rappelons, voir (2.31) et (2.21), que $\varepsilon_h^n \in V_h$ est telle que pour tout $n \in \{0, \dots, N\}$

$$\forall v_h \in V_h \qquad \langle \varepsilon_h^n, v_h \rangle_{0,\Omega} = \langle f(t_n), v_h \rangle_{0,\Omega} - \tfrac{1}{\delta_t} \langle \Pi_h u(t_{n+1}) - \Pi_h u(t_n), v_h \rangle_{0,\Omega} - a(u(t_n), v_h). \tag{2.36}$$

Comme u est solution du problème (2.15) et que $V_h \subset \mathbb{H}_0^1(\Omega)$, on en déduit que pour tout $v_h \in V_h$

$$\langle \varepsilon_h^n, v_h \rangle_{0,\Omega} = \frac{\mathrm{d}}{\mathrm{d}t} \langle u(t_n), v_h \rangle_{0,\Omega} - \frac{1}{\delta_t} \langle \Pi_h u(t_{n+1}) - \Pi_h u(t_n), v_h \rangle_{0,\Omega}$$

(6). Minkowski, Hermann (1864, Alexotas - 1909, Göttingen). Mathématicien et physicien allemand.

En supposant que $u \in \mathcal{C}^1([0,T], \mathbb{H}^1_0(\Omega))$, on obtient

$$\langle \varepsilon_h^n, v_h\rangle_{0,\Omega} = \big\langle \frac{\mathrm{d}}{\mathrm{d}t}u(t_n) - \frac{1}{\delta_t}\big(u(t_{n+1}) - u(t_n)\big), v_h\big\rangle_{0,\Omega} - \frac{1}{\delta_t}\langle \Pi_h u(t_{n+1}) - u(t_{n+1}), v_h\rangle_{0,\Omega} + \frac{1}{\delta_t}\langle \Pi_h u(t_n) - u(t_n), v_h\rangle_{0,\Omega}.$$

Or,

$$\begin{aligned}\langle \Pi_h u(t_{n+1}) - u(t_{n+1}), v_h\rangle_{0,\Omega} - \langle \Pi_h u(t_n) - u(t_n), v_h\rangle_{0,\Omega} &= \langle (I-\Pi_h)u(t_{n+1}) - (I-\Pi_h)u(t_n), v_h\rangle_{0,\Omega}\\ &= \big\langle \int_{t_n}^{t_{n+1}} (I-\Pi_h)\frac{\mathrm{d}}{\mathrm{d}t}u(s)\ \mathrm{d}s, v_h\big\rangle_{0,\Omega}\end{aligned}$$

On a donc

$$\varepsilon_h^n = \eta(t_n) + \frac{1}{\delta_t}\int_{t_n}^{t_{n+1}} (I-\Pi_h)\frac{\mathrm{d}}{\mathrm{d}t}u(s)\ \mathrm{d}s$$

où on a posé

$$\eta(t_n) = \frac{\mathrm{d}}{\mathrm{d}t}u(t_n) - \frac{1}{\delta_t}\big(u(t_{n+1}) - u(t_n)\big).$$

En supposant à présent que $u \in \mathcal{C}^2([0,T], \mathbb{L}^2(\Omega)$, la formule de Taylor à reste intégral [7] indique que

$$u(t_{n+1}) = u(t_n) + \delta_t\,\frac{\mathrm{d}}{\mathrm{d}t}u(t_n) + \int_{t_n}^{t_{n+1}} (t_{n+1}-s)\,\frac{\mathrm{d}^2}{\mathrm{d}t^2}u(s)\ \mathrm{d}s.$$

On a donc

$$\eta(t_n) = \frac{1}{\delta_t}\int_{t_n}^{t_{n+1}} (t_{n+1}-s)\,\frac{\mathrm{d}^2}{\mathrm{d}t^2}u(s)\ \mathrm{d}s$$

et par suite

$$\begin{aligned}\|\eta(t_n)\|_{0,\Omega} &\leqslant \frac{1}{\delta_t}\ \max_{s\in[t_n,t_{n+1}]}(t_{n+1}-s)\ \int_{t_n}^{t_{n+1}} \Big\|\frac{\mathrm{d}^2}{\mathrm{d}t^2}u(s)\Big\|_{0,\Omega}\ \mathrm{d}s\\ &= \int_{t_n}^{t_{n+1}} \Big\|\frac{\mathrm{d}^2}{\mathrm{d}t^2}u(s)\Big\|_{0,\Omega}\ \mathrm{d}s\end{aligned}$$

Finalement, on en déduit que

$$\|\varepsilon_h^n\|_{0,\Omega} \leqslant \int_{t_n}^{t_{n+1}} \Big\|\frac{\mathrm{d}^2}{\mathrm{d}t^2}u(s)\Big\|_{0,\Omega}\ \mathrm{d}s + \frac{1}{\delta_t}\int_{t_n}^{t_{n+1}} \Big\|(I-\Pi_h)\frac{\mathrm{d}}{\mathrm{d}t}u(s)\Big\|_{0,\Omega}\ \mathrm{d}s \tag{2.37}$$

En combinant (2.35) et (2.37), on en conclut que

$$\begin{aligned}\|e_h^n\|_{0,\Omega} &\leqslant \|e_h^0\|_{0,\Omega} + \delta_t \sum_{k=0}^{n-1}\int_{t_k}^{t_{k+1}} \Big\|\frac{\mathrm{d}^2}{\mathrm{d}t^2}u(s)\Big\|_{0,\Omega}\ \mathrm{d}s + \sum_{k=0}^{n-1}\int_{t_k}^{t_{k+1}} \Big\|(I-\Pi_h)\frac{\mathrm{d}}{\mathrm{d}t}u(s)\Big\|_{0,\Omega}\ \mathrm{d}s\\ &= \|e_h^0\|_{0,\Omega} + \delta_t \int_0^{t_n} \Big\|\frac{\mathrm{d}^2}{\mathrm{d}t^2}u(s)\Big\|_{0,\Omega}\ \mathrm{d}s + \int_0^{t_n} \Big\|(I-\Pi_h)\frac{\mathrm{d}}{\mathrm{d}t}u(s)\Big\|_{0,\Omega}\ \mathrm{d}s\end{aligned} \tag{2.38}$$

On a donc démontré la proposition suivante.

[7]. Voir par exemple [3, chap. 18].

Proposition 2.6 *Si $u \in \mathcal{C}^1([0,T], \mathbb{H}^1_0(\Omega) \cap \mathcal{C}^2([0,T], \mathbb{L}^2(\Omega))$ alors, sous la condition de stabilité*

$$\delta_t \, \lambda_{h,J} \leqslant 2$$

où δ_t désigne le pas de la discrétisation temporelle et $\lambda_{h,J}$ la plus grande valeur propre introduite à la proposition 2.4, on a

$$\begin{aligned}\|u(t_n) - u_h^n\|_{0,\Omega} \leqslant \|\Pi_h u_0 - u_h^0\|_{0,\Omega} + \|(I-\Pi_h)u(t_n)\|_{0,\Omega} \\ + \int_0^{t_n} \left(\left\| (I-\Pi_h) \frac{\mathrm{d}}{\mathrm{d}t} u(s) \right\|_{0,\Omega} + C\delta_t \left\| \frac{\mathrm{d}^2}{\mathrm{d}t^2} u(s) \right\|_{0,\Omega} \right) \mathrm{d}s\end{aligned}$$

En utilisant les résultats d'approximation pour l'opérateur de projection elliptique donnés au lemme 2.1, on déduit de la proposition 2.6 le résultat suivant.

Proposition 2.7 *On suppose qu'il existe $k \in \mathbb{N}^*$ et $C \in \mathbb{R}_+^*$ tel que pour tout $\ell \in \{1, \ldots, k\}$ et pour tout $v \in \mathbb{H}^{\ell+1}(\Omega)$, on ait*

$$\inf_{v_h \in V_h} \left(\|v - v_h\|_{0,\Omega} + h \, |v - v_h|_{1,\Omega} \right) \leqslant C \, h^{\ell+1} \, \|v\|_{\ell+1,\Omega}. \tag{2.39}$$

Si $u \in \mathcal{C}^1([0,T], \mathbb{H}^{\ell+1}(\Omega) \cap \mathcal{C}^2([0,T], \mathbb{L}^2(\Omega))$ avec $\ell \in \{1, \ldots, k\}$ alors, sous la condition de stabilité

$$\delta_t \, \lambda_{h,J} \leqslant 2 \tag{2.40}$$

où δ_t désigne le pas de la discrétisation temporelle et $\lambda_{h,J}$ la plus grande valeur propre introduite à la proposition 2.4, on a

$$\begin{aligned}\|u(t_n) - u_h^n\|_{0,\Omega} \leqslant \|u_0 - u_h^0\|_{0,\Omega} + C \, h^{\sigma(\ell)} \left(\|u_0\|_{\ell+1,\Omega} + \|u(t_n)\|_{\ell+1,\Omega} + \int_0^{t_n} \left\| \frac{\mathrm{d}}{\mathrm{d}t} u(s) \right\|_{\ell+1,\Omega} \mathrm{d}s \right) \\ + C \, \delta_t \int_0^{t_n} \left\| \frac{\mathrm{d}^2}{\mathrm{d}t^2} u(s) \right\|_{0,\Omega} \mathrm{d}s\end{aligned}$$

où $\sigma(\ell) = \ell + 1$ si Ω est polyédrique et convexe et $\sigma(\ell) = \ell$ sinon.

L'hypothèse (2.39) est par exemple satisfaite dans le cas où l'espace V_h est l'espace d'approximation éléments finis de Lagrange de type (k) pour un ouvert Ω polyédrique associé à une famille régulière $(\mathcal{T}_h)_h$ de triangulations de $\overline{\Omega}$ formées de triangles de diamètre inférieur ou égal à h

$$V_h = \{ v \in \mathcal{C}^0(\overline{\Omega}) \ ; \ \forall K \in \mathcal{T}_h \ v_{|_K} \in \mathcal{P}_k(\mathbb{R}^d) \}.$$

Dans le cas le plus favorable, si la condition de stabilité est satisfaite, on obtient dans le cas le plus favorable de régularité une erreur en chaque nœud de discrétisation en temps qui, évaluée dans la norme de $\mathbb{L}^2(\Omega)$, est d'ordre 1 en temps et d'ordre k en espace.

La condition de stabilité (2.40) nécessite de calculer, pour l'espace V_h utilisé, la plus grande valeur propre $\lambda_{h,J}$ de la forme bilinéaire sur V_h définie par $a(u,v) = \int_\Omega \nabla u(x) \cdot \nabla v(x) \, \mathrm{d}x$, voir la proposition 2.4. On ne peut espérer en obtenir une valeur explicite, tout au plus une valeur approchée calculée numériquement. On peut néanmoins montrer que la condition de stabilité (2.40) reliant le pas de la discrétisation spatial h et le pas de la discrétisation temporel δ_t requiert qu'il existe une constante $C > 0$ telle que

$$\frac{\delta_t}{h^2} \leqslant C. \tag{2.41}$$

La condition de stabilité (2.40) impose donc de prendre un pas de temps δ_t très petit devant le pas de la discrétisation en espace, ce qui peut parfois devenir rédhibitoire en temps de calcul. Une alternative est

dans ce cas par exemple d'utiliser un schéma d'Euler implicite au lieu du schéma d'Euler (explicite) que nous avons étudié. On montre alors que le schéma numérique obtenu est inconditionnellement stable. Il reste d'ordre 1 en temps. Une autre possibilité est d'utiliser un schéma de Crank-Nicolson. Ce schéma est également inconditionnellement stable mais il est d'ordre 2 en temps.

Bibliographie

[1] W. Appel, *Mathématiques pour la physique et les physiciens (4e édition)*, H & K, 2008.

[2] S. Balac and L. Chupin, *Analyse et algèbre, cours de mathématiques deuxième année avec exercices corrigés*, Collection Metis Lyon Tech, Presses Polytechnique et Universitaires Romandes, Lausanne, 2007.

[3] S. Balac and F. Sturm, *Algèbre et analyse, cours de mathématiques première année avec exercices corrigés*, Collection Metis Lyon Tech, Presses Polytechnique et Universitaires Romandes, Lausanne, 2014. Troisième édition.

[4] H. Brezis, *Analyse fonctionnelle, théorie et applications*, Collection Mathématiques appliquées pour la maîtrise, Masson, 1988.

[5] P. Raviart and J. Thomas, *Introduction à l'analyse numérique des équations aux dérivées partielles*, Collection Mathématiques appliquées pour la maîtrise, Masson, 1992.

[6] P. Struillou, *Analyse de Fourier : Théorie et applications pour l'ingénieur et le physicien, Cours et exercices corrigés*, Technosup (Paris), Ellipses, 2012.